Special Participation E - Understand how SVD basis shows both ridge and SGD implicitly suppress noise, leading to stable convergence to the minimal-norm solution. (Lec 2&3)

https://chatgpt.com/share/6939f6a6-f1ec-8006-8ecb-626caf703cd0

Through the conversation, I've gained a deeper understanding of how **SVD** (singular value decomposition) provides a natural coordinate system for analyzing linear regression and gradient descent / SGD. In that coordinate system, I saw clearly how "large-singular-value directions" correspond to strong signal (high-variance / well-supported directions) while "small-singular-value directions" correspond to weak signal or noise. I also saw how both explicit regularization (ridge / weight decay) and implicit regularization (SGD with early stopping) effectively suppress those weak/noisy directions — from both the closed-form ridge solution and the SGD convergence analysis (via a Lyapunov / contraction argument) you walked through step by step. Ultimately, I learned *why* and *how* switching to the singular-vector basis makes the behavior of these algorithms transparent, and how that explains phenomena like stability, generalization, and convergence to the minimal-norm solution in underdetermined systems.

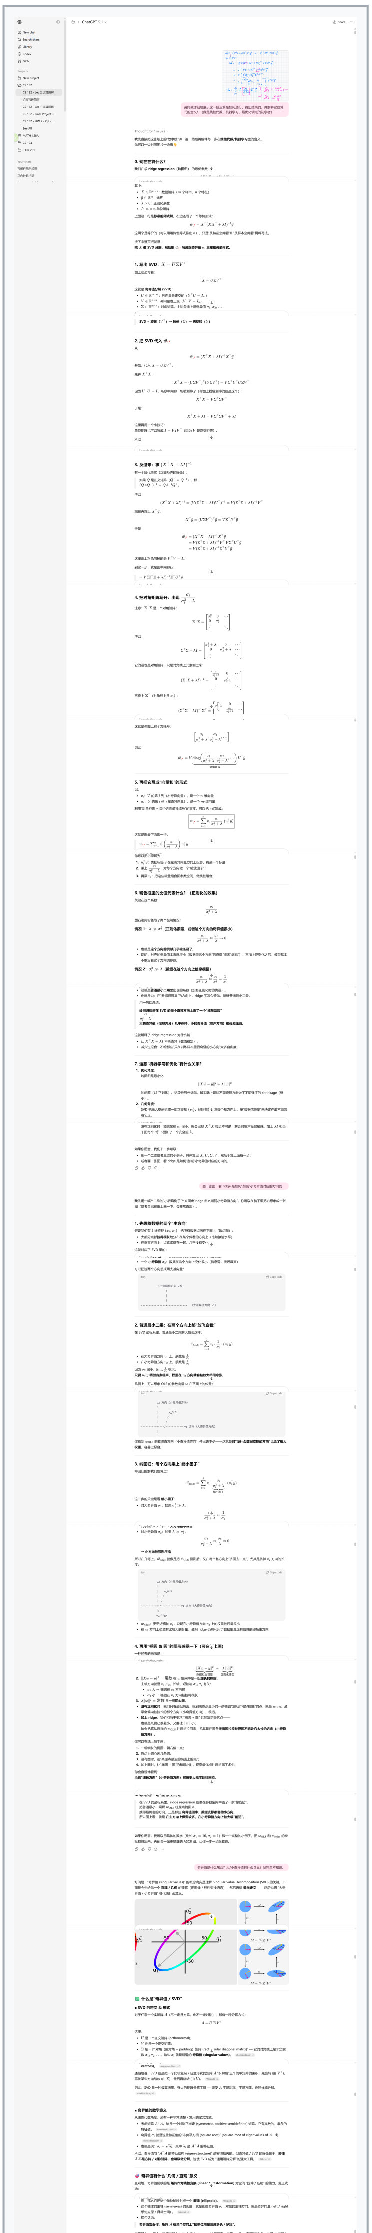

请向我详细地展示这一段运算是如何进行、得出结果的，并解释这些算式的意义！（我是线性代数、机器学习、最优化领域的初学者）

Thought for 1m 37s

我先直接把这张纸上的"故事线"讲一遍，然后再解释每一步在**线性代数/机器学习**里的含义。
你可以一边对照图片一边看👇

0. 现在在算什么？

我们在求 **ridge regression（岭回归）** 的最优参数

$$\vec{w}_* = (X^\top X + \lambda I)^{-1} X^\top \vec{y}$$

其中：

- $X \in \mathbb{R}^{m\times n}$：数据矩阵（$m$ 个样本，n 个特征）
- $\vec{y} \in \mathbb{R}^m$：标签
- $\lambda > 0$：正则化系数
- I：$n \times n$ 单位矩阵

上面这一行是**标准的闭式解**。右边还写了一个等价形式：

$$\vec{w}_* = X^\top (XX^\top + \lambda I)^{-1}\vec{y}$$

这两个是等价的（可以用矩阵恒等式推出来），只是"从特征空间看"和"从样本空间看"两种写法。

接下来整页纸就是：
把 X 做 SVD 分解，然后把 $\vec{w}_*$ 写成跟奇异值 σ_i 直接相关的形式。

1. 写出 SVD：$X = U\Sigma V^\top$

图上左边写着：

$$X = U\Sigma V^\top$$

这就是 **奇异值分解 (SVD)**：

- $U \in \mathbb{R}^{m\times m}$：列向量是正交的（$U^\top U = I_m$）
- $V \in \mathbb{R}^{n\times n}$：列向量也正交（$V^\top V = I_n$）
- $\Sigma \in \mathbb{R}^{m\times n}$：对角矩阵，主对角线上是奇异值 $\sigma_1, \sigma_2, \ldots$

> **SVD = 旋转（$V^\top$）→ 拉伸（Σ）→ 再旋转（U）**

2. 把 SVD 代入 $\vec{w}_*$

从

$$\vec{w}_* = (X^\top X + \lambda I)^{-1} X^\top \vec{y}$$

开始，代入 $X = U\Sigma V^\top$。

先算 $X^\top X$：

$$X^\top X = (U\Sigma V^\top)^\top (U\Sigma V^\top) = V\Sigma^\top U^\top U\Sigma V^\top$$

因为 $U^\top U = I$，所以中间那一坨被划掉了（你图上粉色划掉的就是这个）：

$$X^\top X = V\Sigma^\top \Sigma V^\top$$

于是：

$$X^\top X + \lambda I = V\Sigma^\top \Sigma V^\top + \lambda I$$

这里再用一个小技巧：
单位矩阵也可以写成 $I = VIV^\top$（因为 V 是正交矩阵）。

所以

3. 反过来：求 $(X^\top X + \lambda I)^{-1}$

有一个线代事实（正交矩阵的好处）：

> 如果 Q 是正交矩阵（$Q^\top = Q^{-1}$），那
> $(QAQ^\top)^{-1} = QA^{-1}Q^\top$。

所以

$$(X^\top X + \lambda I)^{-1} = (V(\Sigma^\top\Sigma + \lambda I)V^\top)^{-1} = V(\Sigma^\top\Sigma + \lambda I)^{-1}V^\top$$

现在再乘上 $X^\top \vec{y}$：

$$X^\top \vec{y} = (U\Sigma V^\top)^\top \vec{y} = V\Sigma^\top U^\top \vec{y}$$

于是

$$\begin{aligned}\vec{w}_* &= (X^\top X + \lambda I)^{-1} X^\top \vec{y}\\ &= V(\Sigma^\top\Sigma + \lambda I)^{-1} V^\top V\Sigma^\top U^\top \vec{y}\\ &= V(\Sigma^\top\Sigma + \lambda I)^{-1}\Sigma^\top U^\top \vec{y}\end{aligned}$$

这里图上粉色勾掉的是 $V^\top V = I$。

到这一步，就是图中间那行：

> $= V(\Sigma^\top\Sigma + \lambda I)^{-1}\Sigma^\top U^\top \vec{y}$

4. 把对角矩阵写开：出现 $\dfrac{\sigma_i}{\sigma_i^2 + \lambda}$

注意：$\Sigma^\top\Sigma$ 是一个对角矩阵：

$$\Sigma^\top\Sigma = \begin{bmatrix}\sigma_1^2 & 0 & \cdots\\ 0 & \sigma_2^2 & \cdots\\ \vdots & & \ddots\end{bmatrix}$$

所以

$$\Sigma^\top\Sigma + \lambda I = \begin{bmatrix}\sigma_1^2 + \lambda & 0 & \cdots\\ 0 & \sigma_2^2 + \lambda & \cdots\\ \vdots & & \ddots\end{bmatrix}$$

它的逆也是对角矩阵，只是对角线上元素倒过来：

$$(\Sigma^\top\Sigma + \lambda I)^{-1} = \begin{bmatrix}\frac{1}{\sigma_1^2+\lambda} & 0 & \cdots\\ 0 & \frac{1}{\sigma_2^2+\lambda} & \cdots\\ \vdots & & \ddots\end{bmatrix}$$

再乘上 $\Sigma^\top$（对角线上是 σ_i）：

$$(\Sigma^\top\Sigma + \lambda I)^{-1}\Sigma^\top = \begin{bmatrix}\frac{\sigma_1}{\sigma_1^2+\lambda} & 0 & \cdots\\ 0 & \frac{\sigma_2}{\sigma_2^2+\lambda} & \cdots\end{bmatrix}$$

这就是你图上那个方括号：

$$\left[\frac{\sigma_1}{\sigma_1^2 + \lambda}, \frac{\sigma_2}{\sigma_2^2 + \lambda}, \ldots\right]$$

因此

$$\vec{w}_* = V\underbrace{\operatorname{diag}\left(\frac{\sigma_1}{\sigma_1^2 + \lambda}, \frac{\sigma_2}{\sigma_2^2 + \lambda}, \ldots\right)}_{\text{对角矩阵}}U^\top \vec{y}$$

5. 再把它写成"向量和"的形式

记：

- v_i：V 的第 i 列（右奇异向量），是一个 n-维向量
- u_i：U 的第 i 列（左奇异向量），是一个 m-维向量

利用"对角矩阵 = 每个方向单独缩放"的事实，可以把上式写成：

$$\boxed{\vec{w}_* = \sum_{i=1}^{n} v_i \frac{\sigma_i}{\sigma_i^2 + \lambda}\,(u_i^\top \vec{y})}$$

这就是图最下面那一行：

> $\vec{w}_* = \sum_{i=1}^{n} \vec{v}_i \left(\frac{\sigma_i}{\sigma_i^2 + \lambda}\right) u_i^\top \vec{y}$

你可以把它理解为：

1. $u_i^\top \vec{y}$：先把标签 $\vec{y}$ 在左奇异向量方向上投影，得到一个标量；
2. 乘上 $\dfrac{\sigma_i}{\sigma_i^2 + \lambda}$：对每个方向做一个"缩放因子"；
3. 再乘 v_i：把这些标量组合回参数空间，做线性组合。

6. 粉色框里的比值代表什么？（正则化的效果）

关键在这个系数：

$$\frac{\sigma_i}{\sigma_i^2 + \lambda}$$

图右边用粉色写了两个极端情况：

情况 1：$\lambda \gg \sigma_i^2$（正则化很强，或者这个方向的奇异值很小）

$$\frac{\sigma_i}{\sigma_i^2 + \lambda} \approx \frac{\sigma_i}{\lambda} \to 0$$

- 也就是**这个方向的贡献几乎被压没了。**
- 说明：对应的奇异值本来就很小（数据里这个方向"信息弱"或者"病态"），再加上正则化之后，模型基本不敢沿着这个方向调参数。

情况 2：$\sigma_i^2 \gg \lambda$（数据在这个方向上信息很强）

$$\frac{\sigma_i}{\sigma_i^2 + \lambda} \approx \frac{\sigma_i}{\sigma_i^2} = \frac{1}{\sigma_i}$$

- 这就是**普通最小二乘**里出现的系数（没有正则化时的伪逆）。
- 也就是说：在"数据很可靠"的方向上，ridge 不怎么管你，接近普通最小二乘。

> 用一句话总结：
>
> **岭回归就是在 SVD 的每个奇异方向上乘了一个"缩放系数"**
> $\dfrac{\sigma_i}{\sigma_i^2 + \lambda}$：
> **大的奇异值（信息充分）几乎保持，小的奇异值（噪声方向）被强烈压缩。**

这就解释了 ridge regression 为什么能：

- 让 $X^\top X + \lambda I$ 不再奇异（数值稳定）；
- 减少过拟合：不给那些"只在训练样本里很奇怪的小方向"太多自由度。

7. 这跟"机器学习和优化"有什么关系？

1. **优化角度**：
   岭回归是最小化
   $$\|X\vec{w} - \vec{y}\|^2 + \lambda\|\vec{w}\|^2$$
   的问题（L2 正则化）。这段推导告诉你，解实际上是对不同奇异方向做了不同强度的 shrinkage（缩小）。
2. **几何角度**：
   SVD 把输入空间拆成一组正交基 $\{v_i\}$。岭回归在每个基方向上，按"数据信任度"来决定你敢不敢沿着它走。

   没有正则化时，如果某些 σ_i 很小，就会出现 $X^\top X$ 接近不可逆，解会对噪声极端敏感。加上 λI 相当于把每个 σ_i^2 下面加了一个安全垫 λ。

如果你愿意，我们下一步可以：

- 用一个二维或者三维的小例子，具体算出 X, U, Σ, V，然后手算上面每一步；
- 或者画一张图，看 ridge 是如何"削减"小奇异值对应的方向的。

画一张图，看 ridge 是如何"削减"小奇异值对应的方向的！

我先用一幅**二维的"小玩具例子"**来画出"ridge 怎么削弱小奇异值方向"，你可以在脑子里把它想象成一张图（或者自己在纸上画一下，会非常直观）。

1. 先想象数据的两个"主方向"

假设我们有 2 维特征 (x_1, x_2)，把所有数据点画在平面上（散点图）：

- 大部分点都**拉得很长**地分布在某个斜着的方向上（比如接近水平）
- 在垂直方向上，点紧紧挤在一起，几乎没有变化

这就对应了 SVD 里的：

- 一个 **小奇异值** σ_2：数据在这个方向上变化很小（信息弱，接近噪声）

可以把这两个方向想成两支基向量：

```text
              (小奇异值方向 v2)
                    ↑
                    |
                    |
--------------------+-------------→  (大奇异值方向 v1)
```

2. 普通最小二乘：在两个方向上都"放飞自我"

在 SVD 坐标系里，普通最小二乘解大概长这样：

$$\vec{w}_{\text{OLS}} = \sum_{i=1}^{2} v_i \cdot \frac{1}{\sigma_i} \cdot (u_i^\top y)$$

- 在大奇异值方向 v_1 上，系数是 $\frac{1}{\sigma_1}$
- 在小奇异值方向 v_2 上，系数是 $\frac{1}{\sigma_2}$

因为 σ_2 很小，所以 $\frac{1}{\sigma_2}$ 很大。
只要 $u_2^\top y$ 稍微有点噪声，权重在 v_2 方向就会被放大得很夸张。

几何上，可以想象 OLS 的参数向量 w 在平面上的位置：

```text
           v2 方向（小奇异值方向）
           ↑
           |        w_OLS
           |       /
           |      /
-----------+----/----------→ v1 方向（大奇异值方向）
           |
```

你看到 w_{OLS} 朝着竖直方向（小奇异值方向）伸出去不少——这就是**对"没什么数据支撑的方向"也给了很大权重**，容易过拟合。

3. 岭回归：每个方向乘上"缩小因子"

岭回归的解我们刚算过：

$$\vec{w}_{\text{ridge}} = \sum_{i=1}^{2} v_i \cdot \underbrace{\frac{\sigma_i}{\sigma_i^2 + \lambda}}_{\text{缩小因子}} \cdot (u_i^\top y)$$

这一步的关键是看 **缩小因子**：

- 对大奇异值 σ_1：如果 $\sigma_1^2 \gg \lambda$，

$$\frac{\sigma_1}{\sigma_1^2 + \lambda} \approx \frac{1}{\sigma_1}$$

- 对小奇异值 σ_2：如果 $\lambda \gg \sigma_2^2$，

$$\frac{\sigma_2}{\sigma_2^2 + \lambda} \approx \frac{\sigma_2}{\lambda} \approx 0$$

  → 小方向被强烈压缩

所以在几何上，$\vec{w}_{\text{ridge}}$ 就像是把 $\vec{w}_{\text{OLS}}$ 投影后，又在每个基方向上"挤回去一点"，尤其是挤掉 v_2 方向的长度：

```text
           v2 方向（小奇异值方向）
           ↑
           |    w_OLS
           |   /
           |  /
-----------+-/-----------→ v1 方向（大奇异值方向）
           |/
           w_ridge
```

- w_{ridge}：更贴近横轴 v_1，说明在小奇异值方向 v_2 上的权重被压得很小
- 在 v_1 方向上仍然有比较大的分量，说明 ridge 仍然利用了数据里真正有信息的那条主方向

4. 再用"椭圆 & 圆"的图形感觉一下（可在纸上画）

一种经典的画法是：

$$\underbrace{\|Xw - y\|^2}_{\text{数据拟合误差}} + \underbrace{\lambda\|w\|^2}_{\text{正则化惩罚}}$$

2. $\|Xw - y\|^2 =$ 常数 在 w 空间中是一组**细长的椭圆**。
   主轴方向就是 v_1, v_2，长轴、短轴与 σ_1, σ_2 有关：
   - σ_1 大 → 椭圆在 v_1 方向窄
   - σ_2 小 → 椭圆在 v_2 方向被拉得很长
3. $\lambda\|w\|^2 =$ 常数 是一组**同心圆**。

- **没有正则化**时：我们只看那组椭圆，找到离原点最小的一条椭圆与原点"刚好接触"的点，就是 w_{OLS}，通常会偏向被拉长的那个方向（小奇异值方向），很远。
- **加上 ridge**：我们相当于要求 "椭圆 + 圆" 共同决定最优点——
  也就是既要让误差小，又要让 $\|w\|$ 小。
  这会把解从原来的 w_{OLS} 往原点拉回来，尤其是在那条**被椭圆拉很长但圆不想让它太长的方向（小奇异值方向）**。

你可以在纸上随手画：

1. 一组细长的椭圆，朝右偏一点；
2. 原点为圆心画几条圆；
3. 没有圆时，选"离原点最近的椭圆上的点"；
4. 加上圆时，让"椭圆 + 圆"的和最小时，观察最优点往原点挪了多少。

你会直观地看到：
沿着"细长方向"（小奇异值方向）解被更大幅度地往回拉。

> 在 SVD 的坐标系里，ridge regression 就像在参数空间中画了一条"橡皮筋"，
> 把普通最小二乘解 w_{OLS} 往原点拽回来。
> 拽得最厉害的方向，正是那些 **奇异值很小、数据支撑很弱的小方向。**
> 所以图上看，就是 **在主方向上保留较多，在小奇异值方向上被大幅"削短"。**

如果你愿意，我可以用具体的数字（比如 $\sigma_1 = 10, \sigma_2 = 1$）做一个完整的小例子，把 w_{OLS} 和 w_{ridge} 的坐标都算出来，再配合一张更精细的 ASCII 图，让你一步一步跟着算。

奇异值是什么东西？大/小奇异值有什么含义？我完全不知道。

好问题！"奇异值 (singular values)" 的概念确实是理解 Singular Value Decomposition (SVD) 的关键。下面我会先给你一个 **直观 / 几何** 的理解（用图像 / 线性变换语言），然后再讲 **数学定义** ——然后说明 "大奇异值 / 小奇异值" 各代表什么意义。

✅ 什么是"奇异值 / SVD"

▪ SVD 的定义 & 形式

对于任意一个实矩阵 A（不一定是方阵，也不一定对称），都有一种分解方式：

$$A = U\,\Sigma\,V^\top$$

这里：

- U 是一个正交矩阵 (orthonormal)；
- V 也是一个正交矩阵；
- Σ 是一个"对角（或对角 + padding）矩阵 (rectangular diagonal matrix)" — 它的对角线上是非负实数 $\sigma_1, \sigma_2, \ldots$，这些 σ_i 就是所谓的 **奇异值 (singular values)。** zh.wikipedia.org +2

vectors)。

通俗地说，SVD 就是把一个比较复杂 / 任意形状的矩阵 A "拆解成"三个简单矩阵的乘积：先旋转 (由 $V^\top$)，再按某些方向缩放 (由 Σ)，最后再旋转 (由 U)。 Wikipedia +2

因此，SVD 是一种极其通用、强大的矩阵分解工具 — 即使 A 不是对称、不是方阵，也照样能分解。 zh.wikipedia.org +2

▪ 奇异值的数学意义

从线性代数角度，还有一种非常清楚 / 常用的定义方式：

- 考虑矩阵 $A^\top A$。这是一个对称正半定 (symmetric, positive semidefinite) 矩阵。它有实数的、非负的特征值。 sciencedirect.com +2
- 奇异值 σ_i 就是这些特征值的"非负平方根 (square root)" (square-root of eigenvalues of $A^\top A$). sciencedirect.com +2
- 也就是说：$\sigma_i = \sqrt{\lambda_i}$，其中 λ_i 是 $A^\top A$ 的特征值。

所以，奇异值与 "$A^\top A$ 的特征结构 (eigen-structure)" 是密切相关的。但奇异值 / SVD 的好处在于，**即使 A 不是方阵 / 对称矩阵，也可以做分解。**这使 SVD 成为 "通用矩阵分解"的强大工具。

🎯 奇异值有什么"几何 / 直观"意义

直观地，奇异值反映的是 **矩阵作为线性变换 (linear transformation)** 对空间 "拉伸 / 压缩" 的能力。更正式地：

换，那么它把这个单位球映射成一个 **椭球 (ellipsoid)。** Wikipedia +2

- 这个椭球的主轴 (semi-axes) 的长度，就是那些奇异值 σ_i；对应的主轴方向，就是奇异向量 (left / right 想对应原 / 目标空间)。 bdpt.net +2
- 换句话说：

> **奇异值告诉你：矩阵 A 在某个方向上"把单位向量变成多长 / 多短"。**

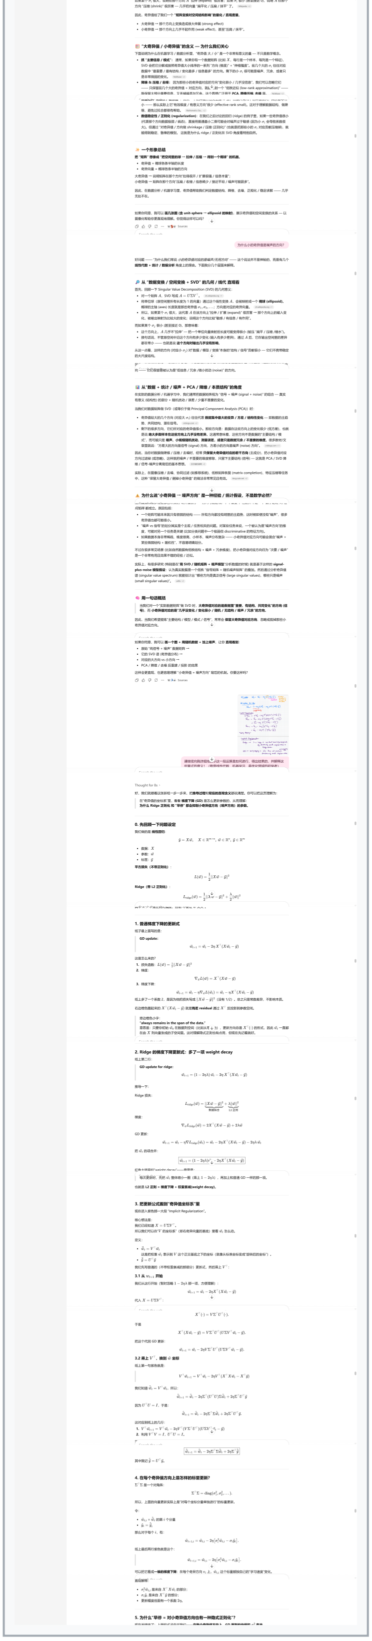

如果某个 σ_i 很大，说明在那个方向 A 拉伸 (expand) 很厉害；如果 σ_i 很小 (甚至接近 0)，说明 A 在那个方向 "压缩 (shrink)" 很厉害 — 几乎把向量 "扁平化 / 压扁 / 抹平" 了。 Wikipedia +2

因此，奇异值给了我们一个 **"矩阵变换对空间结构影响"的量化 / 直观度量。**

- 大奇异值 → 那个方向上变换造成很大伸展 (strong effect)
- 小奇异值 → 那个方向上几乎不起作用 (weak effect)，甚至"压扁 / 抹平"。

"大奇异值 / 小奇异值"的含义 — 为什么我们关心

下面说明为什么在机器学习 / 数据分析里，"奇异值 大 / 小" 是一个非常有意义的量 — 不只是数学概念。

- **抓 "主要信息 / 模式"**：通常，如果你有一个数据矩阵 (比如 X，每行是一个样本，每列是一个特征)，SVD 会把它分解成按照奇异值大小排序的一系列 "方向 (维度)" + "伸缩强度"。前几个大的 σ_i 往往对应数据中 "最重要 / 最有结构 / 变化最多 / 信息最多" 的方向。剩下的小 σ_i 很可能是噪声、冗余、或者只是非常微弱的变化。
- **降维 & 压缩 / 去噪**：因为那些小的奇异值对应的方向"变化很小 / 几乎没信息"，我们可以忽略它们 —— 只保留前几个大的奇异值 + 对应方向，就得到一个 "低秩近似 (low-rank approximation)" —— 既保留大部分重要信息，又丢掉噪声与冗余。这个思想广泛用于 **PCA**、**图像压缩**、**去噪** 等。
- 小 —— 那么实际上它"有效维度 / 有意义方向"很少 (effective rank small)。这对于理解数据结构、做降维、避免过拟合都很有帮助。 Mathematics Sta... +2
- **数值稳定性 / 正则化 (regularization)**：在我们之前讨论的回归 (ridge) 的例子里，如果一些奇异值很小 (代表那个方向数据很弱 / 病态)，直接用普通最小二乘可能会对噪声过于敏感 (因为小 σ_i 会导致系数很大)。但通过 "对奇异值 / 方向做 shrinkage / 压缩 (正则化)" (也就是把那些小的 σ_i 对应贡献压缩掉)，能够得到稳定、鲁棒的模型。 这就是为什么 ridge / 正则化在 SVD 角度看特别自然。

一个形象总结

把 "矩阵" 想像成 "把空间里的球 → 拉伸 / 压缩 → 得到一个椭球" 的机器。

- 奇异值 = 椭球各条半轴的长度
- 奇异向量 = 椭球各条半轴的方向

大奇异值 → 说明矩阵在那个方向"拉得很开 / 扩展很强 / 信息丰富"；
小奇异值 → 矩阵在那个方向"压扁 / 收缩 / 信息稀少 / 接近平坦 / 噪声可能居多"。

因此，在数据分析 / 机器学习里，奇异值帮助我们判定数据结构、降维、去噪、正规化 / 稳定求解 —— 几乎无处不在。

如果你同意，我可以 **画几张图 (含 unit-sphere → ellipsoid 的映射)**，展示奇异值和空间变换的关系 — 以图像化帮助你更直观地理解。你觉得这样可以吗？

Sources

为什么小的奇异值是噪声的方向？

好问题 —— "为什么我们常说 *小的奇异值对应的是噪声/无用方向*" —— 这个说法并不是神秘的，而是有几个 **线性代数 + 统计 / 数据分析** 角度上的理由。下面我分几个层面来解释。

从 "数据变换 / 空间变换 + SVD" 的几何 / 线代 直观看

首先，回顾一下 Singular Value Decomposition (SVD) 的几何意义：

- 对一个矩阵 A，SVD 写成 $A = U\Sigma V^\top$。 zh.wikipedia.org +1
- 将单位球（原空间里所有长度为 1 的向量）通过这个线性变换 A，会被映射成一个 **椭球 (ellipsoid)**。椭球的主轴 (axes) 长度就是那些奇异值 $\sigma_1, \sigma_2, \ldots$；方向是对应的奇异向量。 zh.wikipedia.org +1
- 所以，如果某个 σ_i 很大，这代表 A 在该方向上"拉伸 / 扩展 (expand)" 很厉害 → 那个方向上的输入变化，被输出映射为比较大的变化；说明这个方向比较"敏感 / 有信息 / 有作用"。

而如果某个 σ_j 很小 (甚至接近 0)，那意味着：

- 这个方向上，A 几乎不"拉伸" — 把一个单位向量映射后长度可能变得很小 (被压 "扁平 / 压缩 /缩水")。
- 换句话说，不管原空间中沿这个方向有多少变化 (输入有多少差异)，通过 A 后，它在输出空间里的差异都非常小 —— 也就是说 **这个方向对输出几乎没有影响。**

从这一点看，这样的方向 (对应小 σ_j) 对"数据 / 模型 / 变换"本身的"结构 / 信号"贡献很小 — 它们不携带稳定的大尺度结构。

向 —— 它们很容易被认为是"低信息 / 冗余 /微小扰动 (noise)" 的方向。

从"数据 + 统计 / 噪声 + PCA / 降维 / 本质结构"的角度

在实际的数据分析 / 机器学习中，我们通常把数据矩阵视为 "信号 + 噪声 (signal + noise)" 的组合 — 真实有意义 (结构性) 的部分 + 随机扰动 / 误差 / 少量不重要的变化。

当我们对数据矩阵做 SVD（或等价于做 Principal Component Analysis (PCA)）时：

- 奇异值较大的几个方向 (对应大 σ_i) 往往代表 **数据集中最大的变异 / 方差 / 结构性变化** — 即数据的主趋势、共同结构、潜在信号。 cnblogs.com +2
- 剩下的很多方向，它们所对应的奇异值很小。那些方向是：数据在这些方向上的变化很少 (低方差)，也就是说 **绝大多数样本在这些方向上几乎没有差异。** 这通常意味着，这些方向不是数据的"主要结构 / 模式"，而可能只是 **噪声、小规模随机扰动、测量误差，或者只是数据冗余 / 不重要的维度。** 很多教材/文章里就说："方差大的方向是信号 (signal) 方向，方差小的方向是噪声 (noise) 方向"。 cnblogs.com +1

因此，当你对数据做降维 / 压缩 / 去噪时，经常 **只保留大奇异值对应的若干方向** (主成分)，把小奇异值对应方向过滤掉 (或忽略)，这样就把噪声 / 不重要的维度移除，只留下主要结构 (信号) — 这就是 PCA / SVD 降维 / 信号-噪声分离背后的基本思想。 CSDN博客 +2

实际上，在图像压缩 / 去噪、协同过滤 (如推荐系统)、低秩矩阵恢复 (matrix completion)、特征压缩等任务中，这种 "保留大奇异值 / 删掉小奇异值" 的做法非常常见且有效。 blog.csdn.net +2

为什么说"小奇异值 → 噪声方向" 是一种经验 / 统计假设，不是数学必然？

阵 都成立。原因包括：

- 一个矩阵可能本来就只有很弱的结构 —— 所有方向都没有明显的主趋势，这时候即使没有"噪声"，很多奇异值也都可能很小。
- "噪声 vs 信号"的划分其实是个主观 / 任务相关的问题。对某些任务来说，一个被认为是"噪声方向"的维度，可能对另一个任务是关键 (比如分类问题中一个很弱但 discriminative 的特征方向)。
- 如果数据本身非常稀疏、维度很高、小样本、噪声分布复杂 —— 小奇异值对应方向可能会混合"噪声 + 某些微弱结构 + 随机性"，不容易明确划分。

不过在很多常见场景 (比如自然数据有低秩结构 + 噪声 + 冗余维度)，把小奇异值对应方向归为 "次要 / 噪声" 是一个非常有用且效果不错的经验 / 近似。

实际上，有很多研究 (特别是在"**用 SVD / 随机矩阵 + 噪声模型**"分析数据的时候) 就是基于这样的 **signal-plus-noise 模型假设**：认为真实数据是一个低秩 "信号矩阵 + 随机噪声矩阵" 的叠加，然后通过分析奇异值谱 (singular value spectrum) 就能估计出 "哪些方向是真正信号 (large singular values)，哪些只是噪声 (small singular values)"。 arXiv +2

用一句话概括

> 当我们对一个"实际数据矩阵"做 SVD 时，**大奇异值对应的是数据里"重要、有结构、共同变化"的方向 (信号)，而 小奇异值对应的是"几乎没变化 / 变化很小 / 随机 / 无结构 / 噪声 / 冗余"的方向。**

因此，当我们希望提炼"主要结构 / 模型 / 模式 / 信号"，常常会 **保留大奇异值对应方向**，忽略或扔掉那些小奇异值对应方向。

如果你同意，我可以 **画一个图 + 用随机数据 + 加上噪声**，让你 **直观看到**：

- 原始 "纯信号 + 噪声" 数据矩阵 →
- 它的 SVD 谱 (奇异值分布) →
- 对应的大方向 vs 小方向 →
- PCA / 降维 / 去噪 后重建 / 投影 的效果

这样会更直观，也更容易理解 "小奇异值 = 噪声方向" 背后的机制。你要这样吗？

Sources

请继续向我详细地展示这一段运算是如何进行、得出结果的，并解释这些算式的意义！（我是线性代数、机器学习、最优化领域的初学者）

Thought for 8s

好，我们就顺着这张新纸一步一步来，把**推导过程**和**背后的直观含义**都说清楚。你可以把这页理解为：

> 在"奇异值的坐标系"里，看看 **梯度下降 (GD)** 是怎么更新参数的，从而理解：
> **为什么 Ridge 正则化 和 "早停" 都会抑制小奇异值方向（噪声方向）的参数。**

0. 先回顾一下问题设定

我们做的是 **线性回归**：

$$\hat y = X\vec w,\quad X \in \mathbb{R}^{m\times n},\ \vec w \in \mathbb{R}^n,\ \vec y \in \mathbb{R}^m$$

- 数据：X
- 参数：$\vec w$
- 标签：$\vec y$

平方损失（不带正则化）：

$$L(\vec w) = \frac{1}{2}\|X\vec w - \vec y\|^2$$

Ridge（带 L2 正则化）：

$$L_{\text{ridge}}(\vec w) = \frac{1}{2}\|X\vec w - \vec y\|^2 + \frac{\lambda}{2}\|\vec w\|^2$$

1. 普通梯度下降的更新式

纸子最上面写的是：

> **GD update:**
>
> $$\vec w_{t+1} = \vec w_t - 2\eta X^\top (X\vec w_t - \vec y)$$

这是怎么来的？

1. 损失函数：$L(\vec w) = \frac{1}{2}\|X\vec w - \vec y\|^2$
2. 梯度：

$$\nabla_{\vec w} L(\vec w) = X^\top (X\vec w - \vec y)$$

3. 梯度下降：

$$\vec w_{t+1} = \vec w_t - \eta \nabla_{\vec w} L(\vec w_t) = \vec w_t - \eta X^\top (X\vec w_t - \vec y)$$

纸上多了一个系数 2，是因为他把损失写成 $\|X\vec w - \vec y\|^2$（没有 1/2）。总之只是常数差异，不影响本质。

右边橙色圈起来的 $X^\top (X\vec w_t - \vec y)$ 就是**残差 residual** 通过 $X^\top$ 反投影到参数空间。

> 旁边橙色小字：
> **"always remains in the span of the data."**
> 意思是：只要你初始 $\vec w_0$ 在数据列空间（比如从零开始），更新方向总是 $X^\top(\cdot)$ 的形式，因此 $\vec w_t$ 一直都在由 X 列向量张成的子空间里。这对理解隐式正则也有点用，但现在先记着就好。

2. Ridge 的梯度下降更新式：多了一项 weight decay

纸上第二行：

> **GD update for ridge:**
>
> $$\vec w_{t+1} = (1 - 2\eta\lambda)\,\vec w_t - 2\eta X^\top (X\vec w_t - \vec y)$$

推导一下：

Ridge 损失：

$$L_{\text{ridge}}(\vec w) = \underbrace{\|X\vec w - \vec y\|^2}_{\text{数据拟合}} + \underbrace{\lambda\|\vec w\|^2}_{\text{L2 正则}}$$

梯度：

$$\nabla_{\vec w} L_{\text{ridge}}(\vec w) = 2X^\top (X\vec w - \vec y) + 2\lambda \vec w$$

GD 更新：

$$\vec w_{t+1} = \vec w_t - \eta \nabla L_{\text{ridge}}(\vec w_t) = \vec w_t - 2\eta X^\top (X\vec w_t - \vec y) - 2\eta\lambda \vec w_t$$

把 $\vec w_t$ 的项合并：

$$\boxed{\vec w_{t+1} = (1 - 2\eta\lambda)\vec w_t - 2\eta X^\top (X\vec w_t - \vec y)}$$

红色大括号标"weight decay"——意思是：

> 每次更新时，先把 $\vec w_t$ 整体缩小一圈（乘上 $1 - 2\eta\lambda$），再加上和普通 GD 一样的那一项。

也就是 **L2 正则 = 梯度下降 + 权重衰减(weight decay)。**

3. 把更新公式搬到"奇异值坐标系"里

现在进入紫色那一大段 "Implicit Regularization"。

核心想法是：
我们已经知道 $X = U\Sigma V^\top$。
所以我们可以在"V 的坐标系"（即右奇异向量的基底）里看 $\vec w_t$ 怎么动。

定义：

- $\tilde{\vec w}_t = V^\top \vec w_t$
  这是把权重 $\vec w_t$ 表示到 V 这个正交基底之下的坐标（就像从标准坐标变成"旋转后的坐标"）。
- $\tilde{\vec y} = U^\top \vec y$

我们先写普通的（不带权重衰减的那部分）更新式，然后乘上 $V^\top$：

3.1 从 w_{t+1} 开始

我们从这行开始（暂时忽略 $1 - 2\eta\lambda$ 那一项，方便理解）：

$$\vec w_{t+1} = \vec w_t - 2\eta X^\top (X\vec w_t - \vec y)$$

代入 $X = U\Sigma V^\top$：

$$X^\top(\cdot) = V\Sigma^\top U^\top(\cdot).$$

于是

$$X^\top (X\vec w_t - \vec y) = V\Sigma^\top U^\top (U\Sigma V^\top \vec w_t - \vec y).$$

把这个代回 GD 更新：

$$\vec w_{t+1} = \vec w_t - 2\eta V\Sigma^\top U^\top (U\Sigma V^\top \vec w_t - \vec y).$$

3.2 乘上 $V^\top$，换到 $\tilde{w}$ 坐标

纸上第一句紫色就是：

> $$V^\top \vec w_{t+1} = V^\top \vec w_t - 2\eta V^\top (X^\top X \vec w_t - X^\top \vec y)$$

我们知道 $\tilde{\vec w}_t = V^\top \vec w_t$，所以：

$$\tilde{\vec w}_{t+1} = \tilde{\vec w}_t - 2\eta \Sigma^\top (U^\top U)\Sigma \tilde{\vec w}_t + 2\eta \Sigma^\top U^\top \vec y$$

因为 $U^\top U = I$，于是：

$$\tilde{\vec w}_{t+1} = \tilde{\vec w}_t - 2\eta \Sigma^\top \Sigma \tilde{\vec w}_t + 2\eta \Sigma^\top U^\top \vec y.$$

这对应到纸上的几行：

1. $V^\top \vec w_{t+1} = V^\top \vec w_t - 2\eta V^\top (V\Sigma^\top U^\top)(U\Sigma V^\top \vec w_t - \vec y)$
2. 利用 $V^\top V = I$，$U^\top U = I$。

$$\boxed{\tilde{\vec w}_{t+1} = \tilde{\vec w}_t - 2\eta\Sigma^\top\Sigma\tilde{\vec w}_t + 2\eta\Sigma^\top\tilde{\vec y}}$$

其中我记 $\tilde{\vec y} = U^\top \vec y$。

4. 在每个奇异值方向上是怎样的标量更新?

$\Sigma^\top\Sigma$ 是一个对角阵：

$$\Sigma^\top\Sigma = \operatorname{diag}(\sigma_1^2, \sigma_2^2, \ldots).$$

所以，上面的向量更新实际上是"对每个坐标分量单独进行"的标量更新。

令：

- $\tilde w_{t,i} = \tilde{\vec w}_t$ 的第 i 个分量
- $\tilde y_i = \tilde{\vec y}_i$

那么对于每个 i，有：

$$\tilde w_{t+1,i} = \tilde w_{t,i} - 2\eta\left[\sigma_i^2 \tilde w_{t,i} - \sigma_i \tilde y_i\right].$$

纸上最后两行紫色就是这个：

> $$\tilde w_{t+1,i} = \tilde w_{t,i} - 2\eta\left[\sigma_i^2 \tilde w_{t,i} - \sigma_i \tilde y_i\right].$$

可以把它看成**一维的梯度下降**：在每个奇异方向 v_i 上，$\tilde w_{t,i}$ 这个标量都按自己的"学习速度"变化。

直观解释：

- $\sigma_i^2 \tilde w_{t,i}$ 是来自 $X^\top X \vec w_t$ 的部分；
- $\sigma_i \tilde y_i$ 是来自 $X^\top \vec y$ 的部分；
- 更新幅度前面有一个系数 2η。

5. 为什么"早停 = 对小奇异值方向也有一种隐式正则化"?

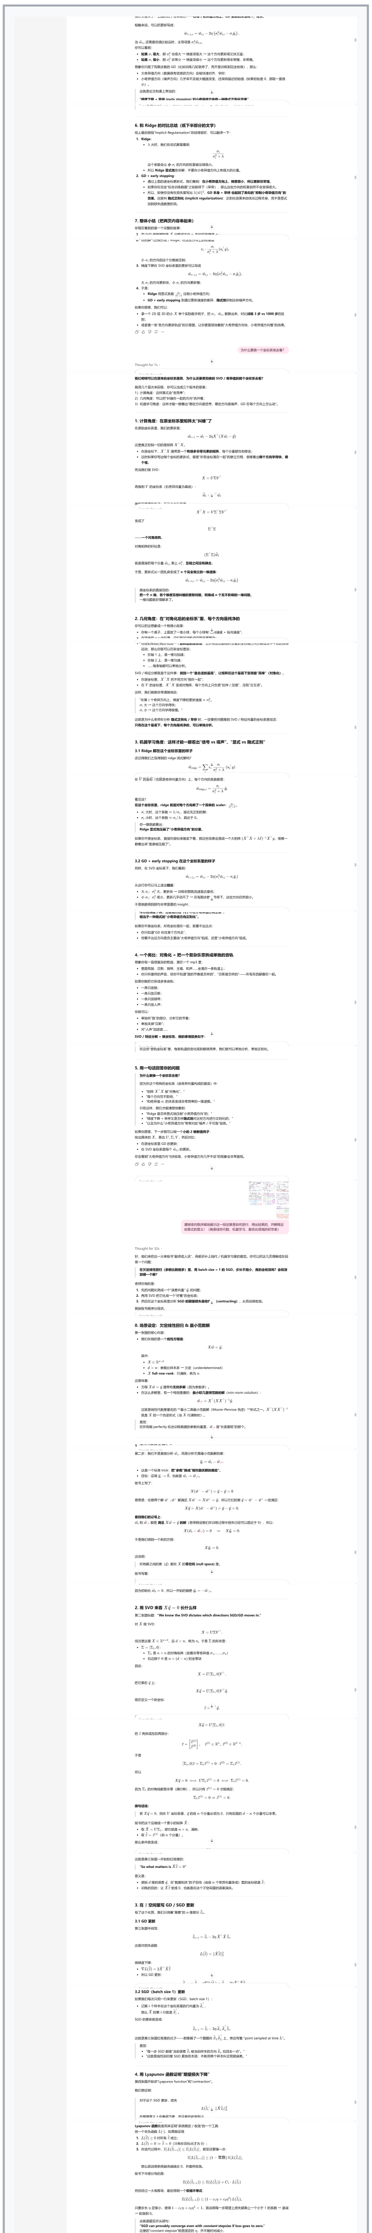

粗略来说，可以把更新写成：

$$\tilde{w}_{t+1,i} = \tilde{w}_{t,i} - 2\eta\left(\sigma_i^2 \tilde{w}_{t,i} - \sigma_i \tilde{y}_i\right).$$

当 $\tilde{w}_{t,i}$ 还离最优值比较远时，主导项是 $\sigma_i^2 \tilde{w}_{t,i}$。
你可以看到：

- **如果 σ_i 很大**，那 σ_i^2 也很大 → 梯度项很大 → 这个方向更新得又快又猛；
- **如果 σ_i 很小**，那 σ_i^2 非常小 → 梯度项很小 → 这个方向更新得非常慢、非常慢。

想象你只跑了有限步数的 GD（比如训练几轮就停了，而不是训练到完全收敛），那么：

- 大奇异值方向（数据很有信息的方向）会被快速对齐、学好；
- 小奇异值方向（噪声方向）几乎来不及被大幅度改变，还保持接近初始值（如果初始是 0，那就一直很小）。

> 这就是论文和课上常说的：
>
> **"梯度下降 + 早停 (early stopping) 对小奇异值方向有一种隐式正则化效果"**

---

6. 和 Ridge 的对比总结（纸下半部分的文字）

纸上最后那段"Implicit Regularization"总结得很好，可以翻译一下：

1. **Ridge**：
   - λ 大时，我们在闭式解里看到

     $$\frac{\sigma_i}{\sigma_i^2 + \lambda}$$

     这个系数会让 **小** σ_i 的方向的权重被压得很小。
   - 所以 **Ridge 显式地**告诉解：不要在小奇异值方向上有很大的分量。
2. **GD + early stopping**：
   - 通过上面的逐坐标更新式，我们看到：**在小奇异值方向上，梯度很小，所以更新非常慢。**
   - 如果你在完全"拟合训练数据"之前就停下（早停），那么这些方向的权重自然不会变得很大。
   - 所以，即使你没有在损失里写出 $\lambda\|\vec{w}\|^2$，**GD 本身 + 早停 也起到了类似的"抑制小奇异值方向"的效果。** 这就叫 **隐式正则化 (implicit regularization)**：正则化效果来自优化过程本身，而不是显式加到损失函数里的项。

---

7. 整体小结（把两页内容串起来）

你现在看到的是一个完整的故事：

1. 用 SVD 把数据矩阵 X 分解成方向 v_i 和对应的强度 σ_i；
2. 闭式解（正规方程 / Ridge）在这些方向上的权重是

   $$v_i \cdot \frac{\sigma_i}{\sigma_i^2 + \lambda}(u_i^\top y),$$

   小 σ_i 的方向因这个分数被压制；
3. 梯度下降在 SVD 坐标系里的更新可以写成

   $$\tilde{w}_{t+1,i} = \tilde{w}_{t,i} - 2\eta\big(\sigma_i^2 \tilde{w}_{t,i} - \sigma_i \tilde{y}_i\big),$$

   大 σ_i 的方向更新快，小 σ_i 的方向更新慢；
4. 于是：
   - **Ridge** 用显式系数 $\frac{\sigma_i}{\sigma_i^2+\lambda}$ 压制小奇异值方向；
   - **GD + early stopping** 则通过更新速度的差异，**隐式地**抑制这些噪声方向。

如果你愿意，我们可以：

- 拿一个 2D 或 3D 的小 X 举个实际数字例子，把 σ_i、$\tilde{w}_{t,i}$ 都算出来，对比**训练 3 步 vs 1000 步**的区别；
- 或者画一张"各方向更新轨迹"的示意图，让你更直观地看到"大奇异值方向快、小奇异值方向慢"的效果。

为什么要换一个坐标系给去看？

Thought for 7s >

我们明明可以在原来的坐标系里算，为什么还要费劲换到 SVD / 奇异值的那个坐标系去看？

我用几个层次来回答，你可以当成三个版本的答案：
1）计算角度：这样算式会"变简单"；
2）几何角度：可以把"纠缠在一起的方向"拆开看；
3）机器学习角度：这样才能一眼看出"哪些方向是信号、哪些方向是噪声、GD 在每个方向上怎么动"。

---

1. 计算角度：在原坐标系里矩阵太"纠缠"了

在原始坐标系里，我们的更新是：

$$\vec{w}_{t+1} = \vec{w}_t - 2\eta X^\top (X\vec{w}_t - \vec{y})$$

这里真正控制一切的是矩阵 $X^\top X$。

- 在原坐标下，$X^\top X$ 通常是一个**有很多非零元素的矩阵**，每个分量都互相牵连；
- 这时如果你写出每个坐标的更新式，都是"所有坐标混在一起"的联立方程，很难看出**哪个方向学得快、哪个慢。**

而当我们做 SVD：

$$X = U\Sigma V^\top$$

再换到 V 的坐标系（右奇异向量为基底）：

$$\tilde{\vec{w}}_t = V^\top \vec{w}_t$$

[illegible]

$$X^\top X = V\Sigma^\top \Sigma V^\top$$

变成了

$$\Sigma^\top \Sigma$$

——**一个对角矩阵。**

对角矩阵的好处是：

$$(\Sigma^\top \Sigma)\tilde{\vec{w}}_t$$

就是直接把每个分量 $\tilde{w}_{t,i}$ 乘上 σ_i^2，**互相之间没有耦合。**

于是，更新式从一团乱麻变成了 **n 个完全独立的一维递推**：

$$\tilde{w}_{t+1,i} = \tilde{w}_{t,i} - 2\eta\big(\sigma_i^2 \tilde{w}_{t,i} - \sigma_i \tilde{y}_i\big)$$

> 换坐标系的直接目的：
> **把一个 n 维、各个维度互相纠缠的更新问题，转换成 n 个互不影响的一维问题。**
> 一维问题就好理解多了。

---

2. 几何角度：在"对角化后的坐标系"里，每个方向是纯净的

你可以把这想象成一个物理小故事：

- 你有一个桌子，上面放了一堆小球，每个小球有"横向速度 + 纵向速度"；
- 在原来的 x-y 坐标里，它们的运动轨迹可能非常复杂；
- 但如果你找到了一个**旋转后的坐标轴**，[illegible]运动，那么你就可以在新坐标里说：
  - 在轴 1 上，是一维匀加速；
  - 在轴 2 上，是一维匀速；
  - ……每条轴都可以单独分析。

SVD / 特征分解就是干这件事：**找到一个"最合适的基底"，让矩阵在这个基底下变得最"简单"（对角化）。**

- 在原坐标里，$X^\top X$ 把不同方向"搅在一起"；
- 在 V 的坐标里，$X^\top X$ 变成对角阵，每个方向上只负责"拉伸 / 压缩"，没有"交叉项"。

这样，我们就能非常清楚地说：

> "在第 i 个奇异方向上，梯度下降的更新速度 $\propto \sigma_i^2$。
> σ_i 大 → 这个方向学得快；
> σ_i 小 → 这个方向学得极慢。"

这就是为什么老师在分析 **隐式正则化 / 早停** 时，一定要把问题搬到 SVD / 特征向量的坐标系里说话：
只有在这个基底下，每个方向是纯净的，可以单独分析。

---

3. 机器学习角度：这样才能一眼看出"信号 vs 噪声"、"显式 vs 隐式正则"

3.1 Ridge 解在这个坐标系里的样子

还记得我们之前得到的 ridge 闭式解吗？

$$\vec{w}_{\text{ridge}} = \sum_i v_i \frac{\sigma_i}{\sigma_i^2 + \lambda}(u_i^\top y)$$

在 V 的坐标（也就是奇异向量方向）上，每个方向的系数都是：

$$\tilde{w}_{\text{ridge},i} = \frac{\sigma_i}{\sigma_i^2 + \lambda}\tilde{y}_i$$

看见没？
在这个坐标系里，ridge 就是对每个方向乘了一个简单的 scaler：$\frac{\sigma_i}{\sigma_i^2+\lambda}$。

- σ_i 大时，这个系数 $\approx 1/\sigma_i$，接近无正则的解；
- σ_i 小时，这个系数 $\approx \sigma_i/\lambda$，趋近于 0。

> 你一眼就能看出：
> **Ridge 显式地压扁了"小奇异值方向"的分量。**

如果你不换坐标系、直接在原标准基底下看，那这些效果会混成一个大矩阵 $(X^\top X + \lambda I)^{-1}X^\top y$，很难一眼看出来"是谁被压扁了"。

3.2 GD + early stopping 在这个坐标系里的样子

同样，在 SVD 坐标系下，我们看到：

$$\tilde{w}_{t+1,i} = \tilde{w}_{t,i} - 2\eta\big(\sigma_i^2 \tilde{w}_{t,i} - \sigma_i \tilde{y}_i\big)$$

从这行你可以马上读出**结论**：

- 大 σ_i：σ_i^2 大，更新快 → 训练初期就迅速靠近最优；
- 小 σ_i：σ_i^2 很小，更新几乎动不了 → 在有限步数早停下，这些方向仍然很小。

于是就能得到那句非常重要的 insight：

> [illegible]
> **相当于一种隐式的"小奇异值方向正则化"。**

如果你不换坐标系，所有坐标混在一起，就看不出这点：

- 你只知道"GD 在往某个方向走"，
- 但看不出这方向是否主要由"大奇异值方向"组成，还是"小奇异值方向"组成。

---

4. 一个类比：对角化 = 把一个复杂乐章拆成单独的音轨

想象你有一首很复杂的歌曲，混在一个 mp3 里：

- 里面有鼓、贝斯、钢琴、主唱、和声……全混在一条轨道上；
- 你只听最终的声音，但你不知道"鼓的节奏是怎样的"、"贝斯是怎样的"——所有东西都叠在一起。

如果你能把它拆成多条音轨：

- 一条只放鼓；
- 一条只放贝斯；
- 一条只放钢琴；
- 一条只放人声；

你就可以：

- 单独听"鼓"的部分，分析它的节奏；
- 单独关掉"贝斯"；
- 对"人声"加滤波……

SVD / 特征分解 + 换坐标系，做的事情就类似于：

> 在这些"音轨坐标系"里，每条轨道的变化规则都很简单，我们就可以单独分析、单独正则化。

---

5. 用一句话回答你的问题

> **为什么要换一个坐标系去看？**
>
> 因为在这个特殊的坐标系（由奇异向量构成的基底）中：
>
> - "矩阵 $X^\top X$ 被"对角化"，"
> - "每个方向互不影响，"
> - "和奇异值 σ_i 的关系变成非常简单的一维递推。"
>
> 只有这样，我们才能清楚地看到：
>
> - "Ridge 是怎样显式地压制"小奇异值方向"的；"
> - "梯度下降 + 早停又是怎样**隐式地**对这些方向进行正则化的；"
> - "以及为什么"小奇异值方向"常常对应"噪声 / 不可靠"信息。"

如果你愿意，下一步我可以做一个**小的 2 维数值例子**：
给出具体的 X、算出 U, Σ, V，然后对比：

- 在原坐标系里 GD 的更新；
- 在 SVD 坐标系里每个 $\tilde{w}_{t,i}$ 的更新。

你会看到"大奇异值方向飞快收敛、小奇异值方向几乎不动"的现象会非常直观。

请继续向我详细地展示这一段运算是如何进行、得出结果的，并解释这些算式的意义！（我是线性代数、机器学习、最优化领域的初学者）

Thought for 32s >

好，咱们来把这一大串板书"翻译成人话"，再顺手补上线代 / 机器学习里的直觉。你可以把这几页理解成在回答一个问题：

> **在欠定线性回归（参数比数据多）里，用 batch size = 1 的 SGD、步长不缩小，真的会收敛吗？会收敛到哪一个解？**

老师在做的是：

1. 先把问题化简成一个"误差向量" $\vec{q}_t$ 的问题；
2. 再用 SVD 把它化成一个"好看"的坐标系；
3. 然后在这个坐标系里分析 **SGD 的期望损失是收缩**（contracting），从而说明收敛。

我按板书顺序分段讲。

---

0. 场景设定：欠定线性回归 & 最小范数解

第一张图的核心内容：

- 我们在做的是一个**线性方程组**：

  $$X\vec{w} = \vec{y},$$

  其中：
  - $X \in \mathbb{R}^{n\times d}$
  - $d > n$：参数比样本多 → 欠定（underdetermined）
  - X **full-row-rank**：行满秩，秩为 n

这意味着：

- 方程 $X\vec{w} = \vec{y}$ 通常有**无穷多解**（因为参数多）。
- 在这么多解里，有一个特别重要的：**最小欧几里得范数的解**（min-norm solution）：

  $$\vec{w}_* = X^\top (XX^\top)^{-1}\vec{y}.$$

  这就是线性代数里著名的 **最小二乘最小范数解（Moore-Penrose 伪逆）**形式之一。$X^\top(XX^\top)^{-1}$ 就是 X 的一个伪逆形式（当 X 行满秩时）。

> 直觉：
> 在所有能 perfectly 拟合训练数据的参数向量里，$\vec{w}_*$ 是"长度最短"的那个。

---

1. [illegible]

第二步：我们不是直接分析 $\vec{w}_t$，而是分析它离最小范数解的差：

$$\vec{q}_t = \vec{w}_t - \vec{w}_*.$$

- 这是一个标准 trick：**把"参数"换成"相对最优解的偏差"。**
- 目标：证明 $\vec{q}_t \to \vec{0}$，也就是 $\vec{w}_t \to \vec{w}_*$。

板书上写了：

$$X(\vec{w}^- - \vec{w}^+) = \vec{y} - \vec{y} = 0$$

意思是：任意两个解 $\vec{w}^-, \vec{w}^+$ 都满足 $X\vec{w}^- = X\vec{w}^+ = \vec{y}$，所以它们的差 $\vec{q} = \vec{w}^- - \vec{w}^+$ 一定满足：

$$X\vec{q} = X(\vec{w}^- - \vec{w}^+) = \vec{y} - \vec{y} = 0.$$

套到我们的记号上：
$\vec{w}_t$ 和 $\vec{w}_*$ 都是 **满足 $X\vec{w} = \vec{y}$ 的解**（老师假设我们在训练过程中损失已经可以趋近于 0），所以：

$$X(\vec{w}_t - \vec{w}_*) = 0 \quad\Rightarrow\quad X\vec{q}_t = 0.$$

于是我们得到一个新的方程：

$$X\vec{q}_t = 0.$$

这说明：

> 所有解之间的差（$\vec{q}$）都在 X 的**零空间 (null space)** 里。

板书写着：

因为初始化 $\vec{w}_0 = 0$，所以一开始的偏差 $\vec{q}_0 = -\vec{w}_*$。

---

2. 用 SVD 来看 $X\vec{q} = 0$ 长什么样

第二张图标题：**"We know the SVD dictates which directions SGD/GD moves in."**

对 X 做 SVD：

$$X = U\Sigma V^\top.$$

但注意这里 $X \in \mathbb{R}^{n\times d}$，且 $d > n$，秩为 n。于是 Σ 的形状是：

- $\Sigma = [\Sigma_1, 0]$：
  - Σ_1 是 $n\times n$ 的对角矩阵（放着非零奇异值 $\sigma_1, \dots, \sigma_n$）
  - 右边那个 0 是 $n \times (d-n)$ 的全零块

因此：

$$X = U[\Sigma_1, 0]V^\top.$$

把它乘在 $\vec{q}$ 上：

$$X\vec{q} = U[\Sigma_1, 0]V^\top\vec{q}.$$

现在定义一个新坐标：

$$\vec{z} = V^\top\vec{q}.$$

$$X\vec{q} = U[\Sigma_1, 0]\vec{z}.$$

把 $\vec{z}$ 再拆成前后两部分：

$$\vec{z} = \begin{bmatrix} \vec{z}^{(1)} \\ \vec{z}^{(2)} \end{bmatrix},\quad \vec{z}^{(1)} \in \mathbb{R}^n,\ \vec{z}^{(2)} \in \mathbb{R}^{d-n}.$$

于是

$$[\Sigma_1, 0]\vec{z} = \Sigma_1\vec{z}^{(1)} + 0\cdot\vec{z}^{(2)} = \Sigma_1\vec{z}^{(1)}.$$

所以

$$X\vec{q} = 0 \iff U\Sigma_1\vec{z}^{(1)} = 0 \iff \Sigma_1\vec{z}^{(1)} = 0.$$

因为 Σ_1 的对角线都是非零（满行秩），所以只有 $\vec{z}^{(1)} = 0$ 才能满足：

$$\Sigma_1\vec{z}^{(1)} = 0 \Rightarrow \vec{z}^{(1)} = 0.$$

换句话说：

> 若 $X\vec{q} = 0$，则在 V 坐标系里，$\vec{q}$ 的前 n 个分量必须为 0，只有后面的 $d-n$ 个分量可以非零。

板书把这个压缩成一个更小的矩阵 $\tilde{X}$：

- 取 $\tilde{X} = U\Sigma_1$，那它就是 $n\times n$，满秩；
- 取 $\tilde{\vec{z}} = \vec{z}^{(1)}$（前 n 个分量）。

那么条件就变成：

这就是第三张图一开始粉红框里的：

> "So what matters is $\tilde{X}\tilde{\vec{z}} = 0$"

意义是：

- 原始 d 维的误差 $\vec{q}$，在"数据相关"的子空间（由前 n 个奇异向量张成）里的坐标就是 $\tilde{\vec{z}}$；
- 训练的目的：让 $\tilde{X}\tilde{\vec{z}}$ 变成 0，也就是在这个子空间里的误差消失。

---

3. 在 $\tilde{z}$ 空间里写 GD / SGD 更新

有了这个化简，我们只用看"重要"的 n 维部分 $\tilde{\vec{z}}_t$。

3.1 GD 更新

第三张图中间写：

$$\tilde{\vec{z}}_{t+1} = \tilde{\vec{z}}_t - 2\eta\,\tilde{X}^\top\tilde{X}\,\tilde{\vec{z}}_t.$$

这是对损失函数

$$L(\tilde{\vec{z}}) = \|\tilde{X}\tilde{\vec{z}}\|_2^2$$

做梯度下降：

- $\nabla L(\tilde{\vec{z}}) = 2\tilde{X}^\top\tilde{X}\tilde{\vec{z}}$
- 所以 GD 更新：

  $$\tilde{\vec{z}}_{t+1} = \tilde{\vec{z}}_t - \eta\nabla L(\tilde{\vec{z}}_t) = \tilde{\vec{z}}_t - 2\eta\tilde{X}^\top\tilde{X}\tilde{\vec{z}}_t$$

3.2 SGD（batch size 1）更新

如果我们每次只用一行来更新（SGD，batch size 1）：

- 记第 i 个样本在这个坐标系里的行向量为 $\tilde{\vec{x}}_i^\top$，
  那么 $\tilde{X}$ 的第 i 行就是 $\tilde{\vec{x}}_i^\top$。

SGD 的更新就变成：

$$\tilde{\vec{z}}_{t+1} = \tilde{\vec{z}}_t - 2\eta\,\tilde{\vec{x}}_{I_t}\tilde{\vec{x}}_{I_t}^\top\tilde{\vec{z}}_t.$$

这就是第三张图红框里的式子——那里画了一个圈圈在 $\tilde{\vec{x}}_{I_t}\tilde{\vec{x}}_{I_t}^\top$ 上，旁边写着 "point sampled at time I_t"。

> 直觉：
> - "每一步 SGD 都是"当前误差 $\tilde{\vec{z}}_t$ 被当前样本的方向 $\tilde{\vec{x}}_{I_t}$ 拉回去一点"。"
> - "这就是线性回归里 SGD 更新的本质：不断用单个样本纠正预测误差。"

---

4. 用 Lyapunov 函数证明"期望损失下降"

第四张图开始讲"Lyapunov function"和"contraction"。

我们想证明：

> 对于这个 SGD 更新，损失
>
> $$L(\tilde{\vec{z}}_t) = \|\tilde{X}\tilde{\vec{z}}_t\|_2^2$$
>
> 在期望意义上会单调下降，并且最后收敛到 0。

Lyapunov 函数就是用来证明"系统稳定 / 收敛"的一个工具：
找一个非负函数 $L(\cdot)$，如果能证明

1. $L(\tilde{\vec{z}}) \ge 0$ 对所有 $\tilde{\vec{z}}$ 成立；
2. $L(\tilde{\vec{z}}) = 0 \Rightarrow \tilde{\vec{z}} = 0$（只有在目标点才为 0）；
3. 在迭代过程中，$\mathbb{E}[L(\tilde{\vec{z}}_{t+1})] \le \mathbb{E}[L(\tilde{\vec{z}}_t)]$，甚至还要强一点：

   $$\mathbb{E}[L(\tilde{\vec{z}}_{t+1})] \le (1 - \text{常数})\,\mathbb{E}[L(\tilde{\vec{z}}_t)],$$

   那么就说明系统越来越接近 0，并最终收敛。

板书下半部分写的是：

$$\mathbb{E}(L(\tilde{\vec{z}}_{t+1})) \le \mathbb{E}(L(\tilde{\vec{z}}_t)) + C_1\cdot L(\tilde{\vec{z}}_t)$$

然后经过一大堆推导，最后得到一个**收缩不等式**：

$$\mathbb{E}(L(\tilde{\vec{z}}_{t+1})) \le (1 - c_1\eta + c_2\eta^2)\,L(\tilde{\vec{z}}_t).$$

只要步长 η 足够小，使得 $1 - c_1\eta + c_2\eta^2 < 1$，就说明每一步期望上损失都乘上一个小于 1 的系数 → 递减 → 收敛到 0。

> 这就是题目开头那句：
> **"SGD can provably converge even with *constant* stepsize if loss goes to zero."**
> 这里的"constant stepsize"就是固定的 η，并不随时间减小；

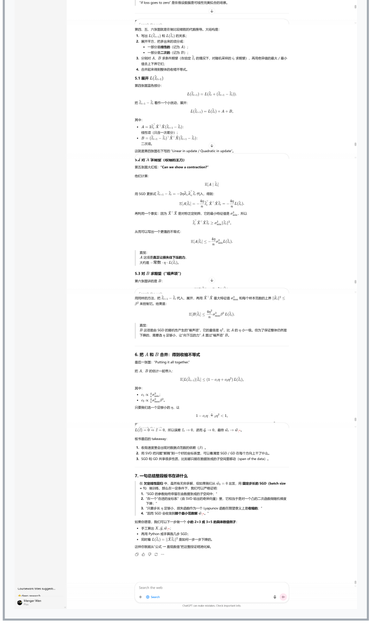

> "if loss goes to zero" 是在假设数据是可线性完美拟合的场景。

第四、五、六张图就是在做比较细致的代数推导。大结构是：

1. 写出 $L(\tilde{z}_{t+1})$ 和 $L(\tilde{z}_t)$ 的关系；
2. 展开平方，把多出来的项分成：
    - 一部分是**线性的**（记为 A）；
    - 一部分是**二次的**（记为 B）；
3. 分别对 A、B 求条件期望（在给定 $\tilde{z}_t$ 的情况下，对随机采样的 i_t 求期望），再用奇异值的最大 / 最小值去上下界它们；
4. 合并起来得到整体的收缩不等式。

5.1 展开 $L(\tilde{z}_{t+1})$

第四张图蓝色部分：

$$L(\tilde{z}_{t+1}) = L(\tilde{z}_t + (\tilde{z}_{t+1} - \tilde{z}_t)).$$

把 $\tilde{z}_{t+1} - \tilde{z}_t$ 看作一个小扰动，展开：

$$L(\tilde{z}_{t+1}) = L(\tilde{z}_t) + A + B,$$

其中：

- $A = 2\tilde{z}_t^\top \tilde{X}^\top \tilde{X}(\tilde{z}_{t+1} - \tilde{z}_t)$:
  线性项（只含一次差分）；
- $B = (\tilde{z}_{t+1} - \tilde{z}_t)^\top \tilde{X}^\top \tilde{X}(\tilde{z}_{t+1} - \tilde{z}_t)$:
  二次项。

这就是第四张图右下写的 "Linear in update / Quadratic in update"。

5.2 对 A 求期望（收缩的主力）

第五张图大红框：**"Can we show a contraction?"**

他们计算：

$$\mathbb{E}[A \mid \tilde{z}_t]$$

用 SGD 更新式 $\tilde{z}_{t+1} - \tilde{z}_t = -2\eta\tilde{x}_{i_t}\tilde{x}_{i_t}^\top\tilde{z}_t$ 代入，得到：

$$\mathbb{E}[A|\tilde{z}_t] = -\frac{4\eta}{n}\tilde{z}_t^\top \tilde{X}^\top \tilde{X}\tilde{z}_t = -\frac{4\eta}{n}L(\tilde{z}_t).$$

再利用一个事实：因为 $\tilde{X}^\top \tilde{X}$ 是对称正定矩阵，它的最小特征值是 $\sigma_{\min}^2$，所以

$$\tilde{z}_t^\top \tilde{X}^\top \tilde{X}\tilde{z}_t \geq \sigma_{\min}^2 \|\tilde{z}_t\|^2,$$

从而可以写出一个更强的不等式：

$$\mathbb{E}[A|\tilde{z}_t] \leq -\frac{4\eta}{n}\sigma_{\min}^2 L(\tilde{z}_t).$$

> 直觉：
> A 这项是**真正让损失往下压的力**，
> 大约是 $-$常数 $\cdot\, \eta \cdot L(\tilde{z}_t)$。

5.3 对 B 求期望（"噪声项"）

第六张图讲的是 B：

用同样的方法，把 $\tilde{z}_{t+1} - \tilde{z}_t$ 代入、展开，再用 $\tilde{X}^\top \tilde{X}$ 最大特征值 $\sigma_{\max}^2$ 和每个样本范数的上界 $\|\tilde{x}_i\|^2 \leq \beta^2$ 来控制它。结果是：

$$\mathbb{E}[B|\tilde{z}_t] \leq \frac{4\eta^2}{n}\sigma_{\max}^2\beta^2 L(\tilde{z}_t).$$

> 直觉：
> B 这项是由 SGD 的随机性产生的"噪声项"，它的量级是 η^2，比 A 的 η 小一级。但为了保证整体仍然是下降的，需要选 η 足够小，让"向下压的力" A 盖过"噪声项" B。

---

6. 把 A 和 B 合并：得到收缩不等式

最后一张图："Putting it all together."

把 A、B 的估计一起带入：

$$\mathbb{E}[L(\tilde{z}_{t+1})|\tilde{z}_t] \leq (1 - c_1\eta + c_2\eta^2)\, L(\tilde{z}_t),$$

其中：

- $c_1 \propto \frac{4}{n}\sigma_{\min}^2$;
- $c_2 \propto \frac{4}{n}\sigma_{\max}^2\beta^2$。

只要我们选一个足够小的 η，让

$$1 - c_1\eta + c_2\eta^2 < 1,$$

$L(\tilde{z}) = 0 \Rightarrow \tilde{z} = 0$，所以误差 $\tilde{z}_t \to 0$，进而 $\vec{q}_t \to 0$，最终 $\vec{w}_t \to \vec{w}_{*}$。

板书最后的 takeaway：

1. 收敛速度里会出现对数据点范数的依赖（β）。
2. 用 SVD 把问题"解耦"到一个好的坐标系里，可以看清楚 SGD / GD 在每个方向上干了什么。
3. SGD 和 GD 共享很多性质，比如都只能在数据张成的子空间里移动（span of the data）。

---

7. 一句总结整段板书在讲什么

> 在 **欠定线性回归** 中，虽然有无穷多解，但如果我们从 $\vec{w}_0 = 0$ 出发，用 **固定步长的 SGD（batch size = 1）** 做训练，那么在一定条件下，我们可以严格证明：
> 1. "SGD 的参数始终停留在由数据张成的子空间中；"
> 2. "在一个"合适的坐标系"（由 SVD 给出的奇异向量）里，它相当于是对一个凸的二次函数做随机梯度下降；"
> 3. "只要步长 η 足够小，损失函数作为一个 Lyapunov 函数在期望意义上是**收缩的**；"
> 4. "因而 SGD 会收敛到**那个最小范数解** $\vec{w}_{*}$。"

如果你愿意，我们可以下一步做一个 **小的 2×3 或 3×5 的具体数值例子**：

- 手工算出 $X, \vec{y}, \vec{w}_{*}$;
- 再用 Python 或手算跑几步 SGD；
- 同时看 $L(\tilde{z}_t) = \|\tilde{X}\tilde{z}_t\|^2$ 是如何一步一步下降的。

这样你就能从"公式 → 直观数值"把这整段证明消化掉。

Search the web
Search
ChatGPT can make mistakes. Check important info.
Coursework titles suggesti...
deep research
Menger Wen
Plus