公司名称：顺丰科技有限公司

公司简介：顺丰科技有限公司成立于 2009 年，是顺丰旗下专注数智物流解决方案的科技服务商。我们深耕于物流数智化十余年，致力于构建全球领先的数字化供应链生态。我们基于对物流场景的深度理解和行业头部公司的数智化实战经验，结合多元业务中沉淀的数据与前沿的技术探索成果，为用户提供更懂数智物流的科技服务。

项目一：大模型推理优化

项目概述：本项目针对大规模语言模型（LLM）的推理性能瓶颈进行系统优化，涵盖模型压缩、推理框架优化、硬件加速等方向，主要包括一下四点。模型轻量化：实现量化、蒸馏、剪枝等技术，降低模型存储和计算成本；推理引擎优化：优化 Attention 计算、KV 缓存管理、批处理策略，提升吞吐量和降低延迟；异构计算加速：利用 GPU/NPU 等硬件特性，实现高效算子融合与内存优化；分布式推理：应用 PD 分离，支持模型并行与张量并行，实现跨设备高效推理。

预期成果：

1. 推理延迟降低 30%以上
2. 吞吐量提升至基线的 1.5 倍
3. 输出优化后的模型部署方案和性能对标报告
4.

技术要求：

1. 核心能力：熟悉 SGLang 推理框架，深入理解 Transformer 架构、CUDA 编程、量化与蒸馏算法
2. 技术栈：PyTorch/TensorFlow、TVM/ONNX Runtime、CuDNN、Flash Attention 等
3. 工程能力：分布式系统设计、性能评测、系统集成

项目二：智能体平台建设

项目概述：构建高性能、可扩展的统一智能体平台后端系统，设计并实现 Agent 运行时引擎，包括大语言模型调用、工具集成、上下文管理等核心组件，构建 Agent 评估与监控体系，设计指标收集、性能分析与质量保障机制。

预期成果：

1. 落地统一智能体平台以及智能体监控和管理功能
2. 支持 2000+活跃智能体的发布以及日常问题排查

技术要求：

1. 熟悉 Golang/Python 等编程语言，具备扎实的编程基础
2. 具有分布式系统设计经验，了解负载均衡、消息队列、缓存等技术，同时理解这些技术在 AI 系统中的应用
3. 熟悉大语言模型工作原理，有 LLM 应用开发或 Agent 系统相关经验