FMA4200 26spring mid 文杰 123090612 cp

covariance between two random variables X_1 and X_2: $\sigma(X_1,X_2)=E\{[X_1-E(X_1)][X_2-E(X_2)]\}=E(X_1Y_2)-E(X_1)E(X_2)$, *correlation* between X_1 and X_2: $-1\le\rho(X_1,X_2)=\frac{\sigma(X_1,X_2)}{\sigma(X_1)\sigma(X_2)}\le 1$, 性质：*1.* $Cov(X_1,X_1)=Var(X_1)$，*2.* $Cov(aX_1,X_2)=aCov(X_1,X_2)$，*3.* $Cov(X_1+c,X_2)=Cov(X_1,X_2)$，*4.* $Cov(X_1+X_2,X_3)=Cov(X_1,X_3)+Cov(X_2,X_3)$, *5.* If $X_3=X_1+X_2$ then $Var(X_3)=Cov(X_3,X_3)=Cov(X_1+X_2,X_1+X_2)$=$Cov(X_1,X_1)+Cov(X_1,X_2)+Cov(X_2,X_1)+Cov(X_2,X_2)$ =$Var(X_1)+Var(X_2)+2Cov(X_1,X_2)$，*6.* $Var(aX_1+bX_2)=a^2Var(X_1)+b^2Var(X_2)+2abCov(X_1,X_2)$

单变量数据分析 收益 *对数收益/连续复利收益*：$r_t=\log(\frac{S_t}{S_{t-1}})$ *简单收益*：$R_t=\frac{S_t}{S_{t-1}}-1\approx r_t$，当 r_t 很小时 更常使用对数收益：*1.* 具有可加性；*2.* 简单收益的取值范围是 $[-1,\infty)$，对数收益的取值范围是 $(-\infty,\infty)$ *一期毛收益*：$G_t:=\frac{S_t}{S_{t-1}}$ *k 期简单收益*：$R_t(k):=\frac{S_t}{S_{t-k}}-1=\prod_{i=0}^{k-1}(1+R_{t-i})-1$ *k 期对数收益*：$r_t(k):=\ln\left(\frac{S_t}{S_{t-k}}\right)=\sum_{i=0}^{k-1}r_{t-i}$ SPX收益率的*分布特征*：尖峰厚尾（leptokurtic，峰度高）且具有厚尾（heavy-tailed）特征，极端收益出现的频率高于正态分布的预测；分布左偏，负收益的极端程度比正收益更强（更容易出现较大的负收益） 随机变量与分布 *离散型* **pmf**: $p_X(x)=\mathbb{P}(X=x)=\mathbb{P}(\{\omega\in\Omega:X(\omega)=x\})$ **cdf**: $F_X(x)=\mathbb{P}(X\le x)=\sum_{x_i\le x}p_X(x_i)$ **期望**: $\mathbb{E}[X]=\sum_x xp_X(x)$ *连续型* **cdf**: $F_X(x)=\int_{-\infty}^x f_X(t)dt$ **pdf**: $f_X(x)=\frac{d}{dx}F_X(x)$ **期望**：$\mathbb{E}[X]=\int_{-\infty}^{\infty}xf_X(x)dx$ *矩* **第 k 阶矩**：$\mathbb{E}[X^k]=\int_{-\infty}^{\infty}x^kf_X(x)dx$ **第 k 阶中心矩**: $\mathbb{E}[(X-\mathbb{E}[X])^k]=\int_{-\infty}^{\infty}(x-\mathbb{E}[X])^kf_X(x)dx$ *矩母函数（mgf）*：$M_X(t)=\mathbb{E}[e^{tX}]$ 并且有 $\mathbb{E}[X^k]=M_X^{(k)}(0)$（即 $M_X(t)$ 在 $t=0$ 处的 k 阶导数） *偏度* 第三阶中心标准化矩 $\text{Skewness}(X)=\frac{\mathbb{E}[(X-\mathbb{E}[X])^3]}{(\mathbb{E}[(X-\mathbb{E}[X])^2])^{3/2}}$ *峰度* 第四阶中心标准化矩 $\text{Kurtosis}(X)=\frac{\mathbb{E}[(X-\mathbb{E}[X])^4]}{(\mathbb{E}[(X-\mathbb{E}[X])^2])^2}$ *超额峰度* $\text{Excess Kurtosis}(X)=\text{Kurtosis}(X)-3$ *用正态分布拟合* SPX 收益率 $\hat\mu=\mathbb{E}[X]=\frac{1}{T}\sum_{t=1}^T r_t$ $\hat\sigma^2=\text{Var}(X)=\frac{1}{T-1}\sum_{t=1}^T(r_t-\hat\mu)^2$（使用样本均值来估计总体均值）标准化后的样本均值 $Z=\sqrt{T}\hat\mu/\hat\sigma$ *矩估计法* 令前 k 个样本矩等于前 k 个总体矩 缺点：*1.* 估计得到的参数可能落在参数空间之外（小样本时更可能发生）*2.* 估计量不一定是充分统计量；有时未能利用样本中的全部相关信息。 *极大似然估计（MLE）* 最大化 $\log L(\theta)=\sum_{i=1}^n\log p(x_i;\theta)$ 其中 $p(x_i;\theta)$ 是该分布的概率密度函数，θ 是参数向量 *Shapiro-Wilk 检验* 一种正态性检验方法 $W=\frac{(\sum_{i=1}^n a_ix_{(i)})^2}{\sum_{i=1}^n(x_i-\bar x)^2}$ 其中 $x_{(i)}$ 是样本的第 i 个顺序统计量，a_i 是向量 $(a_1,a_2,\dots,a_n)$ 的第 i 个元素，且 $a_i=\frac{m_i}{\sqrt{m_0m_i}}$，其中 m_i 是标准正态分布的第 i 阶矩，m_0 是样本均值。在正态分布假设下，统计量 W 的分布为 $W\sim\text{Beta}\left(\frac{n}{2},\frac{n}{2}\right)$ 其中 n 为样本量。*p 值*是在原假设为真时犯第一类错误的概率（即错误拒绝原假设）：$p=P(W\le w_{obs}|H_0)=\int_0^{w_{obs}}f_W(w)dw$ 其中 w_{obs} 为观测到的统计量值，$f_W(w)$ 为 $\text{Beta}(\frac{n}{2},\frac{n}{2})$ 的概率密度函数。 *用学生 t 分布拟合 SPX 收益率* $\max_{\nu,\mu,\sigma}\log L(\nu,\mu,\sigma)=\sum_{t=1}^T\log p(r_t;\nu,\mu,\sigma)$. *Kolmogorov–Smirnov（K-S）检验* 用于检验样本是否来自某分布 检验统计量：$D_n=\sup_{x\in\mathbb{R}}|F_n(x)-F(x)|$ 其中 $F_n(x)$ 是样本的经验分布函数，$F(x)$ 是被检验的理论分布函数。在原假设下，统计量 $\sqrt{n}D_n$ 收敛到 **Kolmogorov 分布**：$P(\sqrt{n}D_n>c)\approx 2\sum_{k=1}^{\infty}(-1)^{k-1}e^{-2k^2c^2}$. 风险度量的估计 *VaR* 是投资组合收益分布的**分位数** $\text{VaR}_\alpha(X):=-\inf\{x\in\mathbb{R}:P(X\le x)>\alpha\}=F_{-X}^{-1}(1-\alpha)$. 给出了在置信水平 $1-\alpha$ 下投资组合可能遭受的最大损失 有一组历史收益样本 $\{X_1,\dots,X_T\}$，置信水平为 α 的 VaR 估计为 $\text{VaR}_\alpha(X)=-X_{(\lceil T\alpha\rceil)}$ 其中 $X_{(i)}$ 是样本 $\{X_1,\dots,X_T\}$ 的第 i 个顺序统计量；$\lceil\cdot\rceil$ 是向上取整函数（返回不小于输入的最小整数） *CVaR* 也称为*期望短缺（Expected Shortfall, ES）* $\text{CVaR}_\alpha(X):=\mathbb{E}[-X|-X\ge\text{VaR}_\alpha(X)]=\frac{1}{\alpha}\int_0^\alpha\text{VaR}_\beta(X)d\beta$. 衡量的是在损失超过 VaR 的条件下的期望损失 性质：*1.* 总是大于或等于 VaR *2.* 考虑了分布的尾部行为 *3.* 是一种一致性（coherent）风险度量 *4.* 对极端事件的敏感性比 VaR 更强 置信水平为 α 的 CVaR 估计为 $\text{CVaR}_\alpha(X)=-\frac{1}{\lceil T\alpha\rceil}\sum_{i=1}^{\lceil T\alpha\rceil}X_{(i)}$, 也即最大 $\lceil T\alpha\rceil$ 个损失的平均值 *Coherent Risk Measures* 性质：*1.* **归一化（Normalized）**：$\rho(0)=0$ *2.* **单调性（Monotonicity）**：若 $X\le Y$，则 $\rho(X)\ge\rho(Y)$ *3.* **次可加性（Subadditivity）**：$\rho(X+Y)\le\rho(X)+\rho(Y)$ *4.* **正齐次性（Positive homogeneity）**：对所有 $\lambda\ge 0$，$\rho(\lambda X)=\lambda\rho(X)$ *5.* **平移不变性（Translation invariance）**：对所有 $A=a$ a.s.，$\rho(X+A)=\rho(X)-a$ 从期权数据提取风险中性分布 *远期* $\text{Payoff}=S_T-K$ *期权* *欧式看涨期权（European call）* 赋予买方在到期日以执行价 K 买入标的的权利：$\text{Payoff}=\max(S_T-K,0)$. *欧式看跌期权（European put）* 赋予买方在到期日以执行价 K 卖出标的的权利：$\text{Payoff}=\max(K-S_T,0)$. *期权的风险中性定价* $C=\mathbb{E}_{\mathbb{P}}[M_Te^{-rT}f(S_T)]$ 其中 M_T 是刻画风险偏好的非负随机变量，$f(S_T)$ 为期权收益函数。 *情形* $f(S_T)\equiv 1$ 考虑一只到期为 T、面值为 1 的零息债券：$C=\mathbb{E}_{\mathbb{P}}[M_Te^{-rT}]=e^{-rT}\Rightarrow\mathbb{E}_{\mathbb{P}}[M_T]=1$. 此时 M_T 可作为 Radon–Nikodym 导数，从而相对于真实世界测度 $\mathbb{P}$ 诱导出一个新测度 $\mathbb{Q}$，即 $\frac{d\mathbb{Q}}{d\mathbb{P}}=M_T$，也即对任意事件 A，$\mathbb{Q}(A)=\mathbb{E}_{\mathbb{P}}[M_T\mathbb{1}_A]$. 在该新测度 $\mathbb{Q}$ 下，期权定价公式变为：$C=\mathbb{E}_{\mathbb{P}}[M_Te^{-rT}f(S_T)]=\mathbb{E}_{\mathbb{Q}}[e^{-rT}f(S_T)]$. *情形* $f(S_T)=S_T-K$ *（远期合约）* 这是持有股票的情形。合约价值为：$C=\mathbb{E}_{\mathbb{P}}[e^{-rT}M_T(S_T-K)]=0$. 因此，公平远期价格为：$F_0=\mathbb{E}_{\mathbb{P}}[M_TS_T]$. *公平远期价格* 在无股息收益的情形下，由无套利原理，公平远期价格也可写为 $F_0=S_0e^{rT}$，因此有 $\mathbb{E}_{\mathbb{P}}[M_TS_T]=S_0e^{rT}$. *Black–Scholes 模型* 给出到期价格：$S_T=S_0e^{(\mu-\frac{1}{2}\sigma^2)T+\sigma\sqrt{T}Z}$ 其中 Z 为标准正态随机变量。定价因子 M_T 取为 $M_T=e^{-\frac{1}{2}\theta^2T-\theta\sqrt{T}Z}$，其中 $\theta\in\mathbb{R}$。注意到 $\mathbb{E}_{\mathbb{P}}[M_Te^{-rT}S_T]=S_0$，可得 $\theta=(\mu-r)/\sigma$，该 θ 称为**风险的市场价格（market price of risk）** *风险中性测度下的 S_T 分布* 注意 S_T 是 Z 的函数，而 Z 在真实世界测度 $\mathbb{P}$ 下是标准正态。为了得到其在风险中性测度 $\mathbb{Q}$ 下的分布，考虑其矩母函数：$\mathbb{E}_{\mathbb{Q}}[e^{uZ}]=\mathbb{E}_{\mathbb{P}}[e^{uZ}M_T]=\mathbb{E}_{\mathbb{P}}\left[e^{-\frac{1}{2}\theta^2T+(u-\theta\sqrt{T})Z}\right]=e^{-\frac{1}{2}\theta^2T+\frac{1}{2}(u-\theta\sqrt{T})^2}=e^{\frac{1}{2}u^2-u\theta\sqrt{T}}$. 右端是均值为 $-\theta\sqrt{T}$、方差为 1 的正态随机变量的矩母函数。因此，$\tilde Z=Z+\theta\sqrt{T}\sim\mathcal{N}(0,1)$，在 $\mathbb{Q}$ 下。并且 $S_T=S_0e^{(r-\frac{1}{2}\sigma^2)T+\sigma\sqrt{T}\tilde Z}$. *Black–Scholes 公式 欧式看涨期权*价格为 $C=\mathbb{E}_{\mathbb{Q}}[e^{-rT}(S_T-K)^+]=S_0\Phi(d_1)-Ke^{-rT}\Phi(d_2)$，其中 Φ 为标准正态分布的累积分布函数，且 $d_1=\frac{\ln(S_0/K)+(r+\frac{1}{2}\sigma^2)T}{\sigma\sqrt{T}}$，$d_2=d_1-\sigma\sqrt{T}$. *欧式看跌期权*价格为 $P=\mathbb{E}_{\mathbb{Q}}[e^{-rT}(K-S_T)^+]=Ke^{-rT}\Phi(-d_2)-S_0\Phi(-d_1)$. *含股息收益率的情形* 考虑常数比例股息收益率 q。定价因子 M_T 需满足：$\mathbb{E}_{\mathbb{P}}[M_Te^{-rT}e^{qT}S_T]=S_0$，$M_T=e^{-\frac{1}{2}\theta^2T-\theta\sqrt{T}Z},\theta=\frac{\mu-(r-q)}{\sigma}$. 此时 $S_T=S_0e^{(r-q-\frac{1}{2}\sigma^2)T+\sigma\sqrt{T}\tilde Z}$，$\mathbb{E}_{\mathbb{Q}}[e^{-rT}S_T]=S_0e^{-qT}$. 此时，欧式看涨期权价格为 $C=\mathbb{E}_{\mathbb{Q}}[e^{-rT}(S_T-K)^+]=S_0e^{-qT}\Phi(d_1)-Ke^{-rT}\Phi(d_2)$，其中 $d_1=\frac{\ln(S_0/K)+(r-q+\frac{1}{2}\sigma^2)T}{\sigma\sqrt{T}}$，$d_2=d_1-\sigma\sqrt{T}$。欧式看跌期权价格为 $P=\mathbb{E}_{\mathbb{Q}}[e^{-rT}(K-S_T)^+]=Ke^{-rT}\Phi(-d_2)-S_0e^{-qT}\Phi(-d_1)$. *一般股息收益率情形* 考虑远期价格过程满足：$\mathbb{E}_{\mathbb{Q}}[F_T]=F_0$，$F_T=S_T$. 因此可设定：$F_T=F_0e^{-\frac{1}{2}\sigma^2T+\sigma\sqrt{T}\tilde Z}$. 此时，欧式看涨期权价格为 $C=\mathbb{E}_{\mathbb{Q}}[e^{-rT}(F_T-K)^+]=e^{-rT}(F_0\Phi(d_1)-K\Phi(d_2))$，其中 $d_1=\frac{\ln(F_0/K)+\frac{1}{2}\sigma^2T}{\sigma\sqrt{T}}$，$d_2=d_1-\sigma\sqrt{T}$。看跌期权公式为 $P=\mathbb{E}_{\mathbb{Q}}[e^{-rT}(K-F_T)^+]=e^{-rT}(K\Phi(-d_2)-F_0\Phi(-d_1))$. 在连续股息收益率情形下，远期价格为 $F_0=S_0e^{(r-q)T}$. *看涨-看跌平价（Put-Call Parity）* $C-P=e^{-rT}(F_0-K)$. 若 $C-P>e^{-rT}(F_0-K)$，卖出看涨、买入看跌，并进入远期合约以远期价格 F_0 买入标的。若 $C-P<e^{-rT}(F_0-K)$，买入看涨、卖出看跌，并进入远期合约以远期价格 F_0 卖出标的。 *隐含波动率曲面* **隐含波动率曲线**：在固定到期日下，隐含波动率随执行价变化的关系 *隐含波动率的存在性* 由**无套利原理**，看涨期权市场价格必须落在以下区间：$(S_0-Ke^{-rT})^+\le C_{MKT}\le S_0$. 并且有 $\lim_{\sigma\to 0}C_{BS}(K,T;\sigma)=(S_0-Ke^{-rT})^+$，$\lim_{\sigma\to\infty}C_{BS}(K,T;\sigma)=S_0$. 因此，只要市场期权价格落在无套利区间内，隐含波动率就一定存在。对看跌期权同理。 *二分法 1.* 设定初始区间 $[\sigma_L,\sigma_H]$，其中 $\sigma_L=0$，σ_H 为一个较大的数。*2.* 计算 $\sigma_M=\frac{\sigma_L+\sigma_H}{2}$ 并计算 $C_{BS}(K,T;\sigma_M)$。*3.* 若 $|C_{BS}(K,T;\sigma_M)-C_{MKT}|<\epsilon$，停止。*4.* 否则：若 $C_{BS}(K,T;\sigma_M)>C_{MKT}$，令 $\sigma_H=\sigma_M$；若 $C_{BS}(K,T;\sigma_M)<C_{MKT}$，令 $\sigma_L=\sigma_M$。*5.* 返回第 2 步。达到精度 ϵ 所需迭代次数为：$\log_2\left(\frac{\sigma_H-\sigma_L}{\epsilon}\right)$. *Newton-Raphson Method* 迭代公式为 $\sigma_{n+1}=\sigma_n-\frac{C_{BS}(K,T;\sigma_n)-C_{MKT}}{\partial_\sigma C_{BS}(K,T;\sigma_n)}$. 收敛速度快于二分法 *SPX 期权* 通过反演 Black–Scholes 公式来计算隐含波动率：使用价外（OTM）的 SPX 看涨期权（通过看涨-看跌平价转换为看跌）与看跌期权（过滤掉成交量与持仓量为 0 的合约），并假设股息收益率为年化 1.213%。结果：由 OTM 看跌与 OTM 看涨推出的隐含波动率存在不一致。用隐含远期价格进行修正：先通过 ATM 看涨与看跌期权，利用看涨-看跌平价计算隐含远期价格，再用该隐含远期价格来计算隐含波动率。一致！ *波动率指数（VIX, The Volatility Index）* VIX 是广泛用于衡量未来 30 天市场预期波动率的波动率指数。$\text{VIX}=100\times\sqrt{\frac{2e^{rT}}{T}\left(\int_0^{F_0}\frac{1}{K^2}P(K)dK+\int_{F_0}^{\infty}\frac{1}{K^2}C(K)dK\right)}$ 其中 F_0 为远期价格，$P(K)$ 与 $C(K)$ 分别为执行价为 K 的看跌与看涨期权价格，r 为无风险利率。用中点法对积分做离散化，得到：$\text{VIX}=100\times\sqrt{\frac{2e^{rT}}{T}\sum_i\frac{\Delta K_i}{K_i^2}e^{rT}Q(K_i)-\frac{1}{T}\left(\frac{F_0}{K_0}-1\right)^2}$，其中 $Q(K_i)$ 是每个执行价 K_i 的期权买卖价差中点，$\Delta K_i=(K_{i+1}-K_{i-1})/2$，$K_0$ 为远期价格下方的第一个执行价。 *隐含偏度、峰度、均值、波动率* $\text{SKEW}(T)=\frac{e^{rT}W(T)-3\mu(T)e^{rT}V(T)+2\mu(T)^3}{(e^{rT}V(T)-\mu(T)^2)^{3/2}}$，$\text{KURT}(T)=\frac{e^{rT}X(T)-4\mu(T)e^{rT}W(T)+6e^{rT}\mu(T)^2V(T)-3\mu(T)^4}{(e^{rT}V(T)-\mu(T)^2)^2}$，其中 $V(T)=\int_0^\infty\frac{2(1-\ln(K/S_0))}{K^2}Q(K)dK$，$X(T)=\int_0^\infty\frac{12(\ln(K/S_0))^2-4(\ln(K/S_0))^3}{K^2}Q(K)dK$，$W(T)=\int_0^\infty\frac{6\ln(K/S_0)-3(\ln(K/S_0))^2}{K^2}Q(K)dK$. 并且，log return 的隐含均值与标准差为：$\mu(T)=e^{rT}-1-\frac{e^{rT}V}{2}-\frac{e^{rT}W}{6}-\frac{e^{rT}X}{24}$，$\sigma(T)=\sqrt{Ve^{rT}-\mu(T)^2}$. *隐含 NIG 模型* 假设 $\ln(S_T/S_0)$ 服从正态逆高斯分布：$\ln(S_T/S_0)\sim\text{NIG}(\alpha,\beta,\delta,\mu)$. 可通过匹配由 BKM（2003）隐含的均值、方差、偏度与峰度来估计参数：$\mu(T)=\mu+\delta\beta/\gamma$，$\sigma^2(T)=\delta\alpha^2/\gamma^3$，$\text{SKEW}(T)=3\beta/(\alpha\sqrt{\delta\gamma})$，$\text{KURT}(T)=3(1+4\beta^2/\alpha^2)/(\delta\gamma)+3$. 隐含的期权价格用蒙特卡洛模拟估计：$P_{NIG}(K,T)=\frac{1}{N}\sum_{i=1}^N e^{-rT}\max(0,S_0e^{X_i}-K)$，其中 X_i 从拟合的 NIG 分布采样，且 N 为模拟次数。 *NIG 模型的进一步改进* 可以通过最小化如下目标函数来细化 NIG 模型参数：$\min_{\alpha,\beta,\delta,\mu}\frac{1}{n}\sum_{i=1}^n(P_{NIG}(K_i,T)-P_{MKT}(K_i,T))^2$，其中 $P_{NIG}(K_i,T)$ 是 NIG 模型隐含价格（通过蒙特卡洛模拟计算），$P_{MKT}(K_i,T)$ 是执行价为 K_i、到期为 T 的市场期权价格。可加入额外惩罚项以保证 NIG 参数有效（$\delta>0$ 且 $|\alpha|>|\beta|$），以及期权价格满足无套利边界：$e^{-rT}(K-F_0)^+\le P_{NIG}(K,T)\le e^{-rT}K$. 为避免对不同参数反复采样，我们按如下方式生成 NIG 分布样本：$X=\mu+\delta(bx+\sqrt{x}W)$，其中 $b=\beta\delta$，W 为标准正态随机变量，x 从逆高斯分布中采样，具体为：$y=\mu_{ig}+\frac{1}{2}\mu_{ig}^2Z^2-\frac{1}{2}\mu_{ig}\sqrt{4\mu_{ig}Z^2+\mu_{ig}^2Z^4}$，$x=\begin{cases}y & \text{若 } U\le\frac{\mu_{ig}}{\mu_{ig}+y},\\ \frac{\mu_{ig}^2}{y} & \text{否则。}\end{cases}$ 其中 $a=\alpha\delta$，$\mu_{ig}=1/\sqrt{a^2-b^2}$，$U$ 服从 $[0,1]$ 上的均匀分布，Z 为标准正态随机变量。 *DEJD 模型（double exponential jump diffusion，双指数跳扩散）* 一个简单、直观且灵活的 log return 分布模型：$\ln(S_T/S_0)=\mu+\sigma\tilde Z+\begin{cases}\mathcal{E}_1/\eta_1 & \text{以概率 } p\lambda,\\ -\mathcal{E}_2/\eta_2 & \text{以概率 } (1-p)\lambda,\end{cases}$ 其中 $\tilde Z$ 为标准正态随机变量，$\mathcal{E}_1$ 与 $\mathcal{E}_2$ 为两个相互独立、均值为 1 的指数随机变量。λ 是发生跳跃的概率。p 是在发生跳跃条件下正向跳跃的概率。$1/\eta_1$ 与 $1/\eta_2$ 分别是正向与负向跳跃的均值。

时间序列数据分析 金融收益的风格化事实 资产价格随时间记录的序列往往非平稳↔收益率往往平稳、围绕某一常数水平上下波动 标普 500 的收益率厚尾且左偏；随着采样频率提高，收益率分布越来越厚尾，而左偏在不同采样频率下都相当明显且持续存在 随着采样频率提高，波动率聚集现象越来越明显，高波动时期往往会跟随高波动时期 *自相关函数（ACF）* 定义为 $\rho(k)=\frac{\gamma(k)}{\gamma(0)}$，其中 $\gamma(k)$ 为*自协方差函数*：$\gamma(k)=\mathrm{Cov}(r_t,r_{t-k})\approx\frac{1}{T-k}\sum_{t=k+1}^{T}(r_t-\bar r)(r_{t-k}-\bar r)$. 对于对数收益，$k\geq1$ 时 $\rho(k)\approx0$；而对于平方收益，$\rho(k)$ 缓慢衰减，表明存在*长程依赖* 当 SPX 指数下跌时，公司*杠杆*变高，公司的风险上升，从而导致波动率（用 VIX 代理）上升 有效市场假说与金融收益的统计模型 *EMH* 认为，资产价格反映了所有可获得的信息，利用任何信息都不可能持续地获得超额收益。**弱式**：资产当前价格反映所有过去公开可得的信息，**半强式**：资产当前价格反映所有公开可得的信息，**强式**：资产当前价格反映所有信息，包括公开与非公开信息。 *EMH 与资产收益的一般动态* 在 EMH 下，资产收益过程可以表示为 $r_t=\mu_t+\varepsilon_t$，其中 μ_t 是在 $t-1$ 时刻基于所有公开可得信息对 r_t 的理性预期或最小二乘预测（根据风格化事实，可令 $\mu_t=\mu$ 为常数）；ε_t 是由于 $t-1$ 到 t 之间到来的新信息而产生的不可预测收益，称为 创新项（innovation），并被设定为 白噪声 过程：ε_t 不存在序列相关，即 $\mathrm{Cov}(\varepsilon_t,\varepsilon_{t-k})=0$，对所有 $k\geq1$；$\mathrm{Var}(\varepsilon_t)=\sigma^2$ *对创新项的两个更强假设* **IID 创新项**：$\varepsilon_t\sim\text{i.i.d.}(0,\sigma^2)$. **鞅差（MD）创新项**：$\mathbb{E}[\varepsilon_t|r_{t-1},r_{t-2},\cdots]=\mathbb{E}[\varepsilon_t|\varepsilon_{t-1},\varepsilon_{t-2},\cdots]=0$，其中 $\varepsilon_{t-1},\varepsilon_{t-2},\cdots$ 是 $t-1,t-2,\cdots$ 时刻的创新项。（一个常用的鞅差创新项例子：$\varepsilon_t=\sigma_t\eta_t$，其中 $\eta_t\sim\text{i.i.d.}(0,1)$） IID $\implies$ 鞅差 $\implies$ 白噪声：i.i.d. 创新项是最强的假设，但它与风格化事实（平方收益存在长程依赖）相矛盾；鞅差创新项是折中且最常用的假设：收益 不可预测、但波动率 可能可预测。 *白噪声检验：Ljung-Box 检验* Ljung-Box 统计量定义为 $Q(m)=T(T+2)\sum_{k=1}^{m}\frac{\hat\rho(k)^2}{T-k}$，其中 $\hat\rho(k)$ 是收益的样本自相关函数（ACF），m 是预先指定的正整数。 当 $Q(m)>\chi^2_{1-\alpha}(m)$ 时，或当 $Q\sim\chi^2(m)$ 下 p 值 $\mathbb{P}(Q>Q(m))<\alpha$ 时，我们在显著性水平 α 下拒绝“白噪声”的原假设。使用过长的数据可能会导致拒绝白噪声的原假设 *ADF 检验* 是检验 单位根（即序列非平稳）这一原假设的常用方法。原假设：$\alpha=1$；备择假设：$\alpha<1$。检验统计量：$\mathrm{DF}=\frac{\hat\alpha-1}{\mathrm{SE}(\hat\alpha)}$，三种版本：**无常数/趋势项**：$\ln S_t=\alpha\ln S_{t-1}+\sum_{i=1}^{p}\beta_i\Delta\ln S_{t-i}+\varepsilon_t$；**仅常数项**：$\ln S_t=\alpha\ln S_{t-1}+\beta+\sum_{i=1}^{p}\beta_i\Delta\ln S_{t-i}+\varepsilon_t$；**常数项与趋势项**：$\ln S_t=\alpha\ln S_{t-1}+\beta+\gamma t+\sum_{i=1}^{p}\beta_i\Delta\ln S_{t-i}+\varepsilon_t$。 金融收益的时间序列模型 *平稳时间序列* 指时间序列 $\{X_t\}$ 的均值与方差为常数，并且不同时刻之间的协方差也为常数，即 $\mathbb{E}[X_t]$，$\mathrm{Var}(X_t)$，$\mathrm{Cov}(X_t,X_{t-k})$ 与 t 无关。平稳时间序列的 ACF 为：$\rho(k)=\frac{\gamma_k}{\gamma_0}$，其中 $\gamma_k=\mathrm{Cov}(X_t,X_{t-k})$。 *强平稳* 对任意 $h\geq0$ 与任意 t，$(X_t,X_{t-1},\cdots,X_{t-k})$ 的联合分布与 $(X_{t+h},X_{t+h-1},\cdots,X_{t+h-k})$ 的联合分布相同 MA(q) 模型 定义为：$X_t=\mu+\varepsilon_t+\sum_{i=1}^{q}a_i\varepsilon_{t-i}$，其中 $\varepsilon_t\sim\mathrm{WN}(0,\sigma^2)$ 是 t 时刻不可观测的创新项，$a_1,a_2,\cdots,a_q$ 为参数。 MA(q) 模型总是平稳的。 $\mathbb{E}[X_t]=\mu$，$\mathrm{Var}(X_t)=\sigma^2(1+a_1^2+a_2^2+\cdots+a_q^2)$，$\mathrm{Cov}(X_t,X_{t-|k|})=\sigma^2\left(a_{|k|}+\sum_{i=1}^{q-|k|}a_{|k|+i}a_i\right)$，$|k|\leq q$，$\mathrm{Cov}(X_t,X_{t-k})=0$，$|k|>q$. *MA(q) 模型的 ACF* $\rho(k)=\begin{cases}\frac{a_{|k|}+\sum_{i=1}^{q-|k|}a_{|k|+i}a_i}{1+a_1^2+a_2^2+\cdots+a_q^2}, & |k|\leq q,\\ 0, & |k|>q.\end{cases}$ MA(q) 模型的 ACF 与 σ^2,μ 无关，并且在 q 阶之后截尾 假设 $\varepsilon_t\sim\text{i.i.d.}(0,\sigma^2)$ 且 $\mathbb{E}[\varepsilon_t^4]<\infty$，则有 $\sqrt{T}\hat\rho(k)\xrightarrow{d}\mathcal{N}\left(0,1+2\sum_{i=1}^{q}\rho(i)^2\right)$，$k>q$，当样本量 $T\to\infty$，其中 $\hat\rho(k)$ 为收益的样本 ACF。可用上式通过检验原假设 $\rho(k)=0$ 来*确定 MA 模型的阶数*，并将 q 取为使得原假设仍被拒绝的最大整数 *MA 模型的识别与可逆性* 考虑两个 MA(1) 模型：$X_t=\varepsilon_t+a\varepsilon_{t-1}$，$\varepsilon_t\sim\text{i.i.d.}(0,\sigma^2)$，$Y_t=e_t+a^{-1}e_{t-1}$，$e_t\sim\text{i.i.d.}(0,a^2\sigma^2)$. 两个模型在观测上等价，即它们具有相同的 ACVF，从而具有相同的 ACF。因此我们无法仅凭 ACF 识别二者。为解决此问题，我们可以施加 $|a|<1$ 的限制。这等价于 MA 模型的**可逆性条件**。对 MA(q) 模型，可逆性条件 是特征多项式 $1+a_1z+a_2z^2+\cdots+a_qz^q=0$ 的所有根都在单位圆之外 AR(p) 模型 定义为：$X_t=c+\sum_{i=1}^{p}b_iX_{t-i}+\varepsilon_t$，其中 $\varepsilon_t\sim\mathrm{WN}(0,\sigma^2)$ 是 t 时刻不可观测的创新项，$b_1,b_2,\cdots,b_p$ 为参数。 AR(p)模型并不总是平稳。 例如，AR(1) 模型 $X_t=bX_{t-1}+\varepsilon_t$ 在 $|b|<1$ 时平稳，在 $|b|\geq1$ 时非平稳。 *平稳的 AR(p) 模型* 当特征多项式 $1-b_1z-b_2z^2-\cdots-b_pz^p=0$ 的 p 个根都在单位圆之外，即根的模都大于 1 时，AR(p) 模型平稳。平稳 AR(p) 模型的 ACF 指数衰减，即当 $k\to\infty$ 时，$\rho(k)=\mathcal{O}(a^k)$，其中某个 $a<1$。若 AR(p) 模型平稳，则其*均值*为：$\mathbb{E}[X_t]=\frac{c}{1-b_1-b_2-\cdots-b_p}$. ACVF 满足所谓 **Yule-Walker 方程**：$\gamma(k)=b_1\gamma(k-1)+b_2\gamma(k-2)+\cdots+b_p\gamma(k-p)$，$k\geq1$. 我们可以先解出 $k\leq p$ 时的 $\gamma(k)$，再用 Yule-Walker 方程计算 $k>p$ 时的 ACVF。例如，对 AR(1) 模型 $X_t=bX_{t-1}+\varepsilon_t$，其 ACVF 与 ACF 为：$\gamma(k)=\begin{cases}\frac{\sigma^2}{1-b^2}, & k=0,\\ \frac{\sigma^2b^{|k|}}{1-b^2}, & |k|>0.\end{cases}$ $\rho(k)=\begin{cases}1, & k=0,\\ b^{|k|}, & |k|>0.\end{cases}$ *AR 模型是 MA(∞) 模型* 考虑 AR(1) 模型 $X_t=bX_{t-1}+\varepsilon_t$。可将其写为：$X_t=\varepsilon_t+b\varepsilon_{t-1}+b^2\varepsilon_{t-2}+\cdots==\sum_{i=0}^{\infty}b^i\varepsilon_{t-i}$，当 $|b|<1$ 时，该级数在均方意义下收敛。上述推导也可用滞后算子 B（$BX_t=X_{t-1}$）来表述：$X_t=(1-bB)^{-1}\varepsilon_t=\sum_{i=0}^{\infty}b^iB^i\varepsilon_t=\sum_{i=0}^{\infty}b^i\varepsilon_{t-i}$，当 $|b|<1$ 时在均方意义下收敛。 自回归模型总是可逆的 *AR 模型具有均值回归（Mean Reverting）* 令 $\mu=\mathbb{E}[X_t]=\frac{c}{1-\sum_{i=1}^{p}b_i}$，则有 $X_t-\mu=\sum_{i=1}^{p}b_i(X_{t-i}-\mu)+\varepsilon_t$. *确定 AR 模型的阶数* *偏自相关函数（PACF）* 定义为：在剔除中间变量 $X_2,X_3,\cdots,X_k$ 的线性依赖后，X_{k+1} 与 X_1 的相关系数。假设做如下回归：$\min_{\beta_0,\beta_1,\beta_2,\cdots,\beta_k}\mathbb{E}\left[\left(X_{k+1}-\beta_0-\sum_{i=1}^{k}\beta_iX_{k-i+1}\right)^2\right]$. PACF 为 $\pi(k)=\beta_k^*$，并在 p 阶之后截尾，即对 $k>p$ 有 $\pi(k)=0$。样本 PACF 可用观测序列做回归估计：$\min_{\beta_0,\beta_1,\beta_2,\cdots,\beta_k}\sum_{t=k+1}^{T}\left(X_t-\beta_0-\sum_{i=1}^{k}\beta_iX_{t-i}\right)^2$. 设真实模型为平稳 AR($p$) 且 $\varepsilon_t\sim\text{i.i.d.}(0,\sigma^2)$ 并满足 $\mathbb{E}[\varepsilon_t^4]<\infty$，则有 $\sqrt{T}\hat\pi(k)\xrightarrow{d}\mathcal{N}(0,1)$，$k>p$. ***ARMA(p, q) 模型*** 定义为：$X_t=c+\sum_{i=1}^{p}b_iX_{t-i}+\varepsilon_t+\sum_{i=1}^{q}a_i\varepsilon_{t-i}$，其中 $\varepsilon_t\sim\mathrm{WN}(0,\sigma^2)$ 是 t 时刻不可观测的创新项，$b_1,b_2,\cdots,b_p$ 与 $a_1,a_2,\cdots,a_q$ 为参数。ARMA(p,q) 模型的 平稳 条件 是特征多项式 $b(z)=1-b_1z-b_2z^2-\cdots-b_pz^p$ 的 p 个根都在单位圆之外。ARMA(p,q) 模型的 可逆 条件 是特征多项式 $a(z)=1+a_1z+a_2z^2+\cdots+a_qz^q$ 的 q 个根都在单位圆之外。 *平稳 ARMA 模型* 均值、方差与自协方差函数为：$\mathbb{E}[X_t]=\mu=\frac{c}{1-\sum_{i=1}^{p}b_i}$，$X_t-\mu=\sum_{j=0}^{\infty}\psi_j\varepsilon_{t-j}$，$\psi(B)=\frac{a(B)}{b(B)}$，$\mathrm{Var}(X_t)=\sigma^2\sum_{j=0}^{\infty}\psi_j^2$，$\mathrm{Cov}(X_t,X_{t-k})=\sigma^2\sum_{j=0}^{\infty}\psi_j\psi_{j+k}$，$\mathrm{Corr}(X_t,X_{t-k})=\frac{\sum_{j=0}^{\infty}\psi_j\psi_{j+k}}{\sum_{j=0}^{\infty}\psi_j^2}$. 可写为：$b(B)X_t=c+a(B)\varepsilon_t$. 若其平稳，则可写为：$X_t=\mu+a(B)^{-1}(1+b(B))\varepsilon_t=\mu+\varepsilon_t+\sum_{i=1}^{\infty}\alpha_i\varepsilon_{t-i}$，并满足 $\sum_{i=1}^{\infty}|\alpha_i|<\infty$，即一个 MA($\infty$) 过程（属于 因果过程 的类） 对*可逆的 ARMA(p, q) 模型*，可写为：$\varepsilon_t=a^{-1}(B)(b(B)X_t-c)=X_t-\mu^*-\sum_{i=1}^{\infty}\beta_iX_{t-i}$，其中 μ^* 与 β_i 为某些常数。这是一个 AR(∞) 过程。例如，对 ARMA(1, 1) 模型 $X_t=c+bX_{t-1}+\varepsilon_t+a\varepsilon_{t-1}$，可写为：$\varepsilon_t=(1+aB)^{-1}(X_t-bX_{t-1}-c)=(1-aB+a^2B^2-\cdots)(X_t-bX_{t-1}-c)=\sum_{i=0}^{\infty}(-a)^iB^i(X_t-bX_{t-1}-c)$. *ARMA 模型的自相关函数* *自相关*：ARMA(p,q) 过程的自相关函数呈指数衰减趋近于 0：不会截尾，而是随着 $|k|$ 增大逐渐消失，可能伴随阻尼振荡；当 $|k|>\max(p,q+1)$ 时，ARMA(p,q) 过程的自相关函数形状与 AR(p) 过程类似。*偏自相关*：ARMA(p,q) 过程的偏自相关函数会逐渐消失（与 MA(q) 模型相同的性质）。 ARMA 模型的阶数比 AR 和 MA 更难确定。 *ARMA 模型的高斯 MLE* 尽管创新项不一定服从高斯分布，仍可使用 **高斯 MLE** 来估计 ARMA 模型参数，从而得到一致的参数估计。此时，$\boldsymbol{X}=(X_1,X_2,\cdots,X_T)$ 服从联合正态分布，均值向量为 $\boldsymbol{\mu}$，协方差矩阵为依赖模型参数 $(c,\boldsymbol{a},\boldsymbol{b},\sigma^2)$ 的 $\boldsymbol{\Sigma}$。则 $\boldsymbol{X}$ 的联合密度为：$f(\boldsymbol{X})=\frac{1}{(2\pi)^{T/2}|\boldsymbol{\Sigma}|^{1/2}}\exp\left(-\frac{1}{2}(\boldsymbol{X}-\boldsymbol{\mu})^T\boldsymbol{\Sigma}^{-1}(\boldsymbol{X}-\boldsymbol{\mu})\right)$. 对数似然函数为：$\ell(\boldsymbol{\theta})=\log L(\boldsymbol{\theta})=-\frac{T}{2}\log(2\pi)-\frac{1}{2}\log|\boldsymbol{\Sigma}|-\frac{1}{2}(\boldsymbol{X}-\boldsymbol{\mu})^T\boldsymbol{\Sigma}^{-1}(\boldsymbol{X}-\boldsymbol{\mu})$. 若真实分布并非高斯，则得到的估计量为 **准 MLE（quasi-MLE）** *ARMA 模型的统计推断* 得到参数的 MLE $\hat{\boldsymbol{\theta}}$ 后，可进行参数的统计推断。例如，可用 ***Wald 检验*** 检验参数显著性。$W=(\hat{\boldsymbol{\theta}}-\boldsymbol{\theta}_0)^T\widehat{\mathrm{Var}}(\hat{\boldsymbol{\theta}})^{-1}(\hat{\boldsymbol{\theta}}-\boldsymbol{\theta}_0)\xrightarrow{\sim H_0}\chi^2(p)$，其中 p 为参数个数，$\widehat{\mathrm{Var}}(\hat{\boldsymbol{\theta}})=-\partial^2\ell(\hat{\boldsymbol{\theta}})/\partial\boldsymbol{\theta}\partial\boldsymbol{\theta}^T$ 为 $\hat{\boldsymbol{\theta}}$ 的协方差矩阵（也称 ***Fisher 信息矩阵***）。若要计算某个光滑函数 $f(\hat{\boldsymbol{\theta}})$ 的标准误，可用 ***Delta 方法***：$\mathrm{Var}(f(\hat{\boldsymbol{\theta}}))\approx\partial f(\hat{\boldsymbol{\theta}})/\partial\boldsymbol{\theta}^T\widehat{\mathrm{Var}}(\hat{\boldsymbol{\theta}})\partial f(\hat{\boldsymbol{\theta}})/\partial\boldsymbol{\theta}$. 渐近地，我们可假设 $\hat{\boldsymbol{\theta}}$ 的分布为高斯 *如何确定 ARMA 模型的阶数* AIC $=-2\log\hat L+2(p+q+1)$，BIC $=-2\log\hat L+\log(T)(p+q+1)$，其中 $\hat L$ 为最大化后的对数似然函数值，p 与 q 分别为 AR 与 MA 部分的阶数 *模型诊断：残差分析* 拟合模型后，我们可以计算残差：$\hat\varepsilon_t=X_t-\sum_{i=1}^{p}\hat b_iX_{t-i}-\sum_{i=1}^{q}\hat a_i\hat\varepsilon_{t-i}-\hat c$，$t=p+1,p+2,\cdots,T$，其中初始值 $\hat\varepsilon_{p+1-i},i=1,2,\cdots,q$ 可设为 0。多数软件包会退化到 AR(∞) 来计算残差。此外，我们还可以用 Ljung-Box 检验来检验残差自相关的显著性，自由度为 $m-p-q$，其中 m 为滞后阶数 *用 ARMA 模型进行预测* 一般而言，我们关心在估计出模型参数后，对序列未来值的点预测。 $X_{T+h}=c+\sum_{i=1}^{p}b_iX_{T+h-i}+\varepsilon_{T+h}+\sum_{i=1}^{q}a_i\varepsilon_{T+h-i}$. 对两边在时间 T 的信息集下取期望，得到：$\mathbb{E}_T[X_{T+h}]=c+\sum_{i=1}^{p}b_i\mathbb{E}_T[X_{T+h-i}]+\sum_{i=1}^{q}a_i\mathbb{E}_T[\varepsilon_{T+h-i}]$，其中 $\mathbb{E}_T[\varepsilon_{T+h-i}]=\begin{cases}0, & i<h,\\ \varepsilon_{T+h-i}, & i\geq h.\end{cases}$ 为计算预测误差，我们调用 ARMA 模型的 MA(∞) 表示：$X_t=\mu+\varepsilon_t+\sum_{i=1}^{\infty}\psi_i\varepsilon_{t-i}$. 这意味着 $X_{T+h}=\mu+\varepsilon_{T+h}+\sum_{i=1}^{\infty}\psi_i\varepsilon_{T+h-i}$. 因此，$\mathrm{Var}_T[X_{T+h}]=\sigma^2\left(1+\sum_{i=1}^{h-1}\psi_i^2\right)$. 有时序列本身不平稳，但其一阶差分序列平稳。此时可先对序列做一阶差分，再对差分序列拟合 ARMA 模型。 ARIMA(p,d,q) 模型 定义为：$\nabla^dX_t=c+\sum_{i=1}^{p}b_i\nabla^dX_{t-i}+\varepsilon_t+\sum_{i=1}^{q}a_i\varepsilon_{t-i}$，其中 ∇^d 是 d 阶差分算子，即 $\nabla^dX_t=(\nabla^{d-1}X_t)-(\nabla^{d-1}X_{t-1})$，并约定 $\nabla^0X_t=X_t$。d 阶差分可以去除形如 t^d 的多项式趋势 *季节性 ARIMA 模型* 有些序列具有季节性，即存在周期性模式。此时可做季节差分以去除季节模式，再对季节差分序列拟合 ARIMA 模型。例如，iPhone 的月销量具有季节性，季节差分用于去除季节模式：$Y_t=X_t-X_{t-4}=(1-B^4)X_t$. 通过 GARCH 模型进行波动率建模 *波动率估计* 波动率无法直接观测，需要从观测到的价格序列中估计：*1.* **隐含波动率**：由期权价格隐含的波动率，例如 VIX。*2.* **实现波动率**：由观测到的价格序列估计，例如某一天的日内收益平方和。*3.* **条件波动率**：由 ARCH、GARCH 等动态模型估计。