概率论与数理统计

李启寨　孟珍　编著

目录

第一章　概率论中的基本概念 1
1.1 事件及其运算 1
1.2 古典概率与几何概率 7
1.3 条件概率与事件独立 16
1.4 全概率公式与Bayes公式 24
习题一 28

第二章　一元随机变量及其概率分布 36
2.1 随机变量的定义 36
2.2 离散型随机变量及常见离散分布 39
2.3 连续型随机变量及常见连续分布 43
2.4 随机变量的函数的概率分布 48
习题二 53

第三章　多元随机变量及其概率分布 58
3.1 多元随机变量的定义 58
3.2 边缘分布 63
3.3 条件概率分布 66
3.4 随机变量的独立性 71
3.5 多元随机变量的函数的概率分布 76
3.6 多元正态分布 85
习题三 88

第四章　随机变量的数字特征和极限性质 97
4.1 数学期望 97
4.2 方差 104
4.3 条件期望 110
4.4 协方差和相关系数 114
4.5 其它数字特征 121
4.6 大数定律 125
4.6 中心极限定理 132
习题四 133

第五章　数理统计中的基本概念 144

5.1 样本和统计量 146
5.2 三大分布 153
5.3 正态总体样本均值和样本方差的分布 159
5.4 相关系数 163
习题五 166

第六章　参数估计 170
6.1 点估计 170
6.2 无偏性和有效性 180
6.3 相合性和渐近正态性 191
6.4 区间估计 197
习题六 205

第七章　假设检验 213
7.1 基本概念 213
7.2 重要参数检验 218
7.3 拟合优度检验 227
7.4 非参数检验 233
7.5 三大检验 236
7.6 假设检验与区间估计之间的关系 240
习题七 242

第八章　线性回归分析 249
8.1 基本概念 249
8.2 最小二乘估计 251
8.3 最小二乘估计的性质 255
8.4 模型系数的检验 63
习题八 266

第一章　概率论中的基本概念

概率论是一门研究随机现象数量规律的学科，它是数学中的一个重要分支。最早关于概率问题的记载是1494年 Pacioli (1445-1517) 提出的赌博中如何分赌本的问题。1550年 Cardano (1501-1576) 在其书《论赌博》中讨论了概率的加法和乘法问题。1654年，Pascal (1623-1662) 与 Fermat (1607-1665) 通过信件多次讨论赌博中如何计算概率等问题。随后 Huyghens (1629-1695) 在研究赌博中的概率问题时提出了概率论的一些基本概念，如事件、概率和数学期望等，并出版了有关概率论的书《掷骰子的博弈中如何推理》。1812年 Laplace (1749-1827) 在其书《分析概率论》中给出了古典概率的明确定义。后来，Bernoulli (1654-1705)、de Moivre (1667-1754)、Gauss (1777-1855) 和 Poisson (1781-1840) 等关于大数定律和中心极限定理的结果奠定了概率论的基础。1933年 Kolmogorov (1903-1987) 建立了概率论的公理化体系，随后概率论得到了快速的发展。

1.1 事件及其运算

1.1.1 随机事件

考察一种光学现象，彩虹，它是水滴在太阳光的反射及折射下形成的拱形七彩光谱。一场雨后天空中可能出现彩虹，也可能不出现彩虹，彩虹的出现具有一定的随机性。人们通过长期观察发现雨后刚转晴时，天空更容易出现彩虹。自然界中有许多类似彩虹的现象，它们发生的结果事先不能确定。通过长期观察，人们可以对它们发生的结果总结出一些规律，这种现象，我们称之为随机现象。下面给出其具体定义。

随机现象：自然界中的客观现象，它发生的结果至少有两种可能性，事先不能确定哪种结果会出现，一旦发生只会出现其中的一种结果。

例1.1 随机抛一枚质地均匀的硬币2次，考察正面朝上的次数，有3种可能的结果：0, 1, 2.

随机现象在生活中无处不在。例如：

(1)每天到天安门广场参观的游客数；

(2)每天上午7点至9点经过一个十字路口的车辆数；

(3)每年7月份某地区的降雨量。

除随机现象外，自然界中还存在着一种现象，在特定的条件下，它们发生的结果总是确定的，我们称它们为确定现象。比如：在一个标准大气压下水加热到100℃会沸腾，质量守恒定律等。

有了随机现象，一个自然的问题是：什么时候随机现象会发生呢？这牵涉到随机试验，下面给出随机试验的定义。

随机试验：称一个满足下面3个条件的试验是随机试验：

(1)在同样的条件下，试验可重复进行；

(2)它发生的所有可能的结果是明确可知的，并且结果的个数大于等于2；
(3)每次试验出现的结果事先不知道。
简单地说，随机试验是随机现象的实现，随机试验简称试验。

有了随机现象和随机试验后，我们就可以定义随机事件了。随机事件贯穿于概率论与数理统计课程的各项知识点内容。比如后面讲述的随机变量，统计量等内容，虽然我们不提随机事件，但它们都与随机事件密切相关。

基本事件：随机试验中的每一个可能的结果。

例1.2 随机抛掷一枚质地均匀的硬币2次。基本事件是：{两次都是正面朝上}、{第一次正面朝上，第二次反面朝上}、{第一次反面朝上，第二次正面朝上}、{两次都是反面朝上}。

随机事件：随机试验中可能出现的各种结果，它由一个或多个基本事件组成。随机事件简称事件，常用大写英文字母比如A, B, C表示，如果用语言表述，常用大括号{ }括起来表示。

必然事件：随机试验中一定会发生的事件。一般用Ω表示。

不可能事件：随机试验中不可能发生的事件。一般用ϕ表示。

由于试验结果是确定的，必然事件和不可能事件本质上不是随机事件。然而，为了研究方便，我们把它们视为随机事件的两个极限情形。

一方面，随机试验所有可能的结果是明确的，而且每种可能的结果对应于基本事件；另一方面，统计推断的目的是利用已有的观测数据来推断未知的规律性。因此，为了更好地界定所研究问题的范围，我们给出样本空间和样本点的概念。

样本空间：随机试验中所有基本事件构成的集合，对应于必然事件。一般用Ω表示。

样本点：样本空间的一个点，对应于基本事件。一般用ω表示。

例1.3 一盒子里有2个白球和1个红球。2个白球的编号为W_1, W_2, 1个红球的编号为R_1. 依次不放回地从盒子里摸球两次，每次摸1个球，用(X_1, X_2)表示两次摸到球的编号，那么样本空间为

$$\Omega = \big\{(W_1, W_2), (W_1, R_1), (W_2, W_1), (W_2, R_1), (R_1, W_1), (R_1, W_2)\big\}.$$

1.1.2 事件的关系与运算

事件与概率是密不可分的，事件发生的概率的计算通常涉及到事件之间的关系和运算。一个样本空间Ω可以包含很多个事件。从集合的观点来看，这些事件都是样本空间的子集，可以利用集合之间的关系和运算来定义事件之间的关系和运算。首先定义一个事件A的发生：在一次试验中，至少有一个A所包含的基本事件发生，称A发生。记A和B为同一试验下的两个事件，下面给出事件的关系和运算法则。

事件的包含和相等：当A发生时，B必发生，称B包含A, 记作$A \subset B$，如图1.1所示。若$A \subset B$且$B \subset A$, 称A与B相等，记作$A = B$.

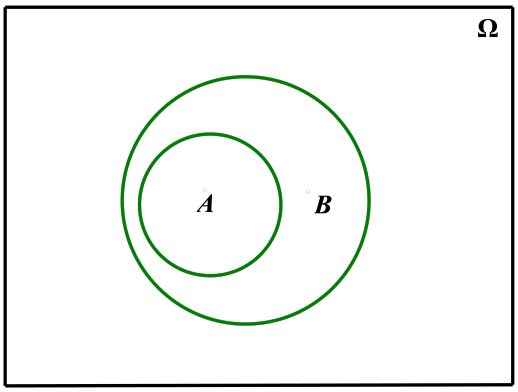


图 1.1 事件B包含A, Ω是必然事件。

例1.4 打靶时，某人打一枪，令事件A ={命中8环}，B ={命中的环数小于9}，易知$A \subset B$.

事件的并：A和B至少有一个发生的事件称为A和B的并，记作$A \cup B$，如图1.2 所示。

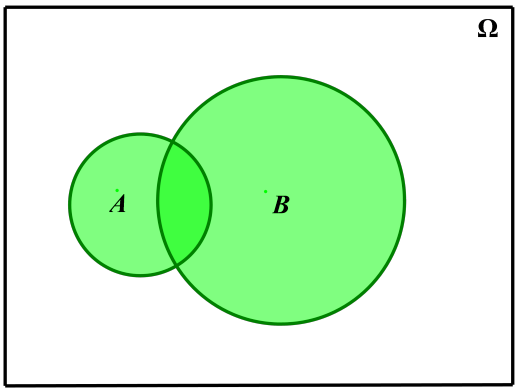


图 1.2 事件A和B的并，Ω是必然事件。

$A \cup B = B \cup A$, $A \cup \Omega = \Omega$, $A \cup \phi = A$.

事件的交：A和B同时发生的事件称为A与B的交，记作$A \cap B$, 简记为AB, 如图1.3 所示。

$A \cap B = B \cap A$, $A \cap \Omega = A$, $A \cap \phi = \phi$.

事件的差：A发生且B不发生的事件称为A和B的差，记作$A \backslash B$, 如图1.4所示。

事件的互斥(或**互不相容**)：若A, B不能在同一次试验中都发生，但可以都不发生，即$A \cap B = \phi$, 称它们是互斥的，或互不相容的，如图1.5所示。如果一些事件中任意两个事件都互斥，则称这些事件是两两互斥的，简称它们是互斥的。

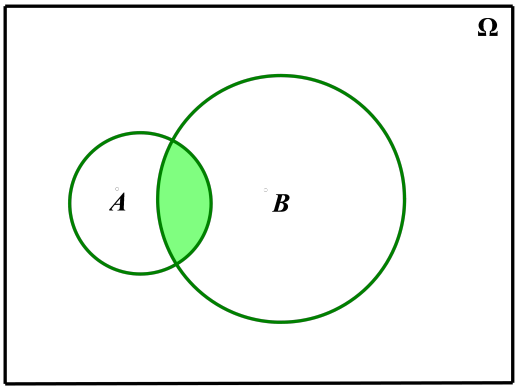


图 1.3 事件A和B的交，Ω是必然事件。

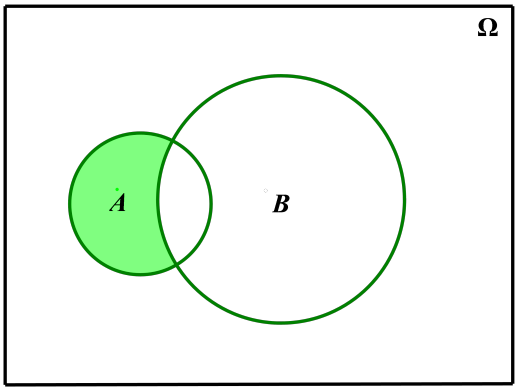


图 1.4 事件A和B的差，Ω是必然事件。

由于事件是由一些基本事件组成，所以两个事件互斥是指构成这两个事件的基本事件没有相同的。

例1.5 奥运会上某项目比赛，事件{一运动员获金牌}与{该运动员获银牌}是互斥的。

事件的对立：A不发生的事件称为A的对立事件，记为$\bar{A}$, 如图1.6 所示。

易知：

(1)Ω和ϕ互为对立事件；

(2)A和B互为对立事件的充要条件：$A \cap B = \phi$ 且$A \cup B = \Omega$;

(3)对立事件一定是互斥事件，因为$A \cap \bar{A} = \phi$; 然而互斥事件不一定是对立事件；

(4)$A \backslash B$可记为$A\bar{B}$.

事件的运算

交换律：$A \cup B = B \cup A,\ A \cap B = B \cap A.$

结合律：$A \cup (B \cup C) = (A \cup B) \cup C,\ (A \cap B) \cap C = A \cap (B \cap C).$

分配律：$A \cup (B \cap C) = (A \cup B) \cap (A \cup C),\ A \cap (B \cup C) = (A \cap B) \cup (A \cap C).$

对偶律，也称De Morgan公式：$\overline{A \cup B} = \bar{A} \cap \bar{B},\ \overline{A \cap B} = \bar{A} \cup \bar{B}.$

推广到多个或可列个事件，有

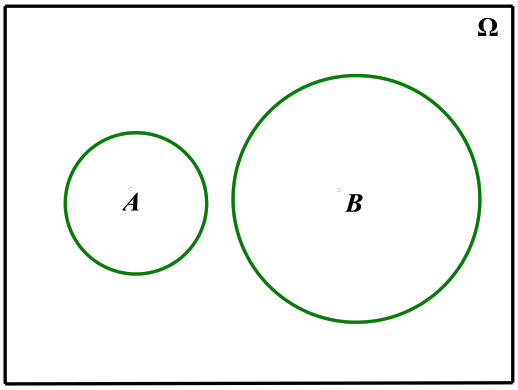


图 1.5 事件A和B互斥或互不相容，Ω是必然事件。

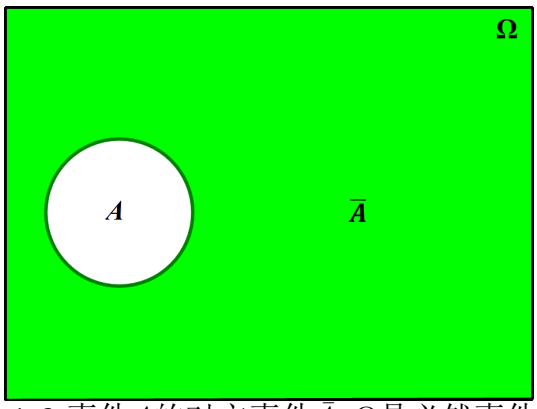


图 1.6 事件A的对立事件$\bar{A}$, Ω是必然事件。

分配律：$A \cup \left(\bigcap\limits_{i=1}^{n} B_i\right) = \bigcap\limits_{i=1}^{n}(A \cup B_i)$, $A \cap \left(\bigcup\limits_{i=1}^{n} B_i\right) = \bigcup\limits_{i=1}^{n}(A \cap B_i)$, n可以取∞.

对偶律：$\overline{\bigcup\limits_{i=1}^{n} A_i} = \bigcap\limits_{i=1}^{n} \bar{A}_i$，$\overline{\bigcap\limits_{i=1}^{n} A_i} = \bigcup\limits_{i=1}^{n} \bar{A}_i$, n 可以取∞.

证明思路：先说明等号左边的事件发生时等号右边的事件发生，再说明等式右边的事件发生时等号左边的事件发生。以证明分配律为例，其余类似。

下面证明：$A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$.

证明：(必要性) 记$\omega \in A \cup (B \cap C)$. 则$\omega \in A$或$\omega \in B \cap C$.

若$\omega \in A$, 有$\omega \in (A \cup B) \cap (A \cup C)$.

若$\omega \in B \cap C$, 有$\omega \in B$且$\omega \in C$, 进而$\omega \in (A \cup B) \cap (A \cup C)$.

因此，$A \cup (B \cap C) \subset (A \cup B) \cap (A \cup C)$.

(充分性)记$\omega \in (A \cup B) \cap (A \cup C)$, 则$\omega \in (A \cup B)$且$\omega \in (A \cup C)$.

若$\omega \in A$，有$\omega \in A \cup (B \cap C)$.

若$\omega \notin A$, 有$\omega \in B \cap C$. 进而，$\omega \in A \cup (B \cap C)$.

因此，$(A \cup B) \cap (A \cup C) \subset A \cup (B \cap C)$.

由事件相等的定义可知$A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$, 得证。

例1.6 令事件A和B满足$AB = \bar{A}\bar{B}$. 求证：$A = \bar{B}$.

证明：由对偶律知$AB = \bar{A}\bar{B} = \overline{A \cup B}$. 进一步

$$A \cup B = \overline{A \cap B}.$$

故$AB = \phi$, $A \cup B = \Omega$. 因此$A = \bar{B}$.

1.2 古典概率与几何概率

1.2.1 概率的公理化定义及性质

在随机试验中，事件发生的可能性大小尤为重要。人们将概率作为随机事件发生的可能性大小的数字表征，其值在0到1之间。事件发生的可能性大小称为主观概率。在概率论发展史上，曾有过概率的古典定义、几何定义、频率定义、主观定义等，然而它们的适用范围有限。比如Laplace 在1812年给出概率的古典定义只适用于古典概率模型，即样本空间有限且样本点发生的可能性都相同，后面会对此进行介绍。而后，1933年Kolmogorov 给出的概率的公理化定义极大地促进了概率论的发展。

概率的公理化： 令Ω是必然事件，ϕ是不可能事件，A和$A_1,\ A_2,\ \cdots,\ A_n$是$n+1$ 个事件，n 可以取∞, $P(\cdot)$ 表示事件发生的概率。则

(1) $P(\Omega)=1,\ P(\phi)=0$;

(2) $0\le P(A)\le 1$;

(3) (**加法公理**) 若$A_1,A_2,\cdots,A_n$是互斥的，则$P\Big(\bigcup\limits_{i=1}^{n}A_i\Big)=\sum\limits_{i=1}^{n}P(A_i)$.

概率的性质

令A和B是两个事件，有下列性质1-3成立。

性质1 $P(A)+P(\bar{A})=1$.

性质2 (**加法公式**) $P(A\cup B)=P(A)+P(B)-P(AB)$.

证明： 由于$A\cup B=A\cup(\bar{A}\cap B)$，且$A$与$\bar{A}\cap B$互斥，得

$$P(A\cup B)=P(A)+P(\bar{A}\cap B).$$

另一方面，$B=(B\cap\bar{A})\cup(B\cap A)$, 且$B\cap A$ 与$B\cap\bar{A}$互斥，得

$$P(B)=P(B\cap\bar{A})+P(B\cap A).$$

合并上述两式得证。

性质3 (Jordan公式) 对任意n个事件$A_1,A_2,\cdots,A_n$, 有

$$P\Big(\bigcup_{i=1}^{n}A_i\Big)=\sum_{i=1}^{n}P(A_i)-\sum_{1\le i<j\le n}P(A_iA_j)+\sum_{1\le i<j<k\le n}P(A_iA_jA_k)+\cdots+(-1)^{n-1}P(A_1A_2\cdots A_n). \tag{1.1}$$

证明： 采用数学归纳法。由加法公式知，当$n=2$时，(1.1)式成立。

假设当$n=m,m\ge 2$时，(1.1)式成立。当$n=m+1$时，由加法公式知

$$P\left(\bigcup_{i=1}^{m+1}A_i\right)=P\left(\left(\bigcup_{i=1}^{m}A_i\right)\cup A_{m+1}\right)=P\left(\bigcup_{i=1}^{m}A_i\right)+P(A_{m+1})-P\left(\left(\bigcup_{i=1}^{m}A_i\right)\cap A_{m+1}\right).$$

由假设知

$$\begin{aligned}P\left(\bigcup_{i=1}^{m}A_i\right) &= \sum_{i=1}^{m}P(A_i)-\sum_{1\le i<j\le m}P(A_iA_j)+\sum_{1\le i<j<k\le m}P(A_iA_jA_k)\\ &\quad-\sum_{1\le i<j<k<l\le m}P(A_iA_jA_kA_l)+\cdots+(-1)^{m-1}P(A_1A_2\cdots A_m),\end{aligned}$$

由分配律及假设知

$$\begin{aligned}
&P\left(\left(\bigcup_{i=1}^{m} A_i\right)\cap A_{m+1}\right)\\
&\quad= P\left(\bigcup_{i=1}^{m}(A_iA_{m+1})\right)\\
&\quad= \sum_{i=1}^{m} P(A_iA_{m+1}) - \sum_{1\le i<j\le m} P(A_iA_jA_{m+1}) + \sum_{1\le i<j<k\le m} P(A_iA_jA_kA_{m+1})\\
&\qquad - \sum_{1\le i<j<k<l\le m} P(A_iA_jA_kA_lA_{m+1}) + \cdots + (-1)^{m-1}P(A_1A_2\cdots A_mA_{m+1}).
\end{aligned}$$

合并上述三式得证。

有的书中将Jordan公式称为容斥原理。对于两个事件A和B, 有

$$P(A\cup B)\le P(A)+P(B).$$

对于n个事件$A_1, A_2, \cdots, A_n$, 有

$$P\left(\bigcup_{i=1}^{n} A_i\right)\le \sum_{i=1}^{n} P(A_i).$$

例1.7 考察三个事件A, B, C, 且$P(A) = 1/2$, $P(B) = 1/4$, $P(C) = 1/8$, $P(AB) = 1/16$, $P(AC) = 1/32$, $P(BC) = 0$. 求A, B, C中至少有一个事件发生的概率。

解： 由$ABC\subset BC$, 知$P(ABC) = 0$. 根据Jordan公式，

$$\begin{aligned}
P(A\cup B\cup C) &= P(A)+P(B)+P(C)-P(AB)-P(AC)-P(BC)+P(ABC)\\
&= \frac{1}{2}+\frac{1}{4}+\frac{1}{8}-\frac{1}{16}-\frac{1}{32}-0+0\\
&= \frac{25}{32}.
\end{aligned}$$

1.2.2 古典概率

随机抛掷一枚质地均匀的硬币1次，有两种可能的结果：正面朝上或反面朝上，这两种结果发生的概率相等，都等于0.5，但是它们不能同时发生，这是一类常见的概率模型。推广之，就是在一定条件下，一次随机试验有多种可能的结果，这些结果互斥，而且各结果出现的概率都相等，称这类模型为古典概率模型。具体定义如下。

古典概率模型： 令$A_1, A_2, \cdots, A_n$是n个事件，称满足下面三个条件的模型为古典概率模型：

(1)**(完备)** $\bigcup_{i=1}^{n} A_i$是必然事件；

(2)**(互斥)** $A_1, A_2, \cdots, A_n$互斥；

(3)**(等概率)** 对任何$i = 1, 2, \cdots, n$, $P(A_i) = 1/n$.

古典概率模型简单直观，有着许多方面的应用，如产品质量抽样调查。由于工厂生产的产品数量很多，全部检查不仅对产品造成破坏而且耗费大量的人力和财力，一般会从中随机抽出若干件产品进行检查，根据检查结果评估整批产品的质量情况(如合格品率或次品率)。这时候，我们可以认为每件产品被抽中的概率是相同的。称古典概率模型涉及到的概率为古典概率。计算古典概率时，需要确定具体问题的样本空间Ω中所有样本点的个数n，以及感兴趣的事件A所包含的样本点的个数m. 在计算中，常用到排列组合的知识。古典概率的计算实际上是排列组合的运算。在分析问题时，怎样选择一个合理的随机化的机制去正确的计算，保证不漏算和不重算非常关键。值得注意的是：所采用的分析机制是否真正实现了所有结果的等可能性。若事件A包含m个可能的结果，则$P(A) = m/n$.

定理1.1 把n件产品随机分成k组，记各组产品的数目分别为$r_1, r_2, \cdots, r_k$. 总的分法为$\dfrac{n!}{r_1!r_2!\cdots r_k!}$, 其中$n = \sum\limits_{i=1}^{k} r_i$.

证明：从n件产品中随机取出r_1件作为第一组，取法有$\binom{n}{r_1}$种；在余下的$n - r_1$件产品中随机取出r_2件作为第二组，取法有$\binom{n-r_1}{r_2}$ 种；依次类推，全部不同的取法为

$$\binom{n}{r_1}\binom{n-r_1}{r_2}\cdots\binom{n-r_1-r_2-\cdots-r_{k-1}}{r_k},$$

化简得$\frac{n!}{r_1!r_2!\cdots r_k!}$.

$\frac{n!}{r_1!r_2!\cdots r_k!}$是$(x_1 + x_2 + \cdots + x_k)^n$的展开式中$x_1^{r_1}x_2^{r_2}\cdots x_k^{r_k}$的系数，它在第三章多项分布的介绍中会用到。

定理1.2 把n件产品分成k组，其中第i组有n_i件产品，$i = 1, 2, \cdots, k$, $n = n_1 + n_2 + \cdots + n_k$, $k \geq 1$. 从这n件产品中随机取出m件，且

$$m = m_1 + m_2 + \cdots + m_k,\ 0 \leq m_i \leq n_i, i = 1, 2, \cdots, k.$$

令事件A =$\{$恰有m_i件产品属于第i组，$i = 1, 2, \cdots, k\}$. 则A发生的概率为

$$P(A) = \frac{\binom{n_1}{m_1}\binom{n_2}{m_2}\cdots\binom{n_k}{m_k}}{\binom{n}{m}}.$$

证明：从n件产品中随机取出m件，总的取法有$\binom{n}{m}$种。从n_i件产品随机取出m_i件的取法有$\binom{n_i}{m_i}$种，$i = 1, 2, \cdots, k$. 事件A发生的取法有$\binom{n_1}{m_1}\binom{n_2}{m_2}\cdots\binom{n_k}{m_k}$. 故$A$发生的概率为

$$P(A) = \frac{\binom{n_1}{m_1}\binom{n_2}{m_2}\cdots\binom{n_k}{m_k}}{\binom{n}{m}}.$$

下面给出一些有关古典概率模型的典型例子。

例1.8 甲、乙两人赌技相同。如果他们赌上奇数局，求甲赢的局数比乙赢的局数多的概率。

解：记$A=\{$甲赢的局数比乙赢的局数多$\}, B=\{$甲赢的局数比乙赢的局数少$\}$。有

$$AB=\phi,\ A\cup B=\Omega.$$

可知$1=P(A\cup B)=P(A)+P(B)$. 由于甲、乙两人赌技相同，知

$$P(A)=P(B).$$

因此，$P(A)=P(B)=0.5$.

例1.9 甲、乙两人赌技相同，各出赌注1000元，采用七局四胜制，胜者拿走全部2000元。现在已经赌了四局，甲三胜一负。由于某种原因要终止赌博，问这2000元如何分配才公平？

解：这2000元全部归甲对乙不公平，平均分对甲欠公平，如果按照3:1分公平吗？仔细想一下这样划分也未必公平。合理的做法是让甲、乙继续赌到七局必能分出胜负，最后三局的赢方有8种可能的结果：

甲甲甲、甲甲乙、甲乙甲、乙甲甲、甲乙乙、乙甲乙、乙乙甲、乙乙乙。

这8种结果具有等可能性，前7种结果都是甲赢。因此甲、乙双方最终赢的赌局的概率之比为7:1. 故甲分$1750(=2000\times 7/8)$元，乙分250元比较合理。

例1.10 一盒子里有1个白球和n个红球，每次从盒子里随机取出1个球并放进1个红球，如此下去，求第m次取的球是红球的概率。

解：令事件$A=\{$第m次取的球是红球$\}$，则$\bar{A}$表示$\{$第m次取的球是白球$\}$。直接计算$P(A)$比较困难，下面我们计算$P(\bar{A})$. 若$\bar{A}$ 发生，说明前$m-1$次都未取到白球，只在第m次取到了白球，即前$m-1$次取的球均为红球而第m次取的球为白球。因此

$$P(\bar{A})=\left(\frac{n}{n+1}\right)^{m-1}\frac{1}{n+1}=\frac{n^{m-1}}{(n+1)^m},$$

$$P(A)=1-\frac{n^{m-1}}{(n+1)^m}.$$

例1.11 (Banach火柴) (Banach, 1892-1945) Banach左右两个口袋各有1盒火柴，每盒有n根。每次他随机取出其中一盒中的一根使用。假设他每次取火柴时并不关注火柴盒里的火柴有多少根。求他首次发现其中一盒火柴已用完，另外一盒恰有m根的概率。

解：令$A=\{$取左口袋那盒火柴中的一根$\}$，那么，$\bar{A}=\{$取右口袋那盒火柴中的一根$\}$。Banach首次发现他左口袋的那盒火柴已空，右口袋那盒恰有m根，这时候巴拿赫已经在左口袋取了$n+1$次，右口袋取了$n-m$次。他一共做了$2n-m+1$次试验，其中前$2n-m$次试验，左口袋发生了n次。因此Banach发现左口袋的火柴已空，右口袋那盒恰有m根的概率为

$$\tbinom{2n-m}{n}0.5^n(1-0.5)^{n-m}0.5.$$

由对称性，Banach发现他右口袋的火柴已空，左口袋的火柴恰有m根的概率也为

$$\binom{2n-m}{n}0.5^n(1-0.5)^{n-m}0.5.$$

因此，所求的概率为

$$\binom{2n-m}{n}0.5^{2n-m}.$$

例1.12 (Maxwell-Boltzmann统计粒子) (Maxwell, 1831-1879; Boltzmann, 1844-1906) 有n个粒子，每个粒子以$1/N$的概率落入N个格子的其中一个，$N \geq n$. 求：

(1)某指定的n个格子中各有一个粒子的概率；

(2)任意n个格子各有一个粒子的概率。

解：由于每个粒子等可能地落入N个格子中的任意一个，共有N^n种可能。

(1)记A={指定的n个格子中各有一个粒子}. A发生的结果种数是n个粒子在指定的n个格子的全排列。故

$$P(A) = \frac{n!}{N^n}.$$

(2)记B={任意n个格子各有一个粒子}. 分两步走：第一步选格子，第二步选粒子。首先，n个格子可以任意选，即从N个格子选出n个格子，有$\binom{N}{n}$种可能；然后，对每种情况下选出的n个格子，每个格子有一个粒子，有$n!$种可能，从而B发生的可能情形有$\binom{N}{n}n!$种。故

$$P(B) = \frac{\binom{N}{n}n!}{N^n} = \frac{N!}{N^n(N-n)!}.$$

例1.13 一年按365天计算，求某班级n名同学中至少有两位同学生日相同的概率($n \leq 365$)。

解：记A={n名同学生日均不相同}. 则$\bar{A}$={至少有两位同学生日相同}. 把n名同学看成n个粒子，一年365天看成N个格子，则$N = 365$. A 发生的概率等价于例1.12的第(2)问，从而

$$P(A) = \frac{\binom{365}{n}n!}{N^n} = \frac{365!}{365^n(365-n)!}.$$

$P(A)$也可以这么算：n名同学生日均不相同，第1名同学的生日有365天供选择；第2名同学与第1名同学的生日不同，则有364天供选择；第3名同学与前2名同学的生日均不同，则有363天供选择；以此类推，第n名同学有$(365-n+1)$天供选择。故

$$P(A) = \frac{365 \times 364 \times \cdots \times (365-n+1)}{365^n}.$$

那么，至少有两名同学生日相同的概率是

$$P(\bar{A}) = 1 - \frac{365 \times 364 \times \cdots \times (365-n+1)}{365^n}.$$

当$n=40$时，$P(\bar{A})=1-0.109=0.891$, 可见40名同学中至少有两名同学的生日相同的概率是0.891. 当$n=100$ 时，概率为0.9999996, 说明100个同学中至少有两名同学的生日是同一天的概率非常接近1. 这有点和我们直觉有些不太符合，因此该例又称为**生日悖论**。

例1.14 某班有n名同学，一次考试阅卷结束后，老师随机把试卷发给同学们。求至少有一名同学拿到自己试卷的概率。

解：记这n张试卷为$L_1, L_2, \cdots, L_n$, 对应的n名同学为$E_1, E_2, \cdots, E_n$,

A={至少有一名同学拿到自己试卷}，A_i={试卷L_i发给E_i}，$i=1,2,\cdots,n$.

根据Jordan公式，有

$$P(A)=P\left(\bigcup_{i=1}^{n}A_i\right)=\sum_{k=1}^{n}(-1)^{k-1}q_k,$$

其中$q_k=\sum\limits_{1\le i_1<i_2<\cdots<i_k\le n}P(A_{i_1}A_{i_2}\cdots A_{i_k})$.

下面计算$P(A_i)$和$P(A_{i_1}A_{i_2}\cdots A_{i_k})$. 把$n$张试卷发给$n$名同学是一个排列问题，共有$n!$种可能的结果，试卷$L_i$发对了有$(n-1)!$种可能的结果，可得

$$P(A_i)=\frac{(n-1)!}{n!}=\frac{1}{n}, i=1,2,\cdots,n,$$

$$P(A_{i_1}A_{i_2}\cdots A_{i_k})=\frac{(n-k)!}{n!}.$$

进而有

$$q_k=\sum_{1\le i_1<i_2<\cdots<i_k\le n}P(A_{i_1}A_{i_2}\cdots A_{i_k})=\sum_{1\le i_1<i_2<\cdots<i_k\le n}\frac{(n-k)!}{n!}=\binom{n}{k}\frac{(n-k)!}{n!}=\frac{1}{k!}.$$

因此

$$P(A)=\sum_{k=1}^{n}(-1)^{k-1}q_k=\sum_{k=1}^{n}(-1)^{k-1}\frac{1}{k!}\approx 1-\frac{1}{2}+\frac{1}{6}-\frac{1}{24}+\frac{1}{120}-\frac{1}{720}\approx 0.632.$$

可见，至少有一名同学拿到自己的试卷的概率约为0.632.

例1.15 植树节到了，同学们围绕圆形操场一周来植树。把n棵松树和m棵银杏树随机植在操场一周，设$m\le n+1$. 记事件A={没有两颗银杏树相邻}。求$P(A)$.

解：由于操场是一个圆形，任何位置都是一样的。先选定一个棵松树固定一个位置，余下$n+m-1$ 棵树随机种植，一共有$(n+m-1)!$种可能。下面考察事件A发生的可能情形：分两步，首先植余下$n-1$ 棵松树，一共$(n-1)!$可能；松树植完后，两棵相邻的松树之间有n个位置可以植银杏树，种植银杏树的可能数目为$\binom{n}{m}m!$. 从而A发生的可能情形有$(n-1)!\binom{n}{m}m!$种。故

$$P(A)=\frac{(n-1)!\binom{n}{m}m!}{(n+m-1)!}=\frac{\binom{n}{m}}{\binom{n+m-1}{m}}.$$

1.2.3 几何概率

古典概率模型可以很好地刻画某一类问题。然而，它要求样本空间中样本点的总数必须有限。在实际问题中，有时样本空间Ω代表一个区域，可用长度、面积或体积等来度量，而该区域包含无限多个样本点。针对这种有无限多种结果且又有“某种等可能性”的情形，需要借助几何的方法来求解概率，这就是几何概率。我们接下来先介绍基本概念，再给出两个例子。

几何概率：令样本空间Ω是一个区域，其度量(一般是长度、面积或体积等)大小为S_Ω. 假定任意一个样本点落在度量相同的子区域内是等可能的。若事件A为Ω的某个子区域，其度量大小为S_A，则事件A 发生的概率为

$$P(A) = \frac{S_A}{S_\Omega}.$$

几何概率的求解一般要借助几何图形，找到样本空间Ω和事件A对应的区域，并计算它们的度量大小。

例1.16 从区间$[0, 10]$中随机取出两个数，求这两个数之和小于5的概率。

解：令x和y表示取到的两个数，关心的事件发生的可能结果构成区域

$$A = \{(x, y)|x + y < 5, 0 \le x, y \le 10\},$$

如图1.7中阴影部分所示，其面积为12.5. 所有可能的结果构成正方形

$$\Omega = \{(x, y)|0 \le x, y \le 10\},$$

其面积为100. 因此，所求概率为$12.5/100 = 1/8$.

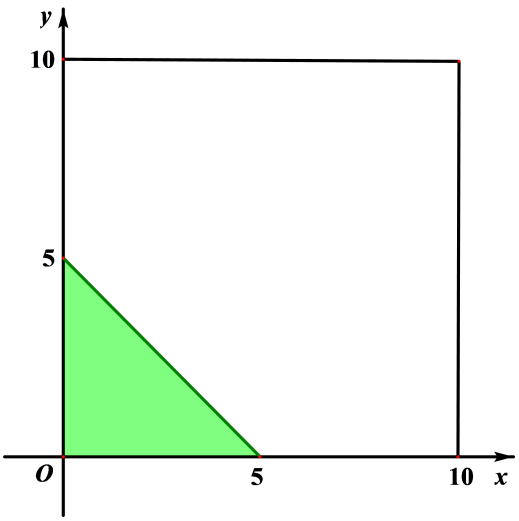


图1.7 从区间$[0, 10]$中随机取出两个数构成的区域。

例1.17 (Buffon投针) (Buffon, 1707-1788) 平面上画着许多条间距长度都为a单位的平行线，向此平面随机投掷一个长度为$k(k < a)$单位的针。求此针与任一平行线相交的概率。

解：以x表示针的中点到最近一条平行线的距离，θ表示针与该平行线的夹角。有

$$0 \le x \le a/2,\ 0 \le \theta \le \pi.$$

投针后所有可能的结果(x,θ)构成了长方形Ω,

$$\Omega = \left\{(x,\theta) : 0 \le x \le \frac{a}{2}, 0 \le \theta \le \pi\right\},$$

其面积为$S_\Omega = \pi a/2$.

针与平行线相交的条件：$x \le k\sin\theta/2$, 区域如图1.8中阴影部分所示。即

$$A = \left\{(x,\theta) : (x,\theta) \in \Omega, x \le \frac{k}{2}\sin\theta\right\},$$

其面积为

$$S_A = \int_0^\pi \int_0^{\frac{k}{2}\sin\theta} dxd\theta = \int_0^\pi \frac{k}{2}\sin\theta d\theta = k.$$

故此针与任一平行线相交的概率为

$$P(A) = \frac{S_A}{S_\Omega} = \frac{2k}{\pi a}.$$

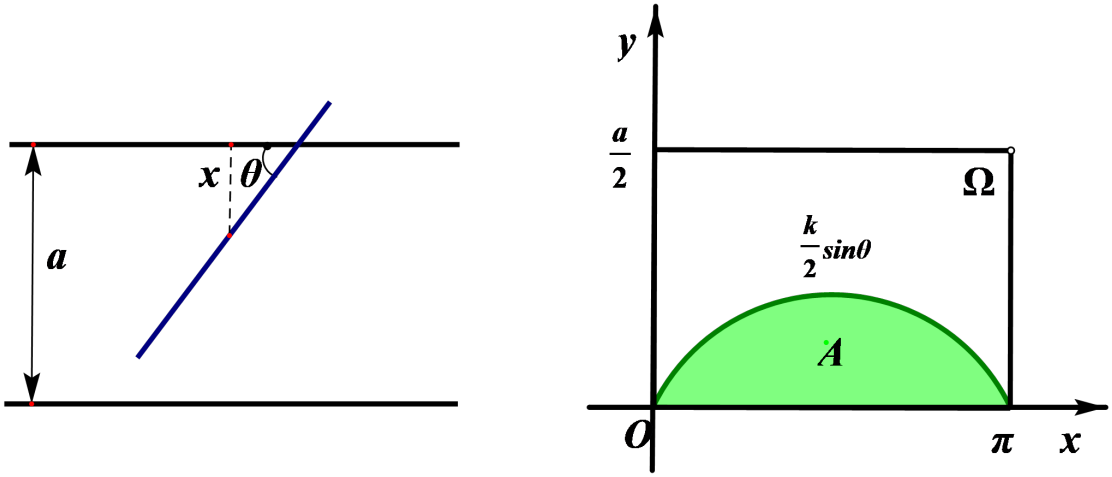


图1.8 平行线与针的位置及平行线与针相交构成的区域。

以几何概率为基础，下面给出必然事件、概率为1的事件、不可能事件、及概率为0的事件的区别。

称发生概率为1或0的事件为概率为1或0的事件，概率为0的事件又称零概率事件。概率为1或0的事件与必然事件或不可能事件是不一样的，主要总结为以下两点：

(1)必然事件发生的概率为1, 而概率为1的事件并非是必然事件。例如：A={向边长为k单位的正方形区域G任意投掷一点，此点落在区域g, g为正方形去掉对角线后所剩下的区域}。记S_G和S_g分别表示区域G和g的面积，那么

$$P(A) = \frac{S_g}{S_G} = \frac{k^2}{k^2} = 1.$$

(2)不可能事件发生的概率为0, 而概率为0的事件并非是不可能事件。例如：B={向边长为k单位的正方形区域G任意投掷一点，此点落在区域g, g为正方形的对角线}。令S_G和S_g分别表示区域G和g 的面积，那么

$$P(B) = \frac{S_g}{S_G} = \frac{0}{k^2} = 0.$$

1.3 条件概率与事件独立

1.3.1 条件概率

事件的发生总是伴随着一些试验条件，如已知某个信息或者已经发生某个事件等。在知道这些已有信息的条件下得到所关心事件的概率称为条件概率。例如甲、乙两厂生产同一品牌的洗衣机，两厂均向某一商场供货，商城中该品牌洗衣机有统一的次品率，比如1%。如果从某个途径知道该商场的这批洗衣机是甲厂生产的，则消费者买到的洗衣机的次品率不再是1%, 这个概率就是条件概率，其中“甲厂生产”是已知的条件。

考察古典概率模型，假设一试验有n个可能的结果，事件A和B分别包含其中的m_1和m_2个结果，两事件同时发生时有m_{12}个结果。若已知B已经发生，那么所关心的可能性结果缩小在这m_2个结果中，其中只有m_{12}个结果会使得A发生。所以，在已知事件B发生时，事件A发生的概率，记作$P(A|B)$，为m_{12}/m_2. 即

$$P(A|B)=\frac{m_{12}}{m_2}=\frac{m_{12}/n}{m_2/n}=\frac{P(AB)}{P(B)}.$$

它具有一般性，下面给出条件概率的定义。

条件概率：令A和B为两个事件，假定$P(B)>0$. 称

$$P(A|B)=\frac{P(AB)}{P(B)}$$

为在给定B发生的条件下，A发生的条件概率。

直观解释：因为试验是在一定的条件下进行的，所以样本空间是相对而言的。取了条件相当于把样本空间改变了，所以得到事件发生的概率一般是不同的。

几何解释：$P(A)$和$P(A|B)$是两个不同的概率。用矩形表示必然事件。定义$P(A)$为A的面积，那么$P(A|B)$表示在给定B下，A所占的比例，即AB这块面积在B的面积中所占的比例，如图1.9 所示。

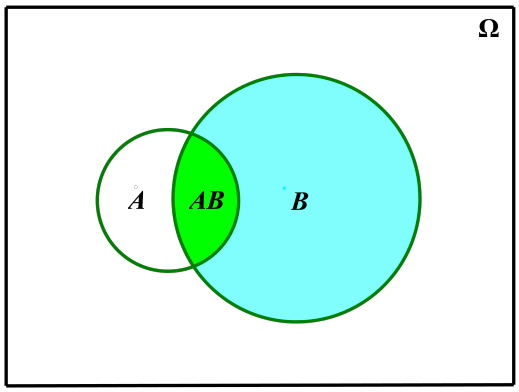


图1.9 条件概率$P(A|B)\big(=P(AB)/B(B)\big)$。

条件概率也是概率，它满足概率所具有的一切性质。

例1.18 (Wiener卡片)(Wiener, 1894-1964) 有三张相同的卡片，第一张卡片两面都涂成红色，第二张卡片一面涂成红色，另一面涂成紫色，第三张卡片两面都涂成紫色。从中随机取出一张，把它放在桌上。假设看到卡片上面的颜色是红色，问卡片下面是红色和紫色的概率一样吗？

解：记A =｛看到卡片上面的颜色是红色｝，B =｛卡片下面的颜色是红色｝，C =｛卡片下面的颜色是紫色｝。那么

$$P(B|A) = \frac{P(AB)}{P(A)} = \frac{1/3}{1/2} = \frac{2}{3}.$$

$$P(C|A) = \frac{P(AC)}{P(A)} = \frac{1/6}{1/2} = \frac{1}{3}.$$

因此，当看到卡片上面的颜色是红色，卡片下面是红色和紫色的概率是不一样的。

由$P(A|B) = P(AB)/P(B), P(B) > 0$ 可以得到

$$P(AB) = P(A|B)P(B).$$

上式是两个事件同时发生的概率。下面给出其一般形式的表述。

定理1.3 (乘法公式) 令$A_1, A_2, \cdots, A_n$是n 个事件，满足$P(A_1A_2\cdots A_{n-1}) > 0$, $n \geq 2$. 则

$$P(A_1A_2\cdots A_n) = P(A_1)P(A_2|A_1)\cdots P(A_n|A_1A_2\cdots A_{n-1}).$$

证明：由条件概率的定义可知

$$\begin{aligned}
\text{等式右边} &= P(A_1)\frac{P(A_1A_2)}{P(A_1)}\cdots P(A_n|A_1A_2\cdots A_{n-1}) \\
&= P(A_1A_2)\cdots P(A_n|A_1A_2\cdots A_{n-1}) \\
&= \cdots \\
&= P(A_1A_2\cdots A_{n-1})P(A_n|A_1A_2\cdots A_{n-1}) \\
&= P(A_1A_2\cdots A_n).
\end{aligned}$$

例1.19 一人想打电话给朋友，然而他忘了朋友的电话号码的最后一位数字，只知道该数字是奇数。因而他随机拨号，问他两次之内拨对电话的概率?

解：令事件A =｛两次之内拨对电话｝，令A_i=｛第i次拨对电话｝, $i = 1, 2$. 则

$$\begin{aligned}
P(A) &= P(A_1 \cup A_2) \\
&= 1 - P(\bar{A}_1\bar{A}_2) \\
&= 1 - P(\bar{A}_1)P(\bar{A}_2|\bar{A}_1) \\
&= 1 - \tfrac{4}{5} \times \tfrac{3}{4} \\
&= 0.4.
\end{aligned}$$

例1.20 Pólya模型 (Pólya, 1887-1985) 某盒子里有n个白球和m个红球。每次从中随机取出1个球并放进$k+1$个与取出的球的颜色相同的球。这样总共进行了N次。求前面N_1次取出的球是白球，后面$N_2(=N-N_1)$次取出的球是红球的概率。

解： 记A_i=$\{$第i次取出的球是白球$\}$, $i=1,2,\cdots,N_1$, A_j=$\{$第j次取出的球是红球$\}$, $j=N_1+1,N_1+2,\cdots,N$. 则

$$\begin{aligned}
P(A_1) &= \frac{n}{n+m},\\
P(A_2|A_1) &= \frac{n+k}{n+m+k},\\
P(A_3|A_1A_2) &= \frac{n+2k}{n+m+2k},\\
&\cdots\cdots\\
P(A_{N_1}|A_1A_2\cdots A_{N_1-1}) &= \frac{n+(N_1-1)k}{n+m+(N_1-1)k},\\
P(A_{N_1+1}|A_1A_2\cdots A_{N_1}) &= \frac{m}{n+m+N_1k},\\
P(A_{N_1+2}|A_1A_2\cdots A_{N_1+1}) &= \frac{m+k}{n+m+(N_1+1)k},\\
&\cdots\cdots\\
P(A_N|A_1A_2\cdots A_{N-1}) &= \frac{m+(N_2-1)k}{n+m+(N-1)k}.
\end{aligned}$$

故，前面N_1次取出的球是白球，后面$N_2=N-N_1$次取出的球是红球的概率为

$$P(A_1A_2\cdots A_N)=\frac{n}{n+m}\cdots\frac{n+(N_1-1)k}{n+m+(N_1-1)k}\frac{m}{n+N_1k+m}\cdots\frac{m+(N_2-1)k}{n+(N-1)k+m}.$$

1.3.2 事件独立

乘法公式可以用来计算两个事件同时发生的概率，即$P(AB)=P(A|B)P(B)$或者$P(AB)=P(B|A)P(A)$. 一个自然的问题是：什么情况下，$P(AB)=P(A)P(B)$呢？即事件A和B同时发生的概率等于两个事件各自发生概率的乘积。这是本节要介绍的事件的独立。我们先考虑两个事件相互独立，三个事件相互独立，然后推广到n个事件相互独立。

两个事件相互独立： 事件A和B满足$P(AB)=P(A)P(B)$. 称A, B相互独立，简称A, B 独立。

下面给出四点说明。

(1)上述定义也可描述为，若$P(A|B)=P(A)$, 称A和B相互独立。直观上解释是：A关于B的条件概率等于无条件概率$P(A)$，换句话说，B 的发生对A的发生与否没有任何影响时，则A, B相互独立。

(2)有时候从实际出发，分析事件的本质就可直观判断出它们是否独立。例

如某工厂生产不同产品的两台机器同时开工，事件{第一台机器24小时内正常运转}和{第二台机器30小时内正常运转}，这两个事件互不影响，相互独立。

(3)零概率事件和任何事件相互独立，概率为1的事件与任何事件相互独立。

(4)互斥事件不相互独立。假设有两个互斥事件A和B, A发生则B必然不发生。因此事件A, B具有一定的负相关性，不相互独立。

定理1.4 若四对事件$(A,B),(A,\bar{B}),(\bar{A},B)$ 和$(\bar{A},\bar{B})$中有一对事件相互独立，则另外三对事件也相互独立。

证明：只证明：当A与B相互独立，A与$\bar{B}$也相互独立，其它情形留作练习。

由于$A=(AB)\cup(A\bar{B})$且AB和$A\bar{B}$互斥，可得

$$P(A\bar{B})=P(A)-P(AB)=P(A)-P(A)P(B)=P(A)\big(1-P(B)\big)=P(A)P(\bar{B}).$$

三个事件相互独立： 若事件A,B,C同时满足下列四个等式：

$$P(AB)=P(A)P(B),\ \ P(AC)=P(A)P(C),$$

$$P(BC)=P(B)P(C),\ \ P(ABC)=P(A)P(B)P(C),$$

称A,B,C相互独立。

这四个条件缺一不可，下面给出两个例子说明之。

例1.21 令事件A, B相互独立，且$P(A)=P(B)=0.5$. 记$C=(AB)\cup(\bar{A}\bar{B})$. 求证：$A,B,C$ 两两独立但不相互独立。

证明：由于AB与$\bar{A}\bar{B}$是互斥的，且A,B相互独立，有

$$P(C)=P(AB)+P(\bar{A}\bar{B})=P(A)P(B)+P(\bar{A})P(\bar{B})=0.5,$$

$$P(AC)=P\big(A\cap(AB\cup\bar{A}\bar{B})\big)=P(AB)=P(A)P(B)=0.25=P(A)P(C).$$

同理

$$P(BC)=P(B)P(C).$$

然而

$$P(ABC)=P(AB)=\frac{1}{4}\neq\frac{1}{8}=P(A)P(B)P(C).$$

因此，A,B,C两两独立但不相互独立。

例1.22 令$\Omega=\{\omega_1,\omega_2,\omega_3,\omega_4\}$.

$$P(\omega_1)=\frac{\sqrt{5}}{2}-\frac{5}{6},\ \ P(\omega_2)=\frac{1}{3},$$

$$P(\omega_3)=\frac{7}{6}-\frac{\sqrt{5}}{2},\ \ P(\omega_4)=\frac{1}{3}.$$

记$A=\{\omega_1,\omega_3\}$, $B=\{\omega_2,\omega_3\}$, $C=\{\omega_3,\omega_4\}$. 求证：

$$P(ABC)=P(A)P(B)P(C),\text{但}A,B,C\text{不两两独立。}$$

证明： 由$ABC=\{\omega_1,\omega_3\}\cap\{\omega_2,\omega_3\}\cap\{\omega_3,\omega_4\}=\{\omega_3\}$可知

$$P(ABC)=P(\omega_3)=\frac{7}{6}-\frac{\sqrt{5}}{2}.$$

由于构成样本空间中的样本点$\{\omega_1\},\{\omega_2\},\{\omega_3\},\{\omega_4\}$是互斥的，则

$$\begin{aligned}
P(A) &= P(\omega_1)+P(\omega_3)=\left(\frac{\sqrt{5}}{2}-\frac{5}{6}\right)+\left(\frac{7}{6}-\frac{\sqrt{5}}{2}\right)=\frac{1}{3},\\
P(B) &= P(\omega_2)+P(\omega_3)=\frac{1}{3}+\left(\frac{7}{6}-\frac{\sqrt{5}}{2}\right)=\frac{3}{2}-\frac{\sqrt{5}}{2},\\
P(C) &= P(\omega_3)+P(\omega_4)=\left(\frac{7}{6}-\frac{\sqrt{5}}{2}\right)+\frac{1}{3}=\frac{3}{2}-\frac{\sqrt{5}}{2}.
\end{aligned}$$

所以

$$P(A)P(B)P(C)=\frac{1}{3}\left(\frac{3}{2}-\frac{\sqrt{5}}{2}\right)\left(\frac{3}{2}-\frac{\sqrt{5}}{2}\right)=\frac{7}{6}-\frac{\sqrt{5}}{2}.$$

即

$$P(ABC)=P(A)P(B)P(C).$$

下面说明A,B,C不两两独立。

$$\begin{aligned}
P(AB) &= P(\omega_3)=\frac{7}{6}-\frac{\sqrt{5}}{2}\neq\frac{1}{2}-\frac{\sqrt{5}}{6}=P(A)P(B),\\
P(AC) &= P(\omega_3)=\frac{7}{6}-\frac{\sqrt{5}}{2}\neq\frac{1}{2}-\frac{\sqrt{5}}{6}=P(A)P(C),\\
P(BC) &= P(\omega_3)=\frac{7}{6}-\frac{\sqrt{5}}{2}\neq\frac{7}{2}-\frac{3\sqrt{5}}{2}=P(B)P(C).
\end{aligned}$$

即A,B,C不两两独立。

n个事件相互独立： 从n个事件$A_1,A_2,\cdots A_n$中任意取出k个事件$A_{i_1},A_{i_2},\cdots,A_{i_k}$, $k\leq n$, 都有

$$P(A_{i_1}A_{i_2}\cdots A_{i_k})=P(A_{i_1})P(A_{i_2})\cdots P(A_{i_k}),\ 1\leq i_1<i_2<\cdots<i_k\leq n.$$

称$A_1,A_2,\cdots,A_n$相互独立，其中$n\geq 2$, n可以取无穷。

由于$\binom{n}{2}+\binom{n}{3}+\cdots+\binom{n}{n}=2^n-n-1$, 上述定义包含了$2^n-n-1$ 个等式。n个事件相互独立的直观含义是：n个事件中任意一些事件的发生不影响其它事件的发生。若一组事件相互独立，则其中一部分也相互独立；相互独立必推出两两独立，反过来不一定对。

定理1.5 令n个事件$A_1,A_2,\cdots,A_n$相互独立。求证：把其中任意一部分事件改成对立事件，所得的事件仍然相互独立。

证明： 记$B_i=A_i$或$\bar{A}_i$. 我们要证$B_1,B_2,\cdots,B_n$相互独立，即对任意$1\leq i_1<i_2<\cdots<i_k\leq n$, $2\leq k\leq n$, 都有

$$P(B_{i_1}B_{i_2}\cdots B_{i_k})=P(B_{i_1})P(B_{i_2})\cdots P(B_{i_k}). \tag{1.2}$$

记m为$B_{i_1}, B_{i_2}, \cdots, B_{i_k}$中表示为$B_{i_j} = \bar{A}_{i_j}$的$j$的个数，$j = 1, 2, \cdots, k$. 下面对$m$进行数学归纳法。

当$m = 0$时，$P(B_{i_1}B_{i_2}\cdots B_{i_k}) = P(B_{i_1})P(B_{i_2})\cdots P(B_{i_k})$显然成立。

假设当$m = d$时，(1.2)式成立。当$m = d+1$时，$B_{i_1}, B_{i_2}, \cdots, B_{i_k}$中有$d+1$个带¯, 不妨设第$d+1$是$B_{i_1} = \bar{A}_{i_1}$, 有

$$B_{i_2}B_{i_3}\cdots B_{i_k} = (\bar{A}_{i_1}B_{i_2}B_{i_3}\cdots B_{i_k}) \cup (A_{i_1}B_{i_2}B_{i_3}\cdots B_{i_k}).$$

由$\bar{A}_{i_1}B_{i_2}B_{i_3}\cdots B_{i_k}$与$A_{i_1}B_{i_2}B_{i_3}\cdots B_{i_k}$互斥，得

$$P(B_{i_2}B_{i_3}\cdots B_{i_k}) = P(B_{i_1}B_{i_2}B_{i_3}\cdots B_{i_k}) + P(A_{i_1}B_{i_2}B_{i_3}\cdots B_{i_k}),$$

$$P(B_{i_1}B_{i_2}B_{i_3}\cdots B_{i_k}) = P(B_{i_2}B_{i_3}\cdots B_{i_k}) - P(A_{i_1}B_{i_2}B_{i_3}\cdots B_{i_k}).$$

由于$B_{i_2}, B_{i_3}, \cdots, B_{i_k}$中只有$d$个带¯, $A_{i_1}, B_{i_2}, B_{i_3}, \cdots, B_{i_k}$中也只有$d$个带¯. 利用假设，知

$$\begin{aligned} P(B_{i_2}B_{i_3}\cdots B_{i_k}) &= P(B_{i_2})P(B_{i_3})\cdots P(B_{i_k}), \\ P(A_{i_1}B_{i_2}B_{i_3}\cdots B_{i_k}) &= P(A_{i_1})P(B_{i_2})P(B_{i_3})\cdots P(B_{i_k}). \end{aligned}$$

因此

$$\begin{aligned} P(B_{i_1}B_{i_2}\cdots B_{i_k}) &= P(B_{i_2})P(B_{i_3})\cdots P(B_{i_k}) - P(A_{i_1})P(B_{i_2})P(B_{i_3})\cdots P(B_{i_k}) \\ &= [1 - P(A_{i_1})]P(B_{i_2})\cdots P(B_{i_k}) \\ &= P(\bar{A}_{i_1})P_r(B_{i_2})\cdots P(B_{i_k}) \\ &= P(B_{i_1})P(B_{i_2})\cdots P(B_{i_k}). \end{aligned}$$

即对任意非负整数$m \geq 0$, (1.2) 都成立。

定理1.6 令$A_1, A_2, \cdots, A_n$是n个事件，满足$P(A_1A_2\cdots A_n) \neq 0, n \geq 2$. 则$A_1$, A_2, $\cdots$, A_n相互独立的充分必要条件是：对任意$\{i_1, i_2, \cdots, i_k\} \subset \{1, 2, \cdots, n\}$, $2 \leq k \leq n$. 有

$$P(A_{i_1}|A_{i_2}A_{i_3}\cdots A_{i_k}) = P(A_{i_1}).$$

证明：(必要性) 由n个事件相互独立的定义及条件概率定义得证。

(充分性) 对任意$\{i_1, i_2, \cdots, i_k\} \subset \{1, 2, \cdots, n\}$, 利用乘法公式知

$$P(A_{i_1}A_{i_2}\cdots A_{i_k}) = P(A_{i_1})\prod_{j=2}^{k} P(A_{i_j}|A_{i_1}A_{i_2}\cdots A_{i_{j-1}}).$$

由假设知$P(A_{i_j}|A_{i_1}A_{i_2}\cdots A_{i_{j-1}}) = P(A_{i_j}), j = 2, 3, \cdots, k$. 于是有

$$P(A_{i_1}A_{i_2}\cdots A_{i_k}) = P(A_{i_1})P(A_{i_2})\cdots P(A_{i_k}).$$

故$A_1, A_2, \cdots, A_n$相互独立.

例1.23 某地区人群携带某种病毒的概率为0.0001, 为了降低检测成本并尽快找到病毒携带者，把10人血清混在一起检测病毒。求该混合血清中有病毒的概率。

解：记A_i为第i个人携带病毒，$i=1,2,\cdots,10$. 则

$$\begin{aligned} P(A_1\cup A_2\cup\cdots\cup A_{10}) &= 1-P\Big(\overline{\bigcup_{i=1}^{n}A_i}\Big)\\ &= 1-P(\bar{A}_1\bar{A}_2\cdots\bar{A}_{10})\\ &= 1-0.9999^{10}\\ &= 0.00099955. \end{aligned}$$

n个事件相互独立不仅可以针对n个不同试验的结果，也可针对一个试验在同一条件下独立重复地进行n次，称这类试验为**独立重复试验**。如抛掷一枚质地均匀的硬币n次，由于每次抛硬币只有两种结果：正面朝上和反面朝上，这n次抛掷是n次独立重复试验。

例1.24 已知某人群A型血比例为28%, 一医院急需A型血，拟从身体合格的献血者获取。如果以99%的把握至少获取5份A型血，问至少需要多少名身体合格的献血者？

解：令事件B_i=$\{$第i名身体合格者是A型血$\}$，$i=1,2,\cdots,n$. n名合格者恰有k名是A型血的概率是$\binom{n}{k}0.28^k(1-0.28)^{n-k}$. 由题意，找一个最小的$n$满足下式

$$\sum_{k=5}^{n}\binom{n}{k}0.28^k(1-0.28)^{n-k}\geq 0.99.$$

可得最小的n为38.

例1.25 甲、乙两人依次独立地做同一试验，甲成功的概率为p, $0<p<1$, 乙成功的概率为q, $0<q<1$. 两人约定一旦有人成功，终止试验。现在甲先做试验，求甲、乙两人成功的概率。

解：记事件$A=\{$甲成功$\}$，$B=\{$乙成功$\}$. 显然A和B是对立事件，且

$$P(A)+P(B)=1.$$

记$C_i=\{$第i次做试验，试验成功$\}$, 其中i是奇数时对应甲做试验，i是偶数时对应乙做试验。可知

$$A=C_1\cup(\bar{C}_1\bar{C}_2C_3)\cup(\bar{C}_1\bar{C}_2\bar{C}_3\bar{C}_4C_5)\cup\cdots.$$

因此，

$$\begin{aligned} P(A) &= P(C_1)+P(\bar{C}_1\bar{C}_2C_3)+P(\bar{C}_1\bar{C}_2\bar{C}_3\bar{C}_4C_5)+\cdots\\ &= p+(1-p)(1-q)p+(1-p)(1-q)(1-p)(1-q)p+\cdots\\ &= \sum_{i=0}^{\infty}(1-p)^i(1-q)^ip\\ &= \frac{p}{1-(1-p)(1-q)}\\ &= \frac{p}{p+q-pq}, \end{aligned}$$

进而得$P(B) = 1 - P(A) = \dfrac{q - pq}{p + q - pq}$.

1.4 全概率公式与Bayes公式

与条件概率有关的重要公式有三个，除了上节的乘法公式外还有全概率公式和Bayes公式。这些公式的共同特点就是：公式简单、证明容易、应用丰富。

全概率公式： 令n个事件$B_1, B_2, \cdots, B_n, n \geq 2$, n可以取无穷，满足：
(1)$B_1, B_2, \cdots, B_n$两两互斥且$P(B_i) > 0, i = 1, 2, \cdots, n$;
(2)$\bigcup_{i=1}^{n} B_i$是必然事件。
那么，对任何事件A有

$$P(A) = \sum_{i=1}^{n} P(A|B_i)P(B_i).$$

证明： 由分配律得$A = A \cap \left(\bigcup_{i=1}^{n} B_i \right) = \bigcup_{i=1}^{n} (AB_i)$. 由于$AB_1, AB_2, \cdots, AB_n$是两两互斥且$P(AB_i) = P(A|B_i)P(B_i)$, $i = 1, 2, \cdots, n$, 故

$$P(A) = \sum_{i=1}^{n} P(AB_i) = P(A|B_i)P(B_i).$$

称满足条件(1)和(2)的$B_1, B_2, \cdots, B_n$为一个**完备事件组**，或为样本空间Ω的一个**划分**或**分割**。最简单的情形：当$n = 2$时，

$$P(A) = P(A|B)P(B) + P(A|\bar{B})P(\bar{B}).$$

全概率公式的理论和实用意义在于：在某些情况下直接计算$P(A)$较难，但A经常是伴随某些B_i发生，巧妙地构造一组B_i可以简化计算。

例1.26 某地区的吸烟人群的比例为30%。已知吸烟者患肺癌的概率是0.0177, 不吸烟者患肺癌的概率是0.00177. 求该地区人群患肺癌的概率。

解： 令A={该地区人群患肺癌}，B_1={吸烟}，B_2={不吸烟}，从而B_1, B_2为对立事件，构成一个完备事件组。由全概率公式得

$$\begin{aligned} P(A) &= P(A|B_1)P(B_1) + P(A|B_2)P(B_2) \\ &= 0.0177 \times 0.3 + 0.00177 \times 0.7 \\ &= 0.006549. \end{aligned}$$

例1.27 某地区的耕地有三种类型：一等地、二等地和三等地。一等地某农作物的平均亩产量超过1000斤的概率是80%，二等地此农作物的平均亩产量超过1000 斤的概率是40%，三等地此农作物的平均亩产量超过1000斤的概率是10%. 已知该地区一等地占比50%, 二等地占比30%, 三等地占比20%. 求该地区此农作物的平均某产量超过1000斤的概率。

解： 令A={该地区农作物的平均某产量超过1000斤},
B_1={一等地}，B_2={二等地}，B_3={三等地}.

由全概率公式得

$$\begin{aligned} P(A) &= P(A|B_1)P(B_1)+P(A|B_2)P(B_2)+P(A|B_3)P(B_3) \\ &= 0.8\times 0.5+0.4\times 0.3+0.1\times 0.2 \\ &= 0.54. \end{aligned}$$

例1.28 (最优选择) 一商场需要从n个供货厂家中选择一家购买一批产品。这n个厂家的次品率均不相同。假设商场在与每个厂家商洽中了解该厂家的次品率且商洽结束后需立即确定是否从该厂家购买产品。为了选择出次品率最低的厂家，商场的策略是：前m个厂家只商洽不选择，从第$m+1$个厂家开始，如果次品率比前面已经商洽厂家的次品率低就选择该厂家。试确定最优的m使得该商场选择次品率最低的厂家的概率最大。

解： 记A=$\{$次品率最低的厂家被选中$\}$，B_i=$\{$表示次品率最低的厂家在商洽中排在第i个$\}$, $i=1,2,\cdots,n$。可知

$$\begin{aligned} P(B_i) &= 1/n,\ \ i=1,2,\cdots,n, \\ P(A|B_i) &= 0,\ \ 1\le i\le m. \end{aligned}$$

下面计算$P(A|B_i), i=m+1,m+2,\cdots,n.$ 当次品率最低的厂家在第i个洽谈时且被选中表明前$i-1$ 个洽谈商家的次品率最低者必须在前m(包括m)个。因此

$$P(A|B_i)=m/(i-1),\ i=m+1,m+2,\cdots,n.$$

由全概率公式知

$$\begin{aligned} P(A) &= \sum_{i=1}^{n} P(A|B_i)P(B_i) \\ &= \frac{1}{n}\sum_{i=m+1}^{n}\frac{m}{i-1} \\ &= \frac{m}{n}\sum_{i=m}^{n-1}\frac{1}{i}. \end{aligned}$$

给定n, 找m使得$P(A)$最大即可。

与全概率公式相对应的一个公式是Bayes公式(Bayes, 1702-1761).

Bayes公式： 令n个事件$B_1,B_2,\cdots,B_n$ 是一个完备事件组，$n\ge 2$, n可以取无穷。则对任意一事件A, $P(A)>0$，有

$$P(B_k|A)=\frac{P(A|B_k)P(B_k)}{\sum_{i=1}^{n}P(A|B_i)P(B_i)}.$$

证明： 由于$P(B_k|A)=P(B_kA)/P(A)$，利用乘法公式和全概率公式即得。

从形式上看，Bayes公式不过是条件概率和全概率公式的一个简单推论，它之所以著名，在于其直观解释。$P(B_1),P(B_2),\cdots,P(B_n)$是在没有进一步的

信息，不知道事件A是否发生的情况下，人们对事件$B_1, B_2, \cdots B_n$发生可能性大小的认识。现在有了新的信息，即事件A发生了，在A发生的条件下，人们对$B_1, B_2, \cdots B_n$发生的可能性大小进一步的认识。

如果我们把事件A看成“结果”，把事件$B_1, B_2, \cdots, B_n$看成导致这个结果可能的“原因”。那么全概率公式可以看成“由原因推结果”；而Bayes公式则是“由结果找原因”。

例1.29 某地区人群患某种疾病的概率为0.002. 在检查时，由于医学条件等原因，使得患者未必被检查出阳性而健康者可能被检查出阳性。记患者检查出阳性的概率是0.98，而健康者检测出阳性的概率是0.001. 问：

(1)某人检出阳性，实际是患者的概率是多少？

(2)某人独立地检测2次均是阳性，实际上是患者的概率是多少？

(3)某人检出阴性，实际上健康的概率是多少？

解：(1)令事件A =\{检出阳性\}，事件B =\{某人是患者\}，则$\bar{B}$=\{某人健康\}。由题意知$P(A|B) = 0.98, P(A|\bar{B}) = 0.001, P(B) = 0.002, P(\bar{B}) = 0.998$. 则

$$\begin{aligned} P(B|A) &= \frac{P(A|B)P(B)}{P(A|B)P(B) + P(A|\bar{B})P(\bar{B})} \\ &= \frac{0.98 \times 0.002}{0.98 \times 0.002 + 0.001 \times 0.998} \\ &\approx 0.6626. \end{aligned}$$

(2)令事件C =\{独立检测2次均是阳性\}.

$$\begin{aligned} P(B|C) &= \frac{P(C|B)P(B)}{P(C|B)P(B) + P(C|\bar{B})P(\bar{B})} \\ &= \frac{0.98^2 \times 0.002}{0.98^2 \times 0.002 + 0.001^2 \times 0.998} \\ &\approx 0.99948. \end{aligned}$$

(3)由题意有$P(\bar{A}|B) = 1 - P(A|B) = 0.02, P(\bar{A}|\bar{B}) = 1 - P(A|\bar{B}) = 0.999$. 则

$$\begin{aligned} P(\bar{B}|\bar{A}) &= \frac{P(\bar{A}|\bar{B})P(\bar{B})}{P(\bar{A}|\bar{B})P(\bar{B}) + P(\bar{A}|B)P(B)} \\ &= \frac{0.999 \times 0.998}{0.999 \times 0.998 + 0.02 \times 0.002} \\ &\approx 0.99996. \end{aligned}$$

例1.30 (周幽王烽火戏诸侯) (周幽王，公元前795年-公元前771年) 西周末年，周幽王为了博得褒姒一笑，谎称犬戎兵来进攻，命人点燃烽火台，把各地诸侯骗过来救驾。假设诸侯们平时认为周幽王可信的概率为0.95；在周幽王可信时认为周幽王说谎的概率为0.02；在周幽王不可信时认为周幽王说谎的概率

为0.9。一旦诸侯们发现被戏弄一次后，问诸侯们认为周幽王可信的概率是多少？

解：记事件A={烽火台被点燃一次但犬戎兵没来}，B ={周幽王可信}。则

$$P(B) = 0.95,\ P(\bar{B}) = 0.05,$$

$$\begin{aligned} P(B|A) &= \frac{P(A|B)P(B)}{P(A|B)P(B) + P(A|\bar{B})P(\bar{B})} \\ &= \frac{0.02 \times 0.95}{0.02 \times 0.95 + 0.9 \times 0.05} \\ &\approx 0.297. \end{aligned}$$

可见一旦诸侯们发现被戏弄一次后，诸侯们对周幽王可信度大大降低了。

习题一

事件及其运算

1. 从某班级里随机挑选一名同学，记事件$A=\{$爱好体育$\}$, $B=\{$擅长唱歌$\}$, $C=\{$喜欢绘画$\}$. 问：
(1) $AB\bar{C}$表示什么意思？
(2) 何时有$ABC=A$？
(3) $\bar{C}\subset B$表示什么意思？

2. 用A,B,C,D,E这五个事件表示下列各事件：
(1)这五个事件都不发生；
(2)这五个事件至少发生一个；
(3)这五个事件最多发生一个；
(4)这五个事件最多发生两个；
(5)这五个事件恰好发生两个；
(6)A,B,C发生，D,E不发生。

3. 令A,B,C是三个事件，满足$ABC=\bar{A}\bar{B}\bar{C}$. 求$A,B,C$之间的关系。

4. 令$A_1,A_2,\cdots,A_n$是n个事件。把$\bigcup\limits_{i=1}^{n}A_i$表示$n$个两两互斥事件的并。

5. 令A,B是两个事件。求证：$(A\cup B)\backslash(AB)=(A\bar{B})\cup(\bar{A}B)$.

6. 求证：对偶律成立。

概率的公理化

7. 令A,B是两个事件，且$P(A)=0.35,P(B)=0.65$. 求：
(1)$P(AB)$何时取最大值，最大值是多少？
(2)$P(AB)$何时取最小值，最小值是多少？

8. 令A,B是两个事件。求证：
(1)$P(B\backslash A)=P(B)-P(AB)$;
(2)A,B恰有一个事件发生的概率等于$P(A)+P(B)-2P(AB)$;
(3)若$A\subset B$, 则$P(A)\leq P(B)$, $P(B\backslash A)=P(B)-P(A)$.

9. 令A,B,C是三个事件。求证：
(1)$P(A)P(B)\geq P(A\cup B)P(AB)$;
(2)$P(B)\geq P(AB)+P(BC)-P(AC)$;
(3)$P(AB)+P(AC)+P(BC)\geq P(A)+P(B)+P(C)-1$.

10. 令$A_1, A_2, \cdots, A_n$是n个事件。求证：
(1)$P(A_1A_2) \geq P(A_1) + P(A_2) - 1$;
(2)$P(A_1A_2\cdots A_n) \geq P(A_1) + P(A_2) + \cdots + P(A_n) - (n-1)$.

11. 称两个事件A, B恰发生一个这一事件为A与B的**对称差**，记作$A\Delta B$. 显然

$$A\Delta B = (A \cup B)\backslash(AB) = (A\backslash B) \cup (B\backslash A).$$

令$A_1, A_2, \cdots, A_n$是n个事件。求证：

$$\begin{aligned} P(A_1\Delta A_2\Delta\cdots\Delta A_n) &= \sum_{i=1}^{n} P(A_i) - 2\sum_{1\leq i<j\leq n} P(A_iA_j) \\ &\quad +4\sum_{1\leq i<j<k\leq n} P(A_iA_jA_k) + \cdots + (-2)^{n-1}P(A_1A_2\cdots A_n). \end{aligned}$$

古典概率模型

12. 随机抛掷一颗质地均匀的骰子3次至少出现一次六点和随机抛掷两颗质地均匀的骰子6次至少出现一次双六的概率相等吗？

13. 有n个粒子，每个粒子都以$1/N$的概率落入N个格子中的一个格子，$N \geq n$. 求某一指定格子里中恰有m个粒子的概率。

14. 有n个粒子，每个粒子都以$1/N$的概率落入N个格子中的一个格子，$N \leq n$. 求每个格子都有粒子的概率。

15. 一质点从等边三角形的一个顶点出发，沿着三角形的一条边运动，每次它到达一个顶点后随机选择一条边继续运动。求经过n次选择(包括第一次选择)后，它向初始点运动的概率。

16. 一质点从坐标原点出发，在平面直角坐标系上运动。它每次等可能地向上、下、左、右移动一个单位距离。求：
(1)经过$2n$次移动后，该质点回到原点的概率；
(2)经过$2n$次移动后，该质点到达点$(-2, 2)$的概率。

17. 在一个有$N(> n+1)$个居民的小区，某人把一消息告诉从中随机选出的n个人，然后这n个人中的一个人把该消息告诉从除自己以外的$N-1$个人中随机选出的n个人，$\cdots$, 如此下去。求进行了k次后，初始那个人被其他人告诉该消息的概率。

18. 从10双不同鞋子中随机取出6只，求：
(1)6只鞋子中至少有2只鞋子是一对的概率；
(2)任意两只鞋子都不成对的概率。

19. 一盒子里有n个球，编号为：$1, 2, \cdots, n$. 从盒子里随机取出m个球，求取出的球的最大编号恰为k $(1 \leq k \leq n)$的概率。

20. 一盒子里有n个球，编号为：$1, 2, \cdots, n$. 逐个有放回地从盒子里随机取出m个球，求取出的球的最大编号恰为k $(1 \leq k \leq n)$的概率。

21. 一盒子里有n个球，编号为：$1, 2, \cdots, n$. 逐个有放回地从盒子里随机取出m个球，求取出的球的编号按照严格上升次序排列的概率。

22. 一盒子里有n个白球和m个红球。从中不放回地逐个取球，求第k次取到的球是白球的概率。

23. 九张卡片上分别写着2, 3, 4, 5, 8, 9, 11, 12, 13. 从中随机取出两张卡片，把其上的数字组成一个分数。求这个分数是最简分数的概率(最简分数是指除了1以外没有其它公约数)。

24. 十一张卡片分别写着$A, B, B, I, I, L, O, P, R, T, Y$.
(1)把它们随机排成一行，求恰好拼成单词“$PROBABILITY$”的概率；
(2)如果从这11张卡片随机依次取出4张，求恰好拼成单词“$BABY$”的概率。

25. 从n阶行列式的一般展开式中任意取出一项，求该项包含主对角线元素的概率。

26. 一工作室里有6名员工。求至少有3名员工的生日在同一个月的概率。

27. 一班级有50名同学，一年按照365天算，假设每名同学的生日在365天中的任意一天是等可能的。求恰有3名同学是同一天生日的概率。

28. 植树节到了，同学们随机把n棵松树和m棵银杏树种植在某马路的一边，$m \leq n + 1$. 求没有两颗银杏树相邻的概率。

29. 一班级有n名同学，$n \geq 2$. 新学期，班主任把这n本新书随机发给同学们，每本书上都写上一名同学的名字，每人一本。求至少有一名同学拿到有自己名字的书的概率。

30. 有n个气球和m位小朋友，$n \geq m$. 随机把这n个气球分给小朋友们。求每位小朋友至少拿到一个气球的概率。

31. 有n组气球，每组有m个。从中随机取出k个气球，$k \geq n$. 求每组都有气球被取出的概率。

几何概率

32. 两人约定11点到12点之间在某地会面，先到者等候一刻钟，过时就离去。假设两个人都不会在11点前和12点后到达会面地点。求这两个人见不到面的概率。

33. 甲、乙两人相约13:00到14:00之间到某公共汽车站一起乘车外出，设他们到车站的时间是随机的，且到车站的时间只在13:00到14:00之间。若该站在13:00-14:00之间有四班公交车运营，开车时间分别为13:10、13:25、13:40、13:55. 求他们在下述情况下同坐一班车的概率：(1)约定见车就乘；(2)约定最多等一班车。

34. 把一个长度为ℓ米的绳子随机分成三段。求这三段能构成三角形的概率。

35. 平面上画着许多间隔为a单位的等距平行线。向该平面随机投掷一个边长为$k(k<a)$单位的等边三角形。求三角形与平行线能相交的概率。

36. 令$\theta>1$, a,b在$[1,\theta]$中随机取值。求$ab<\frac{(\theta-1)^2}{3}$的概率。

37. 向平面直角坐标系中的半圆$0<y<\sqrt{2ax-x^2}, a>0$内随机投掷一点，设点落在半圆内任何区域的概率与区域的面积成正比。求原点和该点的连线与x轴的夹角小于$\pi/4$ 的概率。

条件概率

38. 令$P(A)=0.6$, $P(B)=0.3$, $P(A\bar{B})=0.45$. 求$P(B|A\cup\bar{B})$.

39. 某人给朋友打电话，他忘了朋友的电话号码的最后一个数字，打算随机拨号。求：
(1)4次之内打对电话的概率；
(2)若已知电话号码的最后一个数字是奇数，那么不超过2次他就打对电话的概率。

40. 考察一流行感冒和一3口之家，记

$$P(\text{孩子患流感})=0.05,\ P(\text{母亲患流感}|\text{孩子患流感})=0.4,$$

$$P(\text{父亲患流感}|\text{母亲和孩子同时患流感})=0.6,$$

求母亲及孩子患流感但父亲未患流感的概率。

41. 令A,B是两个事件。求证：
(1)$P(A|B)\geq P(A)\Longleftrightarrow P(B|A)\geq P(B)$;
(2)$|P(AB)-P(A)P(B)|\leq 1/4$;
(3)若$P(A|B)>P(A|\bar{B})$, 则$P(B|A)>P(B|\bar{A})$.

42. 令A, B, C是三个事件。求证：
$(1)P(A)+P(B)+P(C) \leq P(AB)+P(AC)+P(BC)+1.$
$(2)P(A \cup B \cup C)=1-P(\bar{A})P(\bar{B}|\bar{A})P(\bar{C}|\bar{A}\bar{B}).$

事件的独立

43. 一彩票每周开一次，每周中奖的概率为10^{-6}. 假设每次开奖是独立的。求连续522周(相当于10年)从未中奖的概率。

44. 甲、乙两人参加某项目比赛，甲胜的概率为0.6, 乙胜的概率为0.4. 有三种赛制供选择：三局两胜、五局三胜和七局四胜。问那种赛制对甲有利？

45. 甲、乙、丙三人同时独立做某一个试验，甲成功的概率为0.4, 乙成功的概率为0.5, 丙成功的概率为0.6. 求试验能成功的概率。

46. 某厂家新生产一种新型瓶装饮料，为了扩大营销，推出“刮一刮，再来一箱”奖品活动。设每瓶饮料刮一刮的中奖概率是0.001. 一人买了100瓶，问他至少中奖1次的概率是多少？

47. 一盒子里有N个白球和M个红球。从盒子里随机取出1个球后接着放进k个与取出的球具有相同颜色的球，这样总共进行了n次($n < \min\{N, M\}$). 求在这n次取球中恰取出了n_1个白球和n_2个红球的概率。

48. 令A, B, C是三个事件，$A=\left(\frac{1}{8}, \frac{5}{8}\right)$, $B=\left(\frac{3}{8}, \frac{7}{8}\right)$, $C=\left(\frac{1}{8}, \frac{1}{4}\right) \cup \left(\frac{5}{8}, 1\right)$, 且每个事件发生的概率等于其区间的长度。求证：$A, B, C$两两独立但不相互独立。

49. 令A, B, C是三个事件，$A=\left(0, \frac{1}{4}\right)$, $B=\left(\frac{3}{4}, 1\right)$, $C=\left(\frac{15}{64}, \frac{16}{64}\right) \cup \left(\frac{17}{64}, \frac{32}{64}\right)$, 且每个事件发生的概率等于其区间的长度。求证：$P(ABC)=P(A)P(B)P(C)$但$A, B, C$不两两独立。

50. (**Bernstein正四面体**) (Bernstein, 1880-1968) 一质地均匀的正四面体，第一面染成红色，第二面染成黄色，第三面染成蓝色，第四面均匀染成红、黄、蓝三色。在桌上将此四面体随机抛掷1次，考察与桌面接触的那一面上的颜色。令事件A=\{出现红色\}，B=\{出现黄色\}，C=\{出现蓝色\}。证明：这三个事件两两独立但不相互独立。

51. 把定理1.4的其它情形的证明补充完整。

52. 令两个事件为A和B且$P(B)>0$. 求证：A与B相互独立等价于$P(A|B)=P(A|\bar{B})$或$P(A|B)+P(\bar{A}|\bar{B})=1$.

53. 令三个事件A, B, C相互独立。求证：C与AB相互独立，C与$A \cup B$相互独立，C与$A \backslash B$相互独立。

54. 令四个事件A, B, C, D满足A, B, C两两互斥且A, B, C都与D相互独立。求证：$A \cup B \cup C$与D相互独立。

55. 令A, B, C是三个事件。若

$$P(AB|C) = P(A|C)P(B|C),$$

称A, B关于C**条件独立**。若A, B关于C及$\bar{C}$条件独立，且

$$P(A|C) = 0.8, P(B|C) = 0.9, P(A|\bar{C}) = 0.3, P(B|\bar{C}) = 0.1.$$

问A, B相互独立吗？

全概率公式

56. 一盒子里有n个球，其中有n_1个白球，n_2个红球。从中随机取出n_1个球并放进n_1个白球。求再从盒中随机取出n_1个球，取的球都是白球的概率。

57. 一盒子里有n个白球和m个红球。从盒子里随机抽取一个球后并放入k个白球，这样进行N次后，再从盒子里随机抽取一个球，求取到白球的概率。

58. 有两个盒子，第一个盒子里有n个白球和1个红球，第二个盒子里有m个黑球。每次分别从两个盒子里各随机抽取1个球，交换后放进另一个盒子里，求经过n次操作后，红球仍在第一个盒子里的概率。

59. 有两个盒子，第一个盒子里有n个白球和m个红球，第二个盒子里有k个红球。每次从这两个盒子里随机取出1个球，交换后放进另一个盒子里，这样进行r次操作后，求白球仍在第一个盒子里的概率。

60. 有N个盒子，每个盒子里都有n个白球，m个红球。现从第一个盒子里随机取出一个球放进第二个盒子，然后从第二个盒子随机取出一球放进第三个盒子，如此下去，求从最后一盒子随机取出一球为白球的概率。

61. 有N个盒子，每个盒子里有n个白球，m个红球和k个黑球。从第一个盒子里随机抽取一个球放进第二个盒子，然后从第二个盒子里随机取出一个球放进第三个盒子，如此下去，最后从第$N-1$个盒子里随机取出一个球放入第N个盒子里。求从第N个盒子里随机取出一个球分别是白球、红球和黑球的概率。

62. 甲、乙两人随机抛掷一枚质地均匀的硬币，甲掷了n次，乙掷了$n+1$次。求乙掷出的硬币出现正面的次数比甲掷出的硬币出现正面次数多的概率。

63. 甲、乙是某次选举的两位候选人。有N张选票，$N > n+m, n > m$. 若计票过程中的前$n+m$票，甲得到了n票，乙得到了m票。如果剩下的$N-m-n$票，选甲、乙是等可能的，求甲的票数始终领先乙的票数的概率。

64. 某商场的一批产品由甲、乙和丙三个厂家提供。已知甲、乙和丙三厂的次品率分别为0.01, 0.02和0.03, 甲、乙和丙分别给商场提供60%, 25% 和15% 的产品。问从该商场购置此产品的废品率是多少？

65. 令n个事件$A_1, A_2, \cdots, A_n$相互独立，它们发生的概率分别为$p_1, p_2, \cdots, p_n$. 记$p = p_1+p_2+\cdots+p_n$及$p_i \in (0,1), i = 1, 2, \cdots, n$. 求证：事件$\{A_1, A_2, \cdots, A_n$都不发生$\}$的概率小于$e^{-p}$.

Bayes公式

66. 一盒子里有一个球，它是白球的概率为p, 是红球的概率为$1-p$. 现在把一个白球放进盒子里并从中随机取出一个球发现是白球。求盒子里的另一个球是白球的概率。

67. 一盒子有n个球，其中n_1个白球，n_2个红球。从中随机取出n_1个球并放进n_1个白球。求再从盒中随机取出n_1个球是白球时，先前取出的n_1个球都是白球的概率。

68. 有两个盒子，第一个盒子里有n个白球和m个红球，第二个盒子里有m个白球和n个红球，$n > m$. 随机选择一个盒子并从中任意取出1个球，发现是白球，把此球放进该盒子里，求再次从该盒子里随机取出1个球是白球的概率。

69. 某地区男女比例为105:100. 男性人口中四种血型比例分别为：A型血：30%，B型血：20%，O 型血：40%，AB型血：10%；女性人口四种血型的比例分别为：A型血：25%，B 型血：25%，O 型血：45%，AB 型血：5%。随机从该地区选择一个人经检验是A型血，此人是男性的概率是多少？

70. 某地区人群患某种疾病的概率为0.1%. 当检查时，由于医学条件等原因，使得患者未必检查出阳性而健康者可能被检查出阳性的结果。假定患者检查出阳性的概率是99%，而健康者检测出阳性的概率是0.05%. 某人独立地检查了4次，发现3次阳性，1次阴性。问此人是患者的概率是多少？

71. 某地区的吸烟人群的比例是30%。已知吸烟者患肺癌的概率是0.0177, 不吸烟者患肺癌的概率是0.00177. 该地区某人患肺癌，求此患者是吸烟者的概率。

72. 某地区男女比例为105:100. 该地区男性患色盲的概率是5%，女性患色盲的比例是0.5%. 随机从该地区选择一人，发现此人患色盲，求该患者是男性的概率。

第二章　一元随机变量及其概率分布

一个随机试验有多种可能发生的结果，如果把每个结果都记录下来可能会耗费大量的人力和物力。比如，为了调查某项工作的群众满意度，调查表上有三个选项供选择：满意、一般、不满意。假设参与投票的人数是1000，这时候，基本事件的个数有3^{1000}个，这是一个天文数字，意味着把全部基本事件都记录下来是不可取的。一个可行的方案是定义一个函数，它是上述3^{1000}个基本事件的函数，该函数只考虑三个选项中的赞成票数，显然计算量非常小，赞成票数取0到1000之间的整数值，包括0和1000. 这就涉及到本章要介绍的“随机变量”这一概念。直观上，随机变量就是把随机事件进行数量化处理，建立随机事件和实数之间的桥梁。这样我就可以用利用实数的运算对事件发生的概率进行处理。本章介绍一元随机变量及其概率分布，多元随机变量及其概率分布将在第三章介绍。

2.1 随机变量的定义

考察随机抛掷一枚质地均匀的硬币1次，观察是正面朝上还是反面朝上。样本空间为：$\{$正面朝上，反面朝上$\}$。它可用数字来描述：比如，我们可以定义一个取值为0或1的函数来描述它，如果正面朝上，该函数取值为1, 否者取值为0. 事实上，对任意一个事件A, 如果我们关心A发生与否，可以定义一个示性函数

$$I_A(\omega) = \begin{cases} 1, & \omega \in A, \\ 0, & \text{其它。} \end{cases}$$

$I_A(\omega)$的取值表示了事件A发生还是不发生，$I_A(\omega)$等于1表示事件A发生，等于0表示A不发生。示性函数$I_A(\omega)$是一个随机变量，$I_A(\omega)$简记为I_A. 因此，对随机事件的研究就可以通过示性函数转化为对随机变量的研究。下面给出随机变量的具体定义。

随机变量：令$X = X(\omega)$是定义在样本空间Ω, 取值于实数集$\mathcal{R}$的函数，称X是一个随机变量。

随机变量把样本空间与实数联系起来。随机变量常用大写字母X, Y, Z等表示，用小写字母x, y, z 等表示随机变量在一次试验中的取值。随机事件的发生可以用事件$\{X \le x\}$或它的相关运算来表示。因此，对任一实数x，知道事件$\{X \le x\}$发生的概率，即可掌握随机变量X取值的变化规律。$\{X \le x\}$的概率可以写为$P(\{X \le x\})$, 简写为$P(X \le x)$, 它定义了随机变量的概率分布函数。

分布函数：令X为随机变量。记

$$F(x) = P(X \le x), x \in \mathcal{R}.$$

称$F(x)$为X的概率分布函数，也称X服从$F(x)$, 记作$X \sim F(x)$. 概率分布函数简称为分布函数。

在有些情况下，为了区分不同随机变量的分布函数，X的分布函数也常写成$F_X(x)$.

任意一个随机变量X都有其分布函数，它展示了随机变量的变化规律。分布函数$F(x)$有以下三条性质：

(1) **(单调)** $F(x)$单调非降，即当$x_1 < x_2$时，有$F(x_1) \le F(x_2)$;

(2) **(有界)** $\lim\limits_{x\to-\infty} F(x) = 0$, $\lim\limits_{x\to\infty} F(x) = 1$;

(3) **(右连续)** $F(x)$右连续，即对任意$x_0 \in \mathcal{R}$，有 $\lim\limits_{x\to x_0^+} F(x) = F(x_0)$.

证明：性质(1)是显然成立的，当$x_1 < x_2$ 时，事件$\{X \le x_1\} \subset \{X \le x_2\}$, 因此前者的概率小于或等于后者的概率。

性质(2)说明分布函数$F(x)$的取值介于0到1之间。当$x \to \infty$, $\{X \le x\}$是必然事件，故其概率等于1，而当$x \to -\infty$, $\{X \le x\}$是不可能事件，故其概率等于0.

对性质(3)，考察任意单调下降的序列$x_1, x_2, \cdots$, 满足

$$x_1 \ge x_2 \ge \cdots \ge x_n \ge \cdots \ge x_0.$$

下面只需证明当$\lim\limits_{n\to\infty} x_n = x_0$ 时，有$\lim\limits_{n\to\infty} F(x_n) = F(x_0)$ 即可。由于

$$\begin{aligned} F(x_1) - F(x_0) &= P(x_0 < X \le x_1) \\ &= P\Big(\bigcup_{k=1}^{\infty}\{x_{k+1} < X \le x_k\}\Big) \\ &= \sum_{k=1}^{\infty} P(x_{k+1} < X \le x_k) \\ &= \sum_{i=1}^{\infty}\big[F(x_k) - F(x_{k+1})\big] \\ &= F(x_1) - \lim_{n\to\infty} F(x_n). \end{aligned}$$

因此，$\lim\limits_{n\to\infty} F(x_n) = F(x_0)$.

上述三条性质是分布函数所必须具备的。另外，可以证明，满足这三条性质的函数一定是某个随机变量的分布函数，其证明超出本书范围。因此，这三条性质是判别某个函数是否是分布函数的充分必要条件。

例2.1 令函数

$$F(x) = \begin{cases} 1 - \theta^{-x}, & x \ge 0, \\ 0, & x < 0, \end{cases}$$

其中$\theta > 0$. 求证：$F(x)$是一个随机变量的分布函数。

证明：显然$F(x)$是$x \in \mathcal{R}$的非负单调增函数；当$x \to \infty$, $F(x) = 1$，当$x < 0, F(x) \equiv 0$; 且$F(x)$是x的连续函数。$F(x)$满足分布函数的三条性质，因此，$F(x)$是一个随机变量的分布函数。

有了分布函数，随机变量的概率计算就转换成分布函数的数值运算，从而可以利用函数的运算法则，使计算变得简捷。常见的随机变量可以分为三类：

离散型随机变量、连续型随机变量和既非离散也非连续型随机变量。本书只介绍离散型随机变量和连续型随机变量，其性质较容易推广到非离散也非连续型随机变量。

除非特别说明，本书中，$F(x)$表示分布函数，用$X \sim F(x)$表示随机变量X的分布函数为$F(x)$或者X服从分布$F(x)$.

2.2 离散型随机变量及常见离散分布

2.2.1 离散型随机变量

一批产品中的废品数、一天内某单位接到咨询电话的呼叫数等事件的结果都能一一列举出来。用随机变量X表示事件的结果，它的取值个数有限或可数，称X是离散型随机变量。下面给出具体定义。

离散型随机变量：称取有限个或可数个值的随机变量为离散型随机变量。

离散型随机变量的变化规律常用概率函数来表示。

概率函数：令X为离散型随机变量，其全部可能的取值为

$$a_1,\ a_2,\ \cdots,\ a_n,\ a_1 < a_2 < \cdots < a_n,$$

其中n可以取∞. 记

$$p_i = P(X = a_i),\ p_i > 0,\ i = 1, 2, \cdots, n,$$

且$\sum\limits_{i=1}^{n} p_i = 1$. 称$p_i, i = 1, 2, \cdots, n$为$X$的概率函数。以后碰到离散型随机变量，除非特别说明，都假定它的取值按照从小到大排序，且概率函数大于0.

由第一节分布函数的性质可知，判别某个函数是否为概率函数，需要验证其是否满足

$$p_i > 0, i = 1, 2, \cdots, n,\ \sum_{i=1}^{n} p_i = 1.$$

概率函数描述了全部概率1在随机变量的所有可能取值上的分布情况。因此，常把$\{(a_i, p_i), i = 1, 2, \cdots, n\}$称为$X$的**概率分布**。$X$的概率分布也可用下面列表的形式来表示。

取值	a_1	a_2	$\cdots$	a_n
概率	p_1	p_2	$\cdots$	p_n

例2.2 随机投掷一枚质地均匀的骰子1次，记它出现的点数为X. 则X有6种可能的取值。X的概率分布为

取值	1	2	3	4	5	6
概率	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$

由离散型随机变量X的概率函数可以写出其分布函数

$$\begin{aligned} F(x) &= P(X \le x) \\ &= \begin{cases} 0, & x < a_1 \\ \sum\limits_{i=1}^{k-1} p_i, & a_{k-1} \le x < a_k, k = 2, 3, \cdots, n \\ 1, & x \ge a_n, \end{cases} \end{aligned}$$

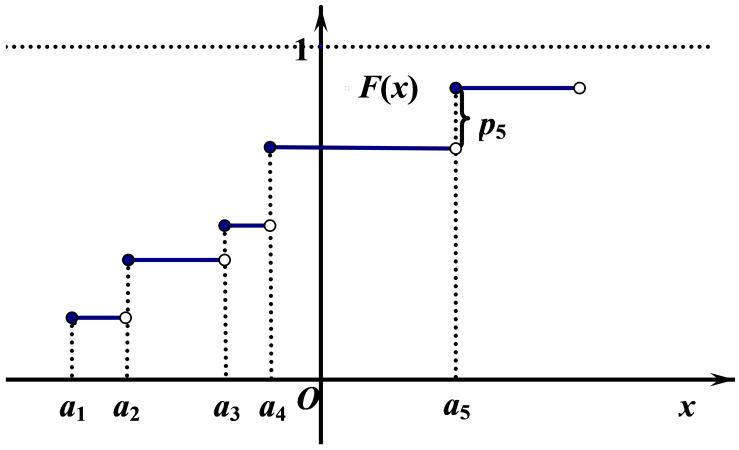


图2.1 离散型随机变量X的分布函数。

它是一个右连续的阶梯函数，如图2.1所示。

另一方面，若已知X的分布函数$F(x)$及X所有可能的取值

$$a_1, a_2, \cdots, a_n,\ a_1 < a_2 < \cdots < a_n.$$

可以得到

$$p_i = P(X = a_i) = F(a_i) - F(a_{i-1}).$$

因此，用概率函数或分布函数描述离散型随机变量都是可以的。常用概率函数描述离散型随机变量。

2.2.2 常见离散分布

离散型随机变量的概率分布又称离散分布。常见的离散分布有：Bernoulli分布(又称0-1分布)、二项分布、几何分布、负二项分布(又称Pascal分布)、超几何分布、Poisson 分布、离散的均匀分布。

Bernoulli分布(又称**0-1分布**)

随机变量X只取0和1两个值且

$$P(X = 1) = p,\ P(X = 0) = 1 - p,\ 0 < p < 1.$$

称X服从Bernoulli分布或0-1分布，记作$X \sim B(1, p)$.

二项分布

令事件A在一次试验中发生的概率为$p, 0 < p < 1$. 独立地重复做n次试验，记这n次试验中A发生的次数为X. 则

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k},\ k = 0, 1, \cdots, n.$$

称X服从二项分布，记作$X \sim B(n, p)$.

几何分布

令事件A在一次试验中发生的概率为$p, 0 < p < 1$. 独立地重复做试验直至A发生为止，记试验次数为X. 则

$$P(X = k) = (1-p)^{k-1}p,\ k = 1, 2, \cdots .$$

称X服从几何分布，记作$X \sim Geo(p)$.

负二项分布(又称**Pascal分布**)

令事件A在一次试验中发生的概率为$p, 0 < p < 1$. 独立地重复做试验直至A发生r次为止，记试验次数为X. 则

$$P(X = k) = \binom{k-1}{r-1}p^{r-1}(1-p)^{k-r}p = \binom{k-1}{r-1}p^{r}(1-p)^{k-r},\ k = r, r+1, \cdots .$$

称X服从负二项分布或Pascal分布，记作$X \sim NB(r, p)$.

也可以换句话描述负二项分布。令事件A在一次试验中发生的概率为$p, 0 < p < 1$. 独立地重复做试验，第$X + r$次试验A恰发生r次。则X服从负二项分布，

$$P(X = m) = \binom{m+r-1}{r-1}p^{r-1}(1-p)^{m}p = \binom{m+r-1}{r-1}p^{r}(1-p)^{m}\ , m = 0, 1, \cdots .$$

负二项分布在产品抽检中有着重要的应用。比如，为了了解一批产品的废品率，事先设置一个数r，比如$r = 5$, 依次从该批产品中抽检，记恰检测到r个废品时所抽取的合格品数为X, 则X服从负二项分布，X越大，废品率越低。

超几何分布

一批产品有N件，其中有M件废品。记从中随机取出n件产品中的废品数为X. 则

$$P(X = m) = \frac{\binom{M}{m}\binom{N-M}{n-m}}{\binom{N}{n}}, m = 0, 1, 2, \cdots, \min\{M, n\}$$

其中$n \le N, M \le N,\ n, N, M$均为正整数。称$X$服从超几何分布，记作$X \sim HG(n, N, M)$.

Poisson分布

若随机变量X的可能取值为$0, 1, \cdots$, 且

$$P(X = k) = \frac{e^{-\lambda}\lambda^{k}}{k!}, \lambda > 0, k = 0, 1, \cdots$$

称X服从Poisson分布，记作$X \sim Poisson(\lambda)$.

由于$e^{\lambda} = 1 + \lambda + \frac{\lambda^2}{2!} + \cdots + \frac{\lambda^i}{i!} + \cdots$, 显然$\sum\limits_{k=0}^{\infty}\frac{e^{-\lambda}\lambda^{k}}{k!} = 1$.

Poisson分布常和单位时间或单位面积上的计数有关。常见的服从Poisson分布的例子有：某商场一天的顾客数、某段时间内某单位咨询电话的呼叫数、单位平方米玻璃液体上的气泡数等。

离散的均匀分布

令随机变量X可能的取值为$a_1, a_2, \cdots, a_n$, $a_1 < a_2 < \cdots < a_n$且

$$P(X = a_k) = \frac{1}{n}, k = 1, 2, \cdots, n.$$

称X服从离散的均匀分布。

离散的均匀分布是古典概率的抽象.

离散分布在实际中有着重要的应用，下面给一个例子。

例2.3 某市一小区有n个居民。为了给用户提供便利，政府管理部门拟在该小区建一个办事处并打算开k个服务窗口，每个窗口都办理所有业务。假设在每一时刻，这n个居民中的每一个人去办事处办理业务是独立的且概率都为p. 问事件{在每一时刻每个窗口排队人数(包括正在被服务的那个人)不超过m} 发生的概率不小于95%时，k最小是多少？

解： 令事件A_i ={某一时刻恰有i个人去办事处办理业务}，$i = 0, 1, \cdots, n$. 由于n个人中每一个人去办事处办理业务是独立的，概率都为p，则

$$P(A_i) = \binom{n}{i} p^i (1-p)^{n-i},\ i = 0, 1, \cdots, n.$$

每一时刻每个窗口排队人数，包括正在被服务的那个人，不超过m的概率为

$$P\Big(\bigcup_{i=0}^{km} A_i\Big).$$

由于$A_0, A_1, \cdots, A_{km}$两两互斥，因此，

$$P\Big(\bigcup_{i=0}^{km} A_i\Big) = \sum_{i=0}^{km} P(A_i) = \sum_{i=0}^{km} \binom{n}{i} p^i (1-p)^{n-i} \geq 0.95.$$

找一个最小的自然数k, 使上式成立。

若$n = 1000, p = 0.01, m = 5$, 由于

$$\sum_{i=0}^{14} \binom{1000}{i} 0.01^i (1-0.01)^{n-i} = 0.918,$$

$$\sum_{i=0}^{15} \binom{1000}{i} 0.01^i (1-0.01)^{n-i} = 0.952.$$

可知，$k = 3$.

2.3 连续型随机变量及常见连续分布

2.3.1 连续型随机变量

相比于只取有限个或可数个值的离散型随机变量，连续型随机变量的取值个数是不可数的。不同于用概率函数刻画离散型随机变量，我们常用概率密度函数来刻画连续型随机变量的变化规律。

概率密度函数：令X为连续型随机变量。若函数$f(x), x \in \mathcal{R}$ 满足下面3个条件：

(1)$f(x) \geq 0,\ x \in \mathcal{R}$;

(2)$\int_{-\infty}^{\infty} f(x)dx = 1$;

(3)对任何$-\infty < a \leq b < \infty$, 有$P(a \leq X \leq b) = \int_a^b f(x)dx$.

称$f(x)$为X的概率密度函数，简称密度函数。

根据分布函数的定义，X的分布函数为

$$F(x) = P(X \leq x) = \int_{-\infty}^{x} f(u)du,$$

如果$F(x)$在x处的导数存在，

$$f(x) = F'(x) = \lim_{h \to 0} \frac{F(x+h) - F(x)}{h}.$$

密度函数可以解释为在x点单位长度上的概率，它反映了在x点处概率的“密集程度”。

连续型随机变量与离散型随机变量的不同，主要体现为以下三点：

(1)连续型随机变量的分布函数$F(x)$是实数轴上的连续函数，而离散型随机变量的分布函数$F(x)$是右连续的阶梯函数；

(2)对连续型随机变量X，$P(X = x) = \int_x^x f(u)du = 0, x \in \mathcal{R}$, 而离散型随机变量$X$在其取值点$\{a_1, a_2, \cdots, a_n\}$的概率不等于0；

(3)对连续型随机变量，

$$P(a < X < b) = P(a \leq X < b) = P(a < X \leq b) = P(a \leq X \leq b).$$

而上式对于离散型随机变量不成立，其概率计算的每个点都很重要。

常用$X \sim f(x)$表示随机变量X的密度函数为$f(x)$, 或X服从密度函数为$f(x)$的分布。本书中除非特别说明，$f(x)$均指密度函数。有时为了区分不同随机变量的密度函数，常记X的密度函数为$f_X(x)$.

2.3.2 常见连续分布

连续型随机变量的概率分布又称连续分布。常见的连续分布有：正态分布、指数分布、Beta分布、Gamma分布、均匀分布。

正态分布

正态分布是一种常见的连续分布，它是由Gauss在1809年处理天文观测数据时发现的，用它刻画测量的误差。因此，正态分布也称为Gauss分布。

令随机变量X的密度函数为

$$f(x)=\frac{1}{\sqrt{2\pi\sigma^2}}\exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\},x\in\mathcal{R},$$

其中μ,σ^2是参数，且$\sigma^2>0$, 称X服从正态分布，记作$X\sim N(\mu,\sigma^2)$.

称参数$\mu=0,\sigma^2=1$的正态分布为标准正态分布。常用$N(0,1)$表示标准正态分布，$\Phi(x)$表示$N(0,1)$的分布函数，$\phi(x)$表示$N(0,1)$的密度函数。$\phi(x)$关于直线$x=0$对称。对任意$x\in\mathcal{R}$, 有$\Phi'(x)=\phi(x)$ 且$\Phi(-x)=1-\Phi(x)$.

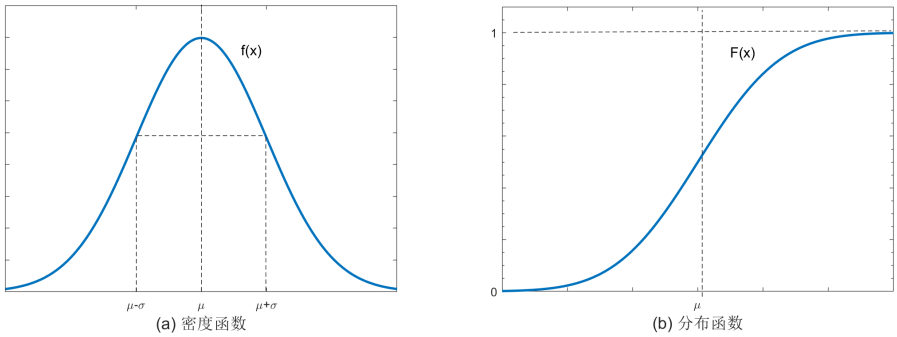


图2.2 正态分布$N(\mu,\sigma^2)$的密度函数(左图)和分布函数(右图)。

正态分布的密度函数和分布函数曲线如图2.2所示。可见，正态分布的密度函数$f(x)$关于$x=\mu$对称，而后往左右两个方向衰减，呈现“两头低、中间高”的状态。

正态分布的密度函数涉及两个参数，μ和σ，分别称它们为位置参数和形状参数。固定一个参数，变化另一个参数，相应的正态密度函数曲线如图2.3. 可见以下两个现象：

(1)μ是正态分布密度函数的对称中心，密度函数在$(-\infty,\mu]$和$[\mu,\infty)$上严格单调，在μ处达到最大值；

(2)σ的大小决定了密度函数的陡峭程度，σ越小，曲线越高，分布越集中；σ越大，曲线越低，分布越分散。

令$X\sim N(0,1)$. 则有

$$\begin{aligned}P(-1.645\le X\le 1.645)&\approx 0.90,\\ P(-1.96\le X\le 1.96)&\approx 0.95,\\ P(-2.576\le X\le 2.576)&\approx 0.99.\end{aligned}$$

指数分布

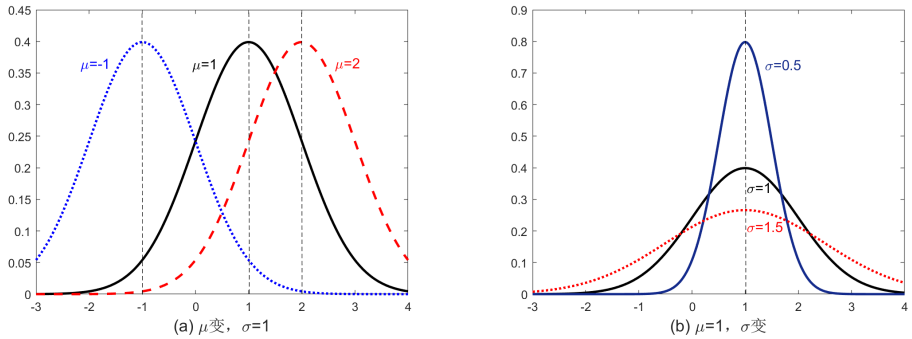


图2.3 正态分布$N(\mu,\sigma^2)$不同参数的密度函数曲线。

令随机变量X的密度函数为

$$f(x)=\begin{cases}\lambda e^{-\lambda x}, & x>0,\\ 0, & x\le 0.\end{cases}$$

其中λ是参数，且$\lambda>0$, 称X服从参数为λ的指数分布，记作$X\sim Exp(\lambda)$.

指数分布的分布函数为

$$F(x)=\begin{cases}1-e^{-\lambda x}, & x>0,\\ 0, & x\le 0.\end{cases}$$

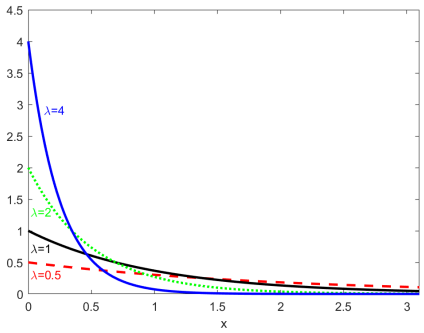


图2.4 指数分布$Exp(\lambda)$不同参数的密度函数曲线。

图2.4给出了λ的不同取值对应的密度函数曲线，可见：参数λ越大，密度函数下降的越快。

Beta分布

令随机变量X的密度函数为

$$f(x)=\frac{\Gamma(\xi+\eta)}{\Gamma(\xi)\Gamma(\eta)}x^{\xi-1}(1-x)^{\eta-1},0<x<1,$$

其中$\Gamma(\xi)=\int_0^\infty u^{\xi-1}e^{-u}du$是Gamma函数，$\xi,\eta$是参数，且$\xi>0,\eta>0$. 称$X$服从Beta分布，记作$X\sim Beta(\xi,\eta)$. 图2.5给出了Beta分布两个参数$\xi,\eta$不同取值时的密度函数曲线。可见不同的参数取值决定了不同的密度函数曲线的形状，

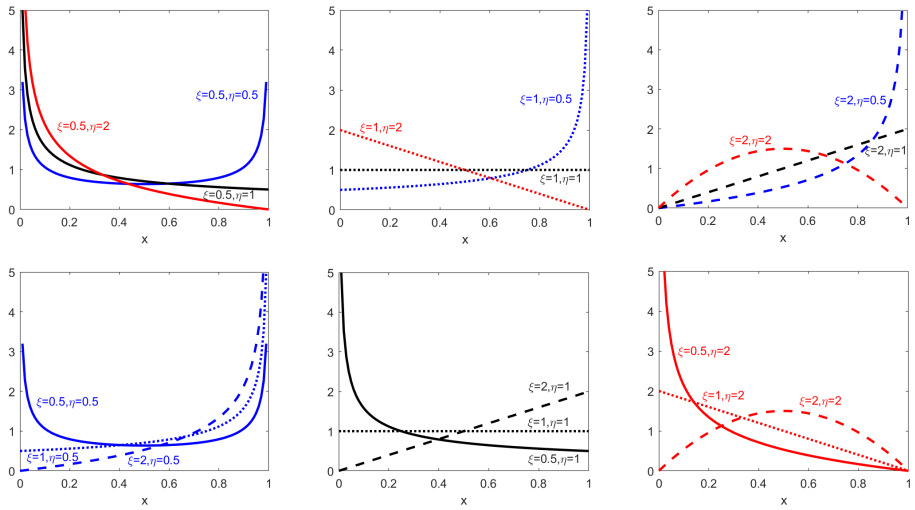


图2.5 Beta分布不同参数的密度函数曲线。

比如当$0 < \xi < 1, 0 < \eta < 1$, 密度函数曲线呈开口向上抛物线型(左图)；当$\xi > 1, \eta > 1$, 密度函数曲线呈开口向下抛物线型(右图)。

Gamma分布

令随机变量X的密度函数为

$$f(x) = \frac{\lambda^{\xi}}{\Gamma(\xi)} x^{\xi-1} e^{-\lambda x}, \ x \geq 0,$$

其中ξ, λ是参数，且$\xi > 0, \lambda > 0$, 称X服从Gamma分布，记作$X \sim Gamma(\xi, \lambda)$.

$\xi = 1$的Gamma分布是指数分布，即$Gamma(1, \lambda) = Exp(\lambda)$. 图2.6给出了Gamma分布两个参数$\xi, \lambda$取不同取值时的密度函数曲线。可见不同的参数取值决定了不同的密度函数曲线的形状，比如当$0 < \xi < 1$时, 密度函数曲线单调下降(中图)；当$\xi > 1$, 密度函数曲线呈开口向下抛物线型(右图)。

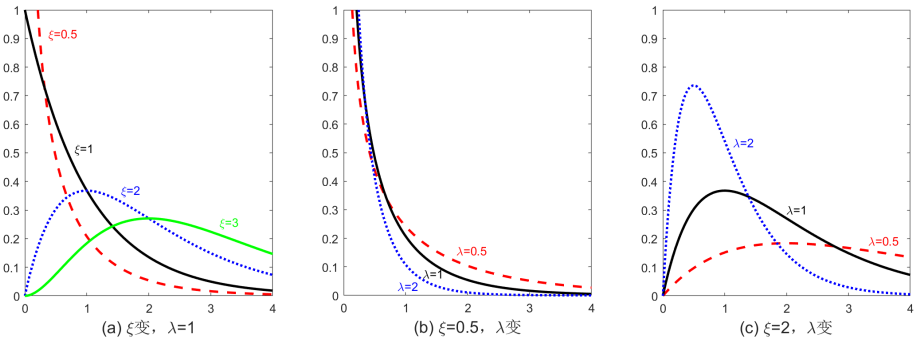


图2.6 Gamma分布不同参数的密度函数曲线。

均匀分布

令随机变量X的密度函数为

$$f(x)=\begin{cases}\dfrac{1}{b-a}, & a\le x\le b,\\ 0, & \text{其它。}\end{cases}$$

其中$a<b, a, b\in\mathcal{R}$, 称X服从$[a,b]$上的均匀分布，记作$X\sim U(a,b)$.

均匀分布名称的由来非常直观。密度函数$f(x)$在$[a,b]$上为常数，故在此区间上，密度在各处的密集程度都一样。或者说，概率均匀地分布在这个区间上。图2.7给出了均匀分布$U(a,b)$的密度函数和分布函数曲线。

均匀分布的分布函数

$$F(x)=\begin{cases}0, & x<a,\\ \dfrac{x-a}{b-a}, & a\le x\le b,\\ 1, & x>b.\end{cases}$$

从密度函数的定义可知，[0,1]上的均匀分布就是参数$\alpha=1,\beta=1$的Beta分布，即$U(0,1)=Beta(1,1)$.

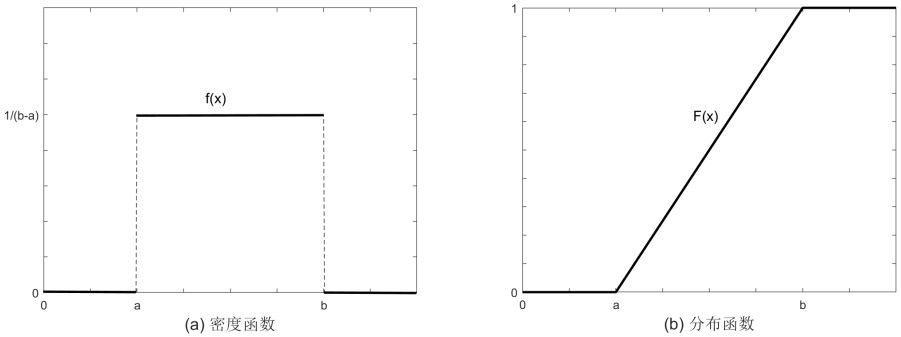


图2.7 均匀分布的密度函数和分布函数曲线。

例2.4 令随机变量$X\sim U(0,b)$。若关于t的二次方程$t^2+Xt+3=0$有实根的概率是90%. 求b.

解：由方程有实根可知$\Delta=X^2-12\ge 0$, 得$X\ge 2\sqrt{3}$ 或$X<-2\sqrt{3}$. 另一方面，$X\sim U(0,b)$知，$X\ge 2\sqrt{3}$. 因此，

$$P(X\ge 2\sqrt{3})=\frac{b-2\sqrt{3}}{b}=0.9.$$

解得$b=20\sqrt{3}$.

本节的最后给出一个即非离散又非连续的随机变量的例子。令随机变量X的分布函数为

$$F(x)=\begin{cases}\int_{-\infty}^{x}\frac{1}{\sqrt{2\pi}}e^{-t^2/2}dt, & x\le 0,\\ 0.5, & 0<x\le 1,\\ 1, & x>1.\end{cases}$$

由于$P(X=1)=\lim\limits_{x\to 1^+}F(x)-F(1)=1-0.5=0.5$, 即$X$取1的概率等于0.5，故$X$不是连续型随机变量。根据$F(x)$的表达式，$X$不满足只取有限个或可列个值的要求，故$X$也不是离散型随机变量。

2.4 随机变量的函数的概率分布

在实际中，我们经常遇到求随机变量的函数的概率分布。例如$y = g(x)$是一个关于x的函数，已知随机变量X的概率分布，关心$Y = g(X)$的概率分布。本节将根据离散和连续两种情况分别介绍随机变量的函数的概率分布。

2.4.1 离散型随机变量的函数的概率分布

令随机变量X的概率函数为

$$p_i = P(X = a_i), i = 1, 2, \cdots, n.$$

记$Y = g(X)$, Y可能的取值为$b_j, j = 1, 2, \cdots, m, m \le n$. 则$Y$的概率函数为

$$P(Y = b_j) = P(g(X) = b_j) = \sum_{i=1}^{n} P(X = a_i) I_{\{g(a_i)=b_j\}}, j = 1, 2, \cdots, m.$$

求$Y = g(X)$的概率分布的步骤是：先根据随机变量X所有可能的取值确定出Y所有可能的取值，然后再利用公式计算出Y的每个可能取值的概率。

例2.5 令X的概率分布为

取值	-2	-1	0	1	2
概率	$\frac{1}{8}$	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{8}$

求$Y = X^2$的概率分布。

解： $Y = X^2$的可能取值为0, 1, 4, 且

$$\begin{aligned} P(Y = 0) &= P(X^2 = 0) = P(X = 0) = \tfrac{1}{4}, \\ P(Y = 1) &= P(X^2 = 1) = P(X = 1) + P(X = -1) = \tfrac{1}{2}, \\ P(Y = 4) &= P(X^2 = 4) = P(X = 2) + P(X = -2) = \tfrac{1}{4}. \end{aligned}$$

故$Y = X^2$的概率分布为

取值	0	1	4
概率	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$

2.4.2 连续型随机变量的函数的概率分布

对连续型随机变量的函数$Y = g(X)$, 一般先求其分布函数

$$F_Y(y) = P(Y \le y) = P\big(g(X) \le y\big), y \in \mathcal{R}.$$

然后对$F_Y(y)$求导得到其密度函数$f_Y(y)$. 如果函数$g(x)$的反函数存在，记之为$h(y)$, 则有

$$F_Y(y) = P\big(X \le h(y)\big) = F_X\big(h(y)\big),$$

即Y的概率分布可以用X的概率分布表示出来。

例2.6 令连续型随机变量$X \sim F(x)$, $F(x)$是x的严格单调增函数。则$F(X) \sim U(0,1)$.

证明： 记$Y = F(X)$, $F_Y(y)$和$f_Y(y)$分别为Y的分布函数和密度函数。利用分布函数的定义先求$Y = F(X)$的分布函数$F_Y(y)$, 然后对y求导得到Y密度函数。
当$y < 0$ 时，$F_Y(y) = P\big(F(X) \le y\big) = 0$;
当$y > 1$ 时，$F_Y(y) = 1$;
当$0 \le y \le 1$ 时，有

$$F_Y(y) = P\big(F(X) \le y\big) = P\big(X \le F^{-1}(y)\big) = F\big(F^{-1}(y)\big) = y.$$

Y的分布函数为

$$F_Y(y) = \begin{cases} 0, & y < 0, \\ y, & 0 \le y \le 1, \\ 1, & y > 1. \end{cases}$$

求导得Y的密度函数为

$$f_Y(y) = \begin{cases} 1, & 0 \le y \le 1, \\ 0, & \text{其它。} \end{cases}$$

因此，$Y = F(X) \sim U(0,1)$.

例2.6告诉我们：任意一个连续型随机变量X，都可以通过它的分布函数$F(X)$转换成服从均匀分布的随机变量。反过来，我们可以根据一组服从均匀分布的随机变量的观测值，进行一个函数逆变换来产生一组服从某个特定连续分布的随机变量的观测值。这种产生随机数的方法称为随机模拟方法或者Monte Carlo方法。

下面的定理给出函数$g(x)$严格单调时，其反函数存在，随机变量的函数的密度函数。

定理2.1 (密度变换公式) 令随机变量$X \sim f_X(x), x \in (a,b)$, a可以取$-\infty$, b可以取∞. 记$y = g(x)$是x的严格单调的连续函数，$y \in (c,d)$，其反函数为$x = h(y)$, $h'(y)$存在且连续。则$Y = g(X)$是连续型随机变量，其密度函数为

$$f_Y(y) = f_X\big(h(y)\big)\big|h'(y)\big|, y \in (c,d).$$

证明： 分两种情况：
(1)$g(x)$关于x严格上升，

$$P(Y \le y) = P\big(g(X) \le y\big) = P\big(X \le h(y)\big) = \int_{-\infty}^{h(y)} f_X(t)dt$$

上式对y求导得

$$f_Y(y) = f_X\big(h(y)\big)h'(y). \tag{2.1}$$

(2)$g(x)$关于x严格下降，

$$P(Y \le y) = P(g(X) \le y) = P(X \ge h(y)) = \int_{h(y)}^{\infty} f_X(t)dt$$

上式对y求导得

$$f_Y(y) = -f_X\big(h(y)\big)h'(y). \tag{2.2}$$

合并(2.1)和(2.2)即得证。

例2.7 令$X \sim N(\mu, \sigma^2)$. 则$Y = \dfrac{X-\mu}{\sigma} \sim N(0,1)$.

证明： 记$Y = \frac{X-\mu}{\sigma}$, 则$y = \frac{x-\mu}{\sigma}$是$\mathcal{R}$上的严格单调增函数，$y \in \mathcal{R}$. 由

$$x = \mu + \sigma y, \ \frac{dx}{dy} = \sigma,$$

及密度变换公式，得Y的密度函数为

$$f_Y(y) = f_X(\mu+\sigma y)\sigma = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(\mu+\sigma y-\mu)^2}{2\sigma^2}} \sigma = \frac{1}{\sqrt{2\pi}} e^{-y^2/2}.$$

故$Y = (X-\mu)/\sigma \sim N(0,1)$.

例2.7告诉我们：任意一个服从正态分布的随机变量$X \sim N(\mu, \sigma^2)$, 都可以通过一个线性变换$\frac{X-\mu}{\sigma}$(称之为标准化)转换成服从标准正态分布的随机变量，进而对任意$a < b \in \mathcal{R}$, 有

$$\begin{aligned} P(X \le a) &= \Phi\big(\tfrac{a-\mu}{\sigma}\big), \\ P(a \le X \le b) &= \Phi\big(\tfrac{b-\mu}{\sigma}\big) - \Phi\big(\tfrac{a-\mu}{\sigma}\big). \end{aligned}$$

例2.8 对数正态分布 令随机变量$X \sim N(\mu, \sigma^2)$, $Y = e^X$. 则Y服从对数正态分布，记作$Y \sim LN(\mu, \sigma^2)$, 其密度函数为

$$f_Y(y) = \begin{cases} \dfrac{1}{\sqrt{2\pi}\sigma y} \exp\left(-\dfrac{(\ln y - \mu)^2}{2\sigma^2}\right) & y > 0 \\ 0 & y \le 0. \end{cases}$$

证明： $y = e^x$关于$x \in \mathcal{R}$的严格单调增函数. 对任意$y > 0$, 有

$$x = \ln y, \ \frac{dx}{dy} = \frac{1}{y}.$$

由密度变换公式得Y的密度函数为

$$f_Y(y) = \frac{1}{\sqrt{2\pi}y\sigma} \exp\left(-\frac{(\ln y - \mu)^2}{2\sigma^2}\right).$$

图2.8给出了不同参数的对数正态分布的密度函数曲线。可见对数正态分布是一种厚尾分布，即相对于正态分布，尾部概率偏大。

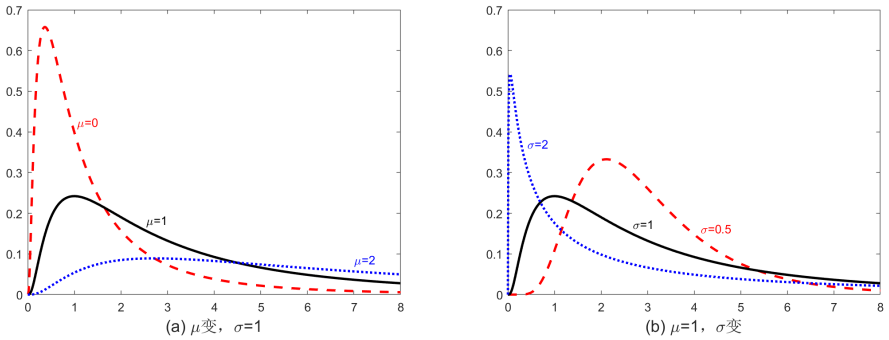


图2.8 对数正态分布$LN(\mu,\sigma^2)$ 不同参数的密度函数曲线。

例2.9 Cauchy分布 (Cauchy, 1789-1857) 令随机变量X的密度函数为

$$f(x)=\frac{\sigma}{\pi[\sigma^2+(x-\mu)^2]},x\in\mathcal{R},$$

其中μ,σ是参数，且$\sigma>0$, 称X服从Cauchy分布。记作$X\sim Cauchy(\mu,\sigma)$. $\mu=0,\sigma=1$的Cauchy分布称为标准Cauchy分布。

若随机变量$Y\sim U(0,1)$, $Z=\tan\big((Y-0.5)\pi\big)$. 则$Z$服从标准Cauchy分布，即$Z$的密度函数为

$$f_Z(z)=\frac{1}{\pi(1+z^2)},z\in\mathcal{R}.$$

证明：利用两种方法来证。

方法一：密度变换公式。显然$Z=(X-0.5)\pi\sim U(-\frac{\pi}{2},\frac{\pi}{2})$. 由密度变换公式可知$Y$的密度函数为

$$f_Y(y)=\frac{1}{\pi}\arctan'(y)=\frac{1}{\pi(1+y^2)}.$$

方法二：先求出分布函数，再对分布函数求导。

$$\begin{aligned}F_Y(y)&=P(Y\le y)\\&=P(\tan Z\le y)\\&=P(Z\le\arctan y)\\&=\int_{-\frac{\pi}{2}}^{\arctan y}\frac{1}{\pi}dy\\&=\frac{1}{\pi}\arctan y+1/2.\end{aligned}$$

对y求导，得到Y的密度函数为

$$f_Y(y)=\frac{1}{\pi(1+y^2)},y\in\mathcal{R}.$$

图2.9给出了Cauchy分布$Cauchy(\mu,\sigma)$不同参数的密度函数曲线，可见Cauchy分布的密度函数关于$x=\mu$对称，而后往两个方向衰减，属于“两头低、中间高”。

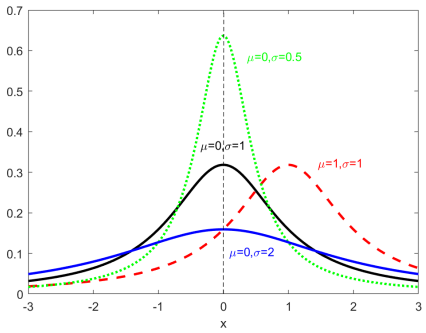


图2.9 Cauchy分布$Cauchy(\mu,\sigma)$不同参数的密度函数曲线。

定理2.1针对的是$g(x)$严格单调的情况。如果$g(x)$是逐段单调而非全区间上单调，或者其它可能情形，一般利用定义来求，即先求分布函数，再对分布函数求导得到密度函数.

例2.10 令$X\sim N(0,1)$. 则$Y=X^2\sim Gamma(0.5,0.5)$.

证明： 当$y\leq 0$时，有$P(Y\leq y)=0$;

当$y>0$时，

$$\begin{aligned} P(Y\leq y) &= P(X^2\leq y)\\ &= P(-\sqrt{y}\leq X\leq \sqrt{y})\\ &= \Phi(\sqrt{y})-\Phi(-\sqrt{y})\\ &= 2\Phi(\sqrt{y})-1. \end{aligned}$$

从而，Y的分布函数为

$$F_Y(y)=\begin{cases} 2\Phi(\sqrt{y})-1, & y>0,\\ 0, & y\leq 0. \end{cases}$$

对y求导，Y的密度函数为

$$f_Y(y)=\begin{cases} \frac{1}{\sqrt{2\pi}}y^{-\frac{1}{2}}e^{-\frac{y}{2}}, & y>0,\\ 0, & y<0. \end{cases}$$

即$Y=X^2\sim Gamma(0.5,0.5)$.

习题二

验证分布函数

1. 下列函数是分布函数吗，为什么？

$$F_1(x)=\begin{cases}0, & x\le 0,\\ \frac{1}{3}, & 0<x\le 1,\\ \frac{1}{2}, & 1<x\le 2,\\ 1, & x>2;\end{cases}\qquad F_2(x)=\begin{cases}0, & x\le 0,\\ \frac{1}{2}, & 0<x\le 1,\\ \frac{1}{3}, & 1<x\le 2,\\ 1, & x>2;\end{cases}$$

$$F_3(x)=\begin{cases}0, & x\le 0,\\ 1-(2x^2+1)\sqrt{1-4x^2}, & 0<x<\frac{1}{2},\\ 1, & x\ge\frac{1}{2};\end{cases}$$

2. 令$F_i(x), i=1,2,\cdots,n$是n个分布函数，$a_1,a_2,\cdots,a_n$是n个给定的正实数，且$\sum\limits_{i=1}^{n}a_i=1$. 求证：$F(x)=\sum\limits_{i=1}^{n}a_iF_i(x)$是分布函数。

离散型随机变量

3. 令事件A在一次试验中发生的概率为p, $0<p<1$. 求n次独立重复试验中A发生偶数次的概率。

4. 令事件A在一次试验中发生的概率为p, $0<p<1$. 独立地重复做试验，当A恰发生三次时，记A没有发生的次数为X. 求X的概率函数。

5. 随机抛掷一枚质地均匀的骰子5次，记出现点数不小于5的次数为X. 求X的概率分布。

6. 令随机变量X的概率函数为$P(X=i)=\frac{k}{i(i+1)}, i=1,2,\cdots$. 求$k$.

7. 有三个盒子，第一个盒子里有2个白球和2个黑球；第二个盒子里有3个白球和3个黑球；第三个盒子里有4个白球和4个黑球。随机选择一个盒子并从该盒子里随任意抽取3个球，用X表示所取到的黑球数。求：(1)X的概率分布；(2)$P(X\ge 2)$.

8. 令随机变量$X\sim Poisson(\lambda), \lambda>0$. 若$P(X=0)=P(X=1)$, 求$P(X>2)$.

9. 从1到6这6个自然数中随机取出2个数，记两个数中的大者为X, 小者为Y. 求X,Y的概率函数。

10. 令随机变量X的的概率函数为

$$P(X=k)=\frac{m}{4^k},\ k=0,1,2,\cdots,$$

求：(1)m的值；(2)$P\big(1<X\leq 2\big)$; (3)$P(X\geq 2)$.

11. 令一排队等待检测的20人中有3名阳性患者。求发现第一个阳性患者时，已检测的阴性个体的数目的概率分布。

12. 一篮球运动员练习投三分球，设他命中三分的概率为0.25. 记他首次命中3分时已经投篮的次数为X. 求：(1)X的概率函数；(2)X取偶数的概率；(3)$P(X>3)$.

13. 考察二项分布，概率函数为$\binom{n}{k}p^k(1-p)^{n-k}$. 求证：
(1)当$np\geq 1$时，概率函数关于k先增后降且当$k=\lfloor np\rfloor$或$k=\lfloor np\rfloor+1$时，概率函数达最大值，其中$\lfloor\cdot\rfloor$表示向下取整；
(2)当$p\leq 1/(n+1)$时，概率函数关于k非增；
(3)当$p\geq 1-1/(n+1)$时，概率函数关于k非降。

14. 考察几何分布，概率函数为$P(X=k)=(1-p)^{k-1}p,\ k=1,2,\cdots$. 求证：概率函数关于$k$先增后降。

15. 考察负二项分布，概率函数为$P(X=k)=\binom{k-1}{r-1}p^r(1-p)^{k-r},\ k=r,r+1,\cdots$. 求证：
(1)当$(r-1)/p\leq r$时，概率函数关于k非增；
(2)当$(r-1)/p>r$时，概率函数关于k先增后降。

16. 考察Poisson分布，概率函数为$\frac{e^{-\lambda}\lambda^k}{k!}$. 求证：
(1)当$\lambda>1$时，概率函数关于k先增后降且当$k=\lfloor\lambda\rfloor$达到最大值；
(2)当$\lambda<1$时，概率函数关于k非增。

连续型随机变量

17. 令函数$f(x)=ke^{-\frac{1}{2}x^2+2x}$是某连续型随机变量的密度函数，$x\in\mathcal{R}$. 求$k$.

18. 令随机变量X的密度函数为

$$f(x)=\begin{cases}2ax\ln x+(a+2b)x, & 1\leq x\leq e,\\ 0, & \text{其它。}\end{cases},$$

其中e是自然对数的底。求X的分布函数。

19. 令随机变量X的密度函数为

$$f(x)=\begin{cases}(k+1)x^2, & 0<x<1,\\ 0, & \text{其它。}\end{cases}$$

求X的分布函数。

20. 向直径为k单位的圆内随机抛掷一点，记此点到圆心的距离为X单位。求X的密度函数及$P(X>k/4)$.

21. 令随机变量X的分布函数为

$$F(x)=\begin{cases}0, & x<-1,\\ k(x+2)^2 & -1\le x\le 1,\\ 1 & x>1.\end{cases}$$

求X的密度函数及$P(-0.5\le X\le 0.5)$.

22. 令$\phi(x)$为标准正态分布的密度函数，

$$f(x)=\begin{cases}\frac{1}{4}, & x\in[-1,3],\\ 0, & \text{其它。}\end{cases}$$

记$a>0,b>0$,

$$g(x)=\begin{cases}a\phi(x), & x\le 0,\\ bf(x), & x>0,\end{cases}$$

求证：当$2a+3b=4$时，$g(x)$是某一随机变量的密度函数。

23. 令$F_1(x),F_2(x)$分别是两个连续型随机变量的分布函数，其密度函数分别为$f_1(x),f_2(x)$. 求证：$f_1(x)F_2(x)+f_2(x)F_1(x)$是某个随机变量的密度函数。

24. 令连续型随机变量X的分布函数和密度函数分别为$F(x)$和$f(x)$. 求证：
(1)若$f(x)$关于原点对称，则$P(X\le -a)=\frac{1}{2}-\int_0^a f(x)dx, a\in\mathcal{R}$;
(2)若$f(x)$关于某点μ对称，则$F(\mu-x)+F(\mu+x)=1, x\in\mathcal{R}$.

离散型随机变量的函数

25. 令一圆形物体的半径为X，其概率分布为

取值	5	6	7	8
概率	0.1	0.4	0.3	0.2

求圆周长Y和圆面积Z的概率分布。

26. 令随机变量$X \sim Poisson(\lambda)$, $Y = \frac{1}{X+1}$. 求Y的概率分布。

27. 令随机变量X的概率分布为

取值	-4	-2	- 1	0	2	4
概率	$\frac{1}{12}$	$\frac{1}{8}$	$\frac{1}{6}$	$\frac{1}{3}$	$\frac{1}{4}$	$\frac{1}{24}$

求X^2和X^3+1的概率分布。

28. 令随机变量X的概率函数为

$$P(X=i)=\frac{1}{2^i}, i=1,2,\cdots.$$

求$Y=\sin(\pi X/2)$的概率函数。

连续型随机变量的函数

29. 令随机变量X的密度函数为$f(x), x \in \mathcal{R}$. 求$1/X, |X|, X^2$的密度函数。

30. 令随机变量$X \sim N(0,1)$. 求$Y=|X|$的密度函数。

31. (1)令随机变量X的密度函数为$f(x)=ax/\pi^2, 0<x<\pi$. 求$Y=2\sin(X/2)$的密度函数。
(2)令随机变量Y的分布函数为$F(y)=1-\exp\big\{-(\frac{y}{\xi})^\eta\big\}, y\geq 0, \xi>0, \eta>0$. 求$(\frac{Y}{\xi})^\eta$的分布。

32. 令随机变量X的密度函数为$f(X)$. 求$aX+b$的密度函数，其中$a\neq 0$.

33. 令随机变量X的密度函数为$f(x)=k\cdot e^{-x^2+4x+2}$. 求$2X$和$X^2$的密度函数。

34. 令随机变量X的密度函数为$f(x)=\frac{k}{1+x^2}, x\in\mathcal{R}$. 求证：$X$与$1/X$具有相同的分布。

35. 令随机变量$X \sim Beta(\xi,\eta)$. 求证：$Y=1-X \sim Beta(\eta,\xi)$.

36. 令随机变量$X \sim Gamma(\xi,\lambda)$. 求证：

$$Y=kX \sim Gamma\big(\xi,\lambda/k\big), k>0.$$

特别地，$2\lambda X \sim Gamma(\xi, 0.5)$.

37. 考察随机变量X. 求证：
(1)若$X \sim Exp(\lambda), \lambda>0$, 则$cX \sim Exp(\lambda/c)$, 其中$c$为给定正常数；
(2)若$X \sim Exp(2)$, 则$e^{-2X} \sim U(0,1)$;

38. 令$f(x), g(x), x \in \mathcal{R}$均为连续型随机变量的密度函数。记$a$是一常数，$a \in [0,1]$. 求证：$af(x) + (1-a)g(x)$是一连续型随机变量的密度函数。

39. 令随机变量X的密度函数为

$$f(x,\xi,\eta) = \frac{\Gamma(\xi+\eta)}{\Gamma(\xi)\Gamma(\eta)} \frac{x^{\xi-1}}{(1+x)^{\xi+\eta}},\ x>0,$$

其中ξ, η是参数，且$\xi > 0, \eta > 0$. 求证：
(1)若$X \sim f(x,\xi,\eta)$, 则$1/X \sim f(x,\eta,\xi)$.
(2)若$Y \sim Beta(\xi,\eta)$, 则$Y/(1-Y) \sim f(x,\xi,\eta)$.
(3)若$X \sim f(x,\xi,\eta)$, 则$X/(1+X) \sim Beta(\xi,\eta)$.

40. 令随机变量$X \sim Gamma(\xi,\lambda)$. 则$Y = 1/X$服从**逆Gamma**分布，其密度函数为：

$$f_Y(y,\xi,\lambda) = \frac{\lambda^{\xi}}{\Gamma(\xi)} \left(\frac{1}{y}\right)^{\xi+1} e^{-\lambda/y},\ y>0,$$

其中ξ, λ是参数，且$\xi > 0, \lambda > 0$.

第三章　多元随机变量及其概率分布

在实际数据分析中，有时候需要用多个随机变量来同时描述试验结果。例如，在一项关于家庭投资理财的收入调查研究中，收入的来源可能有：银行储蓄、股票、房地产、保险、基金和债券等。仅研究其中一个是不全面的，需要把它们作为一个整体来考虑，这里试验的结果要用六个甚至更多的随机变量进行表示。本章将介绍两个及其以上的随机变量所构成的多元随机变量及其概率分布。

3.1 多元随机变量的定义

3.1.1 多元随机变量

n元随机变量：令$X=(X_1,X_2,\cdots,X_n)^\top$, 它的每个分量$X_i$都是一元随机变量，$i=1,2,\cdots,n$, 称$X$是一个$n$元随机变量或随机向量，其中上标$^\top$表示矩阵或者向量的转置。需要说明的是这里考察的$n$元随机变量是列向量。

考察打靶试验。在靶面上取一个平面直角坐标系，靶中心是坐标原点，那么命中的位置可以用二维坐标$(X_1,X_2)^\top$来刻划，由于X_1和X_2都是随机的，故$(X_1,X_2)^\top$是二元随机变量。

类似于一元随机变量的分布函数，我们可以引入多元随机变量的分布函数，称之为联合分布函数。

联合分布函数：令$X=(X_1,X_2,\cdots,X_n)^\top$是$n$元随机变量，对任意$n$个实数$x_1,x_2,\cdots,x_n$, 称$n$元函数

$$F(x_1,x_2,\cdots,x_n)=P(X_1\le x_1,X_2\le x_2,\cdots,X_n\le x_n),$$

为X的联合分布函数。

联合分布函数具有以下性质：

(1) **(单调)** $F(x_1,\cdots,x_n)$对每个x_i是单调非降的，即当$x_{k1}<x_{k2}$时，有

$$F(x_1,\cdots,x_{k1},\cdots,x_n)\le F(x_1,\cdots,x_{k2},\cdots,x_n),k=1,2,\cdots,n.$$

(2) **(有界)** $F(x_1,\cdots,x_n)$介于0到1之间，且对任意的$1\le k\le n$，

$$\lim_{x_k\to-\infty}F(x_1,\cdots,x_k,\cdots,x_n)=0;$$

$$\lim_{x_1\to\infty,x_2\to\infty,\cdots,x_n\to\infty}F(x_1,x_2,\cdots,x_n)=1.$$

(3) **(右连续)** $F(x_1,\cdots,x_n)$对每个x_i是右连续的，即对任意$x_{k0}\in R$，有

$$\lim_{x_k\to x_{k0}^+}F(x_1,\cdots,x_k,\cdots,x_n)=F(x_1,\cdots,x_{k0},\cdots,x_n).$$

(4) **(非负)** 对任意$a_i < b_i, i = 1 \cdots, n$，有

$$P(a_1 < X_1 \leq b_1, a_2 < X_2 \leq b_2, \cdots, a_n < X_n \leq b_n) \geq 0.$$

实际上还可以说明，满足上述四条性质的n元函数$F(x_1, x_2, \cdots, x_n)$一定是某个n元随机变量的分布函数。非负性是多元分布函数所特有的性质，不能由前三条性质得到。下面举个例子，满足前三条性质，却不满足非负性。

例3.1 令二元函数

$$F(x_1, x_2) = \begin{cases} 0, & x_1 + x_2 < 0, \\ 1, & x_1 + x_2 \geq 0. \end{cases}$$

求证：$F(x_1, x_2)$不是一个二元随机变量的联合分布函数。

证明： 图3.1展示了$F(x_1, x_2)$关于x_1, x_2的变化规律，$F(x_1, x_2)$在直线$x_1 + x_2 = 0$的左下方取0，在其右上方取1. 显然$F(x_1, x_2)$具有单调性、有界性和右连续性。由于

$$\begin{aligned} & P(-1 < X_1 \leq 1, -1 < X_2 \leq 1) \\ = \ & P(-\infty < X_1 \leq 1, -\infty < X_2 \leq 1) - P(-\infty < X_1 \leq 1, -\infty < X_2 \leq -1) \\ & -\big[P(-\infty < X_1 \leq -1, -\infty < X_2 \leq 1) - P(-\infty < X_1 \leq -1, -\infty < X_2 \leq -1)\big] \\ = \ & F(1,1) - F(1,-1) - F(-1,1) + F(-1,-1) \\ = \ & -1 \\ < \ & 0. \end{aligned}$$

可见$F(x_1, x_2)$不满足非负性。故$F(x_1, x_2)$不能作为某个二元随机变量的分布函数。

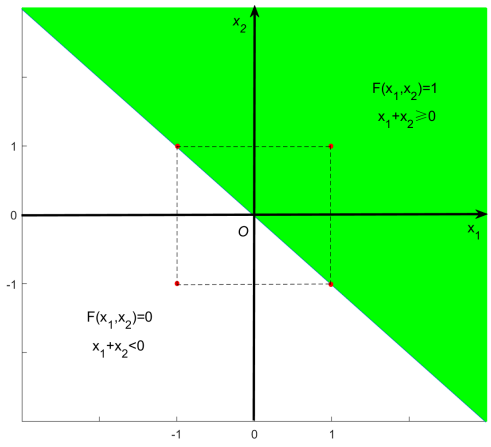


图3.1 $F(x_1, x_2)$。

类似一元随机变量，多元随机变量也有多元离散型随机变量和多元连续型随机变量，当然也有既非离散型也非连续型的多元随机变量。本章只讨论多元离散型随机变量和多元连续型随机变量，其性质较容易推广到非离散型也非连续型的多元随机变量。

3.1.2 多元离散型随机变量

n元离散型随机变量：如果一个n元随机变量$X=(X_1,X_2,\cdots,X_n)^\top$的每一元$X_i$都是离散型随机变量, $i=1,2,\cdots,n$. 称X是一个n元离散型随机变量。

联合概率函数：令$X=(X_1,X_2,\cdots,X_n)^\top$是一个$n$元随机变量, X_i的所有可能取值为$\{a_{i1},a_{i2},\cdots,a_{im_i}\}, i=1,2,\cdots,n$. 记

$$p_{j_1j_2\cdots j_n}=P\big(X_1=a_{1j_1},X_2=a_{2j_2},\cdots,X_n=a_{nj_n}\big), j_i=1,2,\cdots,m_i, i=1,2,\cdots,n,$$

其中

$$p_{j_1j_2\cdots j_n}>0, \sum_{j_1=1}^{m_1}\sum_{j_2=1}^{m_2}\cdots\sum_{j_n=1}^{m_n}p_{j_1j_2\cdots j_n}=1.$$

称$p_{j_1j_2\cdots j_n}, j_i=1,2,\cdots,m_i, i=1,2,\cdots,n$为$X$的联合概率函数。

考察二元离散型随机变量$(X_1,X_2)^\top$. 令X_1所有可能的取值为$a_1,a_2,\cdots,a_m$, X_2所有可能的取值为$b_1,b_2,\cdots,b_n$. 联合概率函数为

$$p_{ij}=P(X_1=a_i,X_2=b_j), i=1,2,\cdots,m, j=1,2,\cdots,n.$$

可以用下面的列联表表示二元离散型随机变量的联合概率分布

$X_1\backslash X_2$	b_1	b_2	$\cdots$	b_n	行和
a_1	p_{11}	p_{12}	$\cdots$	p_{1n}	$p_{1\cdot}$
a_2	p_{21}	p_{22}	$\cdots$	p_{2n}	$p_{2\cdot}$
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
a_m	p_{m1}	p_{m2}	$\cdots$	p_{mn}	$p_{m\cdot}$
列和	$p_{\cdot1}$	$p_{\cdot2}$	$\cdots$	$p_{\cdot n}$	1

例3.2 一盒子里有4个白球和3个红球，从中随机取出2个球。记取到白球的数目为X_1，取到红球的数目为X_2. 求$(X_1,X_2)^\top$的联合概率函数。

解：$(X_1,X_2)^\top$的联合概率函数为

$$P(X_1=k,X_2=m)=\frac{\binom{4}{k}\binom{3}{m}}{\binom{7}{2}}, k+m=2.$$

用列联表表示

$X_1\backslash X_2$	0	1	2	行和
0	*	*	$\frac{1}{7}$	$\frac{1}{7}$
1	*	$\frac{4}{7}$	*	$\frac{4}{7}$
2	$\frac{2}{7}$	*	*	$\frac{2}{7}$
列和	$\frac{2}{7}$	$\frac{4}{7}$	$\frac{1}{7}$	1

称多元离散型随机变量的概率分布为多元离散分布。下面介绍一个常见的多元离散分布，多项分布，它是二项分布的推广。

多项分布

令n个事件A_1,A_2,$\cdots$,A_n互斥且$\bigcup_{i=1}^{n} A_i$是必然事件。每次试验，A_1, A_2, $\cdots$, A_n这n个事件发生一个且只发生一个。记$p_i = P(A_i), p_i > 0, , i = 1, 2, \cdots, n, \sum_{i=1}^{n} p_i = 1$. 把试验独立重复地做$N$次，记$A_i$发生的次数为$X_i$, $i = 1, 2, \cdots, n$. 那么$X = (X_1, X_2, \cdots, X_n)^\top$服从多项分布，其联合概率函数为

$$P(X_1 = k_1, X_2 = k_2, \cdots, X_n = k_n) = \frac{N!}{k_1!k_2!\cdots k_n!} p_1^{k_1} p_2^{k_2} \cdots p_n^{k_n},$$

其中$k_i \geq 0, i = 1, 2, \cdots, n, \sum_{i=1}^{n} k_n = N$. 记作$X \sim Mul(N, p_1, p_2, \cdots, p_n)$.

独立重复地做N次试验，事件A_1发生k_1次，A_2发生k_2次，$\cdots$, A_n发生k_n 次；等价于把N件产品分成n组，各组的产品数分别为$k_1, k_2, \cdots, k_n$. 由第一章定理1.2知，不同的分法有$N!/(k_1!k_2!\cdots k_n!)$种，事件A_1发生k_1次的概率为$p_1^{k_1}$, A_2发生k_2次的概率为$p_2^{k_2}$, $\cdots$, A_n发生k_n 次的概率为$p_n^{k_n}$, 进而得到$P(X_1 = k_1, X_2 = k_2, \cdots, X_n = k_n)$.

多项分布的名称来源于多项式展开式

$$(x_1 + x_2 + \cdots + x_n)^N = \sum_{k_i \geq 0, k_1 + k_2 + \cdots + k_n = N} \frac{N!}{k_1!k_2!\cdots k_n!} x_1^{k_1} x_2^{k_2} \cdots x_n^{k_n}.$$

考察某种族人群基因组上一等位基因位点上的两种等位基因：g和G. 那么该位点有三种基因型gg, Gg 和GG. 记这三种基因型在该人群中的比例分别为p_0, p_1, p_2, 满足$p_0 + p_1 + p_2 = 1$. 即

$$P(\text{gg}) = p_0, \ P(\text{Gg}) = p_1, \ P(\text{GG}) = p_2.$$

那么，从该人群中随机抽取n个人，记具有基因型gg, Gg, GG的人数分别为X_0, X_1, X_2. 则

$$(X_0, X_1, X_2)^\top \sim Mul(n, p_0, p_1, p_2),$$

3.1.3 多元连续型随机变量

n元连续型随机变量：如果一个n元随机变量$X = (X_1, X_2, \cdots, X_n)^\top$的每一元$X_i$都是一元连续型随机变量, $i = 1, 2, \cdots, n$. 称X是一个n元连续型随机变量。

常用联合概率密度函数描述多元连续型随机变量取值的变化规律。

联合概率密度函数：令X是n元连续型随机变量。若函数$f(x_1, x_2, \cdots, x_n)$满足下面3个条件：

(1) $f(x_1, x_2, \cdots, x_n) \geq 0, (x_1, x_2, \cdots, x_n)^\top \in \mathcal{R}^n$;

(2) $\int_{-\infty}^{\infty}\int_{-\infty}^{\infty}\cdots\int_{-\infty}^{\infty} f(x_1,x_2,\cdots,x_n)dx_n\cdots dx_2dx_1=1$;
(3) 对任意$a_i\le b_i, i=1,2,\cdots,n$, a_i和b_i 可以分别取到$-\infty$和∞, 有

$$P(a_1\le X_1\le b_1, a_2\le X_2\le b_2,\cdots,a_n\le X_n\le b_n)$$
$$=\int_{a_1}^{b_1}\int_{a_2}^{b_2}\cdots\int_{a_n}^{b_n} f(x_1,x_2,\cdots,x_n)dx_n\cdots dx_2dx_1.$$

称$f(x_1,x_2,\cdots,x_n)$为X的联合概率密度函数，联合概率密度函数简称联合密度函数。

n元连续型随机变量$X=(X_1,X_2,\cdots,X_n)^\top$的联合分布函数为

$$\begin{aligned} F(x_1,x_2,\cdots,x_n) &= P(X_1\le x_2, X_2\le x_2,\cdots,X_n\le x_n)\\ &= \int_{-\infty}^{x_1}\int_{-\infty}^{x_2}\cdots\int_{-\infty}^{x_n} f(u_1,u_2,\cdots,u_n)du_n\cdots du_2du_1,\end{aligned}$$

其中$(x_1,x_2,\cdots,x_n)^\top\in\mathcal{R}^n$.

常见的多元连续型随机变量是多元正态分布。

多元正态分布

令$\boldsymbol{\mu}=(\mu_1,\mu_2,\cdots,\mu_n)^\top$是一$n$元实值向量，$\boldsymbol{\Delta}$是$n$阶正定对称矩阵。记$\boldsymbol{\Delta}$的行列式为$\det(\boldsymbol{\Delta})$, 逆为$\boldsymbol{\Delta}^{-1}$, $X=(X_1,X_2,\cdots,X_n)^\top$的联合密度函数为

$$f(x_1,x_2,\cdots,x_n)=\frac{1}{(2\pi)^{n/2}\det(\boldsymbol{\Delta})^{1/2}}\exp\left\{-\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu})^\top\boldsymbol{\Delta}^{-1}(\boldsymbol{x}-\boldsymbol{\mu})\right\},$$

其中$\boldsymbol{x}=(x_1,x_2,\cdots,x_n)^\top\in R^n$. 称$X$服从$n$元正态分布，记作$X\sim N(\boldsymbol{\mu},\boldsymbol{\Delta})$.

下面介绍二元正态分布，它是多元正态分布的一个特例。

二元正态分布 服从二元正态分布的随机变量$(X_1,X_2)^\top$的联合密度函数为

$f(x_1,x_2)=$

$$\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}\exp\left\{-\frac{1}{2(1-\rho^2)}\left[\frac{(x_1-\mu_1)^2}{\sigma_1^2}-2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2}+\frac{(x_2-\mu_2)^2}{\sigma_2^2}\right]\right\},$$

其中$-\infty<\mu_1,\mu_2<\infty, 0<\sigma_1,\sigma_2<\infty, -1<\rho<1$. 常记为

$$(X_1,X_2)^\top\sim N(\mu_1,\mu_2,\sigma_1^2,\sigma_2^2,\rho).$$

图3.2给出了二元正态分布的概率密度，呈现中间高，周围低的情形。

二元均匀分布 若二元随机变量$X=(X_1,X_2)^\top$的密度函数为

$$f(x_1,x_2)=\begin{cases}\frac{1}{(b-a)(d-c)}, & a\le x_1\le b且c\le x_2\le d,\\ 0, & 其它。\end{cases}$$

其中$a<b, c<d$, 称X服从$[a,b]\times[c,d]$ 上的均匀分布，记作$X\sim U\big([a,b]\times[c,d]\big)$.

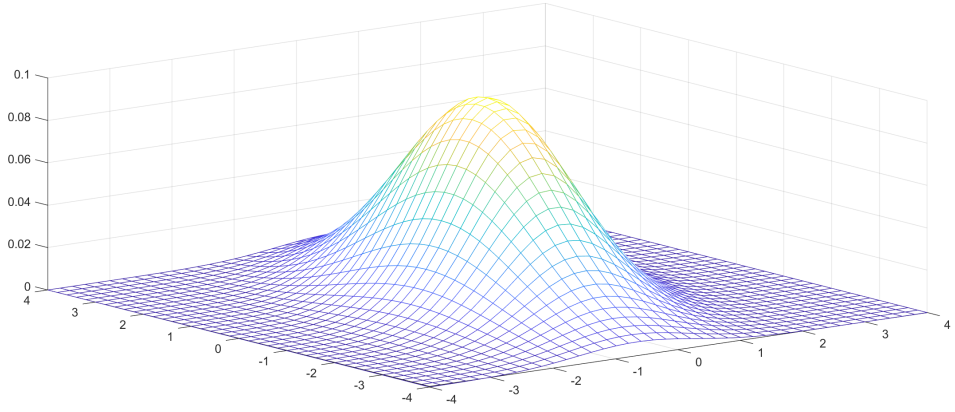


图3.2 二元正态分布的概率密度。

3.2 边缘分布

联合概率分布整体上刻画了多元随机变量取值的变化规律。有时候已知多元随机变量的联合概率分布，我们需要了解构成多元随机变量的部分分量的联合概率分布，这就是本节要介绍的边缘分布。

边缘分布：令$X=(X_1,X_2,\cdots,X_n)^\top\sim F(x_1,x_2,\cdots,x_n)$, $\{i_1,i_2,\cdots,i_k\}\subset\{1,2,\cdots,n\}$. 称$(X_{i_1},X_{i_2},\cdots,X_{i_k})^\top$的联合分布为$X$的边缘分布，或$(X_{i_1},X_{i_2},\cdots,X_{i_k})^\top$的边缘分布。特别地，当$m=1$时，单个随机变量$X_i$的分布是$X_i$的边缘分布，$i=1,2,\cdots,n$.

下面给出n元离散型随机变量的边缘分布和n元连续型随机变量的边缘分布。

n元离散随机变量的边缘分布：令n元随机变量$(X_1,X_2,\cdots,X_n)^\top$的联合概率函数为

$$p_{j_1j_2\cdots j_n}=P(X_1=x_{1j_1},X_2=x_{2j_2},\cdots,X_n=x_{nj_n}),$$

其中$j_i=1,2,\cdots,m_i$, $i=1,2,\cdots,n$. 令$\{i_1,i_2,\cdots,i_k\}\subset\{1,2,\cdots,n\}$, 则$(X_{i_1},X_{i_2},\cdots,X_{i_k})^\top$的概率函数为

$$P(X_{i_1}=x_{i_1j_{i_1}},X_{i_2}=x_{i_2j_{i_2}},\cdots,X_{i_k}=x_{i_kj_{i_k}})$$

$$=\sum P\big(X_{i_1}=x_{i_1j_{i_1}},\cdots,X_{i_k}=x_{i_kj_{i_k}},X_{i_{k+1}}=x_{i_{k+1}j_{i_{k+1}}},\cdots,X_{i_n}=x_{i_nj_{i_n}}\big),$$

其中

$$(i_{k+1},i_{k+2},\cdots,i_n)=\{1,2,\cdots,n\}\backslash\{i_1,i_2,\cdots,i_k\},$$

求和是对除了随机变量$X_{i_1},X_{i_2},\cdots,X_{i_k}$, 剩下的$n-k$的随机变量的所有取值求和。称$P(X_{i_1}=x_{i_1j_{i_1}},X_{i_2}=x_{i_2j_{i_2}},\cdots,X_{i_k}=x_{i_kj_{i_k}})$为$X$或$(X_{i_1},X_{i_2},\cdots,X_{i_k})^\top$的边缘概率函数。

特别地，当$m = 1$时对应单个分量的边缘概率函数，此时，对于$i = 1, 2, \cdots, n$, X_i的边缘概率函数为

$$P(X_i = x_i) = \sum_{k\in\{1,\cdots,i-1,i+1,\cdots,n\}} \sum_{j_k=1}^{m_k} p_{j_1 j_2 \cdots j_n}.$$

考察二元离散型随机变量$(X_2, X_2)^\top$, 其概率分布为：

$X_1 \backslash X_2$	b_1	b_2	$\cdots$	b_m	行和
a_1	p_{11}	p_{12}	$\cdots$	p_{1m}	$p_{1\cdot}$
a_2	p_{21}	p_{22}	$\cdots$	p_{2m}	$p_{2\cdot}$
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
a_k	p_{k1}	p_{k2}	$\cdots$	p_{km}	$p_{k\cdot}$
列和	$p_{\cdot 1}$	$p_{\cdot 2}$	$\cdots$	$p_{\cdot m}$	1

由全概率公式，

$$P(X_1 = a_i) = \sum_{j=1}^{m} P(X_1 = a_i, X_2 = b_j) = \sum_{j=1}^{m} p_{ij} = p_{i\cdot}, i = 1, 2, \cdots, k.$$

行和对应的就是X_1的边缘分布。类似地，列和对应的是X_2的边缘分布，即

$$P(X_2 = b_j) = \sum_{i=1}^{k} P(X_1 = a_i, X_2 = b_j) = \sum_{i=1}^{k} p_{ij} = p_{\cdot j}, j = 1, 2, \cdots, m.$$

例3.3 令$X = (X_1, X_2, \cdots, X_n)^\top \sim M(N, p_1, p_2, \cdots, p_n)$. 求证：$X_1$的边缘分布是二项分布$B(N, p_1)$.

解：我们把对应X_1的事件记为A_1，对应$X_2, X_3, \cdots, X_n$的事件A_2, A_3, $\cdots$ A_n的并记为$\bar{A}_1$. 那么X_1就是在N次独立试验中事件A_1发生的次数，而且每次试验A_1发生的概率为p_1. 因此，X_1的分布就是二项分布$B(N, p_1)$. 下面给出其数学推导。记

$$\tilde{p}_2 = p_2/(1 - p_1), \tilde{p}_3 = p_3/(1 - p_1), \cdots, \tilde{p}_n = p_n/(1 - p_1).$$

有

$$\begin{aligned}
P(X_1 = k) &= \sum_{\substack{k_2 + k_3 + \cdots + k_n = N - k \\ 0 \le k_i \le N - k}} \frac{N!}{k_2! k_3! \cdots k_n!} p_2^{k_2} p_3^{k_3} \cdots p_n^{k_n} \frac{p_1^k}{k!} \\
&= \sum_{k_2, k_3, \cdots, k_n} \frac{(N-k)!}{k_2! k_3! \cdots k_n!} \tilde{p}_2^{k_2} \tilde{p}_2^{k_3} \cdots \tilde{p}_n^{k_n} \frac{N!}{k!(N-k)!} p_1^k (1 - p_1)^{N-k} \\
&= (\tilde{p}_2 + \tilde{p}_3 + \cdots + \tilde{p}_n)^{N-k} \frac{N!}{k!(N-k)!} p_1^k (1 - p_1)^{N-k} \\
&= \frac{N!}{k!(N-k)!} p_1^k (1 - p_1)^{N-k}.
\end{aligned}$$

常用边缘密度函数来刻画多元连续型随机变量的边缘分布。

n元连续型随机变量的边缘密度函数：令$f(x_1,x_2,\cdots,x_n)$为n元连续型随机变量$(X_1,X_2,\cdots\ X_n)^\top$的联合密度函数。对任意$\{i_1,i_2,\cdots,i_k\}\subset\{1,2,\cdots,n\}$, 称

$$f(x_{i_1},x_{i_2},\cdots,x_{i_k})=\int_{-\infty}^{\infty}\int_{-\infty}^{\infty}\cdots\int_{-\infty}^{\infty}f(x_{i_1},x_{i_2},\cdots,x_{i_n})dx_{i_{k+1}}dx_{i_{k+2}}\cdots dx_{i_n},$$

为X或$(X_{i_1},X_{i_2},\cdots,X_{i_k})^\top$的边缘密度函数，其中

$$(i_{k+1},i_{k+2},\cdots,i_n)=\{1,2,\cdots,n\}\backslash\{i_1,i_2,\cdots,i_k\},$$

积分是对除$x_{i_1},x_{i_2},\cdots,x_{i_k}$之外的所有变元求积分。

特别地，当$m=1$时，对于$i=1,2,\cdots,n$, X_i的边缘密度为

$$f_{X_i}(x_i)=\int_{-\infty}^{\infty}\int_{-\infty}^{\infty}\cdots\int_{-\infty}^{\infty}f(x_1,x_2,\cdots,x_n)dx_1\cdots dx_{i-1}dx_{i+1}\cdots dx_n.$$

例3.4 令$(X_1,X_2)^\top\sim N(\mu_1,\mu_2,\sigma_1^2,\sigma_2^2,\rho)$. 求证：$X_1$的边缘分布为$N(\mu_1,\sigma_1^2)$, X_2的边缘分布为$N(\mu_2,\sigma_2^2)$.

证明：按照定义，X_1的边缘密度为$\int_{-\infty}^{\infty}f(x_1,x_2)dx_2$, 其中$f(x_1,x_2)$是$(X_1,X_2)^\top$的联合密度函数。注意到

$$\begin{aligned}&\frac{(x_1-\mu_1)^2}{\sigma_1^2}-\frac{2\rho(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2}+\frac{(x_2-\mu_2)^2}{\sigma_2^2}\\&\qquad=(1-\rho^2)\frac{(x_1-\mu_1)^2}{\sigma_1^2}+\left(\rho\frac{x_1-\mu_1}{\sigma_1}-\frac{x_2-\mu_2}{\sigma_2}\right)^2.\end{aligned}$$

X_1的密度函数为

$$f_1(x_1)=\int_{-\infty}^{\infty}f(x_1,x_2)dx_2=\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}\exp\left(-\frac{(x_1-\mu_1)^2}{2\sigma_1^2}\right)a,$$

其中

$$a=\int_{-\infty}^{\infty}\exp\left[-\frac{1}{2(1-\rho^2)}\left(\rho\frac{x_1-\mu_1}{\sigma_1}-\frac{x_2-\mu_2}{\sigma_2}\right)^2\right]dx_2.$$

做变量代换，令

$$t=\left(\frac{x_2-\mu_2}{\sigma_2}-\rho\frac{x_1-\mu_1}{\sigma_2}\right)/\sqrt{1-\rho^2},$$

得

$$a=\sigma_2\sqrt{1-\rho^2}\int_{-\infty}^{\infty}\exp\Big(-\frac{t^2}{2}\Big)dt=\sqrt{2\pi}\sigma_2\sqrt{1-\rho^2}.$$

带入$f_1(x_1)$，得

$$f_1(x_1)=\frac{1}{\sqrt{2\pi}\sigma_1}\exp\left(-\frac{(x_1-\mu_1)^2}{2\sigma_1^2}\right).$$

多元随机变量的联合分布唯一决定其所有的边缘分布，但边缘分布不能决定联合分布。例如：两个二元正态分布$N(0,0,1,1,0.1)$和$N(0,0,1,1,0.2)$. 它们任意一个边缘分布都是标准正态分布，但这两个分布是不同的分布。这是由于边缘分布只考虑了单个随机变量的情况，没有涉及不同随机变量之间的相关性。

3.3 条件概率分布

一个随机变量的条件概率分布就是在给定某种条件下该随机变量的概率分布，条件概率分布简称条件分布。比如研究某地区人群的收入情况，我们在给定所从事的职业条件下看收入的分布规律。为了陈述方便，本书主要讨论二元随机变量的情形，其结果较容易推广到三元及其以上随机变量的情形。

二元离散型随机变量的条件分布

令$(X_1, X_2)^\top$为二元离散型随机变量，X_1所有可能的取值为$x_{11}, x_{12}, \cdots, x_{1k}$，$X_2$所有可能的取值为$x_{21}, x_{22}, \cdots, x_{2m}$. $(X_1, X_2)^\top$的联合概率函数为：

$$p_{ij} = P(X_1 = x_{1i}, X_2 = x_{2j}), i = 1, 2, \cdots, k, j = 1, 2, \cdots, m.$$

记 $p_{i\cdot} = \sum_{j=1}^{m} p_{ij}$, $p_{\cdot j} = \sum_{i=1}^{k} p_{ij}$. 称

$$P(X_1 = x_{1i}|X_2 = x_{2j}) = \frac{P(X_1 = x_{1i}, X_2 = x_{2j})}{P(X_2 = x_{2j})} = \frac{p_{ij}}{p_{\cdot j}}$$

是给定$X_2 = x_{2j}$的条件下X_1的条件概率函数。

同理，

$$P(X_2 = x_{2j}|X_1 = x_{1i}) = \frac{P(X_2 = x_{2j}, X_1 = x_{1i})}{P(X_1 = x_{1i})} = \frac{p_{ij}}{p_{i\cdot}}$$

是给定$X_1 = x_{1i}$的条件下X_2的条件概率函数。

例3.5 令$(X_1, X_2, \cdots, X_n)^\top \sim Mul(N, p_1, p_2, \cdots, p_n)$. 求在给定$X_2 = k_2$的条件下$X_1$的条件概率分布。

解： 先计算$P(X_1 = k_1, X_2 = k_2)$.

$$\begin{aligned} P(X_1 = k_1, X_2 = k_2) &= \sum_{k_3+k_4+\cdots+k_n=N-k_1-k_2} \frac{N!}{k_1!k_2!\cdots k_n!} p_1^{k_1} p_2^{k_2} \cdots p_n^{k_n} \\ &= \frac{N!}{k_1!k_2!(N-k_1-k_2)!} p_1^{k_1} p_2^{k_2} (1-p_1-p_2)^{N-k_1-k_2} Q, \end{aligned}$$

其中

$$\begin{aligned} Q &= \sum_{\{(k_3,\cdots,k_n)|k_3+\cdots+k_n=N-k_1-k_2\}} \frac{(N-k_1-k_2)!}{k_3!\cdots k_n!} \left(\frac{p_3}{1-p_1-p_2}\right)^{k_3} \cdots \left(\frac{p_n}{1-p_1-p_2}\right)^{k_n} \\ &= \left(\frac{p_3}{1-p_1-p_2} + \cdots + \frac{p_n}{1-p_1-p_2}\right)^{N-k_1-k_2} \\ &= 1. \end{aligned}$$

可见$(X_1, X_2)^\top$的联合分布是三项分布。由例3.3知X_2的边缘分布是二项分布$B(N, p_2)$. 因此

$$\begin{aligned} P(X_1 = k_1|X_2 = k_2) &= \frac{P(X_1=k_1, X_2=k_2)}{P(X_2=k_2)} \\ &= \frac{\frac{N!}{k_1!k_2!(N-k_1-k_2)!} p_1^{k_1} p_2^{k_2} (1-p_1-p_2)^{N-k_1-k_2}}{\frac{N!}{k_2!(N-k_2)!} p_2^{k_2} (1-p_2)^{N-k_2}} \\ &= \frac{(N-k_2)!}{k_1!(N-k_1-k_2)!} \left(\frac{p_1}{1-p_2}\right)^{k_1} \left(1 - \frac{p_1}{1-p_2}\right)^{N-k_1-k_2}. \end{aligned}$$

它是二项分布$B\big(N-k_2,\frac{p_1}{1-p_2}\big)$.

例3.6 一热线电话在单位时间内收到的咨询人数$X\sim Poisson(\lambda)$. 假设每个人咨询一给定事件的概率为p且每个人是否咨询该事件是独立的。求在单位时间内咨询该事件的人数Y的概率分布。

解：由题意知$Y|X=n\sim B(n,p)$. 因此

$$\begin{aligned}
P(Y=k) &= \sum_{n=k}^{\infty}P(Y=k,X=n)\\
&= \sum_{n=k}^{\infty}P(Y=k|X=n)P(X=n)\\
&= \sum_{n=k}^{\infty}\frac{n!}{k!(n-k)!}p^k(1-p)^{n-k}\frac{\lambda^n e^{-\lambda}}{n!}\\
&= e^{-\lambda}\sum_{n=k}^{\infty}\frac{\lambda^n}{k!(n-k)!}p^k(1-p)^{n-k}\\
&= \frac{(\lambda p)^k e^{-\lambda}}{k!}\sum_{n=k}^{\infty}\frac{(\lambda-\lambda p)^{n-k}}{(n-k)!}(\text{令}n-k=i))\\
&= \frac{(\lambda p)^k e^{-\lambda}}{k!}\sum_{i=0}^{\infty}\frac{(\lambda-\lambda p)^{i}}{(i)!}\\
&= \frac{(\lambda p)^k e^{-\lambda}}{k!}e^{\lambda-\lambda p}\\
&= \frac{(\lambda p)^k e^{-\lambda p}}{k!}.
\end{aligned}$$

可见$Y\sim Poisson(\lambda p)$.

二元连续型随机变量的条件分布

令二元连续型随机变量$(X_1,X_2)^\top$的密度函数为$f(x_1,x_2)$, X_2的边缘密度函数为$f_{X_2}(x_2)$. 对任意$x_2\in\mathcal{R}$, $\varepsilon>0$, $P(x_2\le X_2\le x_2+\varepsilon)>0$. 考察在给定$x_2\le X_2\le x_2+\varepsilon$ 的条件下X_1的条件分布函数。

$$\begin{aligned}
P(X_1\le x_1|x_2\le X_2\le x_2+\varepsilon) &= \frac{P(X_1\le x_1, x_2\le X_2\le x_2+\varepsilon)}{P(x_2\le X_2\le x_2+\varepsilon)}\\
&= \frac{\int_{-\infty}^{x_1}\int_{x_2}^{x_2+\varepsilon}f(u,v)dvdu}{\int_{x_2}^{x_2+\varepsilon}f_{X_2}(t)dt}\\
&= \int_{-\infty}^{x_1}\frac{\int_{x_2}^{x_2+\varepsilon}f(u,v)dv}{\int_{x_2}^{x_2+\varepsilon}f_{X_2}(t)dt}du.
\end{aligned}$$

两端关于x_1求导并令$\varepsilon\to 0$, 可得在给定$X_2=x_2$的条件下，X_1的条件密度函数为

$$f_{X_1|X_2}(x_1|x_2)=\frac{f(x_1,x_2)}{f_{X_2}(x_2)}, f_{X_2}(x_2)>0.$$

记作$X_1|X_2=x_2\sim f_{X_1|X_2}(x_1|x_2)$.

同理，在给定$X_1=x_1$的条件下X_2的条件密度函数为

$$f_{X_2|X_1}(x_2|x_1)=\frac{f(x_1,x_2)}{f_{X_1}(x_1)}, f_{X_1}(x_1)>0.$$

记作$X_2|X_1 = x_1 \sim f_{X_2|X_1}(x_2|x_1)$.

上面的条件密度函数可以改写为

$$f(x_1, x_2) = f_{X_2}(x_2) f_{X_1|X_2}(x_1|x_2).$$

即：X_1和X_2的联合密度函数等于其中一个随机变量的密度函数乘以在给定这个随机变量之下另一个随机变量的条件密度函数。这个公式相应于第一章的条件概率公式。

把$f(x_1, x_2) = f_{X_2}(x_2) f_{X_1|X_2}(x_1|x_2)$ 两边对x_2积分，得

$$f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_2}(x_2) f_{X_1|X_2}(x_1|x_2) dx_2.$$

可见X_1的密度函数$f_{X_1}(x_1)$是其关于X_2的条件密度$f_{X_1|X_2}(x_1|x_2)$对x_2的加权平均，其中权重是X_2取值的概率大小。

例3.7 令$(X_1, X_2)^\top \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$. 求$X_1|X_2 = x_2$的条件密度函数。

解：

$$\begin{aligned} f_{X_1|X_2}(x_1|x_2) &= \frac{f(x_1, x_2)}{f_{X_2}(x_2)} \\ &= \frac{1}{\sqrt{2\pi}\sigma_1\sqrt{1-\rho^2}} \exp\left\{ -\frac{\left[x_1 - \left(\mu_1 + \frac{\rho\sigma_1}{\sigma_2}(x_2 - \mu_2)\right)\right]^2}{2\sigma_1^2(1-\rho^2)} \right\}. \end{aligned}$$

即$X_1|X_2 = x_2 \sim N\left(\mu_1 + \frac{\rho\sigma_1}{\sigma_2}(x_2 - \mu_2), (1-\rho^2)\sigma_1^2\right)$. 同理有

$$X_2|X_1 = x_1 \sim N\left(\mu_2 + \frac{\rho\sigma_2}{\sigma_1}(x_1 - \mu_1), (1-\rho^2)\sigma_2^2\right).$$

例3.8 (几何分布的无记忆性) 令随机变量X服从几何分布，即$X \sim Geo(p)$. 若已知前m次试验事件A没有发生，为使A首次发生需要再做的试验次数为$\widetilde{X}$，则$\widetilde{X} \sim Geo(p)$.

证明：$\widetilde{X}$的概率函数为

$$\begin{aligned} P\big(\widetilde{X} = k\big) &= P(X = m + k | X > m) \\ &= \frac{P(X = m + k)}{P(X > m)} \\ &= \frac{(1-p)^{m+k-1} p}{(1-p)^m} \\ &= (1-p)^{k-1} p. \end{aligned}$$

可见$\widetilde{X} \sim Geo(p)$, 与前面的试验次数$m$无关，相当于忘记了过去的经历，称之为几何分布的无记忆性。

例3.9 (指数分布的无老化性和无记忆性) 指数分布常用作寿命分布，比如某种电子元件的使用寿命可以认为服从指数分布。令X表示某电子元件的使用寿命。定义失效率：

$$H(x) = \lim_{\varepsilon \to 0} \frac{P(x \le X \le x + \varepsilon | X > x)}{\varepsilon}.$$

即：该电子元件在时刻x时能正常工作，在时刻x后单位时间内发生失效的概率。

指数分布有两个特性：

(1) “无老化性”：

$$\begin{aligned} H(x) &= \lim_{\varepsilon \to 0} \frac{P(x \le X \le x + \varepsilon | X > x)}{\varepsilon} \\ &= \lim_{\varepsilon \to 0} \frac{P(x < X \le x + \varepsilon)}{\varepsilon[1 - F(x)]} \\ &= \lim_{\varepsilon \to 0} \frac{F(x + \varepsilon) - F(x)}{\varepsilon} \times \frac{1}{1 - F(x)} \\ &= \frac{F'(x)}{1 - F(x)} \\ &= \lambda. \end{aligned}$$

上式表明：在任何时刻，瞬间失效率保持不变，与已经工作过的时间无关。

(2) “无记忆性”：对任意的$s, t > 0$, 有

$$P(X > s + t | X > s) = \frac{P(X > s + t)}{P(X > s)} = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t} = P(X > t).$$

可以解释为：某元件已经使用了s时长后未失效，再使用时长t且不失效的概率等于从零时刻算起使用t时长的概率，它与已经工作的s时长无关，对这部分没有记忆。比如，某产品已经工作100个小时和1000个小时后剩余寿命的概率分布保持不变。

事实上，指数分布是**唯一**具有“无记忆性”的连续分布。下面证明这个结论。

证明： 令$G(s) = P(X > s)$, $s > 0$. 显然$G(s)$是s的单调减函数，且对任意$s, t > 0$,

$$G(s + t) = G(s)G(t).$$

进而对任意正整数n和m,

$$G(1) = G\left(\frac{1}{n}\right)^n, \; G\left(\frac{1}{n}\right) = G(1)^{\frac{1}{n}},$$

$$G\left(\frac{m}{n}\right) = G\left(\frac{1}{n}\right)^m = G(1)^{\frac{m}{n}}.$$

可见，对任意的有理数ξ, 均有$G(\xi) = G(1)^{\xi}$. 进而对任意的无理数η, 也有

$$G(\eta) = G(1)^{\eta}.$$

由于$G(1) = P(X > 1) \in (0, 1)$, 令$G(1) = e^{-\lambda}, \lambda > 0$. 所以

$$P(X \leq x) = 1 - G(x) = 1 - e^{-\lambda x}, x > 0.$$

例3.10 令$(X_1, X_2)^{\top}$服从单位圆上的均匀分布。求$f_{X_1|X_2}(x_1|x_2)$ 和$F_{X_1|X_2}(x_1|x_2)$.

解： $(X_1, X_2)^{\top}$的联合密度函数为

$$f(x_1, x_2) = \begin{cases} \dfrac{1}{\pi}, & x_1^2 + x_2^2 \leq 1, \\ 0, & \text{其它。} \end{cases}$$

X_2的边缘密度函数为

$$f_{X_2}(x_2) = \begin{cases} \frac{2}{\pi}\sqrt{1 - x_2^2}, & -1 \leq x_2 \leq 1, \\ 0, & \text{其它。} \end{cases}$$

因此

$$f_{X_1|X_2}(x_1|x_2) = \begin{cases} \frac{1}{2\sqrt{1-x_2^2}}, & -\sqrt{1 - x_2^2} \leq x_1 \leq \sqrt{1 - x_2^2}, \\ 0, & \text{其它，} \end{cases}$$

$$F_{X_1|X_2}(x_1|x_2) = \begin{cases} 0, & x_1 < -\sqrt{1 - x_2^2}, \\ \frac{x_1 + \sqrt{1-x_2^2}}{2\sqrt{1-x_2^2}}, & -\sqrt{1 - x_2^2} \leq x_1 \leq \sqrt{1 - x_1^2}, \\ 1, & \text{其它。} \end{cases}$$

一般情形

无论离散型还是连续型随机变量的条件分布，上述关于$(X_1, X_2)^{\top}$的结果都可推广到多元随机变量。

以连续型随机变量为例，令

$$(X_1, X_2, \cdots, X_n)^{\top} \sim f(x_1, x_2, \cdots, x_n),$$

$$(X_1, X_2, \cdots, X_k)^{\top} \sim f_{X_1, X_2, \cdots, X_k}(x_1, x_2, \cdots, x_k), 1 \leq k \leq n.$$

在$(X_1, X_2, \cdots, X_k)^{\top} = (x_1, x_2, \cdots, x_k)^{\top}$的条件下，$(X_{k+1}, X_{k+2}, \cdots, X_n)^{\top}$的条件密度函数为

$$\frac{f(x_1, x_2, \cdots, x_n)}{f_{X_1, X_2, \cdots, X_k}(x_1, x_2, \cdots, x_k)},$$

其中$f_{X_1, X_2, \cdots, X_k}(x_1, x_2, \cdots, x_k) > 0$. 如果是离散型随机变量，所求的是条件概率函数，只要把上述密度函数改成概率函数即可。

3.4 随机变量的独立性

多元随机变量中的各个分量之间可能相互影响，也可能没有任何影响。如果没有影响，则称它们是相互独立的，下面给出随机变量独立性的定义。

随机变量的独立：如果n元随机变量$(X_1, X_2, \cdots, X_n)^\top$的联合分布函数等于各自边缘分布函数的乘积，即

$$F(x_1, x_2, \cdots, x_n) = F_{X_1}(x_1)F_{X_2}(x_2)\cdots F_{X_n}(x_n),\ (x_1, x_2, \cdots, x_n)^\top \in \mathcal{R}^n$$

称$X_1, X_2, \cdots, X_n$相互独立，其中$F_{X_i}(x_i)$是X_i的边缘分布函数，$i = 1, 2, \cdots, n.$

离散型随机变量相互独立：如果n元离散型随机变量$(X_1, X_2, \cdots, X_n)^\top$的联合概率函数等于各自边缘概率函数的乘积，即

$$P(X_1 = x_1, X_2 = x_2, \cdots, X_n = x_n) = P(X_1 = x_1)P(X_2 = x_2)\cdots P(X_n = x_n),$$

称$X_1,\ X_2,\ \cdots,\ X_n$相互独立。

连续型随机变量相互独立：如果n元连续型随机变量$(X_1, X_2, \cdots, X_n)^\top$的联合密度函数等于各自边缘密度函数的乘积，即

$$f(x_1, x_2, \cdots, x_n) = f_{X_1}(x_1)f_{X_2}(x_2)\cdots f_{X_n}(x_n).$$

称$X_1,\ X_2,\ \cdots,\ X_n$相互独立，其中$f_{X_i}(x_i)$是X_i的边缘密度函数，$i = 1, 2, \cdots, n.$

$X_1, X_2, \cdots, X_n$相互独立是说各随机变量取值不受其它随机变量取值的影响。

定理3.1 如果随机变量$X_1, X_2, \cdots, X_n$相互独立，则其中任何一部分随机变量也相互独立；反之，仅有某一部分随机变量相互独立无法推出$X_1, X_2, \cdots, X_n$相互独立.

定理3.2 对连续型随机变量$X_1, X_2, \cdots, X_n$及任意$a_i < b_i, i = 1, 2, \cdots, n,$ 定义$A_i = \{a_i \le X_i \le b_i\}.$ 那么$X_1, X_2, \cdots, X_n$相互独立等价于$A_1, A_2, \cdots, A_n$相互独立。

证明：记$(X_1, X_2, \cdots, X_n)^\top$的联合密度函数为$f(x_1, x_2, \cdots, x_n),$ X_i的边缘密度函数为$f_{X_i}(x_i),$ $i = 1, 2, \cdots, n.$

(必要性) 对任何$\{i_1, i_2, \cdots, i_k\} \subset \{1, 2, \cdots, n\},$ 由定义，有

$$
\begin{aligned}
&P(A_{i_1}A_{i_2}\cdots A_{i_m})\\
&= P(a_{i_1}<X_{i_1}<b_{i_1}, a_{i_2}<X_{i_2}<b_{i_2},\cdots, a_{i_k}<X_{i_k}<b_{i_k})\\
&= P(a_{i_1}<X_{i_1}<b_{i_1},\cdots, a_{i_k}<X_{i_k}<b_{i_k}, -\infty<X_{i_{k+1}}<\infty,\cdots,-\infty<X_{i_n}<\infty)\\
&= \int_{-\infty}^{\infty}\cdots\int_{-\infty}^{\infty}\int_{a_{i_k}}^{b_{i_k}}\cdots\int_{a_{i_1}}^{b_{i_1}} f(x_{i_1},x_{i_2},\cdots,x_{i_n})dx_{i_1}\cdots dx_{i_k}dx_{i_{k+1}}\cdots dx_{i_n}\\
&= \int_{-\infty}^{\infty}\cdots\int_{-\infty}^{\infty}\int_{a_{i_k}}^{b_{i_k}}\cdots\int_{a_{i_1}}^{b_{i_1}} f_{X_{i_1}}(x_{i_1})\cdots f_{X_{i_n}}(x_{i_n})dx_{i_1}\cdots dx_{i_k}dx_{i_{k+1}}\cdots dx_{i_n}\\
&= \int_{-\infty}^{\infty} f_{X_{i_n}}(x_{i_n})dx_{i_n}\cdots\int_{-\infty}^{\infty} f_{X_{i_{k+1}}}(x_{i_{k+1}})dx_{i_{k+1}}\int_{a_{i_k}}^{b_{i_k}} f_{X_{i_k}}dx_{i_k}\cdots\int_{a_{i_1}}^{b_{i_1}} f_{X_{i_1}}dx_{i_1}\\
&= \int_{a_{i_k}}^{b_{i_k}} f_{X_{i_k}}dx_{i_k}\cdots\int_{a_{i_2}}^{b_{i_2}} f_{X_{i_2}}dx_{i_2}\int_{a_{i_1}}^{b_{i_1}} f_{X_{i_1}}dx_{i_1}\\
&= P(A_{i_m})\cdots P(A_{i_2})P(A_{i_1}).
\end{aligned}
$$

(充分性) 取$A_i=\{-\infty<X_i\le x_i\}, x_i\in\mathcal{R}, i=1,2,\cdots,n.$ 由

$$P(A_1A_2\cdots A_n)=P(A_1)P(A_2)\cdots P(A_n),$$

得

$$
\begin{aligned}
&\int_{-\infty}^{x_n}\cdots\int_{-\infty}^{x_2}\int_{-\infty}^{x_1} f(t_1,t_2,\cdots,t_n)dt_1dt_2\cdots dt_n\\
&\quad= \int_{-\infty}^{x_n} f_{X_n}(x_n)dx_n\cdots\int_{-\infty}^{x_2} f_{X_2}(x_2)dx_2\int_{-\infty}^{x_1} f_{X_1}(x_2)dx_1\\
&\quad= F_{X_n}(x_n)\cdots F_{X_2}(x_2)F_{X_1}(x_1).
\end{aligned}
$$

定理3.3 令连续型随机变量$(X_1,X_2,\cdots,X_n)^\top$的密度函数为$f(x_1,x_2,\cdots,x_n)$. 若存在函数$g_1(x_1),g_2(x_2),\cdots,g_n(x_n)$ 满足

$$f(x_1,x_2,\cdots,x_n)=g_1(x_1)g_2(x_2)\cdots g_n(x_n)$$

则$X_1,X_2,\cdots,X_n$相互独立，且X_i的边缘密度函数$f_{X_i}(x_i)$与$g_i(x_i)$相差一个常数因子。

证明： X_1的密度函数为

$$
\begin{aligned}
f_{X_1}(x_1) &= \int_{-\infty}^{\infty}\cdots\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} f(x_1,x_2,\cdots,x_n)dx_2dx_3\cdots dx_n\\
&= g_1(x_1)\int_{-\infty}^{\infty} g_2(x_2)dx_2\int_{-\infty}^{\infty} g_3(x_3)dx_3\cdots\int_{-\infty}^{\infty} g_n(x_n)dx_n\\
&= c_1g_1(x_1).
\end{aligned}
$$

其中$c_1=\int_{-\infty}^{\infty} g_2(x_2)dx_2\int_{-\infty}^{\infty} g_3(x_3)dx_3\cdots\int_{-\infty}^{\infty} g_n(x_n)dx_n.$

同理有$f_{X_i}(x_i)=c_ig_i(x_i), i=2,3,\cdots,n.$ 因此，

$$f(x_1,x_2,\cdots,x_n)=\frac{1}{c_1c_2\cdots c_n}f_{X_1}(x_1)f_{X_2}(x_2)\cdots f_{X_n}(x_n)$$

两边对$x_1, x_2, \cdots, x_n$求全空间的积分可得$c_1 c_2 \cdots c_n = 1$. 即

$$f(x_1, x_2, \cdots, x_n) = f_{X_1}(x_1) f_{X_2}(x_2) \cdots f_{X_n}(x_n).$$

定理3.4 令随机变量$X_1, X_2, \cdots, X_n$相互独立。对$1 \leq m \leq n-1$, 记$Y_1 = g_1(X_1, X_2, \cdots, X_m)$, $Y_2 = g_2(X_{m+1}, X_{m+2}, \cdots, X_n)$. 则$Y_1, Y_2$相互独立。

证明： 记$(X_1, X_2, \cdots X_n)^\top$的联合密度函数为$f(x_1, x_2, \cdots, x_n)$, X_i的边缘密度函数为$f_{X_i}(x_i)$, $i = 1, 2, \cdots, n$, $(Y_1, Y_2)^\top$的联合分布函数为$F_{Y_1,Y_2}(y_1, y_2)$, Y_1的边缘分布函数为$F_{Y_1}(y_1)$, Y_2 的边缘分布函数为$F_{Y_2}(y_2)$.
对任意y_1, y_2,

$$Y_1 \in (-\infty, y_1] \Longleftrightarrow (X_1, X_2, \cdots, X_m) \in \mathcal{B}_{y_1}$$

$$Y_2 \in (-\infty, y_2] \Longleftrightarrow (X_{m+1}, X_{m+2}, \cdots, X_n) \in \mathcal{C}_{y_2},$$

其中$\mathcal{B}_{y_1}$是满足$Y_1 \in (-\infty, y_1]$成立对应的$(X_1, X_2, \cdots, X_m)$ 的取值空间集合, $\mathcal{C}_{y_2}$是满足$Y_2 \in (-\infty, y_2]$成立对应的$(X_{m+1}, X_{m+2}, \cdots, X_n)$的取值空间集合。因此，

$$\begin{aligned} F_{Y_1,Y_2}(y_1, y_2) &= \int \cdots \int_{\mathcal{B}_{y_1}} \int \cdots \int_{\mathcal{C}_{y_2}} f(x_1, x_2, \cdots, x_n) dx_1 d_2, \cdots, dx_n \\ &= \int \cdots \int_{\mathcal{B}_{y_1}} f_{X_1}(x_1) \cdots f_{X_m}(x_m) dx_1 \cdots dx_m \\ &\quad \times \int \cdots \int_{\mathcal{C}_{y_2}} f_{X_{m+1}}(x_{m+1}) \cdots f_{X_n}(x_n) dx_{m+1} \cdots dx_n \\ &= F_{Y_1}(y_1) F_{Y_2}(y_2). \end{aligned}$$

定理3.5 对n个事件$A_1, A_2, \cdots, A_n$, 定义$X_i = I_{A_i}$, $i = 1, 2, \cdots, n$. 那么

$$A_1, A_2, \cdots, A_n \text{相互独立} \Longleftrightarrow X_1, X_2, \cdots, X_n \text{相互独立。}$$

证明：(必要性) 记

$$B_i = \begin{cases} A_i, & X_i = 1, \\ \bar{A}_i, & X_i = 0. \end{cases}$$

由第一章定理1.5知，$B_1, B_2, \cdots, B_n$ 相互独立。对

$$\forall x_i \in \{0, 1\}, i = 1, 2, \cdots, n,$$

有

$$\begin{aligned} P(X_1 = x_1, X_2 = x_2, \cdots, X_n = x_n) &= P(B_1 B_2 \cdots B_n) \\ &= P(B_1) P(B_2) \cdots P(B_n) \\ &= P(X_1 = x_1) P(X_2 = x_2) \cdots P(X_n = x_n). \end{aligned}$$

因此，$X_1, X_2, \cdots, X_n$相互独立.

(充分性) 由$X_1, X_2, \cdots, X_n$相互独立，则其中一个部分也相互独立. 对

$$\forall\{i_1, i_2, ..., i_k\} \subset \{1, 2, ..., n\},$$

有

$$\begin{aligned} P(A_{i_1}A_{i_2}\cdots A_{i_k}) &= P(X_{i_1} = 1, X_{i_2} = 1, \cdots, X_{i_k} = 1) \\ &= P(X_{i_1} = 1)P(X_{i_2} = 1)\cdots P(X_{i_k} = 1) \\ &= P(A_{i_1})P(A_{i_2})\cdots P(A_{i_k}). \end{aligned}$$

从而$A_1, A_2, \cdots, A_n$相互独立。

例3.11 令X, Y相互独立，都服从-1和1的两点分布，即

$$P(X = 1) = P(X = -1) = 0.5,$$

$$P(Y = 1) = P(Y = -1) = 0.5.$$

记$Z = XY$. 求证：X, Y, Z两两独立但不相互独立。

证明： 由题意知

$$P(Z = -1) = P(Z = 1) = 0.5,$$

$$P(X = 1, Z = 1) = P(X = 1, XY = 1) = P(X = 1, Y = 1) = \frac{1}{4} = P(X = 1)P(Z = 1).$$

类似地，

$$P(X = 1, Z = -1) = \frac{1}{4} = P(X = 1)P(Z = -1),$$

$$P(X = -1, Z = 1) = \frac{1}{4} = P(X = -1)P(Z = 1),$$

$$P(X = -1, Z = -1) = \frac{1}{4} = P(X = -1)P(Z = -1).$$

因此X与Z相互独立。同理，Y与Z相互独立。而

$$P(X = 1, Y = -1, Z = 1) = 0 \neq P(X = 1)P(Y = -1)P(Z = 1).$$

例3.12 令$(X_1, X_2, \cdots, X_n)^\top \sim Mul(N, p_1, p_2, \cdots, p_n)$. 对任意$u$和$v$, X_u和X_v不独立.

证明：

$$P(X_u = 0, X_v = 0) = (1 - p_u - p_v)^N,$$

$$P(X_u = 0)P(X_v = 0) = (1 - p_u - p_v + p_u p_v)^N.$$

显然有

$$P(X_u = 0, X_v = 0) \neq P(X_u = 0)P(X_v = 0).$$

例3.13 令$(X_1, X_2)^\top \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$. 则$X_1$与$X_2$相互独立的充要条件是$\rho = 0$.

证明：由$(X_1, X_2)^\top \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$，则$(X, Y)^\top$的联合密度函数为

$f(x_1, x_2) =$

$$\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left\{-\frac{1}{2(1-\rho^2)}\left[\frac{(x_1-\mu_1)^2}{\sigma_1^2} - \frac{2\rho(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2}\right]\right\}.$$

X和Y的边缘密度函数分别为：

$$f_{X_1}(x_1) = \frac{1}{\sqrt{2\pi}\sigma_1} \exp\left\{-\frac{(x_1-\mu_1)^2}{2\sigma_1^2}\right\},$$

$$f_{X_2}(x_2) = \frac{1}{\sqrt{2\pi}\sigma_2} \exp\left\{-\frac{(x_1-\mu_2)^2}{2\sigma_2^2}\right\}.$$

一方面，当$\rho = 0$时，有$f(x_1, x_2) = f_{X_1}(x_1) f_{X_2}(x_2)$，则$X_1, X_2$ 相互独立；另一方面，当X_1, X_2相互独立时，$f(x_1, x_2) = f_{X_1}(x_1) f_{X_2}(x_2)$，等式两边对应的函数相等，解得$\rho = 0$.

3.5 多元随机变量的函数的概率分布

在理论和应用中，我们经常会遇到已知某个或者某些随机变量X_1,X_2,$\cdots$,X_n的概率分布，需要去求另外一些随机变量$Y_1 = g_1(X_1, \cdots, X_n), Y_2 = g_2(X_1, \cdots, X_n), \cdots, Y_n = g_n(X_1, \cdots, X_n)$的概率分布。这在后面的假设检验中求统计量的分布经常碰到。下面分离散型和连续型随机变量介绍。

3.5.1 多元离散型随机变量的函数的概率分布

令$(X_1, X_2, \cdots, X_n)^\top$为$n$元离散型随机变量，$X_i$可能取值为$a_{i1}, a_{i2}, \cdots, a_{im_i}$, $i = 1, 2, \cdots, n$. 记$g(\cdot)$为n元函数，那么$Y = g(X_1, X_2, \cdots, X_n)$是一元离散型随机变量, 其可能的取值记为$y_1, y_2, \cdots, y_m$. 那么$Y$的概率函数为

$$\begin{aligned} P(Y = y_j) &= P\big(g(X_1, X_2, \cdots, X_n) = y_j\big) \\ &= \sum_{\substack{g(a_{1r_1}, a_{2r_2}, \cdots, a_{nr_n}) = y_j \\ 1 \le r_i \le m_i, i = 1, 2, \cdots, n}} P(X_1 = a_{1r_1}, X_2 = a_{2r_2}, \cdots, X_n = a_{nr_n}). \end{aligned}$$

例3.14 令$(X_1, X_2, \cdots, X_n)^\top \sim Mul(N, p_1, p_2, \cdots, p_n), n \ge 3$. 求证：

$$Y = X_1 + X_2 \sim B(N, p_1 + p_2).$$

证明：

$$\begin{aligned} P(Y = k) &= P(X_1 + X_2 = k) \\ &= \sum_{i=0}^{k} P(X_1 = i, X_2 = k - i) \\ &= \sum_{i=0}^{k} \frac{N!}{i!(k-i)!(N-k)!} p_1^i p_2^{k-i} (1 - p_1 - p_2)^{N-k} \\ &= \sum_{i=0}^{k} \frac{k!}{i!(k-i)!} p_1^i p_2^{k-i} \frac{N!}{k!(N-k)!} (1 - p_1 - p_2)^{N-k} \\ &= (p_1 + p_2)^k \frac{N!}{k!(N-k)!} (1 - p_1 - p_2)^{N-k}. \end{aligned}$$

因此，$Y \sim B(N, p_1 + p_2)$.

例3.15 (二项分布的再生性) 令$X_1 \sim B(n, p), X_2 \sim B(m, p)$且$X_1, X_2$相互独立，则$X_1 + X_2 \sim B(n + m, p)$.

证明：

$$\begin{aligned}
P(X_1+X_2=k) &= \sum_{i=0}^{k} P(X_1=i, X_2=k-i) \\
&= \sum_{i=0}^{k} P(X_1=i)P(X_2=k-i) \\
&= \sum_{i=0}^{k} \tbinom{n}{i}p^i(1-p)^{n-i}\tbinom{m}{k-i}p^{k-i}(1-p)^{m-k+i} \\
&= p^k(1-p)^{m+n-k}\sum_{i=0}^{k}\tbinom{n}{i}\tbinom{m}{k-i} \\
&= \tbinom{m+n}{k}p^k(1-p)^{m+n-k},
\end{aligned}$$

其中$0 \le k \le m+n$, 上面倒数第二个等式用到超几何分布概率函数求和等于1，即

$$\sum_{i=0}^{k}\frac{\tbinom{n}{i}\tbinom{m}{k-i}}{\tbinom{m+n}{k}} = 1.$$

因此，$X_1+X_2 \sim B(m+n,p)$.

令$X_i \sim B(n_i,p), i=1,2,\cdots,k$, 且$X_1,X_2,\cdots,X_k$相互独立。则

$$\sum_{i=1}^{k} X_i \sim B\left(\sum_{i=1}^{k} n_i, p\right).$$

特别地，$X_1,X_2,\cdots,X_n$**独立同分布**(independent and identically distributed, 简记为iid) 都服从分布$B(1,p)$，常简写为

$$X_1,X_2,\cdots,X_n \; iid \sim B(1,p).$$

则

$$\sum_{i=1}^{n} X_i \sim B(n,p).$$

例3.16 (Poisson分布的再生性) 令$X_1 \sim Poisson(\lambda_1)$, $X_2 \sim Poisson(\lambda_2)$, 且$X_1,X_2$相互独立。求证：$X_1+X_2 \sim Poisson(\lambda_1+\lambda_2)$.

证明：

$$\begin{aligned}
P(X_1+X_2=k) &= \sum_{i=0}^{k} P(X_1=i, X_2=k-i) \\
&= \sum_{i=0}^{k} \frac{\lambda_1^i e^{-\lambda_1}}{i!}\frac{\lambda_2^{k-i}e^{-\lambda_2}}{(k-i)!} \\
&= \frac{e^{-(\lambda_1+\lambda_2)}}{k!}\sum_{i=0}^{k}\frac{k!\lambda_1^i\lambda_2^{k-i}}{i!(k-i)!} \\
&= \frac{e^{-(\lambda_1+\lambda_2)}}{k!}(\lambda_1+\lambda_2)^n.
\end{aligned}$$

一般地，令$X_i \sim Poisson(\lambda_i), i = 1, 2, \cdots, n$, $X_1, X_2, \cdots, X_n$ 相互独立。则有

$$X_1 + X_2 + \cdots + X_n \sim Poisson\left(\lambda_1 + \lambda_2 + \cdots + \lambda_n\right).$$

例3.17 令$X_1, X_2, \cdots, X_r \, iid \sim Geo(p)$. 求证：$X_1+X_2+\cdots+X_r \sim NB(r, p)$. 换言之，若干个独立同分布服从几何分布的随机变量之和服从负二项分布。

证明：利用数学归纳法证明。当$r = 2$时，

$$\begin{aligned} P(X_1 + X_2 = k) &= \sum_{i=1}^{k-1} P(X_1 = i, X_2 = k - i) \\ &= \sum_{i=1}^{k-1} (1-p)^{i-1} p (1-p)^{k-i-1} p \\ &= (k-1)(1-p)^{k-2} p^2. \end{aligned}$$

可见$X_1 + X_2 \sim NB(2, p)$.

假设$r = m$, $Y = X_1 + X_2 + \cdots + X_m \sim NB(m, p)$. 当$r = m + 1$ 时，有

$$\begin{aligned} P(X_1 + X_2 + \cdots + X_{m+1} = k) &= \sum_{i=1}^{m-1} P(Y = i, X_{m+1} = k - i) \\ &= \sum_{i=1}^{k-1} \tbinom{i-1}{m-1} (1-p)^{i-m} p^{m-1} p (1-p)^{k-i-1} p \\ &= (1-p)^{k-m-1} p^{m+1} \sum_{i=1}^{k-1} \tbinom{i-1}{m-1} \\ &= (1-p)^{k-m-1} p^{m+1} \tbinom{k-1}{m}, \end{aligned}$$

即$X_1 + X_2 + \cdots + X_{m+1} \sim NB(m + 1, p)$, 由数学归纳法得证。

3.5.2 多元连续型随机变量的函数的概率分布

令n元连续型随机变量$(X_1, X_2, \cdots, X_n)^\top \sim f(x_1, x_2, \cdots, x_n)$. 假设存在$n$个$n$元函数$y_j = \xi_j(x_1, x_2, \cdots, x_n), j = 1, 2, \cdots, n$, 使得

$$Y_j = \xi_j(X_1, X_2, \cdots, X_n), j = 1, 2, \cdots, n.$$

如果$(X_1, X_2, \cdots, X_n)^\top$与$(Y_1, Y_2, \cdots, Y_n)^\top$一一对应，反函数为

$$X_i = \eta_i(Y_1, Y_2, \cdots, Y_n),$$

且$\eta_i(y_1, y_2, \cdots, y_n)$有一阶连续偏导数，$i = 1, 2, \cdots, n$. 那么$(Y_1, Y_2, \cdots, Y_n)^\top$是连续型随机变量且具有联合密度函数

$$g(y_1, y_2, \cdots, y_n) = \begin{cases} f\Big(\eta_1(y_1, \cdots, y_n), \cdots, \eta_n(y_1, \cdots, y_n)\Big)|J|, & (y_1, \cdots, y_n) \in \mathcal{D}, \\ 0, & (y_1, \cdots, y_n) \notin \mathcal{D}, \end{cases}$$

其中$\mathcal{D}$是随机变量$(Y_1, Y_2, \cdots, Y_n)^\top$的所有可能值得集合. J是变换的Jaccobi行列式，即

$$J = \det \begin{pmatrix} \frac{\partial \eta_1}{\partial y_1} & \frac{\partial \eta_1}{\partial y_2} & \cdots & \frac{\partial \eta_1}{\partial y_n} \\ \frac{\partial \eta_2}{\partial y_1} & \frac{\partial \eta_2}{\partial y_2} & \cdots & \frac{\partial \eta_2}{\partial y_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial \eta_n}{\partial y_1} & \frac{\partial \eta_n}{\partial y_2} & \cdots & \frac{\partial \eta_n}{\partial y_n} \end{pmatrix}.$$

例3.18 令随机变量X, Y $iid \sim N(0,1)$. 对$(X,Y)^\top$进行变换：

$$\begin{cases} X = \Delta \cos \Theta, \\ Y = \Delta \sin \Theta. \end{cases}$$

求$(\Delta, \Theta)^\top$的分布。

解： 由题意知，变换

$$\begin{cases} x = \delta \cos \theta, \\ y = \delta \sin \theta, \end{cases}$$

是$(0,\infty) \times [0, 2\pi)$与$\mathcal{R}^2$(原点除外)的一一变换，变换的Jaccobi行列式为:

$$J = \det \begin{pmatrix} \frac{\partial x}{\partial \delta} & \frac{\partial x}{\partial \theta} \\ \frac{\partial y}{\partial \delta} & \frac{\partial y}{\partial \theta} \end{pmatrix} = \det \begin{pmatrix} \cos\theta & -\delta \sin\theta \\ \sin\theta & \delta \cos\theta \end{pmatrix} = \delta.$$

由$(X,Y)^\top$的联合密度函数为

$$f(x,y) = \frac{1}{\sqrt{2\pi}} \exp\Big(-\frac{x^2}{2}\Big) \frac{1}{\sqrt{2\pi}} \exp\Big(-\frac{y^2}{2}\Big) = \frac{1}{2\pi} \exp\Big(-\frac{x^2+y^2}{2}\Big).$$

知$(\Delta, \Theta)^\top$的联合密度函数为

$$g(\delta, \theta) = \frac{1}{2\pi} \delta \exp\left\{-\frac{\delta^2}{2}\right\}.$$

记

$$g_\Delta(\delta) = \delta \exp\left\{-\frac{\delta^2}{2}\right\}, \delta > 0, \; g_\Theta(\theta) = \frac{1}{2\pi}, \theta \in [0, 2\pi).$$

显然

$$g(\delta, \theta) = g_\Delta(\delta) g_\Theta(\theta).$$

由定理3.3知，Δ和Θ相互独立。

称$\Delta = \sqrt{X^2 + Y^2}$的分布为**Rayleigh分布**(Rayleigh,1842-1919)，密度函数为

$$g_\Delta(\delta) = \delta \exp\left\{-\frac{\delta^2}{2}\right\}, \delta > 0.$$

利用上述介绍的变换法求多元连续型随机变量$(X_1, X_2, \cdots, X_n)^\top$的函数的密度，需要构造$n$个一一对应的函数$Y_1, Y_2, \cdots, Y_n$, 进而求出$(Y_1, Y_2, \cdots, Y_n)^\top$的

联合密度。而有时只要求计算某个边缘密度，以二元为例，已知$(X_1, X_2)^\top \sim f(x_1, x_2)$, 目标是求$Y = g_1(X_1, X_2)$ 的密度函数。一般需要增补一个变量$Z = g_2(X_1, X_2)$, 求出$(Y, Z)^\top$的联合密度函数，再求出Y的边缘密度函数，称上述过程为增补变量法。

定理3.6 (和的密度) 令$(X_1, X_2)^\top \sim f(x_1, x_2)$. 则$Y = X_1 + X_2$的密度函数为$g(y)$为

$$g(y) = \int_{-\infty}^{\infty} f(x_1, y - x_1)dx_1 = \int_{-\infty}^{\infty} f(y - x_2, x_2)dx_2.$$

证明：利用增补变量的方法，记

$$\begin{cases} Y = X_1 + X_2, \\ Z = X_2. \end{cases}$$

利用上面变换公式，可以得到$(Y, Z)^\top$的联合密度函数为

$$f_{Y,Z}(y, z) = f(y - z, z),$$

把$f_{Y,Z}(y, z)$关于z在$\mathcal{R}$ 上积分，可得Y的密度函数

$$\int_{-\infty}^{\infty} f_{Y,Z}(y, z)dz = \int_{-\infty}^{\infty} f(y - z, z)dz.$$

定理3.7 (卷积公式) 令$X \sim f_X(x)$, $Y \sim f_Y(y)$且X, Y相互独立。则$Z = X + Y$的密度函数为

$$g(z) = \int_{-\infty}^{\infty} f_X(x) f_Y(z - x)dx = \int_{-\infty}^{\infty} f_X(z - y) f_Y(y)dy$$

例3.19 令二元随机变量$(X_1, X_2)^\top \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$. 则

$$Y = X_1 + X_2 \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2 + 2\rho\sigma_1\sigma_2).$$

证明：方法一：利用和的密度公式。$(X_1, X_2)^\top$的联合密度函数为
$f(x_1, x_2) =$

$$\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left\{-\frac{1}{2(1-\rho^2)}\left[\frac{(x_1-\mu_1)^2}{\sigma_1^2} - \frac{2\rho(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2}\right]\right\},$$

$Y = X_1 + X_2$的密度函数为$g_Y(y) = \int_{-\infty}^{+\infty} f(x, y - x)dx$.
记

$$A = \frac{\sqrt{\sigma_1^2 + 2\rho\sigma_1\sigma_2 + \sigma_2^2}}{\sigma_1\sigma_2},$$

$$B = \frac{(\mu_2 - y)\sigma_1^2 + \rho(\mu_2 - \mu_1 - y)\sigma_1\sigma_2 - \mu_1\sigma_2^2}{\sigma_1\sigma_2\sqrt{\sigma_1^2 + 2\rho\sigma_1\sigma_2 + \sigma_2^2}},$$

$$C = \frac{(1-\rho^2)(y - \mu_1 - \mu_2)^2}{\sigma_1^2 + 2\rho\sigma_1\sigma_2 + \sigma_2^2}.$$

有

$$\frac{(x-\mu_1)^2}{\sigma_1^2}-\frac{2\rho(x-\mu_1)(y-x-\mu_2)}{\sigma_1\sigma_2}+\frac{(y-x-\mu_2)^2}{\sigma_2^2}=(Ax+B)^2+C$$

$$\begin{aligned}
g_Y(y)&=\int_{-\infty}^{+\infty}f(x,y-x)dx\\
&=\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}\int_{-\infty}^{+\infty}\exp\left\{-\frac{1}{2(1-\rho^2)}\left[(Ax+B)^2+C\right]\right\}dx\\
&=\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}\exp\left\{-\frac{C}{2(1-\rho^2)}\right\}\int_{-\infty}^{+\infty}\exp\left\{-\frac{1}{2}\left(\frac{A}{\sqrt{1-\rho^2}}x+\frac{B}{\sqrt{1-\rho^2}}\right)^2\right\}dx\\
&=\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}\exp\left\{-\frac{C}{2(1-\rho^2)}\right\}\frac{\sqrt{1-\rho^2}}{A}\int_{-\infty}^{+\infty}\exp(-\frac{t^2}{2})dt\\
&=\frac{1}{\sqrt{2\pi}\sqrt{\sigma_1^2+2\rho\sigma_1\sigma_2+\sigma_2^2}}\exp\left\{-\frac{(y-\mu_1-\mu_2)^2}{2(\sigma_1^2+2\rho\sigma_1\sigma_2+\sigma_2^2)}\right\}.
\end{aligned}$$

因此，$Y=X_1+X_2\sim N(\mu_1+\mu_2,\sigma_1^2+2\rho\sigma_1\sigma_2+\sigma_2^2)$.

也可以利用增补变量的方法，读者可以自行验证。特别地，如果$\rho=0$, 即X_1与X_2相互独立，

$$Y=X_1+X_2\sim N(\mu_1+\mu_2,\sigma_1^2+\sigma_2^2).$$

一般化，令$X_i\sim N(\mu_i,\sigma_i^2), i=1,2,\cdots,n$, $X_1,X_2,\cdots,X_n$相互独立. $a_1,a_2,\cdots,a_n,b$ 为任意$n+1$个实数，其中$a_1,a_2,\cdots,a_n$ 不全为0. 记$X=\sum\limits_{i=1}^{n}a_iX_i+b$, 则

$$X\sim N\left(\sum_{i=1}^{n}a_i\mu_i+b,\sum_{i=1}^{n}a_i^2\sigma_i^2\right).$$

例3.20 (Gamma分布的再生性) 令随机变量$X\sim Gamma(\alpha,\lambda)$, $Y\sim Gamma(\beta,\lambda)$, 且$X,Y$相互独立。则$X+Y\sim Gamma(\alpha+\beta,\lambda)$.

证明： 记$Z=X+Y$的密度函数为$f(z)$, 显然$f(z)=0, z\le 0$. 当$z>0$ 时，

$$\begin{aligned}
f(z)&=\frac{\lambda^{\alpha+\beta}}{\Gamma(\alpha)\Gamma(\beta)}\int_0^z(z-y)^{\alpha-1}e^{-\lambda(z-y)}y^{\beta-1}e^{-\lambda y}dy\\
&=\frac{\lambda^{\alpha+\beta}e^{-\lambda z}}{\Gamma(\alpha)\Gamma(\beta)}\int_0^z(z-y)^{\alpha-1}y^{\beta-1}dy\\
&=\frac{\lambda^{\alpha+\beta}e^{-\lambda z}z^{\alpha+\beta-1}}{\Gamma(\alpha)\Gamma(\beta)}\int_0^1(1-x)^{\alpha-1}x^{\beta-1}dx\\
&=\frac{\lambda^{\alpha+\beta}e^{-\lambda z}z^{\alpha+\beta-1}}{\Gamma(\alpha+\beta)}.
\end{aligned}$$

令$X_1,X_2,\cdots,X_n$独立同分布服从$Exp(\lambda)$. 由于$Gamma(1,\lambda)=Exp(\lambda)$, 因此

$$X_1+X_2+\cdots+X_n\sim Gamma(n,\lambda).$$

例3.21 (Cauchy分布的再生性) 令$X \sim Cauchy(0,1), Y \sim Cauchy(0,1)$, 且$X, Y$相互独立。则

$$X + Y \sim Cauchy(0, 2).$$

证明： 由题意知$Z = X + Y$的密度函数为

$$\begin{aligned} f_Z(z) &= \int_{-\infty}^{\infty} f_X(x) f_Y(z-x) dx \\ &= \frac{1}{\pi^2} \int_{-\infty}^{\infty} \frac{1}{\left[1+x^2)(1+(z-x)^2)\right]} dx \\ &= \frac{1}{\pi^2} \int_{-\infty}^{\infty} \frac{1}{z^2(z^2+4)} \Big[\frac{2zx+z^2}{1+x^2} + \frac{3z^2-2zx}{1+(z-x)^2} \Big] dx \\ &= \frac{1}{\pi^2 z^2(z^2+4)} \int_{-\infty}^{\infty} \frac{2zx+z^2}{1+x^2} dx + \frac{1}{\pi^2 z^2(z^2+4)} \int_{-\infty}^{\infty} \frac{3z^2-2zx}{1+(z-x)^2} dx. \end{aligned}$$

下面计算上式的右边的积分。

$$\begin{aligned} \int_{-\infty}^{\infty} \frac{2zx+z^2}{1+x^2} dx &= \int_{-\infty}^{+\infty} z \frac{d(x^2+1)}{x^2+1} + \int_{-\infty}^{\infty} z^2 \frac{1}{x^2+1} dx \\ &= 0 + z^2 \arctan x |_{-\infty}^{+\infty} \\ &= \pi z^2, \\ \int_{-\infty}^{+\infty} \tfrac{3u^2-2zx}{1+(z-x)^2} dx &= \int_{-\infty}^{\infty} \frac{u^2-2ut}{1+t^2} dt \ (\text{令} x - z = t) \\ &= -\int_{-\infty}^{\infty} 2z \frac{t}{t^2+1} dt + \int_{-\infty}^{\infty} z^2 \frac{1}{t^2+1} dt \\ &= 0 + u^2 \arctan t |_{-\infty}^{\infty} \\ &= \pi u^2. \end{aligned}$$

从而

$$f_Z(z) = \frac{1}{\pi^2} \frac{1}{z^2(z^2+4)} (\pi z^2 + \pi z^2) = \frac{2}{\pi \cdot (2^2+u^2)}.$$

因此，$Z = X + Y \sim Cauchy(0, 2)$.

令$X_1, X_2, \cdots, X_n$独立同分布服从$Cauchy(0,1)$，记$w_i > 0, i = 1, 2, \cdots, n$且$\sum_{i=1}^{n} w_i = 1$. 则

$$\sum_{i=1}^{n} w_i X_i \sim Cauchy(0, 1).$$

定理3.8 (商的密度) 令二元连续型随机变量$(X, Y)^\top \sim f(x, y)$. 则$Z = X/Y$的密度函数为

$$g(z) = \int_{-\infty}^{\infty} |u| f(zu, u) du.$$

证明：

$$\begin{aligned} P(Z \le z) &= P(X/Y \le z) \\ &= P(X \le Yz, Y > 0) + P(X > Yz, Y < 0) \\ &= \int_0^{\infty} \int_{-\infty}^{yz} f(x,y)dxdy + \int_{-\infty}^{0} \int_{yz}^{\infty} f(x,y)dxdy. \end{aligned}$$

两边对z求导，得

$$\begin{aligned} g(z) &= \int_0^{\infty} yf(yz,y)dy + \int_{-\infty}^{0}(-y)f(yz,y)dy \\ &= \int_{-\infty}^{\infty} |y|f(yz,y)dy. \end{aligned}$$

例3.22 令$X \sim N(0,1)$, $Y \sim N(0,1)$, 且X与Y相互独立。则

$$\frac{X}{Y} \sim Cauchy(0,1).$$

证明： 记$Z = \frac{X}{Y}$, X, Y的密度函数分别为$f_X(x), f_Y(y)$. 那么，$Z = \frac{X}{Y}$的密度函数为

$$\begin{aligned} f_Z(z) &= \int_{-\infty}^{\infty} |u| f_X(zu) f_Y(u)\, du \\ &= \int_{-\infty}^{\infty} \frac{1}{2\pi} |u| \exp\left(-\frac{(zu)^2}{2} \right) \exp\left(-\frac{u^2}{2} \right) du \\ &= \frac{1}{2\pi} 2 \int_0^{\infty} u \exp\left(-\frac{z^2+1}{2} u^2 \right) du \quad (\text{令} t = u\sqrt{z^2+1}) \\ &= \frac{1}{\pi} \int_0^{\infty} \frac{t}{\sqrt{z^2+1}} \exp\left(-\frac{1}{2}t^2 \right) \frac{1}{\sqrt{z^2+1}}\, dt \\ &= \frac{1}{\pi(z^2+1)} \int_0^{\infty} t \exp\left(-\frac{1}{2}t^2 \right) dt \\ &= \frac{1}{\pi(z^2+1)} \int_0^{\infty} (-1) d\left(e^{-t^2/2}\right) \\ &= \frac{1}{\pi(z^2+1)}. \end{aligned}$$

因此

$$Z = \frac{X}{Y} \sim Cauchy(0,1).$$

例3.23 令$X \sim Exp(1/2), Y \sim U(0,1)$, 且$X, Y$相互独立。求$X - Y$的密度函数和$P(X/Y \le 1)$.

解： 由题意知$-Y \sim U(-1,0)$. 记X和$-Y$ 的密度函数分别为$f_X(x)$ 和$f_{-Y}(y)$,

$$f_X(x) = \frac{1}{2} e^{-x/2}, x > 0, \;\; f_{-Y}(y) = 1, y \in [-1,0].$$

由卷积公式，

$$f_{X-Y}(z) = \int_{-\infty}^{\infty} f_X(x) f_{-Y}(z-x)dx = \int_0^{\infty} f_X(x) f_{-Y}(z-x)dx, z \in [-1,\infty).$$

根据$z-x\in[-1,0]$知$z\leq x\leq z+1$. 下面划分$x>0$的区域来计算$f_{X-Y}(z)$
(1)当$-1\leq z\leq 0$知$0<x\leq z+1$, 有

$$f_{X-Y}(z)=\int_0^{z+1}\frac{1}{2}e^{-x/2}dx=1-e^{-\frac{z+1}{2}}$$

(2)当$z>0$知$z<x\leq z+1$, 有

$$f_{X-Y}(z)=\int_z^{z+1}\frac{1}{2}e^{-x/2}dx=e^{-\frac{z}{2}}-e^{-\frac{z+1}{2}}$$

因此，

$$f_{X-Y}(z)=\begin{cases}\left(e^{-\frac{z}{2}}-e^{-\frac{z+1}{2}}\right), & z>0,\\ 1-e^{-\frac{z+1}{2}}, & -1\leq z\leq 0,\end{cases}$$

$$P(X\leq Y)=P(X-Y\leq 0)=2e^{-\frac{1}{2}}-1.$$

3.6 多元正态分布

前面介绍了多元正态分布，它是常见的多元连续型分布，在概率论与数理统计中占有重要的地位。本节主要对多元正态分布及其性质进行详细介绍。

根据3.1节的符号，多元正态分布$N(\boldsymbol{\mu}, \boldsymbol{\Delta})$的密度函数为

$$f(x_1, x_2, \cdots, x_n) = \frac{1}{(2\pi)^{n/2}\det(\boldsymbol{\Delta})^{1/2}} \exp\left\{-\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu})^\top \boldsymbol{\Delta}^{-1}(\boldsymbol{x}-\boldsymbol{\mu})\right\},$$

其中$\boldsymbol{x} = (x_1, x_2, \cdots, x_n)^\top \in \mathcal{R}^n$, $\boldsymbol{\mu} = (\mu_1, \mu_2, \cdots, \mu_n)^\top$是一$n$元实值向量，$\boldsymbol{\Delta}$是$n$阶正定对称的矩阵，$\det(\boldsymbol{\Delta})$和$\boldsymbol{\Delta}^{-1}$分别为$\boldsymbol{\Delta}$的行列式和逆。

多元正态分布的性质

性质1 令$X \sim N(\boldsymbol{\mu}, \boldsymbol{\Delta})$. 则$\boldsymbol{\Delta}^{-\frac{1}{2}}(X-\boldsymbol{\mu}) \sim N(\mathbf{0}_n, \mathbf{I}_n)$, 其中$\mathbf{0}_n$是$n$维所有元素都是0的列向量，$\mathbf{I}_n$是$n \times n$的单位阵。

证明： 记$Y = \boldsymbol{\Delta}^{-\frac{1}{2}}(X-\boldsymbol{\mu})$, 得$X = \boldsymbol{\Delta}^{\frac{1}{2}}Y + \boldsymbol{\mu}$. Jaccobi行列式为

$$J = \det\left(\frac{\partial X}{\partial Y}\right) = \det\left(\boldsymbol{\Delta}^{\frac{1}{2}}\right) = \det(\boldsymbol{\Delta})^{\frac{1}{2}}.$$

于是Y的密度函数为

$$g(y) = f\left(\boldsymbol{\Delta}^{\frac{1}{2}}y + \boldsymbol{\mu}\right)|J| = \prod_{i=1}^{n}\frac{1}{\sqrt{2\pi}}e^{-\frac{y_i^2}{2}}, y = (y_1, \cdots, y_n)^\top.$$

再利用3.5.2节的转换公式即得。

性质2 令$X \sim N(\boldsymbol{\mu}, \boldsymbol{\Delta})$, $\mathbf{A}$为$m \times n$非随机矩阵, $\mathrm{rk}(\mathbf{A}) = m$, $m \leq n$, $\mathbf{b}$为$m \times 1$非随机向量，其中$\mathrm{rk}(\cdot)$表示矩阵的秩。则

$$Y = \mathbf{A}X + \mathbf{b} \sim N(\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{A}\boldsymbol{\Delta}\mathbf{A}^\top).$$

性质3 令$X \sim N(\boldsymbol{\mu}, \boldsymbol{\Delta})$. 作矩阵分块，记

$$\boldsymbol{\Delta} = \begin{pmatrix} \boldsymbol{\Delta}_{11} & \boldsymbol{\Delta}_{12} \\ \boldsymbol{\Delta}_{21} & \boldsymbol{\Delta}_{22} \end{pmatrix}, X = \begin{pmatrix} \widetilde{X}_1 \\ \widetilde{X}_2 \end{pmatrix}, \tilde{\boldsymbol{\mu}} = \begin{pmatrix} \tilde{\boldsymbol{\mu}}_1 \\ \tilde{\boldsymbol{\mu}}_2 \end{pmatrix}.$$

则

$$\widetilde{X}_1 \sim N(\tilde{\boldsymbol{\mu}}_1, \boldsymbol{\Delta}_{11}), \widetilde{X}_2 \sim N(\tilde{\boldsymbol{\mu}}_2, \boldsymbol{\Delta}_{22}).$$

进一步假定$\boldsymbol{\Delta}_{12} = \mathbf{O}_{m\times n}$, 其中$m$为$\widetilde{X}_1$的维数，$\mathbf{O}_{m\times n}$是$m \times n$所有元素都是0的矩阵。则$\widetilde{X}_1$与$\widetilde{X}_2$相互独立。

性质4 令$X \sim N(\boldsymbol{\mu}, \sigma^2\mathbf{I}_n)$, $\boldsymbol{\mu} = (\mu_1, \mu_2, \cdots, \mu_n)^\top$. 则

$$X_i \sim N(\mu_i, \sigma^2), i = 1, 2, \cdots, n.$$

性质5 令$X \sim N(\boldsymbol{\mu}, \sigma^2\mathbf{I}_n)$, $\mathbf{A}$和$\mathbf{B}$分别为$r \times n$和$s \times n$维非随机矩阵且$r + s \leq n$。若$\mathbf{AB}^\top = \mathbf{O}_{r\times s}$, 则$\mathbf{A}X$与$\mathbf{B}X$相互独立。

证明： 利用性质2和3.

性质6 令$X \sim N(\mathbf{0}_n, \mathbf{I}_n)$, $\mathbf{A}$为$n \times n$非随机对称阵，$\mathbf{B}$为$m \times n$非随机阵且$m \leq n$. 若$\mathbf{BA} = \mathbf{O}_{m\times n}$, 则$\mathbf{B}X$和$X^\top\mathbf{A}X$相互独立。

证明： 由$\mathbf{A}$为对称阵知存在正交阵$\mathbf{Q}$，使得

$$\mathbf{A} = \mathbf{Q}\begin{pmatrix} \Lambda_1 & \mathbf{O}_{r\times(n-r)} \\ \mathbf{O}_{(n-r)\times r} & \mathbf{O}_{(n-r)\times(n-r)} \end{pmatrix}\mathbf{Q}^\top,$$

其中$\Lambda_1 = \mathrm{diag}(\lambda_1, \lambda_2, \cdots, \lambda_r)$, λ_i是$\mathbf{A}$的非0特征根，$r = \mathrm{rk}(\mathbf{A})$. 对$\mathbf{Q}$进行分块$\mathbf{Q} = (\mathbf{Q}_1, \mathbf{Q}_2)$, 其中$\mathbf{Q}_1$为$n \times r$ 阵。记

$$Y = \mathbf{Q}^\top X = \begin{pmatrix} \mathbf{Q}_1^\top X \\ \mathbf{Q}_2^\top X \end{pmatrix} \widehat{=} \begin{pmatrix} \widetilde{Y}_1 \\ \widetilde{Y}_2 \end{pmatrix}$$

则$Y \sim N(\mathbf{0}_n, \mathbf{I}_n)$, $\widetilde{Y}_1 \sim N(\mathbf{0}_r, \mathbf{I}_r)$, $\widetilde{Y}_2 \sim N(\mathbf{0}_{n-r}, \mathbf{I}_{n-r})$, 且$\widetilde{Y}_1$ 和$\widetilde{Y}_2$相互独立。
另一方面，

$$\mathbf{B}X = \mathbf{BQ}Y,\ X^\top\mathbf{A}X = X^\top\mathbf{Q}_1\Lambda_1\mathbf{Q}_1^\top X = \widetilde{Y}_1^\top\Lambda_1\widetilde{Y}_1.$$

由$\mathbf{BA} = \mathbf{O}_{m\times n}$得

$$\mathbf{O}_{m\times n} = \mathbf{BQQ}^\top\mathbf{AQ} = \mathbf{BQ}\begin{pmatrix} \Lambda_1 & \mathbf{O}_{r\times(n-r)} \\ \mathbf{O}_{(n-r)\times r} & \mathbf{O}_{(n-r)\times(n-r)} \end{pmatrix}.$$

记$\mathbf{BQ} = (\mathbf{D}_1, \mathbf{D}_2)$, 其中$\mathbf{D}_1$为$m \times r$矩阵，由上式知$\mathbf{D}_1 = \mathbf{O}_{m\times r}$. 因此，$\mathbf{B}X = \mathbf{D}_2\widetilde{Y}_2$. 由$\widetilde{Y}_1$和$\widetilde{Y}_2$的独立性得证。

性质7 令$X \sim N(\mathbf{0}_n, \mathbf{I}_n)$, $\mathbf{A}$和$\mathbf{B}$皆为n阶非随机对称阵且$\mathbf{AB} = \mathbf{O}_{n\times n}$, 则$X^\top\mathbf{A}X$和$X^\top\mathbf{B}X$相互独立。

证明： 由$\mathbf{AB} = \mathbf{O}_{n\times n}$可知$(\mathbf{AB})^\top = \mathbf{BA} = \mathbf{O}_{n\times n}$, 于是$\mathbf{AB} = \mathbf{BA}$, 即$\mathbf{A}, \mathbf{B}$可交换，因而可用一个正交阵将这两个矩阵同时对角化，即存在正交阵$\mathbf{Q}$使得

$$\mathbf{A} = \mathbf{Q}\Lambda_1\mathbf{Q}^\top, \mathbf{B} = \mathbf{Q}\Lambda_2\mathbf{Q}^\top,$$

其中$\Lambda_j = \mathrm{diag}\left(\lambda_{1j}, \lambda_{2j}\cdots, \lambda_{nj}\right), j = 1, 2$. 由$\mathbf{AB} = \mathbf{O}_{n\times n}$,可知$\Lambda_1\Lambda_2 = \mathbf{O}_{n\times n}$.
记$Y = \mathbf{Q}^\top X \sim N(\mathbf{0}_n, \mathbf{I}_n)$, 于是$Y$的所有分量都相互独立。
另一方面

$$X^\top\mathbf{A}X = Y^\top\Lambda_1 Y,\ X^\top\mathbf{B}X = Y^\top\Lambda_2 Y.$$

$X^\top\mathbf{A}X$与$X^\top\mathbf{B}X$依赖于Y的不同分量，因而相互独立。

性质8 令$X \sim N(\boldsymbol{\mu}, \boldsymbol{\Delta})$. 作矩阵分块，记

$$\boldsymbol{\Delta} = \begin{pmatrix} \boldsymbol{\Delta}_{11} & \boldsymbol{\Delta}_{12} \\ \boldsymbol{\Delta}_{21} & \boldsymbol{\Delta}_{22} \end{pmatrix}, X = \begin{pmatrix} \widetilde{X}_1 \\ \widetilde{X}_2 \end{pmatrix}, \boldsymbol{\mu} = \begin{pmatrix} \tilde{\boldsymbol{\mu}}_1 \\ \tilde{\boldsymbol{\mu}}_2 \end{pmatrix}.$$

则在给定$\widetilde{X}_2$时$\widetilde{X}_1$的条件分布仍是多元正态分布，且

$$\widetilde{X}_1 | \widetilde{X}_2 = \tilde{x}_2 \sim N\left(\boldsymbol{\mu}_1 + \boldsymbol{\Delta}_{12}\boldsymbol{\Delta}_{22}^{-1}(\tilde{x}_2 - \boldsymbol{\mu}_2), \boldsymbol{\Delta}_{11} - \boldsymbol{\Delta}_{12}\boldsymbol{\Delta}_{22}^{-1}\boldsymbol{\Delta}_{21}\right).$$

例3.24 令$X_1, X_2, \cdots, X_n$独立同分布服从$N(\mu, \sigma^2)$. 求证：$\bar{X} = \frac{1}{n}\sum\limits_{i=1}^{n} X_i$与$Y = \sum\limits_{i=1}^{n-1}(X_i - X_{i+1})$相互独立。

证明： 记$\mathbf{b} = (1, 0, \cdots, 0, -1)^\top$, $\boldsymbol{\mu} = (\mu_1, \mu_2, \cdots, \mu_n)^\top$, $X = (X_1, X_2, \cdots, X_n)^\top$. 则

$$X \sim N(\boldsymbol{\mu}, \sigma^2 \mathbf{I}_n).$$

由于

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i = \frac{1}{n}\mathbf{1}_n^\top X,$$

$$Y = \sum_{i=1}^{n-1}(X_i - X_{i+1}) = X_1 - X_n = \mathbf{b}X,$$

且$\mathbf{1}_n^\top \mathbf{b} = 0$, 根据多元正态分布的性质5, $\bar{X}$和Y相互独立。

例3.25 令$X \sim N(\mathbf{0}_n, \boldsymbol{\Delta})$, $\mathbf{A}, \mathbf{C}$为$n \times n$非随机对称阵，$\mathbf{B}$是$m \times n$维矩阵，$m < n$. 求证：

(1)若$\mathbf{B}\boldsymbol{\Delta}\mathbf{A} = \mathbf{O}_{n\times m}$, 则$\mathbf{B}X$与$X^\top \mathbf{A} X$相互独立；

(2)若$\mathbf{A}\boldsymbol{\Delta}\mathbf{C} = \mathbf{O}_{n\times n}$, 则$X^\top \mathbf{A} X$与$X^\top \mathbf{C} X$相互独立。

证明： 记$Y = \boldsymbol{\Delta}^{-\frac{1}{2}} X$. 则$Y \sim N(\mathbf{0}_n, \mathbf{I}_n)$, $X = \boldsymbol{\Delta}^{\frac{1}{2}} Y$. 由题意知

$$\mathbf{B}\boldsymbol{\Delta}^{\frac{1}{2}}\boldsymbol{\Delta}^{\frac{1}{2}}\mathbf{A}\boldsymbol{\Delta}^{\frac{1}{2}} = \mathbf{B}\boldsymbol{\Delta}\mathbf{A} = \mathbf{O}_{n\times m}.$$

根据性质6得到$\mathbf{B}\boldsymbol{\Delta}^{\frac{1}{2}} Y$与$Y^\top \boldsymbol{\Delta}^{\frac{1}{2}}\mathbf{A}\boldsymbol{\Delta}^{\frac{1}{2}} Y$相互独立。因此，$\mathbf{B}X$与$X^\top \mathbf{A} X$相互独立。

(2)由题意知

$$\boldsymbol{\Delta}^{\frac{1}{2}}\mathbf{A}^\top\boldsymbol{\Delta}^{\frac{1}{2}} \times \boldsymbol{\Delta}^{\frac{1}{2}}\mathbf{C}\boldsymbol{\Delta}^{\frac{1}{2}} = \boldsymbol{\Delta}^{\frac{1}{2}}\mathbf{A}^\top\boldsymbol{\Delta}\mathbf{C}\boldsymbol{\Delta}^{\frac{1}{2}} = \mathbf{O}_{n\times n}.$$

根据性质7得到$Y^\top \boldsymbol{\Delta}^{\frac{1}{2}}\mathbf{A}^\top\boldsymbol{\Delta}^{\frac{1}{2}} Y$与$Y^\top \boldsymbol{\Delta}^{\frac{1}{2}}\mathbf{C}\boldsymbol{\Delta}^{\frac{1}{2}} Y$ 相互独立。因此，$X^\top \mathbf{A}^\top X$与$X^\top \mathbf{C} X$相互独立。

习题三

验证分布函数

1. 考察二元函数

$$F(x,y)=\int_{-\infty}^{x}\int_{-\infty}^{y}\frac{1}{2\pi}e^{-\frac{x^2+y^2}{2}}(1+\sin x\sin y),x\in\mathcal{R},y\in\mathcal{R}.$$

问它是某二元随机变量的分布函数吗？

2. 考察二元函数

$$F(x,y)=\begin{cases}0 & x<0,\\ 0 & y<0,\\ 0 & x+y<1,\\ 1 & \text{其它。}\end{cases}$$

问它是某二元随机变量的分布函数吗？

3. 考察二元函数

$$F(x,y)=\begin{cases}(1-e^{-2x})(1+e^{-2y}) & x>0,y>0,\\ \frac{1}{2} & \text{其它。}\end{cases}$$

问它是某二元随机变量的分布函数吗？

多元离散型随机变量

4. 一盒子里有2个白球和3个红球，从中随机取出2个球，记取出的白球和红球的个数分别为X和Y. 求$(X,Y)^\top$的联合概率函数。

5. 一盒子里有1个白球，2个红球和3个黑球。从中随机取出2个球，记取出的白球和红球的个数分别为X和Y. 求$(X,Y)^\top$的联合概率函数。

6. 独立重复地做一试验，试验成功的概率为p, $0<p<1$. 记首次成功之前的失败次数为X，前两次成功之间的失败次数为Y。求二元随机变量$(X,Y)^\top$的联合概率函数。

7. 令随机变量X的概率函数为

$$P(X=-1)=P(X=0)=P(X=1)=\frac{1}{3},$$

$Y\sim B(1,0.5)$. 记$P(XY=0)=1$. 求$(X,Y)^\top$的联合概率函数。

多元连续型随机变量

8. 令二元随机变量$(X,Y)^\top$的联合密度函数为

$$f(x,y)=\begin{cases} ke^{-x-y-xy} & x>0,y>0,\\ 0 & \text{其它。}\end{cases}$$

求$P(X<2,Y<4)$及$P(X<Y)$.

9. 令二元随机变量$(X,Y)^\top$的联合密度函数为

$$f(x,y)=\begin{cases} a\Big(5-\sqrt{x^2+y^2}\Big) & x^2+y^2\le 25,\\ 0 & \text{其它，}\end{cases}$$

求a和$P(X^2+Y^2\le 16)$.

10. 令$g(x)\ge 0$且$\int_0^\infty g(x)=1$. 记

$$f(x,y)=\begin{cases} \frac{2g\left(\sqrt{x^2+y^2}\right)}{\pi\sqrt{x^2+y^2}} & 0<x,y<\infty,\\ 0 & \text{其它。}\end{cases}$$

求证：$f(x,y)$是某二元随机变量的联合密度函数。

11. 令X,Y为连续型随机变量，X的密度函数为$f_X(x)$且$f_X(x)=f_X(-x)$, $x\in\mathcal{R}$, Y取非负值。记$f_Z(z)$是$Z=X/Y$的密度函数。求证：$f_Z(z)=f_Z(-z), z\in\mathcal{R}$.

离散型随机变量的边缘分布

12. 令随机变量X服从1到n(包括1和n)中自然数上的离散均匀分布；Y服从1到X(包括1和X)中自然数上的离散均匀分布。求Y的边缘分布。

13. 令二元随机变量$(X,Y)^\top$的联合概率分布为

$X\backslash Y$	-1	0	1
-1	$\frac{1}{10}$	$\frac{1}{15}$	$\frac{1}{30}$
0	$\frac{1}{5}$	$\frac{2}{15}$	$\frac{1}{15}$
1	$\frac{3}{10}$	$\frac{1}{5}$	$\frac{2}{5}$

求其边缘分布。

14. 令随机变量$(X,Y)^\top$的联合概率函数为

$$P(X=n,Y=k)=\frac{e^{-9}\times 5^k\times 4^{n-k}}{m!(n-k)!}, n=0,1,2,\cdots,\ k=0,1,\cdots,n.$$

求其边缘分布。

连续型随机变量的边缘分布

15. 令随机变量$X \sim B(1,p), 0<p<1$, $Y \sim U(0,X)$. 求Y的边缘分布。

16. 令随机变量$X \sim Exp(\lambda)$, $Y=\min\{X,\theta\}, \lambda>0, \theta>0$. 求$Y$的边缘分布。

17. 令二元随机变量$(X,Y)^\top$的联合密度函数为

$$f(x,y)=k\cdot\exp\left\{-[(x+y)^2+(x-y)^2]\right\}, x\in\mathcal{R}, y\in\mathcal{R}.$$

求X,Y的边缘密度函数。

18. 令$(X,Y)^\top$服从**二元指数分布**，其分布函数为：

$$F(x,y)=\begin{cases}1-e^{-(\lambda_1+\lambda_3)x}-e^{-(\lambda_2+\lambda_3)y}+e^{-\lambda_1 x-\lambda_2 y-\lambda_3\max\{x,y\}}, & x>0,y>0,\\ 0, & \text{其它。}\end{cases}$$

求其边缘分布。

19. 令二元随机变量$(X,Y)^\top$的联合密度函数为

$$f(x,y)=\frac{1}{2\pi}\exp\left(-\frac{x^2+y^2}{2}\right)\left(1-\frac{xy}{(1+x^2)(1+y^2)}\right), x,y\in\mathcal{R},$$

$(U,V)^\top$的联合密度函数为

$$g(u,v)=\frac{1}{2\pi}\exp\left(-\frac{u^2+v^2}{2}\right)(1+\sin u\sin v), u,v\in\mathcal{R}.$$

求证：$f(x,y)$和$g(u,v)$都不是二元正态分布，其边缘分布是$N(0,1)$.

20. 令X,Y是相互独立的连续型随机变量，$X\sim F_X(x)$, $Y\sim f_Y(y)$. 求证：

$$P(X<Y)=\int_{-\infty}^{\infty}F_X(y)f_Y(y)dy.$$

离散型随机变量的条件分布

21. 令二元随机变量$(X,Y)^\top$的联合概率函数为

$$P(X=0,Y=0)=\frac{1}{5},\ P(X=0,Y=1)=\frac{1}{10},$$
$$P(X=1,Y=0)=\frac{3}{10},\ P(X=1,Y=1)=\frac{2}{5}.$$

求其条件分布。

22. 一盒子里有2个白球和3个红球。从盒中随机取两个球，记取到白球和红球的个数分别为X和Y. 求$P(X=1|Y=0)$和$P(Y=1|X=0)$.

23. 一盒子里有2个白球和3个红球。有放回地从盒中随机取球两次，每次取1个球。记两次取到白球和红球的个数分别为X和Y. 求$P(X=1|Y=0)$和$P(Y=1|X=0)$.

24. 令随机变量$X \sim B(1, 0.6)$, Y的条件概率分布为

$$P(Y=-1|X=0)=0.4,\ P(Y=0|X=0)=0.6,$$

$$P(Y=-1|X=1)=0.6,\ P(Y=0|X=1)=0.4.$$

求$(X,Y)^\top$的联合概率分布，及给定Y时X的条件分布。

连续型随机变量的条件分布

25. 令$(X,Y)^\top$的联合密度函数为

$$f(x,y)=\begin{cases}\frac{8xy}{9}, & 1\le x\le y\le 2,\\ 0 & \text{其它。}\end{cases}$$

求其条件密度函数。

26. 考察二元随机变量$(X,Y)^\top$, X的密度函数为

$$f_X(x)=\begin{cases}3x^2, & 0<x<1,\\ 0, & \text{其他，}\end{cases}$$

在给定$X=x, 0<x<1$的条件下，Y的条件密度函数为

$$f_{Y|X}(y|x)=\begin{cases}\frac{3y^2}{x^3}, & 0<y<x,\\ 0, & \text{其它。}\end{cases}$$

求：(1)$(X,Y)^\top$的联合密度函数；(2)Y的边缘密度函数。

27. 令随机变量$(X,Y)^\top$的联合密度函数为

$$f(x,y)=ke^{-x^2+2xy-y^2}, x, y\in\mathcal{R}.$$

求X,Y的边缘分布, $f_{Y|X}(y|x)$和$f_{X|Y}(x|y)$.

28. 令$X\sim U(1,3)$. 求在给定$X>2$的条件下X的条件分布函数。

29. 令$(X,Y)^\top$服从区域Ω上的均匀分布，Ω是由$y=x, y=2-x$, 与$y=0$围成的三角形。求：(1)X的边缘密度函数；(2)给定$Y=y$时，X的条件密度函数。

30. 令随机变量$(X,Y)^\top$的联合分布函数为

$$F(x,y)=a\Big(b+\arctan\frac{x}{2}\Big)\Big(c+\arctan\frac{y}{3}\Big).$$

求: (1) a,b,c; (2)边缘密度函数；(3)条件密度函数。

随机变量的独立

31. 令随机变量X,Y独立同分布，且X的概率函数为

$$P(X=1)=p,\ P(X=0)=1-p.$$

记

$$Z=\begin{cases}1, & X+Y\text{为偶数},\\ 0, & \text{其它。}\end{cases}$$

求p使得X,Z相互独立。

32. 令$(X,Y)^\top$的联合概率分布是

$X\backslash Y$	1	2	3
1	$\frac{1}{2}$	$\frac{1}{4}$	$\frac{1}{8}$
2	$\frac{1}{3}$	a	b

求a,b使得X,Y相互独立。

33. 令随机变量X,Y独立同分布，且X的密度函数为

$$f(x)=\begin{cases}4x^3, & 0<x<1,\\ 0, & \text{其它。}\end{cases}$$

记事件$A=\{X>t\}$, $B=\{Y>t\}$, 且$P(A\cup B)=0.8$. 求t.

34. 令三元随机变量$(X,Y,Z)^\top$的联合密度函数为

$$f(x,y,z)=\begin{cases}\frac{1}{8\pi^3}(1-\sin x\sin y\sin z) & 0\le x,y,z\le 2\pi,\\ 0 & \text{其它。}\end{cases}$$

求证：X,Y,Z两两独立，但不相互独立。

35. 令二元随机变量$(X,Y)^\top$服从单位圆上的均匀分布。求证：X和Y不相互独立。

36. 令二元随机变量$(X,Y)^\top$的联合密度函数为

$$f(x,y)=\begin{cases}\frac{xy+1}{4}, & -1\le x\le 1,-1\le y\le 1,\\ 0, & \text{其它。}\end{cases}$$

求证：X,Y不独立，但X^2,Y^2相互独立。

离散型随机变量的函数的概率分布

37. 令随机变量X的概率函数为

$$P(X=0)=1/3,\ P(X=1)=2/3;$$

Y的概率函数为

$$P(Y=-1)=P(Y=0)=P(Y=1)=1/3,$$

且$P(X^2=Y^2)=1$. 求$(X,Y)^\top$的联合概率分布和$Z=X+Y$的概率分布。

38. 令随机变量X_1,X_2,X_3,X_4独立同分布，且X_1的概率函数为

$$P(X_1=0)=0.4,\ P(X_1=1)=0.6.$$

求行列式

$$\det\begin{pmatrix} X_1 & X_2 \\ X_3 & X_4 \end{pmatrix}$$

的概率分布。

39. 令二元随机变量$(X,Y)^\top$的联合概率分布为

$X\backslash Y$	-1	0	1
-1	0.05	0.05	0.1
0	0.05	0.1	0.1
1	0.1	0.15	0.3

求：$(1)P(X=1|Y=1)$; $(2)\min\{X,Y\}$的概率分布；$(3)X+Y$的概率分布。

40. 令随机变量X,Y独立同分布，且X的概率函数为

$$P(X=i)=\frac{1}{4},\ i=1,2,3,4.$$

记$U=\max\{X,Y\}$, $V=\min\{X,Y\}$. 求$(X,Y)^\top$的联合概率函数。

41. 令X,Y独立同分布，服从$B(n,p)$. 求证：

$$X=k|X+Y=m\sim HG(k,2n,m),m\le n.$$

42. 令随机变量$X\sim B(n,p)$, $Y=n-X$. 求证：

$$X与Y相互独立\iff n\sim Poisson(\lambda),\lambda>0.$$

43. 令随机变量$X \sim Poisson(\lambda_1)$, $Y \sim Poisson(\lambda_2)$, 且$X$与$Y$相互独立。求证：
$$X|X+Y=n \sim B\big(n, \lambda_1/(\lambda_1+\lambda_2)\big), n \geq 1.$$

连续型随机变量的函数的概率分布

44. 令X服从-1和1等可能的两点分布，$Y \sim N(0,1)$, 且X, Y相互独立。求XY, $X+Y$, Y/X的概率分布。

45. 令随机变量X, Y独立同分布，服从$N(\mu, \sigma^2)$. 问$\min\{X,Y\}$ 与$\max\{X,Y\}$相互独立吗？

46. 令$(X,Y)^\top \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$. 求$b$使得$X+bY$与$X-bY$相互独立。

47. 令随机变量X, Y, Z独立同分布，服从$N(0, \sigma^2)$. 求$\sqrt{X^2+Y^2+Z^3}$的密度函数。

48. 令随机变量X, Y相互独立，且$X \sim Exp(\lambda)$, $Y \sim Exp(\zeta)$, $\lambda > 0, \zeta > 0$. 记$Z = I_{\{X \geq Y\}}$. 求Z的概率分布。

49. 令随机变量$X \sim Exp(\lambda_1)$, $Y \sim Exp(\lambda_2)$, 且X, Y相互独立。求$X+Y$和$X-Y$的密度函数。

50. 令随机变量$X \sim Beta(\xi, \eta)$. 求$\frac{1}{X}$和$\frac{1-X}{X}$的密度函数。

51. 令随机变量X与Y相互独立，$X \sim U(1,2)$, $Y \sim Exp(2)$. 求:
(1)$(X,Y)^\top$的联合分布函数；(2)$P(X \leq Y)$; (3)X/Y的密度函数。

52. 令二元随机变量$(X,Y)^\top$的联合密度函数为
$$f(x,y) = \begin{cases} ax(x+y), & 0<x<2, 0<y<2. \\ 0, & \text{其它。} \end{cases}$$
记$U = \max\{X,Y\}$, $V = \min\{X,Y\}$. 求$(U,V)^\top$的联合密度函数。

53. 令连续型随机变量X, Y相互独立，X的分布函数为$F_X(x)$, Y的密度函数为$f_Y(y)$. 求证：
$$P(X<Y) = \int_{-\infty}^{\infty} F_X(y) f_Y(y) dy.$$

54. 令随机变量X的密度函数为$f(x)$,
$$f(x) = \begin{cases} ax, & 0<x<4, \\ 0, & \text{其它。} \end{cases}$$

记

$$Y=\begin{cases}3, & X\le 2,\\ X, & 2<X\le 3,\\ 1, & X>3.\end{cases}$$

求Y的密度函数及$P(X\le Y)$.

55. 令二元随机变量$(X,Y)^\top$的联合密度函数为

$$f(x,y)=\begin{cases}e^{-x}, & 0<y<x,\\ 0, & \text{其它。}\end{cases}$$

求$f_{Y|X}(y|x)$,$f_{X|Y}(x|x)$和$P(X\le 1|Y\le 1)$.

56. 令二元随机变量$(X,Y)^\top$的联合密度函数为

$$f(x,y)=\begin{cases}\frac{1+xy}{4} & -1<x,y<1,\\ 0 & \text{其它。}\end{cases}$$

求证：X^2与Y^2相互独立，但X与Y不独立。

57. 令随机变量X,Y独立同分布，服从$N(0,1)$. 记

$$Z=\begin{cases}X, & XY\ge 0,\\ -X, & \text{其它。}\end{cases}$$

求证：Z服从正态分布，但$(Y,Z)^\top$不服从二元正态分布。

58. 令X,Y独立同分布服从$N(0,1)$. 求证：X^2+Y^2与X/Y相互独立。

59. 令随机变量X,Y独立同分布，其密度函数不等于0且有二阶导数。若$X+Y$与$X-Y$相互独立，则随机变量$X,Y,X+Y,X-Y$均服从正态分布。

60. 令随机变量X,Y独立同分布，服从$U(0,1)$. 记

$$U=\sqrt{-2\ln X}\cos(2\pi Y),\ V=\sqrt{-2\ln X}\sin(2\pi Y).$$

求证：U,V独立同分布，服从$N(0,1)$.

61. 令随机变量X,Y独立同分布，服从$Exp(\lambda),\lambda>0$. 求证：
(1)$X+Y$和X/Y相互独立；
(2)$X+Y$和$X/(X+Y)$相互独立；
(3)$\min\{X,Y\}$与$\max\{X,Y\}$相互独立；
(4)在给定$X>Y$的条件下，$\min\{X,Y\}$ 与$X-Y$相互独立。

62. 令$X,Y,Z\ iid\sim Exp(\lambda),\lambda>0$. 记

$$U=\frac{X}{X+Y},\ V=\frac{X+Y}{X+Y+Z},\ W=X+Y+Z.$$

求证：U,V,W相互独立。

63. 令随机变量X,Y独立同分布，服从$Exp(1)$. 记

$$U=X+Y,\ V=X-Y,\ W=\frac{X}{Y}.$$

求证：(1) U,V相互独立；(2) U,W相互独立。

64. 令随机变量X与Y相互独立，$X\sim Gamma(\alpha,\lambda)$, $Y\sim Gamma(\beta,\lambda)$. 求证：
(1)$X+Y$与X/Y相互独立。
(2)$\frac{X}{X+Y}\sim Beta(\alpha,\beta)$,且$\frac{X}{X+Y}$和$X+Y$相互独立。
(3)X/Y与$X+Y$相互独立。

65. 令$X_1,X_2,\cdots,X_n$独立同分布，服从密度函数$f(x)=xe^{-x},x>0$. 求证：

$$Y=X_1+X_2+\cdots+X_n\sim g(y)=\frac{y^{2n+1}e^{-y}}{(2k+1)!},y>0$$

多元正态分布

66. 令$(X_1,X_2,X_3)^\top\sim N\big(\mathbf{0}_3,(1-\rho)\mathbf{I}_3+\rho\mathbf{1}_3\mathbf{1}_3^\top\big)$. 求$\rho$使得$X_1+X_2-X_3$与$X_1-X_2+X_3$相互独立。

67. 令$X_1,X_2,\cdots,X_n$独立同分布，服从$N(\mu,\sigma^2)$, 求$\Big(\sum\limits_{i=1}^{m}X_i,\sum\limits_{i=k}^{n}X_i\Big)^\top$的概率分布，$m<n$.

68. 令$X=(X_1,X_2,\cdots,X_n)^\top\sim N\left(\mathbf{0}_n,\mathbf{I}_n\right)$, $Y=(Y_1,Y_2,\cdots,Y_n)^\top\sim N\left(\mathbf{0}_n,\mathbf{I}_n\right)$, 且$X,Y$ 相互独立。求证：$\frac{X^\top Y}{\sqrt{Y^\top Y}}\sim N(0,1)$.

69. 令X_1,X_2,X_3独立同分布，服从$N(\mu,\sigma^2)$. 记

$$Y_1=X_1+X_2+X_3,Y_2=X_1-X_3.$$

求证：Y_1,Y_2相互独立。

70. 令n元随机变量$X\sim N(\boldsymbol{\mu},\boldsymbol{\Delta})$, $\mathbf{A}$为$n\times n$非随机对称阵，$\mathbf{B}$是$m\times n$维列向量，$m<n$. 若$\mathbf{B\Delta A}=\mathbf{O}_{n\times n}$, 则$\mathbf{B}X$与$X^\top\mathbf{A}X$相互独立。

第四章　随机变量的数字特征和极限性质

随机变量的概率分布完整地刻画了随机变量的变化规律。在实际应用中，人们有时需要直观上了解随机变量的某一方面的特征。比如某单位打算购买一批日光灯，想了解这批日光灯的寿命，而一般来说日光灯的平均寿命是购买人员所关心的，它给人们一个整体印象。平均值是随机变量的一个重要的数字特征，它在一定程度上刻画了随机变量取值的“中心”位置。随机变量另一个重要的数字特征是方差，它刻画了随机变量取值的分散程度。方差越大，分散程度就越大。了解随机变量数字特征的重要意义在于：当我们不知道随机变量确切的概率分布时，根据它的某些数字特征，可以推断它大致的概率性质。另一方面，类似于数学分析中的级数求和，无穷个随机变量会体现出一定的数学规律性，这是随机变量序列的极限性质，它刻画了当随机变量个数趋于无穷时，其序列整体的变化规律。

4.1 数学期望

4.1.1 数学期望

数学期望也称均值，是随机变量的一个最基本的数字特征。下面分离散型随机变量和连续型随机变量来介绍数学期望。首先考查一元随机变量。

离散型随机变量的数学期望：令离散型随机变量X的所有可能取值为$a_1, a_2, \cdots, a_n, n$可以取无穷，概率函数为$p_i = P(X = a_i), i = 1, 2, \cdots, n.$ 若

$$\sum_{i=1}^{n} |a_i| p_i < \infty,$$

称

$$EX = \sum_{i=1}^{n} a_i p_i$$

为X的数学期望，数学期望简称期望或均值。如果$\sum\limits_{i=1}^{n} |a_i| p_i = \infty$, 称$X$的数学期望不存在。

连续型随机变量的数学期望：令连续型随机变量X的密度函数为$f(x).$ 若

$$\int_{-\infty}^{\infty} |x| f(x) dx < \infty,$$

称

$$EX = \int_{-\infty}^{\infty} x f(x) dx$$

为X的数学期望，如果$\int_{-\infty}^{\infty} |x| f(x) dx = \infty$, 称$X$的数学期望不存在。

下面给出几种常见分布的数学期望。

二项分布 令$X \sim B(n,p)$,

$$\begin{aligned} EX &= \sum_{k=0}^{n} k\frac{n!}{k!(n-k)!}p^k(1-p)^{n-k} \\ &= \sum_{k=1}^{n} \frac{n!}{(k-1)!(n-k)!}p^k(1-p)^{n-k} \\ \overset{i=k-1}{=} &\sum_{i=0}^{n-1} \frac{(n-1)!}{i!(n-1-i)!}p^i(1-p)^{n-1-i}np \\ &= np. \end{aligned}$$

几何分布 令$X \sim Geo(p)$,

$$\begin{aligned} EX &= \sum_{k=1}^{\infty} k(1-p)^{k-1}p \\ &= -p\sum_{k=1}^{\infty}\big[(1-p)^k\big]' \\ &= -p\sum_{k=0}^{\infty}\big[(1-p)^k\big]' \\ &= -p\big[\frac{1}{1-(1-p)}\big]' \\ &= -p\big[-\frac{1}{p^2}\big] \\ &= \frac{1}{p}. \end{aligned}$$

负二项分布 令$X \sim NB(r,p)$,

$$\begin{aligned} EX &= \sum_{k=r}^{\infty} k\tbinom{k-1}{r-1}p^r(1-p)^{k-r} \\ &= \sum_{k=r}^{\infty} k\frac{(k-1)!}{(r-1)!(k-r)!}p^r(1-p)^{k-r} \\ &= \frac{r}{p}\sum_{k=r}^{\infty} \frac{k!}{r!(k-r)!}p^{r+1}(1-p)^{k-r} \\ &= \frac{r}{p}\sum_{k=r}^{\infty} \tbinom{k}{r}p^{r+1}(1-p)^{k-r} \\ &= \frac{r}{p}, \end{aligned}$$

考察倒数第二个等式，$\binom{k}{r}p^{r+1}(1-p)^{k-r}$ 相当于“$k+1$次试验所关心的事件恰好发生$r+1$ 次的概率”，其中$k+1=r+1,r+2,\cdots,$ 它是$NB(r+1,p)$的概率函数，从而求和为1.

考察负二项分布的另一个概率函数：$\binom{k+r-1}{r-1}p^r(1-p)^k$, $k=0,1,\cdots$, 则有

$$\begin{aligned} EX &= \sum_{k=0}^{\infty}\binom{k+r-1}{r-1}(1-p)^k p^r k \\ &= \sum_{k=1}^{\infty}\frac{(k+r-1)!}{(r-1)!(k-1)!}(1-p)^k p^r \\ &\overset{k-1=i}{=} \sum_{i=0}^{\infty}\frac{(i+r)!}{r!i!}(1-p)^i p^{r+1}\frac{r(1-p)}{p} \\ &= \frac{r(1-p)}{p}. \end{aligned}$$

上式的倒数第二个等式可以解释成：假设某批产品的废品率为p, 对该批产品质逐一地抽查检验，直到发现第$r+1$个废品为止，已检测出的合格品(k)服从负二项分布。因此，它们累加和为1. 根据上面式子，p愈小，EX愈大。

超几何分布 令$X \sim HG(n,N,M)$.

$$EX = \sum_{i=0}^{n\wedge M} i\frac{\binom{N-M}{n-i}\binom{M}{i}}{\binom{N}{n}} = n\frac{M}{N}\sum_{i=1}^{n\wedge M}\frac{\binom{N-M}{n-i}\binom{M-1}{i-1}}{\binom{N-1}{n-1}} = n\frac{M}{N},$$

其中$n\wedge M = \min\{n,M\}$.

Poisson分布 $X \sim Poisson(\lambda)$,

$$EX = \sum_{k=0}^{\infty}\frac{k\lambda^k e^{-\lambda}}{k!} = \sum_{k=1}^{\infty}\frac{\lambda^k e^{-\lambda}}{(k-1)!} \overset{i=k-1}{=} \sum_{i=0}^{\infty}\frac{\lambda^i e^{-\lambda}}{i!}\lambda = \lambda.$$

正态分布 $X \sim N(\mu,\sigma^2)$,

$$EX = \int_{-\infty}^{\infty}\frac{x}{\sqrt{2\pi}\sigma}e^{-\frac{(x-\mu)^2}{2\sigma^2}}dx = \int_{-\infty}^{\infty}(\sigma y+\mu)\frac{1}{\sqrt{2\pi}}e^{-\frac{y^2}{2}}dy = \mu.$$

指数分布 $X \sim Exp(\lambda)$,

$$EX = \int_0^{\infty} x\lambda e^{-\lambda x}dx = -\int_0^{\infty} xde^{-\lambda x} = -xe^{-\lambda x}|_0^{\infty} + \int_0^{\infty} e^{-\lambda x}dx = \frac{1}{\lambda}.$$

由第三章例3.9失效率的定义知指数分布的失效率为λ，可见失效率越大，平均寿命$(=1/\lambda)$越短。

Beta分布 $X \sim Beta(\xi,\eta)$,

$$EX = \frac{\Gamma(\xi+\eta)}{\Gamma(\xi)\Gamma(\eta)}\int_0^1 x^{\xi}(1-x)^{\eta-1}dx = \frac{\Gamma(\xi+\eta)}{\Gamma(\xi)\Gamma(\eta)}\times\frac{\Gamma(\xi+1)\Gamma(\eta)}{\Gamma(\xi+\eta+1)} = \frac{\xi}{\xi+\eta}.$$

Gamma分布 $X \sim Gamma(\xi,\lambda)$,

$$EX = \frac{\lambda^{\xi}}{\Gamma(\xi)}\int_0^{\infty} x^{\xi}e^{-\lambda x}dx = \frac{\Gamma(\xi+1)}{\lambda\Gamma(\xi)} = \frac{\xi}{\lambda}.$$

均匀分布 $X \sim U(a,b)$, $EX = \dfrac{a+b}{2}$.

Cauchy分布的期望不存在。以标准柯西分布$Cauchy(0,1)$为例进行说明。

$$\int_{-\infty}^{+\infty} |x| \frac{1}{\pi(1+x^2)} dx = 2\int_0^{+\infty} \frac{x}{\pi(1+x^2)} = \frac{1}{\pi}\int_0^{+\infty} \frac{1}{1+x^2} d(x^2+1) = \frac{1}{\pi}\int_0^{+\infty} \frac{1}{t} dt,$$

由于$\int_0^{+\infty} \frac{1}{t} dt$不收敛，故$Cauchy(0,1)$的期望不存在。

例4.1 令随机变量X的密度函数为

$$f(x) = \begin{cases} \frac{b}{a} e^{-\frac{2x}{a}}, & x \geq 0, \\ 0, & \text{其它}, \end{cases}$$

其中$a > 0$. 求EX.

解： 由

$$1 = \int_0^{\infty} f(x)dx = \int_0^{\infty} \frac{b}{a} e^{-\frac{2x}{a}} dx = \frac{b}{a}\big(-\frac{a}{2}\big) e^{-\frac{2x}{a}}\big|_0^{\infty} = \frac{b}{2}$$

得$b = 2$. 可见，$X \sim Exp(2/a)$, 因此，$EX = a/2$.

针对n元随机变量$(X_1, X_2, \cdots, X_n)^\top$，已知其联合概率函数或联合密度函数，同样可以定义它的数学期望。

多元随机变量的数学期望： 令n元随机变量$(X_1, X_2, \cdots, X_n)^\top$的每个分量$X_i$的数学期望为$EX_i, i = 1, 2, \cdots, n$, 那么$(X_1, X_2, \cdots, X_n)^\top$的数学期望为

$$E(X_1, X_2, \cdots, X_n)^\top = \big(EX_1, EX_2, \cdots, EX_n\big)^\top.$$

由于数学期望是由随机变量的分布完全决定，我们也称某分布F的数学期望。

多项分布 $X \sim M(N, p_1, p_2, \cdots, p_n)$, $EX = (Np_1, Np_2, \cdots, Np_n)^\top$.

多元正态分布 $X \sim N(\boldsymbol{\mu}, \boldsymbol{\Delta})$, 由第三章多元正态分布性质3，多元正态分布的边缘分布是正态分布，因此，$EX = \boldsymbol{\mu}$.

除非特别说明，本书提到某随机变量的数学期望均假定该随机变量的数学期望存在。

4.1.2 期望的性质

数学期望之所以在理论和应用上都很重要，除了它本身可以刻画随机变量的平均值外，还有一个重要原因是它具有许多良好的性质。

性质1 (线性组合的期望等于期望的线性组合) 考察n个随机变量$X_1, X_2, \cdots, X_n$和n个常数$c_1, c_2, \cdots, c_n$. 则

$$E(c_1X_1 + c_2X_2 + \cdots + c_nX_n) = c_1EX_1 + c_2EX_2 + \cdots + c_nEX_n.$$

证明：这里仅以连续型随机变量为例证明证明，离散情形类似。
记

$$(Y_1, Y_2)^\top = (c_1X_1, c_2X_2)^\top \sim f(y_1, y_2).$$

由第三章3.5.2解密度转换公式知$Y = c_1X_1 + c_2X_2 \widehat{=} Y_1 + Y_2$的密度函数为

$$g(y) = \int_{-\infty}^{\infty} f(y_1, y - y_1)dy_1.$$

因此

$$EY = \int_{-\infty}^{\infty} yg(y)dy = \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} yf(y_1, y - y_1)dy_1dy.$$

令$t = y - y_1$, 得

$$EY = \int_{-\infty}^{\infty}\int_{-\infty}^{\infty}(y_1+t)f(y_1, t)dy_1dt = \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} y_1f(y_1, t)dy_1dt+\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} tf(y_1, t)dy_1dt.$$

由于$\int_{-\infty}^{\infty} f(y_1, t)dt$是$Y_1$的密度函数，且$\int_{-\infty}^{\infty} f(y_1, t)dy_1$是$Y_2$的密度函数。从而有

$$EY = EY_1 + EY_2.$$

对n用数学归纳法即得证。

性质2 (随机变量函数的期望) 令X为离散型随机变量，概率函数为$p_i = P(X = a_i), i = 1, 2, \cdots, n$, n可以取∞; 或X为连续型随机变量，密度函数为$f(x)$. 记$g(\cdot)$为一可测函数(可测函数的定义超出本书的内容范围，需要指出的是：一般见到的函数都是可测函数。除非特别说明，本书提到的函数都是可测函数)。则

$$Eg(X) = \begin{cases} \sum\limits_{i=1}^{n} g(a_i)p_i, \\ \int_{-\infty}^{\infty} g(x)f(x)dx. \end{cases}$$

对任意两个可测函数$g_1(X)$和$g_2(X)$，有

$$E\big(g_1(X) + g_2(X)\big) = E\big(g_1(X)\big) + E\big(g_2(X)\big).$$

性质3 (多元随机变量的函数的数学期望) 令n元随机变量$X = (X_1, X_2, \cdots, X_n)^\top$在离散情形下的概率函数为$p_{x_{1j_1}, x_{2j_2}, \cdots, x_{nj_n}}$, $j_i = 1, 2, \cdots, m_i$, $i = 1, 2, \cdots, n$, 或在连续情形下的联合密度函数是$f(x_1, x_2, \cdots, x_n)$. 则，

$$\begin{aligned} &Eg(X_1, \cdots, X_n) \\ &= \begin{cases} \sum\limits_{j_1=1}^{m_1} \cdots \sum\limits_{j_n=1}^{m_n} g(x_{1j_1}, \cdots, x_{nj_n})p_{x_{1j_1}, \cdots, x_{nj_n}}, & \text{离散情形，} \\ \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} g(x_1, \cdots, x_n)f(x_1, \cdots, x_n)dx_1 \cdots dx_n, & \text{连续情形。} \end{cases} \end{aligned}$$

为了计算X的某一函数$g(X)$的期望，可以先求出$g(X)$的概率函数或密度函数，然后利用随机变量的期望的定义来求。然而当$g(\cdot)$比较复杂时，$g(X)$的概率

函数或密度函数很难算。期望的性质3简化了计算$g(X)$的期望的过程，并不需要先算出$g(X)$的概率函数或密度函数，可以直接从X的概率分布出发来计算。

性质4 (独立随机变量乘积的期望等于期望的乘积) 考察n个相互独立的随机变量$X_1, X_2, \cdots, X_n$, 有

$$E(X_1X_2\cdots X_n) = EX_1EX_2\cdots EX_n.$$

证明：仅以连续型随机变量为例进行证明，离散情形类似。
记$(X_1, X_2, \cdots, X_n)^\top \sim f(x_1, x_2, \cdots, x_n)$, $X_i \sim f_{X_i}(x_i), i = 1, 2, \cdots, n.$ 有

$$f(x_1, x_2, \cdots, x_n) = f_{X_1}(x_1)f_{X_2}(x_2)\cdots f_{X_n}(x_n).$$

由期望的性质3可知

$$\begin{aligned}
E(X_1X_2\cdots X_n) &= \int_{-\infty}^{\infty}\int_{-\infty}^{\infty}\cdots\int_{-\infty}^{\infty} x_1x_2\cdots x_nf(x_1, x_2, \cdots, x_n)dx_n\cdots dx_2dx_1 \\
&= \int_{-\infty}^{\infty}\int_{-\infty}^{\infty}\cdots\int_{-\infty}^{\infty} x_1x_2\cdots x_nf_{X_1}(x_1)f_{X_2}(x_2)\cdots f_{X_n}(x_n)dx_n\cdots dx_2dx_1 \\
&= \int_{-\infty}^{\infty} x_1f_{X_1}(x_1)dx_1\int_{-\infty}^{\infty} x_2f_{X_2}(x_2)dx_2\cdots\int_{-\infty}^{\infty} x_nf_{X_n}(x_n)dx_n \\
&= EX_1EX_2\cdots EX_n.
\end{aligned}$$

例4.2 令某一稀有疾病的发病率为p. 为了控制该疾病的传播，需要对一地区n个人的血清(称之为样品)进行检测。为了降低检测成本，把n个样品随机分成m组，每组包含k个样品，对每个组内的混合样品进行检测，如果是阴性，认为该组里的所有样品都是阴性；反之，如果某一组的检测结果是阳性，则对该组的每个样品逐个检测。求平均的检测次数。

解：令X为某一组内k个样品的检测次数，显然X只取1和$k+1$两个值，且

$$P(X = 1) = (1-p)^k,\ \ P(X = k+1) = 1-(1-p)^k.$$

因此

$$EX = (1-p)^k + (k+1)\big[1-(1-p)^k\big].$$

平均检测次数为

$$E(mX) = m(1-p)^k + m(k+1)\big[1-(1-p)^k\big].$$

当$n = 10^7, p = 10^{-5}, k = 10$时，得$m = 10^6$, 平均检测次数为1001000, 远小于$n$.

例4.3 令随机变量$X \sim N(0, 1)$. 求X^2, X^4的数学期望。

解：

$$\begin{aligned}
EX^2 &= \int_{-\infty}^{\infty} x^2\frac{1}{\sqrt{2\pi}}e^{-\frac{x^2}{2}}dx \\
&= \frac{1}{\sqrt{2\pi}}\int_{-\infty}^{\infty}(-x)de^{-\frac{x^2}{2}} \\
&= \frac{1}{\sqrt{2\pi}}\left(-xe^{-\frac{x^2}{2}}\Big|_{-\infty}^{\infty} + \int_{-\infty}^{\infty} e^{-\frac{x^2}{2}}dx\right) \\
&= 1.
\end{aligned}$$

同理，

$$EX^4 = \int_{-\infty}^{\infty} x^4 \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx = 3.$$

例4.4 令$Y \sim LN(\mu, \sigma^2)$. 求EY^k.

解:

$$\begin{aligned} EY^k &= \int_{-\infty}^{\infty} e^x kx \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx \\ &= e^{k\mu+\frac{k^2\sigma^2}{2}} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{[x-(\mu+k\sigma^2)]^2}{2\sigma^2}} dx \\ &= e^{k\mu+\frac{k^2\sigma^2}{2}} \end{aligned}$$

当$k = 1$, $EY = e^{\mu+\frac{\sigma^2}{2}}$; 当$k = 2$, $EY^2 = e^{2\mu+2\sigma^2}$.

4.2 方差

方差是随机变量另一个重要的数字特征，它刻画了随机变量取值的分散程度。如无特殊说明，后面遇到方差的计算和证明都假设方差存在。

方差和标准差：令X是一随机变量。称

$$\mathrm{var}(X) = E(X - EX)^2 = \sigma^2$$

为X的方差，$\sigma = \sqrt{\mathrm{var}(X)}$为$X$的标准差。

对于离散型随机变量X, 其概率函数为$p_i = P(X = a_i), i = 1, 2, \cdots, n$, 有

$$\mathrm{var}(X) = \sum_{i=1}^{n} p_i (a_i - EX)^2.$$

对于连续型随机变量$X \sim f(x)$, 有

$$\mathrm{var}(X) = \int_{-\infty}^{\infty} \big(x - EX\big)^2 f(x) \mathrm{d}x.$$

由方差的定义知

$$\mathrm{var}(X) = E(X - EX)^2 = E\big[X^2 - 2XEX + (EX)^2\big] = EX^2 - (EX)^2.$$

因此，$\mathrm{var}(X) \le EX^2$. 计算方差只需要求两个期望值：EX^2和EX.

下面给出几种常见分布的方差。

二项分布 $X \sim B(n, p)$, $\mathrm{var}(X) = np(1-p)$.

证明：

$$\begin{aligned}
EX^2 &= \sum_{k=0}^{n} k^2 \frac{n!}{k!(n-k)!} p^k (1-p)^{n-k} \\
&= \sum_{k=0}^{n} k(k-1) \frac{n!}{k!(n-k)!} p^k (1-p)^{n-k} + \sum_{k=0}^{n} k \frac{n!}{k!(n-k)!} p^k (1-p)^{n-k} \\
&= \sum_{k=2}^{n} \frac{n!}{(k-2)!(n-k)!} p^k (1-p)^{n-k} + EX \\
&\overset{i=k-2}{=} \sum_{i=0}^{n-2} \frac{(n-2)!}{i!(n-2-i)!} p^i (1-p)^{n-2-i} p^2 n(n-1) + EX \\
&= n(n-1)p^2 + np.
\end{aligned}$$

则

$$\mathrm{var}(X) = n(n-1)p^2 + np - (np)^2 = np(1-p).$$

特别地，针对$n = 1$的Bernoulli分布(0-1分布)，它的期望和方差分别为

$$EX = p, \ \ \mathrm{var}(X) = p(1-p).$$

几何分布 $X \sim Geo(p)$,

$$\mathrm{var}(X) = \frac{1-p}{p^2}.$$

证明：

$$\begin{aligned}
EX^2 &= \sum_{k=1}^{\infty} k^2(1-p)^{k-1}p \\
&= \sum_{k=1}^{\infty} k(k-1)(1-p)^{k-2}p(1-p) + \sum_{k=1}^{\infty} k(1-p)^{k-1}p \\
&= p(1-p)\sum_{k=0}^{\infty}\left[(1-p)^k\right]'' + EX \\
&= p(1-p)\Big[\frac{1}{1-(1-p)}\Big]'' + EX \\
&= p(1-p)\frac{2}{p^3} + EX \\
&= \frac{2-p}{p^2}.
\end{aligned}$$

则

$$\mathrm{var}(X) = \frac{2-p}{p^2} - \big(\frac{1}{p}\big)^2 = \frac{1-p}{p^2}.$$

负二项分布 $X \sim NB(r,p)$,

$$\mathrm{var}(X) = \frac{r(1-p)}{p^2}.$$

证明：

$$\begin{aligned}
EX^2 &= \sum_{k=r}^{\infty} k^2\tbinom{k-1}{r-1}p^r(1-p)^{k-r} \\
&= \sum_{k=r}^{\infty} k(k+1)\tbinom{k-1}{r-1}p^r(1-p)^{k-r} - \sum_{k=r}^{\infty} k\tbinom{k-1}{r-1}p^r(1-p)^{k-r} \\
&= \sum_{k=r}^{\infty} k(k+1)\frac{(k-1)!}{(r-1)!(k-r)!}p^r(1-p)^{k-r} - EX \\
&= \sum_{k=r}^{\infty} \frac{(k+1)!}{(r+1)!(k-r)!}p^{r+2}(1-p)^{k-r}\frac{(r+1)r}{p^2} - EX \\
&= \frac{(r+1)r}{p^2}\sum_{k=r}^{\infty}\tbinom{k+1}{r+1}p^{r+2}(1-p)^{k-r} - EX \\
&= \frac{(r+1)r}{p^2} - \frac{r}{p}.
\end{aligned}$$

考察倒数第二个等式，$\binom{k+1}{r+1}p^{r+2}(1-p)^{k-r}$相当于“$k+2$次试验所关心的事件恰好发生$r+2$ 次的概率”，其中$k+2 = r+2, r+3, \cdots,$ 也即是$NB(r+2,p)$ 的概率函数，从而求和为1. 则

$$\mathrm{var}(X) = \frac{(r+1)r}{p^2} - \frac{r}{p} - \big(\frac{r}{p}\big)^2 = \frac{r(1-p)}{p^2}.$$

超几何分布 $X \sim HG(n, N, M)$,

$$\mathrm{var}(X) = \frac{nM(N-M)(N-n)}{N^2(N-1)}.$$

证明：

$$\begin{aligned}
EX^2 &= \sum_{i=0}^{n\wedge M} i^2 \frac{\binom{N-M}{n-i}\binom{M}{i}}{\binom{N}{n}} = \sum_{i=0}^{n\wedge M} i^2 \frac{\binom{N-M}{n-i}}{\binom{N}{n}} \frac{M!}{i!(M-i)!} \\
&= \sum_{i=0}^{n\wedge M} i(i-1) \frac{\binom{N-M}{n-i}}{\binom{N}{n}} \frac{M!}{i!(M-i)!} + \sum_{i=0}^{n\wedge M} i \frac{\binom{N-M}{n-i}}{\binom{N}{n}} \frac{M!}{i!(M-i)!} \\
&= \sum_{i=2}^{n\wedge M} \frac{\binom{N-M}{n-i}}{\binom{N-2}{n-2}} \frac{(M-2)!}{(i-2)!(M-i)!} \frac{M(M-1)\binom{N-2}{n-2}}{\binom{N}{n}} + EX \\
&= \frac{M(M-1)\binom{N-2}{n-2}}{\binom{N}{n}} + EX \\
&= \frac{M(M-1)n(n-1)}{N(N-1)} + \frac{nM}{N},
\end{aligned}$$

则

$$\mathrm{var}(X) = \frac{M(M-1)n(n-1)}{N(N-1)} + \frac{nM}{N} - \big(\frac{nM}{N}\big)^2 = \frac{nM(N-n)(N-M)}{N^2(N-1)}.$$

Poisson分布 $X \sim Poisson(\lambda)$, $\mathrm{var}(X) = \lambda$.

证明：

$$\begin{aligned}
EX^2 &= \sum_{k=0}^{\infty} \frac{k^2\lambda^k e^{-\lambda}}{k!} \\
&= \sum_{k=0}^{\infty} \frac{k(k-1)\lambda^k e^{-\lambda}}{k!} + \sum_{k=0}^{\infty} \frac{k\lambda^k e^{-\lambda}}{k!} \\
&= \sum_{k=2}^{\infty} \frac{\lambda^k e^{-\lambda}}{(k-2)!} + EX \\
&\overset{i=k-2}{=} \sum_{i=0}^{\infty} \frac{\lambda^i e^{-\lambda}}{i!}\lambda^2 + EX \\
&= \lambda^2 + \lambda,
\end{aligned}$$

则

$$\mathrm{var}(X) = \lambda^2 + \lambda - \lambda^2 = \lambda.$$

正态分布 $X \sim N(\mu, \sigma^2)$，$\mathrm{var}(X) = \sigma^2$.

证明：

$$\begin{aligned}
EX^2 &= \int_{-\infty}^{\infty} \frac{x^2}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx \\
&= \int_{-\infty}^{\infty} (\sigma y + \mu)^2 \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}} dy \\
&= \sigma^2 \int_{-\infty}^{\infty} y^2 \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}} dy + 2\mu\sigma \int_{-\infty}^{\infty} y \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}} dy + \mu^2 \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}} dy \\
&= \sigma^2 + \mu^2
\end{aligned}$$

则

$$\mathrm{var}(X) = \sigma^2 + \mu^2 - (\mu^2) = \sigma^2.$$

正态分布的两个参数，一个是均值，一个是方差。所以正态分布完全由其均值和方差确定。故也称$N(\mu, \sigma^2)$为“均值为μ, 方差为σ^2 的正态分布”。下面给出正态分布落在1倍，2倍和3倍标准差之内的概率：

$$P(-\sigma < X - \mu < \sigma) \approx 68.27\%,$$

$$P(-2\sigma < X - \mu < 2\sigma) \approx 95.45\%,$$

$$P(-3\sigma < X - \mu < 3\sigma) \approx 99.73\%.$$

指数分布 $X \sim Exp(\lambda)$,

$$\mathrm{var}(X) = \frac{1}{\lambda^2}.$$

证明：

$$\begin{aligned} EX^2 &= \int_0^\infty x^2 \lambda e^{-\lambda x} dx \\ &= -\int_0^\infty x^2 de^{-\lambda x} \\ &= -x^2 e^{-\lambda x}|_0^\infty + \int_0^\infty 2x e^{-\lambda x} dx \\ &= \frac{2}{\lambda} \int_0^\infty x \lambda e^{-\lambda x} dx \\ &= \tfrac{2}{\lambda} EX \\ &= \frac{2}{\lambda^2}. \end{aligned}$$

则

$$\mathrm{var}(X) = \frac{2}{\lambda^2} - \left(\frac{1}{\lambda}\right)^2 = \frac{1}{\lambda^2}.$$

Beta分布 $X \sim Beta(\xi, \eta)$,

$$\mathrm{var}(X) = \frac{\xi\eta}{(\xi+\eta)^2(\xi+\eta+1)}.$$

证明：

$$\begin{aligned} EX^2 &= \frac{\Gamma(\xi+\eta)}{\Gamma(\xi)\Gamma(\eta)} \int_0^1 x^{\xi+1}(1-x)^{\eta-1} dx \\ &= \frac{\Gamma(\xi+\eta)}{\Gamma(\xi)\Gamma(\eta)} \times \frac{\Gamma(\xi+2)\Gamma(\eta)}{\Gamma(\xi+\eta+2)} \int_0^1 \frac{\Gamma(\xi+\eta+2)}{\Gamma(\xi+2)\Gamma(\eta)} x^{\xi+1}(1-x)^{\eta-1} dx \\ &= \frac{\Gamma(\xi+\eta)}{\Gamma(\xi)\Gamma(\eta)} \times \frac{\Gamma(\xi+2)\Gamma(\eta)}{\Gamma(\xi+\eta+2)} \\ &= \frac{(\xi+1)\xi}{(\xi+\eta+1)(\xi+\eta)}. \end{aligned}$$

则

$$\mathrm{var}(X) = \frac{(\xi+1)\xi}{(\xi+\eta+1)(\xi+\eta)} - \left(\frac{\xi}{\xi+\eta}\right)^2 = \frac{\xi\eta}{(\xi+\eta)^2(\xi+\eta+1)}.$$

Gamma分布 $X \sim Gamma(\xi, \lambda)$,

$$\mathrm{var}(X) = \frac{\xi}{\lambda^2}.$$

证明：

$$\begin{aligned} EX^2 &= \frac{\lambda^\xi}{\Gamma(\xi)} \int_0^\infty x^{\xi+1} e^{-\lambda x} dx \\ &= \frac{\Gamma(\xi+2)}{\lambda^2 \Gamma(\xi)} \int_0^\infty \frac{\lambda^{\xi+2}}{\Gamma(\xi+2)} x^{\xi+1} e^{-\lambda x} dx \\ &= \frac{\Gamma(\xi+2)}{\lambda^2 \Gamma(\xi)} = \frac{(\xi+1)\xi}{\lambda^2}. \end{aligned}$$

则

$$\mathrm{var}(X) = \frac{(\xi+1)\xi}{\lambda^2} - \big(\frac{\xi}{\lambda}\big)^2 = \frac{\xi}{\lambda^2}.$$

均匀分布 $X \sim U(a, b)$,

$$\mathrm{var}(X) = \frac{(b-a)^2}{12}.$$

证明：

$$EX^2 = \int_a^b x^2 \frac{1}{b-a} dx = \frac{b^3 - a^3}{3(b-a)} = \frac{b^2 + ab + a^2}{3},$$

则

$$\mathrm{var}(X) = \frac{b^2 + ab + a^2}{3} - \big(\frac{a+b}{2}\big)^2 = \frac{(b-a)^2}{12}.$$

例4.5 令$X \sim LN(\mu, \sigma^2)$, 则$\mathrm{var}(X) = e^{2\mu+\sigma^2}\big(e^{\sigma^2} - 1\big)$.

证明： 由例4.4知$EX^2 = e^{(2\mu+2\sigma^2)}$. 因此，

$$\mathrm{var}(X) = e^{(2\mu+2\sigma^2)} - \big[e^{(\mu+\sigma^2/2)}\big]^2 = e^{(2\mu+\sigma^2)}\big(e^{\sigma^2} - 1\big).$$

方差的性质

性质1 对任何常数c，有$\mathrm{var}(X + c) = \mathrm{var}(X)$, $\mathrm{var}(cX) = c^2\mathrm{var}(X)$.

性质2 对任何常数c，有$\mathrm{var}(X) \le E(X - c)^2$,等号成立当且仅当$c = EX$.

证明： 由于

$$\begin{aligned} \mathrm{var}(X) &= E(X - EX)^2 \\ &= E(X - c + c - EX)^2 \\ &= E\left[(X - c)^2 + 2(X - c)(c - EX) + (c - EX)^2\right] \\ &= E(X - c)^2 - (c - EX)^2 \\ &\le E(X - c)^2, \end{aligned}$$

等号成立当且仅当$c = EX$.

这个性质表明$E(X - c)^2$在$c = EX$时取最小值，另一方面也说明了方差定义中取$c = EX$的合理性。

性质3 令随机变量$X_1, X_2, \cdots, X_n$相互独立，$c_i, i = 1, 2, \cdots, n$为常数，则

$$\mathrm{var}\left(\sum_{i=1}^{n} c_i X_i\right) = \sum_{i=1}^{n} c_i^2 \mathrm{var}(X_i).$$

证明：对任意$1 \le i \ne j \le n$,

$$E[c_i(X_i - EX_i)c_j(X_j - EX_j)] = c_i c_j E(X_i - EX_i)E(X_j - EX_j) = 0.$$

有期望的性质4知

$$\begin{aligned}
\mathrm{var}\left(\sum_{i=1}^{n} c_i X_i\right) &= E\left[\sum_{i=1}^{n} c_i X_i - E\left(\sum_{i=1}^{n} c_i X_i\right)\right]^2 \\
&= E\left[\sum_{i=1}^{n} c_i (X_i - EX_i)\right]^2 \\
&= \sum_{i=1}^{n} c_i^2 \mathrm{var}(X_i).
\end{aligned}$$

例4.6 令X, Y独立且均服从标准正态分布。求$|X - Y|$的方差。

解 记$Z = X - Y$. 由方差的性质3和第三章例3.19, 知

$$\mathrm{var}(Z) = \mathrm{var}(X) + \mathrm{var}(Y) = 2, \ \ Z \sim N(0, 2), \ Z/\sqrt{2} \sim N(0, 1).$$

由期望的性质1及例4.3知

$$1 = E\Big(Z/\sqrt{2}\Big)^2 = EZ^2/2,$$

得$E|Z|^2 = EZ^2 = 2$. 另一方面，

$$E\Big|\frac{Z}{\sqrt{2}}\Big| = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} |x| e^{-\frac{x^2}{2}} dx = \sqrt{\frac{2}{\pi}} \int_{0}^{\infty} x e^{-\frac{x^2}{2}} dx = \sqrt{\frac{2}{\pi}}.$$

得$E|Z| = 2/\sqrt{\pi}$. 因此

$$\mathrm{var}(|X - Y|) = E|Z|^2 - (E|Z|)^2 = 2 - \frac{2}{\sqrt{\pi}}.$$

本节的最后介绍一下标准化后的随机变量。**标准化随机变量：**称

$$\widetilde{X} = \frac{X - EX}{\sqrt{\mathrm{var}(X)}}$$

为X的标准化随机变量。显然$E\widetilde{X} = 0, \mathrm{var}(\widetilde{X}) = 1$.

对随机变量进行标准化将其转换成标准化随机变量的好处在于：它消除了由于计量单位的不同给随机变量的取值带来的影响。例如我们测量某个物品的质量，由于随机误差的影响，每次测量值都会有误差。我们可以用千克作单位，也可以用克或毫克作单位，用不同的计量单位得到的随机变量的分布差异很大。如果对它们进行标准化，就可以消除不同的计量单位得到的分布规律的差异。考察$X \sim N(\mu, \sigma^2)$，对其进行标准化，即$Y = \frac{X-\mu}{\sigma}$, 无论μ和σ取什么值，Y都服从均值为0方差为1的标准正态分布。

4.3 条件期望

条件分布也是一种概率分布，类似数学期望的定义，我们可以给出条件期望的定义。为简单起见，以二元随机变量$(X,Y)^\top$为例，记在给定$X=x$的条件之下，Y的条件期望为$E(Y|X=x)$，也可简记为$E(Y|x)$.

条件期望：若$(X,Y)^\top$为离散型随机变量，且在给定$X=x$条件下，Y的概率函数

$$p_{y_j|x}=P(Y=y_j|X=x), j=1,2,\cdots,m,$$

或若$(X,Y)^\top$为连续型随机变量，且在给定$X=x$条件下，Y的条件密度函数为$f(y|x)$. 则

$$E(Y|X=x)=\begin{cases}\sum\limits_{j=1}^{m} y_j p_{y_j|x}, & (X,Y)^\top\text{为离散型，}\\ \int_{-\infty}^{\infty} y f(y|x)dy, & (X,Y)^\top\text{为连续型。}\end{cases}$$

如果说条件分布是随机变量X和Y的相互关系在概率上的刻画，那么条件期望刻画了随着X取值x的变化，Y的取值的平均变化情况。有时候这也是研究者所关心的问题，比如研究平均收入与受教育程度的关系。

期望所具有的性质条件期望同样满足。

例4.7 令$(X,Y)^\top\sim N(\mu_1,\mu_2,\sigma_1^2,\sigma_2^2,\rho)$. 求$E(Y|X=x)$.

解：由于$Y|X=x\sim N\left(\mu_2+\rho\frac{\sigma_2}{\sigma_1}(x-\mu_1),(1-\rho^2)\sigma_2^2\right)$, 因此

$$E(Y|X=x)=\mu_2+\rho\frac{\sigma_2}{\sigma_1}(x-\mu_1).$$

它是x的线性函数. 如果$\rho>0$,则$E(Y|X=x)$随着x增加而增加，即Y“平均来说”有随X取值增大而变大的趋势，换句话说X和Y正相关；反之，如果$\rho<0$, X和Y负相关；$\rho=0$, X与Y不相关。

条件期望$E(Y|X=x)$是x的函数，把x换成X，$E(Y|X)$是一个随机变量。进而有如下的结论。

定理4.1 (双期望公式) 随机变量的期望等于其条件期望的期望。令X,Y为两个随机变量，则$EY=E\big(E(Y|X)\big)$.

证明：我们仅在连续型随机变量的情况下证明结果成立。

记X的概率密度函数为$f_X(x)$, $Y|X=x$ 的密度函数为$f_{Y|X}(y|x)$, $(X,Y)^\top$ 的联合密度为$f(x,y)$. 那么Y的密度函数为

$$f_Y(y)=\int_{-\infty}^{\infty} f(x,y)dx.$$

因此

$$\begin{aligned} EY &= \int_{-\infty}^{\infty} y \int_{-\infty}^{\infty} f(x,y)dxdy \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} y f_{Y|X}(x,y) f_X(x)dxdy \\ &= \int_{-\infty}^{\infty} f_X(x) \int_{-\infty}^{\infty} y f_{Y|X}(x,y)dydx \\ &= \int_{-\infty}^{\infty} E(Y|x) f_X(x)dx \\ &= E(E(Y|X)). \end{aligned}$$

双期望公式又称全期望公式。特别地，若$\{B_1, B_2, \cdots, B_n\}$是样本空间$\Omega$的一个划分，则全期望公式变成

$$EY = \sum_{i=1}^{n} P(B_i)E(Y|B_i).$$

记$EY = P(A), E(Y|B_i) = P(A|B_i)$, 则有$P(A) = \sum\limits_{i=1}^{n} P(A|B_i)P(B_i)$, 这是第一章的全概率公式。

求$E(Y|X)$时，先设定X等于一固定值x, x无随机性，这样算出$E(Y|x)$, 其表达式含有x, 再把x 换成X即可。

定理4.2 令X, Y为两个随机变量。g是一个可测函数且$g(Y)$的数学期望存在。则，

$$Eg(Y) = E\big[E\big(g(Y)|X\big)\big], \;\; E\big[g(X)Y|X\big] = g(X)E(Y|X).$$

下面给出条件方差的定义

$$\mathrm{var}(Y|X) = \begin{cases} \sum\limits_{j=1}^{m} \big(y_j - E(Y|X)\big)^2 p_{y_j|x}, & (X,Y)^\top \text{为离散型，} \\ \int_{-\infty}^{\infty} \big(y - E(Y|X)\big)^2 f(y|x)dy, & (X,Y)^\top \text{为连续型。} \end{cases}$$

其中$p_{y_j|x} = P(Y = y_j|X = x), j = 1, 2\cdots, m$是离散情形下给定$X = x$时$Y$的条件概率函数，$f(y|x)$是连续情形下给定$X = x$时$Y$的条件密度。仿照方差，条件方差的常用计算公式为

$$\mathrm{var}(Y|X) = E(Y^2|X) - [E(Y|X)]^2.$$

定理4.3 令X, Y为两个随机变量，则

$$\mathrm{var}(Y) = \mathrm{var}\big(E(Y|X)\big) + E\big(\mathrm{var}(Y|X)\big).$$

即随机变量的方差等于条件期望的方差加上条件方差的期望。

证明：

$$\mathrm{var}\big[E(Y|X)\big] = E\big(E(Y|X)\big)^2 - [E(E(Y|X))]^2 = E\big(E(Y|X)\big)^2 - (EY)^2.$$

$$E\big(\mathrm{var}(Y|X)\big) = E\big[E(Y^2|X) - \big(E(Y|X)\big)^2\big] = EY^2 - E\big(E(Y|X)\big)^2.$$

两式相加即证。

例4.8 令$(X,Y)^\top \sim N(\mu_1,\mu_2,\sigma_1^2,\sigma_2^2,\rho)$, 求$E(XY)$.

解：可以利用期望的性质3计算$E(XY)$, 然而计算量比较大。下面利用双期望公式计算。

$$E(XY|X=x) = xE(Y|X=x) = x\left(\mu_2 + \frac{\rho\sigma_2}{\sigma_1}(x-\mu_1)\right)$$

$$\begin{aligned} E(XY) &= E\left(\mu_2 X + \frac{\rho\sigma_2}{\sigma_1}X^2 - \frac{\rho\sigma_2}{\sigma_1}\mu_1 X\right) \\ &= \mu_1\mu_2 + \frac{\rho\sigma_2}{\sigma_1}(\mu_1^2+\sigma_1^2) - \frac{\rho\sigma_2}{\sigma_1}\mu_1^2 \\ &= \mu_1\mu_2 + \rho\sigma_1\sigma_2. \end{aligned}$$

例4.9 把一正四面体的各个面依次标记1, 2, 3, 4. 在桌子上随机抛掷该正四面体，考察与桌面接触的那一面出现的数字。记首次连续出现两次标记为1的面所需的连续抛掷次数为X. 求EX.

解：记Y表示抛掷第一次所出现的数字。易知

$$E(X|Y=2) = E(X|Y=3) = E(X|Y=4) = 1 + EX.$$

$$E(X|Y=1) = \frac{1}{4}\times 2 + \frac{1}{4}\sum_{i=2}^{4}\big[1 + E(X|Y=i)\big] = \frac{1}{2} + \frac{1}{4}(3+3EX).$$

所以，

$$\begin{aligned} EX &= \sum_{i=1}^{4} E(X|Y=i)P(Y=i) \\ &= 0.25\times\big[3 + 3EX + 0.5 + 0.25\times(3+3EX)\big]. \end{aligned}$$

解得$EX = 17$.

例4.10 令随机变量序列$X_1, X_2, \cdots$独立同分布，它们与随机变量X有相同的分布。随机变量Y只取正整数，概率函数为$p_i = P(Y=i), i=1,2,\cdots$, 且$X_1, X_2, \cdots$ 与Y相互独立。求证：

(1) $E(X_1 + X_2 + \cdots + X_Y) = EXEY$.

(2) $\mathrm{var}(X_1 + X_2 + \cdots + X_Y) = \mathrm{var}(Y)(EX)^2 + EY\mathrm{var}(X)$.

证明：(1)

$$\begin{aligned} E(X_1 + X_2 + \cdots + X_Y) &= E\big(E(X_1 + X_2 + \cdots + X_Y|Y)\big) \\ &= E\big(E(YX|Y)\big) \\ &= E\big(YE(X)\big) \\ &= EXEY, \end{aligned}$$

其中第1个等号是根据双期望公式，第2个等号由于$X_1, X_2, \cdots$独立同分布且与X有相同分布，第3个等号由于定理4.2，第4个等号由于期望的性质1.

(2) 由定理4.3, 有

$$\begin{aligned}
& \operatorname{var}(X_1 + X_2 + \cdots + X_Y) \\
= \; & \operatorname{var}\big(E(X_1 + X_2 + \cdots + X_Y|Y)\big) + E\big(\operatorname{var}(X_1 + X_2 + \cdots + X_Y|Y)\big) \\
= \; & \operatorname{var}\big(E(YX|Y)\big) + E\big(\operatorname{var}(YX|Y)\big) \\
= \; & \operatorname{var}\big(YE(X)\big) + E\big(Y\operatorname{var}(X)\big) \\
= \; & \operatorname{var}(Y)(EX)^2 + EY \cdot \operatorname{var}(X).
\end{aligned}$$

4.4 协方差和相关系数

除了数学期望，对于多元随机变量而言，还有一类刻画各个分量之间关系的数字特征，它们是协方差和相关系数。为叙述方便，本节以二元随机变量$(X,Y)^\top$例进行介绍。

协方差：对二元随机变量$(X,Y)^\top$, 称

$$\mathrm{cov}(X,Y)=E[(X-EX)(Y-EY)]$$

为X与Y的协方差。显然有

$$\mathrm{cov}(X,Y)=E(XY)-EXEY, \mathrm{var}(X)=\mathrm{cov}(X,X), \mathrm{cov}(X,Y)=\mathrm{cov}(Y,X).$$

协方差的性质

性质1 令随机变量X,Y相互独立，则$\mathrm{cov}(X,Y)=0$.

性质2 令n+m个随机变量$X_1,X_2,\cdots,X_n,Y_1,Y_2,\cdots,Y_m$. 对任意实数$a_1,a_2,\cdots,a_n$, $b_1,b_2,\cdots,b_m$, 有

$$\mathrm{cov}\left(\sum_{i=1}^{n}a_iX_i,\sum_{j=1}^{m}b_jY_j\right)=\sum_{i=1}^{n}\sum_{j=1}^{m}a_ib_j\mathrm{cov}(X_i,Y_j).$$

性质3 (1)**Cauchy-Schwarz不等式** (Schwarz, 1843-1921)

$$[\mathrm{cov}(X,Y)]^2\le \mathrm{var}(X)\mathrm{var}(Y).$$

等号成立当且仅存在常数a,b使得$P(Y=a+bX)=1$.

(2)$(EXY)^2\le EX^2EY^2$.

证明： 对任意$t\in R$, 有$E[t(X-EX)-(Y-EY)]^2\ge 0$. 展开得

$$E[t^2(X-EX)^2-2t(X-EX)(Y-EY)+(Y-EY)^2]\ge 0,$$

$$E(X-EX)^2\times t^2-2E(X-EX)(Y-EY)\times t+E(Y-EY)^2\ge 0.$$

这是关于t的二次方程，且对任意t都成立。因此，

$$\Delta=4[E(X-EX)(Y-EY)]^2-4E(X-EX)^2E(Y-EY)^2\le 0,$$

即

$$[E(X-EX)(Y-EY)]^2\le (X-EX)^2E(Y-EY)^2\le 0.$$

即

$$[\mathrm{cov}(X,Y)]^2\le \mathrm{var}(X)\mathrm{var}(Y).$$

等号成立当且仅当$P\big(t(X-EX)-(Y-EY)=0\big)=1$, 即

$$P\big(Y=tX-tEX+EY\big)=1.$$

令$a=-tEX+EY, b=t$即可。

(2)同理，考察t的二次函数$E(tX-Y)^2$即可。

例4.11 (考察第一章例1.14) 某班有n名同学，一次考试阅卷结束后，老师随机把试卷发给同学们。记拿到自己试卷的学生数为X. 求$EX, \mathrm{var}(X)$.

解：对n名同学编号为$1,2,\cdots,n$. 对$i=1,2,\cdots,n$, 记随机变量

$$X_i=\begin{cases}1, & \text{第}i\text{名同学拿到自己的试卷，}\\ 0, & \text{第}i\text{名同学没有拿到自己的试卷。}\end{cases}$$

有

$$P(X_i=1)=\frac{1}{n}, P(X_i=0)=\frac{n-1}{n}, EX_i=\frac{1}{n}, \mathrm{var}(X_i)=\frac{n-1}{n^2},$$

$$EX=E\sum_{i=1}^{n}X_i=\sum_{i=1}^{n}\frac{1}{n}=1.$$

$$\mathrm{var}(X)=\sum_{i=1}^{n}\mathrm{var}(X_i)+2\sum_{i=1}^{n-1}\sum_{j=i}^{n}\mathrm{cov}(X_i,X_j).$$

下面求$\mathrm{cov}(X_i,X_j)$.

$$\begin{aligned}\mathrm{cov}(X_i,X_j) &= EX_iX_j-EX_iEX_j\\ &= P(X_i=1,X_j=1)-\frac{1}{n^2}\\ &= P(X_j=1|X_i=1)P(X_i=1)-\frac{1}{n^2}\\ &= \frac{1}{n-1}\frac{1}{n}-\frac{1}{n^2}\\ &= \frac{1}{n^2(n-1)}.\end{aligned}$$

因此，$\mathrm{var}(X)=1$.

相关系数：对二元随机变量$(X,Y)^\top$, 称

$$\rho_{X,Y}=\frac{\mathrm{cov}(X,Y)}{\sqrt{\mathrm{var}(X)}\sqrt{\mathrm{var}(Y)}}$$

为X与Y的相关系数。当$\rho_{X,Y}=0$时，称X与Y不相关。

由定义可以看出：

$$\rho_{X,Y}=\mathrm{cov}\left(\frac{X-EX}{\sqrt{\mathrm{var}(X)}},\frac{Y-EY}{\sqrt{\mathrm{var}(Y)}}\right).$$

因此，形式上可以把相关系数视为“标准尺度下的协方差”。从这个角度上说，相关系数可以更好的反映两个随机变量之间的关系，而不受它们各自所用计量单位的影响。

相关系数的性质

性质1 若X和Y相互独立，则$\rho_{X,Y}=0$.

性质2 $|\rho_{X,Y}|\leq 1$. 若$\rho_{X,Y}>0$, 称X与Y正相关，若$\rho_{X,Y}<0$, 称X与Y负相关，若$\rho_{X,Y}=0$, 称X与Y不相关；且

$$若\rho_{X,Y}=1, 则存在a>0, b\in\mathcal{R}, 使得P(Y=a+bX)=1\ (正相关);$$

$$若\rho_{X,Y}=-1, 则存在a<0, b\in\mathcal{R}, 使得P(Y=a+bX)=1\ (负相关).$$

证明： 由协方差性质3知$|\rho_{X,Y}|\leq 1$. 若$\rho_{X,Y}=1$, 有

$$\mathrm{var}\left(\frac{X}{\sqrt{\mathrm{var}(X)}}-\frac{Y}{\sqrt{\mathrm{var}(Y)}}\right)=2-2\rho_{X,Y}=0.$$

故存在常数c, 使得

$$P\left(\frac{X}{\sqrt{\mathrm{var}(X)}}-\frac{Y}{\sqrt{\mathrm{var}(Y)}}=c\right)=1.$$

所以，

$$P\left(Y=-c\sqrt{\mathrm{var}(Y)}+\frac{\sqrt{\mathrm{var}(Y)}}{\sqrt{\mathrm{var}(X)}}X\right)=1.$$

记$a=-c\sqrt{\mathrm{var}(Y)}, b=\frac{\sqrt{\mathrm{var}(Y)}}{\sqrt{\mathrm{var}(X)}}$即可。

同理可得当$\rho_{X,Y}=1$时对应的结论。

常称$\rho_{X,Y}$为X和Y线性相关系数，它刻画了X和Y之间的线性相关程度。$|\rho_{X,Y}|$越接近1，表明X,Y间的线性相关程度越高；$\rho_{X,Y}=0$只是表明X和Y之间不存在线性相关，但可能存在非线性的函数关系。

例4.12 令$(X,Y)^\top\sim N(\mu_1,\mu_2,\sigma_1^2,\sigma_2^2,\rho)$. 则$\rho_{X,Y}=\rho$.

证明： 由于$(X,Y)^\top$服从二元正态分布，则其边缘分布为正态分布，即

$$X\sim N(\mu_1,\sigma_1^2),\ \ Y\sim N(\mu_2,\sigma_2^2),$$

从而

$$E(X)=\mu_1,\ \mathrm{var}(X)=\sigma_1^2,\ \ E(Y)=\mu_2,\ \mathrm{var}(Y)=\sigma_2^2.$$

根据例4.7，有$E(XY)=\mu_1\mu_2+\rho\sigma_1\sigma_2$, 且$\mathrm{cov}(X,Y)=E(XY)-EXEY=\rho\sigma_1\sigma_2$, 那么

$$\rho_{X,Y}=\frac{\mathrm{cov}(X,Y)}{\sqrt{\mathrm{var}(X)}\sqrt{\mathrm{var}(Y)}}=\rho.$$

例4.13 令$X\sim U\left(-\frac{1}{2},\frac{1}{2}\right)$, $Y=\cos X$. 求$\rho_{X,Y}$.

解： $EX=0$,

$$\mathrm{cov}(X,Y)=EXY-EXEY=EXY=\int_{-1/2}^{1/2}x\cos x dx=0$$

所以X,Y不相关，显然X与Y存在着非线性关系。

下面的定理给出了独立和不相关之间的关系。

定理4.4 对随机变量X,Y, 如果X与Y相互独立，则它们一定不相关；反之不成立，即它们不相关则未必相互独立。

例4.14 若$(X,Y)^\top$服从单位圆内的均匀分布，则X,Y不相关但不独立。

解：$(X,Y)^\top$的联合密度函数为

$$f(x,y)=\begin{cases}\frac{1}{\pi} & x^2+y^2\le 1,\\ 0 & \text{其它},\end{cases}$$

X的边缘密度函数为$f_X(x)=\frac{2}{\pi}\sqrt{1-x^2},-1\le x\le 1$，
Y的边缘密度函数为$f_Y(y)=\frac{2}{\pi}\sqrt{1-y^2},-1\le y\le 1.$
从而有$EX=EY=0$, 且

$$EXY=\int_{-1}^{1}x\int_{-\sqrt{1-x^2}}^{\sqrt{1-x^2}}\frac{1}{\pi}ydydx=0.$$

因此，$\mathrm{cov}(X,Y)=0$, $\rho_{X,Y}=0$, 即X,Y不相关。由$f(x,y)\neq f_X(x)f_Y(y)$可知X,Y不独立。

二元正态随机变量$(X,Y)^\top\sim N(\mu_1,\mu_2,\sigma_1^2,\sigma_2^2,\rho)$中的$\rho$代表正态随机变量$X$与$Y$的之间的相关系数，且$X,Y$相互独立等价于$\rho_{X,Y}=0$, 例3.13已证明了这个结论. 事实上，**若分布是多元正态分布，不相关与独立也是等价的。**

例4.15 令随机变量X,Y均只取0和1两个值。求证：X,Y独立等价于$\rho_{X,Y}=0$.

证明：必要性显然。下面证明充分性。令

$$p=P(X=1),q=P(Y=1),a=P(X=0,Y=0).$$

X,Y的联合概率分布如下表

$X\backslash Y$	0	1	列和
0	a	$1-p-a$	$1-p$
1	$1-q-a$	$q+p-1+a$	p
行和	$1-q$	q	1

易知

$$E(XY)=q+p-1+a,\ EXEY=pq.$$

由$\rho_{X,Y}=0$知$E(XY)=EXEY$. 因此，

$$q+p-1+a=pq.$$

得

$$a=(1-p)(1-q)=P(X=0,Y=0).$$

进一步有

$$\begin{aligned} P(X=0,Y=1) &= (1-p)q, \\ P(X=1,Y=0) &= p(1-q), \\ P(X=1,Y=1) &= pq. \end{aligned}$$

所以，X,Y独立。

针对两个以上的多元随机变量，常用协方差矩阵表示它们之间的关系。

协方差矩阵：令$X=(X_1,X_2,\cdots,X_n)^\top$, $Y=(Y_1,Y_2,\cdots,Y_m)^\top$. 称

$$\begin{aligned} \mathrm{cov}(X,Y) &= E[(X-EX)(Y-EY)^\top] \\ &= \begin{pmatrix} \mathrm{cov}(X_1,Y_1) & \mathrm{cov}(X_1,Y_2) & \cdots & \mathrm{cov}(X_1,Y_m) \\ \mathrm{cov}(X_2,Y_1) & \mathrm{cov}(X_2,Y_2) & \cdots & \mathrm{cov}(X_2,Y_m) \\ \vdots & \vdots & & \vdots \\ \mathrm{cov}(X_n,Y_1) & \mathrm{cov}(X_n,Y_2) & \cdots & \mathrm{cov}(X_n,Y_m) \end{pmatrix} \end{aligned}$$

为X和Y的协方差矩阵。特别地，当$Y=X$时，称$\mathrm{cov}(X,X)$为X的方差矩阵，常记作$\mathrm{var}(X)$, 即

$$\begin{aligned} \mathrm{var}(X) &= \mathrm{cov}(X,X) \\ &= E[(X-EX)(X-EX)^\top] \\ &= \begin{pmatrix} \mathrm{var}(X_1) & \mathrm{cov}(X_1,X_2) & \cdots & \mathrm{cov}(X_1,X_n) \\ \mathrm{cov}(X_2,X_1) & \mathrm{var}(X_2) & \cdots & \mathrm{cov}(X_2,X_n) \\ \vdots & \vdots & & \vdots \\ \mathrm{cov}(X_n,X_1) & \mathrm{cov}(X_n,X_2) & \cdots & \mathrm{var}(X_n). \end{pmatrix} \end{aligned}$$

协方差矩阵的性质

性质1 令X和Y分别为n和m元随机变量，$\mathbf{A}$为$m\times n$非随机矩阵，$Z=\mathbf{A}X+Y$. 则

$$EZ=\mathbf{A}EX+EY.$$

性质2 令X和Y分别是n和m元随机变量，$\mathbf{A}$和$\mathbf{B}$分别为$p\times n$和$q\times m$非随机矩阵。则

$$\mathrm{cov}(\mathbf{A}X,\mathbf{B}Y)=\mathbf{A}\mathrm{cov}(X,Y)\mathbf{B}^\top.$$

性质3 令X为n元随机变量。则$\mathrm{var}(X)$ 是正定对阵矩阵。

证明：对称性显然。对任意$n\times 1$非随机向量$\mathbf{c}$, $\mathbf{c}\neq\mathbf{0}_n$, 有

$$\begin{aligned} \mathbf{c}^\top\mathrm{cov}(X)\mathbf{c} &= \mathbf{c}^\top E[(X-EX)(X-EX)^\top]\mathbf{c} \\ &= E[\mathbf{c}^\top(X-EX)(X-EX)^\top\mathbf{c}] \\ &= E[(\mathbf{c}^\top X-E\mathbf{c}^\top X)^2] \\ &= \mathrm{var}(\mathbf{c}^\top X) \\ &> 0. \end{aligned}$$

性质4 令$X=(X_1,X_2,\cdots,X_n)^\top$为$n$元随机变量，$\mathbf{A}=(a_{ij})_{n\times n}$是对称非随机矩阵。称

$$X^\top\mathbf{A}X=\sum_{i=1}^n\sum_{j=1}^n a_{ij}X_iX_j$$

为X的**二次型**。记$EX=\boldsymbol{\mu}$, $\mathrm{var}(X)=\boldsymbol{\Delta}$. 则

$$E(X^\top\mathbf{A}X)=\mu^\top\mathbf{A}\mu+\mathrm{tr}(\mathbf{A}\boldsymbol{\Delta}).$$

证明：由于

$$\begin{aligned}X^\top\mathbf{A}X &= (X-\boldsymbol{\mu}+\boldsymbol{\mu})^\top\mathbf{A}(X-\boldsymbol{\mu}+\boldsymbol{\mu})\\ &= (X-\boldsymbol{\mu})^\top A(X-\boldsymbol{\mu})+\boldsymbol{\mu}^\top\mathbf{A}(X-\boldsymbol{\mu})+(X-\boldsymbol{\mu})^\top\mathbf{A}\boldsymbol{\mu}+\boldsymbol{\mu}^\top\mathbf{A}\boldsymbol{\mu}.\end{aligned}$$

两边取期望，利用迹的可交换性得

$$\begin{aligned}E(X^\top\mathbf{A}X) &= E\big[(X-\boldsymbol{\mu})^\top A(X-\boldsymbol{\mu})\big]+E\big[\boldsymbol{\mu}^\top\mathbf{A}(X-\boldsymbol{\mu})\big]+E\big[(X-\boldsymbol{\mu})^\top\mathbf{A}\boldsymbol{\mu}\big]+\boldsymbol{\mu}^\top\mathbf{A}\boldsymbol{\mu}\\ &= E\mathrm{tr}\big[(X-\boldsymbol{\mu})^\top A(X-\boldsymbol{\mu})\big]+\boldsymbol{\mu}^\top\mathbf{A}\boldsymbol{\mu}\\ &= E\mathrm{tr}\big[A(X-\boldsymbol{\mu})(X-\boldsymbol{\mu})^\top\big]+\boldsymbol{\mu}^\top\mathbf{A}\boldsymbol{\mu}\\ &= \mathrm{tr}\Big(E\big[A(X-\boldsymbol{\mu})(X-\boldsymbol{\mu})^\top\big]\Big)+\boldsymbol{\mu}^\top\mathbf{A}\boldsymbol{\mu}\\ &= \mu^\top\mathbf{A}\mu+\mathrm{tr}(\mathbf{A}\boldsymbol{\Delta}).\end{aligned}$$

例4.16 令$X\sim Mul(N,p_1,p_2,\cdots,p_n)$. 则

$$\mathrm{var}(X)=\begin{pmatrix}Np_1(1-p_1) & -Np_1p_2 & \cdots & -Np_1p_n\\ -Np_1p_2 & -Np_2(1-p_2) & \cdots & -Np_2p_n\\ \vdots & \vdots & \ddots & \vdots\\ -Np_np_1 & -Np_np_2 & \cdots & Np_n(1-p_n)\end{pmatrix}.$$

证明：记$X=(X_1,X_2,\cdots,X_n)^\top$, 有

$$EX_i=Np_i,\ \mathrm{var}(X_i)=Np_i(1-p_i),i=1,2,\cdots,n.$$

对$1\le i\ne j\le n$,

$$\begin{aligned}EX_iX_j &= \sum_{n_i}\sum_{n_j}n_in_j\tfrac{N!}{n_i!n_j!}p_i^{n_i}p_j^{n_j}(1-p_i-p_j)^{N-n_i-n_j}(\text{求和满足}n_i+n_j\le N)\\ &= N(N-1)p_ip_j\sum_{n_i}\sum_{n_j}\tfrac{(N-2)!}{(n_i-1)!(n_j-1)!}p_i^{n_i-1}p_j^{n_j-1}(1-p_i-p_j)^{N-n_i-n_j}\\ &= N(N-1)p_ip_j.\end{aligned}$$

因此，对$i\ne j\in\{1,2,\cdots,n\}$,

$$\mathrm{cov}(X_i,X_j)=E(X_iX_j)-EX_iEX_j=N(N-1)p_ip_j-Np_iNp_j=-Np_ip_j.$$

例4.17 令$X\sim N(\boldsymbol{\mu},\boldsymbol{\Delta})$, $\mathbf{A}$为$n\times n$非随机矩阵。求证：

$$\mathrm{var}(X)=E(X-\boldsymbol{\mu})(X-\boldsymbol{\mu})^\top=\boldsymbol{\Delta}.$$

证明： 记$Y=\boldsymbol{\Delta}^{-\frac{1}{2}}(X-\boldsymbol{\mu})$, 得

$$X=\boldsymbol{\Delta}^{\frac{1}{2}}Y+\boldsymbol{\mu}.$$

X对Y求导的Jaccobi行列式为

$$J=\det\left(\boldsymbol{\Delta}^{\frac{1}{2}}\right)=\det\left(\boldsymbol{\Delta}\right)^{\frac{1}{2}}.$$

于是Y的密度函数为

$$g(y)=f\left(\boldsymbol{\Delta}^{\frac{1}{2}}y+\boldsymbol{\mu}\right)|J|=\prod_{i=1}^{n}\frac{1}{\sqrt{2\pi}}e^{-\frac{y_i^2}{2}},y=(y_1,y_2,\cdots,y_n)^{\top},$$

$\mathrm{cov}(Y)=\mathbf{I}_n$. 再利用协方差矩阵的性质2得证。

4.5 其它数字特征

除了均值、方差、协方差之外，随机变量还有许多其它数字特征，这里只介绍分位数、特征函数、中心矩、原点矩、偏度系数和峰度系数。

分位数： 令连续型随机变量$X \sim F(x)$. 对$0 < \alpha < 1$,

$$F(q_\alpha) = P(X \le q_\alpha) = \alpha.$$

称q_α为分布函数$F(x)$的α分位数或者X的α分位数。

令X的密度函数为$f(x)$, 则$F(q_\alpha) = \int_{-\infty}^{q_\alpha} f(x)\mathrm{d}x = \alpha$.

当$\alpha = 0.5$时，称q_α为中位数，它刻画随机变量取值的“中心位置”。若随机变量X的密度函数$f(x)$是对称的，中位数和均值是相等的，如正态分布$N(\mu, \sigma^2)$，均值和中位数都是μ. [0,1]上的均匀分布的中位数为0.5, 参数为λ的指数分布的中位数为$\ln 2/\lambda$, 即它是方程$\int_0^m \lambda e^{-\lambda x}dx = 1 - e^{-\lambda m} = 1/2$ 的解。

例4.18 令m为连续随机变量X的中位数。则$m = \arg\min_\xi E|X - \xi|$.

证明： 记X的密度函数为$f(x)$. 当$\xi > m$时, 有

$$\begin{aligned}
E|X-\xi| - E|X-m| &= \int_{-\infty}^{\infty} \big[|x-\xi| - |x-m|\big] f(x)dx \\
&= \int_{-\infty}^{m} \big[|x-\xi| - |x-m|\big] f(x)dx \\
&\quad + \int_{m}^{\infty} \big[|x-\xi| - |x-m|\big] f(x)dx \\
&= \int_{-\infty}^{m} [\xi - x - m + x] f(x)dx \\
&\quad + \int_{m}^{\infty} \big[|x-\xi| - |x-m|\big] f(x)dx \\
&\ge \frac{1}{2}(\xi - m) - \int_{m}^{\infty} (\xi - m) f(x)dx \\
&= 0.
\end{aligned}$$

因此，$E|X-\xi| > E|X-m|$. 同理当$\xi < m$时，$E|X-\xi| > E|X-m|$. 从而$m = \arg\min_\xi E|X-\xi|$.

中位数有着许多实际的应用。尤其针对不少社会统计资料，有时中位数比均值更好。比如，考察某社区内居民的收入，中位数可以直观地告诉我们：有一半人的收入低于此值，一半人高于此值，不受某居民收入特别高或者特别低的影响。

上述分位数的定义是针对连续型随机变量定义的，对于离散型随机变量不易定义，下面以$\alpha = 0.5$为例说明。

例4.19 令随机变量$X \sim B(1, \frac{1}{2})$. 求X的中位数。

解：X的分布函数为

$$F(x)=\begin{cases}0 & x<0,\\ \frac{1}{2} & 0\le x<1,\\ 1 & x\ge 1.\end{cases}$$

由中位数的定义知区间$[0,1)$内的每一个数都是X的中位数。

例4.20 令随机变量X的概率函数为：

$$P(X=-1)=\frac{1}{5},\ P(X=0)=\frac{2}{5},\ \ P(X=1)=\frac{2}{5}.$$

求X的中位数。

解：不存在m，满足m两边的概率相等。我们可以找一点m, 使其两边的概率差最小，即$m=0$.

下面介绍k阶中心矩、原点矩、偏度系数和峰度系数。

k阶中心矩和原点矩： 令X为一元随机变量，称$E(X-EX)^k$和EX^k分别为X的k阶中心矩和k阶原点矩，其中k为正整数。

一阶原点矩是期望，二阶中心矩是方差。

例4.21 令$X\sim N(\mu,\sigma^2)$. 求$E(X-\mu)^k$.

解：$X-\mu\sim N(0,\sigma^2)$.

$$\begin{aligned}E(X-\mu)^k &= \frac{1}{\sqrt{2\pi}\sigma}\int_{-\infty}^{\infty}x^k\exp\Big(-\frac{x^2}{2\sigma^2}\Big)dx\\ &= \frac{\sigma^k}{\sqrt{\pi}}\int_{-\infty}^{\infty}u^k\exp\Big(-\frac{u^2}{2}\Big)du.\end{aligned}$$

当k为奇数时，$EX^k=0$.

当k为偶数时，$EX^k=\sigma^k(k-1)(k-3)\cdots 1$.

偏度系数和峰度系数是刻画随机变量的分布形状的数字特征。

偏度系数： 令随机变量X的前三阶矩都存在。称

$$\beta_1=\frac{E(X-EX)^3}{[E(X-EX)^2]^{3/2}}$$

为X的偏度系数.

偏度系数度量了一个分布是不是有偏的。显然，一个关于某点对称的分布的偏度系数为0. 若$\beta_1>0$, 称该分布为右偏的，反之若$\beta_1<0$，称该分布为左偏的。对正态分布而言，$\beta_1=0$。

峰度系数： 令一元随机变量X的前四阶矩都存在。称

$$\beta_2=\frac{E(X-EX)^4}{[E(X-EX)^2]^2}$$

为X的峰度系数。

峰度系数度量了一个分布在均值附近的陡峭程度，若X取值集中在EX附近，则ν_4倾向于取大值，反之ν_4倾向于取小值。

令$X \sim U(a,b)$, 则$\beta_1 = 0,\ \beta_2 = 1.8$.

令$X \sim N(\mu, \sigma^2)$, 则$\beta_1 = 0,\ \beta_2 = 3$.

令$X \sim Exp(\lambda)$, 则$\beta_1 = 2,\ \beta_2 = 9$.

令$X \sim Gamma(\xi, \lambda)$, 则$\beta_1 = 2/\sqrt{\xi},\ \beta_2 = 3 + 6/\xi$.

在介绍特征函数之前，我们先介绍复随机变量和复随机变量的数学期望。

复随机变量：令X, Y为随机变量，i为虚数单位，称$X + iY$为复随机变量。

复随机变量的数学期望： 令X, Y为随机变量，i为虚数单位，称

$$E(X + iY) = EX + iEY$$

为$X + iY$的数学期望。

特征函数：令X是一个随机变量，对于任意$t \in \mathcal{R}$, 称

$$\psi(t) = Ee^{itX},$$

为X的特征函数。

对于离散型随机变量X，若$p_i = P(X = a_i), i = 1, 2, \cdots, n.$ X的特征函数为

$$\psi(t) = \sum_{i=1}^{n} p_i e^{ita_i}.$$

对于连续型随机变量，若其密度函数为$f(x)$, 则特征函数为

$$\psi(t) = \int_{-\infty}^{\infty} e^{itx} f(x) dx.$$

可见特征函数是密度函数的傅里叶(Fourier, 1768-1830)变换。从特征函数的定义可以看出，两个相互独立的随机变量之和的特征函数等于它们的特征函数之积。

多元特征函数：令n元随机变量

$$X = (X_1, X_2, \cdots, X_n)^\top \sim F(x_1, x_2, \cdots, x_n).$$

X的特征函数为

$$\psi(t_1, t_2, \cdots, t_n) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} e^{i(t_1 x_1 + t_2 x_2 + \cdots + t_n x_n)} dF(x_1, x_2, \cdots, x_n).$$

若$(X_1, X_2, \cdots, X_n)^\top$的特征函数为$\psi(t_1, t_2, \cdots, t_n)$, 则$k$维随机变量$(X_1, X_2, \cdots, X_k)^\top$的特征函数为$\psi(t_1, t_2, \cdots, t_k, 0, \cdots, 0)$.

需要指出的是：**随机变量的特征函数和分布函数相互唯一确定**。

正态分布的特征函数：$\psi(t) = e^{i\mu t - \frac{1}{2}\sigma^2 t^2}$.

令$Z_1, Z_2, \cdots, Z_n$独立同分布服从标准正态分布$N(0,1)$, $Z = (Z_1, Z_2, \cdots, Z_n)^\top$. 则$Z$的特征函数为

$$\psi_Z(u) = Ee^{iu^\top Z} = \prod_{i=1}^{n} Ee^{iu_i Z_i} = e^{-\frac{1}{2}u^\top u},\ u = (u_1, u_2, \cdots, u_n)^\top \in \mathcal{R}^n.$$

若$X \sim N(\boldsymbol{\mu}, \boldsymbol{\Delta})$. 则$X$的特征函数为

$$\begin{aligned}
\psi_X(t) &= Ee^{it^\top X} \\
&= Ee^{it^\top(\boldsymbol{\mu}+\boldsymbol{\Delta}^{\frac{1}{2}}Z)} \\
&= E(e^{it^\top\boldsymbol{\mu}} \times e^{it^\top\boldsymbol{\Delta}^{\frac{1}{2}}Z}) \\
&= e^{it^\top\boldsymbol{\mu}} \times E(e^{it^\top\boldsymbol{\Delta}^{\frac{1}{2}}Z}) \\
&= e^{it^\top\boldsymbol{\mu}}\psi_Z(\boldsymbol{\Delta}^{\frac{1}{2}}t) \\
&= \exp\left\{it^\top\boldsymbol{\mu} - \tfrac{1}{2}t^\top\boldsymbol{\Delta}t\right\}.
\end{aligned}$$

定理4.5 令X是n元随机变量，X服从多元正态分布的充分必要条件是它的任意线性函数$\mathbf{c}^\top X$ 服从一元正态分布，$\mathbf{c} \neq \mathbf{0}_n$.

证明： 必要性显然。现证充分性。

记$EX = \boldsymbol{\mu}$, $\mathrm{cov}(X) = \boldsymbol{\Delta}$, 有

$$\mathbf{c}^\top X \sim N(\mathbf{c}^\top\boldsymbol{\mu}, \mathbf{c}^\top\boldsymbol{\Delta}\mathbf{c}).$$

$\mathbf{c}^\top X$的特征函数为

$$\psi_{\mathbf{c}^\top X}(t) = \exp\left\{it\mathbf{c}^\top\boldsymbol{\mu} - \frac{t^2}{2}\mathbf{c}^\top\boldsymbol{\Delta}c\right\}.$$

取$t = 1$, 得到X的特征函数为

$$\psi_X(\mathbf{c}) = Ee^{i\mathbf{c}^\top X} = \psi_{\mathbf{c}^\top X}(1) = \exp\left\{ia^\top\boldsymbol{\mu} - \frac{1}{2}\mathbf{c}^\top\boldsymbol{\Delta}c\right\}.$$

它是多元正态分布的特征函数。由特征函数和分布函数一一对应可知，X服从多元正态分布。

例4.22 令$X_1, X_2, \cdots, X_n$相互独立，X_i的特征函数为$\psi_{X_i}(t)$, $i = 1, 2, \cdots, n$, $X_1 + X_2 + \cdots + X_n$的特征函数$\psi_{X_1+\cdots+X_n}(t)$. 求证：$\psi_{X_1+\cdots+X_n}(t) = \prod_{i=1}^{n}\psi_{X_i}(t)$.

证明：由特征函数的定义和期望的性质4知

$$\psi_{X_1+\cdots+X_n}(t) = Ee^{it(X_1+\cdots+X_n)} = Ee^{itX_1}\cdots Ee^{itX_n} = \prod_{i=1}^{n}\psi_{X_i}(t).$$

注意：期望的性质4(独立随机变量乘积的期望等于期望的乘积)对复随机变量也对。

4.6 大数定律

随机抛掷一枚质地均匀的硬币，用S_n表示抛n次硬币得到的正面朝上的次数，那么正面朝上的频率S_n/n会随着n的增加会趋于一个常数。这涉及随机变量序列的收敛性。

4.6.1 序列收敛

下面定义随机变量序列的四种收敛性。

几乎处处收敛：令$X_1, X_2, \cdots$ 是一随机变量序列，X是一随机变量。若

$$P\left(\lim_{n\to\infty} X_n = X\right) = P\left(\left\{\omega \middle| \lim_{n\to\infty} X_n(\omega) = X(\omega)\right\}\right) = 1,$$

称$X_1, X_2, \cdots$ 几乎处处收敛于X, 记作$X_n \xrightarrow{a.e.} X$ (almost everywhere)，或者$X_n \xrightarrow{a.s.} X$(almost surely)。

下面给出几乎处处收敛的另外两种概率表示：$X_n \xrightarrow{a.e.} X$ 等价于

$$P\left(\bigcap_{\varepsilon>0}\bigcup_{n=1}^{\infty}\bigcap_{i=n}^{\infty}\{|X_i - X| < \varepsilon\}\right) = P\left(\bigcap_{\varepsilon>0}\bigcup_{n=1}^{\infty}\bigcap_{i=n}^{\infty}\{\omega||X_i(\omega) - X(\omega)| < \varepsilon\}\right) = 1,$$

或

$$P\left(\bigcup_{\varepsilon>0}\bigcap_{n=1}^{\infty}\bigcup_{i=n}^{\infty}\{|X_i - X| \geq \varepsilon\}\right) = P\left(\bigcup_{\varepsilon>0}\bigcap_{n=1}^{\infty}\bigcup_{i=n}^{\infty}\{\omega||X_i(\omega) - X(\omega)| \geq \varepsilon\}\right) = 0,$$

上面两式分别等价于，对任意$\varepsilon > 0$,

$$\lim_{n\to\infty} P\left(\bigcap_{i=n}^{\infty}\{|X_i - X| < \varepsilon\}\right) = 1, \tag{4.1}$$

或

$$\lim_{n\to\infty} P\left(\bigcup_{i=n}^{\infty}\{|X_i - X| \geq \varepsilon\}\right) = 0. \tag{4.2}$$

验证一个随机变量序列是否几乎处处收敛到一个给定的随机变量，只要验证(4.1)或(4.2)成立即可。

依概率收敛：令$X_1, X_2, \cdots$ 是一随机变量序列，X是一随机变量。若对任何$\varepsilon > 0$, 有

$$\lim_{n\to\infty} P(|X_n - X| \geq \varepsilon) = 0,$$

成立，称$X_1, X_2, \cdots$ 依概率收敛于X,记作$X_n \xrightarrow{p} X$.

依分布收敛：令$X_1, X_2, \cdots$ 是一随机变量序列，X是一随机变量。若对X的分布函数$F(x)$的任何连续点x, 都有

$$\lim_{n\to\infty} P(X_n \leq x) = P(X \leq x),$$

成立，称$X_1, X_2, \cdots$ 依分布收敛于X, 记作$X_n \xrightarrow{d} X$.

r次平均收敛：令$X_1, X_2, \cdots$是一随机变量序列，X是一随机变量。若当$n \to \infty$时，

$$E|X_n - X|^r \to 0.$$

称$X_1, X_2, \cdots$ **r次平均收敛**于X, 记作$X_n \xrightarrow{r} X$. $r = 2$ 也称为均方收敛。

下面给出上述四种收敛之间的的关系。

定理4.6 令$X_1, X_2, \cdots$ 是一随机变量序列，X是一随机变量。则

$$X_n \xrightarrow{a.e.} X \Longrightarrow X_n \xrightarrow{p} X,$$

$$X_n \xrightarrow{r} X \Longrightarrow X_n \xrightarrow{p} X.$$

证明：根据$X_n \xrightarrow{a.e.} X$的等价概率表达式，显然有$X_n \xrightarrow{a.e.} X \Longrightarrow X_n \xrightarrow{p} X$.

记$X_n - X$的分布函数为$G_n(x)$. 对任意$\varepsilon > 0$,

$$\begin{aligned} P(|X_n - X| \geq \varepsilon) &= \int_{\{x:|x|\geq\varepsilon\}} dG_n(x) \\ &\leq \int_{\{x:|x|\geq\varepsilon\}} \frac{|x|^r}{\varepsilon^r} dG_n(x) \\ &\leq \frac{1}{\varepsilon^r} \int_{-\infty}^{\infty} |x|^r dG_n(x) \\ &= \frac{E|X_n - X|^r}{\varepsilon^r}. \end{aligned}$$

不等式$P(|X_n - X| \geq \varepsilon) \leq \frac{E|X_n - X|^r}{\varepsilon^r}$ 称为Markov(1856-1922)不等式。

定理4.7 令$X_1, X_2, \cdots$ 是一随机变量序列，X是一随机变量，有

$$X_n \xrightarrow{p} X \Longrightarrow X_n \xrightarrow{d} X.$$

证明：记X_i的分布函数为$F_i(x)$, $i = 1, 2, \cdots, n$, 及$x_1 < x$. 则

$$\{X \leq x_1\} = \{X_n \leq x, X \leq x_1\} \cup \{X_n > x, X \leq x_1\}$$

由$\{X_n \leq x, X \leq x_1\}$与$\{X_n > x, X \leq x_1\}$互斥，知

$$P\big(X \leq x_1\big) = P\big(X_n \leq x, X \leq x_1\big) + P\big(X_n > x, X \leq x_1\big).$$

又因为$\{X_n \leq x, X \leq x_1\} \subset \{X_n \leq x\}$ 和$\{X_n > x, X \leq x_1\} \subset \{|X_n - X| \geq x - x_1\}$知

$$P\big(X \leq x_1\big) \leq P\big(X_n \leq x\big) + P\big(|X_n - X| > x - x_1\big).$$

即

$$F(x_1) \leq F_n(x) + P(|X_n - X| \geq x - x_1).$$

由$X_n \xrightarrow{p} X$知

$$\lim_{n\to\infty} P(|X_n - X| \geq x - x_1) = 0.$$

因此，当$n \to \infty$, $F(x_1) \le \underline{\lim}_{n\to\infty} F_n(x)$. 令$x_1 \to x$, 得$F(x-0) \le \underline{\lim}_{n\to\infty} F_n(x)$.

同理，记$x_2 > x$, 有

$$\begin{aligned} \{X > x_2\} &= \{X_n \le x, X > x_2\} \cup \{X_n > x, X > x_2\} \\ &\subset \{X_n > x\} \cup \{|X_n - X| \ge x_2 - x\}. \end{aligned}$$

可得

$$1 - F(x_2) \le 1 - F_n(x) + P(|X_n - X| \ge x_2 - x)$$

可得$\overline{\lim}_{n\to\infty} F_n(x) \le F(x+0), n \to \infty$.有上下极限性质知$\lim_{n\to\infty} F_n(x) = F(x)$.

例4.23 (依概率收敛但不几乎处处收敛) 令随机变量$X \sim U(0,1)$. 定义随机变量序列$X_1, X_2, \cdots$如下：

$$\begin{aligned} X_1 &= X + I_{[0,1]}(X), \\ X_2 &= X + I_{[0,1/2]}(X), \\ X_3 &= X + I_{[1/2,1]}(X), \\ X_4 &= X + I_{[0,1/3]}(X), \\ X_5 &= X + I_{[1/3,2/3]}(X), \\ X_6 &= X + I_{[2/3,1]}(X), \\ &\vdots \end{aligned}$$

求证：$X_1, X_2, \cdots$依概率收敛但不几乎处处收敛到X.

证明： 由题意，对任意$\varepsilon > 0$,

$$P(|X_1 - X| > \varepsilon) = P(X \in [0,1]) = 1,$$

$$P(|X_2 - X| > \varepsilon) = P(X \in [0,1/2]) = 1/2,$$

$$P(|X_3 - X| > \varepsilon) = P(X \in [1/2,1]) = 1/2,$$

依次类推，对于$X_n = X + I_c(X)$, 其中c是对应于X_n的定义的区间长度，该长度与n有关。记$O(\sqrt{n})$ 为$\sqrt{n}$的同阶无穷大量，则有$c = 1/O(\sqrt{n})$. 那么

$$\lim_{n\to\infty} P(|X_n - X| > \varepsilon) = \lim_{n\to\infty} 1/O(\sqrt{n}) = 0.$$

于是，$X_1, X_2, \cdots$依概率收敛到x.

由于对$0 < \varepsilon < 1$,

$$\lim_{n\to\infty} P\left(\bigcup_{i=n} |X_i - X| \ge \varepsilon\right) = 1.$$

可知$X_1, X_2, \cdots$不几乎处处收敛到X. 因此，$X_1, X_2, \cdots$依概率收敛到X但不几乎处处收敛到X.

例4.24 (依概率收敛但不r阶平均收敛) 令随机变量$X \in U(0,1)$ 及随机变量序列$Y_1, Y_2, \cdots$

$$Y_n = \begin{cases} n^{\frac{1}{r}}, & 0 < X \le \frac{1}{n}, \\ 0 & \frac{1}{n} < X \le 1. \end{cases}$$

记退化的随机变量$Y \equiv 0$. 那么$Y_n \xrightarrow{p} Y$但Y_n不以r阶平均收敛到Y.

证明： 对任意$\varepsilon > 0$,

$$P(|Y_n - Y| \ge \varepsilon) \le \frac{1}{n}$$

可知$Y_n \xrightarrow{p} X$. 然而

$$E|X_n - X|^r = \left(n^{\frac{1}{r}}\right)^r \frac{1}{n} = 1.$$

即X_n不以r阶平均收敛到X.

例4.25 (依分布收敛但不概率收敛) 令随机变量X的概率函数为

$$P(X = -1) = P(X = 1) = \frac{1}{2}.$$

记$X_n = -X$, $n = 1, 2, \cdots$. 则X_n依分布收敛但不概率收敛到X.

解： 由于X_n与X有相同的分布，因此$X_n \xrightarrow{d} X$.

考察$0 < \varepsilon < 1$,

$$P(|X_n - X| \ge \varepsilon) = P(2|X| \ge \varepsilon) = 1 \ne 0.$$

定理4.8 (连续映射定理) 令$g(x)$是连续函数，$x \in \mathcal{R}$. 则

(1) $X_n \xrightarrow{a.e.} X \Longrightarrow g(X_n) \xrightarrow{a.e.} g(X)$.

(2) $X_n \xrightarrow{p} X \Longrightarrow g(X_n) \xrightarrow{p} g(X)$.

(3) $X_n \xrightarrow{d} X \Longrightarrow g(X_n) \xrightarrow{d} g(X)$.

证明： 仅证明(2)，其它类似。固定一个充分小的$\varepsilon > 0$, 对任意$\delta > 0$, 定义集合

$$C_\delta = \{x \in \mathcal{R} \big| \text{存在} y \in \mathcal{R}, \text{使得当} |x - y| < \delta \text{时，有} |g(x) - g(y)| > \varepsilon\}.$$

由于$g(x)$是$\mathcal{R}$上的连续函数，有$\lim\limits_{\delta \to 0} C_\delta = \phi$, 其中$\phi$表示空集。

把集合$\{|g(X_n) - g(X)| \ge \varepsilon\}$分成两部分，有

$$\begin{aligned} & P\big(|g(X_n) - g(X)| \ge \varepsilon\big) \\ = \;& P(|g(X_n) - g(X)| \ge \varepsilon, |X_n - X| \ge \delta) + P(|g(X_n) - g(X)| \ge \varepsilon, |X_n - X| < \delta) \\ \le \;& P(|X_n - X| \ge \delta) + P(C_\delta) \end{aligned}$$

由于$X_n \xrightarrow{p} X$, 对任意固定的δ, 有$\lim\limits_{n \to \infty} P(|X_n - X| \ge \delta) = 0$. 另外，当$\delta \to 0$时, 有$P(C_\delta) \to P(\phi) = 0$. 从而

$$\lim_{n \to \infty} P\{|g(X_n) - g(X)| \ge \varepsilon\} = 0.$$

定理4.9 (Slustky定理) 令$X_1, X_2, \cdots$ 和$Y_1, Y_2, \cdots$,是两列随机变量序列，X是一随机变量, c是一常数。

(1)$X_n \xrightarrow{d} X, Y_n \xrightarrow{p} c$, 则$X_n + Y_n \xrightarrow{d} X + c$;

(2)$X_n \xrightarrow{d} X, Y_n \xrightarrow{p} c$, 则$X_n Y_n \xrightarrow{d} cX$.

(3)$X_n \xrightarrow{d} X, Y_n \xrightarrow{p} c$ 且$c \neq 0$, 则$X_n / Y_n \xrightarrow{d} X/c$.

证明：这里只证明(1), 其它类似。(1)记X_n+Y_n, X的分布函数分别为$F_{X_n+Y_n}(x)$, $F(x)$. 对任意$\varepsilon > 0$，

$$\begin{aligned} F_{X_n+Y_n}(x) &= P(X_n + Y_n \le x) \\ &= P\Big(\big\{X_n + Y_n \le x\big\} \cap \big\{|Y_n - c| \le \varepsilon\big\}\Big) + P\Big(\big\{X_n + Y_n \le x\big\} \cap \big\{|Y_n - c| > \varepsilon\big\}\Big) \\ &\le P\Big(\big\{X_n + Y_n \le x\big\} \cap \big\{|Y_n - c| \le \varepsilon\big\}\Big) + P\Big(\big\{|Y_n - c| > \varepsilon\big\}\Big) \\ &= P\Big(\big\{X_n + Y_n \le x\big\} \cap \big\{c - \epsilon \le Y_n \le c + \varepsilon\big\}\Big) + P\Big(\big\{|Y_n - c| > \varepsilon\big\}\Big) \\ &\le P\Big(\big\{X_n \le x - c + \varepsilon\big\}\Big) + P\Big(\big\{|Y_n - c| > \varepsilon\big\}\Big) \end{aligned}$$

类似地，由第一章第1.2节加法公式(对任意两个事件A, B, $P(A \cup B) = P(A) + P(B) - P(AB)$)有

$$\begin{aligned} P\big(X_n + Y_n \le x\big) + P(|Y_n - c| > \varepsilon) &= P\big(\{X_n + Y_n \le x\} \cup \{|Y_n - c| > \varepsilon\}\big) \\ &\quad + P\big(\{X_n + Y_n \le x\} \cap \{|Y_n - c| > \varepsilon\}\big) \\ &\ge P\big(\{X_n + Y_n \le x\} \cup \{|Y_n - c| > \varepsilon\}\big) \\ &= P\big(\{X_n + Y_n \le x\} \cup \{Y_n \ge c + \varepsilon\} \cup \{Y_n < c - \varepsilon\}\big) \\ &\ge P\big(\{X_n + Y_n \le x\} \cup \{Y_n \ge c + \varepsilon\}\big) \\ &\ge P(X_n + c + \varepsilon \le x) \end{aligned}$$

得到

$$F_{X_n+Y_n}(x) \ge P(X_n + c + \varepsilon \le x) - P\big(|Y_n - c| > \varepsilon\big).$$

由于$x - c, x - c - \varepsilon, x - c + \epsilon$都是$F_X(x)$的连续点，且$Y_n \xrightarrow{p} c$ 且$X_n \xrightarrow{d} X$, 可得到

$$F_X(x - c - \varepsilon) \le \liminf_{n\to\infty} F_{X_n+Y_n}(x) \le \limsup_{n\to\infty} F_{X_n+Y_n}(x) \le F_X(x - c + \epsilon),$$

令$\varepsilon \to 0$, 有

$$\lim_{n\to\infty} F_{X_n+Y_n}(x) = F_X(x - c),$$

而$F_X(x-c) = P(X \le x-c) = P(X+c \le x) = F_{X+c}(x)$, 从而$X_n + Y_n \xrightarrow{d} X + c$.

4.6.2 大数定律

大数定律：令$X_1, X_2, \cdots$为一随机变量序列。若$\dfrac{1}{n}\sum_{i=1}^{n} X_i$依概率收敛于它的均值$\dfrac{1}{n}\sum_{i=1}^{n} EX_i$, 称$X_1$, X_2, $\cdots$服从弱大数定律，弱大数定律简称大数定律。

若$\frac{1}{n}\sum_{i=1}^{n}X_i$几乎处处收敛于它的均值$\frac{1}{n}\sum_{i=1}^{n}EX_i$, 则称$X_1, X_2, \cdots$服从强大数定律。后面提到大数定律，若不加强调，一般均指弱大数定律。

Chebyshev不等式：(Chebyshev, 1821-1894) 令随机变量X的期望和方差都存在，则对任意$\varepsilon > 0$, 有

$$P(|X - EX| \geq \varepsilon) \leq \frac{\mathrm{var}(X)}{\varepsilon^2}.$$

Chebyshev不等式是Markov不等式在$r = 2$时的特例，证明过程可参照定理4.6.

Chebyshev不等式可以改写为

$$P(|X - EX| < \varepsilon) > 1 - \frac{\mathrm{var}(X)}{\varepsilon^2},$$

或

$$P\left(\left|\frac{X - EX}{\sqrt{\mathrm{var}(X)}}\right| \geq \varepsilon\right) \leq \frac{1}{\varepsilon^2}.$$

针对随机变量序列$X_1, X_2, \cdots$, 由Chebyshev 不等式可知，$\frac{1}{n}\sum_{i=1}^{n}X_i$ 要依概率收敛到$\frac{1}{n}\sum_{i=1}^{n}EX_i$, 只需要下述条件成立：当$n \to \infty$时，有

$$\frac{1}{n^2}\mathrm{var}\left(\sum_{i=1}^{n}X_i\right) \to 0.$$

该条件是由Markov首次提出的，又称Markov条件。

例4.26 对随机变量X, $\mathrm{var}(X) = 0$当且仅当X几乎处处等于某个常数a, 即

$$P(X = a) = 1.$$

证明：充分性显然。下面证明必要性，

$$\begin{aligned} P(|X - EX| > 0) &= P\Big(\bigcup_{n=1}^{\infty}\{|X - EX| \geq \tfrac{1}{n}\}\Big) \\ &\leq \sum_{n=1}^{\infty}P(|X - EX| \geq \frac{1}{n}) \\ &\leq \sum_{n=1}^{\infty}\frac{\mathrm{var}(X)}{(1/n)^2} \\ &= 0. \end{aligned}$$

可知$P(|X - EX| = 0) = 1$. 令$a = EX$, 即$P(X = EX) = 1$.

定理4.10 (Chebyshev大数定律) 令$X_1, X_2, \cdots$ 是**相互独立**且**方差有界**的随机变量序列。则

$$\frac{1}{n}\sum_{i=1}^{n}(X_i - EX_i) \xrightarrow{p} 0.$$

证明： 由题意知，对任意$i \geq 1$, 存在$M > 0$, $\text{var}(X_i) \leq M$. 下面验证Markov条件成立，即

$$\frac{1}{n^2}\text{var}\left(\sum_{i=1}^{n} X_i\right) \leq \frac{1}{n^2}\sum_{i=1}^{n} M = \frac{M}{n} \xrightarrow{n\to\infty} 0.$$

特别地，令$X \sim B(n,\theta)$. X可写成n个独立的0-1分布之和的形式，即$X = \sum_{i=1}^{n} X_i$, 其中$X_1, X_2, \cdots, X_n \; iid \sim B(1,\theta)$, 此时$EX = \theta$. 当$n \to \infty$ 时，有

$$\frac{X}{n} \xrightarrow{p} \theta.$$

定理4.11 (Khinchin大数定律) (Khinchin, 1894-1959) 令$X_1, X_2, \cdots$ 为独立同分布且期望存在的随机变量序列。则

$$\frac{1}{n}\sum_{i=1}^{n} X_i \xrightarrow{p} \mu.$$

定理4.12 (Cantelli强大数定律) (Cantelli, 1875-1966) 令$X_1, X_2, \cdots$ 是相互独立的随机变量序列。对任意$i = 1, 2, \cdots$, $EX_i = \mu_i$, $E(X_i - \mu_i)^4 \leq M$, M是一个常数。则

$$\frac{1}{n}\sum_{i=1}^{n}(X_i - EX_i) \xrightarrow{a.e.} 0.$$

定理4.13 (Kolmogorov强大数定律) 设$X_1, X_2, \cdots$ 是独立随机变量序列，且

$$\sum_{n=1}^{\infty} \frac{\text{var}(X_n)}{n^2} < \infty.$$

则

$$\frac{1}{n}\sum_{i=1}^{n}(X_i - EX_i) \xrightarrow{a.e.} 0.$$

令事件A在一次试验中发生的概率为p, 在n次独立重复试验中A发生了X_n次，$n \geq 2$. 则当$n \to \infty$ 时，

$$\frac{X_n}{n} \xrightarrow{a.s.} p.$$

例4.27 令$X_1, X_2, \cdots$为独立随机变量序列，且X_n的概率函数为

取值	-2^n	0	2^n
概率	$2^{-(2n+1)}$	$1-2^{-2n}$	$2^{-(2n+1)}$

求证：$X_1, X_2, \cdots$服从大数定律。

证明： 由于$X_1, X_2, \cdots$为独立随机变量序列，且对任意n, 有

$$EX_n = 0, \; \text{var}(X_n) = 1,$$

满足Chebyshev大数定律的条件，从而有$\frac{1}{n}\sum_{i=1}^{n} X_i \xrightarrow{p} 0$.

4.7 中心极限定理

数学上求一列级数的和，比如$1+x+\frac{x^2}{2!}+\cdots+\frac{x^n}{n!}$, 当$n$比较大时，计算比较复杂，但是我们可以用$n$趋于无穷的极限$e^x$来近似。概率论中也有类似的情形。如果求一列随机变量的和的分布，计算起来非常复杂，甚至没法计算，一个自然的问题是：有没有极限的方法来计算呢？答案是肯定的，中心极限定理是概率论中讨论独立的随机变量序列之和的分布函数收敛于正态分布的一类定理。它是概率论中最重要的一类定理，有着广泛的实际应用背景。

定理4.14 (中心极限定理)令$X_1, X_2, \cdots, X_n$为独立同分布且期望和方差有限的随机变量序列。记$EX_1=\mu$, $\mathrm{var}(X_1)=\sigma^2$, $T_n=\dfrac{1}{n}\sum\limits_{i=1}^{n}X_i$, $\dfrac{T_n-\mu}{\sqrt{\sigma^2/n}}$ 的分布函数为$F_n(x)$.则

$$\lim_{n\to\infty}F_n(x)=\Phi(x), x\in\mathcal{R}.$$

其中$\Phi(x)$为标准正态分布$N(0,1)$的分布函数，记作

$$\Big(\frac{1}{n}\sum_{i=1}^{n}X_i-\mu\Big)\Big/\sqrt{\sigma^2/n}\xrightarrow{d}N(0,1).$$

定理4.14又称Lindeberg-Levy中心极限定理(Lindeberg, 1876-1932; Levy, 1886-1971). 该定理告诉我们：任何独立同分布的随机变量序列，无论它的分布是什么，只要存在有限的期望和方差，那么它们求和的标准化后的随机变量序列的分布都渐近标准正态分布，这也说明正态分布的应用普遍性。常称$N(0,1)$为$\frac{T_n-\mu}{\sqrt{\sigma^2/n}}$的渐近分布，即当$n\to\infty$时，$\frac{T_n-\mu}{\sqrt{\sigma^2/n}}$的分布。

定理4.15 (Lindeberg中心极限定理)令$X_1, X_2, \cdots, X_n$为相互独立且期望和方差有限的随机变量序列。记$EX_i=\mu_i$, $\mathrm{var}(X_i)=\sigma_i^2$, $\theta=\sum\limits_{i=1}^{n}\sigma_i^2$, X_i的密度函数为$f_i(x)$, $i=1,2,\cdots,n$. 若该随机变量序列满足**Lindeberg条件**：对任意$\varepsilon>0$，有

$$\lim_{n\to\infty}\frac{1}{\theta}\sum_{i=1}^{n}E\Big[(X_i-\mu_i)^2I_{\left\{|X_i-\mu_i|>\varepsilon\sqrt{\theta}\right\}}\Big]=0.$$

则当$n\to\infty$ 时，有

$$\frac{1}{\sqrt{\theta}}\sum_{i=1}^{n}(X_i-\mu_i)\xrightarrow{d}N(0,1).$$

定理4.16 Lyapunov中心极限定理(Lyapunov, 1857-1918) 令$X_1, X_2, \cdots, X_n$为相互独立且期望和方差有限的随机变量序列。记$EX_i=\mu_i$, $\mathrm{var}(X_i)=\sigma_i^2$, $\theta=\sum\limits_{i=1}^{n}\sigma_i^2$. 若存在$\delta>0$, 使得

$$\lim_{n\to\infty}\frac{1}{\theta^{\frac{2+\delta}{2}}}\sum_{i=1}^{n}E|X_i-\mu_i|^{2+\delta}=0,$$

则

$$\frac{1}{\sqrt{\theta}}\sum_{i=1}^{n}(X_i-\mu_i)\xrightarrow{d}N(0,1).$$

例4.28 某人参加共100道选择题的考试，每道题均为4个备选答案且仅有一个答案是正确的。假设每道题他都随机选择一个答案。评分标准为：选对得1分，选错和不选得0分。问他最终得分大于等于35的概率？

解： 记X_i表示第i题的得分，$i=1,2,\cdots,100$. 则$X_1,X_2,\cdots,X_n$ 是独立同分布的随机变量序列，具有共同的分布：

$$P(X_1=1)=1-P(X_1=0)=0.25.$$

利用中心极限定理，有

$$\begin{aligned}P(X_1+X_2+\cdots+X_{100}\geq 35) &= P\left(\frac{\frac{1}{100}\sum_{i=1}^{100}X_i-0.25}{\sqrt{0.25(1-0.75)/100}}\geq\frac{0.35-0.25}{\sqrt{0.25(1-0.75)/100}}\right)\\ &= 1-\Phi(4)\\ &\approx 0.000032.\end{aligned}$$

习题四

离散型随机变量的期望

1. 令随机变量$X\sim Poisson(\lambda)$且$E\big((X-2)(X-4)\big)=4$. 求λ.

2. 令X_1,X_2是独立同分布的离散型随机变量，且X_1的概率函数为

$$P(X_1=i)=\frac{1}{n},i=1,2,\cdots,n.$$

求$E|X_1-X_2|$和$E(X_1-X_2)^2$.

3. 有n个粒子，每个粒子以$1/N$的概率落入N个格子的一个，$N\geq n$. 记没有粒子的格子数为X. 求EX.

4. 飞机场一大巴车上有40位乘客，离开机场后共有4个车站可以下车，若某个车站没有人下车该车站就不停车。若乘客在每个车站下车的概率相等，记停车的次数为X. 求EX.

5. 考察打靶试验一战士命中十环和没有命中十环两种结果。记该战士第一次命中十环的概率为3/4. 第i次命中十环时，第$i+1$次命中十环的概率为2/3; 第i次没有命中十环时，第$i+1$次命中十环的概率为4/5. 记X表示第一次命中十环的打靶次数。求EX.

6. 令某种稀有疾病的发病率为p, $0<p<1$. 问保险公司需对投保户收多少保险费，才能使保险公司的期望收益是保险费的15%.

7. 令随机变量X的概率函数为

$$P\Big(X=\frac{(-1)^k 2^k}{k}\Big)=\frac{1}{2^k}, k=1,2,\cdots,$$

求证：X的数学期望不存在。

8. 令X为取自然数的离散型随机变量。求证：
(1)$EX=\sum\limits_{k=1}^{\infty}P(X\geq k)$.
(2)$EX^2=\sum\limits_{k=1}^{\infty}P(X\geq k)+2\sum\limits_{k=0}^{\infty}kP(X>k)$.

连续型随机变量的期望

9. 令$(X_1,X_2)^\top\sim N(\mu_1,\mu_2,\sigma_1^2,\sigma_2^2,\rho)$. 记

$$Y_1=\max\{X_1,X_2\}, Y_2=\min\{X_1,X_2\}, Z=|X_1-X_2|$$

求：(1)Z的密度函数；(2)EZ; (3)$E(Y_1+Y_2)$; (4)$E(Y_1-Y_2)$.

10. (1)令随机变量$X\sim N(\mu,\sigma^2)$. 求$E|X-\mu|$, $E|X|$;
(2)令随机变量$X\sim Exp(\lambda)$. 求$E(3X^2+2X+1)$.

11. 令随机变量$X\sim Cauchy(0,1)$，密度函数为

$$f(x)=\frac{1}{\pi(1+x^2)}, x\in\mathcal{R}.$$

记$Y=\min\{|X|,2\}$. 求EY.

12. 令随机变量X的密度函数为

$$f(x)=\begin{cases} ax^2+bx+0.1, & 0<x<1,\\ 0, & \text{其它。}\end{cases}$$

且$EX=1$. 求a,b.

13. 令随机变量X与Y同分布，且X的密度函数为

$$f(x)=\begin{cases} x^3/4, & 0<x<1,\\ 0, & \text{其它。}\end{cases}$$

(1)若事件$A=\{X>a\}$与$B=\{Y>a\}$独立，且$P(A\cup B)=0.6$, 求常数a;
(2)求$E(1/X^3)$.

14. 令连续型随机变量X,Y的密度函数分别为$f(x)$,$g(y)$, 且$f(x)/g(x)$是x的增函数。求证：$EX \geq EY$.

15. 令连续型随机变量X的分布函数为$F(x), x \in \mathcal{R}$, $c > 0$. 求证：
(1)$EX = \int_0^{\infty}[1 - F(x)]dx - \int_{-\infty}^{0} F(x)dx$;
(2)$\int_{-\infty}^{\infty}[F(x + c) - F(x)]dx = c$.

16. 令连续型随机变量X的密度函数$f(x)$关于某点c对称，即

$$f(c - x) = f(c + x),\ x > 0.$$

求证：$EX = c$.

17. 令随机变量X的密度函数为

$$f(x) = \begin{cases} \dfrac{1}{2|x|(\ln|x|)^2}, & |x| > e, \\ 0, & |x| \leq e. \end{cases}$$

求证：对任意$r > 0$, $|X|^r$的数学期望不存在。

18. 令X为取非负值的连续型随机变量。求证：
(1)$EX = \int_0^{\infty} P(X > x)dx$;
(2)$EX^2 = 2\int_0^{\infty} xP(X > x)dx$.

19. 考察连续型随机变量X和连续有界函数$g(x), x \in \mathcal{R}$, 求证：
(1)$[Eg(X)]^2 \leq E[f(X)]^2$.
(2)$\left[\int_a^b g(x)dx\right]^2 \leq (b - a)\int_a^b g^2(x)dx$, $a < b \in \mathcal{R}$.

方差

20. 令随机变量X只取-1和1两个值，且$P(X = -1) = p$, $EX = 4\mathrm{var}(X)$. 求p.

21. 令随机变量X的密度函数为

$$f(x) = \frac{x^n e^{-x}}{n!}, x > 0.$$

求EX, $\mathrm{var}(X)$.

22. 令两只股票的价格分别为50元和40元每股。设这两只股票每股的收益相互独立，分别记为X和Y, 且

$$EX = 8, \mathrm{var}(X) = 30, EY = 5, \mathrm{var}(Y) = 20.$$

今有5万元，求平均收益不低于8000时的最优投资组合方案(“最优”的意思是指收益的方差最小)。

23. 令一钟摆左右来回摆动的振幅为X, 且X的密度函数为$f(x)$,

$$f(x)=\begin{cases} kxe^{-\frac{x^2}{2\sigma^2}}, & x>0,\\ 0 & x\le 0,\end{cases}$$

其中σ^2已知。求$EX, \mathrm{var}(X)$.

24. 令$X_1\sim N(0,1), X_2\sim N(0,1)$且$X_1, X_2$相互独立。记$a_1, a_2, b_1, b_2$为不为0的已知常数，$Y=(a_1X_1^2+a_2X_2^2)/(b_1X_1^2+b_2X_2^2)$. 求$EY, \mathrm{var}(Y)$.

25. 令随机变量X, Y相互独立。求证：

$$\mathrm{var}(XY)=\mathrm{var}(X)\mathrm{var}(Y)+(EX)^2\mathrm{var}(Y)+\mathrm{var}(X)(EY)^2.$$

由此得$\mathrm{var}(XY)\ge \mathrm{var}(X)\mathrm{var}(Y)$.

26. 令随机变量X, Y, 满足$EX=EY=0, \mathrm{var}(X)=\mathrm{var}(Y)=1, \mathrm{cov}(X,Y)=\rho$. 求证：

$$E\big[\max\{X^2,Y^2\}\big]\le 1+\sqrt{1-\rho^2}.$$

27. 令随机变量X的概率函数为

$$p_i=P(X=a_i), i=1,2,\cdots,n, a_1\le a_2\le\cdots\le a_n.$$

求证：$\mathrm{var}(X)\le (a_n-a_1)^2/4$.

28. (第二章习题39续) 令随机变量X的密度函数为第二章习题39中的$f(x,\xi,\eta)$. 求证：

$$EX=\frac{\xi}{\eta-1}, \eta>1,\ \ \mathrm{var}(X)=\frac{\xi(\xi+\eta-1)}{(\eta-1)^2(\eta-2)}, \eta>2.$$

29. (第二章习题40续) 令随机变量X服从逆Gamma分布。求证：

$$EX=\frac{\lambda}{\xi-1}, \xi>1,\ \mathrm{var}(X)=\frac{\lambda^2}{(\xi-1)^2(\xi-2)}, \xi>2.$$

30. 令随机变量X服从**Pareto分布**(Pareto,1848-1923)，其密度函数为

$$f(x,k,\xi)=\begin{cases} k\xi^k\frac{1}{x^{k+1}}, & x\ge\xi,\\ 0 & x<\xi,\end{cases}$$

其中k, ξ是参数，且$k>2, \xi>0$, 记作$X\sim Pareto(k,\xi)$. 求$EX, \mathrm{var}(X)$.

31. 令随机变量X服从**Laplace分布**，其密度函数为

$$f(x,\mu,\lambda)=\frac{1}{2\lambda}e^{-\frac{|x-\mu|}{\lambda}}, x\in\mathcal{R},$$

其中μ, λ是参数，且$\lambda>0$, 记作$X\sim Laplace(\mu,\lambda)$. 求证：
(1)若$Y\sim Laplace(0,1)$, $\lambda Y+\alpha\sim Laplace(\mu,\lambda)$.
(2)$EX=\mu$, $\mathrm{var}(X)=2\lambda^2$.

32. 令随机变量X服从**Maxwell**分布，密度函数为

$$f(x,\alpha)=\begin{cases}\frac{4x^2}{\alpha^3\sqrt{\pi}}e^{-\frac{x^2}{\alpha^2}} & x>0\\ 0 & x\le 0,\end{cases}$$

其中α是参数，且$\alpha>0$. 求：
(1)EX,var(X);
(2)$mX^2/2$的概率分布。

33. 令X服从**Rayleigh分布**(Rayleigh, 1842-1919)，其密度函数为

$$f(x,\sigma^2)=\frac{x}{\sigma^2}\exp\left(-\frac{x^2}{2\sigma^2}\right),x>0,$$

其中σ^2是参数，且$\sigma^2>0$. 求证：

$$EX=\sqrt{\frac{\pi}{2}}\sigma,\ \mathrm{var}(X)=\frac{4-\pi}{2}\sigma^2.$$

34. 令随机变量X服从**双参数Weibull分布**(Weibull, 1887-1979), 其密度函数为

$$f(x,\xi,\eta)=\begin{cases}\frac{\eta}{\xi}\left(\frac{x}{\xi}\right)^{\eta-1}e^{-(x/\xi)^\eta} & x\ge 0,\\ 0 & x<0,\end{cases}$$

其中ξ,η是参数，且$\xi>0,\eta>1$. 求证:
(1)$EX=\xi\Gamma(1+1/\eta)$, $\mathrm{var}(X)=\xi^2\left[\Gamma(1+2/\eta)-\Gamma^2(1+1/\eta)\right]$.
(2)Weibull分布的失效率是x的增函数。

条件期望

35. 把一正方体的各个面依次标记1, 2, 3, 4, 5, 6. 在桌上随机抛掷该正方体，考察正方体朝上的一面出现的数字。记连续抛掷X次后第一次连续出现两次6. 求EX.

36. 一罪犯被关在有4个门的监狱里，其中第1个门走8个小时的地道通向自由；第2个门走6个小时的地道返回监狱；第3个门走4个小时的地道返回监狱，第4个门走2个小时的地道返回监狱。若罪犯每次选择4个门的可能性相同，求该罪犯为获得自由平均需要的时间。

37. 某邮局在一次大型庆祝活动发行了n张m种不同的纪念邮票，$n\gg m$. 一个集邮爱好者打算收集这m种不同的邮票，假设每张邮票出现的概率都是$1/n$. 为了收集齐这m种不同的邮票，求这位集邮爱好者平均需要购买多少张邮票。

38. 一盒子里有n个球，编号为$1, 2, \cdots, n$. 从盒子里随机取出1个球，如果取到编号为n的球，计2分并停止摸球，如果取得其它编号的球计1分，把球放回去，重新摸球，依次下去，求得到分数的数学期望。

39. 令$X \sim N(\mu, \sigma^2)$, c为已知的常数。记

$$Y = \begin{cases} X, & X > c, \\ c, & X \le c. \end{cases}$$

求EX.

40. (1)令$X \sim N(\mu, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$, X, Y相互独立，求$\mathrm{cov}(X, XY)$;
(2)令$X \sim Exp(\lambda)$, $Y \sim Exp(\mu)$ 且X, Y相互独立。求$E(X|X < Y)$.

41. 求证：$\mathrm{cov}(X, Y) = \mathrm{cov}\big(X, E(Y|X)\big)$.

42. 令X, Y独立同分布。求证：$E(X|X + Y = k) = k/2$.

43. 令连续型随机变量X, Y满足$E(Y|X) = 1$. 求证：$\mathrm{var}(XY) \ge \mathrm{var}(X)$.

协方差和相关系数

44. 令随机变量X, Y相互独立，$X \sim Poisson(\lambda), \lambda > 0$, Y服从-1和1等可能的两点分布。求$\mathrm{cov}(X, XY)$.

45. 令随机变量$X \sim U(0, 1)$. 求X与$|X - 0.5|$的相关系数。

46. 令二维随机变量$(X, Y)^\top$在矩形

$$G = \{(x, y) | 0 \le x \le 2, 0 \le y \le 4\}$$

上服从均匀分布。记

$$U = \begin{cases} 0, & X > Y \\ 1, & X \le Y, \end{cases}$$

$$V = \begin{cases} 0, & X > 2Y \\ 1, & X \le 2Y. \end{cases}$$

求U和V的相关系数。

47. 令$X \sim N(1, 16)$,$Y \sim N(0, 25)$, 相关系数$\rho_{XY} = -\frac{1}{2}$, 且$(X, Y)^\top$服从二元正态分布。记$Z = X/4 + Y/5$. 求：
(1)Z的数学期望和方差；(2)X与Z的相关系数并判断X与Z是否独立。

48. 令$(X_1, X_2)^\top \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, $\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho$已知。
(1)求$(X_1-\mu_1)^2/\sigma_1^2$与$(X_2-\mu_2)^2/\sigma_2^2$的相关系数；
(2)记a_1, a_2为已知常数，求$a_1X_1+a_2X_2$与$a_1X_1-a_2X_2$的相关系数；
(3)记$Y=aX_1+bX_2$ 和$Z=aX_1-bX_2$. 若$EY=\theta$且Y, Z相互独立，求a和b.

49. 令$(X_1, X_2)^\top \sim N(0, 0, 1, 1, \rho)$, $\theta = P(XY<0)$. 求证：
(1)$\rho = \cos\theta\pi$;
(2)$E\max\{X_1, X_2\} = \sqrt{\frac{1-\rho}{\pi}}$;
(3)$E\max\{X_1^2, X_2^2\} \le 1+\sqrt{1-\rho^2}$;
(4)$\mathrm{cov}(X-Y, XY)=0$

50. 令随机变量$X\sim N(0,2)$, Y服从-1和1等可能的两点分布，且X和Y相互独立。求证：$XY\sim N(0,1)$, 且XY与X不相关也不独立。

51. 令随机变量X的密度函数为偶函数且其二阶矩存在。求证：X与$|X|$不相关也不独立。

52. 令$X\sim U(-\pi,\pi)$, $Y=\sin X, Z=\cos X$. 求证：Y, Z不相关也不独立。

53. 令$X\sim Laplace(0,1)$ (密度函数见本章习题31). 求证：X与$|X|$不相关也不独立。

54. 考察随机变量X, Y,
(1)求证：$\mathrm{cov}(X,Y)=\mathrm{cov}\big(X, E(Y|X)\big)$.
(2)若$E(Y|X)=1+cX$, 其中c为一常数。求证：$c=\mathrm{cov}(X,Y)/\mathrm{var}(X)$.

55. 令随机变量$(X,Y)^\top$的联合概率分布为

$X\backslash Y$	-1	0	1
-1	$\frac{1}{8}$	$\frac{1}{8}$	$\frac{1}{8}$
0	$\frac{1}{8}$	0	$\frac{1}{8}$
1	$\frac{1}{8}$	$\frac{1}{8}$	$\frac{1}{8}$

求证：X与Y不相关也不独立。

56. 考察事件A和B, $0<P(A)<1$, $0<P(B)<1$. 称

$$\theta = \frac{P(AB)-P(A)P(B)}{P(A)P(\bar{A})P(B)P(\bar{B})}$$

为A和B的相关系数。求证：
(1)$r\le 1$; (2)A, B相互独立$\Longleftrightarrow\theta=0$.

其它数字特征

57. 令随机变量$X \sim Cauchy(\mu, \sigma)$. 求$X$的中位数。

58. (1)若随机变量X的m阶矩存在，则其k阶矩必存在，$k < m$；
(2)举例说明随机变量X的m阶矩不存在，但是其k阶矩可能存在，$k < m$.

59. 令随机变量$X \sim Poisson(\lambda)$, $\lambda > 0$. 求X的偏度系数和峰度系数。

60. 求证：对随机变量X及任意实数$a, b, b \neq 0$, $a + bX$与X有相同的偏度系数和峰度系数。

61. 令随机变量X的n阶矩存在，记$\xi_k = E|X|^k, k < n$. 求证：$\xi_k^{\frac{1}{k}} \leq \xi_{k+1}^{\frac{1}{k+1}}, k = 1, 2, \cdots, n-1$.

62. 令随机变量X的密度函数为

$$f(x) = \begin{cases} \frac{1}{2|x|(\ln|x|)^2}, & |x| > e, \\ 0, & \text{其它。} \end{cases}$$

求证：X的任何k阶$(k > 0)$的原点矩都不存在。

63. 令二元随机变量$(X, Y)^\top$的联合密度函数为：

$$f(x, y) = \begin{cases} \frac{1}{4}[1 + xy(x^2 - y^2)], & -1 \leq x, y \leq 1, \\ 0, & \text{其它。} \end{cases}$$

记$X, Y, X + Y$的特征函数分别为$\psi_X(t), \psi_Y(t), \psi(t)$. 求证：$X, Y$不独立，且$\psi(t) = \psi_X(t) + \psi_X(t)$.

收敛性

64. 令X是非负随机变量，则对任意$\varepsilon > 0$,

$$P(X \geq \varepsilon) \leq \frac{EX}{\varepsilon}.$$

65. 令$X_1, X_2, \cdots, X_n$相互独立，$n \geq 2$, 且对任意$i = 1, 2, \cdots, n$, $EX_i = 0$, $EX_i^4 \leq M < \infty$. 求证：

$$E\Big(\sum_{i=1}^{n} X_i\Big)^2 \leq 3n^2 M.$$

66. 求证: $X_n \xrightarrow{p} X$的充分必要条件是$E\left(\frac{|X_n - X|}{1 + |X_n - X|}\right) \to 0, n \to \infty$.

67. 令$X_1, X_2, \cdots$是独立同分布的随机变量序列，X_1的三阶矩存在。记

$$\mu = EX_1, \ S_n = \frac{X_1X_2X_3 + X_4X_5X_6 + \cdots + X_{3n-1}X_{3n-2}X_{3n}}{n}.$$

求证：S_n依概率收到c, 并求c.

68. 令$X_1, X_2, \cdots$,是随机变量序列，且X_n的密度函数为

$$f_n(x) = \frac{n}{\pi(1+n^2x^2)}, x \in \mathcal{R}, n = 1, 2, \cdots .$$

求证: $X_n \xrightarrow{p} 0$.

69. 令$X_1, X_2, \cdots$,和$Y_1, Y_2, \cdots$, 为两个随机变量序列，X和Y为已知的随机变量, $a, b \neq 0$为已知常数。求证：
(1)若$X_n \xrightarrow{p} X, X_n \xrightarrow{p} Y$, 则$P(X = Y) = 1$;
(2)若$X_n \xrightarrow{p} a, Y_n \xrightarrow{p} b$, 则$\frac{X_n}{Y_n} \xrightarrow{p} \frac{a}{b}$.

70. 令$X_1, X_2, \cdots$为严格单调上升或下降的随机变量序列，c是给定的常数。若$X_n \xrightarrow{p} c$, 则$X_n \xrightarrow{a.e.} c$.

71. 令随机变量X, Y的r阶矩存在，$r > 0$. 记

$$g(r) = \begin{cases} 1, & 0 < r < 1, \\ 2^{r-1}, & r \geq 1. \end{cases}$$

求证：$E|X+Y|^r \leq g(r)\big[E|X|^r + E|Y|^r\big]$.

72. 令随机变量X只取非负整数。求证：$P(X = 0) \leq \mathrm{var}(X)/(EX)^2$.

73. 令随机变量X只取非负值，$g(x) \geq 0$且$g(x)$是x的非负增函数，$x \in \mathcal{R}$. 设$Eg(X)$存在。求证：对任意$\varepsilon > 0$, $P(X \geq \varepsilon) \leq Eg(X)/g(\varepsilon)$.

74. 令$X_1, X_2, \cdots, X_n$独立同分布服从$U(a, b)$. 记

$$X_{(1)} = \min\{X_1, X_2, \cdots, X_n\}, X_{(n)} = \max\{X_1, X_2, \cdots, X_n\}.$$

求证：$X_{(1)} \xrightarrow{p} a$, $X_{(n)} \xrightarrow{p} b$.

75. 令随机变量序列$X_1, X_2, \cdots$ 独立同分布服从$U(0, 1)$, c是给定的常数，$0 < c < 1$. 求证: $\Big(\prod_{i=1}^{n} X_i\Big)^{\frac{1}{n}} \xrightarrow{p} \frac{1}{e}$.

大数定律

76. 令$X_1, X_2, \cdots$为独立同分布的随机变量序列，且$P\Big(X_n = \frac{2^k}{k^2}\Big) = \frac{1}{2^k}, k = 1, 2, \cdots$. 求证：$X_1, X_2, \cdots$服从大数定律。

77. 令随机变量X的密度函数为

$$f(x) = \begin{cases} \dfrac{x^k e^{-x}}{k!}, & x \geq 0 \\ 0, & x < 0. \end{cases},$$

及k为正整数。求证：$P\Big(0 < X < 2k+2\Big) \geq k/(k+1)$.

78. 令$X_1, X_2, \cdots, X_n$ $iid \sim Cauchy(0,1)$. 对任意实数c, 求证：$\frac{1}{n}\sum_{i=1}^{n} X_i$ 不以概率收敛到c.

79. 令$X_1, X_2, \cdots$为独立同分布且期望和方差存在的随机变量序列。记$\mu = EX_1$, $\sigma^2 = \mathrm{var}(X_1)$. 求证：

$$\frac{2}{n(n+1)}\sum_{k=1}^{n} kX_k \xrightarrow{p} \mu.$$

80. (**Bernstein大数定律**)令$X_1, X_2, \cdots$是方差有界的随机变量序列，且

$$\lim_{|i-j|\to\infty} \mathrm{cov}(X_i, X_j) \to 0.$$

则对任意$\varepsilon > 0$, 有

$$\lim_{n\to\infty} P\left(\left|\frac{1}{n}\sum_{i=1}^{n} X_i - \frac{1}{n}\sum_{i=1}^{n} EX_i\right| > \varepsilon\right) = 0.$$

81. (**Poisson大数定律**) 独立地做n次试验，记事件A在第i次试验发生的概率为p_i, $0 < p_i < 1$, $i = 1, 2, \cdots, n$, n次试验中事件A发生的次数为S_n. 则对任意$\varepsilon > 0$, 有

$$\lim_{n\to\infty} P\left(\left|\frac{S_n}{n} - \frac{1}{n}\sum_{i=1}^{n} p_i\right| > \varepsilon\right) = 0.$$

中心极限定理

82. 令$X_1, X_2, \cdots$为独立同分布随机变量序列，均值为0，方差有限。令

$$Y = \frac{\sqrt{n}(X_1 + X_2 + \cdots + X_n)}{X_1^2 + X_2^2 + \cdots + X_n^2}, Z = \frac{X_1 + X_2 + \cdots + X_n}{(X_1^2 + X_2^2 + \cdots + X_n^2)^{\frac{1}{2}}}.$$

求Y和Z的渐近分布。

83. 随机抛掷一枚质地均匀的骰子1200次。试利用中心极限定理来估计出现6点的次数在介于180和240之间的概率(给出有关$\Phi(\cdot)$表达式即可，其中$\Phi(\cdot)$ 为标准正态分布的分布函数)。

84. 令$X_1, X_2, \cdots$为独立同分布服从标准正态分布的随机变量序列。求证：

$$\frac{nX_{n+1}}{\sum_{i=1}^{n} X_i^2} \xrightarrow{d} N(0,1).$$

85. 令$X \sim Gamma(n, \lambda)$. 求证：$\frac{\lambda}{\sqrt{n}}\left(\frac{X}{n} - \frac{1}{\lambda}\right) \xrightarrow{d} N(0,1)$.

86. 令随机变量序列$X_1, X_2, \cdots\ iid \sim U\left(-\frac{1}{2}, \frac{1}{2}\right)$. 求证：

$$\frac{2\sqrt{3}}{\sqrt{n}}(X_1 + X_2 + \cdots + X_n) \xrightarrow{d} N(0,1).$$

87. 试利用Poisson分布和中心极限定理证明：$\lim\limits_{n\to\infty} \sum\limits_{i=0}^{n} \frac{1}{i!} n^i e^{-n} = \frac{1}{2}$.

88. 令$X_1, X_2, \cdots$是独立同分布且四阶矩存在的随机变量序列。记

$$\mu = EX_1, \sigma^2 = \mathrm{var}(X_1), \theta = E(X_1 - \mu)^4, v = \sqrt{\theta - \sigma^4},$$

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i, S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2.$$

求证：$\sqrt{n}(S^2 - \sigma^2)/v \xrightarrow{d} N(0,1)$.

第五章　数理统计中的基本概念

前四章介绍的概率论知识为学习统计学奠定了重要的数学基础。从本章起，我们将介绍本书的第二部分：数理统计。数理统计是统计学中一块重要的基础内容。在介绍具体的内容之前，我们先了解一下统计学的定义及其发展历史。

统计学，英文Statistics, 是由Stat(国家)衍生出来的词，最早来源于国家收集国情资料。《中国大百科全书·理学·统计学》(2021网络版)指出：“统计学是数据的科学，研究在不确定的环境下如何通过收集和分析数据有效地提炼可靠信息，为各学科、领域和社会提供知识、帮助决策的科学”。统计学的研究对象是带有随机性的观测数据；研究内容是从数据出发，进行统计建模和推断，进而挖掘出数据背后隐藏的数量规律性，有效地认识客观事物的一门学科。统计学在许多领域，如生物医学、社会科学、大气环境、工业生产和经济金融等，都有着广泛的应用。

看三个例子。

例5.1 居民消费价格指数(Consumer price index, 简称CPI)度量了居民日常生活消费品和服务的价格水平随时间的变化情况。现有某市近20年的CPI数据，人们感兴趣的问题是未来几年该市的CPI 能达到多少？

例5.2 某工厂生产了1万台空调，为了考察这批空调的质量情况，通常的做法是从这批空调中随机抽出一些空调，比如100台，来检测它们的各项指标是否合格，从而判断这批空调的整体质量情况。

例5.3 临床试验中要评估一种新药是否对某种特定的疾病有效，研究者把100名志愿者随机分配到服用新药的组(50人)和对照组(50人)，并在试验结束时，检测他们的若干个生物标记物的取值在服药前后的变化情况，进而判断该药物的有效性。

例5.1涉及到某市CPI指数的分析和预测，例5.2和例5.3分别涉及到工业生产和生物医学领域中的随机抽样及推断，这些例子都是统计学的直接应用。从这三个例子可以看到，我们要处理的都是具体的实际问题，基于观测到的数据，对所研究的问题给出一定的结论。

统计学的发展主要分为三个阶段：(1)萌芽阶段。1900年前，统计学还没有形成一个学科，研究者们在人口普查与天文地质等领域提出了若干与统计学相关的基本概念和方法。Graunt (1620-1674) 在其编著的《关于死亡账单的自然和政治观察》书中介绍了国家在人口和经济数据分析中所运用的统计学思想；Legendre (1752-1833)和Gauss各自提出了最小二乘法；Gauss提出了正态分布等。(2)创建阶段。1900年至1945年，Galton (1822-1911)、Karl·Pearson (1857-1936)、Fisher (1890-1962)、Neyman (1894-1981)、Egon·Pearson (1895-1980)和Wald (1902-1950) 等建立了统计学的若干基础理论。Galton提出了标准偏差、相关和回归分析的概念；Karl·Pearson给出了回归分析、相关系数、矩估计和拟合优度检验等基本理论和方法；Fisher建立了方差分析、极大似然估计、估计

量的相合性与有效性、Fisher信息量、似然比检验和显著性等理论和方法；Neyman和Egon·Pearson给出了假设检验理论，如N-P 引理等；Wald建立了统计决策理论，引入了损失函数、风险函数和统计决策函数等。(3)发展阶段。1945年至今，随着计算机的发展，统计学的发展和应用进一步扩大，被广泛应用到各个研究领域，许多统计方法被提出，比如COX模型、自助法、LASSO等。

5.1 样本和统计量

5.1.1 总体和样本

由于样本是从总体中抽取出来的，提到样本，不得不先说一下总体。下面先举一个例子来理解总体和样本的概念。

例5.4 某医院近年来有5000名婴儿出生，为了了解这些新生婴儿的体重情况，研究人员从中随机抽取200名婴儿并查看他们的体重值。这里，5000名婴儿的体重值组成的集合是总体，每个婴儿的体重值是个体，抽取的200名婴儿的体重值是样本。样本是由个体构成，其包含个体的数目称为样本量，该例子中的样本量为200.

总体、样本和统计量： 研究的问题中所关心对象的全体称为**总体**，从总体中随机抽取的一部分个体称为**样本**，样本中个体的数目称为**样本量**。

在例5.4中，婴儿的体重值是一个数量指标。总体是由所有婴儿的体重值构成的集合，它是数的集合。由于抽样是随机的，因此抽到的个体的数量指标的观测值也是随机的，这种数量指标可以认为是随机变量，它的概率分布是总体中该数量指标的概率分布。因此，可以用一个随机变量X及其概率分布来描述总体。

由于总体的特征由其概率分布来刻画，所以常把总体和总体分布视为同义语。常用随机变量X或分布函数(或概率函数或密度函数)来表示。如例5.4，用随机变量X表示婴儿的体重值，总体可用X来表示，或用其分布函数$F(x,\theta)$来表示，其中$x \in \mathcal{R}, \theta \in \Theta$是与总体分布有关的未知参数，$\Theta$是参数的取值空间，一般假设$\Theta$为开区间。若$F(x,\theta)$的密度函数为$f(x,\theta)$, 该总体还可以用$f(x,\theta)$来表示。

令总体X的分布函数为$F(x,\theta)$, 密度函数为$f(x,\theta)$, $x \in \mathcal{R}$, $\theta \in \Theta$. 下面三种表述的意思相同：

$$
\begin{aligned}
&X_1, X_2, \cdots, X_n \; iid \sim F(x,\theta),\\
&X_1, X_2, \cdots, X_n \; iid \sim f(x,\theta),\\
&X_1, X_2, \cdots, X_n \; iid \sim X.
\end{aligned}
$$

有时候，也可以根据总体的分布类型来称呼总体的名称，如正态总体、指数分布总体等。当我们关心的数量指标不止一项时，如例5.4中，除了体重之外，研究者们还关心婴儿的身高和视力，我们可以用多元随机变量来表示总体，其定义类似。

当我们从总体中随机抽样时，每次抽取的结果一般不会完全相同，即抽到的样本具有随机性，这就造成了样本具有两重性的特征。

本书以后的章节，除非特别说明，提到的“**抽样**”都是指“**随机抽样**”。

样本的两重性：样本既可以看成是具体的数值，也可以看成是随机变量。在抽样前，事先不知道抽到的是哪些样本，因而被认为是随机变量；在完成抽

样后，它有了具体的观测值，是确定的。为了区分，常用大写字母表示随机变量，小写字母表示随机变量的观测值。

抽样的目的是通过搜集到的数据对总体分布进行有效的推断，为了使抽取的样本尽可能地反映总体的信息，抽样的方式和方法非常重要。常用的一种抽样方法是“简单随机抽样”。

简单随机样本：令总体的分布函数为$F(x,\theta), x \in \mathcal{R}, \theta \in \Theta$. 记$X_1, X_2, \cdots, X_n \, iid \sim F(x,\theta)$. 称$X_1$, X_2, $\cdots$, X_n 为简单随机样本，简称为简单样本或随机样本。

令总体的分布函数为$F(x,\theta)$, $x \in \mathcal{R}$, $\theta \in \Theta$. 记$X_1, X_2 \cdots, X_n \, iid \sim F(x,\theta)$. 则$(X_1, X_2, \cdots, X_n)^\top$的联合分布函数为

$$\prod_{i=1}^{n} F(x_i,\theta), (x_1, x_2, \cdots, x_n)^\top \in \mathcal{R}^n.$$

令$F(x,\theta)$的密度函数为$f(x,\theta)$. 则$(X_1, X_2, \cdots, X_n)^\top$的联合密度函数为

$$\prod_{i=1}^{n} f(x_i,\theta), (x_1, x_2, \cdots, x_n)^\top \in \mathcal{R}^n.$$

类似地可以描述多元随机变量总体。

如果总体X是离散型随机变量，称总体为离散总体；如果总体X是连续型随机变量，称总体为连续总体。

5.1.2 统计量

一般情况下，总体的分布函数形式是已知的，它包含若干未知的参数。比如，正态总体$N(\mu,\sigma^2)$, 其中μ, σ^2是未知的参数。样本是从总体中随机抽取来的，它反映了总体的一些特征。因此，需要将样本中包含的总体的信息融合起来，这就引进了统计量的概念。

统计量：令$X_1, X_2, \cdots, X_n \, iid \sim F(x,\theta), x \in \mathcal{R}, \theta \in \Theta$. 记$T = T(X_1, X_2, \cdots, X_n)$, 它不含有未知参数，称$T$是一个统计量。

两点说明：

(1) 统计量只与样本有关，不能与未知参数有关。例如，令$X_1, X_2 \cdots, X_n \, iid \sim N(\mu,\sigma^2)$. $\sum_{i=1}^{n} X_i$ 和$\sum_{i=1}^{n} X_i^2$ 均是统计量。当μ和σ^2都是未知参数时，$\sum_{i=1}^{n}(X_i - \mu)$和$\sum_{i=1}^{n} X_i^2/\sigma^2$均不是统计量。

(2) 统计量具有两重性。由于样本具有两重性，统计量是样本的函数。因此可认为统计量是随机变量，它有概率分布，这是我们利用统计量进行统计推断的基础。

常用的统计量

样本均值 令$X_1, X_2, \cdots, X_n \, iid \sim F(x,\theta)$, $x \in \mathcal{R}$, $\theta \in \Theta$. 称

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$$

为样本均值。

样本方差 令$X_1, X_2, \cdots, X_n$ $iid \sim F(x,\theta)$, $x \in \mathcal{R}$, $\theta \in \Theta$. 称

$$S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2$$

为样本方差，称

$$S = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2}$$

为样本标准差。

样本矩 令$X_1, X_2, \cdots, X_n$ $iid \sim F(x,\theta)$, $x \in \mathcal{R}$, $\theta \in \Theta$. 称

$$\xi_k = \frac{1}{n}\sum_{i=1}^{n}X_i^k, k = 1, 2, \cdots$$

为样本k阶原点矩。当$k = 1$, ξ_1为样本均值。称

$$\eta_k = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^k, k = 2, 3, \cdots$$

为样本k阶中心矩。当$k = 2$, η_2为样本方差。

基于样本矩可得，样本偏度系数为η_3/S^3 和样本峰度系数为η_4/S^4.

下面为了记号的方便，记某总体的分布函数为$F(x)$, 它可能含有也可能不含有未知参数θ。

经验分布函数 令$X_1, X_2, \cdots, X_n$ $iid \sim F(x), x \in \mathcal{R}$. 称

$$F_n(x) = \frac{1}{n}\sum_{i=1}^{n}I_{\{X_i \le x\}}, x \in \mathcal{R}$$

为经验分布函数。

当样本量n足够大时，经验分布函数$F_n(x)$收敛到总体分布函数$F(x)$. 这是用样本推断总体的理论依据。由Kolmogorov强大数定律知，

$$F_n(x) \xrightarrow{a.e.} F(x),\ x \in \mathcal{R}.$$

进一步，我们不加证明地给出有下面的定理。

定理5.1 (Glivenko-Cantelli定理) (Glivenko, 1896-1940) 令$X_1, X_2, \cdots, X_n$ $iid \sim F(x)$, $x \in \mathcal{R}$. $F_n(x)$是其经验分布函数。则

$$P\Big(\lim_{n\to\infty}\sup_{-\infty<x<\infty}|F_n(x) - F(x)| = 0\Big) = 1.$$

对给定$-\infty < x < \infty$, $I_{\{X_i \le x\}}$服从0-1分布，且

$$EI_{\{X_i \le x\}} = F(x),\ \text{var}\left(I_{\{X_i \le x\}}\right) = F(x)(1 - F(x)),\ i = 1, 2, \cdots, n.$$

由中心极限定理，得

$$\frac{\sqrt{n}\big(F_n(x)-F(x)\big)}{F(x)[1-F(x)]} \xrightarrow{d} N\big(0,1\big),\ x\in\mathcal{R}.$$

次序统计量 令$X_1,X_2,\cdots,X_n\ iid\sim F(x),\ x\in\mathcal{R}.$ 对$X_1,X_2,\cdots,X_n$从小到大排序，即

$$X_{(1)}\le X_{(2)}\le\cdots\le X_{(n)}.$$

称$X_{(1)},X_{(2)},\cdots,X_{(n)}$为次序统计量，$X_{(1)},X_{(2)},\cdots,X_{(n)}$的任意一部分也为次序统计量。

记$F(x)$的密度函数为$f(x).$ $X_{(i)}$的密度函数为

$$f_{X_{(i)}}(x)=\frac{n!}{(i-1)!(n-i)!}F(x)^{i-1}\big[1-F(x)\big]^{n-i}f(x),\ 1\le i\le n.$$

具体推导过程如下：对任意$i\in\{1,2,\cdots,n\},\ x\in\mathcal{R}$ 和充分小的$\varepsilon>0,$ 考察事件

$$A=\{x<X_{(i)}\le x+\varepsilon\}.$$

A发生，$X_1,X_2,\cdots,X_n$中有$i-1$个的值小于等于$x,\ n-k$ 个的值大于$x+\varepsilon,$ 有一个的值落入$(x,x+\varepsilon].$ 这相当于第一章定理1.1把n件产品分成三组，总的分法为$\frac{n!}{(i-1)!1!(n-i)!}.$ 记$X_{(i)}$的分布函数为$F_{X_{(i)}}(x).$ 因此

$$F_{X_{(i)}}(x+\varepsilon)-F_{X_{(i)}}(x)=\frac{n!}{(i-1)!(n-i)!}F(x)^{i-1}[F(x+\varepsilon)-F(x)][1-F(x+\varepsilon)]^{n-i}.$$

进而有

$$f_{X_{(i)}}(x)=\lim_{\varepsilon\to0}\frac{F_{X_{(i)}}(x+\varepsilon)-F_{X_{(i)}}(x)}{\varepsilon}=\frac{n!}{(i-1)!(n-i)!}F(x)^{i-1}[1-F(x)]^{n-i}f(x).$$

特别地，$X_{(1)}$的分布函数为$\big[1-F(x)\big]^n,$ $X_{(n)}$的分布函数为$\big[F(x)\big]^n,\ x\in\mathcal{R}.$

同理，$\big(X_{(i)},X_{(j)}\big)^\top\ (i<j)$的联合密度函数为

$$f_{X_{(i)},X_{(j)}}(x,y)=\frac{n!}{(i-1)!(j-i-1)!(n-j)!}F(x)^{i-1}\big[F(y)-F(x)\big]^{j-i-1}\big[1-F(y)\big]^{n-j}f(x)f(y),\tag{5.1}$$

其中 $x\le y,\ 1\le i<j\le n.$

样本α分位数 令$\lfloor\cdot\rfloor$表示向下取整。任给$0<\alpha<1,$ 记样本α分位数为$Q_\alpha,$

$$Q_\alpha=\begin{cases}X_{(\lfloor n\alpha\rfloor+1)}, & \text{若}n\alpha\text{不是整数，}\\ \frac{1}{2}\left(X_{(n\alpha)}+X_{(n\alpha+1)}\right), & \text{若}n\alpha\text{是整数。}\end{cases}$$

当$\alpha=\frac{1}{2},$ $Q_{\frac{1}{2}}$称为**样本中位数**，即

$$Q_{\frac{1}{2}}=\begin{cases}X_{\left(\frac{n+1}{2}\right)}, & \text{当}n\text{为奇数，}\\ \frac{1}{2}\left[X_{\left(\frac{n}{2}\right)}+X_{\left(\frac{n}{2}+1\right)}\right], & \text{当}n\text{为偶数。}\end{cases}$$

样本分位数反映了总体分位数的信息。当总体分布关于某点对称时，对称中心既是总体中位数又是总体均值，此时，$Q_{\frac{1}{2}}$也反映了总体均值的信息。一般情况，$Q_{\frac{1}{2}}$的精确分布比较难求，然而，当n趋于无穷时，$Q_{\frac{1}{2}}$ 渐近服从正态分布。这就是下面的定理。

定理5.2 令连续总体的密度函数为$f(x)$, $x \in \mathcal{R}$, q_α为其α分位数，$0 < \alpha < 1$, $f(x)$ 在q_α连续且$f(q_\alpha) > 0$. 记$X_1, X_2, \cdots, X_n$ $iid \sim f(x)$, Q_α为样本α分位数。则

$$\frac{Q_\alpha - q_\alpha}{\sqrt{\alpha(1-\alpha)/\big(nf^2(q_\alpha)\big)}} \xrightarrow{d} N(0,1).$$

当$\alpha = 0.5$,

$$\sqrt{4nf^2(q_{\frac{1}{2}})}\left(Q_{\frac{1}{2}} - q_{\frac{1}{2}}\right) \xrightarrow{d} N(0,1).$$

例5.5 令$X_1, X_2, \cdots, X_n$ $iid \sim F(x), x \in \mathcal{R}$且$F(x)$的三阶矩存在。记$\bar{X}$和$S^2$分别为样本均值和样本方差，$\theta = E(X - EX)^3$. 求证：

$$\mathrm{cov}\left(\bar{X}, S^2\right) = \frac{\theta}{n}.$$

证明：注意到

$$\begin{aligned}
\mathrm{cov}\left(\bar{X}, S^2\right) &= E[(\bar{X} - \mu)(S^2 - ES^2)] \\
&= E[(\bar{X} - \mu)S^2 - (\bar{X} - \mu)ES^2] \\
&= E[(\bar{X} - \mu)S^2] - E[(\bar{X} - \mu)ES^2 \\
&= E\big[\left(\bar{X} - \mu\right)S^2\big].
\end{aligned}$$

而

$$\left(\bar{X} - \mu\right)S^2 = \frac{1}{n-1}\left[(\bar{X} - \mu)\sum_{i=1}^{n}(X_i - \mu)^2 - n(\bar{X} - \mu)^3\right],$$

$$\begin{aligned}
E\big[(\bar{X} - \mu)(X_i - \mu)^2\big] &= \frac{1}{n}\Big\{E(X_i - \mu)^3 + E\Big[\sum_{j=1, j\neq i}^{n}(X_j - \mu)(X_i - \mu)^2\Big]\Big\} \\
&= \frac{\theta}{n}, \\
E(\bar{X} - \mu)^3 &= \frac{1}{n^3}E\sum_{i=1}^{n}(X_i - \mu)^3 \\
&= \frac{\theta}{n^2}.
\end{aligned}$$

从而

$$\begin{aligned}
\mathrm{cov}\left(\bar{X}, S^2\right) &= E\big[\left(\bar{X} - \mu\right)S^2\big] \\
&= \frac{1}{n-1}\Big[n \times \frac{\theta}{n} - n \times \frac{\theta}{n^2}\Big] \\
&= \frac{\theta}{n}.
\end{aligned}$$

例5.6 令随机变量X服从**双参数Weibull分布**(见第四章习题34), 密度函数为

$$f(x,\xi,\eta)=\begin{cases}\frac{\eta}{\xi}\left(\frac{x}{\xi}\right)^{\eta-1}e^{-(x/\xi)^{\eta}} & x\geq 0\\ 0 & x<0,\end{cases}$$

其中$\xi>0,\eta>0$. 记$X_1,X_2,\cdots,X_n\ iid\sim X$, $X_{(1)}$是次序统计量最小值。求$X_{(1)}$的分布。

解：X的分布函数为

$$F(x)=\int_0^x\frac{\eta}{\xi}\Big(\frac{t}{\xi}\Big)^{\eta-1}e^{-(t/\xi)^{\eta}}dt=-\int_0^x e^{-(t/\xi)^{\eta}}d\left(-\Big(\frac{t}{\xi}\Big)^{\eta}\right)=1-e^{-(x/\xi)^{\eta}}.$$

最小次序统计量$X_{(1)}$的分布函数为

$$P(X_{(1)}\leq x)=1-[1-F(x)]^n=1-e^{-\left(\frac{x}{\xi n^{-1/\eta}}\right)^{\eta}}.$$

这是参数为$\xi n^{-1/\eta}$和η的Weibull分布，即$X_{(1)}\sim Weibull(\xi n^{-1/\eta},\eta)$.

例5.7 令连续型随机变量X的分布函数为$F(x)$, 密度函数为$f(x)$. 记

$$X_1,X_2,\cdots,X_n\ iid\sim X,$$

$X_{(1)}$, $X_{(n)}$分别为次序统计量的最小值和最大值。求证：$Y=X_{(n)}-X_{(1)}$的分布函数为

$$n\int_{-\infty}^{\infty}\big[F(y+u)-F(u)\big]^{n-1}f(u)du.$$

证明：由(5.1)知，$(X_{(1)},X_{(n)})^{\top}$的联合密度函数为

$$f(x_{(1)},x_{(n)})=\frac{n!}{(n-2)!}\big[F(x_{(n)})-F(x_{(1)})\big]^{n-2}f(x_{(1)})f(x_{(n)}),$$

其中$x_{(1)}\leq x_{(n)}$. 记

$$\begin{cases}Y=X_{(n)}-X_{(1)},\\ Z=X_{(1)}.\end{cases}$$

其逆变换为

$$\begin{cases}X_{(1)}=Z,\\ X_{(n)}=Y+Z.\end{cases}$$

Jaccobi行列式的绝对值为$|J|=1$. Y和Z的联合密度函数为

$$f_{Y,Z}(y,z)=n(n-1)\big[F(y+z)-F(z)\big]^{n-2}f(z)f(y+z).$$

Y的边缘密度函数为

$$f_Y(y)=\int_{-\infty}^{\infty}n(n-1)\big[F(y+z)-F(z)\big]^{n-2}f(z)f(y+z)dz.$$

Y的分布函数为

$$\begin{aligned}
F_Y(y) &= \int_0^y \int_{-\infty}^{\infty} n(n-1)\big[F(t+z)-F(z)\big]^{n-2} f(z) f(t+z) dz dt \\
&= \int_{-\infty}^{\infty} n(n-1) f(z) \Big\{ \int_0^y \big[F(t+z)-F(z)\big]^{n-2} d\big[F(t+z)-F(z)\big] \Big\} dz \\
&= \int_{-\infty}^{\infty} n(n-1) f(z) \frac{\big[F(y+z)-F(z)\big]^{n-1}}{n-1} dz \\
&= n \int_{-\infty}^{\infty} f(z) \big[F(y+z)-F(z)\big]^{n-1} dz.
\end{aligned}$$

5.2. 三大分布

下面介绍基于正态分布抽取的简单随机样本所构造的统计量的分布，它们的分布密度有显式表达式，它们在统计推断中占据着十分重要的地位，有着非常广泛的应用。

1. χ^2分布

χ^2分布： 令$X_1, X_2, \cdots, X_n \ iid \sim N(0,1)$, $X = \sum_{i=1}^{n} X_i^2$. 则X服从自由度为n的χ^2分布，记作$X \sim \chi_n^2$.

χ_n^2的密度函数为

$$f(x,n) = \begin{cases} \dfrac{1}{2^{\frac{n}{2}}\Gamma(\frac{n}{2})} x^{\frac{n}{2}-1} e^{-\frac{x}{2}}, & x > 0, \\ 0, & x \le 0. \end{cases}$$

由于$X = \sum_{i=1}^{n} X_i^2$, $X_i \sim N(0,1)$, $i = 1, 2, \cdots, n$,

$$EX_i^2 = 1, \mathrm{var}(X_i^2) = EX_i^4 - \left(EX_i^2\right)^2 = 3 - 1 = 2.$$

所以，χ^2分布的期望和方差为

$$EX = E\Big(\sum_{i=1}^{n} X_i^2\Big) = \sum_{i=1}^{n} EX_i^2 = n,$$

$$\mathrm{var}(X) = \mathrm{var}\Big(\sum_{i=1}^{n} X_i^2\Big) = \sum_{i=1}^{n} \mathrm{var}(X_i^2) = 2n.$$

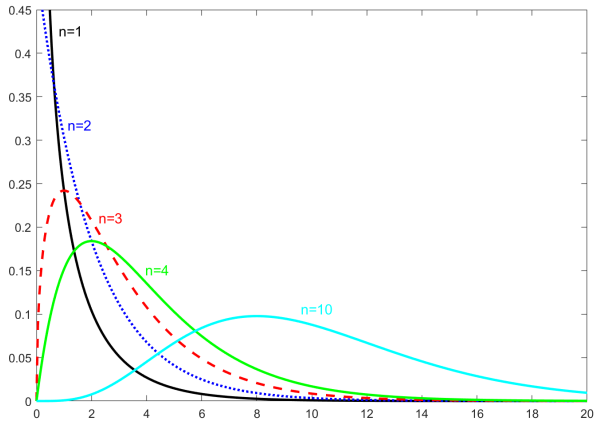


图5.1 不同自由度的χ^2分布的密度函数曲线。

图5.1展示了不同自由度的χ^2分布的密度函数曲线。可见当自由度n越大, χ_n^2的密度函数曲线越趋于对称, n越小, 曲线越不对称。当$n = 1$, 2 时曲线是单调下降. 当$n \ge 3$时曲线是单峰的。

χ^2分布的性质

性质1 令随机变量$Y_1 \sim \chi_n^2$, $Y_2 \sim \chi_m^2$且Y_1, Y_2 相互独立。则$Y = Y_1 + Y_2 \sim \chi_{n+m}^2$.

证明： 由题意知$Y_1 = \sum_{i=1}^{n} X_i^2$, $Y_2 = \sum_{j=n+1}^{n+m} X_j^2$, 且

$$X_1, X_2, \cdots, X_n, X_{n+1}, X_{n+2}, \cdots, X_{n+m} \; iid \sim N(0,1).$$

由χ^2分布的定义，得$Y = Y_1 + Y_2 = \sum_{i=1}^{n+m} X_i^2 \sim \chi_{m+n}^2$.

性质2 令$Y_1, Y_2, \cdots, Y_n \; iid \sim U(0,1)$. 则$-2\sum_{i=1}^{n} \ln Y_i \sim \chi_{2n}^2$.

证明： 令$Y \sim U(0,1)$, $Z = -2\ln Y$. 对$z > 0$,

$$P(Z \le z) = P(Y \ge e^{-\frac{z}{2}}) = 1 - e^{-\frac{z}{2}}.$$

对z求导可得Z的密度函数为$f_Z(z) = \frac{1}{2}e^{-\frac{z}{2}}$, 这是自由度为2的$\chi^2$分布的密度函数，即$Z \sim \chi_2^2$. 由$\chi^2$分布的定义知

$$-2\sum_{i=1}^{n} \ln Y_i = \sum_{i=1}^{n} (-2\ln Y_i) \sim \chi_{2n}^2.$$

性质3 $\chi_n^2 = Gamma(n/2, 1/2)$.

证明： 直接比较密度函数即证。

性质4 令$Y \sim N(\mathbf{0}_n, \mathbf{\Delta})$, 其中$\mathbf{\Delta}$为$n$阶正定阵。则$Y^\top \mathbf{\Delta}^{-1} Y \sim \chi_n^2$.

证明： 记$Z = \mathbf{\Delta}^{-1/2} Y = (Z_1, Z_2, \cdots, Z_n)^\top$. 由第三章第3.6节多元正态分布的性质1知$Z \sim N(\mathbf{0}_n, \mathbf{I}_n)$, 且$Z_1, Z_2, \cdots, Z_n \; iid \sim N(0,1)$. 根据$\chi^2$分布的定义，有

$$Y^\top \mathbf{\Delta}^{-1} Y = Z^\top Z = \sum_{i=1}^{n} Z_i^2 \sim \chi_n^2.$$

性质5 令$Y \sim N(\mathbf{0}_n, \mathbf{I}_n)$, $\mathbf{A}$为$n \times n$对称幂等阵，秩为r. 则$Y^\top \mathbf{A} Y \sim \chi_r^2$.

证明： 对$\mathbf{A}$进行奇异值分解，存在正定阵$\mathbf{Q}$, 使得

$$\mathbf{A} = \mathbf{Q} \begin{pmatrix} \mathbf{I}_r & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{pmatrix} \mathbf{Q}^\top.$$

记$Z = \mathbf{Q}^\top Y = (Z_1, Z_2, \cdots, Z_n)^\top$. 有$Z \sim N(\mathbf{0}_n, \mathbf{I}_n)$, 且$Z_1, Z_2, \cdots, Z_n \; iid \sim N(0,1)$. 因此，

$$Y^\top \mathbf{A} Y = Z^\top \begin{pmatrix} \mathbf{I}_r & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{pmatrix} Z = \sum_{i=1}^{r} Z_i^2 \sim \chi_r^2.$$

性质6 令$Y_1, Y_2, \cdots, Y_n \; iid \sim Exp(\lambda)$. 则$2n\lambda \bar{Y} \sim \chi_{2n}^2$.

证明： 记$Y \sim Exp(\lambda), Z = 2\lambda Y$. 有

$$P(Z \le z) = P\Big(Y \le \frac{z}{2\lambda}\Big) = 1 - e^{-\frac{z}{2}}.$$

可见Z的密度函数为$f_Z(z)=\frac{1}{2}e^{-\frac{z}{2}},\ z>0,$ 这是自由度为2的χ^2分布的密度函数，即$Z\sim\chi^2_2.$ 由χ^2分布的性质1，得$2n\lambda\bar{Y}=\sum_{i=1}^{n}2\lambda Y_i\sim\chi^2_{2n}.$

性质7 令$X\sim\chi^2_n,$ 则

$$\frac{X-n}{\sqrt{2n}}\xrightarrow{d}N(0,1).$$

例5.8 令$(X_1,X_2)^\top\sim N(0,0,1,1,\rho).$ 求$\frac{(X_1+X_2)^2}{2(1+\rho)}$的分布。

解： 由第三章第3.6节多元正态分布的性质2知$X_1+X_2\sim N\big(0,2(1+\rho)\big).$ 因此，

$$\frac{(X_1+X_2)^2}{2(1+\rho)}\sim\chi^2_1.$$

2. t**分布**

t**分布：** 令随机变量$X\sim N(0,1),\ Y\sim\chi^2_n,$ 且X,Y相互独立。则

$$T=\frac{X}{\sqrt{Y/n}}$$

服从自由度n的t分布，记作$T\sim t_n.$

t_n的密度函数为

$$f(x,n)=\frac{\Gamma(\frac{n+1}{2})}{\Gamma(\frac{n}{2})\sqrt{n\pi}}\left(1+\frac{x^2}{n}\right)^{-\frac{n+1}{2}},\ x\in\mathcal{R}.$$

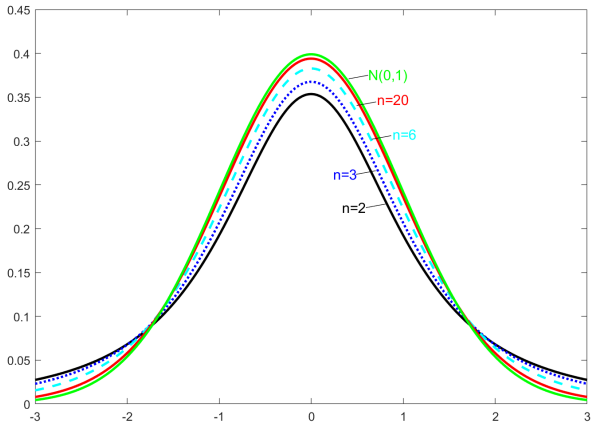


图5.2 不同自由度的t分布的密度函数曲线。

图5.2展示了不同自由度的t分布的密度函数曲线。t_n的密度函数与标准正态分布$N(0,1)$密度函数曲线相似,，它们都是关于原点对称、单峰的偶函数、在$x=0$ 处达到最大。但t_n的峰值低于$N(0,1)$的峰值，t_n的密度函数尾部要比$N(0,1)$的两侧尾部厚一些。

t分布的来源。记$X_1,\ X_2,\ \cdots,\ X_n\ iid\sim N(\mu,\sigma^2),\ \bar{X}$是样本均值，$S$是样本标准差。Gosset(1876-1937)发现当样本量n比较小时，$\sqrt{n}(\bar{X}-\mu)/S$的分布

和$N(0,1)$并不相同，尤其尾部概率相差较大。经过研究，Gosset于1908年以笔名Student发表了一篇论文，提出了t分布，故后人称为“学生氏(student)分布”或“t分布”。

t分布的性质

性质1 令随机变量$T \sim t_n$.

(1)当$n=1$时，T的数学期望不存在；

(2)当$n=2$ 时, $ET=0$, 方差不存在；

(3)当$n \geq 3$时, $ET=0, \mathrm{var}(T)=\frac{n}{n-2}$.

证明： 当$n \geq 2$时，

$$ET = E\left(X/\sqrt{Y/n}\right) = EX \times E\left(1/\sqrt{Y/n}\right) = 0 \times E\left(1/\sqrt{Y/n}\right) = 0.$$

当$n \geq 3$时，

$$\mathrm{var}(T) = E\left(X/\sqrt{Y/n}\right)^2 - \left[E\left(X/\sqrt{Y/n}\right)\right]^2 = nEX^2E\left(1/Y\right) = nE\left(1/Y\right).$$

而

$$\begin{aligned} E(1/Y) &= \int_0^\infty \frac{1}{y}\frac{1}{2^{\frac{n}{2}}\Gamma(\frac{n}{2})}y^{\frac{n}{2}-1}e^{-\frac{y}{2}}dy \\ &= \frac{1}{2^{\frac{n}{2}}\Gamma(\frac{n}{2})}\int_0^\infty y^{\frac{n-2}{2}-1}e^{-\frac{y}{2}} \\ &= \frac{1}{2^{\frac{n}{2}}\Gamma(\frac{n}{2})}2^{\frac{n-2}{2}}\Gamma\big(\frac{n}{2}-1\big) \\ &= \frac{1}{n-2}. \end{aligned}$$

所以，$\mathrm{var}(T) = n/(n-2)$.

性质2 自由度为1的t分布是标准Cauchy分布，即$t_1 = Cauchy(0,1)$.

性质3 当$n \to \infty$时，t分布的极限分布是$N(0,1)$.

证明：

$$\lim_{n\to\infty}\frac{\Gamma\left(\frac{n+1}{2}\right)}{\Gamma\left(\frac{n}{2}\right)\sqrt{n\pi}} = \frac{1}{\sqrt{2\pi}}, \lim_{n\to\infty}\left(1+\frac{x^2}{n}\right)^{-\frac{n+1}{2}} = e^{-\frac{x^2}{2}}.$$

3. F**分布：**

F **分布：** 令随机变量$X \sim \chi_n^2$, $Y \sim \chi_m^2$, 且X,Y相互独立。则

$$Z = \frac{X/n}{Y/m}$$

服从自由度为n和m的F分布，记作$Z \sim F_{n,m}$.

$F_{n,m}$的密度函数为

$$f_{n,m}(x) = \begin{cases} \frac{\Gamma(\frac{n+m}{2})}{\Gamma(\frac{n}{2})\Gamma(\frac{m}{2})}n^{\frac{n}{2}}n^{\frac{m}{2}}x^{\frac{n}{2}-1}(m+nx)^{-\frac{n+m}{2}}, & x>0, \\ 0, & \text{其它。} \end{cases}$$

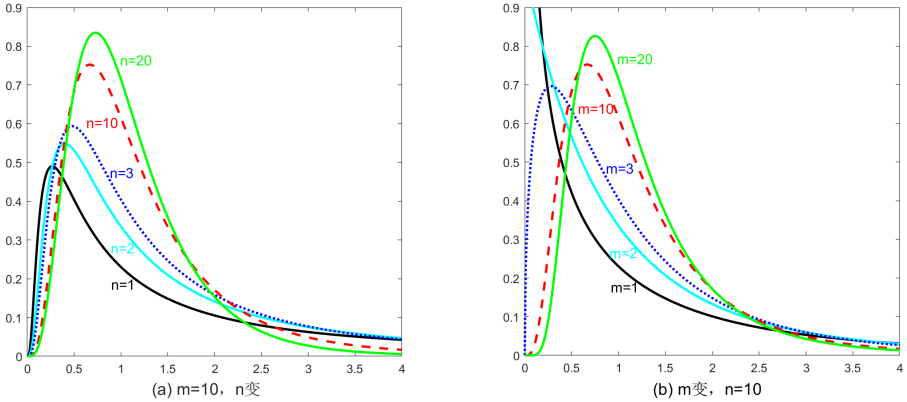


图5.3 不同自由度的F分布的密度函数曲线。

图5.3展示了不同自由度的F分布的密度函数曲线。F 分布的自由度n和m是有顺序的，当$n \neq m$ 时，若将自由度n和m的顺序颠倒一下，得到的是两个不同的F分布。可见F分布的密度函数曲线是有偏的。比如，当n固定时，m越小偏态越严重。

$F_{n,m}$分布的期望与方差为

$$\begin{aligned} EX &= \frac{m}{m-2}, m \geq 3, \\ \mathrm{var}(X) &= \frac{2m^2(n+m-2)}{n(m-2)^2(m-4)}, m \geq 5, \end{aligned}$$

F分布的性质

性质1 令随机变量$Z \sim F_{n,m}$. 则$1/Z \sim F_{m,n}$.

性质2 令随机变量$T \sim t_n$. 则$T^2 \sim F_{1,n}$.

性质3 令自由度为n, m的F分布的$1-\alpha$ 分位数为$F_{n,m}(1-\alpha)$. 则$F_{n,m}(1-\alpha) = 1/F_{m,n}(\alpha)$.

证明： 记$X \sim F_{n,m}$, 有$1/X \sim F_{m,n}$. 因此

$$\begin{aligned} P\left(X \leq F_{n,m}(1-\alpha)\right) &= P\left(1/X \geq F_{m,n}(\alpha)\right) \\ &= P\left(X \leq 1/F_{m,n}(\alpha)\right) \end{aligned}$$

所以$F_{n,m}(1-\alpha) = 1/F_{m,n}(\alpha)$.

性质4 令随机变量$Z \sim F_{n,m}$, 当n固定，$m \to \infty$, 有$nZ \xrightarrow{d} \chi^2_n$.

证明： 由F分布的定义知$Z = \frac{X/n}{Y/m}$, 其中$X \sim \chi^2_n, Y \sim \chi^2_m$. 则$nZ = \frac{X}{Y/m}$, 考察其分母，有

$$E(Y/m) = 1, \mathrm{var}\left(\frac{2}{m}\right) = \frac{2}{m} \xrightarrow{m\to\infty} 0.$$

由Chebyshev不等式知

$$\frac{Y}{m} \xrightarrow{p} 1.$$

再由Slustky定理知$nZ \xrightarrow{d} \chi_n^2$.

例5.9 令随机变量$X \sim F_{n,n}$. 求证：$P(X > 1) = 0.5$.

证明： 由$X \sim F_{n,n}$知$Y = 1/X \sim F_{n,n}$. 进而有

$$P(X > 1) = P(Y > 1) = P(1/X > 1) = P(X < 1).$$

由$P(X > 1) + P(X < 1) = 1$知$P(X > 1) = 0.5$.

5.3 正态总体样本均值和样本方差的分布

正态总体是一类常见的总体，有关正态总体及其相关分布的统计推断在统计理论和应用研究中占据十分重要的地位。下面给出正态总体有关统计量的概率分布，包括正态随机变量线性函数的分布和正态随机变量样本均值和样本方差的分布。

定理5.3 令随机变量$X_1, X_2, \cdots, X_n$ $iid \sim N(\mu, \sigma^2)$, $c_1, c_2, \cdots, c_n$是n个不全为0的常数。则

$$T = \sum_{k=1}^{n} c_k X_k \ \sim \ N\left(\mu \sum_{k=1}^{n} c_k, \sigma^2 \sum_{k=1}^{n} c_k^2\right).$$

证明：由第三章第3.6节多元正态分布性质2得证。

定理5.4 令$X_1, X_2, \cdots, X_n$ $iid \sim N(\mu, \sigma^2)$, 样本均值和样本方差分别为$\bar{X}$和$S^2$. 则

(1)$\bar{X} \sim N\left(\mu, \frac{1}{n}\sigma^2\right)$;

(2)$\dfrac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1}$;

(3)$\bar{X}$和S^2独立；

(4)$T = \dfrac{\sqrt{n}(\bar{X} - \mu)}{S} \sim t_{n-1}$.

证明：(1)由定理5.3可得。

(2)记$X = (X_1, X_2, \cdots, X_n)^\top$, $Y = \dfrac{X - \boldsymbol{\mu}}{\sigma}$, $\mathbf{H} = \mathbf{I}_n - \frac{1}{n}\mathbf{1}_n\mathbf{1}_n^\top$, 其中$\boldsymbol{\mu} = (\mu, \mu, \cdots, \mu)^\top$, 则

$$\begin{aligned} Y &\sim N(\mathbf{0}_n, \mathbf{I}_n), \\ \frac{(n-1)S^2}{\sigma^2} &= \frac{1}{\sigma^2}\sum_{i=1}^{n}(X_i - \bar{X})^2 \\ &= \sum_{i=1}^{n}(Y_i - \bar{Y})^2 \\ &= Y^\top \mathbf{H} Y, \end{aligned}$$

由于$\mathbf{H}$是对称幂等阵，且$\mathrm{rk}(\mathbf{H}) = n - 1$. 根据$\chi^2$分布的性质5，有

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1}.$$

(3)由第三章第3.6节多元正态分布的性质6及

$$\bar{X} = \frac{1}{n}\mathbf{1}_n^\top X = \mu + \frac{1}{n}\sigma \mathbf{1}_n^\top Y, \ \ \mathbf{1}_n^\top \mathbf{H} = \mathbf{0}_n^\top,$$

知$\bar{X}$和S^2相互独立。

(4)由题意知$\sqrt{n}(\bar{X}-\mu)/\sigma \sim N(0,1)$. 又$(n-1)S^2/\sigma^2 \sim \chi^2_{n-1}$, 且$\bar{X}$, S^2相互独立，由t分布的定义有

$$T=\frac{\sqrt{n}(\bar{X}-\mu)/\sigma}{\sqrt{S^2/\sigma^2}}=\frac{\sqrt{n}(\bar{X}-\mu)}{S}\sim t_{n-1}.$$

定理5.5 令$X_1,X_2\cdots,X_n\ iid\sim N\big(\mu_1,\sigma^2\big)$, $Y_1,Y_2,\cdots,Y_m\ iid\sim N\big(\mu_2,\sigma^2\big)$. 两组样本相互独立。记

$$\bar{X}=\frac{1}{n}\sum_{i=1}^{n}X_i,\ \bar{Y}=\frac{1}{m}\sum_{j=1}^{m}Y_j,$$

$$S_1^2=\frac{1}{n-1}\sum_{i=1}^{n}(X_i-\bar{X})^2,\ S_2^2=\frac{1}{m-1}\sum_{j=1}^{m}(Y_j-\bar{Y})^2,$$

$$S_0=\sqrt{\frac{1}{n+m-2}\big[(n-1)S_1^2+(m-1)S_2^2\big]}.$$

则

$$T=\frac{(\bar{X}-\bar{Y})-(\mu_1-\mu_2)}{S_0}\sqrt{\frac{nm}{n+m}}\sim t_{n+m-2}.$$

证明：由题意易知

$$\bar{X}\sim N(\mu_1,\sigma^2/n),\ \bar{Y}\sim N(\mu_2,\sigma^2/m),$$

$$\bar{X}-\bar{Y}\sim N\left(\mu_1-\mu_2,\left(\frac{1}{n}+\frac{1}{m}\right)\sigma^2\right),$$

$$\frac{(\bar{X}-\bar{Y})-(\mu_1-\mu_2)}{\sigma}\sqrt{\frac{nm}{n+m}}\sim N(0,1).$$

由定理5.4知

$$\frac{(n-1)S_1^2}{\sigma^2}\sim\chi^2_{n-1},\ \frac{(m-1)S_2^2}{\sigma^2}\sim\chi^2_{m-1},$$

$$\frac{(n-1)S_1^2+(m-1)S_2^2}{\sigma^2}\sim\chi^2_{n+m-2}.$$

根据t分布的定义，

$$\begin{aligned}T &= \frac{(\bar{X}-\bar{Y})-(\mu_1-\mu_2)}{\sigma}\sqrt{\frac{nm}{n+m}}\Bigg/\sqrt{\frac{(n-1)S_1^2+(m-1)S_2^2}{\sigma^2(n+m-2)}}\\ &= \sqrt{\frac{nm}{n+m}}\frac{(\bar{X}-\bar{Y})-(\mu_1-\mu_2)}{S_0}\end{aligned}$$

及$(\bar{X},\bar{Y})$与(S_1^2,S_2^2)相互独立可知$T\sim t_{n+m-2}$.

定理5.6 令$X_1,X_2,\cdots,X_n\ iid\sim N\big(\mu_1,\sigma_1^2\big)$ $Y_1,Y_2,\cdots,Y_m\ iid\ \sim N\big(\mu_2,\sigma_2^2\big)$, 两组样本相互独立。记

$$\bar{X}=\frac{1}{n}\sum_{i=1}^{n}X_i,\ \bar{Y}=\frac{1}{m}\sum_{j=1}^{m}Y_j,$$

$$S_1^2=\frac{1}{n-1}\sum_{i=1}^{n}(X_i-\bar{X})^2,\ S_2^2=\frac{1}{m-1}\sum_{j=1}^{m}(Y_j-\bar{Y})^2.$$

则

$$T=\frac{S_1^2}{S_2^2}\frac{\sigma_2^2}{\sigma_1^2}\sim F_{n-1,m-1}.$$

证明： 由题意知$(n-1)S_1^2/\sigma_1^2\sim\chi_{n-1}^2$, $(m-1)S_2^2/\sigma_2^2\sim\chi_{m-1}^2$, 且两者相互独立。由$F$分布的定义知

$$T=\frac{\frac{(n-1)S_1^2}{\sigma_1^2}/(n-1)}{\frac{(m-1)S_2^2}{\sigma_2^2}/(m-1)}=\frac{S_1^2}{S_2^2}\frac{\sigma_2^2}{\sigma_1^2}\sim F_{n-1,m-1}.$$

例5.10 令$X_1,X_2,\cdots,X_n,X_{n+1}\ iid\sim N(\mu,\sigma^2)$. 记

$$\bar{X}=\frac{1}{n}\sum_{i=1}^{n}X_i,\ S^2=\frac{1}{n-1}\sum_{i=1}^{n}(X_i-\bar{X})^2.$$

求$\sqrt{\frac{n}{n+1}}\frac{X_{n+1}-\bar{X}}{S}$的分布。

解： 由第三章第3.6节多元正态分布的性质2知

$$X_{n+1}-\bar{X}\sim N\Big(0,\sigma^2+\frac{1}{n}\sigma^2\Big).$$

定理5.4告诉我们

$$\frac{(n-1)S^2}{\sigma^2}\sim\chi_{n-1}^2.$$

又因为$X_{n+1}-\bar{X}$与S^2相互独立，根据t分布的定义有

$$\frac{(X_{n+1}-\bar{X})/\sqrt{\sigma^2+\frac{1}{n}\sigma^2}}{\sqrt{\frac{(n-1)S^2}{\sigma^2}/(n-1)}}\sim t_{n-1}.$$

化简得

$$\sqrt{\frac{n}{n+1}}\frac{X_{n+1}-\bar{X}}{S}\sim t_{n-1}.$$

例5.11 令$X_1,X_2,\cdots,X_{2n}\ iid\sim N(\mu,\sigma^2)$,

$$\bar{X}=\frac{1}{2n}\sum_{i=1}^{2n}X_i,\ Y=\frac{1}{n}\sum_{i=1}^{n}(X_i+X_{n+i}-2\bar{X})^2.$$

求EY.

解： 记$Z_i=X_i+X_{n+i}, i=1,2,\cdots,n.$ 则$Z_1,Z_2,\cdots,Z_n\ iid\sim N(2\mu,2\sigma^2)$. 进而有

$$\bar{Z}=\frac{1}{n}\sum_{i=1}^{n}Z_i=\frac{1}{n}\sum_{i=1}^{2n}X_i=2\bar{X}$$

所以

$$\begin{aligned} EY &= E\Big[\frac{1}{n}\sum_{i=1}^{n}(X_i + X_{n+i} - 2\bar{X})^2\Big] \\ &= E\Big[\frac{1}{n}\sum_{i=1}^{n}(Z_i - \bar{Z})^2\Big] \\ &= \frac{2\sigma^2}{n}E\Big[\sum_{i=1}^{n}\frac{(Z_i - \bar{Z})^2}{2\sigma^2}\Big] \\ &= \frac{2\sigma^2}{n} \times (n-1) \\ &= \frac{2(n-1)\sigma^2}{n}. \end{aligned}$$

5.4 相关系数

为了研究随机变量X和Y的相关性，对$(X,Y)^\top$进行n次独立的观测，记观测的样本为

$$(X_1,Y_1)^\top,(X_2,Y_2)^\top,\cdots,(X_n,Y_n)^\top.$$

对$X_1,X_2,\cdots,X_n$从小到大排序，记X_i在$X_1,X_2,\cdots,X_n$中的秩为$R_{Xi},i=1,2,\cdots,n.$同样对$Y_1,Y_2,\cdots,Y_n$也从小到大排序，记Y_j在$Y_1,Y_2,\cdots,Y_n$中的秩为$R_{Yj},\ j=1,2,\cdots,n.$ 如果出现多个观测数据的数值相等，那么它们的秩就用排序的平均值代替，比如5个观测数据为

$$X_1=-5,\ X_2=-8,\ X_3=2,\ X_4=10,\ X_5=2.$$

把它们按照从小到大排序，它们的秩依次为

$$R_{X1}=2,\ R_{X2}=1,\ R_{X3}=3.5,\ R_{X4}=5,\ R_{X5}=3.5.$$

下面介绍三种常用的描述随机变量X与Y之间相关性的度量。

Pearson相关系数：Pearson相关系数常用来描述两组数据的线性相关程度，定义如下

$$r=\frac{\sum\limits_{k=1}^{n}(X_k-\bar{X})(Y_k-\bar{Y})}{\sqrt{\sum\limits_{i=1}^{n}(X_i-\bar{X})^2\sum\limits_{j=1}^{n}(Y_j-\bar{Y})^2}}$$

其中$\bar{X}=\dfrac{1}{n}\sum\limits_{i=1}^{n}X_i,\ \bar{Y}_j=\dfrac{1}{n}\sum\limits_{j=1}^{n}Y_j.$

Pearson相关系数又称线性相关系数，受极端值的影响较大。

Spearman ρ相关系数：Spearman ρ相关系数定义为

$$\rho=\frac{\sum\limits_{k=1}^{n}(R_{Xk}-\bar{R}_X)(R_{Yk}-\bar{R}_Y)}{\sqrt{\sum\limits_{i=1}^{n}(R_{Xi}-\bar{R}_X)^2\sum\limits_{j=1}^{n}(R_{Yj}-\bar{R}_Y)^2}},$$

其中$\bar{R}_X=\dfrac{1}{n}\sum\limits_{i=1}^{n}R_{Xi},\ \bar{R}_Y=\dfrac{1}{n}\sum\limits_{j=1}^{n}R_{Yj}.$

Spearman ρ相关系数又称秩的Pearson相关系数，它对原始数据的分布不做要求，受极端值的影响较小。

Kendall τ相关系数：Kendall τ相关系数是另一种基于秩的相关系数，定义为

$$\tau=\frac{2}{n(n-1)}\sum_{1\le i<j\le n}\operatorname{sgn}(X_i-X_j)\times\operatorname{sgn}(Y_i-Y_j),$$

其中

$$\mathrm{sgn}(z)=\begin{cases}-1, & z<0,\\ 0, & z=0,\\ 1, & z>0.\end{cases}$$

Kendall τ相关系数对原始数据的分布不做要求，受极端值的影响较小。

例5.12 一生物学实验有5只小鼠，测得酒精干预前后小鼠体内两种生物标记物含量的变化量如下：

$$\text{生物标记物}A:\ 0.1,\ 0.2,\ 0.3,\ 0.4,\ 0.5;$$

$$\text{生物标记物}B:\ 0.3,\ 2.0,\ 0.9,\ 1.7,\ 2.6.$$

求这两种生物标记物含量的变化量的Pearson相关系数、Spearman ρ相关系数和Kendall τ相关系数。

解： 记$x=(x_1,x_2,x_3,x_4,x_5)^\top=(0.1,0.2,0.3,0.4,0.5)^\top$为第一种生物标记物含量的变化量，$y=(y_1,y_2,y_3,y_4,y_5)^\top=(0.3,2,0.9,1.7,2.6)^\top$为第二种生物标记物含量的变化量。

(1) Pearson相关系数：

由于$\bar{x}=0.3,\bar{y}=1.5,\sum\limits_{i=1}^{5}(x_i-\bar{x})^2=0.1,\sum\limits_{i=1}^{5}(y_i-\bar{y})^2=3.3$, 则

$$r=\frac{\sum\limits_{k=1}^{5}(x_k-\bar{x})(y_k-\bar{y})}{\sqrt{\sum\limits_{i=1}^{5}(x_i-\bar{x})^2\sum\limits_{j=1}^{5}(y_j-\bar{y})^2}}=\frac{0.43}{\sqrt{0.1\times3.3}}\approx0.75.$$

(2) Spearman ρ相关系数：

将x中的元素按从小到大排序，$R_x=(R_{x1},R_{x2},R_{x3},R_{x4},R_{x5})^\top=(1,2,3,4,5)$. 同理有$R_y=(R_{y1},R_{y2},R_{y3},R_{y4},R_{y5})^\top=(1,4,2,3,5)^\top$. 因此，$\bar{R}_x=\bar{R}_y=3,\sum\limits_{i=1}^{5}(R_{xi}-\bar{R}_x)^2=\sum\limits_{i=1}^{5}(R_{yi}-\bar{R}_y)^2=10,$

$$\rho=\frac{\sum\limits_{i=1}^{5}(R_{xi}-\bar{R}_x)(R_{yi}-\bar{R}_y)}{\sqrt{\sum\limits_{i=1}^{5}(R_{xi}-\bar{R}_x)^2\sum\limits_{j=1}^{5}(R_{yj}-\bar{R}_y)^2}}=\frac{7}{\sqrt{10\times10}}=0.7.$$

(3) Kendall τ相关系数：对$1\le i,j\le5$,

数据对$\mathrm{sgn}(x_i-x_j)\times\mathrm{sgn}(y_i-y_j)=-1$ 的有2个，它们是

$$(x_2,x_3)=(0.2,0.3),(y_2,y_3)=(2,0.9)\big|(x_2,x_4)=(0.2,0.4),(y_2,y_4)=(2,1.7).$$

数据对$\text{sgn}(x_i - x_j) \times \text{sgn}(y_i - y_j) = -1$ 的有2个，$\text{sgn}(x_i - x_j) \times \text{sgn}(y_i - y_j) = 1$ 的有8个，它们是

$$(x_1, x_2) = (0.1, 0.2), (y_1, y_2) = (0.3, 2.0) \big| (x_1, x_3) = (0.1, 0.3), (y_1, y_3) = (0.3, 0.9),$$

$$(x_1, x_4) = (0.1, 0.4), (y_1, y_4) = (0.3, 1.7) \big| (x_1, x_5) = (0.1, 0.5), (y_1, y_5) = (0.3, 2.6),$$

$$(x_2, x_5) = (0.2, 0.5), (y_2, y_5) = (2.0, 2.6) \big| (x_3, x_4) = (0.3, 0.4), (y_3, y_4) = (0.9, 1.7),$$

$$(x_3, x_5) = (0.3, 0.5), (y_3, y_5) = (0.9, 2.6) \big| (x_4, x_5) = (0.4, 0.5), (y_4, y_5) = (1.7, 2.6).$$

因此，

$$\tau = \frac{2}{5(5-1)} \sum_{1 \le i < j \le 5} sgn(x_i - x_j) \times sgn(y_i - y_j) = \frac{8-2}{10} = 0.6.$$

习题五

样本和统计量

1. 从一小区N名居民中随机抽取6人，测得他们的心率(单位：次/分)为：

$$60,\ 65,\ 74,\ 77,\ 81,\ 68.$$

(1)给出总体、样本、样本量；(2)计算样本均值、样本方差。

2. 考察一批日光灯的使用寿命，从中随机抽取10盏日光灯，它们的寿命(单位：万小时)如下：

$$1.5,\ 1.4,\ 1.6,\ 1.7,\ 2.0,\ 2.1,\ 1.8,\ 1.9,\ 2.1,\ 1.8.$$

(1)给出总体、样本、样本量；(2)计算样本均值、样本方差。

3. 考察简单样本$x_1, x_2, \cdots, x_n$, 把它们从小到大排序为

$$x_{(1)} \le x_{(2)} \le \cdots \le x_{(n)}.$$

记$\alpha \in (0,1)$, 同时删去样本中$\lfloor n\alpha/2 \rfloor$个数值小的和$\lfloor n\alpha/2 \rfloor$个数值大的观测值，对剩余的观测值求均值，记作$\bar{x}_\alpha$, 即

$$\bar{x}_\alpha = \frac{x_{(\lfloor n\alpha/2+1 \rfloor)} + x_{(\lfloor n\alpha/2+2 \rfloor)} + \cdots + x_{(n-\lfloor n\alpha/2 \rfloor)}}{n - 2\lfloor n\alpha/2 \rfloor}.$$

称$\bar{x}_\alpha$为$\alpha-$截尾均值。现有12名用户对一电视节目打分，分值为：

$$83,\ 88,\ 91,\ 86,\ 53,\ 92,\ 100,\ 93,\ 85,\ 84,\ 82,\ 79.$$

求样本均值和$0.1-$截尾均值。

4. 记$X_1, X_2, \cdots, X_n$为简单样本。求证：样本方差可改写为

$$S^2 = \frac{1}{n-1}\left[\sum_{i=1}^n X_i^2 - n\bar{X}^2\right] = \frac{1}{n-1}\sum_{i=1}^n X_i^2 - \frac{1}{n(n-1)}\left(\sum_{i=1}^n X_i\right)^2.$$

5. 考察两组简单样本$X_1, X_2, \cdots, X_n$和$Y_1, Y_2, \cdots, Y_m$, 记它们的样本均值分别为$\bar{X}$和$\bar{Y}$, 样本方差分别为S_1^2和S_2^2,

$$\bar{Z} = \frac{1}{n+m}\left(\sum_{i=1}^n X_i + \sum_{j=1}^m Y_j\right),\ S_3^2 = \frac{1}{n+m-1}\left[\sum_{i=1}^n (X_i - \bar{Z})^2 + \sum_{j=1}^m (Y_j - \bar{Z})\right],$$

求证：$\bar{Z} = \dfrac{n\bar{X} + m\bar{Y}}{n+m}$, $S_3^2 = \dfrac{(n-1)S_1^2 + (m-1)S_2^2}{n+m-1} + \dfrac{nm(\bar{X} - \bar{Y})^2}{(n+m)(n+m+1)}$.

6. 令$X_1, X_2, \cdots, X_n$ $iid \sim F(x), x \in \mathcal{R}$, $F(x)$的四阶矩存在，$\sigma^2 = E(X - EX)^2$, $\zeta = E(X - EX)^3$, $\theta = E(X - EX)^4$. 记样本均值和样本方差分别为$\bar{X}$和S^2. 求证：
(1)对任意$i \neq j \in \{1, 2, \cdots, n\}$, $X_i - \bar{X}$ 与$X_j - \bar{X}$的相关系数为$-1/(n-1)$;
(2)$\mathrm{var}(S^2) = \dfrac{n(\theta - \sigma^4)}{(n-1)^2} - \dfrac{2(\theta - 2\sigma^4)}{(n-1)^2} + \dfrac{\theta - 3\sigma^4}{n(n-1)^2}$;
(3)$\mathrm{cov}(\bar{X}, S^2) = \zeta/n$.

7. (1)令$X_1, X_2, \cdots, X_n, iid \sim N(0,1)$. 求次序统计量最大值的分布函数和密度函数；
(2)令$X_1, X_2, \cdots, X_n, iid \sim U(0,1)$. 求次序统计量最小值的分布函数和密度函数。

三大分布

8. 令连续型随机变量$X_1, X_2, \cdots, X_n$ $iid \sim F(x)$, $F(x)$是严格递增的连续函数。求$-2\sum_{i=1}^{n} \ln F(X_i)$ 的分布。

9. 令X_1, X_2, X_3 $iid \sim N(0,1)$. 若

$$k\Big(\frac{1}{2}X_1^2 + \frac{1}{2}X_2^2 + \frac{1}{2}X_3^2 + X_1X_2 + X_1X_3 + X_2X_3\Big)$$

服从χ^2分布。求k和χ^2分布的自由度。

10. 令$X_1, X_2, \cdots, X_m, X_{m+1}, X_{m+2}, \cdots, X_n$ $iid \sim N(0,1)$. 记

$$Y = (X_1 + X_2 + \cdots + X_m)^2 + (X_{m+1} + X_{m+2} + \cdots + X_n)^2.$$

求常数c使得cY服从χ^2分布。

11. 令$X_1, X_2, \cdots, X_{2n}$ $iid \sim N(0,1)$. 求

$$Y = \frac{1}{2}\sum_{i=1}^{2n} X_i^2 + \sum_{i=1}^{n} X_{2i-1}X_{2i}$$

的分布。

12. 令$X_1, X_2, X_3, X_4, X_5, X_6, X_7, X_8, X_9$ $iid \sim N(0,1)$. 求c, 使得

$$\frac{c(X_1 + X_2 + X_3)}{\sqrt{(X_4 + X_5)^2 + (X_6 + X_7)^2 + (X_8 + X_9)}} \sim t_3.$$

13. 令$X_1, X_2, \cdots, X_n$ $iid \sim N(0,1)$. 记样本方差为S^2. 求X_1^2/S^2的分布。

14. 令$X_1, X_2, \cdots, X_n$ $iid \sim N(\mu_1, \sigma^2)$, $Y_1, Y_2, \cdots, Y_m$ $iid \sim N(\mu_2, \sigma^2)$, 两组样本相互独立。记$c, d$是不为0的常数，

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i, \ \ \bar{Y} = \frac{1}{m}\sum_{j=1}^{m} Y_j,$$

$$S_0^2 = \frac{1}{n+m-2}\left[\sum_{i=1}^{n}(X_i - \bar{X})^2 + \sum_{j=1}^{m}(Y_j - \bar{Y})^2\right].$$

求$\dfrac{c(\bar{X}-\mu_1)+d(\bar{Y}-\mu_2)}{S_0\sqrt{\frac{c^2}{n}+\frac{d^2}{m}}}$的分布。

15. 令$(X_1, Y_1)^\top, (X_2, Y_2)^\top, \cdots, (X_n, Y_n)^\top$ $iid \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$. 记

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i,\ \bar{Y} = \frac{1}{n}\sum_{i=1}^{n} Y_i,\ S_1^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \bar{X})^2,\ S_2^2 = \frac{1}{n}\sum_{i=1}^{n}(Y_i - \bar{Y})^2,$$

$$r = \frac{\sum_{i=1}^{n}(X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^{n}(X_i - \bar{X})^2}\sqrt{\sum_{i=1}^{n}(Y_i - \bar{Y})^2}},\ T = \frac{\sqrt{n-1}\big[\bar{X} - \bar{Y} - (\mu_1 - \mu_2)\big]}{\sqrt{S_1^2 + S_2^2 - 2rS_1S_2}}.$$

求T的分布。

16. 令X_1, X_2, X_3 $iid \sim N(\mu, \sigma^2)$. 求$(X_1 - X_2)\big/\big[\sqrt{2}|X_3 - \mu|\big]$的分布。

17. 令$X_1, X_2, \cdots, X_n$ $iid \sim N(0, 1)$. 记

$$Y = a(X_1 + X_2 + \cdots + X_m)^2 + b(X_{m+1} + X_{m+2} + \cdots + X_n)^2,$$

$$Z = \frac{c(X_1 + X_2 + \cdots + X_m)}{\sqrt{X_{m+1}^2 + X_{m+2}^2 + \cdots + X_n^2}},\ m < n.$$

若Y服从χ^2分布，Z服从t分布，求a, b, c.

18. 令$X_1, X_2, \cdots, X_n$ $iid \sim N(\mu, \sigma^2)$, 样本均值为$\bar{X}$, 样本方差为$S^2$. 记$Y \sim N(\mu, k\sigma^2), k > 0$, 且$Y$与$X_1, X_2, \cdots, X_n$相互独立。求$\sqrt{n}\left(\bar{X} - Y\right)\big/\sqrt{(1+nk)S^2}$的分布。

19. 令$X_1, X_2, \cdots, X_n$ $iid \sim N(\mu, \sigma^2)$. 求证：

$$\sum_{i=1}^{n}(X_i - \mu)^2 \sim Gamma\left(\frac{n}{2}, \frac{1}{2\sigma^2}\right).$$

20. 令$X \sim F_{n,m}$. 求证：

$$\frac{nX/m}{(1+nX/m)} \sim Beta\Big(\frac{n}{2}, \frac{m}{2}\Big).$$

21. 令$Z \sim F_{n,m}$. 求证：
(1)当$m > 2$时，$EZ = \dfrac{m}{m-2}$;
(2)当$m > 4$时，$\mathrm{var}(Z) = \dfrac{2m^2(n+m-2)}{n(m-2)^2(m-4)}$;
(3)当$\min\{m,n\} \to \infty$,

$$\frac{Z - \frac{m}{m-2}}{\sqrt{\frac{2m^2(n+m-2)}{n(m-2)^2(m-4)}}} \xrightarrow{d} N(0,1).$$

22. 令X, Y $iid \sim N(0,1)$. 求证：

$$\frac{(X-Y)^2}{(X+Y)^2} \sim F_{1,1}.$$

正态总体

23. 令$X_1, X_2, \cdots, X_n$ $iid \sim N(\mu, \sigma^2)$. 记样本均值和样本方差分别为$\bar{X}$和$S^2$. 求$\mathrm{var}(\bar{X}S^2)$.

24. 令$X_1, X_2, \cdots, X_n, X_{n+1}, X_{n+2}$ $iid \sim N(0, \sigma^2)$. 记

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i,\ S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2.$$

求：(1)$X_{n+1} + X_{n+2} - \frac{1}{n+1}\sum\limits_{i=1}^{n+1} X_i$的分布；(2)$\frac{X_1^2+X_2^2}{2S^2}$的分布；
(3)a, b使得

$$\frac{a(X_{n+1} + X_{n+2} - \bar{X})}{S}, \frac{b(X_{n+1} - X_{n+2} - \bar{X})}{S}$$

都服从t分布，并给出它们的自由度。

25. 令$X_1, X_2, \cdots, X_n$ $iid \sim N(\mu_1, \sigma^2)$, $Y_1, Y_2, \cdots, Y_m$ $iid \sim N(\mu_2, \sigma^2)$, 两组样本相互独立。记两组样本的样本均值分别为$\bar{X}$和$\bar{Y}$, 样本方差分别为$S_1^2$和$S_2^2$, $S_0^2 = \frac{(n-1)S_1^2 + (m-1)S_2^2}{n+m-2}$, a, b是两个不为0的常数。求证：

$$\frac{a(\bar{X} - \mu_1) + b(\bar{Y} - \mu_2)}{S_0\sqrt{a^2/n + b^2/m}} \sim t_{n+m-2}.$$

26. 令$X_1, X_2, \cdots, X_n$ $iid \sim N(\mu_1, \sigma^2)$, $Y_1, Y_2, \cdots, Y_m$ $iid \sim N(\mu_2, \sigma^2)$, 两组样本相互独立。求证：

$$\frac{\sum\limits_{i=1}^{n}(X_i - \bar{X})^2}{\sum\limits_{i=1}^{n}(X_i - \bar{X})^2 + \sum\limits_{j=1}^{m}(Y_j - \bar{Y})^2} \sim Beta\left(\frac{n-1}{2}, \frac{m-1}{2}\right).$$

第六章　参数估计

先看一个例子。为了判断某暴露因素与某种人类复杂疾病是否有关联，比如吸烟和肺癌，研究者们通常会搜集一些肺癌患者和健康者的指标值，通过考察吸烟在肺癌患者和健康者之间的差异进而判断吸烟与肺癌关联与否以及关联的强度。该差异通常可以用一些未知参数或者未知参数的函数来度量。研究者们需要基于抽到的观测数据来对度量差异的量进行估计。令总体的分布函数为$F(x,\theta)$, θ是未知参数。我们希望通过观测到的数据$X_1, X_2, \cdots, X_n$来了解参数θ或者θ的函数$g(\theta)$值的大小，其中$g(\cdot)$是已知的函数。比如，θ的值是多少？$g(\theta)$以多大的概率落在某个区间？这两类问题分别涉及到点估计和区间估计，我们统称之为参数估计。

除非特别说明，本章提到“总体X的密度函数$f(x,\theta)$”的意思如下：
(1)如果X是连续型随机变量，$f(x,\theta)$是X的密度函数；
(2)如果X是离散型随机变量，$f(x,\theta)$是X的概率函数。

6.1 点估计

令总体X的密度函数为$f(x,\theta)$, $\theta = (\theta_1, \theta_2, \cdots, \theta_k)^\top \in \Theta$, 待估参数为$g(\theta)$. 现从总体中抽取一组简单随机样本：$X_1$, X_2, $\cdots$, X_n, 即X_1, X_2, $\cdots$, X_n $iid \sim f(x,\theta)$. 基于该简单样本构造一个函数$\hat{g} = \hat{g}(X_1, X_2, \cdots, X_n)$估计$g(\theta)$. 相当于用实数轴上的一个点$\hat{g}$去估计另外一个点$g(\theta)$. 称$\hat{g}$为$g(\theta)$的点估计，也称$\hat{g}$为$g(\theta)$的一个估计量。

求点估计的方法有许多种，下面介绍常用的三种估计方法：矩估计、极大似然估计和Bayes估计。

方法一：矩估计

令r为正整数，由大数定律知，如果总体的分布函数满足一定的条件，样本的r阶矩收敛到总体的r阶矩。因此，矩估计的基本思想就是把未知参数表示成总体矩的函数，然后把函数中的总体矩用样本矩来替换。记

样本均值：$\bar{X} = \dfrac{1}{n}\sum_{i=1}^{n} X_i$;

样本方差：$S^2 = \dfrac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2$;

样本标准差：$S = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2}$;

总体r阶中心矩：$E(X - EX)^r$;

总体r阶原点矩：EX^r;

样本r阶中心矩：$\dfrac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^r$;

样本r阶原点矩：$\dfrac{1}{n}\sum_{i=1}^{n}X_i^r$.

根据矩的定义，可以得到如下方程：

$$\begin{cases}\xi_1(\theta_1,\theta_2,\cdots,\theta_k)=EX\\ \xi_2(\theta_2,\theta_2,\cdots,\theta_k)=E(X-EX)^2\\ \quad\vdots\\ \xi_k(\theta_1,\theta_2,\cdots,\theta_k)=E(X-EX)^k.\end{cases}$$

反解得

$$\begin{cases}\theta_1=\eta_1\big(EX,E(X-EX)^2,\cdots,E(X-EX)^k\big)\\ \theta_2=\eta_2\big(EX,E(X-EX)^2,\cdots,E(X-EX)^k\big)\\ \quad\vdots\\ \theta_k=\eta_k\big(EX,E(X-EX)^2,\cdots,E(X-EX)^k\big).\end{cases}$$

将其中的总体矩用相应的样本矩替换，参数$\theta_1,\theta_2,\cdots,\theta_k$的矩估计为

$$\begin{cases}\hat{\theta}_1=\eta_1\Big(\bar{X},S^2,\cdots,\dfrac{1}{n-1}\sum_{i=1}^{n}(X_i-\bar{X})^k\Big)\\ \hat{\theta}_2=\eta_2\Big(\bar{X},S^2,\cdots,\dfrac{1}{n-1}\sum_{i=1}^{n}(X_i-\bar{X})^k\Big)\\ \quad\vdots\\ \hat{\theta}_k=\eta_k\Big(\bar{X},S^2,\cdots,\dfrac{1}{n-1}\sum_{i=1}^{n}(X_i-\bar{X})^k\Big).\end{cases}$$

记$\hat{\theta}=(\hat{\theta}_1,\hat{\theta}_2,\cdots,\hat{\theta}_k)^\top$. $\hat{\theta}$是θ的矩估计，可用$g\big(\hat{\theta}\big)$作为$g(\theta)$的矩估计。采用不同的矩就会得到待估参数的不同的矩估计，这导致了矩估计不是唯一的。由于基于低阶矩容易得到显示解并可以简化计算，因此矩估计的原则是：**能用低阶矩就不用高阶矩。**

例6.1 令$X_1,X_2,\cdots,X_n\ iid\ \sim N(\mu,\sigma^2)$. 求$\mu,\sigma^2$的矩估计。

解：由于$EX_1=\mu,\mathrm{var}(X_1)=\sigma^2$, 所以，$\mu,\sigma^2$的矩估计分别为

$$\hat{\mu}=\bar{X},\ \hat{\sigma}^2=\frac{1}{n-1}\sum_{i=1}^{n}(X_i-\bar{X})^2.$$

例6.2 令$X_1,X_2,\cdots,X_n\ iid\sim U(a,b)$. 求$a,b$的矩估计。

解：由于$EX_1=a+b/2,\ \mathrm{var}(X_1)=(b-a)^2/12$, 得

$$a=EX_1-\sqrt{3\mathrm{var}(X_1)},\ b=EX_1+\sqrt{3\mathrm{var}(X_1)}.$$

因此，a,b的矩估计分别为

$$\hat{a}=\bar{X}-\sqrt{3}S,\ \hat{b}=\bar{X}+\sqrt{3}S.$$

方法二：极大似然估计

令总体X的密度函数为$f(x,\theta)$, $\theta\in\Theta$是未知参数。记X_1, X_2, $\cdots$, X_n $iid\sim f(x,\theta)$. 那么$(X_1,X_2,\cdots,X_n)^\top$的联合密度函数为

$$f(x_1,\theta)f(x_2,\theta)\cdots f(x_n,\theta).$$

记$L(\theta)=\prod_{i=1}^n f(X_i,\theta)$. 固定$X_1,X_2,\cdots,X_n$, $L(\theta)$是θ的函数。称$L(\theta)$为似然函数，它反映了θ取某值时, 观测到$X_1,X_2,\cdots,X_n$的可能性大小，这种可能性大小称为“似然”。记

$$\hat\theta=\arg\max_{\theta\in\Theta}L(\theta).$$

称$\hat\theta$为θ的**极大似然估计**(Maximal likelihood estimate, 简记为MLE)。

极大似然估计具有**不变性**，即对任一函数$g(\theta)$, $g\big(\hat\theta\big)$是$g(\theta)$的极大似然估计。

为了计算上方便，在求极大似然估计之前，常对似然函数求对数，称之为对数似然函数，即$l(\theta)=\ln L(\theta)$. 然后将对数似然函数关于θ求偏导数并令其等于0, 得到似然方程，即

$$\begin{cases}\dfrac{\partial l(\theta)}{\partial\theta_1}=0\\ \dfrac{\partial l(\theta)}{\partial\theta_2}=0\\ \quad\vdots\\ \dfrac{\partial l(\theta)}{\partial\theta_k}=0.\end{cases}$$

解似然方程得到θ的解，记为$\hat\theta$, 然后判断$\hat\theta$是否是对数似然函数的极大值点。判断很重要，似然方程的解不一定都是极大似然估计，见本章习题13. 极大似然估计是目前应用最广泛的点估计方法。

例6.3 令$X_1,X_2,\cdots,X_n$ $iid\sim N(\mu,\sigma^2)$. 求参数μ,σ^2的极大似然估计。

解：似然函数为

$$L(\mu,\sigma^2)=\prod_{i=1}^n\frac{1}{\sqrt{2\pi\sigma^2}}\exp\left(-\frac{(X_i-\mu)^2}{2\sigma^2}\right).$$

对数似然函数为

$$l(\mu,\sigma^2)=-\frac{n}{2}\ln(2\pi)-\frac{n}{2}\ln\sigma^2-\frac{1}{2\sigma^2}\sum_{i=1}^n(X_i-\mu)^2.$$

似然方程为

$$\begin{cases}\dfrac{\partial l(\mu,\sigma^2)}{\partial\mu}=\dfrac{1}{\sigma^2}\displaystyle\sum_{i=1}^n(X_i-\mu)=0\\ \dfrac{\partial l(\mu,\sigma^2)}{\partial\sigma^2}=-\dfrac{n}{2\sigma^2}+\dfrac{1}{2\sigma^4}\displaystyle\sum_{i=1}^n(X_i-\mu)^2=0.\end{cases}$$

求解得到

$$\begin{cases} \hat{\mu} &= \dfrac{1}{n}\sum_{i=1}^{n} X_i = \bar{X}, \\ \hat{\sigma}^2 &= \dfrac{1}{n}\sum_{i=1}^{n}(X_i - \bar{X})^2. \end{cases}$$

可以验证$\big(\hat{\mu}, \hat{\sigma}^2\big)$是$l(\mu, \sigma^2)$的极大值点。因此$\mu, \sigma^2$的极大似然估计分别是$\hat{\mu}, \hat{\sigma}^2$.

如果似然函数或对数似然函数对θ不可微分，甚至它们本身也不连续，这时求极大似然估计要回到原始定义。下面举例说明具体的做法。

例6.4 令$X_1, X_2, \cdots, X_n$ $iid \sim U(a, b)$. 求参数a, b的极大似然估计。

解： 记$X_1, X_2, \cdots, X_n$的次序统计量是$X_{(1)}, X_{(2)}, \cdots, X_{(n)}$. 似然函数为

$$L(a, b) = \frac{1}{(b-a)^n}, a \le X_{(1)} \le X_{(n)} \le b.$$

显然

$$L(a, b) \le \frac{1}{\big(X_{(n)} - X_{(1)}\big)^n}.$$

即似然函数$L(a, b)$在$a = X_{(1)}$, $b = X_{(n)}$处达到最大值。因此，a, b 的极大似然估计分别为

$$\hat{a} = X_{(1)}, \ \hat{b} = X_{(n)}.$$

有时候直接构造似然函数或对数似然函数很难得到未知参数θ的极大似然估计的显式表达式。需要采用函数变换并利用极大似然估计的不变性求θ的极大似然估计。

例6.5 令$X_1, X_2, \cdots, X_n$独立同分布，服从如下离散概率分布

取值	0	1	2
概率	$\frac{1}{2}\big[(1-\theta)^2 + \theta^2\big]$	$2\theta(1-\theta)$	$\frac{1}{2}\big[(1-\theta)^2 + \theta^2\big]$,

其中$\theta \in (0.5, 1)$. 求θ的极大似然估计。

解： 记$\xi = 2\theta(1-\theta)$., 有$\xi \le 0.5$. X_1的概率分布转化为

取值	0	1	2
概率	$\frac{1}{2}(1-\xi)$	ξ	$\frac{1}{2}(1-\xi)$.

记$n_i = \sum_{j=1}^{n} I_{\{X_j = i\}}, i = 0, 1, 2.$ 似然函数为

$$L(\xi) = \left[\frac{1}{2}(1-\xi)\right]^{n_0} \xi^{n_1} \left[\frac{1}{2}(1-\xi)\right]^{n_2} = \xi^{n_1}\left[\frac{1}{2}(1-\xi)\right]^{n-n_1}.$$

对数似然函数为

$$l(\xi) = n_1 \ln \xi + (n - n_1)\ln\frac{1}{2} + (n - n_1)\ln(1-\xi).$$

似然方程为

$$\frac{\partial l(\xi)}{\partial \xi} = \frac{n_1}{\xi} - \frac{n-n_1}{1-\xi} = 0.$$

可得，ξ的极大似然估计为

$$\hat{\xi} = \min\left\{\frac{n_1}{n}, \frac{1}{2}\right\}.$$

反解θ得

$$\theta = \frac{1 \pm \sqrt{1-2\xi}}{2}.$$

考虑$\theta \in (0.5, 1)$ 因此，θ的极大似然估计为

$$\hat{\theta} = \frac{1 + \sqrt{1-2\hat{\xi}}}{2}.$$

类似于矩估计，极大似然估计也不一定唯一，下面举例说明。

例6.6 令$X_1, X_2, \cdots, X_n$ $iid \sim U(\ \theta - 1/2, \theta + 1/2)$, 求参数$\theta$的极大似然估计。

解：记$X_1, X_2, \cdots, X_n$的次序统计量为$X_{(1)}, X_{(2)}, \cdots, X_{(n)}$. 似然函数为

$$\begin{aligned} L(\theta) &= \prod_{i=1}^{n} I_{\{\theta-1/2 \le X_i \le \theta+1/2\}} \\ &= I_{\{\theta-1/2 \le X_{(1)} \le X_{(n)} \le \theta+1/2\}} \\ &= I_{\{X_{(n)}-1/2 \le \theta \le X_{(1)}+1/2\}}. \end{aligned}$$

由于$L(\theta)$只取0和1，使$L(\theta) = 1$对应的$\hat{\theta}$是θ的极大似然估计。因此$\hat{\theta}$为

$$\hat{\theta} = X_{(n)} - 0.5 + \lambda\left(X_{(1)} - X_{(n)} + 1\right), \lambda \in [0, 1].$$

下面考察小学时用比例关系式计算池塘中鱼的总数的例子。

例6.7 为了解某池塘中鱼的总数，从池塘中随机捕捞800条鱼，做好标记后把它们放回池塘。过段时间再从池塘中随机捕捞2000条鱼，发现其中有100条鱼有记号。求池塘中鱼数的矩估计和极大似然估计。

解：假设池塘中有N条鱼，其中M条做好记号，随机捕捞n条，发现X条有记号。X服从超几何分布

$$P(X = k) = \frac{\binom{M}{k}\binom{N-M}{n-k}}{\binom{N}{n}}.$$

(1)由于$EX = n\frac{M}{N}$得$N = \frac{nM}{EX}$. 因此N的矩估计为

$$\hat{N} = \frac{nM}{k} = \frac{2000 \times 800}{100} = 16000(\text{条}).$$

(2)记$L(N)=P(X=k)$. 有

$$\begin{aligned}\frac{L(N)}{L(N-1)} &= \frac{\binom{M}{k}\binom{N-M}{n-k}}{\binom{N}{n}} \times \frac{\binom{N-1}{n}}{\binom{M}{k}\binom{N-M-1}{n-k}} \\ &= \frac{(N-M)(N-n)}{N(N-M-n+k)} \\ &= \frac{N^2-(n+M)N+nM}{N^2-(n+M)N+Nk}.\end{aligned}$$

当$nM > Nk$时，$L(N) > L(N-1)$, $nM < Nk$时，$L(N) < L(N-1)$. 所以，$L(N)$ 在$N=\frac{Mn}{k}$附近达到最大。极大似然估计为

$$\frac{nM}{k}=\frac{2000\times 800}{100}=16000(\text{条}).$$

方法三：Bayes估计

矩估计和极大似然估计都是基于当前观测数据来构造的。如果事先知道参数θ的一些信息，直观上用到这些信息将会提高估计的精度。比如，要估计一工厂生产的某种产品的不合格品率，两家质检单位分别对该产品进行抽检，假设他们抽到的产品没有相同的。如果只用一家单位的数据对该厂生产的产品的质量进行评估，显然会损失一部分信息。一个有效的办法就是把两家单位的数据合并起来。由于某种原因，两家单位只能互相提供估计结果。那么，对一家单位而言，另一家单位提供的估计结果就可作为事先已知的有关不合格品率的信息。统计上常用θ的某种概率分布来表示这些已知的信息，称这个概率分布为θ的先验概率分布，简称先验分布。称先验概率分布对应的密度函数为先验密度函数。令$h(\theta)$为θ的先验密度函数(对离散分布，$h(\theta)$是其概率函数)。一个自然的问题是：如何利用$h(\theta)$和当前的观测数据来估计θ?

令总体的密度函数为$f(x,\theta)$, $\theta\in\Theta$. 记X_1, X_2, $\cdots$, X_n $iid\sim f(x,\theta)$, 那么，$(X_1,X_2,\cdots,X_n)^\top$的联合密度函数为

$$(X_1,X_2,\cdots,X_n)^\top \sim f(x_1,\theta)f(x_2,\theta)\cdots f(x_n,\theta).$$

它可认为是在给定θ时，$(X_1,X_2,\cdots,X_n)^\top$的条件密度函数，即

$$(X_1,X_2,\cdots,X_n)^\top|\theta \sim f(x_1,\theta)f(x_2,\theta)\cdots f(x_n,\theta).$$

进而，$(X_1,X_2,\cdots,X_n,\theta)^\top$的联合密度函数为

$$u(x_1,x_2,\cdots,x_n,\theta)=f(x_1,\theta)f(x_2,\theta)\cdots f(x_n,\theta)h(\theta).$$

$(X_1,X_2,\cdots,X_n)^\top$的边缘密度函数为

$$m(x_1,x_2,\cdots,x_n)=\int_\Theta f(x_1,\theta)f(x_2,\theta)\cdots f(x_n,\theta)h(\theta)d\theta.$$

因此，在给定$X_1, X_2, \cdots, X_n$的条件下，θ的条件密度函数为

$$\begin{aligned} h(\theta|X_1, X_2, \cdots, X_n) &= \frac{u(x_1, x_2, \cdots, x_n, \theta)}{m(X_1, X_2, \cdots, X_n)} \\ &= \frac{u(x_1, x_2, \cdots, x_n, \theta)}{\int_\Theta u(x_1, x_2, \cdots, x_n, \theta)d\theta} \\ &= \frac{f(X_1, \theta)f(X_2, \theta)\cdots f(X_n, \theta)h(\theta)}{\int_\Theta f(X_1, \theta)f(X_2, \theta)\cdots f(X_n, \theta)h(\theta)d\theta}. \end{aligned}$$

$h(\theta)$表示在没有获得观测数据时，人们事先对θ的认识。条件密度函数$h(\theta|X_1, X_2, \cdots, X_n)$表示在获得观测数据$X_1, X_2, \cdots, X_n$ 后，人们对θ的进一步的认识。它综合了θ的先验信息和观测数据，称它为θ的后验密度函数。后验密度函数简称后验密度，对应的概率分布称为θ的后验概率分布，简称后验分布。有了θ的后验分布后，常用后验分布的均值$\tilde{\theta}$作为θ的估计，称之为Bayes估计。对$g(\theta)$的Bayes估计，可用$g(\tilde{\theta})$来估计。

例6.8 令$X_1, X_2, \cdots, X_n \, iid \sim N(\mu, \sigma^2)$, μ的先验分布为$N(\xi, v^2)$. 求μ的Bayes估计。

解：由题意知

$$h(\mu) = \frac{1}{\sqrt{2\pi}v}\exp\left(-\frac{1}{2v^2}(\mu - \xi)^2\right).$$

μ的后验密度函数为

$$h(\mu|X_1, X_2, \cdots, X_n) = \frac{f(X_1, X_2, \cdots, X_n|\mu)h(\mu)}{\int_{-\infty}^{\infty} f(X_1, X_2, \cdots, X_n|\mu)h(\mu)d\mu}.$$

上式的分母与μ无关，分子$f(X_1, X_2, \cdots, X_n|\mu)h(\mu)$与$\mu$有关，它等于

$$f(X_1, X_2, \cdots, X_n|\mu)h(\mu) = \left(\frac{1}{\sqrt{2\pi}\sigma}\right)^n \frac{1}{\sqrt{2\pi}v}\exp\left\{-\frac{1}{2\sigma^2}\sum_{i=1}^n (X_i - \mu)^2 - \frac{(\mu - \xi)^2}{2v^2}\right\}.$$

且

$$\begin{aligned} \frac{1}{\sigma^2}\sum_{i=1}^n (X_i - \mu)^2 + \frac{(\mu - \xi)^2}{v^2} &= \left(\frac{n}{\sigma^2} + \frac{1}{v^2}\right)\mu^2 - 2\left(\frac{n\bar{X}}{\sigma^2} + \frac{\xi}{v^2}\right)\mu + \frac{1}{\sigma^2}\sum_{i=1}^n X_i^2 + \frac{\xi^2}{v^2} \\ &= A\left[\mu - \frac{1}{A}\left(\frac{n\bar{X}}{\sigma^2} + \frac{\xi}{v^2}\right)\right]^2 + C, \end{aligned}$$

其中$A = \dfrac{\sigma^2 + nv^2}{\sigma^2 v^2}$, C与μ无关。故

$$h(\mu|X_1, X_2, \cdots, X_n) = D \times \exp\left\{-\frac{A}{2}\left[\mu - \frac{1}{A}\left(\frac{n\bar{X}}{\sigma^2} + \frac{\xi}{v^2}\right)\right]^2\right\},$$

其中D与μ无关。由于$h(\mu|X_1, X_2, \cdots, X_n)$是一个关于$\mu$的密度函数，可知，它是$N(\tilde{\mu}, \tilde{\sigma}^2)$的密度函数，其中

$$\begin{aligned} \tilde{\mu} &= \frac{nv^2}{\sigma^2 + nv^2}\bar{X} + \frac{\sigma^2}{\sigma^2 + nv^2}\xi, \\ \tilde{\sigma}^2 &= \frac{\sigma^2 v^2}{\sigma^2 + nv^2}. \end{aligned}$$

所以，μ的Bayes估计为

$$\tilde{\mu} = \frac{nv^2}{\sigma^2 + nv^2}\bar{X} + \frac{\sigma^2}{\sigma^2 + nv^2}\xi.$$

可见n越大，$\bar{X}$的权重越大。如果v^2越小，ξ的权重越大。

例6.9 令$X \sim B(n,p)$. 设p的先验分布为$Beta(\xi,\eta), \xi > 0, \eta > 0$. 求$p$的后验分布。

解：由题意知

$$h(p) = \frac{\Gamma(\xi+\eta)}{\Gamma(\xi)\Gamma(\eta)} p^{\xi-1}(1-p)^{\eta-1}.$$

给定p, X的条件密度函数为

$$X|p \sim f(x,p) = \binom{n}{x} p^x (1-p)^{n-x}, x = 0, 1, \cdots, n.$$

$(X,p)^\top$的联合密度函数为

$$u(x,p) = f(x,p)h(p) = \binom{n}{x} \frac{\Gamma(\xi+\eta)}{\Gamma(\xi)\Gamma(\eta)} p^{x+\xi-1}(1-p)^{n-x+\eta-1}.$$

X的边缘密度函数为

$$\begin{aligned}
m(x) &= \int_0^1 u(x,p)dp \\
&= \binom{n}{x} \frac{\Gamma(\xi+\eta)}{\Gamma(\xi)\Gamma(\eta)} \int_0^1 p^{x+\xi-1}(1-p)^{n-x+\eta-1}dp \\
&= \binom{n}{x} \frac{\Gamma(\xi+\eta)}{\Gamma(\xi)\Gamma(\eta)} \frac{\Gamma(x+\xi)\Gamma(n-x+\eta)}{\Gamma(n+\xi+\eta)} \int_0^1 \frac{\Gamma(n+\xi+\eta)}{\Gamma(x+\xi)\Gamma(n-x+\eta)} p^{x+\xi-1}(1-p)^{n-x+\eta-1}dp \\
&= \binom{n}{x} \frac{\Gamma(\xi+\eta)}{\Gamma(\xi)\Gamma(\eta)} \frac{\Gamma(x+\xi)\Gamma(n-x+\eta)}{\Gamma(n+\xi+\eta)}.
\end{aligned}$$

因此，p的后验密度函数为

$$\begin{aligned}
h(p|X) &= \frac{u(X,p)}{m(X)} \\
&= \frac{\Gamma(n+\xi+\eta)}{\Gamma(X+\xi)\Gamma(n-X+\eta)} p^{X+\xi-1}(1-p)^{n-X+\eta-1} \\
&= \frac{\Gamma\big((X+\xi)+(n-X+\eta)\big)}{\Gamma(X+\xi)\Gamma(n-X+\eta)} p^{X+\xi-1}(1-p)^{n-X+\eta-1}.
\end{aligned}$$

它是$Beta(X+\xi, n-X+\eta)$的密度函数。

从上面的两个例子可以看出，未知参数的先验分布和后验分布同属于同一个分布族，只是参数不一样。这样设定具有很好的直观解释。我们称这类分布族为共轭先验分布族，下面给出其具体定义。

共轭先验分布族： 令总体的密度函数为$f(x,\theta)$, θ是未知参数。记θ的先验密度函数是$h(\theta)$, $X_1, X_2, \cdots, X_n$ $iid \sim f(x,\theta)$. 那么θ 的后验分布$h(\theta|X_1, X_2, \cdots, X_n)$与$h(\theta)$ 属于同一个分布族，该分布族称为θ的共轭先验分布族。

除了上面正态分布的均值和二项分布外，下面给出其它几个分布的共轭先验分布族：

(1)Poisson分布的参数λ的共轭先验分布是Gamma分布。
(2)正态分布的方差(均值已知)的共轭先验分布是逆Gamma分布。
(3)负二项分布分布的未知参数p的共轭先验分布族是Beta分布。

下面我们将考虑基于多个观测样本对同一个未知参数的估计问题。如果有两个总体的样本，且待估参数有共同的，我们需要把两组样本合到一起对相同的参数进行估计，以提高估计的准确性。下面以极大似然估计为例来说明。

例6.10 令$X_1, X_2, \cdots, X_n \ iid \sim N(\mu, \sigma^2)$, $Y_1, Y_2, \cdots, Y_m \ iid \sim N(k\mu, m\sigma^2)$, $k \neq 0, m > 0$且已知，两组样本相互独立。求μ, σ^2的极大似然估计。

解：$(X_1, X_2, \cdots, X_n, Y_1, Y_2, \cdots, Y_m)^\top$的联合密度函数为

$$\prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\Big\{ -\frac{(x_i-\mu)^2}{2\sigma^2} \Big\} \prod_{j=1}^{m} \frac{1}{\sqrt{2\pi m\sigma^2}} \exp\Big\{ -\frac{(y_j-k\mu)^2}{2m\sigma^2} \Big\}.$$

似然函数为

$$\begin{aligned} L(\mu, \sigma^2) &= \prod_{i=1}^{n} \tfrac{1}{\sqrt{2\pi\sigma^2}} \exp\Big\{ -\tfrac{(X_i-\mu)^2}{2\sigma^2} \Big\} \prod_{j=1}^{m} \tfrac{1}{\sqrt{2\pi m\sigma^2}} \exp\Big\{ -\tfrac{(Y_j-k\mu)^2}{2m\sigma^2} \Big\} \\ &= \tfrac{1}{(2\pi\sigma^2)^{n/2}} \tfrac{1}{(2\pi m\sigma^2)^{m/2}} \prod_{i=1}^{n} \exp\Big\{ -\tfrac{(X_i-\mu)^2}{2\sigma^2} \Big\} \prod_{j=1}^{m} \exp\Big\{ -\tfrac{(Y_j-k\mu)^2}{2m\sigma^2} \Big\}. \end{aligned}$$

对数似然函数为

$$l(\mu, \sigma^2) = -\frac{n}{2}\ln(2\pi) - \frac{n}{2}\ln\sigma^2 - \frac{m}{2}\ln(2\pi m) - \frac{m}{2}\ln\sigma^2 - \sum_{i=1}^{n} \frac{(X_i-\mu)^2}{2\sigma^2} - \sum_{j=1}^{m} \frac{(Y_j-k\mu)^2}{2m\sigma^2}.$$

似然方程为

$$\begin{cases} \dfrac{\partial l(\mu, \sigma^2)}{\partial \mu} = \dfrac{1}{\sigma^2} \displaystyle\sum_{i=1}^{n} (X_i - \mu) + \frac{k}{m\sigma^2} \sum_{j=1}^{m} (Y_j - k\mu) = 0, \\ \dfrac{\partial l(\mu, \sigma^2)}{\partial \sigma^2} = -\dfrac{n}{2\sigma^2} - \dfrac{m}{2\sigma^2} + \dfrac{1}{2\sigma^4} \displaystyle\sum_{i=1}^{n} (X_i - \mu)^2 + \frac{1}{2m\sigma^4} \sum_{j=1}^{m} (Y_j - k\mu)^2 = 0. \end{cases}$$

求解得到

$$\begin{cases} \hat{\mu} &= \dfrac{1}{m(n+k^2)} \big[m \displaystyle\sum_{i=1}^{n} X_i + k \sum_{j=1}^{m} Y_j \big], \\ \hat{\sigma}^2 &= \dfrac{1}{(n+m)m} \big[m \displaystyle\sum_{i=1}^{n} (X_i - \hat{\mu})^2 + \sum_{j=1}^{m} (Y_j - k\hat{\mu})^2 \big]. \end{cases}$$

可以验证$\big(\hat{\mu}, \hat{\sigma}^2\big)$是$l(\mu, \sigma^2)$的极大值点，因此$\mu, \sigma^2$ 的极大似然估计分别是$\hat{\mu}, \hat{\sigma}^2$.

作为本节的最后，我们将简单介绍一下点估计的有效性准则，具体内容将在下面两节具体介绍。针对未知的待估参数，我们可以构造多个估计量，不同的估计量得到待估参数的估计值一般是不同的。比如，考察一总体X的均值μ的估计。记

$$X_1, X_2, \cdots, X_n \ iid \sim X.$$

我们可以用样本均值$\bar{X}$来估计μ也可以用样本中位数$Q_{\frac{1}{2}}$来估计μ. 一个自然的问题是：到底选哪个估计量呢？因此，我们需要给出统计量优良性的评价标准，在此标准下，选取最优的估计量。常用的评价准则有：无偏性、有效性、相合性和渐近正态性。前两个准则在6.2节介绍，后两个准则在6.3节介绍。

6.2 无偏性和有效性

无偏性和有效性是点估计量两个重要的评价准则，这两个准则也是数据分析中经常要考虑的。我们首先介绍无偏性。

无偏性

令总体的密度函数为$f(x,\theta)$, $\theta \in \Theta$, 待估参数为$g(\theta)$. 记X_1, X_2, $\cdots$, X_n $iid \sim f(x,\theta)$, $\hat{g}(X_1, X_2, \cdots, X_n)$是$g(\theta)$的一个点估计。若

$$E\hat{g}(X_1, X_2, \cdots, X_n) = g(\theta).$$

称$\hat{g}(X_1, X_2, \cdots, X_n)$为$g(\theta)$的无偏估计。

由于样本的随机性，相比于代待估参数$g(\theta)$的真值，估计量的值$\hat{g}$会时而偏大，时而偏小。无偏性是要求估计量不能有系统性偏差。无偏性是对一个估计量的基本要求。因此，如果有多个估计量可供选择时，我们一般优先选择具有无偏性的估计量。

考察某分布的方差σ^2的估计。针对样本方差，有

$$\begin{aligned}
E\Big[\frac{1}{n-1}\sum_{i=1}^{n}(X_i-\bar{X})^2\Big] &= \frac{1}{n-1}E\left[\sum_{i=1}^{n}(X_i-\mu+\mu-\bar{X})^2\right] \\
&= \frac{1}{n-1}E\left[\sum_{i=1}^{n}\Big((X_i-\mu)^2-2(X_i-\mu)(\bar{X}-\mu)+(\bar{X}-\mu)^2\Big)\right] \\
&= \frac{1}{n-1}E\left[\sum_{i=1}^{n}(X_i-\mu)^2-2\sum_{i=1}^{n}(X_i-\mu)(\bar{X}-\mu)+n(\bar{X}-\mu)^2\right] \\
&= \frac{1}{n-1}E\left[\sum_{i=1}^{n}(X_i-\mu)^2-n(\bar{X}-\mu)^2\right] \\
&= \frac{1}{n-1}[n\sigma^2-\sigma^2] \\
&= \sigma^2.
\end{aligned}$$

无偏估计的求法：先求出待估参数的极大似然估计或矩估计，计算其期望，根据求得的期望值进行系数修正。需要说明的是：不是所有的待估参数都存在无偏估计，如果找不到待估参数的无偏估计，一般找它的渐近无偏估计$\hat{g}$, 即$\hat{g}$依概率收到到$g(\theta)$. 极大似然估计不一定都是无偏估计。在一些条件下，极大似然估计是渐近无偏估计。

例6.11 令总体$X \sim Mul\big(n, (1-p)^2, 2p(1-p), p^2\big)$, $0 < p < 1$. 记(n_1, n_2, n_3)是观测样本，$T = a_1n_1 + a_2n_2 + a_3n_3$. 求$a_1, a_2, a_3$使得$ET = p^2$, 进而给出$\mathrm{var}(T)$.

解： 由题意，$(n_1, n_2, n_3)^\top \sim Mul\big(n, (1-p)^2, 2p(1-p), p^2\big)$. 根据第三章例3.3, n_1, n_2, n_3的边缘分布分别为

$$n_1 \sim B\big(n, (1-p)^2\big), n_2 \sim B\big(n, 2p(1-p)\big), n_3 \sim B(n, p^2).$$

由第四章第4.1节数学期望的性质1知

$$\begin{aligned} ET &= E(a_1n_1 + a_2n_2 + a_3n_3) \\ &= a_1n(1-p)^2 + 2a_2np(1-p) + a_3np^2 \\ &= a_1n - (2a_1n - 2a_2n)p + (a_1n - 2a_2n + a_3n)p^2 \end{aligned}$$

根据$ET = p^2$，我们可以得到

$$\begin{cases} a_1n = 0, \\ 2a_1n - 2a_2n = 0, \\ a_1n - 2a_2n + a_3n = 1. \end{cases}$$

解得$a_1 = a_2 = 0, a_3 = 1/n$,$T = n_3/n$. 进而有

$$\mathrm{var}(T) = \frac{p^2(1-p^2)}{n}.$$

例6.12 令$X_1, X_2, \cdots, X_n$ iid $\sim U(0,\theta)$. 求θ的无偏估计。

解： 易知, θ的极大似然估计是$X_{(n)}$. $X_{(n)}$的分布函数是

$$P(X_{(n)} \le y) = \prod_{i=1}^{n} P(X_i \le y) = \left(\frac{y}{\theta}\right)^n,\ 0 \le y \le \theta.$$

$X_{(n)}$的密度函数为

$$f(y,\theta) = \begin{cases} \dfrac{ny^{n-1}}{\theta^n} & 0 \le y \le \theta, \\ 0 & \text{其它。} \end{cases}$$

$X_{(n)}$的数学期望为

$$EX_{(n)} = \int_0^\theta yf(y,\theta)dx = \frac{n}{\theta^n}\int_0^\theta y^n dx = \frac{n}{n+1}\theta.$$

因此，θ的无偏估计为$\hat{\theta}_1 = \dfrac{n+1}{n}X_{(n)}$.

另外从矩估计的角度，可知$E(\bar{X}) = \theta/2$, 则$\hat{\theta}_2 = 2\bar{X}$也是$\theta$的一个无偏估计。可见，一个参数的无偏估计不一定是惟一的。

有效性

常用均方误差来度量一个估计量的有效性。

均方误差： 令$X_1, X_2, \cdots, X_n$ $iid \sim f(x,\theta)$, $\theta \in \Theta$, $g(\theta)$是待估参数。记$\hat{g} = \hat{g}(X_1, X_2, \cdots, X_n)$是$g(\theta)$的一个点估计。称

$$M\big(\hat{g}, g(\theta)\big) = E\big(\hat{g} - g(\theta)\big)^2$$

为$\hat{g}$的均方误差。

从均方误差的定义可知：

$$\begin{aligned} M\big(\hat{g}, g(\theta)\big) &= E\big(\hat{g} - E\hat{g} + E\hat{g} - g(\theta)\big)^2 \\ &= E\big(\hat{g} - E\hat{g}\big)^2 + 2E(\hat{g} - E\hat{g})(E\hat{g} - g(\theta)) + \big(E\hat{g} - g(\theta)\big)^2 \\ &= \mathrm{var}(\hat{g}) + \big(E\hat{g} - g(\theta)\big)^2. \end{aligned}$$

即均方误差等于方差加上偏差的平方。

均方误差从整体上衡量一个估计量的优劣。均方误差越小越好。下面基于均方误差给出有效性的定义。

有效性：令$\hat{g}_1$和$\hat{g}_2$为待估参数$g(\theta)$的估计，若对$\forall\theta \in \Theta$, 有

$$\mathrm{var}(\hat{g}_1) \le \mathrm{var}(\hat{g}_2),$$

且至少存在一个$\theta \in \Theta$使得上式不等号严格成立，称$\hat{g}_1$比$\hat{g}_2$有效。

一致最小均方误差估计：令$\hat{g}$为待估参数$g(\theta)$的一个估计量。如果对$g(\theta)$的任意其它的估计量$\tilde{g}$, 都有$M(\hat{g}, g(\theta)) \le M(\tilde{g}, g(\theta))$ 对$\forall\theta \in \Theta$都成立。称$\hat{g}$是$g(\theta)$的一致最小均方误差估计。

例6.13 令$X_1, X_2, \cdots, X_n$ iid $\sim U(0,\theta)$, $n \ge 2$. 试比较$\hat{\theta}_1 = \dfrac{n+1}{n}X_{(n)}$和$\hat{\theta}_2 = 2\bar{X}$的均方误差。

解：由例6.12知$X_{(n)}$的密度函数为

$$f(y,\theta) = \begin{cases} \dfrac{nx^{n-1}}{\theta^n} & 0 \le x \le \theta, \\ 0 & \text{其它。} \end{cases}$$

因此，

$$EX_{(n)} = \frac{n}{n+1}\theta,\ EX_{(n)}^2 = \frac{n}{\theta^n}\int_0^\theta x^{n+1}dx = \frac{n}{n+2}\theta^2,$$

$$\mathrm{var}(X_{(n)}) = EX_{(n)}^2 - \big(EX_{(n)}\big)^2 = \frac{n}{(n+1)^2(n+2)}\theta^2,$$

$$\mathrm{var}(\hat{\theta}_1) = \Big(\frac{n+1}{n}\Big)^2\mathrm{var}(X_{(n)}) = \frac{1}{n(n+2)}\theta^2.$$

另一方面，

$$\mathrm{var}(\hat{\theta}_2) = 4\mathrm{var}(\bar{X}) = \frac{4}{n}\mathrm{var}(X_1) = \frac{4}{n}\frac{1}{12}\theta^2 = \frac{\theta^2}{3n}.$$

由于$\hat{\theta}_1$和$\hat{\theta}_2$都是无偏的，我们只需要比较其方差即可。当$n \ge 2$时，有$n(n+2) > 3n$, 则$\hat{\theta}_1$的均方误差小于$\hat{\theta}_2$.

更一般地，考察θ的估计量$\hat{\theta}_a = aX_{(n)}$, a为常数，对应的均方误差为

$$\begin{aligned} M\big(\hat{\theta}_a, \theta\big) &= \mathrm{var}(\hat{\theta}_a) + \big(E\hat{\theta}_a - \theta\big)^2 \\ &= a^2\mathrm{var}(X_{(n)}) + \big(aEX_{(n)} - \theta\big)^2 \\ &= a^2\tfrac{n}{(n+1)^2(n+2)}\theta^2 + \big(a\tfrac{n}{n+1} - 1\big)^2\theta^2 \\ &= \Big[\tfrac{n}{n+2}a^2 - 2\tfrac{n}{n+1}a + 1\Big]\theta^2 \\ &= \Big[\tfrac{n}{n+2}\big(a - \tfrac{n+2}{n+1}\big)^2 + \tfrac{1}{(n+1)^2}\Big]\theta^2 \end{aligned}$$

当$a=\frac{n+2}{n+1}$时，均方误差达到最小，此时$M\left(\frac{n+2}{n+1}X_{(n)},\theta\right)=\frac{1}{(n+1)^2}\theta^2$. 由于$(n+1)^2>n(n+2)$, 知$\frac{n+2}{n+1}X_{(n)}$ 的均方误差小于$\hat{\theta}_1=\frac{n+1}{n}X_{(n)}$. 因此，在均方误差最小的准则下，有偏估计$\frac{n+2}{n+1}X_{(n)}$优于无偏估计$\hat{\theta}_1$.

针对无偏估计，均方误差为$M\big(\hat{g},g(\theta)\big)=\mathrm{var}(\hat{g})$, 无偏估计量的方差越小，该估计量越好。一个好的估计量要兼顾无偏性和有效性，这就是下面要讲的一致最小方差无偏估计。

一致最小方差无偏估计： 令$X_1,X_2,\cdots,X_n\ iid\sim f(x,\theta),\ \theta\in\Theta$, $g(\theta)$是待估参数。记$\hat{g}=\hat{g}(X_1,X_2,\cdots,X_n)$为$g(\theta)$的无偏估计。若对$g(\theta)$的任意一个无偏估计$\tilde{g}=\tilde{g}(X_1,X_2,\cdots,X_n)$及任意$\theta\in\Theta$,

$$\mathrm{var}\big(\hat{g}\big)\le\mathrm{var}\big(\tilde{g}\big).$$

称$\hat{g}$是$g(\theta)$的一致最小方差无偏估计(Uniformly Minimum Variance Unbiased Estimate, 简记为UMVUE).

在无偏估计类中，从均方误差最小的角度来说，UMVUE是最好的。那么一个自然的问题是怎样才能找到待估参数$g(\theta)$的UMVUE呢？下面给出找UMVUE的两种方法(除了这两种方法，还有一种方法，见本章习题32)。

方法一：Cramer-Rao(简称C-R)不等式下界准则

为了理解方便，我们只考虑单参数的情情形。首先给出Fisher信息量的定义。

Fisher信息量： 令总体X的密度函数为$f(x,\theta),\ \theta\in\Theta$, 代估参数为$g(\theta)$. 记$X_1$,$X_2,\cdots,X_n\ \ iid\sim f(x,\theta)$. 称

$$I(\theta)=E\left(\frac{\partial\ln f(X,\theta)}{\partial\theta}\right)^2$$

为Fisher信息量，它是Fisher在20世纪20年代提出的。

为方便起见，假设关于$f(x,\theta)$的积分和求偏导可以交换次序(常见的概率密度函都满足该性质，后面用到都假设它满足，不在赘述该性质)，即

$$\frac{\partial}{\partial\theta}\int_{-\infty}^{\infty}f(x,\theta)dx=\int_{-\infty}^{\infty}\frac{\partial f(x,\theta)}{\partial\theta}dx.$$

$$\frac{\partial}{\partial\theta}\int_{-\infty}^{\infty}\frac{\partial f(x,\theta)}{\partial\theta}dx=\int_{-\infty}^{\infty}\frac{\partial^2 f(x,\theta)}{\partial\theta^2}dx.$$

则

$$\begin{aligned}E\Big(\frac{\partial\ln f(X,\theta)}{\partial\theta}\Big)&=0,\\ \mathrm{var}\Big(\frac{\partial\ln f(X,\theta)}{\partial\theta}\Big)&=I(\theta),\\ E\left(\frac{\partial^2\ln f(X,\theta)}{\partial\theta^2}\right)&=-I(\theta).\end{aligned}$$

上面第一个等式的证明：

$$\begin{aligned} E\Big(\tfrac{\partial \ln f(X,\theta)}{\partial\theta}\Big) &= \int_{-\infty}^{\infty} \tfrac{\partial f(x,\theta)/\partial\theta}{f(x,\theta)} f(x,\theta)dx \\ &= \int_{-\infty}^{\infty} \tfrac{\partial f(x,\theta)}{\partial\theta} dx \\ &= \tfrac{\partial}{\partial\theta}\int_{-\infty}^{\infty} f(x,\theta)dx \\ &= \tfrac{\partial 1}{\partial\theta} = 0. \end{aligned}$$

第二个等式的证明：

$$\mathrm{var}\Big(\frac{\partial \ln f(X,\theta)}{\partial\theta}\Big) = E\left(\frac{\partial \ln f(X,\theta)}{\partial\theta}\right)^2 - 0^2 = I(\theta).$$

针对第三个等式，

$$\begin{aligned} E\left(\tfrac{\partial^2 \ln f(X,\theta)}{\partial\theta^2}\right) &= E\left(\tfrac{f''(X,\theta)f(X,\theta)}{f^2(X,\theta)} - \left(\tfrac{f'(X,\theta)}{f(X,\theta)}\right)^2\right) \\ &= E\left(\tfrac{f''(X,\theta)f(X,\theta)}{f^2(X,\theta)}\right) - E\left(\tfrac{f'(X,\theta)}{f(X,\theta)}\right)^2 \\ &= -E\left(\tfrac{f'(X,\theta)}{f(X,\theta)}\right)^2 \\ &= -I(\theta), \end{aligned}$$

其中

$$f'(X,\theta) = \frac{\partial f(x,\theta)}{\partial\theta},\ \ f''(X,\theta) = \frac{\partial^2 f(x,\theta)}{\partial\theta^2}.$$

为了记号方便，以下内容，$f'(X,\theta)$和$f''(X,\theta)$ 均表示类似的含义。

定理6.1 (C-R不等式) 令总体X的密度函数为$f(x,\theta)$, $\theta \in \Theta$, 待估参数为$g(\theta)$. 记$X_1, X_2, \cdots, X_n$ $iid \sim f(x,\theta)$, $\hat{g} = \hat{g}(X_1, X_2, \cdots, X_n)$是$g(\theta)$的一个无偏估计。则

$$\mathrm{var}(\hat{g}) \geq \frac{g'(\theta)^2}{nI(\theta)}.$$

特别地，当$g(\theta) = \theta$时，对θ的任意一个无偏估计$\hat{\theta}$, 有

$$\mathrm{var}(\hat{\theta}) \geq \frac{1}{nI(\theta)}.$$

证明：记

$$\xi = \xi(X_1, X_2, \cdots, X_n, \theta) = \frac{1}{n}\sum_{i=1}^{n} \frac{\partial \ln f(X_i,\theta)}{\partial\theta}.$$

称ξ为样本得分函数(Score function)，对应的$\partial \ln f(X,\theta)/\partial\theta$ 为总体得分函数。有

$$\begin{aligned} E\xi &= 0, \\ \mathrm{var}(\xi) &= \frac{1}{n^2}\sum_{i=1}^{n} \mathrm{var}\left(\frac{\partial \ln f(X_i,\theta)}{\partial\theta}\right) = \frac{1}{n} I(\theta), \\ \mathrm{cov}(\hat{g},\xi) &= E(\hat{g}\xi) \\ &= \int\cdots\int \hat{g} \times \frac{1}{n}\sum_{i=1}^{n}\left[\frac{f'(x_i,\theta)}{f(x_i,\theta)}\right] \times \prod_{i=1}^{n} f(x_i,\theta)dx_1\cdots dx_n. \end{aligned}$$

由偏导数公式可知

$$\sum_{i=1}^{n}\left[\frac{f'(x_i,\theta)}{f(x_i,\theta)}\right]\times\prod_{i=1}^{n}f(x_i,\theta)=\frac{\partial f(x_1,\theta)f(x_2,\theta)\cdots f(x_n,\theta)}{\partial\theta}.$$

带入上式，得

$$\begin{aligned}\mathrm{cov}(\hat{g},\xi) &= \frac{1}{n}\int\cdots\int\hat{g}\frac{\partial f(x_1,\theta)f(x_2,\theta)\cdots f(x_n,\theta)}{\partial\theta}dx_1\cdots dx_n\\ &= \frac{1}{n}\frac{\partial}{\partial\theta}\int\cdots\int\hat{g}f(x_1,\theta)f(x_2,\theta)\cdots f(x_n,\theta)dx_1\cdots dx_n\\ &= \frac{1}{n}\frac{\partial E\hat{g}}{\partial\theta}\\ &= \frac{1}{n}g'(\theta).\end{aligned}$$

由Cauchy-Schwarz不等式，有

$$[\mathrm{cov}(\hat{g},\xi)]^2\le\mathrm{var}(\hat{g})\mathrm{var}(\xi)=\frac{1}{n}I(\theta)\mathrm{var}(\hat{g}).$$

因此，

$$\mathrm{var}(\hat{g})\ge\frac{[\mathrm{cov}(\hat{g},\xi)]^2}{\frac{1}{n}I(\theta)}=\frac{g'(\theta)^2}{nI(\theta)}.$$

由C-R不等式可知：若$g(\theta)$的某个无偏估计的方差等于不等式的下界，那么该无偏估计就是$g(\theta)$的UMVUE. 这个不等式是Cramér(1893-1985)和Rao(1920-)分别于1945和1946年各自独立给出的。显然，$I(\theta)$越大，下界越小，表明可能存在$g(\theta)$的无偏估计有更小的方差，即找到的无偏估计会更有效。

用C-R不等式找UMVUE的方法：先找待估参数$g(\theta)$的一个无偏估计，一般是极大似然估计；然后计算其方差，看它是否等于C-R不等式的下界，如果相等，那么该无偏估计就是UMVUE.

例6.14 令$X_1,X_2,\cdots,X_n\ iid\sim B(1,p)$. 求证：$\bar{X}$是$p$的UMVUE.

证明： 记$X\sim B(1,p)$, 其概率函数为$f(x,p)=p^x(1-p)^{1-x},x=0,1$. 易知Fisher信息量为

$$\begin{aligned}I(p) &= E\left(\frac{\partial\ln(p^X(1-p)^{1-X})}{\partial p}\right)^2\\ &= E\left(\frac{\partial\Big(X\ln p+(1-X)\ln(1-p)\Big)}{\partial p}\right)^2\\ &= E\left(\frac{(X-p)^2}{p^2(1-p)^2}\right)\\ &= \frac{\mathrm{var}(X)}{p^2(1-p)^2}\\ &= \frac{1}{p(1-p)}.\end{aligned}$$

C-R不等式的下界是

$$\frac{p(1-p)}{n}.$$

而$\text{var}(\bar{X}) = \frac{p(1-p)}{n}$. 因此，$\bar{X}$ 是p的UMVUE.

方法二：充分完备性准则

先给出充分统计量和完备统计量的定义，再给出基于充分完备统计量构造UMVUE 的方法。

充分统计量： 令总体的密度函数为$f(x,\theta), \theta \in \Theta$ 是未知参数。记$X_1, X_2, \cdots, X_n \, iid \sim f(x,\theta)$, 统计量$T = T(X_1, X_2, \cdots, X_n)$. 如果在给定$T$的取值后，$(X_1, X_2, \cdots, X_n)^\top$的条件分布与$\theta$无关，称$T$为充分统计量。

由定义可知充分统计量提供样本的所有有用的信息。然而，从定义出发去验证一个统计量是否是充分统计量有时非常困难，下面的因子分解定理提供了一个简单判断充分统计量的途径。

定理6.2 (因子分解定理) 令总体的密度函数为$f(x,\theta)$. 记$X_1, X_2, \cdots, X_n$ $iid \sim f(x,\theta)$, 统计量$T = T(X_1, X_2, \cdots, X_n)$. T为充分统计量的充分必要条件是

$$\prod_{i=1}^{n} f(X_i, \theta) = A(T, \theta) \times B(X_1, X_2, \cdots, X_n),$$

其中函数A依赖于T和θ, B不依赖于θ.

定理6.2中的A是T和θ的函数，T是一个整体。如果统计量T是充分统计量，$R = R(X_1, X_2, \cdots, X_n)$与$T$一一对应，则$R$也是充分统计量。可见，充分统计量不唯一。

完备统计量： 令总体的密度函数为$f(x,\theta)$, $\theta \in \Theta$ 是未知参数。记$X_1, X_2, \cdots, X_n$ $iid \sim f(x,\theta)$, $T = T(X_1, X_2, \cdots, X_n)$为统计量。若对任何函数$\psi(\cdot)$和$\theta \in \Theta$, 如果$E_\theta \psi(T) = 0$ 时，则$\psi(T) = 0$, 称T为完备统计量。

若T既是充分统计量，又是完备统计量，称T为**充分完备统计量**。统计量的充分性保证了T包含样本参数的所有信息，而完备性保证了T不包含与参数无关的多余信息，即已经将多余的信息全部压缩完了。

下面我们给出一类特殊的分布族，称为**指数分布族**，基于此分布族的密度函数或者概率函数，比较容易验证一个统计量是否是充分完备统计量。

指数分布族： 令随机变量X的密度函数为

$$f(x,\theta) = \psi(\theta) h(x) \exp\left\{ \sum_{j=1}^{m} g_j(\theta) T_j(x) \right\},$$

其中$\theta \in \Theta, \Theta$是开区间，$\psi(\theta)$和$g_j(\theta)$是$\theta$ 一一对应的连续函数，$h(x)$和$T_j(x)$是与参数θ无关的函数，$j = 1, 2, \cdots, m$. 称该分布族为指数分布族。

常见的分布如二项分布、Poisson分布、正态分布、指数分布、Gamma分布都属于指数族。但是均匀分布不属于指数族。

定理6.3 (指数族与充分完备统计量) 令随机变量X的分布属于**指数分布族**，即其密度函数有如下形式

$$f(x,\theta)=\psi(\theta)h(x)\exp\left\{\sum_{j=1}^{m}g_j(\theta)T_j(x)\right\},$$

其中$\theta\in\Theta,\Theta$是开区间，$\psi(\theta)$和$g_j(\theta)$是θ 一一对应的连续函数，$h(x)$和$T_j(x)$是与参数θ无关的函数，$j=1,2,\cdots,m$. 记$X_1,X_2,\cdots,X_n\ iid\sim X$. 则

$$\left(\sum_{i=1}^{n}T_1(X_i),\sum_{i=1}^{n}T_2(X_i),\cdots,\sum_{i=1}^{n}T_m(X_i)\right),$$

为充分完备统计量。

下面给出与充分统计量和充分完备统计量有关的一个重要结果。

定理6.4 令总体的密度函数为$f(x,\theta),\ \theta\in\Theta$, 待估参数为$g(\theta)$. 记$X_1,\ X_2,\ \cdots,\ X_n\ iid\sim f(x,\theta),\ T=T(X_1,X_2,\cdots,X_n)$是统计量。那么有

(1)如果T是**充分统计量**，$\tilde{g}=\tilde{g}(X_1,X_2,\cdots,X_n)$ 是$g(\theta)$的一个无偏估计。则

$$E\big(E(\tilde{g}|T)\big)=g(\theta),\mathrm{var}\big(E(\tilde{g}|T)\big)\le\mathrm{var}(\tilde{g}).$$

(2)如果T是**充分完备统计量**，则$g(\theta)$有有且仅有一个依赖于T 的无偏估计。

(3)如果T是**充分完备统计量**，$\tilde{g}=\tilde{g}(X_1,X_2,\cdots,X_n)$是$g(\theta)$的一个无偏估计。则$g(\theta)$的UMVUE 为

$$\eta(T)=E(\tilde{g}|T),$$

且$\eta(T)$是唯一的。

证明：(1)记$\hat{g}=E(\tilde{g}|T)$. 由充分统计量的定义知$\hat{g}=E(\tilde{g}|T)$与θ无关，且

$$E\hat{g}=E[E(\tilde{g}|T)]=E\tilde{g}=g(\theta).$$

另一方面，

$$\begin{aligned}
\mathrm{var}(\tilde{g}) &= E[\tilde{g}-g(\theta)]^2\\
&= E[(\tilde{g}-\hat{g})+(\hat{g}-g(\theta))]^2\\
&= E(\tilde{g}-\hat{g})^2+2E[(\tilde{g}-\hat{g})(\hat{g}-g(\theta))]+E(\hat{g}-g(\theta))^2\\
&= E(\tilde{g}-\hat{g})^2+2E\left\{E[(\tilde{g}-\hat{g})(\hat{g}-g(\theta))|T]\right\}+\mathrm{var}(\hat{g})\\
&= E(\tilde{g}-\hat{g})^2+2E\left\{(\hat{g}-g(\theta))E[(\tilde{g}-\hat{g})|T]\right\}+\mathrm{var}(\hat{g})\\
&= E(\tilde{g}-\hat{g})^2+\mathrm{var}(\hat{g})\\
&\ge \mathrm{var}(\hat{g}).
\end{aligned}$$

(2)记$g^*=g^*(X_1,X_2,\cdots,X_n)$是$g(\theta)$的一个无偏估计，

$$\eta(T)=E\left(g^*|T\right).$$

显然$\eta(T)$是依赖于T的，且$E\eta(T)=g(\theta)$. 设$\tilde{\eta}(T)$是另一个依赖于T的$g(\theta)$的一个无偏估计。有

$$E\big(\eta(T)-\tilde{\eta}(T)\big)=0.$$

由于T是完备统计量，有

$$\eta(T)-\tilde{\eta}(T)=0.$$

(3)记$\eta(T)=E(\tilde{g}|T)$. 由于T是充分完备统计量，结合结论(1)和(2)，对$g(\theta)$的任意一个无偏估计的$\tilde{g}_1$, 有

$$\mathrm{var}(\tilde{g}_1)\geq \mathrm{var}\big(E(\tilde{g}_1|T)\big)=\mathrm{var}\big(E(\tilde{g}|T)\big)=\mathrm{var}(\eta(T)),$$

从而$\eta(T)$是$g(\theta)$的UMVUE.

下面用反证法证明唯一性。设$\eta^*=\eta^*(X_1,X_2,\cdots,X_n)$是$g(\theta)$的另一个UMVUE，由结论(2)，依赖于$T$ 的无偏估计唯一，则η^*不是T的函数。再由结论(1),

$$\mathrm{var}\Big(E\big(\eta^*|T\big)\Big)\leq \mathrm{var}\big(\eta^*\big),$$

由于η^*不是T的函数，上式等号严格成立。因此

$$\mathrm{var}\Big(E\big(\eta^*|T\big)\Big)< \mathrm{var}(\eta^*),$$

与η^*是$g(\theta)$的UMVUE矛盾。

文献中称结论(1)为Rao-Blackwell定理，称结论(2)为Lehmann-Scheffe定理。基于定理6.4, 下面给出求待估参数$g(\theta)$的UMVUE的两种方法：
(1)找$g(\theta)$的一个无偏估计$\tilde{g}$, 求$\eta(T)=E(\tilde{g}|T)$即可。
(2)令$E(\eta(T))=g(\theta)$, 比较系数，解出$\eta(T)$.
当无偏估计不好找时，可用第二种方法。

例6.15 令$X_1,X_2,\cdots,X_n$ $iid\sim N(\mu,\sigma^2)$. 求充分完备统计量，并基于它们给出μ,σ^2的UMVUE。

解： $(X_1,X_2,\cdots,X_n)^\top$的联合密度函数为

$$\begin{aligned}
f(x_1,x_2,\cdots,x_n,\mu,\sigma^2) &= (2\pi\sigma^2)^{-\frac{n}{2}}\exp\left\{-\frac{1}{2\sigma^2}\sum_{i=1}^n(x_i-\mu)^2\right\}\\
&= (2\pi\sigma^2)^{-\frac{n}{2}}\exp\left\{-\frac{1}{2\sigma^2}\left[\sum_{i=1}^n x_i^2-2\mu\sum_{i=1}^n x_i+n\mu^2\right]\right\}\\
&= (2\pi\sigma^2)^{-\frac{n}{2}}\exp\left\{-\frac{n\mu^2}{2\sigma^2}\right\}\exp\left\{-\frac{1}{2\sigma^2}\sum_{i=1}^n x_i^2-\frac{\mu}{\sigma^2}\sum_{i=1}^n x_i\right\}.
\end{aligned}$$

可见$\Big(\sum\limits_{i=1}^n X_i,\sum\limits_{i=1}^n X_i^2\Big)$ 是充分完备统计量。由于样本方差

$$S^2=\frac{1}{n-1}\sum_{i=1}^n X_i^2-\frac{n}{n-1}\bar{X}^2,$$

因此$(\bar{X}, S^2)$也是充分完备统计量。由于$E\bar{X} = \mu, ES^2 = \sigma^2$, 所以$\bar{X}, S^2$分别是$\mu, \sigma^2$ 的UMVUE.

例6.16 令总体$X \sim B(1,p)$, $0 < p < 1$. 记$X_1, X_2, \cdots, X_n$ $iid \sim X$, $n \geq 2$. 求p^2的UMVUE.

解：$(X_1, X_2, \cdots, X_n)^\top$的联合概率函数为

$$\begin{aligned} P(X_1 = x_1, X_2 = x_2, \cdots, X_n = x_n) &= \sum_{i=1}^{n} p^{x_i}(1-p)^{1-x_i} \\ &= (1-p)^n \left(\tfrac{p}{1-p}\right)^{\sum_{i=1}^{n} X_i} \\ &= (1-p)^n \exp\left(\ln \tfrac{p}{1-p} \sum_{i=1}^{n} X_i\right). \end{aligned}$$

由定理6.3知，$T = \sum_{i=1}^{n} X_i$是充分完备统计量。记

$$\hat{g} = \hat{g}(X_1, X_2, \cdots, X_n) = I_{\{X_1 + X_2 = 2\}}.$$

有

$$E\hat{g} = P(X_1 + X_2 = 2) = p^2.$$

可见$\hat{g}$是p^2的一个无偏估计。p^2的UMVUE是

$$\begin{aligned} E(\hat{g}|T=t) &= P\left(X_1 + X_2 = 2 \Big| \sum_{i=1}^{n} X_i = t\right) \\ &= \frac{P\left(X_1 + X_2 = 2, \sum_{i=1}^{n} X_i = t\right)}{P\left(\sum_{i=1}^{n} X_i = t\right)} \\ &= \frac{P\left(X_1 + X_2 = 2, \sum_{i=3}^{n} X_i = t-2\right)}{P\left(\sum_{i=1}^{n} X_i = t\right)} \\ &= \frac{p^2 \binom{n-2}{t-2} p^{t-2}(1-p)^{n-t}}{\binom{n}{t} p^t (1-p)^{n-t}} \\ &= \frac{t(t-1)}{n(n-1)}. \end{aligned}$$

所以，p^2的UMVUE是

$$\frac{1}{n(n-1)} \left(\sum_{i=1}^{n} X_i\right)\left(\sum_{i=1}^{n} X_i - 1\right).$$

例6.17 令$X_1, X_2, \cdots, X_n$ $iid \sim Poisson(\lambda), \lambda > 0$. 给定$k$, 求$\lambda^k$的UMVUE.

解：(**先找充分完备统计量**) 由于$(X_1, X_2, \cdots, X_n)^\top$的联合概率函数为

$$\prod_{i=1}^{n} \frac{\lambda^{x_i}}{x_i!} e^{-\lambda} = e^{-n\lambda} \prod_{i=1}^{n} \frac{1}{x_i!} \exp\left\{\sum_{i=1}^{n} x_i \ln \lambda\right\},$$

可见$T=\sum_{i=1}^{n}X_i$是充分完备统计量。也可以从定义出发验证，下面给出具体的验证过程。

记统计量$\psi(T)$满足$E\big(\psi(T)\big)=0$. 由Poisson分布的可加性，$T\sim Poisson(n\lambda)$, 其概率函数为

$$P(T=t)=\frac{(n\lambda)^t}{t!}e^{-n\lambda},\ \ t=0,1,\cdots.$$

有

$$0=E(\psi(T))=\sum_{t=0}^{\infty}\psi(t)\frac{(n\lambda)^t}{t!}e^{-n\lambda}=\sum_{t=0}^{\infty}\psi(t)\frac{n^t}{t!}e^{-n\lambda}\lambda^t,$$

是关于λ的多项式，从而$\psi(t)=0,\ t=0,1,\cdots$. 因此，T是充分完备统计量。

设$\eta(T)$是$h(\lambda)=\lambda^k$的UMVUE. 由无偏性知

$$\lambda^k=E(\eta(T))=\sum_{t=0}^{\infty}\eta(t)\frac{(n\lambda)^t}{t!}e^{-n\lambda},$$

把$e^{n\lambda}=\sum_{j=0}^{\infty}\frac{(n\lambda)^j}{j!}$ 代入上式有

$$\sum_{t=0}^{\infty}\eta(t)\frac{n^t}{t!}\lambda^t=\lambda^k e^{n\lambda}=\sum_{j=0}^{\infty}\frac{n^j}{j!}\lambda^{k+j},$$

对比两边关于λ的多项式系数，有

$$\eta(t)=\begin{cases}0, & t=0,1,\cdots,k-1,\\ \dfrac{1}{n^k}\dfrac{t!}{(t-k)!}, & t=k,\cdots.\end{cases}$$

即

$$\eta(T)=\begin{cases}0, & T<k,\\ \dfrac{1}{n^k}\dfrac{T!}{(T-k)!}, & T\geq k.\end{cases}$$

需要指出的是：除了均方误差，还有其它准则，比如**平均绝对偏差**：

$$E|\hat{g}-g(\theta)|.$$

6.3 相合性和渐近正态性

上节将介绍估计量的两个性质：无偏性和有效性；本节将介绍估计量的两外两个性质：相合性和渐近正态性。

相合性

无偏性和有效性都是针对有限的样本量而言的，称这种性质为估计量的“小样本性质”。下面要讲的相合性和渐近正态性都是针对样本量趋于无穷时估计量的性质，称这种性质为估计量的“大样本性质”。极大似然估计是一种常用的估计量，然而在许多种情况下，它没有显示表达式，很难验证它是否具有无偏性，在一定的条件下，极大似然估计具有相合性和渐近正态性。

相合估计：令某总体的密度函数为$f(x,\theta),\ \theta\in\Theta$, 待估参数为$g(\theta)$. 记$X_1,\ X_2,\ \cdots,\ X_n\ iid\sim f(x,\theta),\ \hat{g}=\hat{g}(X_1,X_2,\cdots,X_n)$为$g(\theta)$的一个估计量。如果对$\forall\varepsilon>0,\theta\in\Theta$, 有

$$\lim_{n\to\infty}P\left(|\hat{g}-g(\theta)|\geq\varepsilon\right)=0,$$

称$\hat{g}$为$g(\theta)$的一个相合估计。

从相合性的定义可知，如果样本量无限增加时，估计量依概率收敛于待估参数的真值。相合性是对一个估计量的最基本的要求。如果一个估计量没有相合性，那么无论样本量有多大，很难得到待估参数的有效估计。需要说明的是，这里的相合估计是针对依概率收敛而言，一般称之为弱相合估计(类似弱大数定律)，简记为相合估计；如果$\hat{g}$几乎处处收敛到$g(\theta)$, 称$\hat{g}$是$g(\theta)$的强相合估计。

考察样本方差是否收敛到总体方差，

$$\begin{aligned}\frac{1}{n-1}\sum_{i=1}^{n}(X_i-\bar{X})^2 &= \frac{1}{n-1}\sum_{i=1}^{n}(X_i-\mu+\mu-\bar{X})^2\\ &= \frac{1}{n-1}\sum_{i=1}^{n}\left[(X_i-\mu)^2+2(X_i-\mu)(\mu-\bar{X})+(\mu-\bar{X})^2\right]\\ &= \frac{1}{n-1}\left[\sum_{i=1}^{n}(X_i-\mu)^2+2n(\bar{X}-\mu)(\mu-\bar{X})+n(\mu-\bar{X})^2\right]\\ &= \frac{1}{n-1}\sum_{i=1}^{n}(X_i-\mu)^2-\frac{n}{n-1}(\bar{X}-\mu)^2.\end{aligned}$$

由Khinchin大数定律，$\frac{1}{n}\sum_{i=1}^{n}(X_i-\mu)^2\xrightarrow{p}E(X_1-\mu)^2=\sigma^2,\ \mu-\bar{X}\xrightarrow{p}0.$ 可见样本方差收敛到总体方差。需要指出的是：一般说的收敛一般是指依概率收敛，称之为弱收敛。除了若收敛，还有强收敛，它是指几乎处处收敛。

在一定的条件下，矩估计总是相合的，其原因在于矩估计函数的连续性和大数定律。极大似然估计不一定是相合的，但是，极大似然估计在一些条件下是相合的。在给出定理和证明前，先引入一个不等式。

定理6.5 (Jensen不等式) 令X是一随机变量，$\psi(\cdot)$是一个连续、有界、二阶可导函数。

(1)如果$\psi''(x) \geq 0$, 则$\psi(EX) \leq E\big(\psi(X)\big)$;
(2)如果$\psi''(x) \leq 0$, 则$\psi(EX) \geq E\big(\psi(X)\big)$.

证明： (1) 对$\psi(x)$在EX处Taylor展开，

$$\psi(x) = \psi(EX) + \psi'(EX)(x - EX) + \psi''(\tilde{x})(x - EX)^2/2,$$

其中$\tilde{x}$介于x与EX之间。由$\psi''(x) \geq 0$ 可知

$$\psi(X) \geq \psi(EX) + \psi'(EX)(X - EX).$$

两边求期望得

$$E\psi(X) \geq E\psi(EX).$$

同理可证：如果$\psi''(x) \leq 0$, $\psi(EX) \geq E\big(\psi(X)\big)$.

下面给出当$n \to \infty$, 似然方程以概率1有解且极大似然估计是相合的结果。

定理6.6 令总体$X \sim f(x,\theta)$, $\theta \in \Theta$, Θ是开区间, θ的真值是θ_0. 记$X_1, X_2, \cdots, X_n \, iid \sim f(x,\theta)$, 对数似然函数为$l(\theta) = \sum_{i=1}^{n} \ln f(X_i,\theta)$. 设$\ln f(x,\theta)$在$\Theta$上可微，$E\big(\ln f(X,\theta)\big)$存在，且$f(x,\theta)$ 是可识别的，即

$$P\big(\{x | f(x,\theta_1) \neq f(x,\theta_2)\}\big) \neq 0, \ \forall \theta_1 \neq \theta_2.$$

那么，当$n \to \infty$, 似然方程$\partial l(\theta)/\partial\theta = 0$ 以概率1有解，记为$\hat{\theta}$且$\hat{\theta} \xrightarrow{p} \theta_0$.

证明: 由于$f(x,\theta)$是可识别的，所以对任意$\theta_1 \neq \theta_2$, $\ln \frac{f(X,\theta_1)}{f(X,\theta_2)}$存在且不恒等于0。由于$E\big(\ln f(X,\theta)\big)$存在，则

$$E\Big|\ln\frac{f(X,\theta_1)}{f(X,\theta_2)}\Big| = E\big|\ln f(X,\theta_1) - E\ln f(X,\theta_1)\big| \leq E|\ln f(X,\theta_1)| + E|\ln f(X,\theta_2)| < \infty,$$

从而$\ln \frac{f(X,\theta_1)}{f(X,\theta_2)}$的期望存在。由Jensen不等式及$d^2(\ln x)/dx^2 = -1/x^2 < 0$ 知，对充分小的$\varepsilon > 0$, 有$(\theta_0 - \varepsilon, \theta_0 + \varepsilon) \subset \Theta$, 且

$$E\ln\frac{f(X,\theta_0-\varepsilon)}{f(X,\theta_0)} < \ln E\Big(\frac{f(X,\theta_0-\varepsilon)}{f(X,\theta_0)}\Big) = \ln 1 = 0,$$

$$E\ln\frac{f(X,\theta_0+\varepsilon)}{f(X,\theta_0)} < \ln E\Big(\frac{f(X,\theta_0+\varepsilon)}{f(X,\theta_0)}\Big) = \ln 1 = 0,$$

其中求期望是在$\theta = \theta_0$处。由Khinchin大数定律，当$n \to \infty$,

$$\frac{1}{n}\big[l(\theta_0-\varepsilon) - l(\theta_0)\big] \xrightarrow{p} E_{\theta_0}\ln\frac{f(X,\theta_0-\epsilon)}{f(X,\theta_0)} < 0,$$

$$\frac{1}{n}\big[l(\theta_0+\varepsilon) - l(\theta_0)\big] \xrightarrow{p} E_{\theta_0}\ln\frac{f(X,\theta_0+\epsilon)}{f(X,\theta_0)} < 0.$$

又由于$l(\theta)$在$(\theta_0 - \varepsilon, \theta_0 + \epsilon)$上连续，因而$l(\theta)$必有一局部极大值点。从而，似然方程

$$\frac{\partial l(\theta)}{\partial\theta} = 0$$

以概率1有解，记之为$\hat{\theta}$, 且$|\hat{\theta}-\theta_0|<\varepsilon$. 因此$\hat{\theta}$ 是θ_0的相合估计。

定理6.7 令$X_1,X_2,\cdots,X_n\, iid\sim f(x,\theta)$, 待估参数为$g(\theta)$. $\hat{g}=\hat{g}(X_1,X_2,\cdots,X_n)$是$g(\theta)$ 的一个点估计，若

$$\lim_{n\to\infty}E\hat{g}=g(\theta),\ \lim_{n\to\infty}\mathrm{var}(\hat{g})=0.$$

则$\hat{g}$是$g(\theta)$的相合估计。

证明：由题意知，对任意$\varepsilon>0$, 存在充分大的N, 当$n>N$时，

$$|E\hat{g}-g(\theta)|<\varepsilon/2.$$

由于$|\hat{g}-g(\theta)|\le|\hat{g}-E\hat{g}|+|E\hat{g}-g(\theta)|$, 知当$n>N$时，

$$\{|\hat{g}-E\hat{g}|<\varepsilon/2\}\subset\{|\hat{g}-g(\theta)|<\varepsilon\},$$

于是

$$\{|\hat{g}-E\hat{g}|\ge\varepsilon/2\}\supset\{|\hat{g}-g(\theta)|\ge\varepsilon\}.$$

最后由Chebyshev不等式，

$$P(|\hat{g}-g(\theta)|\ge\varepsilon)\le P(|\hat{g}-E\hat{g}|\ge\varepsilon/2)\le 4\mathrm{var}(\hat{g})/\varepsilon^2.$$

及$\lim\limits_{n\to\infty}\mathrm{var}(\hat{g})=0$得证。

令$\hat{g}$是$g(\theta)$的相合估计，$\zeta=h\big(g(\theta)\big)$是$g(\theta)$的连续有界函数。则$\hat{\zeta}=h\big(g(\hat{\theta})\big)$是$\zeta$的相合估计。

例6.18 令$X_1,X_2,\cdots,X_n\ iid\sim X$, 且$EX=\mu,\mathrm{var}(X)=\sigma^2<\infty$. 求证：$\hat{\mu}=\frac{2}{n(n+1)}\sum\limits_{i=1}^{n}iX_i$是$\mu$的相合估计。

证明：由题意得

$$E\hat{\mu}=E\Big(\frac{2}{n(n+1)}\sum_{i=1}^{n}iX_i\Big)=\frac{2}{n(n+1)}\sum_{i=1}^{n}iE(X_i)=EX=\mu,$$

$$\mathrm{var}(\hat{\mu})=\mathrm{var}\Big(\frac{2}{n(n+1)}\sum_{i=1}^{n}iX_i\Big)=\frac{4\sigma^2}{n^2(n+1)^2}\sum_{i=1}^{n}i^2=\frac{2\sigma^2(2n+1)}{3n(n+1)}\overset{n\to\infty}{\longrightarrow}0.$$

由定理6.7知，$\hat{\mu}$是μ的相合估计。

渐近正态性

先介绍一下渐近分布。渐近分布就是一个统计量在当样本量n趋于无穷时，它的极限分布。在许多情况下，统计量的精确分布很难的得到，然而当样本量趋于无穷时，它的极限分布有显式表达式，比如标准正态分布等。极大似然估计是样本$X_1,X_2,\cdots,X_n$的函数，它一般没有显式表达式，它的精确分布很难得到。在一些条件下，当n很大时，极大似然估计的分布会渐近于正态分布，这个性质称为极大似然估计的“渐近正态性”。

定理6.8 极大似然估计的渐近正态性。令$X_1, X_2, \cdots, X_n \; iid \sim f(x,\theta)$, $\theta \in \Theta$是未知参数, Θ为开区间，θ_0是θ的真值。记$\hat{\theta}$是θ的极大似然估计。如果对充分小的$\varepsilon > 0$,

(1)当$\theta \in (\theta_0 - \varepsilon, \theta_0 + \varepsilon)$, $\dfrac{\partial \ln f(x,\theta)}{\partial \theta}$, $\dfrac{\partial^2 \ln f(x,\theta)}{\partial \theta^2}$, $\dfrac{\partial^3 \ln f(x,\theta)}{\partial \theta^3}$存在;

(2)当$\theta \in (\theta_0 - \varepsilon, \theta_0 + \varepsilon)$，$\dfrac{\partial^3 \ln f(x,\theta)}{\partial \theta^3} \le H(x)$, 其中$H(x)$是可积函数且期望存在，即$E\big(H(X)\big) < \infty$;

(3)关于θ求偏导与积分可以交换顺序。则

$$\sqrt{n}\big(\hat{\theta} - \theta_0\big) \xrightarrow{d} N\left(0, \frac{1}{I(\theta_0)}\right)$$

证明：对数似然函数为

$$l(\theta) = \sum_{i=1}^{n} \ln f(X_i, \theta).$$

对$\partial l(\theta)/\partial\theta$在$\theta_0$处进行Taylor展开，有

$$\frac{\partial l(\theta)}{\partial \theta} = \frac{\partial l(\theta)}{\partial \theta}\Big|_{\theta_0} + (\theta - \theta_0)\frac{\partial^2 l(\theta)}{\partial \theta^2}\Big|_{\theta_0} + \frac{(\theta - \theta_0)^2}{2}\frac{\partial^3 l(\theta)}{\partial \theta^3}\Big|_{\theta_1},$$

其中θ_1介于θ与θ_0之间。取$\theta = \hat{\theta}$, 得到

$$0 = \frac{\partial l(\theta)}{\partial \theta}\Big|_{\hat{\theta}} = \frac{\partial l(\theta)}{\partial \theta}\Big|_{\theta_0} + (\hat{\theta} - \theta_0)\frac{\partial^2 l(\theta)}{\partial \theta^2}\Big|_{\theta_0} + \frac{(\hat{\theta} - \theta_0)^2}{2}\frac{\partial^3 l(\theta)}{\partial \theta^3}\Big|_{\theta_1},$$

其中θ_1介于θ_0和$\hat{\theta}$之间。故$\theta_1 \xrightarrow{p} \theta_0$. 由上式得

$$\sqrt{n}(\hat{\theta} - \theta_0) = \frac{-\sqrt{n}\frac{1}{n}\frac{\partial l(\theta)}{\partial \theta}\Big|_{\theta_0}}{\frac{1}{n}\left\{\frac{\partial^2 l(\theta)}{\partial \theta^2}\Big|_{\theta_0} + \frac{(\hat{\theta}_n - \theta_0)}{2}\frac{\partial^3 l(\theta)}{\partial \theta^3}\Big|_{\theta_1}\right\}}.$$

$\frac{\partial l(\theta)}{\partial \theta}\big|_{\theta_0}$为独立同分布的随机变量和，及

$$E\left[\frac{\partial \ln f(X_1,\theta)}{\partial \theta}\Big|_{\theta_0}\right] = 0, \;\; \mathrm{var}\left[\frac{\partial \ln f(X_1,\theta)}{\partial \theta}\Big|_{\theta_0}\right] = I(\theta_0).$$

利用中心极限定理得

$$\sqrt{n}\frac{1}{n}\frac{\partial l(\theta)}{\partial \theta}\Big|_{\theta_0} \xrightarrow{d} N\big(0, I(\theta_0)\big).$$

又$\frac{\partial^2 l(\theta)}{\partial \theta^2}\big|_{\theta_0}$为独立同分布的随机变量和，利用积分和求导可交换次序及$\ln f(X_1,\theta)$的三阶偏导可积，可以知道$\ln f(X_1,\theta)$二阶偏导期望存在，且

$$E\left[\frac{\partial^2 \ln f(X_1,\theta)}{\partial \theta^2}\Big|_{\theta_0}\right] = -I(\theta_0),$$

由Khinchin大数定律, 得

$$\frac{1}{n}\frac{\partial^2 l(\theta)}{\partial\theta^2}\Big|_{\theta_0} \xrightarrow{p} -I(\theta_0).$$

最后由于

$$\frac{1}{n}\frac{(\hat{\theta}-\theta_0)}{2}\frac{\partial^3 l(\theta)}{\partial\theta^3} \xrightarrow{p} 0.$$

和Slustky定理得证。

常称$1/I(\theta_0)$为$\sqrt{n}\hat{\theta}$的渐近方差。下面介绍Delta方法，它主要用来求一个具有渐近正态性的估计量的函数的渐近分布。

定理6.9 (Delta方法) 令随机变量序列$X_1, X_2, \cdots$ 满足

$$\sqrt{n}(X_n-\mu) \xrightarrow{d} N\left(0,\sigma^2\right),$$

其中μ和σ^2是常数，那么对任意函数$g(\cdot)$满足$g'(\mu)$存在、连续且$g'(\mu)\neq 0$，有

$$\sqrt{n}\big(g(X_n)-g(\mu)\big) \xrightarrow{d} N\left(0,\sigma^2[g'(\mu)^2]\right).$$

证明： 由Taylor展开得

$$g(X_n) = g(\mu) + g'(\tilde{\mu})(X_n-\mu),$$

其中$\tilde{\mu}$位于X_n和μ之间。由题意，有$\sqrt{n}(X_n-\mu)/\sigma \xrightarrow{d} N(0,1)$, 那么对任意$\varepsilon>0$,有

$$P(|X_n-\mu|\geq\varepsilon) = 1-P\Big(-\sqrt{n}\varepsilon/\sigma < \sqrt{n}(X_n-\mu)\sigma < \sqrt{n}\varepsilon/\sigma\Big) \xrightarrow{n\to\infty} 0,$$

即$X_n \xrightarrow{p} \mu$. 另一方面，$|\tilde{\mu}-\mu|<|X_n-\mu|$和$g'(\mu)$连续，可得

$$\tilde{\mu} \xrightarrow{p} \mu,\ \ g'(\tilde{\mu}) \xrightarrow{p} g'(\mu).$$

由Slustky定理得

$$\sqrt{n}\big(g(X_n)-g(\mu)\big) = g'(\tilde{\mu})\sqrt{n}(X_n-\mu) \xrightarrow{d} N\left(0,\sigma^2[g'(\mu)^2]\right).$$

例6.19 令$X_1, X_2, \cdots, X_n \sim Poisson(\lambda)$. 求$e^{-\lambda}$的一个估计量且其具有渐近正态性。

解： 似然函数为

$$L(\lambda) = \prod_{k=1}^{n}\frac{\lambda^{X_k}e^{-\lambda}}{X_k!} = \frac{\lambda^{\sum\limits_{k=1}^{n}X_k}e^{-n\lambda}}{\prod\limits_{k=1}^{n}X_k!}.$$

对数似然函数为

$$l(\lambda)=\sum_{k=1}^{n}X_k\ln\lambda-n\lambda-\sum_{k=1}^{n}\ln(X_k!).$$

似然方程为

$$\frac{\partial l(\lambda)}{\partial\lambda}=\frac{1}{\lambda}\sum_{k=1}^{n}X_k-n=0,$$

其解为

$$\hat{\lambda}=\frac{1}{n}\sum_{k=1}^{n}X_k=\bar{X}.$$

可知$\hat{\lambda}=\bar{X}$是λ的极大似然估计。记$X\sim Poisson(\lambda)$. 下面求Fisher 信息量，

$$I(\lambda)=E\Big(\frac{\partial\ln(\lambda^X e^{-\lambda}/X!)}{\partial\lambda}\Big)^2=E(X/\lambda-1)^2=\frac{1}{\lambda}.$$

根据定理6.8, 得

$$\sqrt{n}(\bar{X}-\lambda)\xrightarrow{d}N(0,\lambda).$$

记$g(\lambda)=e^{-\lambda}$, 则$g'(\lambda)=-e^{-\lambda}$. 由Delta 方法得

$$\sqrt{n}\big(g(\bar{X})-g(\lambda)\big)\xrightarrow{d}N\left(0,\lambda[g'(\lambda)^2]\right),$$

即

$$\sqrt{n}\big(e^{-\bar{X}}-e^{-\lambda}\big)\xrightarrow{d}N\left(0,\lambda e^{-2\lambda}\right).$$

因此，$e^{-\bar{X}}$是$e^{-\lambda}$的一个估计量且其具有渐近正态性。

常称一个具有渐近正态性的估计为渐近正态估计。

6.4 区间估计

前面介绍的点估计只能给出待估参数的一个具体的取值，如果能给出关于待估参数的取值范围, 并且知道这个范围包含待估参数$g(\theta)$的真值的概率，显然比只给出一个值能更多的了解待估参数的信息。比如，要估计一池塘里的鱼的总数，如果能有99%把握知道鱼的总数落在区间[10000,12000], 显然比只给11000条鱼提供的信息量多。这就是接下来要介绍的区间估计。

6.3.1. 置信区间

置信区间理论是Neyman于20世纪30年代建立起来的，它的基本思想是确定一个区间并给出该区间包含待估参数$g(\theta)$的置信度。令$X_1,\ X_2,\ \cdots,\ X_n$ $iid\sim f(x,\theta),\ \theta\in\Theta$是未知参数。寻找待估参数$g(\theta)$的区间估计，就是确定

$$\hat{g}_L=\hat{g}_L(X_1,X_2,\cdots,X_n)$$

和

$$\hat{g}_U=\hat{\theta}_U(X_1,X_2,\cdots,X_n),$$

使得$P\big(g(\theta)\in[\hat{g}_L,\hat{g}_U]\big)$ 尽可能大且$\big|\hat{g}_U-\hat{g}_L\big|$尽可能小。前者称为可靠性，后者称为精度。两者是相互矛盾的，所以区间估计的一个准则是：在保证可靠性的前提下尽可能地提高精度。

置信水平为$1-\alpha$的置信区间： 令$X_1,X_2,\cdots,X_n\ iid\sim f(x,\theta),\ \theta\in\Theta$，待估参数为$g(\theta),\ 0<\alpha<1.$ 记统计量$\hat{g}_L=\hat{g}_L(X_1,X_2,\cdots,X_n),\ \hat{g}_U=\hat{g}_U(X_1,X_2,\cdots,X_n),$ 满足

$$P(\hat{g}_L\le g(\theta)\le\hat{g}_U)=1-\alpha,\ \ \forall\theta\in\Theta.$$

称$[\hat{g}_L,\hat{g}_U]$为$g(\theta)$的置信水平为$1-\alpha$的置信区间。如果找不到$P(\hat{g}_L\le\theta\le\hat{g}_U)$恰好等于$1-\alpha$, 就找$\hat{g}_L,\hat{g}_U$, 使得

$$P(\hat{g}_L\le\theta\le\hat{g}_U)>1-\alpha,$$

且$P(\hat{g}_L\le\theta\le\hat{g}_U)$尽可能接近$1-\alpha.$

构造区间估计有三种方法：枢轴量法、大样本法和Bayes 法。

为了方便，约定下面符号：令$0<\alpha<1.$ 记标准正态分布的α分位数为u_α, 自由度为n的χ^2分布的α分位数为$\chi^2_n(\alpha)$, 自由度为n的t分布的α分位数为$t_{n-1}(\alpha)$, 自由度为n,m的F分布的α分位数为$F_{n,m}(\alpha).$

1. 枢轴量法

用枢轴量法构造待估参数的区间估计分为四个步骤。令$X_1,X_2,\cdots,X_n\ iid\sim f(x,\theta),\ \theta\in\Theta,$ 待估参数为$g(\theta).$

(1) 找$g(\theta)$的一个优良的估计$\hat{g}=\hat{g}(X_1,X_2,\cdots,X_n),$ 一般是极大似然估计；

(2) 构造一个关于$\hat{g}$与$g(\theta)$的函数$h\big(\hat{g}, g(\theta)\big)$, 使得$h\big(\hat{g}, g(\theta)\big)$的分布函数为$H(\cdot)$且$H(\cdot)$与$\theta$无关，称$h\big(\hat{g}, g(\theta)\big)$为枢轴量；

(3) 计算$H(\cdot)$的α_L分位数$H^{-1}(\alpha_L)$和$1-\alpha_U$ 分位数$H^{-1}(1-\alpha_U)$, 其中$\alpha_L+\alpha_U=\alpha$, 常取$\alpha_L=\alpha_U=\alpha/2$. 因此

$$P\Big(H^{-1}(\alpha_L) \le h\big(\hat{g}, g(\theta)\big) \le H^{-1}(1-\alpha_U)\Big) = 1-\alpha;$$

(4) 把不等式$H^{-1}(\alpha_L) \le h\big(\hat{g}, g(\theta)\big) \le H^{-1}(1-\alpha_U)$ 改写成$A \le g(\theta) \le B$, 其中A, B与θ无关。那么$[A, B]$就是我们所求的置信水平为$1-\alpha$的置信区间。

例6.20 令$X_1, X_2, \cdots, X_n \ iid \sim N(\mu, \sigma^2)$. 求参数$\mu, \sigma^2$的置信水平为$1-\alpha$的置信区间。

解： 下面按照上面介绍的四步构造μ, σ^2 的置信水平为$1-\alpha$的置信区间。

(1) μ, σ^2的优良估计分别为$\bar{X}, S^2$;

(2) 枢轴量为

$$T_1 = \frac{\sqrt{n}(\bar{X}-\mu)}{S},\ T_2 = \frac{(n-1)S^2}{\sigma^2},$$

且$T_1 \sim t_{n-1}, T_2 \sim \frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1}$. 两个分布均与$\mu, \sigma^2$无关；

(3)

$$P\Big(t_{n-1}(\alpha/2) \le \frac{\sqrt{n}(\bar{X}-\mu)}{S} \le t_{n-1}(1-\alpha/2)\Big) = 1-\alpha,$$
$$P\Big(\chi^2_{n-1}(\alpha/2) \le \frac{(n-1)S^2}{\sigma^2} \le \chi^2_{n-1}(1-\alpha/2)\Big) = 1-\alpha.$$

(4) μ, σ^2的$1-\alpha$置信区间分别为

$$\left[\bar{X} - \frac{1}{\sqrt{n}}St_{n-1}(1-\alpha/2),\ \bar{X} - \frac{1}{\sqrt{n}}St_{n-1}(\alpha/2)\right],$$
$$\left[\frac{(n-1)S^2}{\chi^2_{n-1}(1-\alpha/2)},\ \frac{(n-1)S^2}{\chi^2_{n-1}(\alpha/2)}\right].$$

由于t分布是对称分布，$t_{n-1}(\alpha/2) = -t_{n-1}(1-\alpha/2)$, 常把$\mu$的区间估计写为

$$\left[\bar{X} - \frac{1}{\sqrt{n}}St_{n-1}(1-\alpha/2),\ \bar{X} + \frac{1}{\sqrt{n}}St_{n-1}(1-\alpha/2)\right],$$

称上式μ的区间估计为单样本均值的t区间估计。

例6.21 令$X_1, X_2, \cdots, X_n \ iid \sim U(0, \theta)$. 试给出$\theta$的置信水平为$1-\alpha$ 的置信区间。

解： θ的极大似然估计为$\hat{\theta} = X_{(n)}$, $X_{(n)}/\theta$的密度函数为

$$f(y) = ny^{n-1}, 0 < y < 1.$$

它与θ无关，枢轴量为$X_{(n)}/\theta$, 且

$$P\left(b_1 \leq \frac{X_{(n)}}{\theta} \leq b_2\right) = 1-\alpha.$$

可得

$$b_2^n - b_1^n = 1-\alpha.$$

θ的置信水平为$1-\alpha$的置信区间可构造成

$$\left[\frac{X_{(n)}}{b_2}, \frac{X_{(n)}}{b_1}\right],$$

其中$0 \leq b_1 < b_2 \leq 1$满足$b_2^n - b_1^n = 1-\alpha$. 由于b_1, b_2未知，下面考察区间的长度。上述置信区间的长度为

$$(1/b_1 - 1/b_2)/X_{(n)}.$$

显然$b_2 = 1, b_1 = \alpha^{\frac{1}{n}}$时，区间长度最短。因此，$\theta$的置信水平为$1-\alpha$ 的置信区间为

$$\left[X_{(n)}, \frac{X_{(n)}}{\alpha^{1/n}}\right].$$

例6.22 令$X_1, X_2, \cdots, X_n$ $iid \sim N(\mu_1, \sigma^2)$, $Y_1, Y_2 \cdots, Y_m$ $iid \sim N(\mu_2, \sigma^2)$, 两组样本相互独立。求$\mu_1 - \mu_2$和$\sigma^2$的置信水平为$1-\alpha$的置信区间。

解: 记

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i,\ \bar{Y} = \frac{1}{m}\sum_{j=1}^{m} Y_j,$$

$$S_1^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2,\ S_2^2 = \frac{1}{m-1}\sum_{j=1}^{n}(Y_j - \bar{Y})^2,$$

$$S_0 = \sqrt{\frac{1}{n+m-2}\left[\sum_{i=1}^{n}(X_i - \bar{X})^2 + \sum_{j=1}^{m}(Y_j - \bar{Y})^2\right]}.$$

枢轴量及其分布为

$$\sqrt{\frac{nm}{n+m}}\left[(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)\right]/S_0 \sim t_{n+m-2},$$

$$\frac{(n-1)S_1^2}{\sigma^2} + \frac{(m-1)S_2^2}{\sigma^2} \sim \chi^2_{n+m-2}.$$

因此，$\mu_1 - \mu_2$的置信水平为$1-\alpha$的置信区间为

$$\left[(\bar{X} - \bar{Y}) - S_0 t_{n+m-2}(1-\alpha/2)\sqrt{\frac{n+m}{nm}}, (\bar{X} - \bar{Y}) + S_0 t_{n+m-2}(1-\alpha/2)\sqrt{\frac{n+m}{nm}}\right],$$

σ^2的$1-\alpha$的置信区间为

$$\left[\frac{(n-1)S_1^2 + (m-1)S_2^2}{\chi^2_{n+m-2}(1-\alpha/2)}, \frac{(n-1)S_1^2 + (m-1)S_2^2}{\chi^2_{n+m-2}(\alpha/2)}\right],$$

称上式$\mu_1-\mu_2$的区间估计为两样本均值的t区间估计。

2. 大样本法

用枢轴量构造的区间一般是精确置信区间，即区间包含真值的概率(称之为覆盖率)一般能够保证$1-\alpha$。然而有时候，尤其是数据的概率分布比较复杂且未知时，很难找到合适的枢轴量，这时候，若样本量n较大时，可利用中心极限定理来构造枢轴量，进而构造近似的置信区间。这里的“近似”是指利用了渐近正态分布。下面举例说明。

例6.23 令$X\sim B(n,p)$. 求p的置信水平为$1-\alpha$的置信区间。

解：由中心极限定理知$\frac{X-np}{\sqrt{np(1-p)}}\xrightarrow{d}N(0,1)$, 从而$\frac{X-np}{\sqrt{np(1-p)}}$是枢轴量。记$\hat{p}=X/n$. 由

$$P\left(-u_{1-\alpha/2}\le\frac{X-np}{\sqrt{np(1-p)}}\le u_{1-\alpha/2}\right)\approx 1-\alpha,$$

可知p的置信水平为$1-\alpha$的置信区间为$[\hat{p}_L,\hat{p}_U]$, 其中

$$\hat{p}_L=\frac{n}{n+u_{1-\alpha/2}^2}\left[\hat{p}+\frac{u_{1-\alpha/2}^2}{2n}-u_{1-\alpha/2}\sqrt{\frac{\hat{p}(1-\hat{p})}{n}+\frac{u_{1-\alpha/2}^2}{4n^2}}\right],$$

$$\hat{p}_U=\frac{n}{n+u_{1-\alpha/2}^2}\left[\hat{p}+\frac{u_{1-\alpha/2}^2}{2n}+u_{1-\alpha/2}\sqrt{\frac{\hat{p}(1-\hat{p})}{n}+\frac{u_{1-\alpha/2}^2}{4n^2}}\right],$$

例6.20 令$X_1,X_2,\cdots,X_n\ iid\sim N(\mu_1,\sigma_1^2)$, $Y_1,Y_2,\cdots,Y_m\ iid\sim N(\mu_2,\sigma_2^2)$, 两组样本相互独立，$\mu_1,\mu_2,\sigma_1^2,\sigma_2^2$都未知。求参数$\mu_1-\mu_2$和$\sigma_1^2/\sigma_2^2$ 的$1-\alpha$置信区间。

解：(1)关于$\mu_1-\mu_2$的区间估计是统计学上的一个著名的问题，即Benhrens-Fisher问题。Benhrens和Fisher分别在1929年和1930年研究过这个问题，后面许多研究者都给过一些解法，但是没有一个方法构造的区间长度是一致最短的。按照以前的记号，由中心极限定理及Slustky定理知

$$\frac{(\bar{X}-\bar{Y})-(\mu_1-\mu_2)}{\sqrt{S_1^2/n+S_2^2/m}}\xrightarrow{d}N(0,1).$$

上式左边即为枢轴量。因此，$\mu_1-\mu_2$的置信水平为$1-\alpha$的置信区间为

$$\left[\bar{X}-\bar{Y}-u_{1-\alpha/2}\sqrt{S_1^2/n+S_2^2/m},\ \bar{X}-\bar{Y}+u_{1-\alpha/2}\sqrt{S_1^2/n+S_2^2/m}\right].$$

(2) 由$\frac{S_2^2/\sigma_2^2}{S_1^2/\sigma_1^2}\sim F_{m-1,n-1}$,可得

$$\frac{\sigma_1^2}{\sigma_2^2}\frac{S_2^2}{S_1^2}\sim F_{m-1,n-1}.$$

由此可得$\frac{\sigma_1^2}{\sigma_2^2}$的置信水平为$1-\alpha$的区间估计为

$$\left[\frac{S_1^2}{S_2^2}F_{m-1,n-1}(\alpha/2),\ \frac{S_1^2}{S_2^2}F_{m-1,n-1}(1-\alpha/2)\right],$$

例6.24 令总体$X \sim Cauchy(\mu,1)$, 密度函数为

$$f(x,\theta)=\frac{1}{\pi[1+(x-\mu)^2]}, x\in\mathcal{R},$$

其中$\mu\in\mathcal{R}$是为未知参数。记$X_1,X_2,\cdots,X_n\ iid\sim X$. 求$\mu$的置信水平为$1-\alpha$的置信区间。

解： $Cauchy(\mu,1)$的密度函数关于μ是对称的，μ是X的中位数。由第五章定理5.2知样本中位数

$$m_{\frac{1}{2}} \xrightarrow{d} N\Big(\mu,\frac{\pi^2}{4n}\Big),$$

进而

$$P\left(-u_{1-\alpha/2}\le\frac{2\sqrt{n}(m_{\frac{1}{2}}-\mu)}{\pi}\le u_{1-\alpha/2}\right)=1-\alpha.$$

可得μ的置信水平为$1-\alpha$的置信区间为

$$\left[m_{\frac{1}{2}}-\frac{\pi}{2\sqrt{n}}u_{1-\alpha/2},\ m_{\frac{1}{2}}+\frac{\pi}{2\sqrt{n}}u_{1-\alpha/2}\right].$$

3. Bayes法

如果有未知参数θ的先验信息, 直观上用到这些知识可以提高区间估计的精度。令$X_1,\ X_2,\ \cdots,\ X_n\ iid\ \sim\ f(x,\theta)$. 假设$\theta$的先验密度为$h(\theta)$, 目的是求$\theta$的Bayes区间估计。我们首先计算$\theta$的后验密度$h(\theta|X_1,X_2,\cdots,X_n)$. 然后寻找两个与样本$X_1,\ X_2,\ \cdots,\ X_n$有关的统计量$\hat{\theta}_1,\hat{\theta}_2$, 使得

$$\int_{\hat{\theta}_1}^{\hat{\theta}_2}h(\theta|X_1,X_2,\cdots,X_n)d\theta=1-\alpha.$$

那么，$[\hat{\theta}_1,\hat{\theta}_2]$是$\theta$的置信水平为$1-\alpha$的Bayes区间。一般以$\hat{\theta}_2-\hat{\theta}_1$最小为原则寻找$\hat{\theta}_1$和$\hat{\theta}_2$. 基于Bayes法构造的置信区间被称为Bayes置信区间。

例6.25 令$X_1,X_2,\cdots,X_n\ iid\ \sim\ N(\mu,\sigma^2)$, μ的先验分布为$N(\xi,v^2)$. 求μ的Bayes区间估计。

解： 由例6.8知μ的后验分布是$N\left(\tilde{\mu},\tilde{\sigma}^2\right)$, 其中

$$\begin{aligned}\tilde{\mu} &= \frac{nv^2}{\sigma^2+nv^2}\bar{X}+\frac{\sigma^2}{\sigma^2+nv^2}\xi,\\ \tilde{\sigma}^2 &= \frac{\sigma^2v^2}{\sigma^2+nv^2}.\end{aligned}$$

因此

$$\frac{\mu-\tilde{\mu}}{\tilde{\sigma}}\sim N(0,1).$$

μ的置信水平为$1-\alpha$的Bayes置信区间为

$$\left[\tilde{\mu}-u_{1-\alpha/2}\tilde{\sigma},\tilde{\mu}+u_{1-\alpha/2}\tilde{\sigma}\right].$$

6.3.2 置信界

有时我们只对待估参数$g(\theta)$的一端感兴趣. 比如产品的保质期等。因此我们需要给出$g(\theta)$的置信上下界。

令总体X的密度函数为$f(x,\theta),\theta\in\Theta$, 待估参数为$g(\theta)$. 记$X_1,X_2,\cdots,X_n\ iid\sim f(x,\theta)$, 统计量$\hat{g}_L=\hat{g}_L(X_1,X_2,\cdots,X_n)$, $\hat{g}_U=\hat{g}_U(X_1,X_2,\cdots,X_n)$, $0<\alpha<1$. 如果

$$P\big(g(\theta)\le\hat{g}_U\big)=1-\alpha,\ \ \forall\theta\in\Theta,$$

$$P\big(g(\theta)\ge\hat{g}_L\big)=1-\alpha,\ \ \forall\theta\in\Theta.$$

称$\hat{g}_U$, $\hat{g}_L$分别为$g(\theta)$的一个置信系数为$1-\alpha$的置信上，下界。

一般是找$\hat{g}_U,\hat{g}_L$使得$P(g(\theta)\le\hat{g}_U)$, $P(g(\theta)\ge\hat{g}_L)$恰好等于$1-\alpha,\forall\theta\in\Theta$. 如果找不到这样的$\hat{g}_U,\hat{g}_L$, 就找$\hat{g}_U,\hat{g}_L$ 使得

$$P(g(\theta)\le\hat{g}_U)>1-\alpha,\ P(g(\theta)\ge\hat{g}_L)>1-\alpha,$$

且它们尽可能地接近$1-\alpha$.

确定置信上下界的方法和确定置信区间的方法完全一样。

例6.26 令$X_1,X_2,\cdots,X_n\ iid\sim N(\mu_1,\sigma^2)$, $Y_1,Y_2,\cdots,Y_m\ iid\sim N(\mu_2,\sigma^2)$, σ^2未知，两组样本相互独立。求$\mu_1-\mu_2$的置信水平为$1-\alpha$的置信上下界？

解： 利用前述记号，由于

$$\sqrt{\frac{nm}{n+m}}\left[(\bar{X}-\bar{Y})-(\mu_1-\mu_2)\right]/S_0\sim t_{n+m-2},$$

$\mu_1-\mu_2$的置信水平为$1-\alpha$的置信上界为

$$(\bar{X}-\bar{Y})+S_0t_{n+m-2}(1-\alpha)\sqrt{\frac{n+m}{nm}}.$$

$\mu_1-\mu_2$的置信水平为$1-\alpha$的置信下界为

$$(\bar{X}-\bar{Y})-S_0t_{n+m-2}(1-\alpha)\sqrt{\frac{n+m}{nm}}.$$

例6.27 令$X\sim B(n,p)$. 设p的先验分布为$Beta(\xi,\eta),\xi>0,\eta>0$. 求$p$的置信水平为$1-\alpha$的Bayes置信上下界。

解： 由例6.9知p的后验分布$Beta(X+\xi,n-X+\eta)$. 因此，p的置信水平为$1-\alpha$的Bayes置信上、下界分别为满足下面两个等式的U和L,

$$\int_0^U\frac{\Gamma(n+\xi+\eta)}{\Gamma(X+\xi)\Gamma(n-X+\eta)}p^{X+\xi-1}(1-p)^{n-X+\eta-1}dp=1-\alpha,$$

$$\int_L^1 \frac{\Gamma(n+\xi+\eta)}{\Gamma(X+\xi)\Gamma(n-X+\eta)} p^{X+\xi-1}(1-p)^{n-X+\eta-1}dp = 1-\alpha.$$

6.3.3 确定样本量

以区间长度最小为准则时，同一置信水平的置信区间长度越短越好。直观上来说，一个好的区间估计，当样本量趋于无穷时，关于待估参数的信息全都获悉后，区间长度应该依概率收敛到0. 因此若给定区间长度的值，我们可以确定样本量大小。下面以一个例子来简要说明。

例6.28 一地区要调查某项惠民方案的支持率p, 问应该至少调查多少人才能使p的置信水平为$1-\alpha$ 的置信区间长度不超过c? 如果已知该区的$p \geq 0.8$, 所需的样本量会减少吗？

解：设需要调查n个人，其中X个人支持该政策。则$X \sim B(n,p)$. p的极大似然估计为$\hat{p} = X/n$. 由例6.23可知，p的置信水平为$1-\alpha$的置信区间为$[\hat{p}_L, \hat{p}_U]$, 其中

$$\hat{p}_L = \frac{n}{n+u_{1-\alpha/2}^2}\left[\hat{p} + \frac{u_{1-\alpha/2}^2}{2n} - u_{1-\alpha/2}\sqrt{\frac{\hat{p}(1-\hat{p})}{n} + \frac{u_{1-\alpha/2}^2}{4n^2}}\right],$$

$$\hat{p}_L = \frac{n}{n+u_{1-\alpha/2}^2}\left[\hat{p} + \frac{u_{1-\alpha/2}^2}{2n} + u_{1-\alpha/2}\sqrt{\frac{\hat{p}(1-\hat{p})}{n} + \frac{u_{1-\alpha/2}^2}{4n^2}}\right].$$

区间的长度为

$$\frac{2nu_{1-\alpha/2}\sqrt{\frac{\hat{p}(1-\hat{p})}{n} + \frac{u_{1-\alpha/2}^2}{4n^2}}}{n+u_{1-\alpha/2}^2}.$$

由于对任意$\hat{p} \in (0,1)$, $\hat{p}(1-\hat{p}) \leq 0.5^2 = 0.25$, 可知

$$\begin{aligned}\frac{2nu_{1-\alpha/2}\sqrt{\frac{\hat{p}(1-\hat{p})}{n} + \frac{u_{1-\alpha/2}^2}{4n^2}}}{n+u_{1-\alpha/2}^2} &\leq \frac{2nu_{1-\alpha/2}\sqrt{\frac{1}{4n} + \frac{u_{1-\alpha/2}^2}{4n^2}}}{n+u_{1-\alpha/2}^2} \\ &= \frac{u_{1-\alpha/2}}{\sqrt{n+u_{1-\alpha/2}^2}} \\ &< c.\end{aligned}$$

得

$$n \geq \left(\frac{1}{c^2} - 1\right)u_{1-\alpha/2}^2.$$

可见置信区间长度越小，所需要调查的人数就越大。

若$p \geq 0.8$, 则可近似认为$\hat{p} \geq 0.8$, 有$\hat{p}(1-\hat{p}) \leq 0.16$, 可知

$$\frac{2nu_{1-\alpha/2}\sqrt{\frac{\hat{p}(1-\hat{p})}{n} + \frac{u_{1-\alpha/2}^2}{4n^2}}}{n+u_{1-\alpha/2}^2} \leq \frac{u_{1-\alpha/2}\sqrt{0.64n + u_{1-\alpha/2}^2}}{n+u_{1-\alpha/2}^2} < c.$$

由于$0.64n + u_{1-\alpha/2}^2 < n + u_{1-\alpha/2}^2$, 即

$$\frac{u_{1-\alpha/2}\sqrt{0.64n + u_{1-\alpha/2}^2}}{n + u_{1-\alpha/2}^2} < \frac{u_{1-\alpha/2}}{\sqrt{n + u_{1-\alpha/2}^2}},$$

可见，所需要的样本量比不知道p的任何信息要小。

习题六

矩估计和极大似然估计

1. 令$X_1, X_2, \cdots, X_n \sim Geo(p)$. 求$p$的矩估计和极大似然估计。

2. 令$(X_1, X_2, \cdots, X_k)^\top \sim Mul(N, p_1, p_2, \cdots, p_k)$. 求$p_1, p_2, \cdots, p_k$的矩估计和极大似然估计。

3. 令某人群基因组上一等位基因位点有三种基因型：gg, GG, GG, 基因型频率分别为$P(\text{gg}) = (1-p)^2$, $P(\text{Gg}) = 2p(1-p)$, $P(\text{GG}) = p^2$. 记随机抽取的n个人中拥有上述三种基因型的人数分别为n_0, n_1, n_2. 求p的矩估计和极大似然估计。

4. 令$X_1, X_2, \cdots, X_n \; iid \sim U(-\theta/2, \theta/2)$. 求$\theta$的矩估计和极大似然估计。

5. 令$X_1, X_2, \cdots, X_n \; iid \sim N(\mu, \sigma^2)$, μ, σ^2是未知参数。求$P(X_1 > 1)$的极大似然估计。

6. 令$X_1, X_2, \cdots, X_n \; iid \sim LN(\mu, \sigma^2)$. 求$\mu, \sigma^2$的矩估计和极大似然估计。

7. 令$X_1, X_2, \cdots, X_n \; iid \sim Laplace(\mu, \lambda)$ (密度函数见第四章习题31). 求μ, λ的矩估计和极大似然估计。

8. 令$X_1, X_2, \cdots, X_n$独立同分布，且X_1的分布函数为

$$F(x, \theta) = \begin{cases} k - \frac{1}{x^{2\theta}}, & x > 1, \\ 0, & x \le 1, \end{cases}$$

其中$\theta \ge 1$. 求θ的矩估计和极大似然估计。

9. 令$X_1, X_2, \cdots, X_n$独立同分布，且X_1的密度函数为

$$f(x, \theta) = \begin{cases} -\theta^x \ln \theta, & x > 0, \\ 0, & x \le 0, \end{cases}$$

其中$0 < \theta < 1$. 求θ的矩估计和$\ln \theta$的极大似然估计。

10. 令$X_1, X_2, \cdots, X_n$独立同分布，且X_1的密度函数为

$$f(x, \mu) = \begin{cases} 4e^{-4(x-\mu)}, & x \ge \mu, \\ 0, & \text{其它。} \end{cases}$$

求μ的极大似然估计。

11. 令$X_1, X_2, \cdots, X_n \; iid \sim B(1, p)$, $Y_1, Y_2, \cdots, Y_m \; iid \sim B(1, p/2)$, 两组样本相互独立。求$p$的极大似然估计。

12. 令$X_1, X_2, \cdots, X_n$独立同分布，服从**双参数指数分布**，其密度函数为$f(x, \theta_1, \theta_2)$,

$$f(x, \theta_1, \theta_2) = \begin{cases} \dfrac{1}{\theta_2} \exp\left(-\dfrac{x-\theta_1}{\theta_2}\right), & x \geq \theta_1 \\ 0, & x < \theta_1. \end{cases}$$

(1)θ_1已知时，求θ_2的极大似然估计；
(2)θ_2已知时，求θ_1的极大似然估计；
(3)θ_1, θ_2都未知时，求θ_1, θ_2的极大似然估计。

13. 令总体的均值为μ, 标准差σ, 称σ/μ为**变异系数**。若$X_1, X_2, \cdots, X_n$ $iid \sim N(\mu, \sigma^2)$. 求$\sigma/\mu$的极大似然估计。

14. 令X_1, X_2 $iid \sim Cauchy(\mu, 1)$. 试验证似然方程的解不全是极大似然估计。

Bayes估计

15. 令$X \sim B(n, p)$, p的先验分布为$U(0, 1)$. 求p的Bayes估计。

16. 令$X_1, X_2, \cdots, X_n$ $iid \sim Exp(\lambda), \lambda > 0$. 记$\lambda \sim Exp(\theta), \theta > 0$. 求$\lambda$的Bayes估计。

17. 令$X_1, X_2, \cdots, X_n$ $iid \sim U(0, \theta)$. 记θ的先验分布为Pareto分布(密度函数见第四章习题30). 求证：Pareto分布是θ的共轭先验分布。

18. 令$X = (X_1, X_2, \cdots, X_n)^\top \sim Mul(N, p_1, p_2, \cdots, p_n)$. 记$p = (p_1, p_2, \cdots, p_n)^\top$的先验分布为**Dirichlet分布**(记作$Dirichlet(p)$), 其密度函数为

$$h(p) = \frac{\Gamma(\alpha_0)}{\prod_{i=1}^{n} \Gamma(\alpha_i)} \prod_{i=1}^{n} p_i^{\alpha_i - 1}, 0 \leq p_i \leq 1, i = 1, 2, \cdots, n,$$

其中$\alpha_i > 0, i = 1, 2, \cdots, n$, $\alpha_0 = \sum_{i=1}^{n} \alpha_i$. 求证：Dirichilet分布是$p$的共轭先验分布族，$p$的后验分布为$Dirichlet(\alpha + X)$, 其中$\alpha = (\alpha_1, \alpha_2, \cdots, \alpha_n)^\top$.

无偏估计

19. 令$X_1, X_2, \cdots, X_n$ $iid \sim Geo(p)$. 求$1/p$和$1/p^2$的无偏估计。

20. 令$X_1, X_2, \cdots, X_n$ $iid \sim Poisson(\lambda)$. 求$\lambda^2$的无偏估计。

21. 令$X_1, X_2, \cdots, X_n$ $iid \sim N(\mu, \sigma^2)$. 记样本均值和样本方差分别为$\bar{X}$和$S^2$, $W = \dfrac{1}{n-1} \sum_{i=1}^{n} |X_i - \bar{X}|$.
(1)以S为基础，构造σ的无偏估计；

(2)以W为基础，构造σ的无偏估计；

(3)求常数k，使$\frac{1}{k}\sum_{i=1}^{n-1}(X_{i+1}-X_i)^2$为$\sigma^2$的无偏估计；

(4)求证：$\bar{X}^2-\frac{1}{n}S^2$是μ^2的无偏估计。

22. 令$X_1,X_2,\cdots,X_n\ iid\sim Exp(\lambda)$. 求$\lambda$的无偏估计。

23. 令$X_1,X_2,\cdots,X_n\ iid\sim U(\theta-1/2,\theta+1/2)$. 求证：

$$\hat{\theta}_1=\frac{1}{n}\sum_{i=1}^{n}X_i,\quad \hat{\theta}_2=\frac{1}{2}\big(\max_{1\le i\le n}X_i+\min_{1\le i\le n}X_i\big)$$

都是θ的无偏估计。

24. 令$X_1,X_2,\cdots,X_n$独立同分布，且X_1的密度函数为

$$f(x,\theta)=\begin{cases}2e^{-2(x-\theta)} & x>\theta,\\ 0, & x\le\theta,\end{cases}$$

其中θ是未知参数，且$\theta>0$。求θ的无偏估计。

25. 令$X_1,X_2,\cdots,X_n$独立同分布，且X_1的密度函数为

$$f(x;\theta)=\begin{cases}\frac{1}{\theta}x^{(1-\theta)/\theta}, & 0<x<1,\\ 0, & \text{其他},\end{cases}$$

其中$\theta>0$. 求θ的无偏估计。

26. 令$X_1,X_2,\cdots,X_n$独立同分布，且X_1的密度函数为

$$f(x,\theta)=\begin{cases}\frac{3x^2}{\theta^3}, & 0<x<\theta,\\ 0, & \text{其它},\end{cases}$$

其中$\theta>0$. 求θ的无偏估计。

均方误差

27. 令$X_1,X_2,\cdots,X_n\ iid\sim U(\theta-1,\theta+1)$, θ是未知参数。记样本均值、次序统计量的最小值、最大值分别为$\bar{X}$, $X_{(1)}$, $X_{(n)}$. 试比较$\bar{X}$, $\frac{X_{(1)}+X_{(n)}}{2}$的均方误差。

28. 令$X_1,X_2,\cdots,X_n\ iid\sim N(\mu,\sigma^2)$, $n\ge2$, μ,σ^2未知。记样本均值为$\bar{X}$，

$$T_1=\frac{1}{n-1}\sum_{i=1}^{n}(X_i-\bar{X})^2,\ T_2=\frac{1}{n}\sum_{i=1}^{n}(X_i-\bar{X})^2,\ T_3=\frac{1}{n+1}\sum_{i=1}^{n}(X_i-\bar{X})^2.$$

试比较T_1,T_2,T_3的均方误差。

29. 令总体$X_1, X_2, \cdots, X_n\, iid \sim N(\mu_1, \sigma^2)$, $Y_1, Y_2, \cdots, Y_m\, iid \sim N(\mu_2, \sigma^2)$, μ_1, μ_2, σ^2未知，两组样本相互独立。记它们的样本均值分别为$\bar{X}, \bar{Y}$; 样本方差分别为S_1^2, S_2^2; $S_0^2 = \frac{1}{n+m-2}[(n-1)S_1^2 + (m-1)S_2^2]$. 求证：
(1)S_0^2是σ^2的无偏估计;
(2)S_1^2和S_2^2的线性组合$wS_1^2 + (1-w)S_2^2$, $w \in [0,1]$也是σ^2的无偏估计且在其类中，S_0^2的方差是最小的。

30. 令$X_1, X_2, \cdots, X_n\, iid \sim F(x, \theta)$. 记待估参数为$g(\theta)$, $T = T(X_1, X_2, \cdots, X_n)$是$g(\theta)$的无偏估计，$a, b$是给定的常数，$a < b$. 考察截尾估计

$$Z = \begin{cases} T, & a \le T \le b, \\ a, & T < a, \\ b, & T > b. \end{cases}$$

求证：$E\big(Z - g(\theta)\big)^2 \le E\big(E - g(\theta)\big)^2$.

C-R不等式

31. 令总体X的密度函数为

$$f(x, \theta) = \theta c^{2\theta} x^{-(\theta+1)}, x > c^2, c \ne 0.$$

求θ的Fisher信息量。

32. 令$X_1, X_2, \cdots, X_n$独立同分布，且服从离散分布

$$P(X_1 = -1) = \frac{1-\theta}{2},\ P(X_1 = 0) = \frac{1}{2},\ P(X_1 = 1) = \frac{\theta}{2},\ 0 < \theta < 1.$$

(1)求θ的无偏估计；
(2)求θ的无偏估计的方差的C-R不等式下界。

33. 令总体X的密度函数为

$$f(x, \theta) = \begin{cases} \theta x^{\theta-1}, & 0 < x < 1, \\ 0, & \text{其他}, \end{cases}$$

其中$\theta > 0$, $g(\theta) = 1/\theta$. 记$X_1, X_2, \cdots, X_n\, iid \sim X$.
(1)求$g(\theta)$的矩估计$\hat{g}_1(\theta)$和极大似然估计$\hat{g}_2(\theta)$;
(2)$\hat{g}_1(\theta)$和$\hat{g}_2(\theta)$是否无偏估计吗？
(3)计算$g(\theta)$的无偏估计的方差的C-R不等式下界；
(4)$\hat{g}_1(\theta)$和$\hat{g}_2(\theta)$是UMVUE吗？

34. 令$X_1, X_2, \cdots, X_n\, iid \sim Gamma(\xi, \lambda)$及$g(\lambda) = 1/\lambda$.
(1)求$g(\lambda)$的矩估计$\hat{g}_1$和极大似然估计$\hat{g}_2$；
(2)求证：$\hat{g}_2$是$g(\theta)$的相合估计；
(3)问$\hat{g}_2$是UMVUE吗？

35. (1) 令$X \sim B(n,p)$. 求证：X/n是p的UMVUE;
(2) 令$X_1, X_2, \cdots, X_n$ iid $\sim Poisson(\lambda)$. 求证：样本均值$\bar{X}$是λ的UMVUE;
(3) 令$X_1, X_2, \cdots, X_n$ $iid \sim Exp(\lambda)$. 求证：$\bar{X}$是$1/\lambda$的UMVUE.

36. 令$X_1, X_2, \cdots, X_n$ $iid \sim N(\mu, \sigma^2)$, μ已知。求证：
(1)$\frac{1}{n}\sum_{i=1}^{n}(x_i-\mu)^2$是$\sigma^2$的无偏估计，且达到了C-R不等式的下界；
(2)$\frac{1}{n}\sqrt{\frac{\pi}{2}}\sum_{i=1}^{n}|x_i-\mu|$是$\sigma$的无偏估计，但未达到C-R不等式的下界。

充分完备统计量

37. 试说明二项分布族、负二项分布族、几何分布族、超几何分布族和Poisson分布族都属于指数族。

38. (1)令$X_1, X_2, \cdots, X_n$ $iid \sim Exp(\lambda)$. 求其充分完备统计量。
(2)令$X_1, X_2, \cdots, X_n$服从双参数指数分布(见本章习题12)，求其充分完备统计量。

39. 令$X_1, X_2, \cdots, X_n$ $iid \sim N(\theta, \theta^2)$. 问$\big(\sum_{i=1}^{n}X_i, \sum_{i=1}^{n}X_i^2\big)$是充分完备统计量吗?

40. 令总体$X \sim B(1,p)$, $0<p<1$, $X_1, X_2, \cdots, X_n$ $iid \sim X$, $n \geq 2$. 求：(1)充分完备统计量；(2)$p(1-p)$的UMVUE.

41. 令$X_1, X_2, \cdots, X_n$ $iid \sim Poisson(\lambda), \lambda > 0$. 给定$k$, 记

$$g(\lambda) = \frac{e^{-\lambda}\lambda^k}{k!}.$$

求$g(\lambda)$的UMVUE.

42. 令$X_1, X_2, \cdots, X_n$ $iid \sim U(0,\theta)$. 求证：$X_{(n)}$是充分完备统计量，$\frac{n+1}{n}X_{(n)}$是θ的UMVUE.

43. 令$\hat{g}_i$是待估参数$g_i(\theta)$的UMVUE, $i=1,2,\cdots,k$ $(k \geq 2)$. 求证：对任意的非零常数a_i, $i=1,2,\cdots,k$, $\sum_{i=1}^{k}a_i\hat{g}_i$是$\sum_{i=1}^{k}g_i(\theta)$的UMVUE.

44. (**判断UMVUE的准则：零期望不相关**) 令总体的分布函数为$F(x,\theta)$, $\theta \in \Theta$. 记$X_1, X_2, \cdots, X_n$ $iid \sim F(x,\theta)$, $\hat{\theta} = \hat{\theta}(X_1, X_2, \cdots, X_n)$是$\theta$的一个无偏估计且方差存在。那么$\hat{\theta}$是$\theta$的UMVUE的充分必要条件是：对任意一个期望为0方差存在的估计量$U = U(X_1, X_2, \cdots, X_n)$, $\mathrm{cov}(\hat{\theta}, U) = 0$.

相合性

45. 令$X_1, X_2, \cdots, X_n$ $iid \sim F(x,\theta)$,

$$F(x,\theta) = \begin{cases} 1 - e^{-x^2/\theta}, & x \geq 0, \\ 0, & \text{其它}, \end{cases}$$

其中$\theta > 0$.
(1)求$F(x,\theta)$的均值和方差；
(2)求θ的矩估计和极大似然估计；
(3)极大似然估计是θ的相合估计吗？

46. 令$Z_{ij} = \mu + X_i + Y_{ij}$, $EX_i = 0, \mathrm{var}(X_i) = \sigma^2 < \infty$, $EY_{ij} = 0, \mathrm{var}(Y_{ij}) = \delta^2 < \infty$, $i = 1, 2, \cdots, n$, $j = 1, 2, \cdots, m$, 且对所有的i, j, X_i和Y_{ij}都相互独立。记$\bar{Z} = \frac{1}{nm} \sum_{i=1}^{n} \sum_{j=1}^{m} Z_{ij}$. 求证：当$n \to \infty$且$m$固定时，$\bar{Z}$是$\mu$的相合估计。

47. 令$X_1, X_2, \cdots, X_n$ $iid \sim U(0,\theta)$, $\theta > 0$. 记次序统计量的最大值为$X_{(n)}$. 求证：$X_{(n)}$是θ的相合估计。

Jessen不等式

48. 令随机变量X的r阶矩存在。求证：对任意$0 < k < r$,

$$\big(E|X|^k\big)^{\frac{1}{k}} \leq \big(E|X|^r\big)^{\frac{1}{r}}.$$

49. 令离散型随机变量X的概率函数为

$$P(X = a_i) = p_i, i = 1, 2, \cdots, n.$$

定义X的**熵**为$H(X) = -\sum_{i=1}^{n} p_i \ln p_i$. 求证：当$p_1 = p_2 = \cdots = p_n = 1/n$ 时，$H(X)$达到最大值。

渐近正态性

50. 令$X_1, X_2, \cdots, X_n$ $iid \sim B(1,p)$. 记样本均值为$\bar{X}$. 求证：
(1)$2\sqrt{n}\big(\arcsin\sqrt{\bar{X}} - \arcsin\sqrt{p}\big) \xrightarrow{d} N(0,1)$;
(2)求$\sqrt{n}\bar{X}(1-\bar{X})$的渐近方差。

51. 令$X_1, X_2, \cdots, X_n$ $iid \sim N(\mu, \sigma^2)$, μ已知。
(1)求常数k, 使$\hat{\sigma}_1 = \dfrac{k}{n} \sum_{i=1}^{n} |X_i - \mu|$ 是σ的相合估计；
(2)求σ的矩估计$\hat{\sigma}_2$和极大似然估计$\hat{\sigma}_3$；
(3)求$\sqrt{n}\hat{\sigma}_1, \sqrt{n}\hat{\sigma}_2, \sqrt{n}\hat{\sigma}_3$的渐近方差。

52. 令$X_1, X_2, \cdots, X_n$ $iid \sim U(0,1)$, $Y_n = \big(\prod_{i=1}^{n} X_i\big)^{-1/n}$, 求证：

$$\frac{\sqrt{n}(Y_n - e)}{e} \xrightarrow{d} N(0,1).$$

区间估计

53. 令$X_1, X_2, \cdots, X_n$ $iid \sim N(\mu_1, \sigma_1^2)$, $Y_1, Y_2, \cdots, Y_m$ $iid \sim N(\mu_2, \sigma_2^2)$且两组样本相互独立，$\mu_1, \mu_2, \sigma_1^2, \sigma_2^2$都未知，且$\sigma_1^2/\sigma_2^2 = c$, 其中$c$为已知常数。求$\mu_1 - \mu_2$的置信水平为$1-\alpha$的置信区间。

54. 令$X_1, X_2, \cdots, X_n$ $iid \sim N(\mu, \sigma^2)$, $Y_1, Y_2, \cdots, Y_m$ $iid \sim N(c\mu, \sigma^2)$, μ未知，σ^2和c已知，两组样本相互独立。记两组样本的样本均值分别为$\bar{X}$和$\bar{Y}$.
(1)求μ的极大似然估计$\hat{\mu}$;
(2)求证：$\hat{\mu}$是形如$a\bar{X} + b\bar{Y}$的μ的无偏估计类中方差最小的；
(3)给定$0 < \alpha < 1$, 利用$\hat{\mu}$构造μ的置信水平为$1-\alpha$的置信区间。

55. 令$X_1, X_2, \cdots, X_n$ $iid \sim Exp(\lambda)$. 求λ和$1/\lambda$的置信水平为$1-\alpha$的置信区间。

56. 令$X_1, X_2, \cdots, X_n$ $iid \sim Exp(\lambda_1)$, $Y_1, Y_2, \cdots, Y_m$ $iid \sim Exp(\lambda_2)$, 两组样本相互独立，c是不等于0的常数。求$c\lambda_1/\lambda_2$的置信水平为$1-\alpha$的置信区间。

57. 令$X_1, X_2, \cdots, X_n$ $iid \sim U(\theta - 1, \theta + 1)$. 求$\theta$的置信水平为$1-\alpha$的置信区间。

58. 令$X_1, X_2, \cdots, X_n$ $iid \sim U(0, \theta)$, $\theta > 0$. 试以$X_{(n)}$为基础构造θ的置信水平为$1-\alpha$的置信区间。

59. 令$X_1, X_2, \cdots, X_n$ $iid \sim U(0, \theta_1)$, $Y_1, Y_2, \cdots, Y_m$ $iid \sim U(0, \theta_2)$, 且两组样本相互独立。对任意给定$k, k \neq 0$, 求$k\theta_2/\theta_1$的置信水平为$1-\alpha$的置信区间。

60. 令$X_1, X_2, \cdots, X_n$ $iid \sim Poisson(\lambda)$. 利用大样本法求$\lambda$的区间估计。

61. 令$X_1, X_2, \cdots, X_n$独立同分布，其密度函数为

$$f(x,\theta) = \begin{cases} \frac{2x}{\theta} e^{-\frac{x^2}{\theta}}, & x > 0, \\ 0, & x \leq 0, \end{cases}$$

其中$\theta > 0$. 求：
(1)$f(x,\theta)$的充分完备统计量。
(2)X_1^2的分布，并给出θ的置信水平为$1-\alpha$的置信区间和大样本的置信区间。

62. 令$X_1, X_2 \cdots, X_n \; iid \sim N(\mu, \sigma^2)$. 求$\sigma^2$的置信水平为$1-\alpha$的置信区间

$$\left[\frac{(n-1)S^2}{\chi^2_{n-1}(1-\alpha/2)}, \frac{(n-1)S^2}{\chi^2_{n-1}(\alpha/2)}\right].$$

的区间长度的数学期望。

第七章　假设检验

假设检验是统计推断的重要内容之一。最早于17世纪，Laplace 运用假设检验比较欧洲城市男孩和女孩出生率的差异。20世纪初，随着假设检验基本理论的形成和完善，假设检验被人们广泛应用到各行各业中。假设检验是一种统计推断方法，用于确定收集到的数据是否充分支持某个特定的假设。假设检验中常见的是参数检验，即根据收集到的数据对总体分布含有的未知参数或者未知参数的函数进行判断，给出事先对它们做出的假设正确与否的决定。比如，考察某厂生产一批零件的尺寸是否合格。把零件的尺寸看成一个随机变量，认为它服从正态分布$N(\mu_0, \sigma_0^2)$, μ_0和σ_0^2已知。随着时间的流逝，生产零件的机器磨损，厂方怀疑零件的尺寸不合格了，认为零件的尺寸的均值μ不等于μ_0了。厂方需要根据搜集到的若干零件的尺寸来判断$\mu \neq \mu_0$. 再比如，在临床试验中，为了判断新生产的药物是否对治疗某种特定的疾病有效，将招募来的志愿者随机分成两组，一组为新药治疗组，另一组为安慰剂组，通过检验两组个体间的若干生物标记物指标的差异来判断新药有效与否。

此外，当总体分布的形式未知，需要对总体分布进行检验。拟合优度检验就是用于检验一组数据是否来自于一个离散的总体，它还可用于属性数据列联表的独立性检验。如果检验一组数据是否来自于一个连续总体，可使用基于经验分布函数的Kolmogorov-Smirnov检验；如果检验两个总体分分布是否相同，可使用基于样本秩的Mann-Whitney检验，这两类检验都不涉及任何参数且对总体分布不做要求，被称为非参数检验方法。这些检验方法将在本章进行一一介绍。

为了描述方便，本章考虑的参数检验都是针对未知参数θ的检验，基于第六章定理6.9(Delta方法)，针对θ的函数$g(\theta)$, 同样可以构造$g(\theta)$ 的假设检验。除非特别说明，本章提到的“总体X的密度函数$f(x,\theta)$”的意思如下：
(1)如果X是连续型随机变量，$f(x,\theta)$是X的密度函数；
(2)如果X是离散型随机变量，$f(x,\theta)$是X的概率函数。

7.1 基本概念

看一个例子：水果酸奶试验，该试验类似于女士品茶试验。

例7.1 (水果酸奶试验) 一女士声称：通过品尝，她可以鉴别出一个盛满水果丁和酸奶的杯子是先加酸奶后加水果丁，还是先加水果丁后加酸奶。我们事先给出两种假设：“该女士没有鉴别能力”和“该女士有鉴别能力”。为了判断上面两个假设哪个正确，我们设计一个试验：准备了10杯水果酸奶，其中5杯先加酸奶，另外5杯先加水果丁。试验开始时，随机打乱10杯水果酸奶杯子，让女士依次品尝，每次说出是否先加酸奶。该试验一共有$2^{10} = 1024$种可能的结果。

如果该女士靠蒙的话，对杯子正确分类的概率为$1/1024 \approx 0.000977$。如果该女士全都选对了，概率仅有0.000977的事件在一次试验中发生了，我们有理由相信“该女士有鉴别能力”这个假设。进一步，该女士靠蒙成功选择出9杯和8杯正确的概率分别为$\binom{10}{9} \times 2^{-10} = 0.00977$和$\binom{10}{8} \times 2^{-10} = 0.0439$. 针对这两种情况，我们又该做出如何判断呢？

假设检验就是根据观测到的数据对事先所做的假设进行判断。下面给出假设检验中的一些基本概念。

零假设或原假设：在统计检验中一个事先建立的假设叫做零假设或原假设，记作H_0.

例7.1中，我们可以取H_0为：“该女士没有鉴别能力”。

备择假设或对立假设：与零假设或原假设相对立的假设称为备择假设或对立假设，记作H_1.

例7.1中，我们可以取H_1为：“该女士有鉴别能力”。

为了判断H_0正确还是H_1正确，我们需要从总体中随机抽取样本。令$X_1, X_2, \cdots, X_n$是观测到的数据，基于观测数据构造统计量

$$T = T(X_1, X_2, \cdots, X_n).$$

称T为**检验统计量**。检验统计量是样本的函数，它要尽可能地体现H_0和H_1之间的差异。

例7.1的观测数据为女士对每一个杯子的判断，比如，我们用X_i表示该女士对第i个杯子的判断情况：X_i取1表示该女士认为是先加酸奶，取0表示该女士认为是先加水果丁。检验统计量T可取成该女士正确识别“先加酸奶”的杯子的个数，即

$$T = \sum_{i=1}^{10} X_i.$$

有了检验统计量T后，不妨假定T越大越有利于H_1. 因此，当$T > c$拒绝H_0, 反之接受H_0, 其中c是事先给定的常数，称c为**临界值**。记

$$W = \{(X_1, X_2, \cdots, X_n) | T(X_1, X_2, \cdots, X_n) > c\}.$$

称W为检验的**拒绝域**，当样本的取值落在拒绝域W内拒绝H_0, 否则接受H_0. 一个自然的问题是c取多大？c越大拒绝H_0的概率就越小，比如$c = \infty$, 这时候$P(T > c) = 0$; 反之，c 越小拒绝H_0的概率就越大。怎样选一个合适的c? 这涉及犯两类错误(见表7.1)和显著性水平。后面为了记号的方便，拒绝域简写为$W = \{T > c\}$.

如果H_0正确但被拒绝了称为**犯第I类错误**，称其发生的概率为犯第I类错误概率；反之，如果H_0错误但被接受了称为**犯第II类错误**，称其发生的概率为犯第II类错误概率。由于检验统计量T的取值随抽取的观测样本的变化而变化，因

表7.1 犯两类错误。

事实\决策	接受H_0	拒绝H_0
H_0正确	$\surd$	犯第I类错误
H_1正确	犯第II类错误	$\surd$

此难免会犯错误。理想的做法是使犯上述两类错误的概率都小。要使犯第I类错误概率小, 应该增大c; 而要使犯第II类错误概率小, 则要减小c. 因此这两类错误是相互矛盾的。解决这个矛盾的一个有效办法是：在控制犯I类错误概率的基础上, 尽量减少犯第II类错误概率。控制犯I类错误概率就是选择一个非常小的常数α, 使得犯第I类错误的概率小于等于α. 称α为**显著性水平**。在理想情况下, 取c恰好满足$P_{H_0}(W)=\alpha$. 如果不能使$P_{H_0}(W)=\alpha$, 选择c使得$P_{H_0}(W)<\alpha$但尽可能地接近α. α常取为0.05, 0.01等较小的数, 具体取多大值视实际问题而定。有时候要求α非常小，比如全基因组关联分析，取$\alpha=5\times10^{-8}$.

针对例7.1, 我们可以取$\alpha=0.05$, 此时$c=8$, 拒绝域为

$$W=\{(X_1,X_2,\cdot,X_{10})|X_1+X_2+\cdots+X_{10}>8\}.$$

犯第I类错误的概率为

$$1/1024+10/1024=0.0107.$$

下面把假设检验问题一般化，令Θ_0和Θ_1分别是H_0和H_1成立时参数θ的取值空间。假设检验问题为

$$H_0:\theta\in\Theta_0\leftrightarrow H_1:\theta\in\Theta_1.$$

记$X_1,X_2,\cdots,X_n$为简单随机样本，T为检验统计量，α为显著性水平，W为拒绝域。定义检验ϕ为

$$\phi=\begin{cases}1, & (X_1,X_2,\cdots,X_n)\in W.\\ 0, & (X_1,X_2,\cdots,X_n)\notin W.\end{cases}$$

水平α的检验：令ϕ是一个检验。如果

$$P_{H_0}(\phi=1)=P_{H_0}\big(\{\text{拒绝}H_0\}\big)\le\alpha,\forall\,\theta\in\Theta_0,$$

称ϕ为一个水平为α的检验，其中$P_{H_0}(A)$表示在H_0成立时，事件A发生的概率。

功效函数或势函数：令ϕ是一个水平为α的检验。ϕ的功效函数或势函数为

$$\beta_\phi(\theta)=P(\phi=1)=P\big(\{\text{在检验}\phi\text{下，}H_0\text{被拒绝}\}|\theta\big),$$

当H_0成立时，$\beta_\phi(\theta)$是犯第I类错误概率；当H_1成立时，$1-\beta_\phi(\theta)$ 是犯第II类错误概率。因此，当H_0成立时，$\beta_\phi(\theta)\le\alpha$; 当$H_1$成立时，我们希望$\beta_\phi(\theta)$尽可

能地大。故在H_1成立时，称$\beta_\phi(\theta)$为检验ϕ在θ处的“功效”或者“势”。所以功效可以作为评价一个检验优劣的准则。

一致最优势检验：令ϕ是一个水平为α的检验，若对任意其它水平α的检验ϕ_1, 有

$$\beta_\phi(\theta) \geq \beta_{\phi_1}(\theta), \forall\, \theta \in \Theta_1.$$

称ϕ是水平为α的一致最优势检验(Uniformly most powerful test, 简记为UMPT)。

p-值：针对水平为α的检验ϕ, T是检验统计量。有了样本之后，记T的观测值为t. 若假设拒绝域的形式为$W = \{T > c\}$, 则p-值定义为

$$p\text{-值} = P_{H_0}(T > t).$$

另外，针对拒绝域形式为$W = \{T < c\}$, 则p-值 $= P_{H_0}(T < t)$; 针对拒绝域形式为$W = \{|T| > c\}$, 则p-值 $= P_{H_0}(|T| > |t|)$. 根据拒绝域的形状，p-值是零假设成立时，比观测数据的结果更极端(发生概率更小)的那些数据出现的概率之和(如果T是离散随机变量，求和需包括观测值发生的概率)。换句话说，p-值就是基于观测样本拒绝零假设所需要的的最小显著性水平。

针对例7.1，如果女士正确识别出8个杯子，则p-值为

$$0.000977 + 0.00977 + 0.0439 = 0.054647.$$

若取显著性水平为0.05, $0.054647 > 0.05$, 接受H_0, 认为该女士没有鉴别能力。如果取显著性水平为0.1, $0.054647 < 0.1$, 拒绝H_0, 认为该女士有鉴别能力。

拒绝域W和p-值是在零假设成立时计算的，而且零假设成立时它被拒绝的概率不会超过α. 由于α比较小，所以假设检验保护零假设，接受零假设只能说明没有充分的证据拒绝零假设；把零假设拒绝了，则说明得到的结论比较可信。因此应该把**想要的结论的对立面**作为零假设。比如司法判定，“无罪判定”即假设“嫌疑人是无罪的”作为零假设；再比如，“新药的疗效”即假设“新药无效”作为零假设。

例7.2 令$X_1, X_2, \cdots, X_n\ iid \sim N(\mu, 1)$. 假设检验问题为

$$H_0 : \mu = 0 \leftrightarrow H_1 : \mu = 1.$$

拒绝域为$W = \{\bar{X} \geq 0.5\}$.

(1)求检验犯两类错误概率并说明当$n \to \infty$, 犯两类错误的概率都趋于0. (2)要使犯第II错误概率小于或等于$1 - \beta$ $(0 < \beta < 1)$, n最小为多少？

解：记犯第I类错误的概率为ξ, 犯第II类错误的概率为η, 标准正态分布的分布函数为$\Phi(\cdot)$.

(1)由定义得犯第I类错误概率为

$$\xi = P_{H_0}(W) = P_{H_0}(\bar{X} \geq 0.5) = P_{H_0}(\sqrt{n}\bar{X} \geq 0.5\sqrt{n}) = 1 - \Phi\big(0.5\sqrt{n}\big),$$

犯第II类错误概率为

$$\eta = 1-P_{H_1}(W) = 1-P_{H_1}(\bar{X} \geq 0.5) = 1-P_{H_1}\big(\sqrt{n}(\bar{X}-1) \geq -0.5\sqrt{n}\big) = \Phi\big(-0.5\sqrt{n}\big).$$

又因为，

$$\lim_{n\to\infty} \Phi\big(0.5\sqrt{n}\big) = 1, \ \lim_{n\to\infty} \Phi\big(-0.5\sqrt{n}\big) = 0,$$

可知当$n \to \infty$, 犯两类错误的概率都趋于0.

(2)使犯第II错误概率小于或等于$1-\beta$ $(0<\beta<1)$, 即

$$\Phi\big(-0.5\sqrt{n}\big) < 1-\beta.$$

由于$\Phi\big(-0.5\sqrt{n}\big)$是$n$的减函数，$n$满足

$$n \geq 4u_{1-\beta}^2$$

的最小整数。

常见的假设检验问题:

(1)$H_0: \ \theta = \theta_0 \leftrightarrow H_1: \ \theta = \theta_1$;

(2)$H_0: \ \theta = \theta_0 \leftrightarrow H_1: \ \theta \neq \theta_0$;

(3)$H_0: \ \theta = \theta_0 \leftrightarrow H_1: \ \theta > \theta_0$ 或者$H_0: \ \theta \leq \theta_0 \leftrightarrow H_1: \ \theta > \theta_0$;

(4)$H_0: \ \theta = \theta_0 \leftrightarrow H_1: \ \theta < \theta_0$ 或者$H_0: \ \theta \geq \theta_0 \leftrightarrow H_1: \ \theta < \theta_0$.

称(1)为**简单假设**, (2)为**双侧检验**, (3)和(4)为**单侧假设**.

下面给出假设检验的一般步骤，分为四步：

(1) 设定显著性水平α. 求出θ的一个点估计$\hat{\theta} = \hat{\theta}(X_1, X_2, \cdots, X_n)$, 一般是极大似然估计；

(2) 以$\hat{\theta}$为基础, 构造检验统计量$T = T(X_1, X_2, \cdots, X_n)$ 且当$\theta = \theta_0$时，T的分布已知, 如$N(0,1)$, χ_n^2, t_n, $F_{m,n}$ 等，它与θ 无关；

(3) 以T为基础, 根据备择假设H_1的实际意义，确定拒绝域的形状，它是关于T的一个或两个不等式，其中包含一个或两个临界值；

(4) 根据显著性水平α计算了检验的拒绝域，即确定步(3)不等式的临界值，根据样本计算检验统计量T 的值, 进而判断样本是否落入拒绝域中，如果落入拒绝域就拒绝H_0, 否则接受H_0;
或者计算检验的p-值，如果p-值小于α, 拒绝H_0, 否者接受H_0.

7.2 重要参数检验

7.2.1. N-P引理

N-P引理在假设检验理论中处于非常重要的地位，它是由Neyman和Egon·Pearson于1933年提出来的，阐明了简单假设检验问题存在一致最优势检验。

定理7.1 (Neyman-Pearson引理，简记为N-P引理) 令总体X的密度函数为$f(x,\theta)$. 假设检验问题为：

$$H_0:\ \theta=\theta_0 \leftrightarrow H_1:\ \theta=\theta_1.$$

记$X_1,X_2,\cdots,X_n\ iid\sim f(x,\theta)$. 则对任意的$\alpha,0<\alpha<1$, 存在一致最优势检验$\phi\left(X_1,X_2,\cdots,X_n\right)$,

$$\phi\left(X_1,X_2,\cdots,X_n\right)=\begin{cases}1, & \prod\limits_{i=1}^{n}f(X_i,\theta_1)\Big/\prod\limits_{i=1}^{n}f(X_i,\theta_0)>c,\\ 0, & \prod\limits_{i=1}^{n}f(X_i,\theta_1)\Big/\prod\limits_{i=1}^{n}f(X_i,\theta_0)<c,\end{cases}$$

其中c满足$E_{H_0}\phi\left(X_1,X_2,\cdots,X_n\right)=\alpha$.

证明：以连续总体为例证明该定理，对离散总体同样可以证明，只是细节上稍微复杂些。

先证检验ϕ的存在性，令

$$T=\prod_{i=1}^{n}f(X_i,\theta_1)\Big/\prod_{i=1}^{n}f(X_i,\theta_0).$$

可知，T是$(X_1,X_2,\cdots,X_n)$的函数，由于X_i是连续型随机变量，$i=1,2,\cdots,n$. 所以，T是连续型随机变量，记其分布函数为$G(t)$, $c=G^{-1}(1-\alpha)$, G 的$1-\alpha$ 分位数。我们有

$$E_{H_0}\phi(X_1,X_2,\cdots,X_n)=P_{H_0}(T>c)=1-G(\alpha)=\alpha.$$

下面证明检验ϕ是一致最优势检验。设$\tilde{\phi}$ 为任一水平为α的检验。由于

$$\begin{aligned}E_{H_1}(\phi-\tilde{\phi}) &= \int\cdots\int(\phi-\tilde{\phi})\prod_{i=1}^{n}f(x_i,\theta_1)dx_1\cdots dx_n\\ &= \int\cdots\int(\phi-\tilde{\phi})\left(\prod_{i=1}^{n}f(x_i,\theta_1)-c\prod_{i=1}^{n}f(x_i,\theta_0)\right)dx_1\cdots dx_n\\ &\quad +c\int(\phi-\tilde{\phi})\prod_{i=1}^{n}f(x_i,\theta_0)dx_1\cdots dx_n\\ &= \int\cdots\int(\phi-\tilde{\phi})\left(\prod_{i=1}^{n}f(x_i,\theta_1)-c\prod_{i=1}^{n}f(x_i,\theta_0)\right)dx_1\cdots dx_n+cE_{H_0}(\phi-\tilde{\phi}).\end{aligned}$$

根据ϕ的形式，有

$$(\phi-\tilde{\phi})\left(\prod_{i=1}^{n}f(x_i,\theta_1)-c\prod_{i=1}^{n}f(x_i,\theta_0)\right)\geq 0,$$

另一方面，

$$E_{H_0}(\phi - \tilde{\phi}) = \alpha - E_{H_0}(\tilde{\phi}) \geq 0.$$

所以，

$$E_{H_1}(\phi - \tilde{\phi}) \geq cE_{H_0}(\phi - \tilde{\phi}) \geq 0.$$

即

$$E_{H_1}(\phi) \geq E_{H_1}(\tilde{\phi}).$$

7.2.2. 正态分布参数的假设检验

正态总体是常见的总体，关于正态总体的假设检验问题较多。我们将介绍单个正态总体和两个总体总体参数的假设检验。首先考察对单个正态总体参数的假设检验。

令$X_1, X_2, \cdots, X_n$ $iid \sim N(\mu, \sigma^2)$, $\mu \in \mathcal{R}, \sigma^2 > 0$. 记样本均值和样本方差分别为

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i,\ S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2.$$

一、一样本方差已知时均值的检验，即σ^2 已知，μ 的检验。

记μ_0是已知的常数。关于μ的假设检验问题有以下几种类型：

(1)$H_0: \mu = \mu_0 \leftrightarrow H_1: \mu \neq \mu_0$;

(2)$H_0: \mu = \mu_0 \leftrightarrow H_1: \mu > \mu_0$;

(3)$H_0: \mu = \mu_0 \leftrightarrow H_1: \mu < \mu_0$;

(4)$H_0: \mu \leq \mu_0 \leftrightarrow H_1: \mu > \mu_0$;

(5)$H_0: \mu \geq \mu_0 \leftrightarrow H_1: \mu < \mu_0$.

下面考察假设检验问题(1)和(4), 其它情形类似。首先考察检验问题(1),

$$(1)H_0: \mu = \mu_0 \leftrightarrow H_1: \mu \neq \mu_0.$$

由于μ的极大似然估计为$\bar{X}$, 因此$\bar{X}$离μ_0比较远时否定零假设。构造检验统计量

$$T = \frac{\bar{X} - \mu_0}{\sqrt{\sigma^2/n}} = \frac{\sqrt{n}(\bar{X} - \mu_0)}{\sigma}.$$

当H_0成立时，$T \sim N(0,1)$. 拒绝域为

$$W = \left\{\left|\sqrt{n}(\bar{X} - \mu_0)/\sigma\right| > c\right\}.$$

由控制犯第I类错误概率可知

$$P_{H_0}\left(\left|\frac{\sqrt{n}(\bar{X} - \mu_0)}{\sigma}\right| > c\right) = 2\left[1 - \Phi(c)\right] \leq \alpha.$$

即

$$\Phi(c) \geq 1 - \alpha/2.$$

由分布函数的非降性，可知$c \geq u_{1-\alpha/2}$. 取$c = u_{1-\alpha/2}$即c为控制犯第I类错误概率的临界值。于是检验的拒绝域为

$$\left\{ \left| \frac{\sqrt{n}(\bar{X} - \mu_0)}{\sigma} \right| > u_{1-\alpha/2} \right\}.$$

把样本的观测值代入T, 记T的观测值为t. p-值为

$$p\text{-值} = 2[1 - \Phi(|t|)].$$

下面考察假设检验问题(4),

$$(4)\ H_0 :\ \mu \leq \mu_0 \leftrightarrow H_1 :\ \mu > \mu_0.$$

考虑零假设的边界$\mu = \mu_0$。类似(1), 构造统计量：

$$T = \frac{\sqrt{n}(\bar{X} - \mu_0)}{\sigma}.$$

当$\mu = \mu_0$时，$T \sim N(0,1)$. T大时，拒绝零假设。拒绝域为

$$W = \left\{ \sqrt{n}(\bar{X} - \mu_0)/\sigma > c \right\}.$$

由控制犯第I类错误概率可知

$$P_{H_0}\left(\frac{\sqrt{n}(\bar{X} - \mu_0)}{\sigma} > c \right) = 1 - \Phi(c) \leq \alpha.$$

即

$$\Phi(c) \geq 1 - \alpha.$$

取$c = \Phi^{-1}(1-\alpha)$. 下面证明当$\mu < \mu_0$ 时，基于拒绝域W的犯第一类错误概率小于α.

$$\begin{aligned}
P_{H_0}\left(\tfrac{\sqrt{n}(\bar{X}-\mu_0)}{\sigma} > u_{1-\alpha}) \right) &= P_{H_0}\left(\frac{\sqrt{n}(\bar{X} - \mu + \mu - \mu_0)}{\sigma} > u_{1-\alpha} \right) \\
&= P_{H_0}\left(\frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} + \frac{\sqrt{n}(\mu - \mu_0)}{\sigma} > u_{1-\alpha} \right) \\
&= P_{H_0}\left(\frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} > u_{1-\alpha} + \frac{\sqrt{n}(\mu_0 - \mu)}{\sigma} \right) \\
&< P_{H_0}\left(\frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} > u_{1-\alpha} \right) \\
&= \alpha.
\end{aligned}$$

一样本方差已知时均值的检验见表7.2.

表7.2. 一样本方差已知时均值的检验。

假设检验	检验统计量	分布	拒绝域
$H_0 :\ \mu = \mu_0 \leftrightarrow H_1 :\ \mu \neq \mu_0$	$T = \frac{\sqrt{n}(\bar{X}-\mu_0)}{\sigma}$	$N(0,1)$	$\left\{ \lvert T \rvert > u_{1-\alpha/2} \right\}$
$H_0 :\ \mu = \mu_0 \leftrightarrow H_1 :\ \mu > \mu_0$			$\{T > u_{1-\alpha}\}$
$H_0 :\ \mu = \mu_0 \leftrightarrow H_1 :\ \mu < \mu_0$			$\{T < u_{\alpha}\}$
$H_0 :\ \mu \leq \mu_0 \leftrightarrow H_1 :\ \mu > \mu_0$			$\{T > u_{1-\alpha}\}$
$H_0 :\ \mu \geq \mu_0 \leftrightarrow H_1 :\ \mu < \mu_0$			$\{T < u_{\alpha}\}$

二、一样本方差未知时均值的检验见表7.3.

表7.3. 一样本方差未知时均值的检验。

假设检验	检验统计量	分布	拒绝域
$H_0:\ \mu=\mu_0 \leftrightarrow H_1:\ \mu\neq\mu_0$	$T=\frac{\sqrt{n}(\bar{X}-\mu_0)}{S}$	t_{n-1}	$\{\lvert T\rvert > t_{n-1}(1-\alpha/2)\}$
$H_0:\ \mu=\mu_0 \leftrightarrow H_1:\ \mu>\mu_0$			$\{T > t_{n-1}(1-\alpha)\}$
$H_0:\ \mu=\mu_0 \leftrightarrow H_1:\ \mu<\mu_0$			$\{T < t_{n-1}(\alpha)\}$
$H_0:\ \mu\leq\mu_0 \leftrightarrow H_1:\ \mu>\mu_0$			$\{T > t_{n-1}(1-\alpha)\}$
$H_0:\ \mu\geq\mu_0 \leftrightarrow H_1:\ \mu<\mu_0$			$\{T < t_{n-1}(\alpha)\}$

针对对方差σ^2的假设检验，同样分别μ 已知和未知两种情形。记σ_0^2为已知的常数。

三、一样本均值已知时方差的检验见表7.4.

表7.4. 一样本均值已知时方差的检验。

假设检验	检验统计量	分布	拒绝域
$H_0:\sigma^2=\sigma_0^2 \leftrightarrow H_1:\sigma^2\neq\sigma_0^2$	$T=\frac{1}{\sigma_0^2}\sum_{i=1}^{n}(X_i-\mu)^2$	χ_n^2	$\{T > \chi_n^2(1-\frac{\alpha}{2})\}\cup\{T < \chi_n^2(\frac{\alpha}{2})\}$
$H_0:\sigma^2=\sigma_0^2 \leftrightarrow H_1:\sigma^2>\sigma_0^2$			$\{T > \chi_n^2(1-\alpha)\}$
$H_0:\sigma^2=\sigma_0^2 \leftrightarrow H_1:\sigma^2<\sigma_0^2$			$\{T < \chi_n^2(\alpha)\}$
$H_0:\sigma^2\leq\sigma_0^2 \leftrightarrow H_1:\sigma^2>\sigma_0^2$			$\{T > \chi_n^2(1-\alpha)\}$
$H_0:\sigma^2\geq\sigma_0^2 \leftrightarrow H_1:\sigma^2<\sigma_0^2$			$\{T < \chi_n^2(\alpha)\}$

四、一样本均值未知时方差的检验见表7.5.

表7.5. 一样本均值未知时方差的检验。

假设检验	检验统计量	分布	拒绝域
$H_0:\sigma^2=\sigma_0^2 \leftrightarrow H_1:\sigma^2\neq\sigma_0^2$	$T=\frac{1}{\sigma_0^2}\sum_{i=1}^{n}(X_i-\bar{X})^2$	χ_{n-1}^2	$\{T > \chi_{n-1}^2(1-\frac{\alpha}{2})\}\cup\{T < \chi_{n-1}^2(\frac{\alpha}{2})\}$
$H_0:\sigma^2=\sigma_0^2 \leftrightarrow H_1:\sigma^2>\sigma_0^2$			$\{T > \chi_{n-1}^2(1-\alpha)\}$
$H_0:\sigma^2=\sigma_0^2 \leftrightarrow H_1:\sigma^2<\sigma_0^2$			$\{T < \chi_{n-1}^2(\alpha)\}$
$H_0:\sigma^2\leq\sigma_0^2 \leftrightarrow H_1:\sigma^2>\sigma_0^2$			$\{T > \chi_{n-1}^2(1-\alpha)\}$
$H_0:\sigma^2\geq\sigma_0^2 \leftrightarrow H_1:\sigma^2<\sigma_0^2$			$\{T < \chi_{n-1}^2(\alpha)\}$

下面考察两个正态总体参数的假设检验。

令$X_1, X_2, \cdots, X_n\ iid\sim N(\mu_1,\sigma_1^2), Y_1, Y_2, \cdots, Y_m\ iid\sim N(\mu_2,\sigma_2^2)$, 两样本相互独立。记

$$\bar{X}=\frac{1}{n}\sum_{i=1}^{n}X_i,\ \bar{Y}=\frac{1}{m}\sum_{j=1}^{n}Y_j,$$

$$S_1^2=\frac{1}{n-1}\sum_{i=1}^{n}(X_i-\bar{X})^2,\ S_2^2=\frac{1}{m-1}\sum_{j=1}^{m}(Y_j-\bar{Y})^2,$$

$$S_0^2=\frac{1}{n+m-2}\Big[\sum_{i=1}^{n}(X_i-\bar{X})^2+\sum_{j=1}^{m}(Y_j-\bar{Y})^2\Big],$$

和

$$\tilde{S}_1^2=\frac{1}{n}\sum_{i=1}^{n}(X_i-\mu_1)^2,\ \tilde{S}_2^2=\frac{1}{m}\sum_{j=1}^{m}(Y_j-\mu_2)^2.$$

五、两样本方差已知时均值差异的检验见表7.6.

表7.6. 两样本方差已知时均值差异的检验。

假设检验	检验统计量	分布	拒绝域
$H_0:\mu_1=\mu_2\leftrightarrow H_1:\mu_1\neq\mu_2$	$T=\frac{\bar{X}-\bar{Y}}{\sqrt{\frac{\sigma_1^2}{n}+\frac{\sigma_2^2}{m}}}$	$N(0,1)$	$\{\lvert T\rvert>u_{1-\alpha/2}\}$
$H_0:\mu_1=\mu_2\leftrightarrow H_1:\mu_1>\mu_2$			$\{T>u_{1-\alpha}\}$
$H_0:\mu_1=\mu_2\leftrightarrow H_1:\mu_1<\mu_2$			$\{T<u_{\alpha}\}$
$H_0:\mu_1\leq\mu_2\leftrightarrow H_1:\mu_1>\mu_2$			$\{T>u_{1-\alpha}\}$
$H_0:\mu_1\geq\mu_2\leftrightarrow H_1:\mu_1<\mu_2$			$\{T<u_{\alpha}\}$

六、两样本方差未知且相等时均值差异的检验见表7.7.

表7.7. 两样本差未知且相等时均值差异的检验。

假设检验	检验统计量	分布	拒绝域
$H_0:\mu_1=\mu_2\leftrightarrow H_1:\mu_1\neq\mu_2$	$T=\frac{\bar{X}-\bar{Y}}{S_0\sqrt{\frac{1}{n}+\frac{1}{m}}}$	t_{n+m-2}	$\{\lvert T\rvert>t_{n+m-2}(1-\frac{\alpha}{2})\}$
$H_0:\mu_1=\mu_2\leftrightarrow H_1:\mu_1>\mu_2$			$\{T>t_{n+m-2}(1-\alpha)\}$
$H_0:\mu_1=\mu_2\leftrightarrow H_1:\mu_1<\mu_2$			$\{T<t_{n+m-2}(\alpha)\}$
$H_0:\mu_1\leq\mu_2\leftrightarrow H_1:\mu_1>\mu_2$			$\{T>t_{n+m-2}(1-\alpha)\}$
$H_0:\mu_1\geq\mu_2\leftrightarrow H_1:\mu_1<\mu_2$			$\{T<t_{n+m-2}(\alpha)\}$

七、两样本均值已知时方差差异的检验见表7.8.

表7.8. 两样本均值已知时方差差异的检验。

假设检验	检验统计量	分布	拒绝域
$H_0:\sigma_1^2=\sigma_2^2\leftrightarrow H_1:\sigma_1^2\neq\sigma_2^2$	$T=\frac{\tilde{S}_1^2}{\tilde{S}_2^2}$	$F_{n,m}$	$\{T<F_{n,m}(\frac{\alpha}{2})\}\cup\{T>F_{n,m}(1-\frac{\alpha}{2})\}$
$H_0:\sigma_1^2=\sigma_2^2\leftrightarrow H_1:\sigma_1^2>\sigma_2^2$			$\{T>F_{n,m}(1-\alpha)\}$
$H_0:\sigma_1^2=\sigma_2^2\leftrightarrow H_1:\sigma_1^2<\sigma_2^2$			$\{T<F_{n,m}(\alpha)\}$
$H_0:\sigma_1^2\leq\sigma_2^2\leftrightarrow H_1:\sigma_1^2>\sigma_2^2$			$\{T>F_{n,m}(1-\alpha)\}$
$H_0:\sigma_1^2\geq\sigma_2^2\leftrightarrow H_1:\sigma_1^2<\sigma_2^2$			$\{T<F_{n,m}(\alpha)\}$

八、两样本均值未知时方差差异的检验见表7.9.

表7.9. 两样本均值未知时方差差异的检验。

假设检验	检验统计量	分布	拒绝域
$H_0:\sigma_1^2=\sigma_2^2 \leftrightarrow H_1:\sigma_1^2\neq\sigma_2^2$	$T=\frac{S_1^2}{S_2^2}$	$F_{n-1,m-1}$	$\{T<F_{n-1,m-1}(\frac{\alpha}{2})\}$ $\cup\{T>F_{n-1,m-1}(1-\frac{\alpha}{2})\}$
$H_0:\sigma_1^2=\sigma_2^2 \leftrightarrow H_1:\sigma_1^2>\sigma_2^2$			$\{T>F_{n-1,m-1}(1-\alpha)\}$
$H_0:\sigma_1^2=\sigma_2^2 \leftrightarrow H_1:\sigma_1^2<\sigma_2^2$			$\{T<F_{n-1,m-1}(\alpha)\}$
$H_0:\sigma_1^2\leq\sigma_2^2 \leftrightarrow H_1:\sigma_1^2>\sigma_2^2$			$\{T>F_{n-1,m-1}(1-\alpha)\}$
$H_0:\sigma_1^2\geq\sigma_2^2 \leftrightarrow H_1:\sigma_1^2<\sigma_2^2$			$\{T<F_{n-1,m-1}(\alpha)\}$

例7.3 某地区有甲、乙两种类型的耕地。为了解哪种类型耕地的小麦亩产量高，甲土地种植小麦50亩，乙土地种植小麦60亩。假设两种类型土地的播种量、施肥量、雨水量等外在条件都一样，甲土地平均亩产量是1000公斤，标准差为40公斤，乙土地平均亩产量是900公斤，标准差30公斤。假设两种类型土地的亩产量都服从正态分。试问在显著性水平为0.05 时，甲土地比乙土地的亩产量高吗？$(t_{108}(0.95)=1.659)$.

解：假设检验问题为

H_0 : 两种类型的土地亩产量一样 $\leftrightarrow$ H_1 : 甲土地比乙土地的亩产量高。

由于两种类型土地的播种量、施肥量、雨水量等外在条件都一样，可以认为两组数据的方差相等。针对甲土地，样本量$n=50$, 样本均值和样本方差分别为$\bar{X}=1000$和$S_1^2=40^2$. 针对乙土地，样本量$m=60$, 样本均值和样本方差分别为$\bar{Y}=900$和$S_2^2=30^2$. 记

$$S_0^2=\frac{1}{n+m-2}\left[(n-1)S_1^2+(m-1)S_2^2\right]=1217.593.$$

构造检验统计量

$$T=\frac{\bar{X}-\bar{Y}}{S_0\sqrt{\frac{1}{n}+\frac{1}{m}}}.$$

当H_0成立时，$T\sim t_{108}$. T的观测值为

$$\frac{1000-900}{\sqrt{1217.593}\times\sqrt{1/50+1/60}}=14.966.$$

给定显著性水平$\alpha=0.05$, $t_{108}(1-\alpha)=1.659$. 由于$14.966>1.659$, 因此，拒绝H_0, 认为甲土地比乙土地的亩产量高。

例7.4 某厂生产的一零件尺寸(单位：厘米)$X \sim N(\mu, 0.1)$，μ未知。从该厂生产的一批零件中随机抽取10个产品测得其尺寸(单位：厘米)分别为

$$5.2,\ 4.9,\ 5.1,\ 4.8,\ 5.5,\ 5.3,\ 4.7,\ 5.4,\ 4.8,\ 5.3.$$

问在显著性水平$\alpha = 0.05$下, 这批零件尺寸的方差是否过大?

解：假设检验问题为

$$H_0 : \sigma^2 = 0.1 \leftrightarrow H_1 : \sigma^2 > 0.1.$$

样本量$n = 10$, 样本均值为5.1，样本方差为$S^2 = 0.08$, 检验统计量为

$$T = \frac{(n-1)S^2}{\sigma_0^2}.$$

当H_0成立时，$T \sim \chi_9^2$. T的观测值为

$$\frac{9 \times 0.08}{0.1} = 7.2.$$

当显著性水平$\alpha = 0.05$时，$\chi_9^2(0.95) = 16.92$. 由于$7.2 < 16.92$, 不能拒绝零假设，认为这批零件的方差没有偏大。

7.2.3. 大样本检验

上面讨论的正态分布参数的假设检验都是精确检验，即统计量的分布是精确分布。然而在某些情况，检验统计量的精确分布很难得到，这时候我们可以利用中心极限定理构造检验统计量并得到它的渐近分布，称此类检验为大样本检验。下面以两样本方差未知且不等的正态分布均值差异的检验和指数分布参数的假设检验为例介绍大样本检验。

令$X_1, X_2, \cdots, X_n\ iid \sim N(\mu_1, \sigma_1^2)$, $Y_1, Y_2, \cdots, Y_m\ iid \sim N(\mu_2, \sigma_2^2)$, 两组样本相互独立，且$\sigma_1^2 \neq \sigma_2^2$未知. 考察如下假设检验问题

$$H_0 : \mu_1 = \mu_2 \leftrightarrow H_1 : \mu_1 \neq \mu_2.$$

记两组样本的样本均值分别为$\bar{X}$和$\bar{Y}$, 样本方差分别为S_1^2和S_2^2. 易知

$$T_1 = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}} \sim N(0, 1).$$

由于σ_1^2, σ_2^2未知，因此T_1不能作为检验统计量。另一方面

$$\frac{(n-1)S_1^2}{\sigma_1^2} \sim \chi_{n-1}^2,\ \ \frac{(m-1)S_2^2}{\sigma_2^2} \sim \chi_{m-1}^2.$$

$$T_2 = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}} \Bigg/ \sqrt{\frac{1}{n+m-2}\left[\frac{(n-1)S_1^2}{\sigma_1^2} + \frac{(m-1)S_2^2}{\sigma_2^2}\right]} \sim t_{n+m-1}.$$

由于T_2的分子分母的σ_1^2, σ_2^2消不掉，因此T_2也不能作为统计量。为此，基于中心极限定理和Slustky定理知

$$T = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{S_1^2}{n} + \frac{S_2^2}{m}}} \xrightarrow{d} N(0,1).$$

T可以作为检验统计量。由于它利用了中心极限定理，我们称这类检验为大样本检验。关于两样本均值差异的比较的检验问题，具体做法见表7.10.

表7.10. 两样本方差未知且不等时均值差异的检验。

假设检验	检验统计量	分布	拒绝域
$H_0: \mu_1 = \mu_2 \leftrightarrow H_1: \mu_1 \neq \mu_2$	$T = \frac{\bar{X}-\bar{Y}}{\sqrt{\frac{S_1^2}{n}+\frac{S_2^2}{m}}}$	$N(0,1)$	$\{\lvert T\rvert > u_{1-\alpha/2}\}$
$H_0: \mu_1 = \mu_2 \leftrightarrow H_1: \mu_1 > \mu_2$			$\{T > u_{1-\alpha}\}$
$H_0: \mu_1 = \mu_2 \leftrightarrow H_1: \mu_1 < \mu_2$			$\{T < u_{\alpha}\}$
$H_0: \mu_1 \leq \mu_2 \leftrightarrow H_1: \mu_1 > \mu_2$			$\{T > u_{1-\alpha}\}$
$H_0: \mu_1 \geq \mu_2 \leftrightarrow H_1: \mu_1 < \mu_2$			$\{T < u_{\alpha}\}$

关于指数分布参数的精确性检验见本章习题10和习题11.下面介绍指数分布的参数的大样本检验。指数分布常用来刻画电子元件等的寿命，然而，在元件寿命检验中，如果元件寿命比较长，就必须要等待很长时间才能结束试验，这显然耗时耗力，一个有效的方案是采取截尾寿命检验。它包括定数截尾试验和定时截尾试验。

定数截尾试验：一试验有n元件，在试验开始前指定一个正整数r, $r < n$. 试验开始后记第一个失效的元件的工作时间为Y_1，接着第二个失效的元件的工作时间为Y_2, 如此下去，直到有r个元件失效，试验结束，记第r个失效元件的工作时间为Y_r. 由于剩下的$n-r$个元件没有失效，这n个元件总的工作时间为

$$Q = Y_1 + Y_2 + \cdots + Y_r + (n-r)Y_r,$$

Q越大，元件的平均寿命就越长。可以证明(这里略之，可参见陈希孺《概率论与数理统计》第254 页习题15)：当参数真值为λ_0,

$$T = 2\lambda_0 Q \sim \chi^2_{2r}.$$

定时截尾试验：一试验有n元件，在试验开始前指定一个时刻t_0，试验进行到t_0时刻终止试验。记第i个元件的工作时间为Y_i, $i = 1, 2, \cdots, n$, 到时刻t_0已经失效的元件个数为k. 这n个元件总的工作时间为

$$Q = Y_1 + Y_2 + \cdots + Y_n.$$

Q越大，元件的平均寿命就越长。可以证明(这里略之)：当参数真值为λ_0,

$$2\lambda_0 Q \sim \chi^2_{2k+1}.$$

例7.5 令某厂生产的节能灯的使用寿命服从$Exp(1/6000)$。经过技术革新后，该厂生产出一批新的节能灯，从中取出20个节能灯来做实验，预定到第5个失效时试验停止，而测得前5 个灯的工作时间(单位：时)分别为：

$$6000, 6300, 6600, 6700, 6800.$$

问在显著性水平为0.05时, 技术革新后节能灯的平均寿命是否提高了？

解：这是个定数截尾试验。假设检验问题为

$$H_0 : \lambda \geq 1/6000 \leftrightarrow H_1 : \lambda < 1/6000.$$

备择假设意味着平均寿命比6000大。由题意知，$n = 20, r = 5$, 这20个节能灯总的工作时间为

$$Q = 6000 + 6300 + 6600 + 6700 + 6800 + 15 \times 6800 = 134400.$$

构造检验统计量

$$T = 2\lambda Q.$$

当H_0成立时，$T \sim \chi^2_{10}$. T的观测值为

$$2 \times 1/6000 \times 134400 = 44.8.$$

当$\alpha = 0.05$时，$\chi^2_{10}(0.95) \approx 18.307$, T值越大越有可能拒绝H_1, 故拒绝域为$\{T > 18.307\}$. 由于$44.8 > 18.307$, 在显著性水平为0.05时，拒绝H_0，认为技术革新后节能灯的平均寿命提高了。

7.3. 拟合优度检验

上一节介绍的检验是针对分布形式已知而参数未知时参数的假设检验。有时总体的分布形式未知，需要对总体分布进行检验，称这类问题为分布的假设检验。一个重要关于分布假设的检验是拟合优度检验，它主要用来检验一个组数据是否来自一个离散总体。

7.3.1. 离散分布的拟合优度检验

令$F_0(x)$是一个已知离散总体的分布函数。现有n个独立同分布的观测样本

$$X_1, X_2, \cdots, X_n.$$

不妨假定$X_1 \sim F(x)$. 假设检验问题为

$$H_0: \ F(x) = F_0(x), x \in \mathcal{R} \leftrightarrow H_1: \exists\, x \in \mathcal{R} \text{ 使得 } F(x) \neq F_0(x).$$

当样本量n比较大时，Karl·Pearson于1900年提出了χ^2拟合优度检验。下面针对$F_0(x)$包含及不包含未知参数这两种情况，分别进行讨论。

(1)概率函数不含未知参数

首先考虑$F_0(x)$不包含有未知参数时的情形。令$F_0(x)$的概率函数为

$$p_j = P(X_1 = a_j), j = 1, 2, \cdots, k.$$

记$n_j = \sum_{i=1}^{n} I_{\{X_i = a_j\}}, j = 1, 2, \cdots, k.$ a_j的观测频数n_j和期望频数np_j如下表所示。

取值	a_1	a_2	$\cdots$	a_k
理论频数	np_1	np_2	$\cdots$	np_k
观测频数	n_1	n_2	$\cdots$	n_k

由大数定律知，当H_0成立时，n_j/n依概率收敛于p_j, $j = 1, 2, \cdots, k$, 故理论频数np_j与观测频数n_j接近。当H_1成立时，n_j/n不依概率收到p_j, $j = 1, 2, \cdots, k$, 故理论频数np_j与观测频数n_j距离较大。检验统计量为

$$T = \sum_{j=1}^{k} \frac{(n_j - np_j)^2}{np_j}.$$

当H_0成立时，可以证明(具体细节略之),

$$T \xrightarrow{d} \chi^2_{k-1}.$$

称该检验方法为**拟合优度检验**。

这个统计量中的每项分母的选取可以这样粗略的解释: 由于n_j取非负整数，假设n_j服从Poisson分布，则n_j的均值和方差均为np_j, 从而$(n_j - np_j)/\sqrt{np_j}$的极

限分布为标准正态分布。T近似表示为k个服从自由度为1的χ_1^2分布的随机变量之和，又$\sum_{j=1}^{k}(n_j - np_j) = 0$, 故这$k$个随机变量满足一个约束，减少了一个自由度，从而$T$ 的自由度为$k-1$. 下面以$k=2$为例来证明。在H_0成立时，$n_1 \sim B(n, p_1)$, $n_2 \sim B(n, p_2)$, 且$p_1 + p_2 = 1$. 因此，

$$\begin{aligned} T &= \frac{(n_1 - np_1)^2}{np_1} + \frac{(n_2 - np_2)^2}{np_2} \\ &= \frac{(n_1 - np_1)^2}{np_1} + \frac{[n - n_1 - n(1-p_1)]^2}{n(1-p_1)} \\ &= \frac{(n_1 - np_1)^2}{np_1} + \frac{(n_1 - np_1)^2}{n(1-p_1)} \\ &= \frac{(n_1 - np_1)^2}{np_1(1-p_1)}. \end{aligned}$$

由中心极限定理知：$\dfrac{(n_1 - np_1)}{\sqrt{np_1(1-p_1)}} \xrightarrow{d} N(0,1)$. 所以

$$T = \frac{(n_1 - np_1)^2}{np_1(1-p_1)} \xrightarrow{d} \chi_1^2.$$

例7.6 考察某大学一专业连续四年的招生人数是否规模相当。从该大学此专业在校学生中随机抽取600 名，发现大一学生150名、大二学生165人，大三学生145 人，大四学生140人。问各年级的学生数是否服从离散均匀分布？

解：由于有大学有四个年级，记随机变量X服从离散均匀分布，概率函数

$$P(X = i) = \frac{1}{4},\ i = 1, 2, 3, 4.$$

假设检验问题是

$$H_0 \text{:数据来自上述分布} \leftrightarrow H_1 \text{:数据不来自上述分布。}$$

观测的频数分别为：150, 165, 145, 140. 当H_0成立时，期望频数都是$600 \times 1/4 = 150$. 检验统计量的观测值为

$$T = \frac{(150-150)^2}{150} + \frac{(165-150)^2}{150} + \frac{(145-150)^2}{150} + \frac{(140-150)^2}{150} = 2.33.$$

当$\alpha = 0.05$时，$\chi_3^2(0.95) = 7.815$. 由于$2.33 < 7.815$, 故在显著性水平0.05 下，接受H_0，认为这四个年级的学生数服从离散均匀分布。

(2)概率函数含有若干未知参数

令分布函数$F_0(x)$的概率函数为

$$P(X = a_j) = p_j(\theta_1, \theta_2, \cdots, \theta_r), j = 1, 2, \cdots, k,$$

其中$\theta_1, \theta_2, \cdots, \theta_r$是未知的，$r < k$.

当H_0成立时，记$(\theta_1, \theta_2, \cdots, \theta_r)$的极大似然估计为$(\hat{\theta}_1, \hat{\theta}_2, \cdots, \hat{\theta}_r)$. 根据极大似然估计的不变性，当$H_0$成立时，$p_j$的极大似然估计为

$$\hat{p}_j = \hat{p}_j(\hat{\theta}_1, \hat{\theta}_2, \cdots, \hat{\theta}_r), j = 1, 2, \cdots, k.$$

构造检验统计量

$$T = \sum_{j=1}^{k} \frac{(n_j - n\hat{p}_j)^2}{n\hat{p}_j}.$$

当H_0成立时，$T \xrightarrow{d} \chi^2_{k-r-1}$, 其中$r$是未知参数的个数。自由度个数可以这么理解：共$k$个自由度，求$\theta_1, \theta_2, \cdots, \theta_r$ 的极大似然估计，需要r个方程，即有r个约束，减少了r个自由度，约束$\sum_{j=1}^{k} \hat{p}_j = 1$又减少了1 个自由度，剩下$k-1-r$个自由度。

例7.7 从某人群中随机抽取100个人，考察他们在某等位基因位点处的基因型。假设该等位基因位点只有两个等位基因g和G. 这100个人中，该位点的基因型gg, Gg和GG的人数分别为48, 42和10. 问能否在0.05的显著性水平下认为该群体在此位点处达到Hardy-Weinberg平衡？

解： 记$p = P(\mathrm{G})$. 当该位点的基因型达到Hardy-Weinberg平衡时，

$$P(\mathrm{GG}) = p^2, P(\mathrm{Gg}) = 2p(1-p), P(\mathrm{gg}) = (1-p)^2.$$

假设检验问题是

$H_0 : P(\mathrm{GG}) = p^2, P(\mathrm{Gg}) = 2p(1-p), P(\mathrm{gg}) = (1-p)^2 \leftrightarrow H_1$: 至少有一个等式不成立。

当H_0成立时, p的极大似然估计是

$$\hat{p} = \frac{42 + 20}{100 \times 2} = 0.31.$$

3种基因型gg, Gg和GG的期望频数分别为

$$\begin{aligned} 100 \times (1 - 0.31)^2 &= 47.61, \\ 100 \times 2 \times 0.31 \times (1 - 0.31) &= 42.78, \\ 100 \times 0.31^2 &= 9.61. \end{aligned}$$

检验统计量的值为

$$T = \frac{(48 - 47.61)^2}{47.61} + \frac{(42 - 42.78)^2}{42.78} + \frac{(10 - 9.61)^2}{9.61} = 0.0332.$$

当$\alpha = 0.05$时，$\chi^2_1(1-\alpha) = 3.84$. 由于$0.0332 < 3.84$, 故可在0.05 的显著性水平下认为该位点的基因型达到了Hardy-Weinberg平衡。

7.3.2. 属性数据列联表的独立性检验

设有两个属性：A, B. 属性A有k个水平：$a_1, a_2, \cdots, a_k$, 属性B有m个水平：$b_1, b_2, \cdots, b_m$. 现有样本量为n的观测数据, 属性A有水平a_i且属性B有水平b_j的频数为n_{ij}, $i = 1, 2, \cdots, k, j = 1, 2, \cdots, m$. 数据如下述列联表所示。

$A\backslash B$	b_1	b_2	$\cdots$	b_m	行和
a_1	n_{11}	n_{12}	$\cdots$	n_{1m}	$n_{1\cdot}$
a_2	n_{11}	n_{12}	$\cdots$	n_{1m}	$n_{1\cdot}$
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
a_k	n_{k1}	n_{k2}	$\cdots$	n_{km}	$n_{k\cdot}$
列和	$n_{\cdot 1}$	$n_{\cdot 2}$	$\cdots$	$n_{\cdot m}$	n

考察A和B这两个属性是否独立，即是列联表的独立性检验问题(检验行列对应的随机变量是否独立)。假设检验问题为：

$$H_0: \text{属性}A\text{与属性}B\text{独立} \leftrightarrow H_1: \text{属性}A\text{与属性}B\text{不独立}$$

记

$$u_i = P(\text{属性}A\text{有水平}a_i), i = 1, 2, \cdots, k,$$

$$v_j = P(\text{属性}B\text{有水平}b_j), j = 1, 2, \cdots, m.$$

当H_0成立时，

$$P(\text{属性}A\text{有水平}a_i, \text{属性}B\text{有水平}b_j) = u_i v_j, i = 1, 2, \cdots, k, j = 1, 2, \cdots, m.$$

由题意可得u_i和v_j的极大似然估计为

$$\hat{u}_i = \frac{n_{i\cdot}}{n}, \hat{v}_j = \frac{n_{\cdot j}}{n},$$

属性A有水平a_i且属性B有水平b_j的观测频数为n_{ij}, H_0成立时的期望频数为$n_{i\cdot}n_{\cdot j}/n$. 故检验统计量取为

$$T = \sum_{i=1}^{k}\sum_{j=1}^{m}\frac{(n_{ij} - n_{i\cdot}n_{\cdot j}/n)^2}{n_{i\cdot}n_{\cdot j}/n}$$

当H_0成立时，可以证明(这里略之)

$$T \xrightarrow{d} \chi^2_{(k-1)(m-1)}.$$

自由度可以这么计算：总共km个自由度，求解$u_1, u_2, \cdots, u_k$的极大似然估计需要$k-1$个方程(因为$u_1 + u_2 + \cdots + u_k = 1$)，减少$k-1$个自由度，求解$v_1, v_2, \cdots, v_m$的极大似然估计需要$m-1$个方程，减少了$m-1$个自由度，又因为零假设成立时，

$$\sum_{i=1}^{k}\sum_{j=1}^{m}\frac{n_{i\cdot}n_{\cdot j}}{n^2} = 1$$

减少了一个自由度，剩余的自由度为$km-(k-1)-(m-1)-1=(k-1)(m-1)$.

例7.8 考察基因Q与胰腺癌之间的关联。设基因Q有三种基因型：gg, Gg和GG. 从某地区胰腺癌患者中随机抽取200人，发现具有基因型gg, Gg 和GG的人数分别为43, 102和55. 从该地区健康人群中随机抽取200人，发现具有基因型gg, Gg和GG的人数分别为：72, 96和32. 数据如下表所示。问在显著性水平0.05下，基因Q与胰腺癌独立吗？

	gg	Gg	GG	行和
胰腺癌	43	102	55	200
健康	72	96	32	200
行和	115	198	87	400

解：这是一个2×3的列联表。独立性检验统计量为

$$\begin{aligned} T &= \frac{(43-200\times 115/400)^2}{200\times 115/400}+\frac{(102-198\times 200/400)^2}{198\times 200/400}+\frac{(55-87\times 200/400)^2}{87\times 200/400} \\ &= \frac{(72-200\times 115/400)^2}{200\times 115/400}+\frac{(96-198\times 200/400)^2}{198\times 200/400}+\frac{(32-87\times 200/400)^2}{87\times 200/400} \\ &= 13.575. \end{aligned}$$

由于$\chi^2(1-0.05)=3.84$, $13.575>3.84$, 认为基因Q与胰腺癌不独立。

与列联表有关的另一类重要的检验是**齐一性检验**，即检验q个总体是否有相同的分布。比如，检验不同医院得肝癌患者的死亡率是否一样。这种检验跟独立性检验有着本质的区别。独立性问题中两属性都是随机的。而齐一性检验问题只有一个属性是非随机的，涉及到的分布实际上是条件分布。尽管如此, 所采用的方法跟独立性检验完全一样。

7.3.3. Fisher精确检验

针对$k\times m$的列联表的独立性检验，当$n_{\min}=\min\{n_{ij}, i=1,2,\cdots,k, j=1,2,\cdots,m\}$ 比较大时，比如$n_{\min}\geq 5$，可以利用列联表的卡方检验。然而，当$n_{\min}$比较小时，独立性检验方法不再适用。下面将介绍处理$n_{\min}$比较小时的Fisher精确检验，以2×2的列联表为例，数据见下表。

$A\backslash B$	b_1	b_2	行和
a_1	a	b	$a+b$
a_2	c	d	$c+d$
列和	$a+c$	$b+d$	n

给定行和$a+b, c+d$, 列和$a+c, b+d$时，这个四格表就剩下一个自由度，以a为例，一旦a确定了，其它三个格子的数字都确定了。令随机变量X为属性A有水平a_1且属性B有水平b_1的数目，显然$X\sim HG(a+c,n,a+b)$, 即

$$P(X=k)=\frac{\binom{a+b}{k}\binom{n-(a+b)}{a+c-k}}{\binom{n}{a+c}}=\frac{\binom{a+b}{k}\binom{c+d}{a+c-k}}{\binom{n}{a+c}}.$$

X的观测值是a, 检验p-值就是这个列联表给定行和、列和的条件下比观测到$X=a$的更小的概率和(包括$P(X=a)$)

$$p\text{-值} = \sum_{k=0}^{\min\{a+c,a+b\}} P(X=k) I_{\{P(X=k)\le P(X=a)\}}.$$

例7.9 考察某地区吸烟和肺癌之间的关联。现从该地区人群中的吸烟者随机抽取1000人，发现患肺癌者20人；从不吸烟者随机抽取2000人，发现患肺癌者2人，数据如下表所示。问在显著性水平0.05，吸烟和肺癌是否独立？

	肺癌	健康	和
不吸烟	2	1998	2000
吸烟	20	980	1000
和	22	2978	3000

解：由于表格中最小的频数是2，列联表的卡方检验不是很适合了。下面我们采用Fisher精确性检验。令X为给定行和与列和，不吸烟得肺癌的人数。那么，观测数据的概率为：

$$P(X=2) = \frac{\binom{2000}{2}\binom{1000}{20}}{\binom{3000}{22}} = 2.625732 \times 10^{-8}.$$

另一方面，

$$\begin{aligned} P(X=0) &= 2.728 \times 10^{-11}, \\ P(X=1) &= 1.226 \times 10^{-9}, \\ P(X=2) &= 2.626 \times 10^{-8}, \\ P(X=20) &= 0.00757, \\ P(X=21) &= 0.00143, \\ P(X=22) &= 0.000129. \end{aligned}$$

p-值为

$$\begin{aligned} p\text{-值} &= \sum_{k=0}^{22} P(X=k) I_{\{P(X=k)\le P(X=2)\}} \\ &= P(X=0)+P(X=1)+P(X=2) \\ &= 2.728 \times 10^{-11} + 1.226 \times 10^{-9} + 2.6256 \times 10^{-8} \\ &= 2.75 \times 10^{-8}. \end{aligned}$$

由于$2.75 \times 10^{-8} \ll 0.05$, 认为吸烟和肺癌不独立。

7.4. 非参数检验

本节将介绍两种检验方法：Kolmogorov-Smirnov检验和Mann-Whitney检验。前一个检验是度量一组数据是否来自一个连续总体，后一个检验是检验两个总体的分布是否相同。这两个检验分别基于经验分布和样本秩构造检验统计量，对总体的分布不作任何要求，不牵涉到任何参数，称它们为**非参数检验**。

7.4.1 Kolmogorov-Smirnov检验

Kolmogorov-Smirnov检验从经验分布的角度出发，判断某一组观察样本的分布是否与某一连续型随机变量的理论分布相同。

令$F_0(x), x \in \mathcal{R}$为已知的连续型随机变量的分布函数, $F(x), x \in \mathcal{R}$为观测数据的分布函数。假设检验问题为

$$H_0 : F(x) = F_0(x), x \in \mathcal{R} \leftrightarrow H_1 : \exists\, x \in \mathcal{R}\text{使得}F(x) \neq F_0(x).$$

记$X_1, X_2, \cdots, X_n$为简单随机样本，$F_n(x)$ 为其经验分布函数。由第五章定理5.1知，

$$P\left(\lim_{n\to\infty}\Big[\sup_{-\infty<x<\infty}|F_n(x) - F(x)|\Big] = 0\right) = 1$$

Kolmogorov-Smirnov检验统计量为

$$T = \sup_{-\infty<x<\infty}|F_n(x) - F_0(x)|.$$

下面计算T. 记$X_1, X_2, \cdots, X_n$的次序统计量为$X_{(1)}, X_{(2)}, \cdots, X_{(n)}$(从小到大)，则

$$\begin{aligned} T \;=\; \max\Big\{ & F_0(X_{(1)}), |\tfrac{1}{n} - F_0(X_{(1)})|, \\ & |\tfrac{1}{n} - F_0(X_{(2)})|, |\tfrac{2}{n} - F_0(X_{(2)})|, \\ & \cdots, \\ & |\tfrac{n-2}{n} - F_0(X_{(n-1)})|, |\tfrac{n-1}{n} - F_0(X_{(n-1)})|, \\ & |\tfrac{n-1}{n} - F_0(X_{(n)})|, |1 - F_0(X_{(n)})|\Big\}. \end{aligned}$$

当H_0成立时，

$$\lim_{n\to\infty} P\left(T < \frac{\lambda}{\sqrt{n}}\right) = 1 - 2\sum_{k=1}^{\infty}(-1)^{k-1}e^{-2k^2\lambda^2}, \lambda > 0$$

T大时拒绝零假设。

7.4.2. Mann-Whitney检验

前面介绍的都是检验观测到的样本是否服从一个已知的分布，下面我们将介绍如何检验两组样本具有相同的分布。设有两组简单随机样本$X_1, X_2, \cdots, X_n$和$Y_1, Y_2, \cdots, Y_m$, 且两组样本相互独立。记第一组样本对应总体的分布函数

为$F(x)$, 即$X_1, X_2, \cdots, X_n$ $iid \sim F(x)$; 第二组样本对应总体的分布函数为$G(x)$, 即$Y_1, Y_2, \cdots, Y_m$ $iid \sim G(x)$. 假设检验问题为

$$H_0 : F(x) = G(x), x \in \mathcal{R} \leftrightarrow H_1 : \exists x \in \mathcal{R}\text{使得} F(x) \neq G(x).$$

Mann-Whitney检验统计量为

$$T = \frac{1}{n}\frac{1}{m}\sum_{i=1}^{n}\sum_{j=1}^{m} I_{\{X_i<Y_j\}}.$$

如果$F(x) = G(x)$, T的值应该在0.5附近. 显然T越大或越小，拒绝H_0. 当H_0成立时，

$$P(X < Y) = \int_{-\infty}^{\infty} F(u)dG(u) = \int_0^1 udu = 0.5.$$

对任意$i = 1, 2, \cdots, n, j = 1, 2, \cdots, m$,

$$E_{H_0} I_{\{X_i<Y_j\}} = P(X_i < Y_j) = 0.5.$$

由第四章第1节数学期望的性质1，知

$$ET = E\left(\frac{1}{nm}\sum_{i=1}^{n}\sum_{j=1}^{m} I_{\{X_i<Y_j\}}\right) = \frac{1}{2}.$$

下面计算H_0成立时，T的方差。易知

$$\text{var}(I_{\{X_1<Y_1\}}) = EI^2_{\{X_1<Y_1\}} - \left(EI_{\{X_1<Y_1\}}\right)^2 = \frac{1}{4},$$

$$\begin{aligned}
\text{cov}(I_{\{X_1<Y_1\}}, I_{\{X_1<Y_2\}}) &= E(I_{\{X_1<Y_1\}} - 0.5)(I_{\{X_1<Y_2\}} - 0.5) \\
&= EI_{\{X_1<Y_1\}}I_{\{X_1<Y_2\}} - \tfrac{1}{4} \\
&= \int_{-\infty}^{\infty}\int_{x}^{\infty}\int_{x}^{\infty} f(y_1)f(y_2)dy_1dy_2dF(x) - \frac{1}{4} \\
&= \int_{-\infty}^{\infty}[1 - F(x)]^2 dF(x) - \frac{1}{4} \\
&= \int_0^1 (1-t)^2 dt - \frac{1}{4} \\
&= \frac{1}{12}.
\end{aligned}$$

$$
\begin{aligned}
\mathrm{var}_{H_0}(T) &= E\Big[\frac{1}{nm}\sum_{i=1}^{n}\sum_{j=1}^{m} I_{\{X_i<Y_j\}} - 0.5\Big]^2 \\
&= \frac{1}{n^2m^2}E\Big[\sum_{i=1}^{n}\sum_{j=1}^{m}\big(I_{\{X_i<Y_j\}} - 0.5\big)\Big]^2 \\
&= \frac{1}{n^2m^2}E\left(\sum_{i=1}^{n}\sum_{j=1}^{m}\big(I_{\{X_i<Y_j\}} - 0.5\big)^2 + \sum_{i=1}^{n}\sum_{j=1}^{m}\sum_{k=1,k\neq j}^{m}\big(I_{\{X_i<Y_j\}} - 0.5\big)\big(I_{\{X_i<Y_k\}} - 0.5\big)\right. \\
&\quad \left. + \sum_{i=1}^{n}\sum_{l=1,l\neq i}^{n}\sum_{j=1}^{m}\big(I_{\{X_i<Y_j\}} - 0.5\big)\big(I_{\{X_i<Y_j\}} - 0.5\big)\right) \\
&= \frac{1}{n^2m^2}\left(\sum_{i=1}^{n}\sum_{j=1}^{m}\frac{1}{4} + \sum_{i=1}^{n}\sum_{j=1}^{m}\sum_{k=1,k\neq j}^{m}\frac{1}{12} + \sum_{i=1}^{n}\sum_{l=1,l\neq i}^{n}\sum_{j=1}^{m}\frac{1}{12}\right) \\
&= \frac{1}{n^2m^2}\left(\frac{1}{4}nm + \frac{1}{12}nm(m-1) + \frac{1}{12}n(n-1)m\right) \\
&= \frac{n+m+1}{12nm}.
\end{aligned}
$$

可以证明(这里略之)：

$$\frac{\sqrt{12nm}(T-0.5)}{\sqrt{n+m+1}} \xrightarrow{d} N(0,1).$$

给定显著性水平α, $0<\alpha<1$, 当$\left|\frac{\sqrt{12nm}(T-0.5)}{\sqrt{n+m+1}}\right| > u_{1-\alpha/2}$ 时，拒绝零假设，否则接受零假设。

例7.10 考察吃饭前后的血糖(单位：毫摩尔每升)的分布是否一致。随机抽取20个人，其中10个人空腹的血糖值为

$$4.65,\ 4.21,\ 3.92,\ 5.33,\ 4.84,\ 5.95,\ 4.22,\ 4.56,\ 4.12,\ 5.35.$$

另外10个人吃完饭后两小时内的血糖值为

$$5.81,\ 5.23,\ 6.84,\ 7.34,\ 6.85,\ 5.91,\ 8.23,\ 6.54,\ 5.99,\ 6.36.$$

问：在显著性水平0.05下，吃饭前后血糖的分布相同吗？

解：假设检验问题为

$$H_0: \text{两组数据的分布相同} \leftrightarrow H_1: \text{两组数据的分布不同。}$$

构造统计量

$$T = \frac{1}{100}(10+10+10+9+10+7+10+10+10+9) = 0.95.$$

检验统计量的值为

$$\frac{\sqrt{1200}(0.95-0.5)}{\sqrt{21}} \approx 3.4.$$

由于$3.4 > u_{1-0.05/2} = 1.96$, 拒绝$H_0$, 认为吃饭前后血糖的分布不同。

7.5. 三大检验

本节将介绍常用的三类检验统计量：似然比检验、Wald检验和得分检验统计量。这三类检验在假设检验中占有十分重要的地位，第7.2节介绍的重要参数检验中的很多检验统计量都是基于这三类检验中的一类构造的。

1. 似然比检验统计量

似然比检验统计量是1928年Neyman和Egon·Pearson提出的。令总体的密度函数为$f(x,\theta),\theta\in\Theta$, Θ是个开区间。$X_1,X_2,\cdots,X_n\ iid\sim f(x,\theta)$. 假设检验问题为

$$H_0:\theta\in\Theta_0\leftrightarrow H_1:\theta\in\Theta_1.$$

似然函数为

$$L(\theta)=\prod_{i=1}^{n}f(X_i,\theta).$$

记$\hat{\theta}$是在H_1成立时θ的极大似然估计，$\tilde{\theta}$是H_0成立时θ的极大似然估计。似然比检验统计量为

$$T=2\ln\frac{\prod\limits_{i=1}^{n}f(X_i,\hat{\theta})}{\prod\limits_{i=1}^{n}f(X_i,\tilde{\theta})},$$

在一定的条件下(极大似然估计渐近正态性需要的条件)，当H_0成立时，

$$T\xrightarrow{d}\chi^2_k,$$

其中k是H_1成立时参数空间的维数减去H_0成立时参数空间的维数。

例7.11 令$X_1,X_2,\cdots,X_n\ iid\sim N(\mu,\sigma^2)$, μ和σ^2都未知。求假设检验问题

$$H_0:\mu=\mu_0\leftrightarrow H_1:\mu\neq\mu_0$$

的似然比检验统计量。

解：似然函数为

$$L(\mu,\sigma^2)=\prod_{i=1}^{n}\frac{1}{(2\pi)^{\frac{n}{2}}(\sigma^2)^{\frac{n}{2}}}\exp\left(-\frac{(X_i-\mu)^2}{2\sigma^2}\right).$$

对数似然函数为

$$l(\mu,\sigma^2)=-\frac{n}{2}\ln(2\pi)-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(X_i-\mu)^2-\frac{n}{2}\ln\sigma^2.$$

μ,σ^2的极大似然估计为

$$\hat{\mu}=\bar{X},\ \hat{\sigma}^2=\frac{1}{n}\sum_{i=1}^{n}(X_i-\bar{X})^2.$$

当H_0成立时，即$\mu=\mu_0$, σ^2的极大似然估计为

$$\tilde{\sigma}^2=\frac{1}{n}\sum_{i=1}^{n}(X_i-\mu_0)^2.$$

似然比检验统计量为：

$$\begin{aligned}
T &= 2\left\{\frac{n}{2}\ln\sum_{i=1}^{n}(X_i-\mu_0)^2-\frac{n}{2}\ln\sum_{i=1}^{n}(X_i-\bar{X})^2\right\}\\
&= n\ln\frac{\sum_{i=1}^{n}(X_i-\mu_0)^2}{\sum_{i=1}^{n}(X_i-\bar{X})^2}\\
&= n\ln\frac{\sum_{i=1}^{n}(X_i-\bar{X})^2+n(\bar{X}-\mu_0)^2}{\sum_{i=1}^{n}(X_i-\bar{X})^2}\\
&= n\ln\Big(1+\frac{n(\bar{X}-\mu_0)^2}{\sum_{i=1}^{n}(X_i-\bar{X})^2}\Big)\\
&= n\ln\Big(1+\frac{1}{n-1}\Big(\frac{\sqrt{n}(\bar{X}-\mu_0)}{S}\Big)^2\Big).
\end{aligned}$$

$\frac{\sqrt{n}(\bar{X}-\mu_0)}{S}$ 是单样本正态均值的t检验统计量，$\ln(\cdot)$是单调增函数。可见似然比统计量是单样本正态均值的t 统计量的严格增函数，因此两个检验统计量等价。

2. Wald检验统计量

令总体的密度函数为$f(x,\theta),\theta\in\Theta$, Θ是个开区间，参数真值θ_0是Θ的一个内点。记X_1, X_2, $\cdots$, X_n $iid\sim f(x,\theta)$, $\hat{\theta}$是θ的极大似然估计。假设检验问题为

$$H_0:\theta=\theta_0\leftrightarrow H_1:\theta\neq\theta_0.$$

由极大似然估计的渐近正态性知

$$\sqrt{n}(\hat{\theta}-\theta_0)\xrightarrow{d}N\big(0,I^{-1}(\theta_0)\big).$$

由于θ_0是未知的，我们用其极大似然估计$\hat{\theta}$代替，进而构造Wald检验统计量

$$T=\frac{\sqrt{n}(\hat{\theta}-\theta_0)}{\sqrt{I^{-1}(\hat{\theta})}}.$$

当H_0成立时，

$$T\xrightarrow{d}N(0,1).$$

3. 得分检验统计量

得分检验统计量是由Rao于1948年提出的，它的构造基础是得分函数。令总体的密度函数为$f(x,\theta),\theta\in\Theta$, Θ是个开区间，参数真值θ_0是Θ的一个内点。假设检验问题为

$$H_0:\theta=\theta_0\leftrightarrow H_1:\theta\neq\theta_0.$$

似然函数为

$$l(\theta)=\prod_{i=1}^{n}f(X_i,\theta).$$

对数似然函数为

$$l(\theta)=\sum_{i=1}^{n}\ln f(X_i,\theta).$$

记样本得分函数为

$$\xi=\xi(X_1,X_2,\cdots,X_n,\theta)=\frac{1}{n}\frac{\partial l}{\partial\theta}=\frac{1}{n}\sum_{i=1}^{n}\frac{f'(X_i,\theta)}{f(X_i,\theta)}.$$

$$\mathrm{var}(\xi)=\frac{1}{n}\mathrm{var}\left(\frac{f'(X_1,\theta)}{f(X_1,\theta)}\right)=\frac{1}{n}I(\theta).$$

得分检验统计量

$$T=\frac{\sqrt{n}\xi(X_1,X_2,\cdots,X_n,\theta)|_{\theta_0}}{\sqrt{I(\theta_0)}}.$$

当H_0成立时，

$$T\xrightarrow{d}N(0,1).$$

例7.11. 令$X_1,X_2,\cdots,X_n\ iid\sim Poisson(\lambda)$. 假设检验问题为

$$H_0:\lambda=\lambda_0\longleftrightarrow H_1:\lambda\neq\lambda_0.$$

试构造似然比检验、Wald检验以及得分检验统计量。

解： 记$f(x,\lambda)=\frac{\lambda^x e^{-\lambda}}{x!},x=0,1,2,\cdots$. 样本均值为$\bar{X}$.
似然函数为

$$L(\lambda)=\prod_{i=1}^{n}\frac{\lambda^{X_i}}{X_i!}e^{-\lambda}=e^{-n\lambda}\lambda^{n\bar{X}}\Big/\prod_{i=1}^{n}X_i!,$$

λ的极大似然估计是$\hat{\lambda}=\bar{X}$.
(1)似然比检验统计量为

$$\begin{aligned}T_1&=2\ln\frac{L(\hat{\lambda})}{L(\lambda_0)}\\&=2\ln\Big[e^{-n(\bar{X}-\lambda_0)}\big(\frac{\bar{X}}{\lambda_0}\big)^{n\bar{X}}\Big]\\&=2n\big[\bar{X}\ln\bar{X}-\bar{X}\ln\lambda_0-(\bar{X}-\lambda_0)\big].\end{aligned}$$

当H_0成立时，

$$T_1\xrightarrow{d}\chi_1^2.$$

下面计算Fisher信息量。

$$\begin{aligned} I(\lambda) &= E\left(\frac{\partial \ln f(X,\lambda)}{\partial \lambda}\right)^2 \\ &= E\left(\frac{\partial \ln \frac{\lambda^{X_1} e^{-\lambda}}{X_1!}}{\partial \lambda}\right)^2 \\ &= E\left(\frac{\partial (X_1 \ln \lambda - \lambda - \ln X_1!)}{\partial \lambda}\right)^2 \\ &= E\left(\frac{X_1}{\lambda} - 1\right)^2 \\ &= E\left(\frac{X_1^2}{\lambda^2} - \frac{2X_1}{\lambda} + 1\right) \\ &= \frac{\lambda+\lambda^2}{\lambda^2} - \frac{2\lambda}{\lambda} + 1 \\ &= 1/\lambda. \end{aligned}$$

由极大似然估计的渐近正态性有

$$\sqrt{n}(\hat{\lambda} - \lambda) \xrightarrow{d} N\big(0, \lambda\big).$$

(2)Wald检验统计量为

$$T_2 = \frac{\sqrt{n}(\hat{\lambda} - \lambda_0)}{\hat{\lambda}} = \frac{\sqrt{n}(\bar{X} - \lambda_0)}{\sqrt{\bar{X}}},$$

当H_0成立时，

$$T_2 \xrightarrow{d} N(0,1).$$

(3)样本得分函数为

$$\begin{aligned} \xi(\lambda) &= \frac{1}{n}\sum_{i=1}^{n} \frac{\partial \ln f(X_i,\lambda)}{\partial \lambda} \\ &= \frac{1}{n}\sum_{i=1}^{n} \Big(\frac{X_i}{\lambda} - 1\Big) \\ &= \frac{\bar{X}}{\lambda} - 1. \end{aligned}$$

得分检验统计量为

$$T_3 = \frac{\sqrt{n}\xi(\lambda)|_{\lambda_0}}{\sqrt{I(\lambda)|_{\lambda_0}}} = \frac{\sqrt{n}(\bar{X}/\lambda_0 - 1)}{\sqrt{1/\lambda_0}} = \frac{\sqrt{n}(\bar{X} - \lambda_0)}{\sqrt{\lambda_0}}.$$

当H_0成立时，

$$T_3 \xrightarrow{d} N(0,1).$$

7.6. 假设检验与区间估计之间的关系

假设检验和区间估计有着密切的关系，假设检验中的检验统计量和区间估计中的枢轴量一般是相同的。直观上说，一致最优势检验对应着待检验参数的最优的区间估计，即相同的置信水平下，区间长度最短。下面以正态分布参数的假设检验为例说明了两者之间的关系。

令$X_1, X_2, \cdots, X_n$ $iid \sim N(\mu, \sigma^2)$，显著性水平为$\alpha$. 考察假设检验问题

$$H_0 : \mu = \mu_0 \leftrightarrow H_1 : \mu \neq \mu_0,$$

和μ的置信水平为$1-\alpha$的置信区间。

记

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i, S^2 = \frac{1}{n}\sum_{i=1}^{n-1}(X_i - \bar{X})^2.$$

检验统计量为

$$\frac{\sqrt{n}(\bar{X} - \mu_0)}{S} \sim t_{n-1}.$$

拒绝域为

$$W = \left\{ (X_1, X_2, \cdots, X_n) \middle| \left| \frac{\sqrt{n}(\bar{X} - \mu_0)}{S} \right| > t_{n-1}(1-\alpha/2) \right\}.$$

接受域为

$$A = \left\{ (X_1, X_2, \cdots, X_n) \middle| \left| \frac{\sqrt{n}(\bar{X} - \mu_0)}{S} \right| \leq t_{n-1}(1-\alpha/2) \right\}.$$

当H_0成立时，$P(A) = 1-\alpha$. 因此，当H_0成立时，

$$P\Big(\mu_0 \in [\bar{X} - St_{n-1}(1-\alpha/2)/\sqrt{n}, \bar{X} + St_{n-1}(1-\alpha/2)/\sqrt{n}]\Big) = 1-\alpha.$$

下面我们构造区间估计。考察上述假设检验的接受域，由于μ_0的任意性，因此上述接受域即是μ的置信水平为$1-\alpha$的区间估计。

类似地，我们可以给出假设检验与置信上下界的关系。以置信下界为例。令$X_1, X_2, \cdots, X_n$ $iid \sim N(\mu, \sigma^2)$, 显著性水平为$\alpha$. 考察假设检验问题

$$H_0 : \mu = \mu_0 \leftrightarrow H_1 : \mu > \mu_0,$$

和μ的置信水平为$1-\alpha$的置信下界。

检验统计量为

$$\frac{\sqrt{n}(\bar{X} - \mu_0)}{S} \sim t_{n-1}.$$

拒绝域为

$$W = \left\{ (X_1, X_2, \cdots, X_n) \middle| \frac{\sqrt{n}(\bar{X} - \mu_0)}{S} > t_{n-1}(1-\alpha) \right\}.$$

接受域为

$$A=\left\{(X_1,X_2,\cdots,X_n)\middle|\frac{\sqrt{n}(\bar{X}-\mu_0)}{S}\leq t_{n-1}(1-\alpha)\right\}.$$

当H_0成立时，$P(A)=1-\alpha$. 因此，当H_0成立时，

$$P\Big(\mu_0\in[\bar{X}-St_{n-1}(1-\alpha)/\sqrt{n},\infty]\Big)=1-\alpha.$$

$\bar{X}-St_{n-1}(1-\alpha)/\sqrt{n}$是$\mu$ 的置信水平为$1-\alpha$的置信下界。

习题七

两类错误概率

1. 一盒子里有红球和白球共8个，记红球的比例为p. 考察假设检验问题

$$H_0 : p = 1/4 \leftrightarrow H_1 : p = 3/4.$$

从盒子里随机抽取4个球，当红球的个数大于等于3时拒绝H_0, 否者接受H_0. 试给出拒绝域和犯两类错误概率。

2. 令X_1, X_2, X_3, X_4 $iid \sim Poisson(\lambda)$. 考察假设检验问题

$$H_0 : \lambda = \frac{1}{2} \leftrightarrow H_1 : \lambda = 2.$$

取拒绝域$W = \left\{ (X_1, X_2, X_3, X_4) \,\middle|\, \sum_{i=1}^{4} X_i \geq 3 \right\}$. 求犯第II类错误概率和功效函数。

3. 令$X_1, X_2, \cdots, X_n$ $iid \sim N(\mu, \sigma^2)$, σ^2已知. 记μ_0, μ_1, c为已知常数且满足$\mu_0 < c < \mu_1$, 样本均值$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$. 考察假设检验问题

$$H_0 : \mu = \mu_0 \leftrightarrow H_1 : \mu = \mu_1.$$

取拒绝域$W = \{(X_1, X_2, \cdots, X_n) \big| \bar{X} \geq c\}$.
(1)求犯第I类错误的概率$\xi(\mu_0)$;
(2)求犯第II类错误的概率$\eta(\mu_1)$;
(3)若取$\xi(\mu_0) \leq \alpha$，欲使犯第II类错误的概率$\eta(\mu_1) \leq 1 - \beta$, $0 < \beta < 1$, 问样本量n至少多大?

4. 令$X_1, X_2, \cdots, X_n$ $iid \sim N(\mu, \sigma_0^2)$, σ_0^2已知。记μ_0, a_0为已知常数，显著性水平为α, $0 < \alpha < 1$. 考察假设检验问题

$$H_0 : \mu = \mu_0 \leftrightarrow H_1 : \mu \geq \mu_0 + a_0\sigma_0.$$

(1)构造检验统计量，并给出拒绝域使得犯第I类错误概率不超过α;
(2)求犯第II类错误的概率;
(3)如果犯第II类错误的概率不超过$1 - \beta$, $0 < \beta < 1$, 问样本量n至少需取多大?

5. 令$X_1, X_2, \cdots, X_n$ $iid \sim Exp(\lambda)$. 考察假设检验问题

$$H_0 : \lambda = 1, \leftrightarrow H_1 : \lambda = 4.$$

取检验统计量$T = \bar{X}$, 拒绝域为$W = \{T \leq 1/2\}$. 求证:

$$\lim_{n\to\infty} P_{H_0}(W) = 0, \ \lim_{n\to\infty} P_{H_1}(W) = 1.$$

重要参数检验

6. 令$X_1, X_2, \cdots, X_n$ $iid \sim N(\mu_1, \sigma^2)$, $Y_1, Y_2, \cdots, Y_m$ $iid \sim N(\mu_2, \sigma^2)$, σ^2未知，两组样本相互独立。记$k \neq 0$已知。试给出下面两个假设检验问题

$$H_0 : \mu_1 = k\mu_2, \quad H_1 : \mu_1 \neq k\mu_2,$$

$$H_0 : \mu_1 \leq k\mu_2, \quad H_1 : \mu_1 > k\mu_2$$

的水平为α的检验，$0 < \alpha < 1$.

7. 令$X_1, X_2, \cdots, X_n$ $iid \sim N(\mu_1, \sigma^2)$, $Y_1, Y_2, \cdots, Y_m$ $iid \sim N(\mu_2, k\sigma^2)$, $k > 0$已知，σ^2未知，两组样本相互独立。试给出下面两个假设检验问题

$$H_0 : \mu_1 = \mu_2 \leftrightarrow H_1 : \mu_1 \neq \mu_2,$$

$$H_0 : \mu_1 \leq \mu_2 \leftrightarrow H_1 : \mu_1 > \mu_2$$

的水平为α的检验，$0 < \alpha < 1$.

8. 令$X_1, X_2, \cdots, X_n$ $iid \sim N(\mu_1, \sigma^2)$, $Y_1, Y_2, \cdots, Y_m$ $iid \sim N(\mu_2, k\sigma^2)$, $k > 0$已知, σ^2未知。两组样本相互独立。记$a \neq 0, b \neq 0, c \in \mathcal{R}$是三个已知常数。试给出下面两个假设检验问题

$$H_0 : a\mu_1 + b\mu_2 = c \leftrightarrow H_1 : a\mu_1 + b\mu_2 \neq c,$$

$$H_0 : a\mu_1 + b\mu_2 \leq c \leftrightarrow H_1 : a\mu_1 + b\mu_2 > c$$

的水平为α的检验，$0 < \alpha < 1$.

9. 令$X_1, X_2, \ldots, X_n$ $iid \sim N(\mu_1, \sigma_1^2), Y_1, Y_2, \ldots, Y_m$ $iid \sim N(\mu_2, \sigma_2^2)$, 两组样本相互独立，$\sigma_1^2, \sigma_2^2$未知。记$c = \sigma_1^2/\sigma_2^2$和$k > 0$已知。试给出下面两个假设检验问题

$$H_0 : \mu_1 = k\mu_2 \leftrightarrow H_1 : \mu_1 \neq k\mu_2,$$

$$H_0 : \mu_1 \leq k\mu_2 \leftrightarrow H_1 : \mu_1 > k\mu_2$$

的水平为α的检验，$0 < \alpha < 1$.

10. 令$X_1, X_2, \cdots, X_n$ $iid \sim Exp(\lambda)$. 试给出下面两个假设检验问题

$$H_0 : \lambda = \lambda_0 \leftrightarrow H_1 : \lambda \neq \lambda_0,$$

$$H_0 : \lambda \leq \lambda_0 \leftrightarrow H_1 : \lambda > \lambda_0.$$

的水平为α的检验，$0 < \alpha < 1$.

11. 令$X_1, X_2, \cdots, X_n$ $iid \sim Exp(\lambda_1)$, $Y_1, Y_2, \cdots, Y_m$ $iid \sim Exp(\lambda_2)$, 两组样本相互独立。记k为已知的正数。试给出下面两个假设检验问题

$$H_0 : \lambda_1 = k\lambda_2 \leftrightarrow H_1 : \lambda_1 \neq k\lambda_2,$$

$$H_0 : \lambda_1 \leq k\lambda_2 \leftrightarrow H_1 : \lambda_1 > \lambda_2,$$

的水平为α的检验，$0 < \alpha < 1$.

12. 令$X_1, X_2, \cdots, X_n$ iid 来自**双参数指数分布**，其密度函数$f(x, \theta_1, \theta_2)$(见第六章习题13). 试给出下面四个假设检验问题

$$H_0 : \theta_1 = 0 \leftrightarrow H_1 : \theta_1 \neq 0,$$

$$H_0 : \theta_1 = 0 \leftrightarrow H_1 : \theta_1 \geq 0,$$

$$H_0 : \theta_2 = 1 \leftrightarrow H_1 : \theta_2 \neq 1,$$

$$H_0 : \theta_2 = 1 \leftrightarrow H_1 : \theta_2 \geq 1,$$

水平为α的检验，$0 < \alpha < 1$.

13. 令$X_1, X_2, \cdots, X_n$ $iid \sim U(\theta, 1)$, $0 < \theta < 1$. 记$\theta_0 \in (0, 1)$已知。试给出下面两个假设检验问题

$$H_0 : \theta = \theta_0 \longleftrightarrow H_1 : \theta \neq \theta_0,$$

$$H_0 : \theta \leq \theta_0 \longleftrightarrow H_1 : \theta > \theta_0,$$

的水平为α的检验，$0 < \alpha < 1$.

14. 令$X_1, X_2, \cdots, X_n$ $iid \sim U(0, \theta)$. 试给出下面两个假设检验问题

$$H_0 : \theta = 0.5 \longleftrightarrow H_1 : \theta \neq 0.5,$$

$$H_0 : \theta = 0.5 \longleftrightarrow H_1 : \theta \geq 0.5,$$

水平为α的检验，$0 < \alpha < 1$.

大样本检验

15. 令$X \sim B(n, p)$, $p_0 \in (0, 1)$已知。试给出假设检验问题

$$H_0 : p = p_0 \leftrightarrow H_1 : p \neq p_0$$

的一个水平为α的大样本检验，$0 < \alpha < 1$.

16. 令$X_1, X_2, \cdots, X_n$ $iid \sim Poisson(\lambda)$, $\lambda_0 > 0$已知。试给出假设检验问题

$$H_0 : \lambda = \lambda_0 \leftrightarrow H_1 : \lambda \neq \lambda_0$$

一个水平为α的大样本检验，$0 < \alpha < 1$.

17. 令$X_1, X_2, \cdots, X_n$ $iid \sim f(x,\theta)$, $\theta > 0$,

$$f(x,\theta) = \begin{cases} \frac{2x}{\theta} e^{-\frac{x^2}{\theta}}, & x > 0, \\ 0, & x \le 0. \end{cases}$$

试给出假设检验问题

$$H_0 : \theta = 1 \leftrightarrow H_1 : \theta \neq 1,$$

的一个水平为α的检验及大样本检验，$0 < \alpha < 1$.

18. 令$(X_1, Y_1)^\top, (X_2, Y_2)^\top, \cdots, (X_n, Y_n)^\top$ $iid \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$. 记$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$, $\bar{Y} = \frac{1}{n}\sum_{j=1}^{n} Y_j$，及样本相关系数为

$$r = \frac{\sum_{k=1}^{n}(X_k - \bar{X})(Y_k - \bar{Y})}{\sqrt{\sum_{i=1}^{n}(X_i - \bar{X})^2 \sum_{j=1}^{n}(Y_j - \bar{Y})^2}}.$$

可以证明当$\rho = 0$, $\frac{\sqrt{n-2}\, r}{\sqrt{1-r^2}} \sim t_{n-2}$. 试给出假设检验问题

$$H_0 : \rho = 0 \leftrightarrow H_1 : \rho \neq 0,$$

一个水平为α的大样本检验，$0 < \alpha < 1$.

19. 某咨询电话在50个单位时间内收到的咨询次数如下：

2, 4, 1, 1, 6, 3, 4, 0, 4, 0, 1, 2, 0, 4, 3, 0, 2, 3, 1, 7, 1, 1, 3, 2, 0,

1, 1, 0, 2, 4, 3, 1, 2, 4, 0, 2, 3, 1, 2, 1, 6, 1, 2, 0, 1, 2, 0, 2, 1, 1.

假设该咨询电话单位时间内收到的咨询次数服从Poisson分布。问在显著性水平$\alpha = 0.05$下，能否认为该咨询电话单位时间收到的咨询次数不低于2次。

20. 令一种灌装饮料容量(单位：毫升)$X \sim N(500, 9)$. 现从市场购买20听该灌装饮料，测的容量如下：

487, 501, 494, 491, 503, 502, 488, 489, 505, 489.

问在显著性水平0.05下，该灌装饮料的容量是否偏小？

21. 为了检验一种新研发的药物A是否对治疗糖尿病有效，随机将20名糖尿病患者分成甲、乙组，甲组11人服用药物A，乙组9人服用安慰剂组。一段时间后，测得两组个体的空腹血糖值(单位：mmol/L) 如下：
第一组：6.9, 3.6, 6.2, 4.2, 4.8, 5.1, 4.1, 3.2, 3.6, 4.5, 3.9;
第二组：7.7, 6.8, 5.1, 6.2, 7.9, 8.0, 8.7, 8.3，6.4.
设这两组数据相互独立均服从正态分布。问在显著性水平0.05下，药物A能否控制血糖水平？

拟合优度检验

22. 圆周率π的前800位小数中，0到9出现的次数如下：

数字	0	1	2	3	4	5	6	7	8	9
次数	74	92	83	79	80	73	77	75	76	91

试根据表中的数据检验这10个数字出现的概率是否相等。

23. 某人自制一骰子，声称是均匀的。现随机投掷该骰子48次，结果如下：

数字	1	2	3	4	5	6
次数	5	8	10	9	8	8

问在显著性水平为0.05时，这个骰子均匀吗？

24. 令分布函数$F_0(x)$的概率函数为

$$P(X=-1)=\frac{1-\theta}{2},\ P(X=0)=\frac{1}{2},\ P(X=1)=\frac{\theta}{2},\ 0<\theta<1.$$

现有如下观测数据：

$$-1,\ 0,\ -1,\ 0,\ 1,\ 0,\ -1,\ 0,\ -1,\ 1,\ 1,\ 0,\ 0,\ 0,\ 0,\ 0,\ 1,\ -1,\ 1,\ 1.$$

问在显著性水平为0.05时，这组数据来自$F_0(x)$吗？

25. 令分布函数$F_0(x)$的概率函数如下

取值	0	1	2
概率	$\frac{1}{2}\left[(1-\theta)^2+\theta^2\right]$	$2\theta(1-\theta)$	$\frac{1}{2}\left[(1-\theta)^2+\theta^2\right]$.

现有如下观测数据：

$$0,\ 2,\ 1,\ 1,\ 1,\ 0,\ 2,\ 0,\ 1,\ 1,\ 1,\ 0,\ 0,\ 2,\ 0,\ 0,\ 1,\ 0,\ 0,\ 0.$$

问在显著性水平为0.05时，这组数据来自$F_0(x)$吗？

列联表的独立性检验

26. 考察2×2列联表(见下表)的独立性检验，

$X\backslash Y$	b_1	b_2	求和
a_1	a	b	$a+b$
a_2	c	d	$c+d$
求和	$a+c$	$b+d$	$n.$

求证：列联表的独立性检验统计量可以改写为

$$T = \frac{n(ad-bc)^2}{(a+b)(c+d)(a+c)(b+d)}.$$

27. 一项年龄与高血压的调查研究数据如下表：

年龄区间	高血压	健康	行和
0-20	11	189	200
21-40	32	188	220
41-60	84	106	190
61以上	83	147	230
列和	210	630	840

在显著性水平为0.05时，患高血压与年龄独立吗？

28. 考察某地区居民患一种传染病的病情严重程度是否与年龄有关。从患病人群中随机抽取212人，在各个年龄段的死亡人数如下表所示：

年龄区间	重症	一般	轻症	行和
$[1,20]$	5	8	15	28
$[21,40]$	7	31	38	76
$[40,60]$	8	28	33	69
$60+$	15	18	6	39
列和	35	85	92	212

问在显著性水平为0.05时，病情严重程度是否与年龄有关？

非参数检验

29. 现有5个独立同分布样本：1.72, 2.59, 1.81, 2.28, 1.13. 在显著性水平为0.05下，问它们是否来自正态分布$N(2,1)$?

30. 现有两组简单随机样本：

甲组：2.2, 3.3, 5.5, 2.5, 3.5, 4.5, 5.5, 3.3, 4.1, 5.2,

乙组：3.5, 2.2, 3.1, 1.6, 2.1, 3.7, 1.2, 2.2, 3.1.

问它们的分布是否存在显著差异？

三大检验

31. 针对7.3节介绍的已知分布不含未知参数的拟合优度检验，试构造似然比检验统计量。

32. 试给出列联表独立性检验的似然比检验统计量。

33. 令$X_1, X_2, \cdots, X_n \; iid \sim N(\mu, \sigma^2)$. 试给出假设检验问题

$$H_0 : \sigma^2 = \sigma_0^2 \leftrightarrow H_1 : \sigma^2 \neq \sigma_0^2$$

在μ已知且$\mu = \mu_0$和μ未知时的似然比检验统计量。

34. 从某人群中随机抽取n个人，检测他们在某等位基因位点的基因型。假设该位点只有两个等位基因g和G, 这n个人在该位点的基因型gg, Gg, GG的个数分别为n_0, n_1, n_2. 记显著性水平为α, $0 < \alpha < 1$. 试构造得分检验和Wald检验，检验该群体在此位点是否达到Hardy-Weinberg平衡。

第八章　线性回归分析

8.1 基本概念

“回归(Regression)”最早由Galton在1855年的论文《遗传的身高向平均数方向的回归》给出的。为研究父代和子代的身高之间的关系，Galton和他的合作者分析了1078对夫妇和儿子的身高数据(单位：米)，以每对夫妇的平均身高x为横坐标，他们的成年儿子身高y为纵坐标，绘制散点图，如图8.1所示。他们发现散点图大致呈一条直线，拟合的直线方程为：$y = 0.857 + 0.516x$。总体趋势是儿子的身高随父母身高增加而增加，他们还发现一个有趣的现象：矮个子父母的儿子的身高一般比其父母高，而高个子父母所生儿子的身高却有降回多数人的平均身高的趋势，也就是说，族群身高的分布在一定时期内相对稳定，不会产生两极分化，会趋向(称之为“回归”)于族群的平均身高。

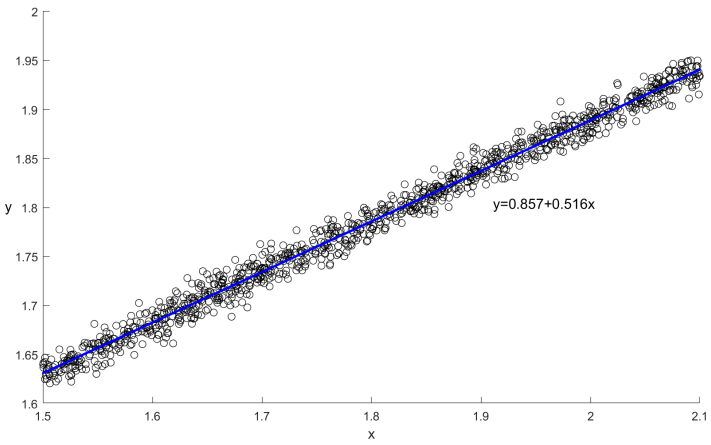


图8.1 1078对夫妇的数据图(单位：米)。

除此之外，在现实生活中存在着许多类似的现象。两个或多个变量之间有一些联系，但没有确切到可以严格决定的程度。例如，人的身高和体重有关，一般表现为身高高的人，其体重也倾向于大，但是身高并不能严格地决定体重。再比如某种商品的销售量与其销售价格、投入的广告费有关，但是这些因素也不能严格决定商品的销售量。称上述体重或某商品的销售量为因变量或响应变量，称身高、销售价格、投入广告费等可能对因变量造成影响的指标为自变量或解释变量。回归分析的主要任务是：建立因变量与自变量之间的相关关系，并对所关心的因变量进行预测。这里，自变量一般认为非随机的，不受随机因素的影响，而因变量的取值是一个随机变量。

令Y为因变量，$X_1, X_2, \cdots, X_m$为自变量，$\mathcal{E}$为随机误差，$\beta_0, \beta_1, \cdots, \beta_m$ 为未知的系数。如果Y与$X_1, X_2, \cdots, X_m$满足下述线性关系，即

$$Y = \beta_0 + X_1\beta_1 + \cdots + X_m\beta_m + \mathcal{E},$$

称上述模型为线性回归模型，一般称它为线性回归模型的总体形式。$m=1$时的回归模型对应的是一元线性回归模型，$m>1$时的回归模型对应的是多元线性回归模型。

需要指出的是，虽然现实中许多模型都不一定是非线性的，然而经过适当变换，都可化成线性回归模型。如多项式回归模型：

$$Y=\beta_0+X_1\beta_1+X_2\beta_2+X_1^2\beta_3+X_2^2\beta_4+X_1X_2\beta_5+\mathcal{E}.$$

引入新变量$X_3=X_1^2,X_4=X_2^2,X_5=X_1X_2$,上述模型便转换成线性回归模型。因此，线性回归模型的推断理论是许多模型推断的基础。

为了推断未知的参数$\beta_0,\beta_1,\cdots,\beta_m$, 我们对$Y$和$X_1,X_2,\cdots,X_m$进行了$n$次观测，$n$次观测值为

$$y_i,x_{i1},x_{i2},\cdots,x_{im},i=1,2,\cdots,n.$$

记第i次的随机误差为ε_i，线性回归模型的数据形式可以表示为

$$\begin{aligned}
y_1 &= \beta_0+x_{11}\beta_1+x_{12}\beta_2+\cdots+x_{1m}\beta_m+\varepsilon_1,\\
y_2 &= \beta_0+x_{21}\beta_1+x_{22}\beta_2+\cdots+x_{2m}\beta_m+\varepsilon_2,\\
&\vdots\\
y_n &= \beta_0+x_{n1}\beta_1+x_{n2}\beta_2+\cdots+x_{nm}\beta_m+\varepsilon_n.
\end{aligned}$$

为了对上述线性回归模型进行推断，我们通常假定误差$\varepsilon_i,i=1,2,\cdots,n$ 满足Gauss-Markov 假定。

Gauss-Markov假定需要满足下面三个条件：

(1)(**零均值**) $E\varepsilon_i=0,i=1,2,\cdots,n$;

(2)(**等方差**) $\mathrm{var}(\varepsilon_i)=\sigma^2,i=1,2,\cdots,n$;

(3)(**不相关**) $\mathrm{cov}(\varepsilon_i,\varepsilon_j)=0,i\neq j\in\{1,2,\cdots,n\}$.

在以后的讲述中，如不特殊说明，都假定随机误差满足Gauss-Markov假定。记

$$\begin{aligned}
y &= (y_1,y_2,\cdots,y_n)^\top,\\
\beta &= (\beta_0,\beta_1,\cdots,\beta_m)^\top,\\
\varepsilon &= (\varepsilon_1,\varepsilon_2,\cdots,\varepsilon_n)^\top.\\
x_i &= (1,x_{i1},x_{i2},\cdots,x_{im})^\top,i=1,2,\cdots,n.
\end{aligned}$$

及

$$\mathbf{X}=\begin{pmatrix}x_1^\top\\x_2^\top\\\cdots\\x_n^\top\end{pmatrix}=\begin{pmatrix}1&x_{11}&x_{12}&\cdots&x_{1m}\\1&x_{21}&x_{22}&\cdots&x_{2m}\\\vdots&\vdots&\ddots&\vdots&\\1&x_{n1}&x_{n2}&\cdots&x_{nm}\end{pmatrix}$$

常称$\mathbf{X}$为设计矩阵(Design matrix)，简称设计阵，β为回归系数。线性回归模型的矩阵形式可表示为

$$y=\mathbf{X}\beta+\varepsilon,E\varepsilon=\mathbf{0}_n,\ \mathrm{cov}(\varepsilon)=\sigma^2\mathbf{I}_n. \tag{8.1}$$

8.2 最小二乘估计

除了随机误差部分，线性回归模型中未知的部分是β，一般采用最小二乘法确定β的值。最小二乘法就是极小化y_i与$x_i^\top\beta$之间差异的平方和，记其为$\psi(\beta)$, 即

$$\psi(\beta)=\sum_{i=1}^{n}(y_i-x_i^\top\beta)^2=\|y-\mathbf{X}\beta\|^2,$$

其中$\|\cdot\|$表示向量的二范数。

最小二乘估计： 令

$$\hat{\beta}=\arg\min_{\beta}\|y-\mathbf{X}\beta\|^2.$$

称$\hat{\beta}$为最小二乘估计(Least Square Estimate)，简称为LSE.

显然, $\psi(\beta)=\|y-\mathbf{X}\beta\|^2=(y-\mathbf{X}\beta)^\top(y-\mathbf{X}\beta)=y^\top y-2\beta^\top\mathbf{X}^\top y+\beta^\top\mathbf{X}^\top\mathbf{X}\beta$. 由$\partial\psi(\beta)/\partial\beta=0$, 得

$$\mathbf{X}^\top\mathbf{X}\beta=\mathbf{X}^\top y. \tag{8.2}$$

称(8.2)式为**正则方程**，它有唯一解的充分必要条件是$\mathbf{X}^\top\mathbf{X}$的秩为$m+1$，等价于$\mathbf{X}$是列满秩的。在以后的讨论中，我们总假定$\mathbf{X}$是列满秩的且$\frac{\partial^2\psi(\beta)}{\partial\beta^\top\partial\beta}>0$, 由此得到$\beta$的LSE为

$$\hat{\beta}=(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top y.$$

下面验证$\psi(\beta)$在$\hat{\beta}$处达到最小。事实上，对任意β, 我们有

$$\begin{aligned}\psi(\beta) &= \|y-\mathbf{X}\beta\|^2\\ &= \|y-\mathbf{X}\hat{\beta}+\mathbf{X}(\hat{\beta}-\beta)\|^2\\ &= \|y-\mathbf{X}\hat{\beta}\|^2+(\hat{\beta}-\beta)^\top\mathbf{X}^\top\mathbf{X}(\hat{\beta}-\beta)+2(\hat{\beta}-\beta)\mathbf{X}^\top(y-\mathbf{X}\hat{\beta}).\end{aligned}$$

由$\mathbf{X}^\top(y-\mathbf{X}\hat{\beta})=0$可知上式的第三项等于0. 又因为$\mathbf{X}^\top\mathbf{X}$是一个正定阵，上式的第二项总是非负的。因此，

$$\psi(\beta)\geq\psi(\hat{\beta}),$$

等号成立当且仅当$(\hat{\beta}-\beta)^\top\mathbf{X}^\top\mathbf{X}(\hat{\beta}-\beta)=0$, 即$\beta=\hat{\beta}$.

例8.1 考察一元线性回归模型

$$y_i=\beta_0+z_i\beta_1+\varepsilon_i, i=1,2,\cdots,n.$$

假设随机误差满足Gauss-Markov假定。求回归系数的最小二乘估计。

解： 记

$$\bar{z}=\frac{1}{n}\sum_{i=1}^{n}z_i,\ \ \bar{y}=\frac{1}{n}\sum_{i=1}^{n}y_i,\ \ \mathbf{Z}=\begin{pmatrix}1 & z_1\\ 1 & z_2\\ \vdots & \vdots\\ 1 & z_n\end{pmatrix}.$$

$(\beta_0,\beta_1)^\top$的最小二乘估计为

$$(\hat{\beta}_0,\hat{\beta}_1)^\top=(\mathbf{Z}^\top\mathbf{Z})^{-1}\mathbf{Z}^\top y.$$

化简得

$$\begin{cases}\hat{\beta}_0=\bar{y}-\bar{z}\hat{\beta}_1,\\ \hat{\beta}_1=\dfrac{\sum\limits_{i=1}^n z_iy_i-n\bar{z}\bar{y}}{\sum\limits_{i=1}^n z_i^2-n\bar{z}^2}=\dfrac{\sum\limits_{i=1}^n(z_i-\bar{z})(y_i-\bar{y})}{\sum\limits_{i=1}^n(z_i-\bar{z})^2}.\end{cases}$$

为了减少计算量和计算误差，在进行数据分析之前，我们经常要对数据作适当的预处理。令

$$\bar{x}_j=\frac{1}{n}\sum_{i=1}^n x_{ij},j=1,2,\cdots,m,$$
$$s_j^2=\frac{1}{n-1}\sum_{i=1}^n(x_{ij}-\bar{x}_j)^2,j=1,2,\cdots,m.$$

常用的数据预处理方法有：

(1) 中心化：$x_{ij}-\bar{x}_j$, 把自变量的n次观测值的均值变为0;

(2) 标准化：$\dfrac{x_{ij}-\bar{x}_j}{s_j}$, 消除回归自变量的单位和取值范围的差异。

下面分别考察经过上述两种数据预处理后的最小二乘估计。

中心化的线性回归模型

对自变量的n次观测值进行中心化及$i=1,2,\cdots,n$,

$$y_i=\beta_0+\bar{x}_1\beta_1+\cdots+\bar{x}_m\beta_m+(x_{i1}-\bar{x}_1)\beta_1+\cdots+(x_{im}-\bar{x}_m)\beta_m+\varepsilon_i,\quad(8.3)$$

记

$$\begin{aligned}\eta_0&=\beta_0+\bar{x}_1\beta_1+\cdots+\bar{x}_m\beta_m,\\ \eta_j&=\beta_j,j=1,2,\cdots,m,\\ \eta&=(\eta_0,\eta_1,\cdots,\eta_m)^\top,\\ \mathbf{X}_c&=\begin{pmatrix}x_{11}-\bar{x}_1&x_{12}-\bar{x}_2&\cdots&x_{1m}-\bar{x}_m\\ x_{21}-\bar{x}_1&x_{22}-\bar{x}_2&\cdots&x_{2m}-\bar{x}_m\\ \vdots&\vdots&\ddots&\vdots\\ x_{n1}-\bar{x}_1&x_{n2}-\bar{x}_2&\cdots&x_{nm}-\bar{x}_m\end{pmatrix}\end{aligned}$$

中心化后的线性回归模型(8.3)可以改写成

$$y=\Big(\mathbf{1}_n,\mathbf{X}_c\Big)\eta+\mathcal{E}.$$

可见，中心化的线性回归模型前后除了常数项有区别外，其余回归系数不变。下面运用最小二乘法来估计中心化后模型的回归系数。由于$\mathbf{X}_c$已经中心化，因

此$\mathbf{1}_n^\top \mathbf{X}_c = \mathbf{0}_m^\top$. 正则方程为

$$\begin{pmatrix} n & \mathbf{0}_m^\top \\ \mathbf{0}_m & \mathbf{X}_c^\top \mathbf{X}_c \end{pmatrix} \eta = \begin{pmatrix} \mathbf{1}_n^\top y \\ \mathbf{X}_c^\top y \end{pmatrix}$$

回归系数η的最小二乘估计为

$$\begin{cases} \hat{\eta}_0 = \bar{y}, \\ \left(\hat{\eta}_1, \hat{\eta}_2, \cdots, \hat{\eta}_m\right)^\top = (\mathbf{X}_c^\top \mathbf{X}_c)^{-1} \mathbf{X}_c^\top y. \end{cases}$$

可见，中心化的回归模型把常数项η_0和$\eta_1, \eta_2, \cdots, \eta_m$的最小二乘估计分离开了，常数项的最小二乘估计等于因变量的观测平均值，其余参数的最小二乘估计相当于是线性回归模型

$$y = \mathbf{X}_c(\eta_1, \eta_2, \cdots, \eta_m)^\top + \varepsilon$$

的最小二乘估计。可见，把常数项和回归系数的估计分离开是数据中心化的好处之一。在实际应用中，我们总是特别关心回归系数，所以中心化是很必要的。下面计算$\hat{\eta}_0$和$\left(\hat{\eta}_1, \hat{\eta}_2, \cdots, \hat{\eta}_m\right)^\top$ 的协方差阵。

$$\begin{aligned} \operatorname{cov}\left(\hat{\eta}_0, \left(\hat{\eta}_1, \hat{\eta}_2, \cdots, \hat{\eta}_m\right)^\top\right) &= \operatorname{cov}\left(\bar{y}, (\mathbf{X}_c^\top \mathbf{X}_c)^{-1} \mathbf{X}_c^\top y\right) \\ &= \operatorname{cov}\left(\tfrac{1}{n}\mathbf{1}_n^\top y, (\mathbf{X}_c^\top \mathbf{X}_c)^{-1} \mathbf{X}_c^\top y\right) \\ &= \tfrac{1}{n}\mathbf{1}_n^\top \operatorname{cov}(y) \mathbf{X}_c (\mathbf{X}_c^\top \mathbf{X}_c)^{-1} \\ &= \tfrac{1}{n}\mathbf{1}_n^\top \sigma^2 \mathbf{I}_n \mathbf{X}_c (\mathbf{X}_c^\top \mathbf{X}_c)^{-1} \\ &= \tfrac{1}{n}\sigma^2 \mathbf{1}_n^\top \mathbf{X}_c (\mathbf{X}_c^\top \mathbf{X}_c)^{-1} \\ &= \mathbf{0}_m^\top. \end{aligned}$$

可见中心化后，常数项η_0的最小二乘估计$\hat{\eta}_0$和$\left(\hat{\eta}_1, \hat{\eta}_2, \cdots, \hat{\eta}_m\right)^\top$的最小二乘估计是不相关的。

例8.2 考察一元线性回归模型

$$y_i = \beta_0 + z_i \beta_1 + \varepsilon_i, i = 1, 2, \cdots, n.$$

中心化后，

$$y_i = \eta_0 + (z_i - \bar{z})\eta_1 + \varepsilon_i, i = 1, 2, \cdots, n.$$

求η_0和η_1的最小二乘估计。

解： 记$\mathbf{Z}_c = (z_1 - \bar{z}, z_2 - \bar{z}, \cdots, z_n - \bar{z})^\top$, 有

$$(\mathbf{Z}_c^\top \mathbf{Z}_c)^{-1} \mathbf{Z}_c^\top y = \frac{\sum\limits_{i=1}^{n} y_i (z_i - \bar{z})}{\sum\limits_{i=1}^{n} (z_i - \bar{z})^2}.$$

回归系数η_0, η_1的最小二乘估计为

$$\begin{cases} \hat{\eta}_0 = \bar{y}, \\ \hat{\eta}_1 = \dfrac{\sum\limits_{i=1}^{n} y_i(z_i - \bar{z})}{\sum\limits_{i=1}^{n}(z_i - \bar{z})^2}. \end{cases}$$

标准化的线性回归模型

对自变量进行标准化及$i = 1, 2, \cdots, n$,

$$y_i = \zeta_0 + \Big(\frac{x_{i1} - \bar{x}_1}{s_1}\Big)\zeta_1 + \Big(\frac{x_{i2} - \bar{x}_2}{s_2}\Big)\zeta_2 + \cdots + \Big(\frac{x_{im} - \bar{x}_m}{s_m}\Big)\zeta_m + \varepsilon_i,$$

其中$\zeta_0 = \beta_0 + \bar{x}_1\beta_1 + \bar{x}_2\beta_2 + \cdots + \bar{x}_m\beta_m$, $\zeta_j = s_j\beta_j$, $j = 1, 2, \cdots, m$. 记

$$\mathbf{W} = \left(\frac{x_{ij} - \bar{x}_j}{s_j}\right)_{n\times m}.$$

则$\mathbf{1}_n^\top \mathbf{W} = \mathbf{0}_m^\top$. 由中心化的回归模型的结果可得$\zeta_0$的最小二乘估计为

$$\hat{\zeta}_0 = \bar{y},$$

$(\zeta_1, \zeta_2, \cdots, \zeta_m)^\top$的最小二乘估计为

$$\Big(\hat{\zeta}_1, \hat{\zeta}_2, \cdots, \hat{\zeta}_m\Big)^\top = (\mathbf{W}^\top\mathbf{W})^{-1}\mathbf{W}^\top y$$

且

$$\operatorname{cov}\Big(\hat{\zeta}_0, \big(\hat{\zeta}_1, \hat{\zeta}_2, \cdots, \hat{\zeta}_m\big)^\top\Big) = \mathbf{0}_m^\top.$$

记$\mathbf{R} = \mathbf{W}^\top\mathbf{W} = (r_{jk})_{m\times m}$, 它是自变量的样本相关系数矩阵。可见，经过标准化后，消除了回归自变量之间的单位和取值范围的差异。

8.3. 最小二乘估计的性质

考察一般线性回归模型(8.1), 最小二乘估计有如下性质。

定理8.1 令$\mathbf{H}=\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top$. 则：

(1)$\mathbf{H}$和$\mathbf{I}_n-\mathbf{H}$ 是对称幂等矩阵;

(2)$\mathrm{rk}(\mathbf{H})=m+1, \mathrm{rk}(\mathbf{I}_n-\mathbf{H})=n-m-1$;

(3)$(\mathbf{I}_n-\mathbf{H})\mathbf{X}=\mathbf{O}_{n\times(m+1)}$.

证明：(1)和(3)显然。下面证明(2)，由幂等矩阵的性质(秩等于迹)，有

$$\mathrm{rk}(\mathbf{H})=\mathrm{tr}\big(\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\big)=\mathrm{tr}\left((\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{X}\right)=\mathrm{tr}(\mathbf{I}_{m+1})=m+1,$$

$$\mathrm{rk}(\mathbf{I}_n-\mathbf{H})=\mathrm{tr}(\mathbf{I}_n-\mathbf{H})=n-\mathrm{tr}(\mathbf{H})=n-m-1$$

定理8.2 最小二乘估计$\hat\beta=(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top y$ 具有下列性质：

(1)$E\hat\beta=\beta$;

(2)$\mathrm{cov}(\hat\beta)=\sigma^2(\mathbf{X}^\top\mathbf{X})^{-1}$.

证明：(1) $E\hat\beta=(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top Ey=(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{X}\beta=\beta$.

(2)

$$\begin{aligned}\mathrm{cov}\left(\hat\beta\right) &= \mathrm{cov}\left((\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top y\right)\\ &= (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathrm{cov}(y)\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\\ &= (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\sigma^2\mathbf{I}_n\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\\ &= \sigma^2(\mathbf{X}^\top\mathbf{X})^{-1}.\end{aligned}$$

令$c\in\mathcal{R}^{m+1}$. 考察$c^\top\beta$的线性估计，估计量是$y_1,y_2,\cdots,y_n$的线性组合。下面的定理说明在误差项满足Gauss-Markov假定时，最小二乘估计的线性组合$c^\top\hat\beta$是$c^\top\beta$的所有线性无偏估计类中方差最小的。

定理8.3 (**Gauss-Markov定理**) 在$c^\top\beta$ 的所有线性无偏估计构成的集合

$$\Omega=\{b^\top y|E(b^\top y)=c^\top\beta, b\in\mathcal{R}^n\}$$

中，$c^\top\hat\beta$ 是最优线性无偏估计(Best linear unbiased estimate)，简称为BLUE, 这里“最优”体现在所有线性无偏估计中方差最小。

证明： 记$b^\top y$ 是$c^\top\beta$的任意一个线性无偏估计。那么对一切β 有

$$c^\top\beta=E(b^\top y)=b^\top\mathbf{X}\beta,$$

由于β的任意性可知$b^\top\mathbf{X}=c^\top$. 另一方面，

$$\begin{aligned}\mathrm{var}(b^\top y) &= \sigma^2 b^\top b,\\ \mathrm{var}(c^\top\hat\beta) &= \sigma^2 c^\top(\mathbf{X}^\top\mathbf{X})^{-1}c=\sigma^2 b^\top\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top b,\end{aligned}$$

$\mathbf{I}_n-\mathbf{H}$半正定矩阵。则

$$\mathrm{var}(b^\top y)-\mathrm{var}(c^\top\hat\beta)=\sigma^2 b^\top(\mathbf{I}_n-\mathbf{H})b\geq 0.$$

下面我们对β进行统计推断，包括构造β的区间估计和β的假设检验。这里涉及到随机误差ε的协方差阵$\sigma^2\mathbf{I}_n$. 因此，我们需要给出σ^2的估计。在此之前，先介绍几个概念。对$i=1,2,\cdots,n$, 称$\hat{y}_i=x_i^\top\hat{\beta}$ 为y_i 的拟合值，$\hat{\varepsilon}_i=y_i-x_i^\top\hat{\beta}$ 为第i次观测的残差。

残差平方和：称

$$RSS=\sum_{i=1}^{n}\hat{\varepsilon}_i^2,$$

为残差平方和(Residual Sum of Squares)，简称为RSS.

RSS反映了实际数据与理论模型的偏离程度或者说拟合程度。RSS愈小，数据与模型拟合得愈好。

定理8.4 残差平方和具有以下性质：

(1)$RSS=y^\top[\mathbf{I}_n-\mathbf{H}]y$;

(2)$\hat{\sigma}^2=\frac{RSS}{n-m-1}$是$\sigma^2$ 的无偏估计。

证明：(1)

$$\begin{aligned}RSS &= \hat{\varepsilon}^\top\hat{\varepsilon}\\ &= (y-\mathbf{X}\hat{\beta})^\top(y-\mathbf{X}\hat{\beta})\\ &= [(\mathbf{I}_n-\mathbf{H})y]^\top[(\mathbf{I}_n-\mathbf{H})y]\\ &= y^\top(\mathbf{I}_n-\mathbf{H})y.\end{aligned}$$

(2) 由于$Ey=\mathbf{X}\beta,\mathrm{cov}(y)=\sigma^2\mathbf{I}_n$,

$$\begin{aligned}E(RSS) &= E[y^\top(\mathbf{I}_n-\mathbf{H})y]\\ &= \beta^\top\mathbf{X}^\top(\mathbf{I}_n-\mathbf{H})\mathbf{X}\beta+\sigma^2\mathrm{tr}(\mathbf{I}_n-\mathbf{H})\\ &= (n-m-1)\sigma^2.\end{aligned}$$

判定系数：称

$$R^2=\frac{(y-\bar{y})^\top(y-\bar{y})-RSS}{(y-\bar{y})^\top(y-\bar{y})},$$

为判定系数.

相比于残差平方和，判定系数更能体现拟合的好坏。判定系数取值于0到1之间，它的值越大，说明Y与$X_1,X_2,\cdots,X_m$拟合的线性回归模型越好。在Gauss-Markov假定的基础上，进一步假定随机误差服从多元正态分布，即$\varepsilon\sim N(\mathbf{0}_n,\sigma^2\mathbf{I}_n)$. 称其对应的线性回归模型

$$y=\mathbf{X}\beta+\varepsilon,\varepsilon\sim N(\mathbf{0}_n,\sigma^2\mathbf{I}_n),\tag{8.4}$$

为正态线性回归模型或正态模型。在正态模型下，β 的最小二乘估计与极大似然估计是相等的。

定理8.5 对于正态线性回归模型(8.4), β的最小二乘估计等于其极大似然估计。

证明：β的最小二乘估计为$\hat{\beta}=(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top y$. 对于正态线性模型(8.4), 似然函数为

$$\begin{aligned} L(\beta) &= \frac{1}{(2\pi)^{n/2}\sigma^n}\exp\Big\{-\frac{1}{2\sigma^2}(y-\mathbf{X}\beta)^\top(y-\mathbf{X}\beta)\Big\} \\ &= \frac{1}{(2\pi)^{n/2}\sigma^n}\exp\Big\{-\frac{1}{2\sigma^2}y^\top y+\frac{1}{\sigma^2}y^\top\mathbf{X}\beta-\frac{1}{2\sigma^2}\beta^\top\mathbf{X}^\top\mathbf{X}\beta\Big\}. \end{aligned}$$

对数似然函数为

$$l(\beta)=-\frac{n}{2}\ln(2\pi\sigma^2)-\frac{1}{2\sigma^2}y^\top y+\frac{1}{\sigma^2}y^\top\mathbf{X}\beta-\frac{1}{2\sigma^2}\beta^\top\mathbf{X}^\top\mathbf{X}\beta.$$

似然方程为

$$\frac{\partial l(\beta)}{\partial\beta}=\frac{1}{\sigma^2}\mathbf{X}^\top y-\frac{2}{2\sigma^2}\mathbf{X}^\top\mathbf{X}\beta=0.$$

解得$\hat{\beta}=(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top y$, 它是$\beta$的极大似然估计。故而，$\beta$ 的最小二乘估计与极大似然估计相等。

定理8.6 对于正态线性回归模型(8.4), 记$c\in\mathcal{R}^{m+1}$, 则$c^\top\hat{\beta}$是$c^\top\beta$的一致最小方差无偏估计。

证明：y的密度函数为

$$\begin{aligned} f(y) &= \frac{1}{(2\pi)^{n/2}\sigma^n}\exp\Big\{-\frac{1}{2\sigma^2}(y-\mathbf{X}\beta)^\top(y-\mathbf{X}\beta)\Big\} \\ &= \frac{1}{(2\pi)^{n/2}\sigma^n}\exp\Big\{-\frac{1}{2\sigma^2}y^\top y+\frac{1}{\sigma^2}y^\top\mathbf{X}\beta-\frac{1}{2\sigma^2}\beta^\top\mathbf{X}^\top\mathbf{X}\beta\Big\} \\ &= \left[\frac{1}{(-\pi)^{n/2}}a^n\exp\Big(\frac{1}{4a}b^\top\mathbf{X}^\top\mathbf{X}b\Big)\right]\exp(aT_1+bT_2), \end{aligned}$$

其中$a=-\frac{1}{2\sigma^2}$, $b=\frac{\beta}{\sigma^2}\in\mathcal{R}^m$, $T_1=y^\top y$, $T_2=\mathbf{X}^\top y$. 可见T_1和T_2是充分完备统计量。由于

$$c^\top\hat{\beta}=c^\top(\mathbf{X}^\top\mathbf{X})^{-1}T_2$$

是充分完备统计量的函数，且是无偏的，即$E(c^\top\hat{\beta})=c^\top\beta$, 根据第六章定理6.4, 可知$c^\top\hat{\beta}$是$c^\top\beta$的一致最小方差无偏估计。

Gauss-Markov定理说明$c^\top\hat{\beta}$在线性无偏类中方差最小，在进一步假定$\varepsilon\sim N(\mathbf{0}_n,\sigma^2\mathbf{I}_n)$, 定理8.6说明：无论是针对线性无偏估计，还是非线性无偏估计，$c^\top\hat{\beta}$在$c^\top\beta$是所有无偏估计中方差最小的。

定理8.7. 对于正态线性回归模型，有

(1)$\hat{\beta}\sim N\big(\beta,\sigma^2(\mathbf{X}^\top\mathbf{X})^{-1}\big)$.

(2)$\frac{RSS}{\sigma^2}\sim\chi^2_{n-m-1}$;

(3)$\hat{\beta}$与RSS相互独立。

证明：(1)由于$y\sim N(\mathbf{X}\beta,\sigma^2\mathbf{I}_n)$, 且$\hat{\beta}=(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top y$是$y$的线性变换，由第三章3.6节多元正态分布性质2知(1)成立。

(2)根据定理8.4, $RSS = y^\top(\mathbf{I}_n - \mathbf{H})y$. 由$\mathbf{HX} = \mathbf{O}_{n\times(m+1)}$, 知

$$RSS = (\mathbf{X}\beta + \varepsilon)^\top(\mathbf{I}_n - \mathbf{H})(\mathbf{X}\beta + \varepsilon) = \varepsilon^\top(\mathbf{I}_n - \mathbf{H})\varepsilon.$$

又因为$\varepsilon \sim N(\mathbf{0}_n, \sigma^2\mathbf{I}_n)$及$(\mathbf{I}_n - \mathbf{H})^2 = \mathbf{I}_n - \mathbf{H}$, 根据第五章$\chi^2$分布性质5得证。

(3)因为$\hat{\beta} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top(\mathbf{X}\beta+\varepsilon) = \beta+(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\epsilon$, 且$RSS = \varepsilon^\top(\mathbf{I}_n-\mathbf{H})\varepsilon$. 由第三章第3.6节多元正态分布性质6, 只要证明$(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top(\mathbf{I}_n - \mathbf{H}) = \mathbf{O}_{(m+1)\times n}$ 即可，该式显然成立，故(3)得证。

定理8.8. 对于中心化的正态线性回归模型$y = \Big(\mathbf{1}_n, \mathbf{X}_c\Big)\eta+\varepsilon, \varepsilon \sim N(\mathbf{0}_n, \sigma^2\mathbf{I}_n)$, 有

(1)$E\hat{\eta} = \eta$.

(2)$\mathrm{cov}(\hat{\eta}) = \sigma^2 \begin{pmatrix} \frac{1}{n} & 0 \\ 0 & (\mathbf{X}_c^\top\mathbf{X}_c)^{-1} \end{pmatrix}$.

(3)$\hat{\eta}_0 \sim N(\eta_0, \sigma^2/n)$, $(\hat{\eta}_1, \hat{\eta}_2, \cdots, \hat{\eta}_m)^\top \sim N\left(\beta, \sigma^2(\mathbf{X}_c^\top\mathbf{X}_c)^{-1}\right)$, 且$\hat{\eta}_0$和$(\hat{\eta}_1, \hat{\eta}_2, \cdots, \hat{\eta}_m)^\top$相互独立。

证明： (1)和(2)显然易得。下面证明(3). 由题意知

$$\hat{\eta}_0 = \frac{1}{n}\mathbf{1}_n^\top y = \frac{1}{n}\mathbf{1}_n^\top\Big[\Big(\mathbf{1}_n, \mathbf{X}_c\Big)\eta + \varepsilon\Big] = \eta_0 + \frac{1}{n}\mathbf{1}_n^\top\varepsilon.$$

$$\begin{aligned}
(\hat{\eta}_1, \hat{\eta}_2, \cdots, \hat{\eta}_m)^\top &= (\mathbf{X}_c^\top\mathbf{X}_c)^{-1}\tilde{\mathbf{X}}_c^\top y \\
&= (\mathbf{X}_c^\top\mathbf{X}_c)^{-1}\mathbf{X}_c^\top\Big(\mathbf{1}_n \vdots \mathbf{X}_c\Big)\eta + (\mathbf{X}_c^\top\mathbf{X}_c)^{-1}\mathbf{X}_c^\top\varepsilon \\
&= (\mathbf{X}_c^\top\mathbf{X}_c)^{-1}\mathbf{X}_c^\top\mathbf{X}_c(\eta_1, \eta_2, \cdots, \eta_m)^\top + (\mathbf{X}_c^\top\mathbf{X}_c)^{-1}\mathbf{X}_c^\top\varepsilon \\
&= (\eta_1, \eta_2, \cdots, \eta_m)^\top + (\mathbf{X}_c^\top\mathbf{X}_c)^{-1}\mathbf{X}_c^\top\varepsilon.
\end{aligned}$$

由定理8.6及$(\mathbf{X}_c^\top\mathbf{X}_c)^{-1}\mathbf{X}_c^\top\mathbf{1}_n = \mathbf{0}_{m+1}$和第三章多元正态分布分布性质6得证。

从这个定理我们可以看到中心化的作用，它不仅仅把回归常数项η和回归系数β 的最小二乘有分离的简洁表达式，而且当误差服从正态分布时，两者的估计也是相互独立的。

例8.3 针对正态线性回归模型(8.4), 记最小二乘估计为$\hat{\beta}$, 残差平方和为RSS. 求证：

$$\frac{n-m-1}{RSS}(\hat{\beta} - \beta)^\top(\mathbf{X}^\top\mathbf{X})(\hat{\beta} - \beta) \xrightarrow{d} \chi^2_{m+1}.$$

证明：由定理8.7知

$$\sigma^{-1}(\mathbf{X}^\top\mathbf{X})^{\frac{1}{2}}(\hat{\beta} - \beta) \sim N\big(\mathbf{0}_{m+1}, \mathbf{I}_{m+1}\big),$$

$$E\Big(\frac{RSS}{n-m-1}\Big) = \sigma^2,$$

$$\begin{aligned}
\mathrm{var}\Big(\tfrac{RSS}{n-m-1}\Big) &= \mathrm{var}\Big(\frac{RSS}{\sigma^2}\frac{\sigma^2}{n-m-1}\Big) \\
&= \frac{\sigma^4}{(n-m-1)^2}\mathrm{var}\Big(\frac{RSS}{\sigma^2}\Big) \\
&= \frac{\sigma^4}{(n-m-1)^2}\times 2(n-m-1) \\
&= \frac{2\sigma^4}{n-m-1} \\
&\overset{n\to\infty}{\longrightarrow} 0.
\end{aligned}$$

由第六章第6.3节定理6.7知$\frac{RSS}{n-m-1}$是σ^2的相合估计。由χ^2分别的定义知

$$\sigma^{-2}(\hat{\beta}-\beta)^\top(\mathbf{X}^\top\mathbf{X})(\hat{\beta}-\beta)\sim\chi^2_{m+1}.$$

最后由Slustsky定理知

$$\frac{n-m-1}{RSS}(\hat{\beta}-\beta)^\top(\mathbf{X}^\top\mathbf{X})(\hat{\beta}-\beta)\xrightarrow{d}\chi^2_{m+1}.$$

7.4. 模型系数的检验

利用最小二乘法得到回归系数的估计，建立了经验回归方程

$$Y = \hat{\beta}_0 + X_1\hat{\beta}_1 + X_2\hat{\beta}_2 + \cdots + X_m\hat{\beta}_m.$$

经验回归方程是否真实地反映因变量和自变量之间的关系呢？我们需要对回归方程整体做假设检验。回归方程显著，表明至少有一个自变量与因变量相关，进而，还需要进一步找到哪些自变量与因变量相关，需要对回归系数逐个地进行检验。本节主要在正态线性模型下考察回归方程和回归系数的假设检验。

回归方程的假设检验

假设检验问题为

$$H_0 : \beta_1 = \beta_2 = \cdots = \beta_m = 0 \leftrightarrow H_1 : \text{至少存在一个}\beta_j \neq 0, j = 1, 2, \cdots, m.$$

H_0成立时，说明自变量$X_1, X_2, \cdots, X_m$对因变量Y都没有显著的影响，此时应该考虑选择的自变量是否恰当，是否还有一些重要的对因变量有显著影响的自变量没有考虑到模型中。如果拒绝原假设，则说明至少有一个自变量与Y有线性相关关系。记H_0成立时的残差平方和为

$$RSS_{H_0} = (y - \bar{y})^\top (y - \bar{y}).$$

H_1成立时的残差平方和为

$$RSS_{H_1} = y^\top [\mathbf{I}_n - \mathbf{H}]y.$$

检验统计量为

$$T = \frac{\big(RSS_{H_0} - RSS_{H_1}\big)/m}{RSS_{H_1}/(n - m - 1)}.$$

当H_0成立时，

$$T \sim F_{m,n-m-1}.$$

给定T的观测值t_0, 可通过$\int_{t_0}^{\infty} f_{m,n-m-1}(u)du$来计算统计量的$p$-值，其中$f_{m,n-m-1}(u)$为自由度为$m$ 和$n - m - 1$ 的F分布的密度函数。给定显著性水平α, 当p-值小于α时，拒绝H_0, 反之接受H_0.

回归系数的假设检验

如果回归方程是显著的，需要进一步确定哪些回归自变量对于因变量的影响是显著的。因此需要对每个回归自变量的系数逐一做检验。对$j = 1, 2, \cdots, m$, 假设检验问题为

$$H_{j0} : \beta_j = 0 \leftrightarrow H_{j1} : \beta_j \neq 0.$$

当样本量n较大时，有

$$\sqrt{\frac{n - m - 1}{RSS}}(\mathbf{X}^\top \mathbf{X})^{\frac{1}{2}}(\hat{\beta} - \beta) \xrightarrow{d} N\big(\mathbf{0}_{m+1}, \mathbf{I}_{m+1}\big).$$

记

$$\frac{RSS}{n-m-1}(\mathbf{X}^\top\mathbf{X})^{-1}=(\delta_{k_1,k_2})_{(m+1)\times(m+1)}.$$

检验统计量为

$$T_j=\frac{\hat{\beta}_j}{\sqrt{\delta_{j+1,j+1}}}.$$

当零假设成立时，即$\beta_j=0$, $T_j\xrightarrow{d}N(0,1)$. 给定T_j的观测值t_j, p-值为

$$p_j=2\big[1-\Phi(|t_j|)\big].$$

给定显著性水平α, 当$p_j<\alpha$时, 拒绝H_{0j}, 反之接受H_{0j}. 接受零假设$\beta_j=0$, 认为回归自变量X_j对因变量Y无显著的影响，可将其从回归模型中剔除，剔除不显著的自变量，对剩下的自变量与因变量重新建立线性回归模型。

除了上面介绍的一次性剔除所有不显著的自变量外，还有一种逐步回归的方法，该方法的基本思想是：首先剔除最不显著的自变量(对应回归系数检验的p-值最大的自变量)；然后对剩下的$m-1$个自变量对因变量建立线性回归模型，再做回归系数的显著性检验；接着剔除余下的$m-1$ 个自变量中最不显著的自变量，如此下去，直到所有的自变量都显著为止。

例8.4 考察一元线性回归模型

$$y_i=\beta_0+z_i\beta_1+\varepsilon_i,\ i=1,2,\cdots,n,$$

其中$\varepsilon_1,\varepsilon_2,\cdots,\varepsilon_n\ iid\ \sim N(0,\sigma^2)$. 试给出假设检验问题

$$H_0:\beta_1=0\leftrightarrow H_1:\beta_1\neq 0$$

的一个水平为α的检验, $0<\alpha<1$.

解： 由于是一元线性回归模型，这是回归方程的检验。记

$$\bar{y}=\frac{1}{n}\sum_{i=1}^{n}y_i,\bar{z}=\frac{1}{n}\sum_{i=1}^{n}z_i,$$

β_1的最小二乘估计为

$$\hat{\beta}_1=\frac{\sum\limits_{i=1}^{n}(z_i-\bar{z})(y_i-\bar{y})}{\sum\limits_{i=1}^{n}(z_i-\bar{z})^2},$$

y_i的拟合值为

$$\hat{y}_i=\bar{y}+z_i\hat{\beta}_1,i=1,2,\cdots,n.$$

当H_0成立时，残差平方和为

$$RSS_{H_0}=\sum_{i=1}^{n}(y_i-\bar{y})^2.$$

当H_1成立时，残差平方和为

$$RSS_{H_1} = \sum_{i=1}^{n}(y_i - \hat{y}_i)^2.$$

检验统计量为

$$T = \frac{RSS_{H_0} - RSS_{H_1}}{RSS_{H_1}/(n-2)}.$$

当H_0成立时，$T \sim F_{1,n-2}$. 给定T的观测值t, 我们可以计算检验的p-值，p-值小于α时，拒绝零假设，认为$\beta_1 \neq 0$; 反之，接受零假设，认为$\beta_1 = 0$.

下面进一步计算T.

$$\begin{aligned}
RSS_{H_0} - RSS_{H_1} &= \sum_{i=1}^{n}(y_i - \bar{y})^2 - \sum_{i=1}^{n}(y_i - \hat{y}_i)^2 \\
&= \sum_{i=1}^{n}(y_i - \bar{y})^2 - \sum_{i=1}^{n}[y_i - \bar{y} - (\hat{y}_i - \bar{y})]^2 \\
&= 2\sum_{i=1}^{n}(y_i - \bar{y})(\hat{y}_i - \bar{y}) - \sum_{i=1}^{n}(\hat{y}_i - \bar{y})^2 \\
&= 2\hat{\beta}_1 \sum_{i=1}^{n}(y_i - \bar{y})(z_i - \bar{z}) - \hat{\beta}_1^2 \sum_{i=1}^{n}(z_i - \bar{z})^2 \\
&= \hat{\beta}_1^2 \sum_{i=1}^{n}(z_i - \bar{z})^2
\end{aligned}$$

$$T = \frac{\hat{\beta}_1^2 \sum_{i=1}^{n}(z_i - \bar{z})^2}{RSS_{H_1}/(n-2)} = \left(\hat{\beta}_1 \Big/ \sqrt{\frac{RSS_{H_1}}{n-2} \frac{1}{\sum_{i=1}^{n}(z_i - \bar{z})^2}} \right)^2$$

记$\mathbf{X}^\top = \begin{pmatrix} 1 & 1 & \cdots & 1 \\ z_1 & z_2 & \cdots & z_n \end{pmatrix}$. 有$\mathbf{X}^\top\mathbf{X} = \begin{pmatrix} n & \sum_{i=1}^{n} z_i \\ \sum_{i=1}^{n} z_i & \sum_{i=1}^{n} z_i^2 \end{pmatrix}$,

$$(\mathbf{X}^\top\mathbf{X})^{-1} = \frac{1}{n\sum_{i=1}^{n}(z_i - \bar{z})^2} \begin{pmatrix} \sum_{i=1}^{n} z_i^2 & -\sum_{i=1}^{n} z_i \\ -\sum_{i=1}^{n} z_i & n \end{pmatrix} = \begin{pmatrix} \frac{\frac{1}{n}\sum_{i=1}^{n} z_i^2}{\sum_{i=1}^{n}(z_i - \bar{z})^2} & -\frac{\bar{z}}{\sum_{i=1}^{n}(z_i - \bar{z})^2} \\ -\frac{\bar{z}}{\sum_{i=1}^{n}(z_i - \bar{z})^2} & \frac{1}{\sum_{i=1}^{n}(z_i - \bar{z})^2} \end{pmatrix}$$

根据定理8.7, 知$\hat{\beta}_1 \sim N\Big(\beta_1, \sigma^2 \frac{1}{\sum_{i=1}^{n}(z_i - \bar{z})^2}\Big)$, 且$\frac{RSS_{H_1}}{\sigma^2} \sim \chi^2_{n-2}$, 从而当$H_0$成立时，

$$\frac{\hat{\beta}_1}{\sqrt{\frac{RSS_{H_1}}{n-2} \frac{1}{\sum_{i=1}^{n}(z_i - \bar{z})^2}}} \sim t_{n-2}.$$

即$T \sim t^2_{n-2} = F_{1,n-2}$.

7.5. 预测

建立线性回归模型的一个重要目的是给定自变量取某个或某些取值后，可以直接对因变量的值进行估计，而不需要测量来了解因变量的值，这是预测问题。如在工业生产领域，线性模型中的自变量可代表一组试验的条件，由于试验的经费有限，我们希望有了经验模型之后，为节省成本，一些试验可以不用去做，就能知道因变量可能的取值或者取值范围。预测问题是建立线性模型的重要应用之一。

对于正态线性模型

$$y = \mathbf{X}\beta + \varepsilon, \varepsilon \sim N(\mathbf{0}_n, \sigma^2\mathbf{I}_n).$$

假定我们知道一组自变量的取值x_0(其中x_0是$m+1$维向量且第1个元素为1), 要预测其对应的因变量值y_0, y_0可表示为

$$y_0 = x_0^\top\beta + \varepsilon_0,$$

其中$\varepsilon_0 \sim N(0, \sigma^2)$, 且与$\varepsilon_i, i = 1, 2, \cdots, n$相互独立。

为预测y_0, 我们用$x_0^\top\hat{\beta}$去估计$x_0^\top\beta$. 由于ε_0是均值为0的随机变量，我们用0预测它。于是y_0的预测值为

$$\hat{y}_0 = x_0^\top\hat{\beta}.$$

这是y_0的点预测。

定理8.9. 针对预测量$\hat{y}_0$, 有
(i)$E\hat{y}_0 = Ey_0$, 即预测量与被预测量具有相同的均值；
(ii)在y_0的一切线性无偏预测中，$\hat{y}_0$具有最小方差。

证明： (i)$E\hat{y}_0 = E(x_0^\top\hat{\beta}) = x_0^\top E(\hat{\beta}) = x_0^\top\beta = Ey_0$.

(ii)由于$\hat{y}_0 = x_0^\top\hat{\beta}$, 根据Gauss-Markov定理，$\hat{y}_0$是最优线性无偏估计，即在所有线性无偏估计中方差最小。若进一步假定$\varepsilon_0 \sim N(0, \sigma^2)$, 根据定理8.6, $\hat{y}_0$是UMVUE，即在所有无偏估计中方差最小。

下面我们考虑y_0的区间预测。由于$x_0^\top\hat{\beta}$和y_0均服从正态分布，且$x_0^\top\hat{\beta}$只依赖于$y_1, y_2, \cdots, y_n$. 故$x_0^\top\hat{\beta}$与y_0独立。我们有

$$\hat{y}_0 - y_0 \sim N(0, \sigma^2[x_0^\top(\mathbf{X}^\top\mathbf{X})^{-1}x_0]),$$

$$\frac{\hat{y}_0 - y_0}{\sqrt{\sigma^2[x_0^\top(\mathbf{X}^\top\mathbf{X})^{-1}x_0]}} \sim N(0, 1).$$

由定理8.7知$\hat{\beta}$与RSS独立，y_0与RSS独立。进而，$\hat{y}_0 - y_0$与RSS相互独立，且

$$\frac{RSS}{\sigma^2} \sim \chi^2_{n-m-1},$$

由t分布的定义知

$$\frac{(\hat{y}_0 - y_0)/\sqrt{x_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} x_0}}{\sqrt{RSS/(n-m-1)}} \sim t_{n-m-1}.$$

给定显著性水平α, y_0的置信水平为$1-\alpha$ 的区间预测为

$$\left[\hat{y}_0 - t_{n-m-1}(1-\alpha/2)\sqrt{\frac{RSS\times[x_0^\top (X^\top X)^{-1}x_0]}{n-m-1}},\right.$$
$$\left.\hat{y}_0 + t_{n-m-1}(1-\alpha/2)\sqrt{\frac{RSS\times[x_0^\top (X^\top X)^{-1}x_0]}{n-m-1}}\right].$$

例8.5 考察一元线性回归模型

$$y_i = \beta_0 + z_i\beta_1 + \varepsilon_i,\ i = 1, 2, \cdots, n,$$

其中$\varepsilon_1, \varepsilon_2, \cdots, \varepsilon_n\ iid\ \sim N(0, \sigma^2)$. 给定$z_0$时，试给出$y_0$的点预测和置信水平为$1-\alpha$的区间预测。

解： 由例8.1知，β_0, β_1的最小二乘估计为

$$\begin{cases} \hat{\beta}_0 = \bar{y} - \bar{z}\hat{\beta}_1, \\ \hat{\beta}_1 = \dfrac{\sum\limits_{i=1}^n z_i y_i - n\bar{z}\bar{y}}{\sum\limits_{i=1}^n z_i^2 - n\bar{z}^2} = \dfrac{\sum\limits_{i=1}^n (z_i - \bar{z})(y_i - \bar{y})}{\sum\limits_{i=1}^n (z_i - \bar{z})^2}. \end{cases}$$

y_0的点预测为

$$\hat{y}_0 = \hat{\beta}_0 + z_0\hat{\beta}_1.$$

记

$$RSS = \sum_{i=1}^n (y_i - \hat{\beta}_0 - z_i\hat{\beta}_1)^2.$$

y_0的置信水平为$1-\alpha$的预测区间为

$$\left[\hat{y}_0 - t_{n-2}(1-\alpha/2)\sqrt{\frac{RSS}{n-2}\left[\frac{1}{n} + \frac{(z_0-\bar{z})^2}{\sum\limits_{i=1}^n (z_i-\bar{z})^2}\right]},\right.$$
$$\left.\hat{y}_0 + t_{n-2}(1-\alpha/2)\sqrt{\frac{RSS}{n-2}\left[\frac{1}{n} + \frac{(z_0-\bar{z})^2}{\sum\limits_{i=1}^n (z_i-\bar{z})^2}\right]}\right].$$

例8.6 现有一组关于关于自变量X和响应变量Y的观测数据:

X	-0.72	0.88	-1.94	-0.87	0.083	0.54	-0.71	-2.55	1.98	0.54
Y	-0.061	1.55	-0.97	-0.42	0.55	0.93	-0.23	-1.61	2.02	0.73.

假设随机误差项服从$N(0, \sigma^2)$, σ^2未知。试画出散点图，建立一元线性回归方程，并给出回归方程X的系数的显著性检验，基于建立的回归方程给出X的新观测值$x_0 = 0.8$对应响应变量Y的预测值和95%的预测区间。

解： 记搜集到的数据为$(x_i, y_i), i = 1, 2, \cdots, 10$, 在平面直角坐标系中绘制散点图，如图8.2. 从散点图可以看到这10个点基本在一条直线附近，说明Y和X有

线性相关关系。建立一元线性回归模型

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i,\ i = 1, 2, \cdots, 10,$$

其中$\varepsilon_1, \varepsilon_2, \cdots, \varepsilon_{10}\ iid\ \sim N(0, \sigma^2)$.

计算得到

$$\bar{x} = \frac{1}{10}\sum_{i=1}^{10} x_i = -0.277, \bar{y} = \frac{1}{10}\sum_{i=1}^{10} y_i = 0.249,$$

$$l_{xx} = \sum_{i=1}^{10}(x_i - \bar{x})^2 = 16.565, l_{yy} = \sum_{i=1}^{10}(y_i - \bar{y})^2 = 11.330,$$

$$l_{xy} = \sum_{i=1}^{10}(x_i - \bar{x})(y_i - \bar{y}) = 13.554.$$

由例8.1知，β_1, β_0的最小二乘估计为

$$\hat{\beta}_1 = \frac{l_{xy}}{l_{xx}} \approx 0.818,\ \ \hat{\beta}_0 = \bar{y} - \bar{x}\hat{\beta}_1 \approx 0.476.$$

经验线性回归方程为

$$\hat{y} = 0.476 + 0.818x.$$

针对检验问题：

$$H_0 : \beta_1 = 0 \leftrightarrow H_1 : \beta_1 \neq 0$$

可计算在H_1下的残差平方和为$RSS_{H_1} = \sum\limits_{i=1}^{10}(y_i - \hat{y}_i)^2 = 0.239$, 由例8.4的最后两行，可得$t$-检验的统计量的值为

$$T = \frac{\hat{\beta}_1}{\sqrt{\frac{RSS_{H_1}}{10-2}\frac{1}{\sum\limits_{i=1}^{10}(x_i-\bar{x})^2}}} = \frac{\hat{\beta}_1}{\sqrt{\frac{RSS_{H_1}}{8l_{xx}}}} \approx 19.262,$$

若取显著性水平$\alpha = 0.05$, 则$t_8(0.975) = 2.306$, 由于$T > t_8(0.975)$, 落入拒绝域，则说明回归系数是显著的，即自变量X对因变量Y有显著的影响。

由例8.5，将新观测值$x_0 = 0.8$代入一元线性回归方程，得到响应变量Y的预测值为

$$\hat{y}_0 = 0.476 + 0.818 \times 0.8 \approx 1.130,$$

由于$t_8(0.975)\sqrt{\frac{RSS_{H_1}}{10-2}\left[\frac{1}{10} + \frac{(x_0-\bar{x})^2}{\sum\limits_{i=1}^{10}(x_i-\bar{x})^2}\right]} \approx 0.164$, 则响应变量$Y$的95%的预测区间为$[\hat{y}_0 - 0.164, \hat{y}_0 + 0.164]$, 即为$[0.966, 1.294]$.

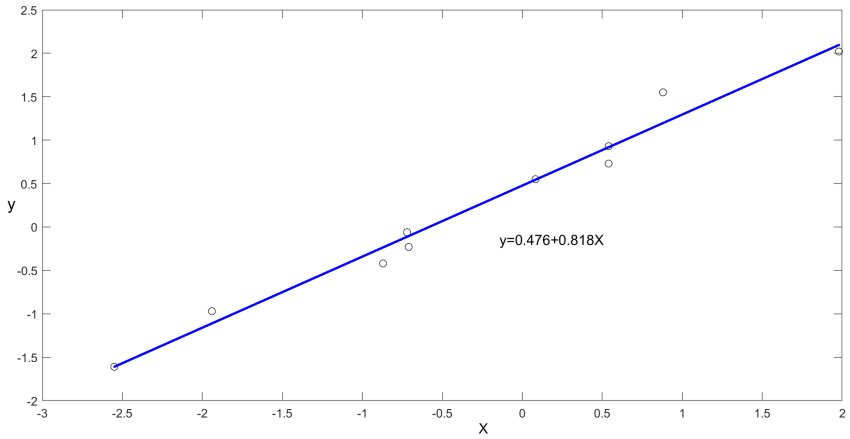


图8.2 散点图。

习题八

1. 考察一般线性回归模型(8.1). 求证：$E\|\hat{\beta}-\beta\|^2=\sigma^2\sum\limits_{i=1}^{n}\frac{1}{\lambda_i}$, 其中$\lambda_i$是$\mathbf{X}^\top\mathbf{X}$的特征值。

2. 考察一元线性回归模型

$$y_i=\beta x_i+\varepsilon_i,\ \ i=1,2,\cdots,n,$$

其中$\varepsilon_1,\varepsilon_2,\cdots,\varepsilon_n\ iid\sim N(0,\sigma^2)$, $\sigma^2>0$未知。
(1)求β的最小二乘估计$\hat{\beta}$, 及σ^2的无偏估计$\hat{\sigma}^2$;
(2)求证：$\hat{\beta}\sim N(\beta,\sigma^2/\sum\limits_{i=1}^{n}x_i^2)$;
(3)记残差平方和为$RSS=\sum\limits_{i=1}^{n}(y_i-\hat{\beta}x_i)^2$. 求证：$\frac{RSS}{\sigma^2}\sim\chi^2_{n-1}$及$RSS$与$\hat{\beta}$独立;
(4)给出假设检验问题

$$H_0:\beta=0\leftrightarrow H_1:\beta\neq 0$$

的一个水平为α的检验，$0<\alpha<1$.

3. 有n对独立观测的数据$(x_i,y_i),i=1,2,\cdots,n$. 分别以x_i 为自变量y_i为因变量和y_i为自变量x_i为因变量建立一元线性回归方程。问两者的回归系数有何差别?

4. 现有自变量X和因变量Y的10组观测值：

X	3.1	1.6	2.5	1.4	1.2	2.2	2.8	2.2	1.3	1.7
Y	3.69	2.07	3.08	1.62	1.45	2.51	3.51	2.94	1.65	2.34

试绘制散点图，并给出y与x之间的经验回归方程。

5. 令一元线性回归模型为

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, i = 1, 2, \cdots, 26,$$

其中$\varepsilon_1, \varepsilon_2, \cdots, \varepsilon_{26}$ $iid \sim N(0, \sigma^2)$, $\sigma^2 > 0$ 未知。记$\bar{x}$和$\bar{y}$分别为自变量和因变量的样本均值, S_1^2和S_2为它们的样本方差, r是它们之间的样本相关系数。经计算，

$$\bar{x} = 1,\ \bar{y} = 10,\ S_1^2 = 0.8,\ S_2^2 = 1.2,\ r = 0.8.$$

核对时，发现有一组数据记录错误，正确数据为$(1.5, 8.5)$, 记录为$(2.2, 12.3)$. 求β_0, β_1的最小二乘估计。

6. 对于正态线性回归模型(8.4), 记$\hat{\beta} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1}\mathbf{X}^\top y$, $\hat{\sigma}^2 = \|y - \mathbf{X}\hat{\beta}\|^2/(n - m - 1)$. (1)求$\hat{\sigma}^2$的期望和方差。(2)求证：$var\left(\hat{\beta}_j\right) \geq \frac{\sigma^2}{\tilde{x}_j^\top \tilde{x}_j}$, $\quad 2 \leq j \leq m+1$, 其中$\tilde{x}_j$表示$\mathbf{X}$的第$j+1$ 列, 等号成立当且仅当$\tilde{x}_{j_1}^\top \tilde{x}_{j_2} = 0$对一切$j_1 \neq j_2 \in \{2, 3, \cdots, m+1\}$.

7. 对习题4, 试给出模型系数是否为0的一个水平为α的检验, $0 < \alpha < 1$.

8. 对习题4, 记X的新观测的值为2, 求其对应的因变量的预测值和置信水平为95%的预测区间。

参考文献

1. 陈希孺. 《概率论与数理统计》，中国科学技术大学出版社，2009.
2. 陈家鼎，郑忠国. 《概率与统计》，北京大学出版社，2007.
3. 苏淳、冯群强. 《概率论》，科学出版社，2020.
4. 复旦大学编著. 《概率论第一册概率论基础》，高等教育出版社，1987.
5. 河北科技大学数学系. 《概率论与数理统计学习指导与习题全解》，中国标准出版社，2009.
6. 华中科技大学数学系. 《概率论与数理统计学习辅导与习题全解》，高等教育出版社，2013.
7. 李松岗. 《实用生物统计》，北京大学出版社，2004.
8. 茆诗松，程依明，濮晓龙. 《概率论与数理统计教程》，高等教育出版社，2017.
9. 茆诗松，程依明，濮晓龙. 《概率论与数理统计教程习题与解答》，高等教育出版社，2017.
10. 茆诗松，王静龙，濮晓龙. 《高等数理统计》，高等教育出版社，2010.
11. 牛丽英，陈勇. 《概率论与数理统计同步辅导及习题全解》，中国水利水电出版社，2016.
12. 盛骤、谢式千，潘承毅. 《概率论与数理统计》，高等教育出版社，2021.
13. 孙清华，孙昊. 《概率论与数理统计疑难分析与解答方法》，华中科技大学出版社，2009.
14. 王松桂，陈敏，陈立萍. 《线性统计模型– 线性回归与方差分析》，高等教育出版社，1999.
15. 魏宗舒等. 《概率论与数理统计教程》，高等教育出版社，2016.
16. 吴赣昌主编. 《概率论与数理统计学习辅导与习题解答》理工类第四版，中国人民大学出版社，2017.
17. 谢琍、尹素菊、陈立萍、李寿梅. 《概率论与数理统计解题指导》，北京大学出版社，2004.
18. 薛留根. 《概率统计问题与思考》，科学出版社，2010.
19. 郑忠国，童兴伟，赵慧. 《高等统计学》，北京大学出版社，2012.
20. 中国科学技术大学国家级精品课程《概率论与数理统计》，2009.
21. 韦博成. (2011). 漫谈统计学的应用与发展(4). 数学统计与管理30(4)：671-685.